

Magdalena Osińska

Ekonometria finansowa

Polskie
Wydawnictwo
Ekonomiczne
Warszawa 2006

Recenzent
Prof. dr hab. Aleksander Zeliaś

Projekt okładki i stron tytułowych
Maciej W. Kucharczuk

Redaktor
Krzyszyna Leciak

Redaktor techniczny
Jolanta Czapska

Redakcja
Halina Wieczorek

Wydawnictwo akademickie dotowany przez Ministerstwo Edukacji Narodowej i Sportu

Copyright by Polskie Wydawnictwo Ekonomiczne S.A.
Warszawa 2006

ISBN 83-208-1581-9

Polskie Wydawnictwo Ekonomiczne S.A.
ul. Chałubińskiego 4, 00-099 Warszawa
tel. (centrala) (0-22) 827-80-01, faks 827-55-67
e-mail: pwe@pwe.com.pl
http://www.pwe.com.pl

Skład i łamanie: FOTOSKLAD Pracownia Poligraficzna
ul. Czarnasza 16/18, 02-169 Warszawa
druk i oprawa: Wojskowa Drukarnia w Łodzi

Spis treści

Od autora	9
Wprowadzenie	13

CZĘŚĆ PIERWSZA

Rozdział 1. Charakterystyka finansowych szeregów czasowych	21
1.1. Finansowe szeregi czasowe i ich charakterystyki	21
1.2. Analiza rozkładów stóp zwrotu	26
1.3. Hipoteza rynku efektywnego w świetle analizy ekonometrycznej ...	30
1.4. Hipoteza racjonalnych oczekiwań	32
1.5. Metody weryfikacji hipotezy słabej efektywności rynku	34
1.6. Efektywność rynków a efekty kalendarzowe	43
Pytania i problemy	46
Rozdział 2. Modele jednowymiarowych szeregów czasowych	47
2.1. Procesy stochastyczne i szeregi czasowe	47
2.2. Modele stacjonarnych procesów stochastycznych	49
2.3. Identyfikacja modeli ARMA(p, q)	51
2.4. Estymacja parametrów modeli ARMA(p, q)	55
2.5. Prognozowanie na podstawie modeli ARMA(p, q)	56
2.6. Niestacjonarne procesy stochastyczne i ich modele	60
2.6.1. Modele procesów niestacjonarnych w zakresie wartości średniej	60
2.6.2. Modele procesów niestacjonarnych w zakresie wariancji oraz	
funkcji kowariancyjnej	62
2.7. Identyfikacja procesów niestacjonarnych w zakresie wariancji	68
2.7.1. Podstawowe testy na obecność pierwiastka jednostkowego ..	68
2.7.2. Testowanie pierwiastków jednostkowych w przypadku zmiany	
strukturalnej	72
2.7.3. Testowanie sezonowych pierwiastków jednostkowych	75
2.8. Modele procesów ułamkowo zintegrowanych ARFIMA(p, d, q) ...	76
Pytania i problemy	78

Rozdział 3. Jednowymiarowe modele zmienności	79
3.1. Cechy analizy krótkookresowej	79
3.2. Podstawowy model ARCH	81
3.3. Uogólniony model ARCH Bollersleva (GARCH)	84
3.3.1. Równoważna reprezentacja modelu GARCH	86
3.3.2. Stacjonarność modelu GARCH(q, p)	86
3.4. Model GARCH-in-mean	88
3.5. Inne modele klasy ARCH (GARCH)	90
3.5.1. Modele GARCH z asymetrią	90
3.5.2. Modele GARCH z rozkładem innym niż normalny	91
3.6. Estymacja parametrów modeli GARCH i ocena ich jakości	92
3.7. Prognozowanie na podstawie modeli GARCH	94
3.8. Procesy zmienności stochastycznej (SV)	95
3.9. Analiza danych o ultrawysokiej częstotliwości i mikrostruktura rynku	97
3.9.1. Model niesynchronicznych transakcji	98
3.9.2. Autoregresyjny model warunkowego czasu trwania między transakcjami	100
3.9.3. Empiryczna charakterystyka danych obserwowanych w czasie transakcyjnym	102
3.10. Zastosowania modeli zmienności	103
3.10.1. Model równowagi rynku CAPM i proces ARCH	103
3.10.2. Wykorzystanie ekonometrycznych modeli GARCH do wyznaczenia wartości zagrożonej	104
3.10.3. Porównanie empirycznych modeli ARCH/GARCH dla stóp zmian indeksu WIG oraz kontraktów futures	111
3.10.4. Prognozowanie na podstawie modeli GARCH	115
Pytania i problemy	116
Rozdział 4. Wybrane nieliniowe modele szeregów czasowych	117
4.1. Nieliniowość w procesach finansowych	118
4.2. Jednorównaniowe modele nieliniowe szeregów czasowych	120
4.2.1. Charakterystyka nieliniowych modeli szeregów czasowych	120
4.2.2. Wybrane modele nieliniowe	121
4.2.3. Kryteria wyboru funkcji nieliniowej	127
4.3. Stacjonarność i stabilność w przypadku modeli nieliniowych	128
4.4. Testowanie nieliniowości	129
4.5. Estymacja i prognozowanie na podstawie modeli progowych	133
4.5.1. Estymacja modeli nieliniowych TAR	133
4.5.2. Prognozowanie na podstawie modeli progowych	135
4.6. Zastosowanie modeli TAR do opisu finansowych szeregów czasowych	136
Pytania i problemy	138

Rozdział 5. Modele szeregów czasowych z losowymi parametrami i reprezentacja przestrzeni stanów	139
5.1. Reprezentacja przestrzeni stanów	139
5.2. Modele autoregresyjne z losowymi parametrami	143
5.3. Filtr Kalmana jako narzędzie estymacji parametrów przestrzeni stanów	146
5.4. Testowanie stabilności ocen parametrów	147
5.5. Procesy zawierające stochastyczne pierwiastki jednostkowe	148
5.5.1. Własności procesów zawierających pierwiastki jednostkowe	148
5.5.2. Testowanie stochastycznych pierwiastków jednostkowych	150
5.5.3. Zastosowania empiryczne modeli ze stochastycznym pierwiastkiem jednostkowym	152
5.6. Wybrane modele zmienności w zapisie przestrzeni stanów	154
Pytania i problemy	155
Rozdział 6. Analiza szeregów czasowych w dziedzinie częstości	156
6.1. Podstawy analizy spektralnej szeregów czasowych	157
6.1.1. Estymacja funkcji gęstości spektralnej	160
6.1.2. Okno spektralne	162
6.1.3. Weryfikacja istotności poszczególnych częstości	165
6.2. Analiza spektralna stóp zwrotu z akcji i ich portfeli	166
6.3. Wykorzystanie analizy spektralnej do testowania rzędu integracji szeregów czasowych	168
6.3.1. Zastosowanie funkcji gęstości spektralnej w testowaniu pierwiastków jednostkowych	168
6.3.2. Identyfikacja szeregów ułamkowo zintegrowanych	169
6.4. Podstawy dekompozycji falkowej	171
Pytania i problemy	174

SPIS TREŚCI

Rozdział 7. Modele regresji w analizie finansowych szeregów czasowych	179
7.1. Modele regresji liniowej dla procesów stacjonarnych	180
7.2. Modele regresji liniowej dla procesów niestacjonarnych	183
7.2.1. Niestacjonarność w wartości średniej procesu	183
7.2.2. Kointegracja procesów stochastycznych	184
7.2.3. Testowanie kointegracji szeregów czasowych	187
7.2.4. Jednorównaniowy model korekty błędem	188
7.3. Wykorzystanie modeli regresji w analizach finansowych	192
7.3.1. Model pojedynczego indeksu	192
7.3.2. Model wyceny arbitrażowej	194
7.4. Racjonalne bąble spekulacyjne	197
7.5. Porównywanie modeli niezagnieżdżonych	202
Pytania i problemy	203

Rozdział 8. Analiza wielowymiarowych szeregów czasowych	204
8.1. Reprezentacja modelowa wielowymiarowych procesów stochastycznych	205
8.2. Analiza strukturalna w modelu VAR	208
8.2.1. Badanie zależności przyczynowych opisywanych przez model VAR	208
8.2.2. Analiza egzogeniczności w modelu VAR	213
8.2.3. Analiza odpowiedzi na impuls	215
8.3. Model VAR dla procesów skointegrowanych (VEC)	216
8.3.1. Wektorowy model korekty błędem	216
8.3.2. Testowanie kointegracji w modelach VAR	218
8.4. Estymacja parametrów modeli VAR	219
8.5. Empiryczne modele wielowymiarowe finansowych szeregów czasowych	220
8.6. Reprezentacja spektralna wielowymiarowych szeregów czasowych	223
Pytania i problemy	226
Rozdział 9. Wielowymiarowe modele GARCH	227
9.1. Ogólna postać wielorównaniowego modelu GARCH(p, q)	228
9.2. Model stałych warunkowych korelacji	229
9.3. Modele ze zmienną w czasie korelacją	230
9.3.1. Model BEKK i jego własności	231
9.3.2. Wielowymiarowe modele GARCH z rozkładem t -Studenta	232
9.4. Testowanie stałości korelacji	234
9.5. Testowanie przyczynowości w zakresie wariancji	236
9.6. Zastosowania wielowymiarowych modeli GARCH	238
Pytania i problemy	241
Bibliografia	242
Indeks	253

Od autora

Prezentowany podręcznik został podzielony na dwie części. W pierwszej, obejmującej rozdziały 1–6, skupiono się zasadniczo na analizie jednowymiarowych szeregów czasowych, opisujących dynamikę zjawisk finansowych bez odwoływania się do przyczyn tych zjawisk. Z kolei druga, do której należą rozdziały 7–9, obejmuje jednorównaniowe modele regresji, wielorównaniowe modele VAR oraz wielorównaniowe modele GARCH. Postaci tych modeli pozwalają, jeżeli to możliwe, na analizę współzależności między zjawiskami finansowymi, a także między innymi procesami, zwłaszcza fundamentalnymi, będącymi punktami odniesienia dla wielu zdarzeń zachodzących na rynkach finansowych. Struktura taka pozwoliła, jak się wydaje, na uporządkowanie zagadnień ekonometrycznych według określonego klucza.

W rozdziale pierwszym scharakteryzowano finansowe szeregi czasowe, takie jak stopy zwrotu z inwestycji, ryzyko inwestycyjne oraz rozkłady stóp zwrotu. Omówiono hipotezę efektywności informacyjnej rynku oraz hipotezę racjonalnych oczekiwań. Przedstawiono wybrane metody weryfikacji hipotezy słabej efektywności rynków finansowych oraz problematykę opisu i weryfikacji efektów kalendarzowych.

Przedmiotem rozdziału drugiego są modele jednowymiarowych szeregów czasowych opisujące ich warunkową wartość oczekiwaną. Skoncentrowano się zwłaszcza na zdefiniowaniu procesu stochastycznego i szeregu czasowego, a także przedstawieniu liniowych modeli stacjonarnych i niestacjonarnych szeregów czasowych. Omówiono następujące modele: ARMA, ARIMA, SARIMA, a także wybrane metody ich identyfikacji w empirycznych szeregach czasowych. Wiele miejsca poświęcono testowaniu pierwiastków jednostkowych: zwykłych, sezonowych oraz powiązanych z pojedynczą zmianą strukturalną. Osobny podrozdział poświęcono modelom zintegrowanym w stopniu ułamkowym (ARFIMA), które umożliwiają modelowanie długiej pamięci szeregów czasowych.

W rozdziale trzecim zostały przedstawione modele jednowymiarowych szeregów czasowych zmienności reprezentowanej przez warunkową wariancję, które w praktyce zazwyczaj znajdują zastosowanie w połączeniu z modelem opisującym

warunkową średnią procesu. Do tej klasy zaliczamy modele: ARCH, GARCH, GARCH-*in-mean* i ich modyfikacje, a także modele zmienności stochastycznej. W pracy zostały omówione metody testowania efektu ARCH, estymacji parametrów i oceny jakości modeli oraz prognozowania na ich podstawie. W przykładach empirycznych zostały pokazane wybrane zastosowania tych modeli, m.in. do wyznaczania wartości zagrożonej (VaR). Ponieważ rozdział ten dotyczy zasadniczo metod analizy zjawisk finansowych w krótkim okresie, przedstawiono w nim także kilka podstawowych zagadnień z zakresu mikrostruktury rynku. Ze względu na ograniczoną objętość książki zostały one potraktowane sygnalnie. Wydaje się, iż rozwój tej dziedziny wiedzy wraz z aplikacjami, odnoszącymi się także do polskich rynków finansowych, będzie wymagał poświęcenia jej odrębnej publikacji.

W rozdziale czwartym następuje powrót do modeli warunkowej wartości oczekiwanej, ale mających nieliniową postać analityczną. Motywacją do ich omawiania jest brak potwierdzenia hipotezy o normalności rozkładów stóp zwrotu. Wśród tego rodzaju modeli wyróżniamy: nieliniowe modele AR i MA, modele dwuliniowe, modele progowe, modele wygładzonego przejścia oraz modele przełącznikowe oparte na łańcuchach Markowa. Sygnalnie zostało potraktowane zagadnienie chaosu deterministycznego, znajdującego zastosowanie w przypadku nieliniowości. Omówiono metody testowania nieliniowości, takie jak test RESET, test BDS oraz testy weryfikujące hipotezę o liniowości wobec konkretnej nieliniowej postaci analitycznej. Najwięcej uwagi, także w zakresie estymacji i prognozowania, poświęcono modelom progowym.

Rozdział piąty dotyczy modeli jednowymiarowych szeregów czasowych, których parametry zmieniają się w sposób losowy. Stanowią one alternatywę dla modeli nieliniowych, a także — w pewnym zakresie — dla jednowymiarowych modeli zmienności. Możliwości te zależą przede wszystkim od wariancji składnika losowego w modelu opisującym mechanizm zmienności parametrów. W rozdziale została opisana reprezentacja modeli szeregów czasowych w przestrzeni stanów, a także estymacja za pomocą filtru Kalmana. Szczególną uwagę poświęcono relatywnie nowym zagadnieniom związanym ze stochastycznym pierwiastkiem jednostkowym.

W rozdziale szóstym zostały omówione podstawowe metody analizy spektralnej będącej reprezentacją szeregów czasowych w dziedzinie częstości. Umożliwia ona wykrycie pewnych regularności w wahanach szeregów czasowych, które obserwuje się również w finansach. Narzędziami analizy są periodogram i funkcja gęstości spektralnej. Ich zastosowanie zostało omówione w kontekście testowania pierwiastków jednostkowych oraz długiej pamięci. Wskazano także na możliwość wykorzystania analizy falkowej, stanowiącej nowe narzędzie w ekonometrii.

Treścią rozdziału siódmego, rozpoczynającego drugą część książki, są dynamiczne modele ekonometryczne o charakterze przyczynowo-skutkowym. Należą do nich modele autoregresyjne z rozłożonymi opóźnieniami (ADL), modele zgodne oraz modele korekty błędem (ECM). Osobnym zagadnieniem omawianym w tym rozdziale jest problem kointegracji szeregów czasowych. Stanowi on o długo-

okresowej zależności procesów ekonomicznych i jest podstawą weryfikacji wielu hipotez finansowych, w tym hipotezy o bąblach spekulacyjnych. Spośród modeli znanych głównie z zastosowań finansowych omówiono model jednowskaźnikowy Sharpe'a oraz model wyceny arbitrażowej.

W rozdziale ósmym omówiono modele wielowymiarowe szeregów czasowych oparte na koncepcji modeli wektorowej autoregresji (VAR). Zawarto w nim informacje o konstrukcji podstawowych i strukturalnych modeli VAR wraz z ich interpretacją, o analizie przyczynowości, egzogeniczności, a także funkcji odpowiedzi na impuls. Przedstawiono także koncepcję budowy wektorowego modelu korekty błędem (VEC) w przypadku kointegracji badanych szeregów. Modele wielowymiarowych szeregów czasowych pozwalają na analizę współzależności między badanymi procesami finansowymi, a także między różnymi rynkami finansowymi, co zostało zaznaczone w prezentowanych przykładach empirycznych.

Przedmiotem rozdziału dziewiątego są wielowymiarowe modele zmienności. Podobnie jak rozdziały 2 i 3 uzupełniają się wzajemnie w zakresie jednowymiarowych modeli warunkowej wartości oczekiwanej oraz wariancji, tak samo rozdziały 8 i 9 mają analogiczny charakter w odniesieniu do modeli wielowymiarowych. W rozdziale tym przedstawiono model nie tylko ze zmienną w czasie wariancją warunkową, ale również ze stałą i zmienną w czasie kowariancją. Nowością metodologiczną jest testowanie przyczynowości w zakresie wariancji. Analizowane przykłady pozwalają na ocenę wzajemnego oddziaływania zmienności różnych szeregów finansowych.

Przedstawiony materiał teoretyczny jest ilustrowany przykładami empirycznymi, dotyczącymi głównie polskiego rynku finansowego, oraz interpretacją ich wyników. Każdy rozdział zakończono zestawem zagadnień utrwalających materiał i problemów do samodzielnego rozwiązania. Poruszanie się wśród dużej liczby modeli prezentowanych w książce powinny ułatwić słowa kluczowe, znajdujące się na początku każdego rozdziału, a także indeks rzeczowy.

Zakres podręcznika jest dość szeroki i z pewnością wykracza poza program standardowego 30-godzinnego wykładu. Wiele zagadnień omawianych w książce można, bez utraty ogólności rozważań, pominąć. Dotyczy to analizy spektralnej oraz modeli mikrostruktury rynku. Do trudniejszych zagadnień należą modele z losowymi parametrami oraz wielowymiarowe modele GARCH. Intencją autorki było jednak przedstawienie Czytelnikom możliwie wielu najnowszych dziedzin zainteresowań ekonometrii finansowej, także w celu inspiracji dla słuchaczy studiów doktoranckich, którzy poszukują tematów dla swych badań. Z drugiej strony można wskazać zagadnienia, które niewątpliwie muszą być omówione w kursowym wykładzie ekonometrii finansowej. Należą do nich tematy przedstawione w czterech pierwszych rozdziałach podręcznika, a także zawarte w rozdziałach 7 i 8. Uwzględniając obecny stan wiedzy z ekonometrii finansowej, na podkreślenie zasługuje fakt, że zagadnienia omawiane w oddawanej do rąk Czytelnika książce są przedmiotem rozważań i dyskusji naukowych na wielu specjalistycznych konferencjach naukowych, zarówno krajowych, jak i międzynarodowych, z zakresu ekonometrii i finansów.

Uważny Czytelnik zwróci zapewne uwagę na fakt prezentowania w pracy przykładów pochodzących z prac magisterskich pisanych w Katedrze Ekonometrii i Statystyki Wydziału Nauk Ekonomicznych i Zarządzania Uniwersytetu Mikołaja Kopernika w Toruniu pod kierunkiem autorki. Świadczy to z jednej strony o dużym zainteresowaniu studentów omawianymi tu zagadnieniami, z drugiej zaś o ogromnych możliwościach tkwiących w młodzieży, która dobrze sobie radzi z przyswojeniem nowej, niejednokrotnie trudnej metodologii i potrafi z powodzeniem ją zastosować.

Zagadnienia omawiane w podręczniku nie należą do łatwych. Istnieje jednak potrzeba ich popularyzacji i prezentowania, zwłaszcza wobec szybkiego rozwoju komputerowych pakietów ekonometryczno-statystycznych. Stanowi to bardzo duże ułatwienie w zakresie estymacji i testowania prezentowanych w książce modeli. Stąd najistotniejszym czynnikiem stają się ich właściwe rozumienie oraz interpretacja. Wszystkie prezentowane obliczenia zostały wykonane w pakiecie EViews 4.0.

Proponowany podręcznik jest przeznaczony dla studentów magisterskich i licencjackich studiów ekonomicznych o kierunku informatyka i ekonometria, a także specjalności: metody ilościowe w zarządzaniu, informatyka w zarządzaniu oraz finanse i bankowość. Powinien być on także wykorzystywany w badaniach własnych doktorantów, a także w programach dynamicznie rozwijających się studiów doktoranckich. Podręcznikiem zainteresują się zapewne również praktycy stosujący metody ilościowe w bankach, funduszach inwestycyjnych oraz innych podmiotach inwestujących aktywnie kapitał, a także ci, którzy ten kapitał pozyskują lub zamierzają dopiero pozyskać w celu wyceny rynkowej wartości zainwestowanych środków. Trzeba zauważyć, że prezentowany — w miarę kompleksowy — zakres ekonometrii finansowej nie jest obecnie dostępny w żadnej publikacji zwartej znajdującej się na polskim rynku wydawniczym.

Podjmując się zadania napisania podręcznika z zakresu ekonometrii finansowej, spotkałam się z ogromną życzliwością wielu osób. Podziękowania kieruję przede wszystkim do Panów Profesorów: Krzysztofa Jajugi oraz Aleksandra Zeliasia za cenne uwagi nad zawartością i strukturą podręcznika. Panu Profesorowi Zeliasiowi dziękuję ponadto za wnikliwe przeczytanie tekstu i recenzję wydawniczą. Panu Profesorowi Józefowi Stawickiemu dziękuję za przeczytanie pierwszej wersji książki i wsparcie w trakcie jej powstawania. Panu Profesorowi Jackowi Osiewalskiemu dziękuję za wskazanie pewnych pozycji literatury i życzliwą akceptację. Panu mgr. Michałowi Pietrzakowi serdecznie dziękuję za trud włożony w przeczytanie i korektę pierwszej wersji książki. Wszystkie pozostałe błędy, niejasności i uchybienia obciążają wyłącznie autorkę pracy.

Moim dzieciom: Julii i Arturowi dziękuję za cierpliwość i wyrozumiałość.

Powstanie tej publikacji nie byłoby możliwe bez istnienia środowiska ekonometrycznego, stworzonego przez Pana Profesora Zygmunta Zielińskiego na Wydziale Nauk Ekonomicznych i Zarządzania Uniwersytetu Mikołaja Kopernika w Toruniu, któremu książkę tę dedykuję.

Magdalena Osipińska

Wprowadzenie

Pierwszą istotną książką z zakresu ilościowego opisu cen instrumentów finansowych była praca Louisa Bacheliera opublikowana w 1900 roku. Wychodząc z założenia o równowadze rynku i opierając się na wzorze na prawdopodobieństwo warunkowe, przy pewnych mileząco przyjętych założeniach o gęstości rozkładu cen, doszedł on do wniosku, że przyrosty kolejnych cen francuskich obligacji muszą być niezależnymi zmiennymi losowymi o tym samym rozkładzie normalnym z zerową wartością oczekiwaną i stałą wariancją. Było to równoznaczne ze sformulowaniem hipotezy o przypadkowym normalnym błędzeniu cen, co stało się podstawą hipotezy o efektywności rynków finansowych. Praca Bacheliera została jednak zapomniana na prawie pół wieku.

W 1937 roku Cowles i Jones przeanalizowali przyrosty cen na giełdzie w Nowym Jorku. Od tej pory zaczęto prowadzić badania nad zgodnością rzeczywistych zjawisk giełdowych z hipotezą o błędzeniu przypadkowym, które trwają do chwili obecnej. Początkowo ograniczały się one do statystycznej weryfikacji hipotezy o braku autokorelacji przyrostów cen akcji. Na ogół uzyskiwano różne wyniki, jednak zauważono, że nawet jeśli autokorelacja istnieje, to jest zbyt słaba, żeby na tej podstawie wystarczająco dokładnie przewidywać zmiany cen. Następnie, dopuszczając hipotezę o zależności przyrostów cen przy braku ich autokorelacji, do badania niezależności cen zaczęto używać także innych metod. W pierwszej połowie lat sześćdziesiątych XX w. Moore zastosował testy oparte na teorii serii do badania niezależności przyrostów logarytmów indeksu *Standard and Poor*, Alexander do badania ewentualnych zależności nieliniowych wykorzystał filtry generujące sygnały kupna i sprzedaży akcji, z kolei Granger i Morgenstern do badania niezależności zmian różnych indeksów giełdy w Nowym Jorku użyli metod analizy spektralnej. Żadna z wymienionych prac nie podważyła hipotezy o niezależności zmian cen.

Dopiero amerykański matematyk Mandelbrot [1963] zwrócił uwagę na inny, znany z badań empirycznych, lecz często pomijany fakt, że empiryczne rozkłady pierwszych i dalszych różnic cen wykazują duże odchylenia od rozkładu normalnego. Są co prawda jednodzielne, ale mają zazwyczaj grube ogony, co powoduje, że krzywe normalne dopasowane na podstawie kryterium minimalizacji błędu średnio-

kwadratowego są zbyt płaskie. Sugeruje to bowiem możliwość nieistnienia wariancji rozkładu, co pozostaje w sprzeczności z modelem błędzenia przypadkowego Bacheliera. Konsekwencje badań Mandelbrota były bardzo daleko idące. Oznaczały bowiem, że zachodzi jedna z trzech możliwości:

- 1) przyrosty cen nie są niezależne,
- 2) przyrosty cen nie mają tego samego rozkładu,
- 3) przyrosty cen nie mają rozkładu normalnego.

Zaproponowane przez Mandelbrota zastąpienie rozkładu normalnego klasą rozkładów stabilnych, stanowiących naturalne uogólnienie rozkładu normalnego, mogłoby spowodować utrzymanie założenia o jednakowym rozkładzie przyrostów, a być może nawet założenie o niezależności. Jednakże badania w tym kierunku straciły na znaczeniu ze względu na trudności analityczne polegające na niemożności jednoznacznego zdefiniowania funkcji gęstości większości rozkładów stabilnych.

Kolejny etap w kierunku urealnienia hipotezy o błędzeniu przypadkowym cen stanowiło założenie, że przyrosty cen tworzą grę sprawiedliwą, tzn. mają w dalszym ciągu niezależne rozkłady normalne, ale o niejednakowych wariancjach. Umożliwiło to wyjaśnienie wątpliwości sformułowanych przez Mandelbrota. Związek między efektywnością rynku a teorią martyngalów po raz pierwszy wykazał w 1965 roku Samuelson. Oznacza to, że ceny mają postać martyngalu, stopy zmian natomiast postać różnicy martyngalowej. Dopuszcza to modelowanie oraz przewidywanie momentów wyższych rzędów, na przykład wariancji. Taka wersja hipotezy o efektywności rynku jest przyjmowana obecnie. Została ona uznana po opublikowaniu w 1970 roku pracy Famy, rozpoczynającej współczesny okres badania efektywności. Należy zauważyć, iż zasługą Famy jest wyróżnienie słabej, średniej oraz silnej efektywności informacyjnej rynku ze względu na zbiór posiadanych informacji.

Od połowy lat siedemdziesiątych XX w. w literaturze na temat efektywności obecny jest nurt kwestionujący średnią efektywność wielu rynków poprzez wykrywanie i analizowanie tzw. anomalii rynku. Stwierdzono, że na wielu rynkach w przeszłości występowały regularne zmiany stóp zwrotu, zwane efektami kalendarzowymi, wśród których najważniejszymi były efekt poniedziałku i efekt stycznia. Zauważono też, że w wielu przypadkach do prognozowania stóp zwrotu można było używać pewnych publicznie dostępnych informacji, np. ceny akcji, zysku lub dywidendy na akcję. Obszerny zestaw prac na temat anomalii oraz innych prac empirycznych znajduje się w artykułach Famy [1970] i [1991] oraz LeRoya [1989].

Dopiero ogromny rozwój technik informacyjnych oraz informatycznych, który nastąpił w latach osiemdziesiątych, spowodował powszechną dostępność wysokiej jakości danych finansowych oraz znaczne zwiększenie mocy obliczeniowej komputerów. Zbiegło się to w czasie z rozwojem zaawansowanych metod i narzędzi ekonometrycznych, co w znaczący sposób zmieniło dziedzinę ekonometrii finansowej. Do metod, które powstały właśnie w tym okresie, należy zaliczyć: modele ARFIMA, ARCH, GARCH i ich modyfikacje, analizę kointegracji szeregów

czasowych, modele wektorowo-autoregresyjne i wiele innych omawianych w tej książce. Także lata 90. XX wieku i początek XXI wieku obfitowały w liczne publikacje z zakresu ekonometrii finansowej, dotyczących zwłaszcza wielowymiarowych modeli GARCH, modeli nieliniowych czy też metod analizy danych o tzw. ultrawysokiej częstotliwości. O znaczeniu zagadnień finansowych w rozwoju nauk ekonomicznych może świadczyć liczba Nagród Nobla przyznanych za prace w dziedzinie finansów dla: J. Tobina (1981), F. Modiglianiego (1985), H. Markowitza, W. Sharpe'a i M. Millera (1990) oraz R. Mertona i M. Scholesa (1997). Ukoronowaniem tych honorów była przyznana w roku 2003 Nagroda Nobla dla C. Grangera oraz R. Engle'a, których wkład w rozwój nowoczesnej ekonometrii, a w szczególności ekonometrii finansowej jest bezsprzeczny.

Należy przy tym zauważyć, iż metody ekonometryczne przestały być w znacznym stopniu zarezerwowane dla naukowców, a stały się podstawą wielu praktycznych zastosowań w zakresie planowania, wyceny i zarządzania inwestycjami finansowymi.

Przedmiot ekonometrii finansowej i jej związek z innymi dyscyplinami

Termin ekonometria kojarzy się z wykorzystaniem statystyki matematycznej do rozwiązywania problemów ekonomicznych. Narzędziem ekonometrii jest model opisujący zależności między zmiennymi ekonomicznymi, przy czym wyrażające go równanie ma charakter stochastyczny (w przypadku układu równań — co najmniej jedno z nich musi być stochastyczne). Parametry modelu są estymowane z dokładnością wynikającą z charakteru zależności oraz własności przyjętego estymatora.

W ciągu 80-letniej historii ekonometrii jako nauki włączono w jej zakres wiele metod, nie stosowanych dotąd w ekonomii, do których należy zaliczyć zwłaszcza teorię procesów stochastycznych w czasie dyskretnym oraz modele stochastycznych równań różniczkowych umożliwiające analizę w czasie ciągłym. Rozwojowi metod ekonometrycznych towarzyszy wielkie zainteresowanie ich zastosowaniem, skąd wynika podział dyscypliny na teorię ekonometrii oraz ekonometrię stosowaną. Obie części nauki wzajemnie się przenikają, dając nowe impulsy do jej rozwoju. Wyróżnienie ekonometrii finansowej (*financial econometrics*) ma na celu wyseparowanie tych metod i narzędzi, które mają zastosowanie do zagadnień występujących w finansach.

Centralnym zadaniem badawczym ekonometrii finansowej jest odkrycie łącznego rozkładu warunkowego, postaci:

$$f(\mathbf{P}_{t,t} | \Omega_t),$$

gdzie:

$\mathbf{P}_t$ — wektor cen aktywów finansowych w okresie t ,

Ω_t — zasób informacji posiadanych przez ekonometryka w okresie t , w tym znajomość wektora cen z przeszłości.

Etapy badania ekonometrycznego, począwszy od specyfikacji modelu, poprzez jego estymację, weryfikację aż do praktycznego wykorzystania, pozostają oczywiście niezmienione, aczkolwiek na każdym z nich pojawiają się nowe wyzwania. W ostatnich latach badacze coraz większą uwagę koncentrują na modelowaniu momentów wyższych rzędów, w szczególności wariancji i kowariancji; możliwa stała się estymacja modeli z rozkładami składników resztowych innymi niż normalne, szerokie jest zainteresowanie rozkładami wartości ekstremalnych oraz modelowaniem danych o ultrawysokiej częstotliwości. Wszystkie rozpatrywane zagadnienia odnoszą się do wyceny i prognozowania cen zarówno podstawowych instrumentów finansowych, jak i derywatów.

Przedmiotem ekonometrii finansowej są procesy finansowe, które charakteryzują się wysoką częstotliwością obserwacji, często niestacjonarnością, wrażliwością na różnorodne informacje oraz trudnościami w przewidywaniu zmian. Zagadnienia te wymagają specjalnych metod analizy i przewidywania przyszłych wartości. W literaturze finansowej szczególnie rozpowszechnione są pojęcia analizy technicznej oraz analizy fundamentalnej (por. Tarczyński [2002]). Jest oczywiste, że analiza ekonometryczna bazuje na analizie fundamentalnej, której wynikiem jest specyfikacja wielu modeli przyczynowo-skutkowych będących dobrym narzędziem analizy w dłuższym horyzoncie czasowym. Z kolei modele szeregów czasowych jednowymiarowych i wielowymiarowych są bardziej odpowiednie do wykorzystania w analizach krótkookresowych.

Walory ekonometrii finansowej można sformułować następująco: daje narzędzia przewidywania procesów finansowych w przyszłości z określonym prawdopodobieństwem, pozwala określać wpływ czynników ekonomicznych na poszczególne procesy, a także weryfikować większość hipotez ekonomicznych i finansowych. Wyniki analiz ekonometrycznych można wykorzystać do redukcji ryzyka inwestycyjnego, a także w konstrukcji nowych narzędzi i instrumentów finansowych.

Pisząc o ekonometrii finansowej, warto wspomnieć o pewnych narzędziach wywodzących się z matematyki finansowej, która — jak zwracają uwagę Weron, Weron [1999] — powstała dopiero w latach czterdziestych XX wieku. Początkowo obejmowała teorię wyceny obligacji oraz modele wykorzystywane na rynku ubezpieczeń. Matematyka finansowa z jej narzędziami w postaci aktualnej i przyszłej wartości pieniądza, modelami wyceny papierów wartościowych itp. stanowi dla ekonometrii finansowej bazę analityczną. Przeliczone wartości stóp zwrotu, kursów spot i forward itp. stanowią dane w postaci szeregów czasowych, które analizuje się za pomocą narzędzi ekonometrycznych, natomiast modele wyceny, często deterministyczne, są podstawą do szacowania modeli stochastycznych na bazie rzeczywistych danych. Wyznaczona na podstawie modeli wyceny tzw. cena sprawiedliwa czy też oczekiwana jest jednocześnie oczekiwaniem inwestorów co do przyszłych wartości instrumentów finansowych, które także są przedmiotem analiz ekonometrycznych.

Podobne zależności można także wskazać między ekonometrią finansową a analizą portfelową i modelami równowagi rynków kapitałowych, takimi jak CAPM, model APT, czy też teorią chaosu deterministycznego, znaną głównie na gruncie matematyki. Choć podstawy tej teorii leżą w pewnej sprzeczności ze stochastycznym charakterem procesów ekonomicznych, to jednak znajduje ona szerokie zastosowanie w zakresie analizy szeregów finansowych, którą prowadzą przede wszystkim ekonometrycy.

Rozwój instrumentów pochodnych, jak również innych sposobów zabezpieczania aktywów przed ryzykiem zaowocował pojawieniem się nowej dziedziny wiedzy — inżynierii finansowej. Nauka ta ma pewien związek z ekonometrią, gdyż ryzyko można analizować za pomocą narzędzi statystyczno-ekonometrycznych, w tym zwłaszcza modeli zmienności.

Twórcy nowoczesnej ekonometrii finansowej (Bollerslev [2001], Engle [2001]) szczególną uwagę zwracają na to, co decyduje o jej rozwoju i sukcesie w ostatnich latach. Wskazując na dużą elastyczność metod, jako najistotniejsze wymieniają modele ARCH i GARCH oraz modele stochastycznej zmienności z innym niż normalny rozkładem błędów. Drugim zagadnieniem rozwijającym się w kierunku praktycznych zastosowań jest modelowanie danych o ultrawysokiej częstotliwości, charakteryzujących się długą pamięcią.

W światowej literaturze przedmiotu można wyróżnić dwa nurty. Pierwszy z nich, reprezentowany m.in. przez prace: Gouriérouxa, Jasiak [2001], Millsa [2002] i Tsaya [2002], skupia się na omówieniu narzędzi ekonometrycznych wykorzystywanych w analizach finansowych, w tym zwłaszcza finansowych szeregów czasowych, przy czym przykłady empiryczne mają charakter ilustracji pozwalających na przybliżenie praktycznego zastosowania omawianych metod. W drugim nurcie, reprezentowanym m.in. przez prace: Cuthbertsona [1997], Campbella, Lo i MacKinleya [1997] czy Alexandra [2003], mamy do czynienia z prezentacją i analizą zagadnień finansowych przeprowadzaną zazwyczaj za pomocą modeli matematyki finansowej oraz ekonometrii.

Niniejszy podręcznik wpisuje się w pierwszy nurt badań. Jego idea polega na tym, aby dostarczyć Czytelnikowi różnorodnych narzędzi ekonometrycznych — obecnie opisywanych w wielu rozproszonych publikacjach — i pokazać możliwości ich wykorzystania. Zakłada się przy tym, iż osoby studiujące niniejszą książkę znają podstawy statystyki matematycznej oraz ekonometrii. W toku studiów rozmaitych zagadnień z zakresu ekonometrii finansowej zwraca uwagę brak jedynego uniwersalnego modelu dla cen czy stóp zwrotu instrumentów finansowych. Jest faktem, że takie cechy, jak skupianie się wariancji czy też grube ogony rozkładów, mogą być modelowane za pomocą różnych modeli nieliniowych oraz modeli liniowych z losowymi parametrami. Na tym tle widać także, że rozwój metod ekonometrycznych w zakresie kryteriów selekcji modeli, zwłaszcza nieliniowych, jest jeszcze niewystarczający.

Część
pierwsza

Rozdział 1

Charakterystyka finansowych szeregów czasowych

Słowa kluczowe: stopa zwrotu, rozkład stóp zwrotu, hipoteza rynku efektywnego i jej weryfikacja, hipoteza racjonalnych oczekiwań, efekty sezonowe

Przedmiotem analizy niniejszego rozdziału są finansowe szeregi czasowe. Są to głównie ceny rynkowe takich instrumentów finansowych, jak akcja, obligacja, opcja, a także rynkowe stopy zwrotu z inwestycji w wymienione instrumenty. Ponadto analizą zostały objęte kursy walutowe i stopy procentowe. Podstawową sprawą są kwestie pojęciowe, a więc definicje stopy zwrotu (zysku) i logarytmicznej stopy zwrotu (zysku), mierników ryzyka papierów wartościowych, a także determinanty kształtowania się cen i stóp zwrotu. Istotną częścią analizy stóp zwrotu są ich rozkłady, którym poświęcono jeden z podrozdziałów. W rozdziale ponadto będą przedyskutowane podstawowe hipotezy leżące u podstaw analiz finansowych, takie jak hipoteza rynku efektywnego oraz hipoteza racjonalnych oczekiwań. Ekonometryczne implikacje wymienionych hipotez zawierają się w możliwościach ich weryfikacji. Narzędzia weryfikacji oraz ich zastosowanie są także przedmiotem rozważań w rozdziale pierwszym.

1.1. Finansowe szeregi czasowe i ich charakterystyki

Podział rynku finansowego na rynek pieniężny i kapitałowy według kryterium czasu budzi wiele kontrowersji, ale jest powszechnie stosowany (por. Tarczyński [1997]). W niniejszej publikacji pozostaniemy w zgodzie z tym podziałem, skupiając jednak większą uwagę na instrumentach rynku kapitałowego, a więc o horyzoncie inwestycyjnym dłuższym niż rok. Jednakże nie sposób oddzielić tego segmentu od transakcji krótkoterminowych, reprezentowanych na przykład przez bony skarbowe, stopy procentowe o okresach krótszych niż rok oraz kursy walutowe.

Stopa zwrotu z inwestycji. Dyskusja nad nazwą stopa zwrotu czy stopa zysku (*rate of return* lub *asset return*) jest przedmiotem rozważań w literaturze. Wydaje się,

że stopa zysku lepiej pasuje do powszechnego rozumienia osiąganego efektu inwestycyjnego, aczkolwiek stopa zwrotu z inwestycji czy też po prostu zwrot z inwestycji to terminy, które także przyjęły się w literaturze polskiej. Stąd w niniejszej książce oba terminy będą traktowane równoprawnie. Należy pamiętać, że mamy tu na myśli rynkową stopę zwrotu (zysku).

Zwykła stopa zwrotu. Zwykła jednookresowa stopa zwrotu z inwestycji w papiery wartościowe jest definiowana jako:

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}}, \quad (1.1)$$

gdzie:

R_t — zwykła stopa zwrotu z akcji,

P_t — cena instrumentu finansowego.

Wzór (1.1) można zapisać także jako:

$$1 + R_t = \frac{P_t}{P_{t-1}}. \quad (1.1a)$$

Uwzględniając płatności dywidendy (na ogół w okresach rocznych), mamy:

$$R_t = \frac{P_t - P_{t-1} + D_t}{P_{t-1}}, \quad (1.2)$$

gdzie:

D_t — wartość dywidendy w okresie t .

W analogiczny sposób można określić k -okresową stopę zwrotu:

$$R_t(k) = \frac{P_t - P_{t-k}}{P_{t-k}}, \quad (1.3)$$

gdzie k oznacza odstęp, dla którego liczymy stopę zwrotu.

W praktyce wzór (1.3) oznacza, że k -okresowa zwykła stopa zwrotu jest iloczynem jednookresowych stóp zwrotu, czyli:

$$1 + R_t(k) = \frac{P_t}{P_{t-k}} = \frac{P_t}{P_{t-1}} \times \frac{P_{t-1}}{P_{t-2}} \times \dots \times \frac{P_{t-k+1}}{P_{t-k}} = (1 + R_t)(1 + R_{t-1}) \dots (1 + R_{t-k+1}). \quad (1.4)$$

Logarytmiczna stopa zwrotu. W analizach empirycznych często korzysta się z logarytmicznej stopy zwrotu postaci:

$$r_t = \ln(1 + R_t) = \ln \frac{P_t}{P_{t-1}} = \ln P_t - \ln P_{t-1} = p_t - p_{t-1}, \quad (1.5)$$

gdzie:

r_t — logarytmiczna jednookresowa stopa zwrotu,

p_t — logarytm ceny instrumentu finansowego.

Wzór (1.5) definiuje jednookresową logarytmiczną stopę zwrotu. K -okresowy odpowiednik (1.5) jest następujący:

$$\begin{aligned} r_t(k) &= \ln[1 + R_t(k)] = \ln(1 + R_t)(1 + R_{t-1}) \dots (1 + R_{t-k+1}) = \\ &= \ln(1 + R_t) + \ln(1 + R_{t-1}) + \dots + \ln(1 + R_{t-k+1}) = r_t + r_{t-1} + \dots + r_{t-k+1}. \end{aligned} \quad (1.6)$$

Z (1.6) wynika, że k -okresowa logarytmiczna stopa zwrotu jest sumą jednookresowych logarytmicznych stóp zwrotu, co daje jej przewagę nad zwykłą stopą zwrotu.

Logarytmiczna stopa zwrotu jest lepszym narzędziem analizy niż zwykła stopa zwrotu, gdyż transformacja logarytmiczna umożliwia liniowe przekształcenia i bezpośrednie stosowanie takich klasycznych narzędzi opisu statystycznego, jak momenty zwykłe i centralne (np. średnia arytmetyczna i odchylenie standardowe).

Nadwyżka stopy zwrotu. Nadwyżką stopy zwrotu (*excess return*) będziemy nazywać różnicę między zwrotem z inwestycji w dany papier wartościowy a zwrotem z inwestycji w instrument finansowy będący punktem odniesienia, np. instrument wolny od ryzyka, czyli:

$$Z_t = R_t - R_{0t}, \quad (1.7)$$

lub:

$$z_t = r_t - r_{0t}, \quad (1.7a)$$

gdzie R_{0t} , r_{0t} oznaczają — odpowiednio — zwykłą lub logarytmiczną stopę zwrotu aktywa referencyjnego. Aktywem referencyjnym bywają 52-tygodniowe bony skarbowe, stąd ich oprocentowanie wyznacza zarazem tzw. stopę wolną od ryzyka.

Ryzyko papieru wartościowego. Podstawowe mierniki ryzyka papieru wartościowego, a dokładnie inwestycji w dany papier wartościowy, koncentrują się zwykle wokół miar zmienności, co nie wyczerpuje zagadnienia (por. np. Jajuga (red.) [2000]). Przedstawimy tylko dwa powszechnie używane mierniki ryzyka. Wariancja i odchylenie standardowe papieru wartościowego, odpowiadające neutralnemu rozumieniu ryzyka¹, mają odpowiednie postaci:

$$S^2 = \frac{\sum_{t=1}^T (R_t - \bar{R})^2}{T-1}, \quad (1.8)$$

$$S = \sqrt{S^2}, \quad (1.8a)$$

gdzie:

T — liczba obserwacji w szeregu,

$$\bar{R} = \frac{\sum_{t=1}^T R_t}{T} \text{ — średnia stopa zwrotu w badanym okresie.}$$

¹ Ryzyko w rozumieniu neutralnym oznacza niezgodność efektu z oczekiwaniami.

Z kolei semiwariancja i semiodchylenie standardowe biorą pod uwagę tylko negatywne odchylenia od wartości średniej² i przyjmują odpowiednio postaci:

$$SV^2 = \frac{\sum_{t=1}^T d_t^2}{T-1}, \quad (1.9)$$

$$SV = \sqrt{SV^2}, \quad (1.9a)$$

przy czym:

$$d_t = \begin{cases} 0, & \text{gdy } R_t \geq \bar{R}, \\ R_t - \bar{R}, & \text{gdy } R_t < \bar{R}. \end{cases} \quad (1.10)$$

Reguła $T^{1/2}$. Założenie o stabilnej zmienności rozkładów stóp zwrotu głosi, że:

$$S[R_t(k)] = \sqrt{T} S(R_t), \quad (1.11)$$

gdzie:

$S[R_t(k)]$ — odchylenie standardowe dla k -okresowej stopy zwrotu,

$S(R_t)$ — odchylenie standardowe jednookresowej stopy zwrotu.

W praktyce trudno potwierdzić powyższe założenie z powodu bardzo wysokiej zmienności stóp zwrotu.

Podstawowe charakterystyki portfela aktywów. Przedstawione wyżej wzory dotyczyły pojedynczych aktywów. Jednakże w analizach finansowych mamy często do czynienia z portfelem aktywów. Podstawowe zależności są następujące:

Stopa zwrotu portfela:

$$R_p = \sum_{i=1}^k x_i R_{it}, \quad (1.12)$$

gdzie:

x_i — udział danego papieru wartościowego w portfelu.

Zakłada się, że $\sum x_i = 1$ oraz że $x_i \geq 0$. W przypadku gdy $x_i < 0$, dopuszczalna staje się tzw. krótka sprzedaż aktywów.

Ryzyko portfela:

— wariancja:

$$S_p^2 = \sum_{i=1}^k x_i^2 S_i^2 + 2 \sum_{i=1}^{k-1} \sum_{j=i+1}^k x_i x_j S_i S_j r_{ij}, \quad (1.13)$$

² Semiodchylenie standardowe odpowiada ryzyku w pojęciu negatywnym rozumianym jako oczekiwana strata; por. Jajuga (red.) [2000].

gdzie:


— współczynnik korelacji i -tego i j -tego papieru wartościowego;

— odchylenie standardowe portfela:

$$S_p = \sqrt{S_p^2}. \quad (1.13a)$$

Empiryczne szeregi finansowe I. Na rysunku 1.1 zostały przedstawione średnie tygodniowe z indeksu WIG obserwowane w okresie 2.01.1995–2.04.2003, logarytmy z tych obserwacji, zwykłe i logarytmiczne stopy zwrotu, a także kwadraty stóp zwrotu.

Rysunek 1.1. Indeksy WIG obserwowane tygodniowo w okresie 1995–2003



Źródło: Opracowanie własne.

Analogiczny charakter mają także inne szeregi finansowe obserwowane zarówno na rynku polskim, jak i na rynkach zagranicznych. Na tej podstawie można określić podstawowe własności tych szeregów, do których należą:

- wysoka częstotliwość obserwacji,
- bardzo duża zmienność stóp zwrotu,
- grupowanie wariancji.

Obserwując wykresy kwadratów stóp zwrotu z indeksu WIG, zauważamy okresy skupiania się wyższych wartości i okresy, gdy obok siebie znajdują się relatywnie niskie wartości. Zjawisko to nosi nazwę grupowania wariancji.

1.2. Analiza rozkładów stóp zwrotu

Modele rozkładów stóp zwrotu pozwalają na analizę według aktywów oraz w kolejnych jednostkach czasu. Na przykład dla N aktywów obserwowanych w czasie $t = 1, 2, \dots, T$ i logarytmicznych stóp zwrotu mamy $\{r_{it}; i = 1, 2, \dots, N; t = 1, 2, \dots, T\}$.

Łączny rozkład stóp zwrotu możemy zapisać następująco:

$$F(r_{11}, \dots, r_{NT}; r_{21}, \dots, r_{N2}; r_{12}, \dots, r_{NT}; \mathbf{Y}; \mathbf{\Theta}), \quad (1.14)$$

gdzie:

$\mathbf{Y}$ — wektor zmiennych determinujących stopy zwrotu,

$\mathbf{\Theta}$ — wektor parametrów.

Model (1.14) stanowi zasadnicze ramy dla konkretnych modeli ekonometrycznych opisujących stochastyczną strukturę stóp zwrotu. Jak wiadomo, w łącznym rozkładzie prawdopodobieństwa wyróżnia się rozkłady warunkowe oraz rozkłady brzegowe. W przypadku jednowymiarowym odpowiedni rozkład z podziałem na brzegowy i warunkowy może zostać zapisany w poniższy sposób:

$$F(r_{11}, \dots, r_{1T}; \mathbf{\Theta}) = F(r_{11}) F(r_{12}|r_{11}) \dots F(r_{1T}|r_{11}, \dots, r_{1T-1}). \quad (1.15)$$

Wzór (1.15) pokazuje zależność i -tej stopy zwrotu od jej przeszłych wartości, opisując sposób, w jaki warunkowe prawdopodobieństwo ewoluje w czasie. Model (1.15) może opisywać na przykład łączną strukturę jednowymiarowego modelu ARMA (por. rozdz. 2). Jeżeli przyjmiemy założenie o efektywności rynku, to rozkład brzegowy jest równy rozkładowi warunkowemu, co świadczy o niezależności kolejnych stóp zwrotu w czasie. Wzory (1.14)–(1.15) dotyczą obserwacji w dyskretnych odstępach czasu, ale z łatwością można je przedstawić w wersji dla obserwacji w czasie ciągłym (por. np. Tsay [2002]).

Wśród teoretycznych rozkładów wykorzystywanych w analizach ekonometrycznych i statystycznych najczęściej zastosowanie znajdują:

a. Rozkład normalny jest przyjmowany w celu podkreślenia, że zwykle jednookresowe stopy zwrotu mają identyczne, niezależne rozkłady (i.i.d. — *independently, identically distributed*), dające w konsekwencji rozkład normalny ze stałą średnią i wariancją. W przypadku k -okresowych zwykłych stóp zwrotu, które na

mocy wzoru (1.4) są iloczynami stóp jednookresowych, własność normalności rozkładu nie zachodzi.

b. Rozkład logarytmiczno-normalny zakłada, że jednookresowe logarytmiczne stopy zwrotu są i.i.d. według rozkładu normalnego o średniej μ i wariancji σ^2 . Wówczas zwykle stopy zwrotu są zmiennymi losowymi o rozkładzie logarytmiczno-normalnym, których średnia i wariancja są dane odpowiednio jako:

$$E(R_t) = \exp\left(\mu + \frac{\sigma^2}{2}\right) - 1, \quad (1.16)$$

$$\text{var}(R_t) = \exp(2\mu + \sigma^2) [\exp(\sigma^2) - 1]. \quad (1.17)$$

K -okresowe logarytmiczne stopy zwrotu mają rozkład normalny, ponieważ skończona suma zmiennych losowych o rozkładach normalnych ma także rozkład normalny. Warto zauważyć, że jeśli przyjmiemy, iż logarytmiczne stopy zwrotu mają rozkład normalny, to ceny walorów mają wówczas rozkład logarytmiczno-normalny.

c. Rozkład t -Studenta — symetryczny lub niesymetryczny (standaryzowany), zależnie od parametru skali, na ogół z niewielką liczbą stopni swobody — służy do opisu rozkładów stóp zwrotu zawierających grube ogony (por. Osiewalski, Pipień [1999b], Piontek [2002]).

d. Rozkłady stabilne to klasa rozkładów dobrze opisujących wyższą kurtozę stóp zwrotu, których wadą jednakże jest nieskończona wariancja. Klasa rozkładów stabilnych stanowi uogólnienie rozkładu normalnego dla logarytmicznych stóp zwrotu. Poza rozkładem normalnym, zdefiniowane w tej klasie są jeszcze rozkład Cauchy'ego oraz rozkład Levy'ego. Inne postaci funkcji gęstości rozkładów stabilnych nie są dane w postaci jawnej. Stanowi to poważne utrudnienie w stosowaniu tej klasy rozkładów statystycznych. Funkcja gęstości rozkładu Cauchy'ego ma postać:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad (1.18)$$

przy czym $-\infty < x < \infty$.

e. Skalowane mieszane rozkłady normalne (por. Tsay [2002]), np.:

$$(1-\alpha)N(\mu, \sigma_1^2) + \alpha N(\mu, \sigma_2^2), \quad (1.19)$$

przy czym: $0 \leq \alpha \leq 1$, σ_1^2 jest niska, zaś σ_2^2 relatywnie wysoka. Dzięki zróżnicowanemu wariansom mieszanki rozkładów dobrze opisują podwyższoną kurtozę oraz grube ogony rozkładów. Rozkłady te pozwalają także na opis tego, jaka część zmienności zachowuje się według pierwszego, a jaka według drugiego rozkładu normalnego. Występują jednak trudności z estymacją funkcji gęstości takich rozkładów, zwłaszcza parametru α .

1. Rozkłady wartości ekstremalnych³. Rozważmy logarymiczne stopy zwrotu $\{r_1, \dots, r_n\}$. Stopa zwrotu $r_1 = \min_{1 \leq j \leq n} r(j)$ jest nazywana statystyką minimalną, natomiast $r_n = \max_{1 \leq j \leq n} r(j)$ — statystyką maksymalną. Statystyka minimalna odnosi się do długiej pozycji⁴ w finansach, podczas gdy statystyka maksymalna odpowiada pozycji krótkiej. Ogólna postać granicznej dystrybuanty dla statystyki minimalnej, przy założeniu niezależności stóp zwrotu, jest dana jako:

$$F'_{\min}(x) = \begin{cases} 1 - \exp[-(1+kx)^{1/k}], & \text{dla } k \neq 0, \\ 1 - \exp[-\exp(x)], & \text{dla } k = 0, \end{cases} \quad (1.20)$$

przy czym $x < -1/k$, gdy $k < 0$ i $x > -1/k$, gdy $k > 0$. Postać (1.20) jest bardzo ogólna i może być opisana przez różne rodziny rozkładów (por. Tsay [2002]).

Empiryczne szeregi finansowe II. Rozważmy stopy zwrotu z wybranych instrumentów finansowych obecnych na rynku polskim.

Jak wynika z analizy wykresów zamieszczonych na rysunku 1.2, rozkłady empirycznych szeregów finansowych niezbyt często przypominają rozkład normalny. Rozkłady te charakteryzują się grubymi ogonami, co oznacza, że prawdopodobieństwo wystąpienia obserwacji nietypowej jest tu wyższe aniżeli w rozkładzie normalnym. Stanowi to poważne wyzwanie dla ekonometrycznego modelowania szeregów finansowych, stąd pojawienie się w ekonometrii finansowej modeli opisujących (wyjaśniających) grube ogony rozkładów (np. klasa modeli ARCH, modele oparte na rozkładach wartości ekstremalnych, modele mikrostruktury rynku). Niektóre z nich będą przedmiotem rozważań w dalszej części podręcznika.

W tabelicy 1.1 zostały przedstawione wyniki analiz opisowych dokonanych na kursach walutowych PLN/USD, PLN/EURO, PLN/GBP i PLN/JPY (logarymiczne stopy zwrotu) obserwowanych dziennie w 2003 roku.


Tabela 1.1. Statystyki opisowe stóp zwrotu dla walut

Waluty	Średnia	Mediana	Minimum	Maksimum	Odechylenie standardowe	Rozstęp	Skośność	Kurtoza
EURO	0,002	0,002	-0,090	0,103	0,026	0,193	0,396	4,913
USD	0,000	-0,003	-0,056	0,111	0,025	0,166	0,968	5,493
GBP	0,002	0,002	-0,107	0,182	0,039	0,289	0,729	5,907
JPY	0,001	0,000	-0,063	0,096	0,024	0,159	0,449	4,023

Źródło: Opracowanie własne.

³ Teoria i praktyka wartości ekstremalnych są również często włączane do szeroko rozumianych zagadnień ekonometrii finansowej, chociaż w niniejszej pracy temat ten nie będzie rozwijany; por. Jajuga [2001a], Tsay [2002].

⁴ Pozycja długa w finansach oznacza posiadanie aktywów. Pozycja krótka odnosi się do sytuacji sprzedaży aktywów, którego nie mamy. Towarzyszy temu pożyczanie go od inwestora, który go nabył. Ponieważ pożyczka podlega określonej liczbie papierów wartościowych, a nie suma pieniędzy, taką samą



Rysunek 1.2. Przykładowe rozkłady empirycznych stóp zwrotu

liczbę należy również zwrócić. Inwestor dokonujący krótkiej sprzedaży korzysta zatem na różnicy w cenie aktywów. Jeżeli w tym okresie wypłacane są dywidendy (z akcji), to pożyczkobiorca, dokonujący krótkiej sprzedaży, jest zobowiązany zwrócić kwotę dywidendy pożyczkodawcy. Dywidenda zostanie wypłacona inwestorowi, który nabył aktywa sprzedawane w ramach krótkiej sprzedaży.

Źródło: Opracowanie własne.

Jak wynika z danych, rozkłady wszystkich stóp zwrotu charakteryzują się wysoką zmiennością (odchylenia standardowe większe od wartości średnich), prawostronną skończonością oraz podwyższoną kurtozą. Są to cechy towarzyszące niemal wszystkim finansowym szeregom czasowym.

1.3. Hipoteza rynku efektywnego w świetle analizy ekonometrycznej

Większość analiz finansowych opiera się na hipotezie rynku efektywnego. Hipoteza ta została zapoczątkowana przez Bacheliera w 1900 roku, a następnie reaktywowana w literaturze m.in. poprzez prace Fama [1970]. Obecnie jest szeroko znana w finansach (por. np. Jajuga (red.) [2000], Czekaj i in. [2001]).

Założenia hipotezy rynku efektywnego są następujące:

1. Zmiana cen poszczególnych walorów jest minimalna.
2. Dzienna liczba transakcji jest skończona i nieistotna.
3. Cena i wartość są ze sobą związane, a ich wzajemna relacja jest najważniejszym wyznacznikiem stopy zwrotu na rynku.
4. W przypadku dwóch papierów wartościowych o różnych oczekiwanych stopach zwrotu logiczną decyzją jest wybór tego papieru, który daje szansę większego zysku.
5. W sytuacji gdy osiągnięcie zysku przez sprzedającego i kupującego nie jest możliwe, szanse na zawarcie transakcji są mało prawdopodobne, co oznacza, że inwestorzy potrafią racjonalnie przełożyć wartość na cenę i dlatego w zawieranych przez nich transakcjach obowiązują ceny równowagi ustalone na podstawie dostępnych w danej chwili informacji.
6. Następujące kolejno zmiany cenowe są od siebie niezależne, ponieważ ceny są dostosowane do aktualnie dostępnych informacji.
7. Ponieważ zmiany cenowe są od siebie niezależne, tj. podlegają błędzeniu losowemu, można się spodziewać, że ich rozkład będzie rozkładem normalnym ze stałą średnią i skończoną wariancją.

Niech oczekiwana przyszła stopa zwrotu będzie dana jako:

$$E(R_{t+1}) = \frac{E(P_{t+1}) - P_t}{P_t} \quad (1.21)$$

Oczekiwana cenę instrumentu finansowego można — zgodnie z hipotezą efektywności informacyjnej — zapisać w następujący sposób:

$$E(P_{t+1}) = (1+r)P_t + \beta_1 E(d_{t+1}) + \beta_2 E(X_{t+1}) + \beta_3 E(e_{t+1}), \quad (1.22)$$

gdzie:

r — stopa procentowa (ogólnie koszt utraconych możliwości posiadania aktywów, które mogą zawierać premię za ryzyko ponad stopę zwrotu wolną od ryzyka),

- β_1 — dodatnia stała, która szacuje wpływ przyszłej dywidendy na wzrost kapitału,
 β_2 — dodatnia stała, która określa wpływ informacji zewnętrznych (niezawartych w cenach) na stopę zwrotu (np. splity, nowe emisje, fuzje itp.),
 β_3 — dodatnia stała, która określa wpływ informacji poufnych na stopę zwrotu,
 X_t — czynniki znane badaczowi i prognozowalne, które mogą mieć wpływ na przyszłą stopę zwrotu,
 e_t — czynniki nieznane badaczowi, które jednakże mogą być znane niektórym uczestnikom rynku (np. członkom zarządów spółek akcyjnych).

Formuła (1.22) ma charakter równania przyczynowo-skutkowego wyjaśniającego, jakie czynniki opisują oczekiwania cenowe inwestorów; innymi słowy wskazuje na źródła przesłanek prognostycznych inwestorów. Z uwagi na obecność dywidendy ma ona zastosowanie głównie do cen akcji. W przypadku innych instrumentów, np. papierów dłużnych, należy zmodyfikować równanie (1.22) poprzez włączenie do niego zmiennych wpływających na ich rentowność.

Efektywność rynków finansowych oznacza, że średnio nie jest możliwe uzyskanie ponadprzeciętnych zysków z inwestycji, czyli:

$$E(R_{t+1}) = r. \quad (1.23)$$

Rozwiązując (1.21) ze względu na P_t przy założeniu (1.23), otrzymujemy:

$$P_t = \gamma E(P_{t+1}), \quad (1.24)$$

przy czym:

$$\gamma = \frac{1}{1+r}.$$

Dla krótkich okresów i niskich stóp procentowych przyjmuje się, że $r = 0$.

Z równania (1.22) wynika, że (1.24) jest prawdziwe tylko wówczas, gdy:

$$\beta_1 = \beta_2 = 0, \quad (1.25)$$

$$\beta_3 = 0 \quad \text{lub} \quad E(e_{t+1}) = 0. \quad (1.26)$$

Formuła (1.22) definiuje źródła informacji, do jakich ma dostęp inwestor. Zbiór informacji uwzględniany przez inwestora może obejmować zarówno informacje ogólnie dostępne dla wszystkich uczestników rynku (np. ceny lub publikowane prognozy cen, publikowane informacje o wynikach finansowych), jak i informacje prywatne, niedostępne powszechnie lub tajne. Stopnie efektywności rynku są więc relatywizowane zależnie od zbioru posiadanych informacji. Biorąc to pod uwagę, możemy wyróżnić słabą, średnią lub silną efektywność (Fama [1970]).

Słaba efektywność ma miejsce wówczas, gdy nie jest możliwe uzyskanie ponadprzeciętnych zysków z tytułu wykorzystania informacji tkwiących w cenach (bieżących i przeszłych). Oznacza to, że historyczna analiza szeregów czasowych

cen giełdowych nie doprowadzi do uzyskania prognoz bardziej dokładnych niż te, które można obliczyć, biorąc pod uwagę tylko bieżące ceny, które natychmiast i w pełni odzwierciedlają całą informację zawartą w historii cen papierów wartościowych.

Jeśli zachodzi słaba forma efektywności, to:

$$E(P_{t+1}) = P_t, \quad (1.27)$$

z czego wynika, że⁵:

$$P_{t+1} = P_t + e_{t+1}. \quad (1.27a)$$

Zatem zakładamy (1.25), natomiast (1.26) jest przedmiotem testowania. Jeśli słaba forma efektywności nie zachodzi, to w celu przewidywania cen można stosować narzędzia analizy technicznej.

Średnia efektywność występuje wtedy, kiedy nie jest możliwe uzyskanie dodatkowych zysków z tytułu wykorzystania wszystkich informacji powszechnie dostępnych dla uczestników rynku (publikowanych prognoz cen, analizy i oceny ekspertów dotyczących sytuacji finansowej firmy, prognoz makroekonomicznych). Oznacza to, że wszystkie powszechnie dostępne inwestorom informacje zostały już odzwierciedlone w cenach akcji przez działający mechanizm rynkowy. Odnosząc to do warunków (1.25)–(1.26), średnia forma efektywności zachodzi, jeżeli (1.25) jest pozytywnie zweryfikowany przy danym (1.26). Jeśli średnia efektywność rynku nie zachodzi, to w celu przewidywania cen można stosować narzędzia analizy fundamentalnej.

Silna efektywność występuje w przypadku, gdy nie jest możliwe uzyskanie dodatkowych zysków nawet przez wykorzystanie informacji prywatnych, niedostępnych dla innych uczestników rynku (np. wynikających z funkcji wykonywanej przez inwestora).

Jeśli średnia i wariancja e_{t+1} są przy danym P_t nieprognozowalne, czyli:

$$E(e_{t+1} | P_t) = 0, \quad \text{var}(e_{t+1} | P_t) = \text{const}, \quad (1.28)$$

to (1.27a) jest błędzeniem przypadkowym. Gdy tylko średnia jest nieprognozowalna, a wariancja (lub jakikolwiek inny moment rozkładu) może być prognozowalna, wówczas (1.27a) jest martyngalem. Martyngał odzwierciedla proces opisujący uczciwą grę rynkową, tzn. taką, że jej wartość oczekiwana jest równa zeru. Martyngał stanowi podstawę przyjmowanej obecnie wersji hipotezy słabej efektywności rynku.

4. Hipoteza racjonalnych oczekiwań

Twórcą koncepcji racjonalnych oczekiwań w ekonomii jest Muth [1961]. W 1976 roku, po kilkunastu latach zapomnienia o niej, nastąpił powrót do problematyki oczekiwań za sprawą krytyki Lucasa, który stwierdził, że pomijanie oczekiwań w modelowaniu gospodarki jest poważnym błędem (por. Osińska [2000]).

⁵ W kontekście wzoru (1.27a) przez e_{t+1} rozumie się nowe informacje.

Racjonalne oczekiwania są według definicji predykcją prawdziwej teorii ekonomicznej. Głównym wymogiem koncepcji Mutha jest to, że uczestnicy życia gospodarczego formułują swoje oczekiwania na podstawie prawdziwego i pełnego modelu strukturalnego gospodarki. Nieobserwowalne, subiektywne i różnokierunkowe oczekiwania jednostek są dokładnie równe warunkowej nadziei matematycznej opisywanej przez model. Badacze muszą znać nie tylko model generujący zmienną endogeniczną, lecz także modele generujące zmienne egzogeniczne.

Założenia hipotezy racjonalnych oczekiwań są następujące:

1. Jeżeli agenci zachowują się w sposób racjonalny, to formułując oczekiwania co do przyszłości, biorą pod uwagę całość informacji z przeszłości dostępnej w okresie t , tj. Ω_t . Informacje te zawierają wszystkie dane z okresu bieżącego i z przeszłości dotyczące zmiennych występujących w prawdziwym modelu gospodarki, jak również wszystkie inne informacje dostępne dla agenta w okresie t , włączając w to także oczekiwania z przeszłości.

2. Prognozy agentów są nieobciążone, nieskorelowane i efektywne.

Oznaczmy warunkowy rozkład prawdopodobieństwa wektora zmiennych losowych x_{t+1} przez $f(x_{t+1} | \Omega_t)$. Racjonalne oczekiwania formułuje się zwykle w odniesieniu do pierwszego momentu rozkładu, tzn.:

$${}_t x_{t+1}^e = E(x_{t+1} | \Omega_t) = \int_R x_{t+1} f(x_{t+1} | \Omega_t) dx_{t+1}, \quad (1.29)$$

gdzie:

${}_t x_{t+1}^e$ — oczekiwania formułowane w okresie t co do wartości, jaką zmienna x przyjmie w okresie $t+1$,

R — obszar zmienności zmiennych x .

Własności racjonalnych oczekiwań. Niech $x_{t+1} - {}_t x_{t+1}^e = \varepsilon_{t+1}$ oznacza błąd oczekiwań. Hipoteza racjonalnych oczekiwań zakłada, że:

$$E(\varepsilon_{t+1} | \Omega_t) = 0, \quad (1.30)$$

$$E(\varepsilon_{t+1}^2 | \Omega_t) = \sigma_\varepsilon^2, \quad (1.31)$$

$$E(\varepsilon_{t+1} \varepsilon_{t+1-j}) = 0, \quad \text{dla } j > 0. \quad (1.32)$$

W powyższym przypadku (oczekiwania na jeden okres w przód) błąd prognozy Ω_{t+1} jest białym szumem i jest niezależny (ortogonalny) od zbioru informacji Ω_t oraz jego dowolnego podzbioru Ψ_t . W ogólnym przypadku (oczekiwania na m okresów w przód) błąd prognozy jest procesem MA($m-1$).

Zachowanie warunków optymalności racjonalnych oczekiwań jest możliwe tylko wtedy, kiedy agenci znają prawdziwy model, co zdarza się niezmiernie rzadko. Ponadto model taki może nie być stabilny w czasie.

Wadą koncepcji racjonalnych oczekiwań jest nierealność założeń, w tym:

— ceny są doskonale giętkie, co powoduje, że w każdej chwili popyt i podaż wyrównują się na wszystkich rynkach,

— nie istnieją żadne koszty dostępu do informacji ani przerobu informacji dostępnych dla uczestników życia gospodarczego,

— istnieje symetria w zakresie posiadanych informacji, czyli brak jest informacyjnej nierówności między tymi, którzy tworzą politykę, a prywatnymi podmiotami gospodarczymi.

Założenie o racjonalności oczekiwań inwestorów stanowi istotne wsparcie teoretyczne dla hipotezy rynku efektywnego. Z własności wartości oczekiwanej wynika wprost liniowa postać modeli cen instrumentów finansowych.

1.5. Metody weryfikacji hipotezy słabej efektywności rynku

Przedmiotem weryfikacji statystycznej jest przede wszystkim hipoteza o słabej efektywności rynku, ponieważ ma ona bezpośredni związek z hipotezą o błędzeniu przypadkowym cen. Gdy tylko nowa informacja staje się dostępna, ceny dostosowują się w pełni i natychmiast. Rynek działa więc efektywnie w tym sensie, że inwestorzy, podejmując decyzje odnośnie do kupna lub sprzedaży, muszą znać tylko najbardziej aktualną cenę. Informacje o cenach pochodzące z okresów poprzednich (historycznych) są bowiem w niej w pełni zawarte.

Rynek efektywny odznacza się czterema charakterystycznymi cechami (Haugen [1996]):

- ceny papierów wartościowych reagują na nowe informacje bezzwłocznie i w sposób w pełni do nich adekwatny,
- zmiany cen papierów wartościowych mają charakter losowy,
- wykorzystanie w eksperymentach symulacyjnych ustalonych reguł dokonywania transakcji nie przynosi średnio wyższych zwrotów,
- profesjonalni inwestorzy nie są w stanie uzyskać średnio wyższych zysków ani działając pojedynczo, ani w grupie.

Do badania efektywności rynku służą odpowiednie testy statystyczne. Są to zarówno testy parametryczne, jak i nieparametryczne. Hipoteza błędzenia losowego jest mocniejsza od hipotezy słabej efektywności rynku, zatem dopiero jej odrzucenie wymaga przeprowadzenia testów słabej efektywności, a w przypadku braku podstaw do jej odrzucenia nie ma również podstaw do odrzucenia hipotezy o słabej efektywności rynku.

Weryfikacja hipotezy rynku efektywnego może polegać na:

- 1) zbadaniu, czy ceny instrumentów finansowych są dobrze opisane przez proces błędzenia przypadkowego⁶:

$$p_t = p_{t-1} + e_t, \quad (1.33)$$

⁶ Małe litery p_t oznaczają logarytmy cen.

- 2) zbadaniu, czy stopy zwrotu z inwestycji w instrumenty finansowe mają własności białego szumu:

$$r_t = e_t. \quad (1.34)$$

Powstaje pytanie, czy oba sposoby weryfikacji hipotezy efektywności rynku są równoważne. Odpowiedź nie jest wcale jednoznaczna. Jeżeli mamy na myśli pojedynczy szereg cen lub stóp zwrotu, to możemy oba sposoby traktować równorzędnie. Jeśli natomiast przyjmiemy, że szereg cen jest zintegrowany rzędu 1 (tak jak model błędzenia przypadkowego), to musimy dopuścić, że może on być skointegrowany z innymi szeregami. Oznacza to, że może pozostawać w długookresowej zależności z innymi zjawiskami, które są prognozowalne, a zatem na ich podstawie możemy prognozować przyszłą cenę instrumentu finansowego. Pojęcia integracji i kointegracji szeregów czasowych będą omówione odpowiednio w rozdziałach 2 i 7.

W niniejszym rozdziale skupimy się na testowaniu białoszumowych własności stóp zwrotu, gdyż w przypadku poziomów cen wystarczy jedynie dodać testowanie pierwiastka jednostkowego w równaniu cen według procedur opisanych w rozdziale 2.

W literaturze wyróżnia się trzy następujące rodzaje białego szumu:

- 1) niezależne przyrosty o jednakowych rozkładach (gaussowski biały szum),
- 2) niezależne przyrosty o różnych rozkładach,
- 3) nieskorelowane przyrosty.

Zajmiemy się weryfikacją białego szumu w ujęciu pierwszym, gdyż drugie i trzecie ujęcia są słabsze. Testowaniu będą podlegać: autokorelacja, losowość oraz normalność rozkładu stóp zwrotu.

Testowanie autokorelacji stóp zwrotu. Istnieje wiele sposobów badania autokorelacji szeregów czasowych, w tym szeregów stóp zwrotu. Można wśród nich wymienić funkcję autokorelacji i autokorelacji cząstkowej, omówione w rozdziale 2, a ponadto wiele testów statystycznych. W praktyce najczęściej stosowanym testem jest statystyka Boxa-Ljunga. Jest to tzw. statystyka portfelowa (*portmanteau statistics*), umożliwiającą testowanie hipotezy o braku autokorelacji dowolnego rzędu:

$$H_0: \forall \rho_j = 0,$$

$$H_1: \exists \rho_j \neq 0.$$

Statystyka Q' Boxa-Ljunga ma postać (por. Greene [1994]):

$$Q' = T(T+2) \sum_{j=1}^p \frac{\rho_j^2}{T-j}, \quad (1.35)$$

gdzie:

- T — liczba obserwacji (długość szeregu czasowego),
- ρ_j — współczynniki korelacji Pearsona między wartościami szeregu czasowego z okresu t i $t-j$, są to zatem współczynniki autokorelacji rzędu j ,
- j — testowany rząd autokorelacji, $j = 1, 2, 3, \dots, p$.

Do realizacji białego szumu stosuje się następujący estymator tego współczynnika:

$$\hat{\rho}_j = \frac{\sum_{t=j+1}^T e_t e_{t-j}}{\sum_{t=1}^T e_t^2} \quad (1.36)$$

Statystyka Q' posiada rozkład zbieżny do chi-kwadrat o p stopniach swobody. Znaczenie autokorelacji dla hipotezy o efektywności rynku polega na tym, że gdyby istniała dostatecznie silna autokorelacja szeregów stóp zwrotu, można by z dużym prawdopodobieństwem i dokładnością prognozować przyszłe stopy zwrotu w krótkim okresie.

Testowanie losowości stóp zwrotu. Do testowania hipotezy o losowości stosuje się na ogół testy serii oraz znaków.

Test serii Walda-Wolfowitza. Idea testu serii jest następująca: porównujemy wzrosty (1) i spadki (-1) cen akcji pod względem kolejności ich wystąpienia. Brak zmian, czyli zmiany równe zeru, są w tym teście pomijane. Należy uporządkować dane według kolejnych jednostek czasu i znaleźć takie przypadki, gdy w tak danym szeregu występują obok siebie 1 lub -1. W przypadku braku różnic między wystąpieniami wzrostów i spadków notowań liczba i długość serii 1 czy -1 powinna mieć charakter przypadkowy. Formalnie hipoteza zerowa zakłada, że dwie próby pochodzą z tej samej populacji. Jako hipotezę alternatywną przyjmujemy stwierdzenie, iż dwie próby pochodzą z dwu populacji różniących się pod względem ogólnego kształtu rozkładu.

Nie ma znaczenia, czy porównujemy różnice cen akcji, czy stopy zwrotu. Test nie bazuje na wartościach, ale na znakach; z tego powodu wzrost ceny lub dodatnia stopa zwrotu widziane są tak samo — takiej sytuacji przyporządkowaliśmy 1. Spadkowi ceny akcji czy ujemnej stopie zwrotu przyporządkowaliśmy -1.

Zapisujemy hipotezę:

$$H_0: r_t = e_t,$$

$$H_1: r_t \neq e_t.$$

Do weryfikacji postawionej hipotezy jest stosowana statystyka:

$$Z = \frac{|K - E(K)| - 0,5}{\sqrt{V(K)}}, \quad \text{dla } K \geq E(K), \quad (1.37)$$

$$Z = -\frac{|K - E(K)| - 0,5}{\sqrt{V(K)}}, \quad \text{dla } K \leq E(K), \quad (1.38)$$

gdzie:

K — liczba serii w szeregu,

$$E(K) = \frac{2n_1 n_2}{n_1 + n_2} + 1,$$

$$V(K) = \frac{2n_1 n_2 (2n_1 n_2 - n_1 - n_2)}{(n_1 + n_2)^2 (n_1 + n_2 - 1)},$$

n_1, n_2 — odpowiednio liczba dodatnich i ujemnych stóp zwrotu.

Statystyka Z ma standaryzowany rozkład normalny.

Test znaków. Test ten ma zastosowanie w sytuacjach, w których badacz dysponuje dwoma pomiarami (np. przeprowadzanymi w dwóch różnych warunkach) dla każdej jednostki i chce dowiedzieć, że pomiary (lub warunki, w jakich je przeprowadzono) się różnią. W przypadku notowań cen instrumentów finansowych test ten można zastosować w następujący sposób: po pierwsze, wzrostom notowań przyporządkować np. liczbę 1, spadkom notowań -1, a sesjom, na których zmiana nie wystąpiła, przyporządkować 0; po drugie, wzrostom notowań przyporządkować liczbę 1, a gdy wystąpi brak wzrostu (spadek lub brak zmiany) liczbę -1. Tak przekształcony szereg różnic cen bądź stóp zwrotu porównujemy z szeregiem składającym się z samych zer. Pierwsze podejście pozwoli odpowiedzieć na pytanie, czy prawdopodobieństwa pojawienia się wzrostu i spadku ceny akcji są takie same, drugie natomiast, czy prawdopodobieństwa wzrostu i braku wzrostu ceny są takie same. Podstawą drugiego podejścia jest założenie, że już sam fakt niezmięności ceny akcji przynosi inwestorowi stratę w wyniku zamrożenia gotówki.

Hipotezę zerową formułujemy w następujący sposób: dwie porównywane zmienne mają ten sam rozkład. Jako hipotezę alternatywną przyjmujemy natomiast stwierdzenie, że rozkłady dwóch zmiennych różnią się między sobą. W przypadku cen akcji porównanie odpowiednio przekształconego szeregu wzrostów i spadków notowań z szeregiem złożonym z samych zer pozwoli odpowiedzieć na pytanie, czy częstości pojawiania się wzrostów i spadków notowań różnią się między sobą istotnie. Nie bierze się tutaj pod uwagę kolejności ich pojawiania się oraz wartości. Zgodnie z hipotezą zerową (która przyjmuje, że dwie zmienne nie różnią się między sobą) oczekujemy, że przypadków, gdy jedna zmienna ma wartość wyższą od drugiej, pojawi się około 50%.

$$H_0: p = P\{X - Y > 0\} = P\{X - Y < 0\} = \frac{1}{2},$$

$$H_1: p \neq \frac{1}{2}.$$

Do weryfikacji postawionych hipotez jest stosowana statystyka postaci:

$$M = \frac{\frac{1}{T-\pi} \cdot f}{\frac{1}{T} \sqrt{\pi(1-\pi)}}, \quad (1.39)$$

gdzie:

f — liczba uzyskanych znaków „plus”,

π — prawdopodobieństwo sukcesu w próbie (tu $\frac{1}{2}$),

T — liczebność próby.

Przy założeniu prawdziwości hipotezy zerowej zmienna losowa M ma rozkład dwumianowy. Wartości krytyczne należy odczytać z tablicy testu znaków (por. Greń [1979]).

Testowanie normalności rozkładu. Do zbadania zgodności rozkładów cen akcji oraz stóp zwrotu z rozkładem normalnym wykorzystuje się następujące testy: Lillieforsa, Shapiro-Wilka oraz Bery-Jarque'a. Zasada działania poszczególnych testów jest podobna: porównują one rozkład z próby z postulowanym, teoretycznym rozkładem normalnym. Testy te niejako uzupełniają się nawzajem, gdyż w przypadku mniejszej próby lepszy jest test Shapiro-Wilka, natomiast test Lillieforsa wymaga dużej liczby obserwacji. Test Bery i Jarque'a jest jednym z najczęściej stosowanych testów w literaturze ekonometrycznej.

Hipotezy podlegające weryfikacji są następujące:

$$H_0: F(r_t) = F_N(r_t),$$

$$H_1: F(r_t) \neq F_N(r_t).$$

Test Lillieforsa [1967] jest oparty na statystyce λ -Kolmogorowa:

$$d_n = \max_{x_i} |F(x_i) - S_n(x_i)|, \quad (1.40)$$

gdzie:

$F(x)$ — dystrybuenta postulowanego rozkładu normalnego,

$S_n(x)$ — dystrybuenta empiryczna.

Statystyka λ ma postać:

$$\lambda = \sqrt{T} d_n, \quad (1.41)$$

przy czym T oznacza liczbę obserwacji. Wartości krytyczne tego testu znajduje się w tablicach rozkładu λ -Kolmogorowa.

Test W Shapiro-Wilka [1965] jest oparty na statystyce:

$$W = \frac{\left(\sum_{i=1}^{\left[\frac{n}{2} \right]} a_i(n) (x_{(n-i+1)} - x_i) \right)^2}{\sum_{j=1}^n (x_j - \bar{x})^2}, \quad (1.42)$$

gdzie:

x_j — j -ta obserwacja zmiennej X próbki uporządkowanej,

$\bar{x}$ — średnia wartość zmiennej X ,

$x_{(n-i+1)} - x_i$ — tzw. quasi-rozstępny rzędu i ,

$a_i(n)$ — stałe zależne od liczebności n próbki i od wartości i .

Wartości krytyczne testu W znajdują się w odpowiednich tablicach testu Shapiro-Wilka (np. Nowak [1990]).

Statystyka Bery-Jarque'a ma postać:

$$JB = T \left(\frac{1}{6} \beta_1 + \frac{1}{24} (\beta_2 - 3) \right)^2, \quad (1.43)$$

przy czym:

$$\sqrt{\beta_1} = \frac{1}{T} \sum_{t=1}^T e_t^3 / S^3(e_t),$$

$$\beta_2 = \frac{1}{T} \sum_{t=1}^T e_t^4 / S^4(e_t).$$

Rozkład statystyki JB jest zbliżony do rozkładu chi-kwadrat o 2 stopniach swobody.

Empiryczne szeregi finansowe III. W ramach analizy efektywności zostało przeprowadzone badanie empiryczne, polegające na zastosowaniu omówionych wyżej procedur, w celu ilustracji empirycznej dotyczącej wybranych akcji notowanych na GPW w Warszawie⁷. Przedstawione procedury zostały zastosowane w odniesieniu do danych dziennych, tygodniowych i miesięcznych. Długości dostępnych szeregów czasowych były zatem zróżnicowane.

W przeważającej większości analizowanych w tablicy 1.2 firm nie mamy podstaw do odrzucenia hipotezy o losowości stóp zwrotu. Tylko dla jednej spółki w przypadku danych dziennych i miesięcznych oraz dla czterech w przypadku danych tygodniowych odrzuciliśmy tę hipotezę. Na uwagę zasługuje fakt, że spółki te się nie pokryły.

Podobna interpretacja towarzyszy wynikom badania autokorelacji stóp zwrotu. Okazuje się empirycznie, że wpływ autozależności stóp zwrotu jest niezbyt silny, z czego można wnioskować o niewielkim wpływie tego zjawiska na możliwość przewidywania przyszłych zysków. Wyniki dotyczące wartości ocen współczynników autokorelacji rzędu I oraz ich błędów zostały zaprezentowane w tablicy 1.3, w której przedstawione prawdopodobieństwa empiryczne (wartości p) odpowiadają wynikom testu Boxa-Ljunga.

⁷ Analizę efektywności polskiego rynku papierów wartościowych znajdzie Czytelnik w pracach: Jajuga (red.) [2000], Czekał i in. [2001].

Tablica 1.2. Wyniki testu serii dla przyrostów cen

Lp.	Nazwa spółki	Dane dzienne		Dane tygodniowe		Dane miesięczne	
		Z	poziom p	Z	poziom p	Z	poziom p
1	AGORA	1,098	0,272	0,4581	0,647	-0,250	0,803
2	BIG	0,629	0,529	-1,392	0,164	-1,662	0,097
3	BRE	0,538	0,591	0,527	0,598	-1,115	0,265
4	BSK	-0,235	0,814	0,098	0,922	-1,858	0,063
5	COMARCH	-3,158*	0,002	-0,271	0,786	-0,189	0,850
6	COMPLAND	-1,386	0,166	-0,256	0,798	0,415	0,678
7	ELEKTRIM	-1,2959	0,195	1,535	0,125	-0,897	0,370
8	KABELHOLD	-0,805	0,421	0,692	0,489	-0,372	0,710
9	KGHM	0,084	0,933	1,966*	0,049	0,480	0,632
10	MOSTEXPORT	-0,325	0,745	-0,697	0,486	0,196	0,845
11	OPTIMUS	-0,551	0,582	-2,263*	0,024	0,953	0,341
12	ORBIS	-0,725	0,468	2,194*	0,028	-0,722	0,470
13	PEKAO	0,290	0,772	3,017*	0,003	0,101	0,920
14	PKNORLEN	-0,969	0,332	0,348	0,728	-0,418	0,676
15	PRGKOM	-0,220	0,826	-0,350	0,727	0,025	0,980
16	SOFTBANK	-0,718	0,473	0,308	0,758	-0,278	0,781
17	SWIECIE	0,001	0,999	1,446	0,148	-1,177	0,239
18	TPSA	1,065	0,287	-0,155	0,876	-1,706	0,088
19	WIG20	-1,074	0,283	-1,277	0,202	-2,601*	0,009
20	WIG	-0,863	0,388	0,618	0,536	-1,842	0,065

* Przypadki odrzucenia H_0 .Źródło: D. Przekota, *Badanie słabej efektywności spółek wchodzących w skład indeksu WIG20 w okresie 01.1999-07.2001*, praca magisterska napisana pod kierunkiem M. Osińskiej, UMK, Toruń 2002.

Brak zależności między stopami zwrotu oznacza, że przyszły zysk może mieć dowolną wartość, a to potwierdza błędzenie losowe cen akcji. Tylko w niektórych przypadkach współczynniki autokorelacji były istotnie różne od zera. Akurat dla tych szeregów możliwe byłoby prognozowanie przyszłych zmian na podstawie przeszłych. Warto jednak uwzględnić jeszcze koszty transakcyjne, które towarzyszą decyzjom kupna lub sprzedaży akcji. Należy także dodać, że dla danych dziennych wykorzystano 600 obserwacji, których liczba zmniejszyła się w przypadku danych tygodniowych i miesięcznych, co spowodowało odpowiednio większy błąd. Stąd wyniki powinny być porównywane jedynie w ramach tych samych częstotliwości obserwacji.

Wyniki badania normalności prawie w ogóle nie potwierdzają tej własności empirycznych rozkładów stóp zwrotu. Niewiele wyjątków miało miejsce w przypadku danych miesięcznych, jednak może to wynikać z krótszych szeregów obser-

Tablica 1.3. Wyniki badania autokorelacji stóp zwrotu rzędu I

Lp.	Nazwa spółki	Dane dzienne — przyrosty cen			Dane tygodniowe — przyrosty cen			Dane miesięczne — przyrosty cen		
		współczynnik autokorelacji	błąd standardowy	wartość p	współczynnik autokorelacji	błąd standardowy	wartość p	współczynnik autokorelacji	błąd standardowy	wartość p
1	AGORA	0,04	0,04	0,3849	0,12	0,09	0,1837	0,13	0,18	0,4597
2	BIG	0,01	0,04	0,8868	0,19*	0,09	0,0273	-0,03	0,17	0,8488
3	BRE	0,00	0,04	0,9222	-0,24*	0,09	0,0041	0,07	0,17	0,6975
4	BSK	0,01	0,04	0,8127	-0,16*	0,09	0,0620	-0,23	0,17	0,1885
5	COMARCH	0,07*	0,04	0,0780	0,01	0,09	0,9436	0,09	0,18	0,6352
6	COMPLAND	0,06	0,04	0,1269	-0,14	0,09	0,0925	-0,19	0,17	0,2634
7	ELEKTRIM	0,04	0,04	0,2949	-0,04	0,09	0,6271	0,10	0,17	0,5610
8	KABELHOLD	0,00	0,04	0,9052	-0,13	0,09	0,1364	0,02	0,17	0,9191
9	KGHM	0,02	0,04	0,6610	-0,20*	0,09	0,0221	0,08	0,17	0,6489
10	MOSTEXPORT	0,03	0,04	0,4383	-0,16*	0,09	0,0596	-0,10	0,17	0,5730
11	OPTIMUS	0,03	0,04	0,4464	0,33*	0,09	0,0001	-0,07	0,17	0,6814
12	ORBIS	0,04	0,04	0,3431	-0,33*	0,09	0,0001	0,07	0,17	0,6817
13	PEKAO	0,00	0,04	0,9963	-0,20*	0,09	0,0204	0,01	0,17	0,9758
14	PKNORLEN	-0,01	0,05	0,8991	-0,15	0,11	0,1631	-0,01	0,21	0,9599
15	PROKOM	-0,08*	0,04	0,0388	-0,11	0,09	0,1820	-0,05	0,17	0,7600
16	SOFTBANK	0,12*	0,04	0,0034	-0,16*	0,09	0,0681	0,10	0,17	0,5787
17	SWIECIE	0,00	0,04	0,9601	0,02	0,09	0,8397	-0,09	0,17	0,5943
18	TPSA	-0,03	0,04	0,4161	0,02	0,09	0,8240	0,14	0,17	0,4153
19	WIG20	-0,04	0,04	0,2741	-0,05	0,09	0,5643	0,25	0,17	0,1491
20	WIG	-0,02	0,04	0,6466	-0,09	0,09	0,2955	0,27	0,17	0,1171

* Przypadki odrzucenia H_0 .Źródło: D. Przekota, *Badanie słabej efektywności spółek wchodzących w skład indeksu WIG20 w okresie 01.1999-07.2001*, praca magisterska napisana pod kierunkiem M. Osińskiej, UMK, Toruń 2002.

wowanych zmian. Rezultaty badań zostały przedstawione w tablicy 1.4 oraz w komentarzu poniżej.

Przedstawione wyniki testów normalności dla danych dziennych we wszystkich przypadkach pozwalają na odrzucenie hipotezy zerowej o normalności rozkładu. Rozkład przyrostów cen (ani też stóp zwrotu) nie jest rozkładem normalnym. Spowodowane jest to występowaniem grubych ogonów oraz jednego ostrego wierzchołka.

W analogiczny sposób przeprowadzono badanie normalności dla danych tygodniowych i miesięcznych. Szczegółowych wyników nie prezentujemy ze względu na ograniczoną objętość książki. W przypadku danych tygodniowych tylko w jednym przypadku nie odrzucono hipotezy o normalności rozkładu. Wyniki

Tablica 1.4. Wyniki testowania normalności rozkładów dziennych stóp zwrotu

Lp.	Nazwa spółki	Liczba obserwacji	Daneienne			
			test W Shapiro-Wilka		test Lillieforsa	
			statystyka W	wartość p	statystyka λ	wartość p
1	AGORA	571	0,890*	0,0000	0,124*	0,01
2	BIG	635	0,914*	0,0000	0,087*	0,01
3	BRE	647	0,892*	0,0000	0,111*	0,01
4	BSK	646	0,950*	0,0000	0,085*	0,01
5	COMARCH	600	0,839*	0,0000	0,184*	0,01
6	COMPLAND	647	0,913*	0,0000	0,151*	0,01
7	ELEKTRIM	646	0,967*	0,0000	0,060*	0,01
8	KABELHOLD	647	0,960*	0,0000	0,076*	0,01
9	KGHM	645	0,949*	0,0000	0,067*	0,01
10	MOSTEXPORT	647	0,934*	0,0000	0,124*	0,01
11	OPTIMUS	647	0,802*	0,0000	0,221*	0,01
12	ORBIS	647	0,953*	0,0000	0,074*	0,01
13	PEKAO	647	0,942*	0,0000	0,078*	0,01
14	PKNORLEN	421	0,956*	0,0000	0,075*	0,01
15	PROKOM	647	0,913*	0,0000	0,171*	0,01
16	SOFTBANK	646	0,876*	0,0000	0,193*	0,01
17	SWIECIE	647	0,898*	0,0000	0,135*	0,01
18	TPSA	647	0,947*	0,0000	0,089*	0,01
19	WIG20	647	0,936*	0,0000	0,082*	0,01
20	WIG	647	0,939*	0,0000	0,093*	0,01

* Przypadki odrzucenia H_0 .Źródło: D. Przekota, *Badanie słabej efektywności spółek wchodzących w skład indeksu WIG20 w okresie 01.1999–07.2001*, praca magisterska napisana pod kierunkiem M. Osipińskiej, UMK, Toruń 2002.

uzyskane dla danych miesięcznych są znacząco różne od wyników uzyskanych dla danych dziennych i dla danych tygodniowych. W około połowie przypadków nie mamy prawa odrzucić hipotezy o rozkładzie normalnym. Tak różne wyniki są spowodowane krótką długością miesięcznych szeregów czasowych, co sprawia, że wnioskowanie o normalności rozkładów miesięcznych stóp zwrotu jest obciążone zbyt dużym błędem.

Przedstawione wyniki badania wskazują, że hipoteza słabej efektywności rynku kapitałowego jest w dużej mierze empirycznie potwierdzona. Testy przeprowadzone dla przyrostów cen wskazują, że najlepszą prognozą przyrostu nie jest przyrost ostatnio zrealizowany. Może to oznaczać dwie sytuacje: najlepszą prognozą przyrostu jest inny niż ostatnio zrealizowany lub nie ma możliwości prognozy.

Przychylać się należy raczej do tej drugiej możliwości. Oznacza to zgodność z wynikami uzyskanymi dla szeregów cen, gdyż brak jakiejkolwiek możliwości prognozy sugeruje, że jest to szum losowy. Uzyskane wyniki są zbliżone z publikowanymi w innych opracowaniach (por. np. Jajuga (red.) [2000], Czekaj i in. [2001]).

1.6. Efektywność rynków a efekty kalendarzowe

Na wielu rynkach finansowych, ale głównie na giełdach papierów wartościowych obserwuje się tzw. anomalie, które mogą podważać lub zakłócać hipotezę efektywności. Jeżeli są one regularne, można podjąć próbę ich modelowania oraz prognozowania. Należą do nich (por. np. Cuthbertson [1997], Szyszka [1999]):

1. Efekt miesiąca w roku — efekt stycznia:
 - stopy zwrotu w styczniu są przeciętnie znacznie wyższe niż w innych miesiącach roku,
 - są potwierdzone w badaniach empirycznych dla 16 krajów rozwiniętych,
 - dotyczą w większym stopniu spółek o mniejszej kapitalizacji,
 - są spowodowane wyprzedzają w grudniu akcje przynoszących straty (spadek cen); te same akcje inwestorzy decydują się nabywać w styczniu (wzrost cen).
2. Rozkład stóp zwrotu w ciągu miesiąca:
 - wyższe stopy zwrotu w ciągu pierwszej połowy miesiąca niż w ciągu drugiej.
3. Efekt dnia w tygodniu — efekt poniedziałku:
 - poniedziałkowe stopy zwrotu są przeciętnie niższe niż w pozostałych dniach tygodnia,
 - dłuższy niż zwykle czas na podjęcie decyzji między sesją piątkową i poniedziałkową (efekt weekendu).
4. Efekt godziny w dniu:
 - niższe stopy zwrotu w pierwszej godzinie trwania sesji w poniedziałek, wyższe zaś w pierwszej godzinie trwania sesji w pozostałych dniach,
 - wyższe stopy zwrotu w ciągu ostatnich 15 minut trwania sesji we wszystkich dniach tygodnia.

Do testowania efektów sezonowych można stosować wiele metod. Jedną z najprostszych jest znany test na równość dwóch średnich stóp zwrotu. Badamy dwie populacje generalne mające rozkłady normalne o znanych odchyleniach standardowych σ_1 i σ_2 . Na podstawie wyników dwu niezależnych prób, o liczebnościach n_1 i n_2 , należy sprawdzić hipotezy:

$$H_0: E(r_1) = E(r_2),$$

$$H_1: E(r_1) \neq E(r_2).$$

Statystyka z ma rozkład normalny:

$$z = \frac{\bar{r}_1 - \bar{r}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \quad (1.44)$$

lub w przypadku nieznanych odchyłeń standardowych:

$$z = \frac{\bar{r}_1 - \bar{r}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (1.44a)$$

W przypadku małej próby należy stosować modyfikację testu na równość dwóch średnich, który ma wtedy rozkład t -Studenta. Wymaga on uprzedniej weryfikacji hipotezy o równości wariancji w badanych próbach lub przyjęcia stosownego założenia. Testy te są na ogół znane z podstawowego kursu statystyki.

W odniesieniu do GPW w Warszawie wyniki empiryczne są niejednoznaczne (por. Szyszka [1999]). Wynika to głównie z faktu, że giełda w Warszawie jest jeszcze młodym, niedojrzałym rynkiem, wrażliwym na wiele czynników zewnętrznych. Występowanie efektów sezonowych na ogół kojarzy się z zaprzeczeniem hipotezy rynku efektywnego, co jednak nie musi być interpretowane tak jednoznacznie, jeśli hipotezę tę zinterpretuje się jako niemożność stałego osiągania ponadnormalnych dochodów (por. Cuthbertson [1997]).

Przykład 1.1

Rozważmy codienne obserwacje dotyczące zwykłych stóp zwrotu w okresie 3.01.2000–8.10.2004 spółek Novita i TPSA oraz indeksu WIG20. W pierwszej kolejności dane zostały uporządkowane zgodnie z kalendarzem, co oznacza, że wyeliminowano z nich dni braku notowań. Wyznaczono wartości średnie ze względu na dzień tygodnia (tablica 1.5). W badaniu przyjęto, że odchylenia standardowe stóp zwrotu w poszczególnych dniach tygodnia są nieznane. Wyniki zastosowania testu z przedstawione zostały w tablicy 1.6.

Analizując wyniki możemy stwierdzić, że w Novicie dostrzegana jest różnica między średnimi stopami zwrotu z poniedziałków i wtorków. Średnia stopa zwrotu z poniedziałków jest ujemna, natomiast średnia z wtorków jest najwyższą dodatnią średnią stopą zwrotu z poszczególnych dni tygodnia. W pozostałych dniach tygodnia nie zaobserwowano istotnych różnic między średnimi. W przypadku Telekomunikacji Polskiej S.A. — ujemna średnia stopa zwrotu z poniedziałków istotnie różni się od dodatnich średnich z czwartków i piątków. Dla pozostałych średnich wartości statystyki z nie dają podstaw do odrzucenia H_0 . W przypadku indeksu WIG20 zachodzi istotna różnica między średnimi stopami zwrotu z środy a średnimi z piątków. Średnie z środy są ujemne i zarazem najniższe, natomiast średnie z piątków są, co do modułu, zbliżone, ale dodatnie. W pozostałych przypadkach nie występują różnice między średnimi stopami zwrotu.

Tablica 1.5. Średnie i wariancje stóp zwrotu w poszczególnych dniach tygodnia

Dzień tygodnia	Liczba obserwacji	Średnia	Wariancja
Novita			
Poniedziałek	147	−0,006453	0,005715
Wtorek	148	0,016139	0,004534
Środa	159	0,001381	0,004996
Czwartek	149	−0,000474	0,004779
Piątek	150	0,008095	0,005410
TPSA			
Poniedziałek	237	−0,003852	0,000681
Wtorek	242	0,001444	0,000615
Środa	241	−0,002030	0,000730
Czwartek	238	0,001880	0,000676
Piątek	238	0,001843	0,000723
WIG20			
Poniedziałek	237	−0,000662	0,000356001
Wtorek	242	0,001076	0,000299330
Środa	241	−0,002240	0,000320138
Czwartek	238	0,000152	0,000281028
Piątek	238	0,002425	0,000317481

Źródło: K. Kluth, *Analiza efektów sezonowych na polskim rynku kapitałowym*, praca magisterska napisana pod kierunkiem M. Osińskiej, UMK, Toruń 2005.

Tablica 1.6. Wyniki weryfikacji hipotezy o jednakowych średnich w poszczególnych dniach tygodnia

Dni tygodnia	Novita Wartość testu z	TPSA Wartość testu z	WIG20 Wartość testu z
Poniedziałek – wtorek	−1,919*	−1,610	−0,743
Poniedziałek – środa	−0,661	−0,530	0,664
Poniedziałek – czwartek	−0,502	−1,695*	−0,352
Poniedziałek – piątek	−1,188	−1,656*	−1,296
Wtorek – środa	1,325	1,041	1,464
Wtorek – czwartek	1,484	−0,133	0,420
Wtorek – piątek	0,697	−0,119	−0,595
Środa – czwartek	0,165	−1,141	−1,068
Środa – piątek	−0,578	−1,111	−2,022*
Czwartek – piątek	−0,734	0,011	−1,014

* Odrzucenie hipotezy o równości średnich stóp zwrotu z poszczególnych dni, co najmniej na poziomie istotności 0,1.

Źródło: K. Kluth, *Analiza efektów sezonowych na polskim rynku kapitałowym*, praca magisterska napisana pod kierunkiem M. Osińskiej, UMK, Toruń 2005.

Pytania i problemy

1. Porównaj cechy zwykłych i logarytmicznych stóp zwrotu z inwestycji.
2. Jakie są typowe cechy empirycznych finansowych szeregów czasowych?
3. Dla wybranego szeregu kursów akcji policz zwykle i logarytmiczne stopy zwrotu; porównaj różnice.
4. Wyjaśnij pojęcie rozkładu stopy zwrotu. Jakie teoretyczne rozkłady wykorzystuje się w modelowaniu stóp zwrotu?
5. Wygeneruj po 1000 obserwacji o rozkładzie normalnym $N(0, 1)$ i o rozkładzie mieszanym $N(0; 0,9)$ i $N(0; 1,9)$, $\alpha = 0,1$, a następnie porównaj na wykresie cechy obu rozkładów.
6. Na czym polega hipoteza efektywności rynku? Jakie są jej implikacje ekonometryczne?
7. W jaki sposób weryfikuje się hipotezę efektywności rynków?
8. Jakie są cechy i konsekwencje przyjęcia założenia o racjonalności oczekiwań inwestorów giełdowych?
9. Testowanie autokorelacji stóp zwrotu — metody i spostrzeżenia empiryczne.
10. Testowanie losowości stóp zwrotu.
11. Metody testowania normalności rozkładów. Jakie są konsekwencje niespełnienia założenia o normalności rozkładów w przypadku szeregów finansowych?
12. Wskaż przykłady efektów sezonowych na rynkach finansowych.

Rozdział 2

Modele jednowymiarowych szeregów czasowych

Słowa kluczowe: proces stochastyczny, szereg czasowy, modele ARMA, ARIMA, SARIMA — identyfikacja, estymacja, prognozowanie, testowanie pierwiastków jednostkowych, modelowanie długiej pamięci

Metody i modele ekonometrii finansowej odnoszą się w znacznej mierze do finansowych szeregów czasowych. W niniejszym rozdziale zostaną omówione podstawowe modele jednowymiarowych szeregów czasowych stosowane do opisu warunkowej wartości oczekiwanej. Stanowią one bazę, na której powstały nowoczesne modele ekonometrii finansowej odnoszące się w znacznej części do warunkowych momentów wyższych rzędów. Bez zrozumienia treści tego rozdziału trudno będzie studiować następne. Metodologia tutaj omówiona należy już do klasyki ekonometrii dynamicznej opartej na modelach szeregów czasowych. Część z nich została opisana w klasycznej publikacji Boxa i Jenkinsa [1983] (wyd. oryg. 1976). Inne pochodzą z okresów jeszcze wcześniejszych, a w polskiej literaturze były analizowane w pionierskich pracach Zielińskiego [1979] oraz Talagi i Zielińskiego [1986], a także ich następców. W niniejszym rozdziale omawiamy tylko te modele i ich charakterystyki, które — naszym zdaniem — są najczęściej wykorzystywane w ekonometrii finansowej lub są niezbędne do zrozumienia dalszej partii materiału. Pełniejszy obraz przedstawianych zagadnień znajdzie Czytelnik m.in. w następnych publikacjach Endersa [1995] oraz Brockwella i Davisa [1996].

2.1. Procesy stochastyczne i szeregi czasowe

Teoria procesów stochastycznych stanowi o istocie ekonometrii w okresie ostatnich kilkudziesięciu lat, a oparte na niej dynamiczne modele ekonometryczne znajdują zastosowanie w wielu zagadnieniach finansowych. Najbardziej popularne określenie modelu dynamicznego podają Bauwens, Lubrano i Richard [1999], z którego wynika, że model jest dynamiczny zawsze wtedy, gdy zmienne są indeksowane po czasie i występują z różnymi odstępami czasowymi. Ścisła definicja wymaga wprowadzenia pojęć procesu stochastycznego i szeregu czasowego.

Definicja 2.1

Procesem stochastycznym nazywamy funkcję losową zmiennych losowych X oraz nielosowego argumentu t , oznaczającego czas. Procesy stochastyczne zapisuje się za pomocą następujących symboli: X_t , Y_t lub odpowiednio $X(t)$, $Y(t)$.

Definicja 2.2

Szereg czasowy jest realizacją procesu stochastycznego; oznaczamy go przez x_t , y_t .

W ekonomii można wskazać wiele procesów, które będziemy określać jako ekonomiczne procesy stochastyczne. Są to wszystkie zjawiska, które dadzą się przedstawić w kolejnych jednostkach czasu, na przykład: dochód narodowy w danym kraju w kolejnych latach, kurs walutowy w kolejnych dniach, stopa procentowa kredytów czy wreszcie ceny papierów wartościowych notowane każdego dnia czy nawet w odstępach sekundowych. Jeżeli dysponujemy obserwacjami liczbowymi dotyczącymi ww. czy też innych procesów stochastycznych z kolejnych jednostek czasu, to mówimy o ekonomicznych szeregach czasowych.

Z praktycznego punktu widzenia w badaniach ekonometrycznych najczęściej rozważa się procesy stochastyczne stacjonarne w szerszym sensie oraz procesy niestacjonarne.

Definicja 2.3

Proces stochastyczny Y_t jest *stacjonarny w szerszym sensie*, jeżeli:

$$E(Y_t) = \text{constans}, \quad (2.1)$$

$$D^2(Y_t) = \text{constans}, \quad (2.2)$$

$$\text{cov}(Y_t, Y_s) = K(s-t) = K(\tau). \quad (2.3)$$

Niespełnienie jednego z warunków (2.1)–(2.3) oznacza, że proces jest niestacjonarny w zakresie jednego z parametrów rozkładu, tzn. wartości oczekiwanej, wariancji oraz funkcji kowariancyjnej. Procesy niestacjonarne, zwłaszcza w zakresie wariancji i funkcji kowariancyjnej, nie mają ściśle określonej trajektorii przebiegu, dlatego wnioskowanie na ich podstawie może prowadzić do błędów. W trakcie wstępnej analizy ekonometrycznej empirycznych szeregów czasowych należy rozpoznać rodzaj niestacjonarności i opisać za pomocą odpowiedniego modelu¹.

W analizie procesów stochastycznych szczególnie użyteczne jest pojęcie białego szumu.

¹ Na ogół jest to jednoznaczne z eliminacją niestacjonarności.

Definicja 2.4

Biały szum ε_t jest to stacjonarny proces stochastyczny spełniający następujące warunki:

$$E(\varepsilon_t) = 0, \quad (2.4)$$

$$D^2(\varepsilon_t) = \sigma^2, \quad (2.5)$$

$$\text{cov}(\varepsilon_t, \varepsilon_s) = K(s-t) = 0, \quad \text{dla } s-t > 0. \quad (2.6)$$

W przypadku dynamicznych modeli ekonometrycznych własności białego szumu są najbardziej pożądane dla składników resztowych tych modeli.

2.3 Modele stacjonarnych procesów stochastycznych

Ogólnym modelem opisującym stacjonarny proces stochastyczny jest model ARMA(p, q). Model ARMA (*autoregressive moving average*) procesu stochastycznego Y_t ma postać:

$$\alpha(B)Y_t = \beta(B)\varepsilon_t, \quad (2.7)$$

gdzie:

$\alpha(B) = 1 - \alpha_1 B - \dots - \alpha_p B^p$ — operator autoregresji rzędu p ,

$\beta(B) = 1 - \beta_1 B - \dots - \beta_q B^q$ — operator średniej ruchomej rzędu q ,

ε_t — biały szum,

lub:

$$Y_t = \alpha_1 Y_{t-1} + \dots + \alpha_p Y_{t-p} + \varepsilon_t - \beta_1 \varepsilon_{t-1} - \dots - \beta_q \varepsilon_{t-q}. \quad (2.8)$$

Model (2.7) stanowi kombinację dwóch modeli rozważanych także oddzielnie:

— modelu autoregresyjnego rzędu p (oznaczamy AR(p) lub ARMA($p, 0$))

postaci:

$$\alpha(B)Y_t = \varepsilon_t,$$

— modelu średniej ruchomej rzędu q (oznaczamy MA(q) lub ARMA(0, q))

postaci:

$$Y_t = \beta(B)\varepsilon_t.$$

Własności modelu ARMA(p, q) są następujące. Proces opisany równaniem (2.7) jest:

— *stacjonarny*, jeżeli wszystkie pierwiastki zespolone równania charakterystycznego $\alpha(B) = 0$ nie leżą na okręgu jednostkowym,

— *kauzalny*, jeżeli wszystkie pierwiastki równania charakterystycznego $\alpha(B) = 0$ leżą na zewnątrz okręgu jednostkowego.

— *odwracalny*, jeżeli wszystkie pierwiastki równania charakterystycznego $\beta(B) = 0$ leżą na zewnątrz okręgu jednostkowego.

Stacjonarność modelu ARMA jest pojęciem szerszym niż jego kauzalność. Stacjonarny proces (2.7) można zapisać w postaci nieskończonej średniej ruchomej $MA(\infty)$, tzn.:

$$Y_t = \alpha^{-1}(B)\beta(B)\varepsilon_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}, \quad (2.9)$$

przy czym:

$$\psi_0 = 1,$$

$$\psi_j = \sum_{i=1}^{\min(p,j)} \alpha_i \psi_{j-i} - \beta_j, \quad j > q \Rightarrow \beta_j = 0, \quad j = 1, 2, \dots$$

Minimalna reprezentacja ARMA. W celu uniknięcia nadmiernej parametryzacji modelu ARMA, definiuje się tzw. reprezentację minimalną tego modelu.

Definicja 2.5

Proces stacjonarny Y_t posiada *minimalną reprezentację ARMA* (p, q) , jeśli można go opisać równaniem (2.7), przy czym:

- 1) $\alpha_p \neq 0, \quad \beta_q \neq 0$,
- 2) Y_t jest kauzalny i odwracalny,
- 3) wielomiany $\alpha(B), \beta(B)$ nie mają wspólnych pierwiastków²,
- 4) ε_t jest białym szumem z wariancją $\sigma^2 \neq 0$.

Minimalna reprezentacja ARMA gwarantuje zarówno stacjonarność, jak i odwracalność modelu. Model ARMA, który posiada minimalną reprezentację, można zapisać zarówno w postaci nieskończonego modelu średniej ruchomej $MA(\infty)$ (2.9), jak i w postaci nieskończonego modelu autoregresyjnego $AR(\infty)$:

$$\begin{cases} \alpha(B)\beta^{-1}(B)Y_t = \varepsilon_t, \\ \sum_{j=0}^{\infty} \pi_j Y_{t-j} = \varepsilon_t, \end{cases} \quad (2.10)$$

² Wspólne pierwiastki (*common factors*) powiększają rzędy opóźnień p i q , a ich rozpoznanie prowadzi do redukcji tych rzędów; odpowiednie procedury znajdują się m.in. w pracy: Charemza, Deadman [1997].

przy czym:

$$\pi_0 = 1,$$

$$\pi_j = \sum_{i=1}^{\min(q,j)} \beta_i \pi_{j-i} - \alpha_j, \quad j > p \Rightarrow \alpha_j = 0, \quad j = 1, 2, \dots$$

2.3 Identyfikacja modeli ARMA(p, q)

W niniejszym podrozdziale rozważymy dwa typy narzędzi identyfikacji rzędu modelu ARMA(p, q) oparte na funkcji autokorelacji oraz na minimalizacji wariancji składnika resztowego modelu. Podstawowym narzędziem służącym do identyfikacji modeli są funkcja autokorelacji ACF (*autocorrelation function*) oraz funkcja autokorelacji cząstkowej PACF (*partial autocorrelation function*).

Funkcja autokorelacji procesu stochastycznego przy odstępie τ jest wyrażona wzorem:

$$R(\tau) = \frac{K(\tau)}{K(0)}, \quad (2.11)$$

gdzie:

$K(\tau)$ — funkcja kowariancyjna (lub autokowariancyjna),

$K(0)$ — wariancja procesu.

W próbie korzysta się z odpowiednich oszacowań funkcji kowariancyjnej oraz wariancji. Estymator współczynnika autokorelacji jest dany jako:

$$r(\tau) = \frac{c(\tau)}{c(0)} = \frac{c(\tau)}{D^2(y_t)}, \quad (2.12)$$

gdzie $c(\tau)$ oznacza estymator funkcji kowariancyjnej, przy odstępie $\tau = 0, 1, 2, \dots, p$, postaci:

$$c(\tau) = \frac{\frac{1}{T-\tau} \sum_{t=j+1}^T (y_t - \bar{y})(y_{t-j} - \bar{y})}{\frac{1}{T} \sum_{t=1}^T (y_t - \bar{y})^2}, \quad (2.13)$$

gdzie $j = 1, 2, \dots, \tau$ i $\bar{y}_{t-\tau} = \sum_{t=j+1}^T y_{t-j} / (T-\tau)$ (por. Wiśniewski, Zieliński [1998]).

Funkcja autokorelacji informuje o autozależności, czyli tzw. pamięci procesu stochastycznego. Oznacza to, że wpływ impulsu dokonanego w czasie t może trwać dłużej lub krócej, zależnie od liczby niezerowych współczynników autokorelacji.

Funkcja autokorelacji cząstkowej jest zdefiniowana za pomocą następujących równań:

$$\alpha(0) = 1, \quad (2.14)$$

$$\alpha(\tau) = \phi_{\tau\tau}, \quad \tau \geq 1, \quad (2.15)$$

gdzie:

$\phi_{\tau\tau}$ — ostatni element rozwiązania układu równań, przy $\tau = 0, 1, \dots, p$,

$$\phi_{\tau} = \Gamma_{\tau}^{-1} K(\tau),$$

przy czym:

$$\Gamma_{\tau} = [K(i-j)]_{i,j=1}^{\tau},$$

$$K(\tau) = [K(1), K(2), \dots, K(\tau)].$$

W praktyce współczynniki autokorelacji cząstkowej są współczynnikami korelacji między błędami predykcji $Y_t - P(Y_t | Y_1, \dots, Y_{t-1})$ oraz $Y_0 - P(Y_0 | Y_1, \dots, Y_{t-1})$, przy rozszerzaniu modelu o kolejne opóźnienia, tzn. zmianie τ od 0 do p . Równoważnie można je także traktować jako współczynniki regresji w równaniu Y_t względem stałej i opóźnionych o τ wartości Y_t . Określają one korelację między Y_t i $Y_{t-\tau}$, przy pominięciu wpływu wszystkich pozostałych opóźnień.

Estymacja współczynników autokorelacji cząstkowej odbywa się za pomocą metody najmniejszych kwadratów lub równań Yule'a-Walkera, opisanych w podrozdziale 2.4. Możliwe jest także zastosowanie następującego wzoru iteracyjnego:

$$\phi_{\tau\tau} = \begin{cases} r(1), & \text{dla } \tau = 1, \\ \frac{r(\tau) - \sum_{j=1}^{\tau-1} \phi_{\tau-1,j}(\tau-1)}{1 - \sum_{j=1}^{\tau-1} \phi_{\tau-1,j} r_{\tau-1}}, & \text{dla } \tau > 1, \end{cases} \quad (2.16)$$

gdzie:

$r(\tau)$ — oszacowany współczynnik autokorelacji rzędu τ ,

$$\phi_{\tau j} = \phi_{\tau-1,j} - \phi_{\tau} \phi_{\tau-1,\tau-j}.$$

Zasady identyfikacji:

• Jeśli proces jest typu AR(p), to funkcja autokorelacji maleje wykładniczo lub jest sinusoidą o zmniejszającej się amplitudzie wahań, natomiast funkcja autokorelacji cząstkowej urywa się (równa się zero) po odstępie p .

• Jeśli proces jest typu MA(q), to funkcja autokorelacji urywa się po odstępie q , a funkcja autokorelacji cząstkowej maleje wykładniczo lub jest sinusoidą o zmniejszającej się amplitudzie wahań.

• Jeśli proces jest typu ARMA(p, q), to zarówno funkcja autokorelacji, jak i autokorelacji cząstkowej łagodnie zanikają w taki sposób, że funkcja autokorelacji procesu mieszanego ARMA(p, q) po $q-p$ odstępach jest sumą zanikających funkcji wykładniczych i tłumionych sinusoid, a funkcja autokorelacji cząstkowej po $p-q$ odstępach jest zdominowana przez zanikające funkcje wykładnicze i tłumione sinusoidy.

Opisana metoda nie zawsze daje jednoznaczne wyniki, zwłaszcza w przypadku modeli ARMA. Dlatego jest ona często uzupełniana tzw. testem Quinoille'a, który stosuje się zwykle do określenia rzędu opóźnień modeli autoregresyjnych. Zachodzi bowiem:

$$\begin{cases} \phi_{\tau,\tau} \neq 0, & \text{dla } \tau \leq p, \\ \phi_{\tau,\tau} = 0, & \text{dla } \tau > p. \end{cases} \quad (2.17)$$

Do sprawdzenia hipotez:

$$H_0: \phi_{\tau,\tau} = 0,$$

$$H_1: \phi_{\tau,\tau} \neq 0,$$

stosuje się statystykę t postaci:

$$t = \frac{\hat{\phi}_{\tau,\tau}}{S(\hat{\phi}_{\tau,\tau})}. \quad (2.18)$$

Jeżeli $t \geq 2$, to współczynnik jest statystycznie istotny. Statystyka t ma rozkład t -Studenta.

Przyjmując, że:

$$S(\hat{\phi}_{\tau,\tau}) = \frac{1}{\sqrt{n}} \quad (2.19)$$

i podstawiając do (2.18), mamy:

$$\hat{\phi}_{\tau,\tau} \geq \frac{2}{\sqrt{n}}. \quad (2.20)$$

Jeżeli $\hat{\phi}_{\tau,\tau} < \frac{2}{\sqrt{n}}$, to następuje zanikanie autokorelacji cząstkowej; rząd mo-

delu AR nie będzie większy od p . W praktyce τ ustala się na poziomie nieprzekraczającym 20% długości szeregu czasowego obejmującego n obserwacji. W praktyce najczęściej stosowanym testem służącym do badania autokorelacji³ dowolnego rzędu jest statystyka Boxa-Ljunga, omówiona w podrozdziale 1.5.

³ W praktyce ekonometrycznej powszechnie używa się statystyki Durбина-Watsona, której zastosowanie jest jednak ograniczone do przypadku autokorelacji rzędu 1 oraz braku występowaniu w modelu opóźnionej zmiennej zależnej; por. Gajda [2002]. Nie znajduje ona zatem poprawnego zastosowania w modelu typu ARMA.

Wyniki funkcji autokorelacji i autokorelacji cząstkowej bywają niejednoznaczne, dlatego w takich przypadkach rekomenduje się wykorzystanie kryteriów informacyjnych.

Kryteria informacyjne jako metoda identyfikacji modelu ARMA w empirycznych szeregach czasowych. W celu wyznaczenia rzędu opóźnień modelu ARMA przyjmuje się relatywnie wysokie p i q (np. ARMA(3, 3)) i szacuje modele zawierające wszystkie możliwe kombinacje $p \leq 3$ i $q \leq 3$. Następnie oblicza się jedno z poniższych kryteriów.

1. Kryterium informacyjne Akaike'a (AIC):

$$AIC = T \ln \hat{\sigma}_e^2 + 2k, \quad (2.21)$$

gdzie:

T — liczba obserwacji,

k — liczba szacowanych parametrów,

$\hat{\sigma}_e^2$ — estymator największej wiarygodności wariancji reszt.

Wybrany zostaje model, dla którego utrata informacji jest najmniejsza, to znaczy taki model, dla którego AIC przyjmuje wartość najmniejszą.

2. Bayesowskie rozszerzenie minimum AIC (BIC):

$$BIC = (T-k) \ln \frac{\hat{\sigma}_e^2}{T-k} + T \ln T + k \ln \frac{\hat{\sigma}_e^2 - \hat{\sigma}_e^2}{k}, \quad (2.22)$$

gdzie $\hat{\sigma}_e^2$ jest estymatorem wariancji szeregu.

Wybrany zostaje model, dla którego BIC jest najmniejsze. Jeśli BIC i AIC mają minima dla różnych rzędów p, q , to w wyborze kierujemy się kryterium BIC . Kryterium BIC jest modyfikacją kryterium AIC i koryguje skłonność AIC do używania zbyt dużej liczby parametrów.

3. Bayesowskie kryterium Schwartz'a (SC):

$$SC = T \ln \hat{\sigma}_e^2 + k \ln T; \quad (2.23)$$

wyбір modelu jest dokonywany na podstawie minimalnej wartości kryterium.

4. Kryterium Hannana-Quinna (HQ):

$$HQ = -T \ln \hat{\sigma}_e^2 + k \ln (\ln T). \quad (2.24)$$

5. Kryterium błędu predykcji (FPE):

$$FPE = \frac{n+p}{n-p} \hat{\sigma}_e^2; \quad (2.25)$$

wybrany zostaje model, dla którego FPE przyjmuje wartość najmniejszą. Im większa wartość FPE , tym p jest mniejsze. Kryterium tym posługujemy się tylko wówczas, gdy mamy do czynienia z procesem $AR(p)$.

2.4. Estymacja parametrów modeli ARMA(p, q)

Metody estymacji parametrów modelu ARMA(p, q) można podzielić na 2 grupy:

1) metody estymacji parametrów modelu ARMA($p, 0$) — faktycznie modeli autoregresyjnych: równania Yule'a-Walkera, klasyczna metoda najmniejszych kwadratów, metoda największej wiarygodności,

2) metody estymacji parametrów modelu ARMA(p, q) oraz ARMA($0, q$) — czyli modeli średniej ruchomej: metoda największej wiarygodności; do estymacji parametrów modelu ARMA nie można stosować metody najmniejszych kwadratów, ponieważ zmienne występujące w części MA mają charakter zmiennych nieobserwowalnych.

Równania Yule'a-Walkera. W przypadku skończonego modelu $AR(p)$ dla szeregu y_t parametry autoregresji można wyrazić poprzez układ równań współczynników autokorelacji zwanych równaniami Yule'a-Walkera:

$$\begin{cases} R(1) = \alpha_1 + \alpha_2 R(1) + \dots + \alpha_p R(p-1), \\ R(2) = \alpha_1 R(1) + \alpha_2 + \dots + \alpha_p R(p-2), \\ \vdots \\ R(p) = \alpha_1 R(p-1) + \alpha_2 R(p-2) + \dots + \alpha_p. \end{cases} \quad (2.26)$$

Rozwiązując ten układ równań, otrzymujemy:

$$\alpha = \mathbb{R}_p^{-1} \mathbf{p}_p, \quad (2.27)$$

przy czym:

$$\alpha = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_p \end{bmatrix}, \quad \mathbf{p}_p = \begin{bmatrix} R(1) \\ R(2) \\ \vdots \\ R(p) \end{bmatrix}, \quad \mathbb{R}_p = \begin{bmatrix} 1 & R(1) & R(2) & \dots & R(p-1) \\ R(1) & 1 & R(1) & \dots & R(p-2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ R(p-1) & R(p-2) & R(p-3) & \dots & 1 \end{bmatrix}.$$

Zastępując wartości teoretyczne funkcji autokorelacji odpowiednimi oszacowaniami z próby, otrzymujemy oceny Yule'a-Walkera parametrów modelu $AR(p)$.

Metoda najmniejszych kwadratów. Innym sposobem ustalenia wartości parametrów modelu AR jest zastosowanie MNK. Estymator MNK daje takie same wyniki jak estymator największej wiarygodności, zaś oceny Yule'a-Walkera parametrów autoregresyjnych w pewnych sytuacjach mogą się różnić od oszacowań MNK. Estymator Yule'a-Walkera jest często wykorzystywany w celu uzyskania oszacowań początkowych.

Metoda największej wiarygodności. Metodę tę stosuje się do estymacji parametrów modelu ARMA(p, q). Logarytm funkcji wiarygodności jest dany wzorem:

$$\ln L(\alpha, \beta, \sigma_\varepsilon^2) = -\frac{T}{2} \ln 2\pi\sigma_\varepsilon^2 - \frac{S(\alpha, \beta)}{2\sigma_\varepsilon^2}, \quad (2.28)$$

przy czym:

$$S(\alpha, \beta) = \sum_{t=-M}^n [E(\varepsilon_t | \alpha, \beta, y)]^2,$$

gdzie M jest dostatecznie dużą liczbą całkowitą, taką że dla $t \leq -(M+1)$ wartość $E(y_t | \alpha, \beta, y) - E(y_{t-1} | \alpha, \beta, y)$ jest mniejsza od ustalonej z góry wartości ε .

Wybrane zostają te oceny wartości parametrów α, β , dla których funkcja (2.28) osiąga maksimum. Należy zatem zminimalizować $S(\alpha, \beta)$. Estymacja parametrów modelu ARMA dzieli się na dwa etapy. W pierwszym uzyskuje się oszacowania początkowe parametrów (np. według metody Yule'a-Walkera lub przyjmuje się z góry zadane), w drugim zaś modyfikuje się początkowe wartości parametrów tak, aby zminimalizować sumę kwadratów reszt. Większość standardowych pakietów statystycznych i ekonometrycznych (np. Statistica, Eviews) umożliwia zastosowanie dowolnej z omówionych metod do danych empirycznych. Najważniejszym problemem empirycznym pozostaje zatem identyfikacja rzędów opóźnień modelu ARMA.

Prognozowanie na podstawie modeli ARMA(p, q)

Prognozowanie na podstawie modelu ARMA oznacza prognozowanie wartości szeregu czasowego y_t wyrażonego jako ważona suma bieżących i poprzednich impulsów tegoż szeregu oraz szeregu białego szumu. Zapiszmy model ARMA dla szeregu y_t :

$$\alpha(B)y_t = \beta(B)\varepsilon_t, \quad (2.29)$$

co można rozpisać jako:

$$y_t = -\alpha_1 y_{t-1} - \alpha_2 y_{t-2} - \dots - \alpha_p y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \beta_2 \varepsilon_{t-2} + \dots + \beta_q \varepsilon_{t-q}. \quad (2.30)$$

Prognoza na h okresów w przód ma postać:

$$y_{t+h} = -\alpha_1 y_{t+h-1} - \alpha_2 y_{t+h-2} - \dots - \alpha_p y_{t+h-p} + \varepsilon_{t+h} + \beta_1 \varepsilon_{t+h-1} + \beta_2 \varepsilon_{t+h-2} + \dots + \beta_q \varepsilon_{t+h-q}; \quad (2.31)$$

oblicza się ją jako warunkową wartość oczekiwaną szeregu⁴:

$$\hat{y}_t(h) = E(y_{t+h} | y_t, y_{t-1}, \dots), \quad (2.32)$$

⁴ Zgodnie z zasadą predykcji nieobciążonej; por. Zeliaś [1997].

czyli:

$$E(y_{t+j} | y_t, y_{t-1}, \dots) = \begin{cases} y_{t+j}, & j \leq 0, \\ \hat{y}_t(j), & j > 0, \end{cases} \quad (2.33)$$

$$E(\varepsilon_{t+j} | \varepsilon_t, \varepsilon_{t-1}, \dots) = \begin{cases} \varepsilon_{t+j}, & j \leq 0, \\ 0, & j > 0, \end{cases} \quad (2.34)$$


gdzie $j = 1, 2, \dots, h$.

Oznacza to, że aby obliczyć prognozy, podstawiamy za przeszłe oczekiwania y_{t+j} i ε_{t+j} , a za przyszłe oczekiwania odpowiednio prognozę $\hat{y}_t(j)$, natomiast pozostałe wartości są zerami.

Przykład 2.1

Podjęto próbę dopasowania modelu ARMA(1, 1) do danych dotyczących stóp zwrotu z kursów walut PLN/EURO (deuro), obserwowanych dziennie w okresie 1.01.1999–25.04.2003.

Rysunek 2.1. Wykresy szeregu empirycznego deuro oraz odpowiadających mu funkcji autokorelacji i autokorelacji cząstkowej



Źródło: Opracowanie własne.

Wartości funkcji ACF i PACF, a także statystyki Boxa-Ljunga i odpowiadające im prawdopodobieństwa empiryczne zostały podane w tablicy 2.1.

Tablica 2.1. Wartości ACF, PACF oraz statystyki Q' dla deuro

Odstęp	ACF	PACF	Q'	p
1	-0,097	-0,097	10,353	0,001
2	-0,014	-0,024	10,563	0,005
3	-0,124	-0,129	27,407	0
4	0,024	-0,002	28,014	0
5	-0,069	-0,075	33,181	0
6	0,053	0,024	36,216	0
7	-0,01	-0,005	36,322	0
8	0,013	-0,003	36,516	0
9	-0,001	0,01	36,518	0
10	-0,039	-0,046	38,211	0
11	0,072	0,073	43,89	0
12	0,052	0,064	46,84	0
13	0,047	0,058	49,302	0
14	-0,074	-0,042	55,329	0
15	0,026	0,026	56,059	0
16	0,016	0,044	56,345	0
17	-0,017	-0,023	56,659	0
18	0,006	0,016	56,699	0

Źródło: Opracowanie własne.

Najlepszym modelem okazał się ARMA(1, 1). Model ten oszacowany na podstawie 1086 obserwacji ma postać zaprezentowaną w tablicy 2.2.

Tablica 2.2. Oszacowany model ARMA(1, 1) dla deuro

Zmienna	Ocena parametru	Błąd oceny	Statystyka t -Studenta	Wartość p
AR(1)	0,549527	0,138693	3,962182	0,0001
MA(1)	-0,664511	0,124106	-5,354365	0,0000
R^2	0,019143	średnia zmiennej zależnej		0,000193
Błąd standardowy reszt	0,031055	odchylenie standardowe zmiennej zależnej		0,031342
		AIC		-4,104251
Logarytm funkcji wiarygodności	2230,608	SC		-4,095061

Źródło: Opracowanie własne.

Oceny parametrów modelu są istotne statystycznie, natomiast z klasycznych wskaźników najwięcej wątpliwości budzi R^2 , którego wartość nie przekracza 2%. Jest to zjawisko typowe w analizie dziennych stóp zwrotu z instrumentów finansowych, które cechują się bardzo wysokim stopniem zmienności. Wynika z tego, że mimo dobrych własności oszacowany model ARMA jest niewystarczający do opisu zmian stóp zwrotu z dziennych inwestycji w walutę euro.

Przykład 2.2

Wykorzystując koncepcję modeli ARMA w połączeniu z efektami sezonowymi, włączonymi w postaci zmiennych zero-jedynkowych dla wybranych okresów otrzymuje się model opisujący stopy zwrotu z uwzględnieniem na przykład efektu poniedziałku. Rozważmy przykład dotyczący stóp zwrotu z akcji spółki Novita. W tablicy 2.3 przedstawione zostały średnie i wariancje stóp zwrotu w poszczególnych dniach tygodnia.

Tablica 2.3. Charakterystyka stóp zwrotu wg dni tygodnia spółki Novita w okresie 3.01.2000–8.10.2004

Dzień tygodnia	Liczba obserwacji	Średnia	Wariancja
Poniedziałek	147	-0,006453	0,005715
Wtorek	148	0,016139	0,004534
Środa	159	0,001381	0,004996
Czwartek	149	-0,000474	0,004779
Piątek	150	0,008095	0,005410

Źródło: K. Kluth, *Analiza efektów sezonowych na polskim rynku kapitałowym*, praca magisterska napisana pod kierunkiem M. Osłuskiej, UMK, Toruń 2005.

Wyniki testu z na równość dwóch średnich (por. rozdział 1) wskazują na to, że w przypadku spółki Novita ujemna średnia stopa zwrotu z poniedziałków istotnie różni się od dodatniej średniej z wtorków. Dla pozostałych średnich wartości statystyki z nie dają podstaw do odrzucenia H_0 , czyli można założyć, że są jednakowe. Oszacowany model ARMA(1, 1) ze zmiennymi zero-jedynkowymi ma postać:

$$Novita_t = \underset{(0,0038)}{0,0008} - \underset{(0,0017)}{0,0086} Q_1 + \underset{(0,0039)}{0,0073} Q_2 + \underset{(0,055)}{0,67} y_{t-1} + \varepsilon_t - \underset{(0,045)}{0,79} \varepsilon_{t-1}, \quad (2.35)$$

gdzie:

$$Q_1 = \begin{cases} 1 & \text{w poniedziałek,} \\ 0 & \text{w pozostałe dni tygodnia,} \end{cases}$$

$$Q_2 = \begin{cases} 1 & \text{we wtorek,} \\ 0 & \text{w pozostałe dni tygodnia.} \end{cases}$$

W nawiasach podane zostały błędy średnie ocen parametrów. Istotny okazał się efekt poniedziałku, to znaczy, że stopa zwrotu z akcji Novita w poniedziałki jest przeciętnie mniejsza od średniej o 0,0086 (0,86%) niż w inne dni tygodnia. Ponadto we wtorki stopa zwrotu z akcji badanej firmy jest przeciętnie wyższa od średniej o 0,0073 (0,73%).

2.2. Niestacjonarne procesy stochastyczne i ich modele

Procesy, które nie spełniają jednego lub wszystkich warunków stacjonarności (2.1)–(2.3) są procesami niestacjonarnymi.

Rozważmy składnikową reprezentację procesu stochastycznego postaci:

$$Y_t = P_t + S_t + \eta_t, \quad (2.36)$$

gdzie:

P_t — składnik trendu, który wyznacza zasadniczy kierunek rozwoju danego zjawiska w czasie; jest to funkcja mająca gładki i spokojny przebieg, bo zmiany trendowe są związane z długim okresem,

S_t — składnik sezonowy określający wahania sezonowe (wahania cykliczne o okresie rocznym),

η_t — składnik stochastyczny (stacjonarny lub niestacjonarny) o średniej zero,

$P_t + S_t$ — składnik niestochastyczny opisujący zmiany wartości średniej procesu, tzn. $E(Y_t) = P_t + S_t$ i $E(\eta_t) = 0$.

W literaturze rozważa się ponadto następującą addytywną reprezentację procesu stochastycznego:

$$Y_t = P_t + S_t + \mu_t + \delta_t + \eta_t, \quad (2.37)$$

gdzie — poza wymienionymi oznaczeniami — μ_t oznacza trend w wariancji (trend stochastyczny), a δ_t — stochastyczną sezonowość; wówczas składnik η_t jest pozbawiony niestacjonarności. W ogólnym przypadku przyjmuje się postać ARMA(p, q) dla reszt.

2.2.1. Modele procesów niestacjonarnych w zakresie wartości średniej

Do opisu zmiennej wartości średniej procesu mogą służyć modele trendu deterministycznego i wahań sezonowych.

Model trendu. Najczęściej stosowana, wielomianowa funkcja trendu ma postać:

$$P_t = \sum_{j=1}^r \alpha_j t^j, \quad (2.38)$$

gdzie:

r — stopień wielomianu trendu,

t — zmienna czasowa.

Jest ona przyjmowana wtedy, kiedy nie mamy żadnych innych informacji o postaci funkcji trendu. Modele trendu deterministycznego odnoszą się zwłaszcza do procesów obserwowanych w długich i bardzo długich okresach, np. można wyznaczyć długookresowy trend rosnący dla indeksu giełdy nowojorskiej obserwowanego w latach 1900–2003. Inwestorzy nie patrzą jednak na zyski z papierów wartościowych w kategoriach trendów długookresowych. Ich horyzont inwestycyjny jest znacznie krótszy⁵. Nazywa się go często spekulacyjnym. W krótkim okresie liczy się przede wszystkim płynność aktywów finansowych oraz ich zyskowność. Stąd znaczenie trendów deterministycznych w modelowaniu cen instrumentów finansowych nie jest zbyt duże.

Model sezonowości. Regularne wahania sezonowe, które mają okres roczny, spotyka się w wielu procesach ekonomicznych (np. popyt na niektóre towary, inflacja, bezrobocie, produkt krajowy brutto). W odniesieniu do zjawisk finansowych rzadziej obserwuje się taką regularność, aczkolwiek nie wyklucza się pewnych efektów sezonowych, o których mowa w podrozdziale 1.5 oraz w przykładzie 2.2.

Deterministyczny model sezonowości periodycznej zapiszemy w postaci:

$$S_t = \sum_{k=1}^m d_k Q_{kt}, \quad (2.39)$$

gdzie:

d_k — parametr mierzący efekt sezonowy w danym cyklu roku w porównaniu z wartością średnią, która może być stała lub generowana przez trend; zakłada

się, że $\sum_{k=1}^m d_k = 0$,

m — liczba sezonów w ciągu roku, $m = 4, 12, 36$ itp.,

$Q_{kt} = \begin{cases} 1, & \text{zjawisko występuje,} \\ 0, & \text{zjawisko nie występuje.} \end{cases}$

Sezonowe zmienne zero-jedynkowe przyjmują wartość jeden zawsze w tym samym okresie roku, w pozostałych zaś są równe zero. Bardziej formalnie spełniają one relację modulo m , tzn. wartość jeden przyjmują zawsze wtedy, gdy $t-k$ jest podzielne przez m .

⁵ Wystarczy zwrócić uwagę na horyzont obligacji skarbowych; na ogół nie przekracza on 10–20 lat.

Ekonometryczny model szeregu niestacjonarnego z trendem liniowym i sezonowością kwartalną można zapisać jako:

$$Y_t = \alpha_0 + \alpha_1 t + \sum_{k=1}^4 d_k Q_{kt} + \eta_t. \quad (2.40)$$


W celu estymacji parametrów powyższego modelu stosuje się metodę najmniejszych kwadratów, przy czym wymagana jest w tym przypadku jego modyfikacja do formy:

$$Y_t = \alpha_0 + \alpha_1 t + \sum_{k=1}^3 d_k Q_{kt} + \eta_t, \quad (2.41)$$

a efekt sezonowy czwartego kwartału oblicza się ze wzoru $d_4 = -\sum_{k=1}^3 d_k$.

Na rysunku 2.2 został przedstawiony typowy przykład szeregu czasowego zawierającego trend oraz wahania sezonowe.

Rysunek 2.2. Przykładowa realizacja szeregu niestacjonarnego zawierającego trend liniowy oraz sezonowość periodyczną



Źródło: Opracowanie własne.

2.6.2. Modele procesów niestacjonarnych w zakresie wariancji oraz funkcji kowariancyjnej

Model ARIMA. Podstawową klasą modeli opisujących procesy niestacjonarne w zakresie wariancji są modele ARIMA(p, d, q). Model ARIMA (autoregresyjny (p) zintegrowany (d) proces średniej ruchomej (q)) opisuje proces zintegrowany⁶ i może być zapisany jako:

$$\alpha(B)\Delta^d Y_t = \beta(B)\varepsilon_t, \quad (2.42)$$

⁶ Słowo zintegrowany pochodzi od angielskiego *integrated*, które tłumaczy się jako sumacyjny lub skalkowany. W literaturze występują wszystkie wymienione terminy: por. Charemza, Deadman [1997], Kufel [2002].

przy czym:

$$\alpha(B) = (1 - \alpha_1 B - \alpha_2 B^2 - \dots - \alpha_p B^p),$$

$$\Delta^d = (1 - B)^d,$$

$$\beta(B) = (1 - \beta_1 B - \beta_2 B^2 - \dots - \beta_q B^q).$$

Model ARIMA(p, d, q) oznacza, że po obliczeniu różnic rzędu d (d -krotnym różnicowaniu szeregu czasowego) otrzymujemy proces stacjonarny ARMA(p, q), stąd metodologia dotycząca modeli ARMA nie traci na aktualności. Modele ARIMA należą do klasy procesów zintegrowanych rzędu d , co się często oznacza jako $Y_t \sim I(d)$.

Przyjęcie hipotezy modelowej postaci ARIMA nie wyklucza niestacjonarności w zakresie wartości średniej. Jednak w praktyce nie istnieją metody identyfikacji pozwalające na jednoznaczne rozróżnienie obu typów niestacjonarności. Trend deterministyczny jest jednoznacznie określony przez postać funkcyjną, natomiast modele ARIMA generują, nawet przy tych samych parametrach, różne przebiegi szeregów czasowych, co zależy głównie od warunków początkowych oraz od zmian wariancji. Należy pamiętać, że model deterministyczny (wielomianowy lub inny) opisuje tylko wahania systematyczne o najdłuższym okresie, zastosowanie natomiast operatora różnicowego pozwala na usunięcie trendu zarówno w średniej, jak i w wariancji. W efekcie może to powodować zniekształcenia badanych szeregów, takie jak na przykład autokorelacja (por. Pilatowska [2003]).

Model błędzenia przypadkowego. Szczególny przypadek modelu ARIMA stanowi model błędzenia przypadkowego (*random walk*):

$$Y_t = Y_{t-1} + \varepsilon_t, \quad (2.43)$$

gdzie symbolem ε_t oznaczono biały szum.

Inne zapisy tego modelu są następujące:

$$(1 - B)Y_t = \varepsilon_t, \quad (2.43a)$$

$$\Delta Y_t = \varepsilon_t. \quad (2.43b)$$

Model błędzenia przypadkowego jest w istocie modelem ARIMA(0, 1, 0).

Rozważmy sposób powstawania procesu błędzenia przypadkowego. Niech wartość szeregu czasowego y_t w okresie 0 jest równa wartości szeregu losowego ε_0 , tj.:

$$y_0 = \varepsilon_0.$$

Będziemy ją nazywali wartością początkową szeregu czasowego. Zakłada się przy tym, że wszystkie wartości szeregu ε_t pochodzą z rozkładu normalnego o średniej zero i wariancji σ^2 .

Następnie — zgodnie z wzorem (2.43) — postępujemy według poniższego schematu:

$$\begin{aligned} y_1 &= y_0 + \varepsilon_1 = \varepsilon_0 + \varepsilon_1, \\ y_2 &= y_1 + \varepsilon_2 = \varepsilon_0 + \varepsilon_1 + \varepsilon_2, \\ &\vdots \\ y_t &= \sum_{i=0}^t \varepsilon_{t-i}. \end{aligned} \quad (2.44)$$

Proces błędzenia przypadkowego powstaje w wyniku sumowania białych szumów, stąd jego nazwa — sumacyjny.

Proces zintegrowany ma wariancję zmienną w czasie, co oznacza, że jest niestacjonarny w zakresie wariancji:

$$\text{var}(y_t) = \sum_{i=0}^t \text{var}(\varepsilon_{t-i}). \quad (2.45)$$

Ponieważ wariancja białego szumu wynosi $\sigma^2 = \text{const}$, więc odpowiednio dla t białych szumów mamy:

$$\text{var}(y_t) = \sum_{i=0}^t \text{var}(\varepsilon_{t-i}) = t\sigma^2, \quad (2.46)$$

co oznacza występowanie trendu w wariancji procesu; jest to trend stochastyczny.

Na rysunku 2.3 zostały przedstawione przykładowy proces błędzenia przypadkowego oraz jego charakterystyki. W teorii oraz w praktyce występuje także proces błędzenia przypadkowego z dryfem. Jego postać jest następująca:

$$Y_t = \alpha + Y_{t-1} + \varepsilon_t. \quad (2.47)$$

Stosując zapis:

$$\Delta Y_t = \alpha + \varepsilon_t, \quad (2.48)$$

widzimy, że model ten łączy liniową postać trendu deterministycznego z trendem stochastycznym, gdyż sposób tworzenia tego modelu przebiega według schematu:

$$\begin{aligned} y_0 &= \varepsilon_0, \\ y_1 &= \alpha + y_0 + \varepsilon_1 = \alpha + \varepsilon_0 + \varepsilon_1, \\ y_2 &= \alpha + y_1 + \varepsilon_2 = \alpha + \alpha + \varepsilon_0 + \varepsilon_1 + \varepsilon_2, \\ &\vdots \\ y_t &= \alpha t + \sum_{i=0}^t \varepsilon_{t-i}. \end{aligned} \quad (2.49)$$


W teorii procesów stochastycznych istotne jest także pojęcie martyngału, które w finansach nabiera szczególnego znaczenia (por. LeRoy [1989]). Pozwala ono bowiem rozróżnić założenia dotyczące nieprzewidywalności momentów wyższych rzędów.

Definicja 2.6

Niech $Y_1, Y_2, Y_3, \dots$ będzie ciągiem zmiennych losowych i niech $\Omega_1, \Omega_2, \Omega_3$ będzie rosnącym ciągiem zasobów informacji (tj. $\Omega_1 \subset \Omega_2 \subset \Omega_3 \subset \dots$). Y_t jest martyngałem określonym przez $\{\Omega_t\}$, jeżeli spełnione są następujące warunki:

- 1) Y_t jest mierzalne w odniesieniu do Ω_t ,
- 2) istnieje skończona wartość oczekiwana co do wartości Y_t (tj. $E(Y_t) < \infty$),
- 3) $E(Y_t | \Omega_{t-1}) = Y_{t-1}$ z prawdopodobieństwem równym 1.

Rysunek 2.3. Cechy procesu błędzenia przypadkowego (ACF i PACF)



Źródło: Opracowanie własne.

Należy zauważyć, że szereg generowany przez model błędzenia przypadkowego charakteryzuje się dłuższą pamięcią aniżeli stacjonarne szeregi AR, MA i ARMA. Funkcja autokorelacji maleje liniowo, zatem spadek ten następuje wolniej niż w przypadku szeregów stacjonarnych. Funkcja autokorelacji cząstkowej wskazuje jednoznacznie na jedno opóźnienie autoregresyjne.

Model SARIMA. Model uwzględniający stochastyczne pierwiastki sezonowe nosi nazwę SARIMA (sezonowy model ARIMA — *seasonal ARIMA*). Jeżeli proces:

$$Y_t = (1 - B^s)X_t \quad (2.50)$$

możemy opisać za pomocą stacjonarnego i odwracalnego modelu ARMA $\alpha(B)Y_t = \beta(B)\varepsilon_t$, to model:

$$\alpha(B)(1-B^s)X_t = \beta(B)\varepsilon_t \quad (2.51)$$

jest szczególnym przypadkiem ogólnego modelu SARIMA (por. Brockwell, Davis [1996]).

Najprostszym przypadkiem sezonowego modelu ARIMA jest:

$$Y_t = Y_{t-s} + \varepsilon_t, \quad (2.52)$$

który możemy nazwać sezonowym modelem błędzenia przypadkowego (por. Ghysels, Osborn, Rodrigues [1999]). Własności tego procesu można przedstawić, zapisując go w postaci oddzielnych obserwacji dla każdego sezonu (okresu w roku). Niech:

$$Y_t = Y_{s+5(n-1)} = Y_{sn},$$

przy czym subskrypt s odnosi się do sezonu, n do roku, a S oznacza liczbę sezonów w roku.

W analogiczny sposób można zdefiniować proces zakłóceń:

$$\varepsilon_t = \varepsilon_{s+5(n-1)} = \varepsilon_{sn}.$$

Jeżeli dysponujemy liczbą obserwacji obejmujących N pełnych lat ($N = TS$), to model (2.52) możemy zapisać jako model błędzenia przypadkowego dla poszczególnych sezonów jako:

$$Y_{sn} = Y_{s0} + \sum_{j=1}^n \varepsilon_{sj}, \quad (2.53)$$

przy czym $s = 1, \dots, S$; $n = 1, \dots, N$.

Definicja 2.7

Niech d i D oznaczają nieujemne liczby całkowite. Proces X_t jest sezonowym procesem ARIMA $[(p, d, q) \times (P, D, Q)]$ o okresie s , jeżeli proces:

$$Y_t = (1-B)^d (1-B^s)^D X_t \quad (2.54)$$

może być opisany za pomocą kauzalnego modelu ARMA postaci:

$$\alpha(B)A(B^s)Y_t = \beta(B)B(B^s)\varepsilon_t, \quad (2.55)$$

gdzie:

ε_t — biały szum,

$$\alpha(B) = 1 - \alpha_1 B - \dots - \alpha_p B^p; \quad A(B) = 1 - A_1 B - \dots - A_P B^P,$$

$$\alpha(B) = 1 - \beta_1 B - \dots - \beta_q B^q; \quad B(B) = 1 - B_1 B - \dots - B_Q B^Q.$$

Model (2.55) ma dość skomplikowaną strukturę, ponieważ zakłada on zarówno zwykle, jak i sezonowe pierwiastki jednostkowe, a ponadto opóźnienia AR i MA w strukturze czasowej procesu oraz w strukturze sezonowej. Badania empiryczne wskazują, że D rzadko jest większe niż 1, natomiast P i Q nie przekraczają 3.

Model (2.55) można zapisać w prostszej formie, a mianowicie:

$$\alpha^*(B)Y_t = \beta^*(B)\varepsilon_t, \quad (2.56)$$

przy czym $\alpha^*(B)$, $\beta^*(B)$ są odpowiednio wielomianami stopnia $p+sP$ i $q+sQ$.

Użyteczność modelu SARIMA polega na założeniu, że cykle sezonowe nie muszą odtwarzać dokładnie tego samego przebiegu co roku, jak zakładano w modelu sezonowości deterministycznej⁷.

Podwójny filtr różnicowy:

$$\Delta_d \Delta_s = (1-B)^d (1-B^s)^D \quad (2.57)$$

jest używany do usuwania pierwiastków jednostkowych z sezonowych szeregów czasowych. Najpierw usuwa się pierwiastki sezonowe, wyznaczając różnice sezonowe (D razy), a następnie niesezonowe pierwiastki jednostkowe. Na przykład, jeżeli kwartalne szeregi czasowe są przekształcane za pomocą filtru różnicowego:

$$\Delta_1 \Delta_4 = (1-B)(1-B^4), \quad (2.58)$$

to znaczy, że stosujemy operator postaci:

$$\Delta_1 \Delta_4 = (1-B)(1-B^4) = (1-B)(1-B)(1+B)(1-iB)(1+iB). \quad (2.59)$$


Podwójny filtr zakłada zatem obecność 5 pierwiastków jednostkowych w autoregresyjnym wielomianie modelu ARMA dla kwartalnego szeregu x_t . Dwa pierwiastki odpowiadają niesezonowej częstości, tj. $(1-B)^2$, przy czym jeden z nich usuwa trend stochastyczny. Pozostałe trzy $(1+B)$, $(1-iB)$, $(1+iB)$ odpowiadają za sezonowe pierwiastki $\{-1, +i, -i\}$, które likwidują sezonową strukturę, implikują cykle stochastyczne o okresie półrocznym i rocznym.

W celu prezentacji został wygenerowany najprostszy szereg SARIMA o sezonowości miesięcznej według następującego wzoru:

$$y_t = y_{t-12} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1). \quad (2.60)$$

Zarówno funkcja autokorelacji, jak i autokorelacji cząstkowej wskazują na istotność 12. (czyli sezonowego) opóźnienia. Istotność opóźnień 4. i 6. wskazuje na obecność cykli o okresie kwartalnym i półrocznym. Ilustruje to rysunek 2.4.

⁷ Wyróżniamy deterministyczne modele sezonowości stałej i zmiennej. W przypadku sezonowości zmiennej zakłada się zmienność cyklu sezonowego, ale zwykle odbywa się to według jakiejś deterministycznej funkcji, jak na przykład w modelu Hannana; por. Zielński [1979].

Rysunek 2.4. Realizacja procesu SARIMA $y_t = y_{t-12} + \varepsilon_t$ 

Źródło: Opracowanie własne.

Estymacja parametrów modelu SARIMA jest analogiczna do estymacji w przypadku modelu ARMA (po zróżnicowaniu), podobnie zresztą jak i prognozowanie.

2.7. Identyfikacja procesów niestacjonarnych w zakresie wariancji

2.7.1. Podstawowe testy na obecność pierwiastka jednostkowego

Identyfikacji procesu ARIMA dokonuje się w zakresie ustalenia rzędu różnic sprowadzających proces do stacjonarności, a także głębokości opóźnień autoregresyjnych oraz średniej ruchomej (p i q). W odniesieniu do ostatnich stosuje się metody opisane przy identyfikacji modeli ARMA. W zakresie ustalenia rzędu d stosuje się testy dotyczące obecności pierwiastków jednostkowych wielomianu $\alpha(B) = 0$.

Integracyjna statystyka Durbina-Watsona. Do stwierdzenia, czy zmienna y_t jest zintegrowana w stopniu 0 — czyli stacjonarna w zakresie wariancji — bez badania wyższych stopni integracji, służy test oparty na statystyce Durbina-Watsona. Statystyka testowa wyraża się wzorem:

$$IDW = \frac{\sum_{t=2}^T (y_t - y_{t-1})^2}{\sum_{t=1}^T (y_t - \bar{y}_t)^2}, \quad (2.61)$$

gdzie:

 y_t — obserwacje procesu Y_t w okresie t , $\bar{y}_t$ — średnia wartość szeregu y_t .

Test ten nie wymaga szacowania równania regresji. Bazuje on na fakcie, że:

$$\sum (y_t - y_{t-1})^2 = \sum \varepsilon_t^2 \quad (2.62)$$

w przypadku, gdy $\rho = 1$ w równaniu $y_t = \rho y_{t-1} + \varepsilon_t$. Jeżeli rzeczywiście $\rho = 1$, to wartość statystyki IDW powinna być bliska zeru. W zastosowaniach empirycznych wartości statystyki mniejsze od 0,5 traktuje się jako świadczące o istnieniu pierwiastka jednostkowego, natomiast wartości bliskie 2 oznaczają, że zmienna jest zintegrowana w stopniu 0, czyli szereg jest stacjonarny w zakresie wariancji.

Test Dickeya-Fullera. Jest to najpopularniejszy i najczęściej stosowany test na obecność pierwiastków jednostkowych. Nie ma on niestety dużej mocy, w związku z czym zbyt często faworyzuje hipotezę o istnieniu pierwiastka jednostkowego. Niemniej jednak może być stosowany jako jedno z narzędzi identyfikacji pierwiastka jednostkowego w szeregach finansowych.

Przyjmijmy, że model szeregu czasowego jest dany wzorem:

$$y_t = \rho y_{t-1} + \varepsilon_t. \quad (2.63)$$

Hipoteza zerowa mówi o istnieniu co najmniej pierwiastka jednostkowego w badanym szeregu, natomiast hipoteza alternatywna o jego braku:

$$H_0: \rho = 1 \Rightarrow y_t \sim I(1),$$

$$H_1: \rho < 1 \Rightarrow y_t \sim I(0).$$

Aby test był operacyjny, przedstawimy model w postaci:

$$y_t - y_{t-1} = \rho y_{t-1} - y_{t-1} + \varepsilon_t, \quad (2.64)$$

czyli:

$$\Delta y_t = \delta y_{t-1} + \varepsilon_t, \quad (2.65)$$

przy czym:

$$\delta = \rho - 1.$$

Zapiszemy odpowiednie hipotezy:

$$H_0: \delta = 0 \Rightarrow y_t \sim I(1),$$

$$H_1: \delta < 0 \Rightarrow y_t \sim I(0),$$

przy czym hipoteza zerowa powinna być interpretowana w ten sposób, że szereg y_t jest zintegrowany co najmniej rzędu 1. Brak podstaw do odrzucenia H_0 nie oznacza zatem zakończenia procedury. Model (2.63) jest modelem bez stałej. Równanie to może jednak zawierać składnik deterministyczny w postaci stałej, trendu liniowego (lub wielomianowego) oraz składnika sezonowego. Odpowiednie modyfikacje będą miały postaci:

$$y_t = \alpha + \rho y_{t-1} + \varepsilon_t, \quad y_t = \alpha_0 + \alpha_1 t + \rho y_{t-1} + \varepsilon_t \quad \text{lub} \quad y_t = \sum_{k=1}^m d_k Q_{kt} + \rho y_{t-1} + \varepsilon_t.$$

Dołączenie kolejnych elementów do równania (2.63) ma określone konsekwencje dla rozkładu testu DF i ADF , co można zauważyć także w tablicach wartości krytycznych.

Test Dickeya-Fullera ma postać:

$$DF = \frac{\hat{\delta}}{S(\hat{\delta})}. \quad (2.66)$$

Statystyka DF , mimo prostej formy, posiada niestandardowy rozkład, lewostronnie asymetryczny. Wybrane wartości krytyczne zostały podane w tablicy 2.3.

Kryteria wyboru są następujące:

- $DF \leq DF_0$ — odrzucamy H_0 , szereg y_t jest zintegrowany rzędu 0, czyli stacjonarny w wariancji i procedura się kończy,
- $DF > DF_0$ — nie ma podstaw do odrzucenia H_0 , szereg y_t jest zintegrowany co najmniej rzędu 1, należy dalej badać dla $d \geq 1$.

W dalszej kolejności obliczamy drugie różnice i uzależniamy od pierwszych różnic:

$$\Delta^2 y_t = \delta \Delta y_{t-1} + \varepsilon_t. \quad (2.67)$$

Hipoteza zerowa oznacza, że szereg zawiera co najmniej dwa pierwiastki jednostkowe, alternatywna zaś, że jest dokładnie jeden. Odpowiednie hipotezy mają postać:

$$H_0: \delta = 0 \Rightarrow y_t \sim I(2),$$

$$H_1: \delta < 0 \Rightarrow y_t \sim I(1).$$

Jeżeli:

- $DF \leq DF_0$ — odrzucamy H_0 , szereg jest zintegrowany rzędu 1,
- $DF > DF_0$ — nie ma podstaw do odrzucenia H_0 , szereg jest zintegrowany co najmniej rzędu 2, należy powtórzyć procedurę dla $I(3)$.

Na ogół otrzymuje się niskie wartości d . Gdyby badanie było kontynuowane dłużej, wówczas w pewnym momencie doszlibyśmy do nadmiernego zróżnicowania i w ogóle nie mielibyśmy do czynienia z procesem zintegrowanym.

Zwykły test Dickeya-Fullera dobrze sprawdza się w przypadku, gdy mamy do czynienia z modelem $ARIMA(0, d, 0)$. Gdy mamy do czynienia z modelem $ARIMA(p, d, q)$, musimy uwzględnić autokorelację. W tym przypadku właściwy jest test ADF (*augmented Dickey-Fuller* — rozszerzony test Dickeya-Fullera). Równania podlegające testowaniu są następujące:

$$\Delta y_t = \delta y_{t-1} + \sum_{i=1}^k \alpha_i \Delta y_{t-i} + \varepsilon_t, \quad (2.68)$$

przy hipotezach:

$$H_0: \delta = 0,$$

$$H_1: \delta < 0$$

oraz:

$$\Delta^2 y_t = \delta \Delta y_{t-1} + \sum_{i=1}^k \alpha_i \Delta^2 y_{t-i} + \varepsilon_t, \quad (2.69)$$

przy hipotezach:

$$H_0: \delta = 0,$$

$$H_1: \delta < 0.$$

Pozostała część procedury nie ulega zmianie. Wielkość k ustala się na podstawie funkcji autokorelacji i autokorelacji cząstkowej lub kryteriów informacyjnych.

Tablica 2.4. Wybrane wartości krytyczne testu DF/ADF przy poziomie istotności 5%

n	Model bez stałej	Model ze stałą	Model z trendem liniowym	Model z sezonowością kwartalną
25	-1.95	-3.00	-3.60	-3.97*
50	-1.95	-2.93	-3.50	-2.96*
100	-1.95	-2.89	-3.43	-2.93*
250	-1.95	-2.88	-3.43	-2.91*
500	-1.95	-2.87	-3.42	—
∞	-1.95	-2.86	-3.41	—

* W tablicy podano jedynie dolne wartości krytyczne, które jednoznacznie przesądzą o wyniku testu. Źródło: Fuller [1976]; Charemza, Dendman [1997].

Przykład 2.3

Obecność pierwiastków jednostkowych w empirycznych szeregach finansowych ilustruje tablica 2.5. Pokazano w niej wyniki testu DF z dryfem (stałą) dla dziennych obserwacji wybranych spółek w okresie 1999–2001.

Tablica 2.5. Wyniki testu DF dla cen akcji i przyrostów cen akcji

Spółka	Dane dziennie – równanie z dryfem					
	ceny			przyrosty cen		
	delta	błąd standardowy	DF	delta	błąd standardowy	DF
AGORA	-0,0042	0,0037	-1,118	-0,9633	0,0400	-24,096
BIG	-0,0080	0,0050	-1,612	-0,9944	0,0398	-24,978
BRE	-0,0129	0,0062	-2,094	-0,9962	0,0395	-25,248
BSK	-0,0118	0,0058	-2,032	-0,9907	0,0395	-25,112
COMARCH	-0,0077	0,0046	-1,684	-0,9282	0,0408	-22,727
COMPLAN	-0,0115	0,0054	-2,124	-0,9401	0,0394	-23,880
ELEKTRIM	-0,0075	0,0059	-1,274	-0,9589	0,0394	-24,324
KABELHOL	-0,0071	0,0051	-1,392	-0,9953	0,0394	-25,252
KGHM	-0,0125	0,0056	-2,251	-0,9828	0,0395	-24,883
MOSTOSTAL	-0,0238	0,0090	-2,648	-0,9696	0,0394	-24,622
OPTIMUS	-0,0048	0,0038	-1,274	-0,9701	0,0394	-24,611
ORBIS	-0,0028	0,0042	-0,672	-0,9628	0,0394	-24,428
PEKAO	-0,0067	0,0051	-1,320	-1,0002	0,0394	-25,359
PKNORLEN	-0,0111	0,0078	-1,428	-1,0062	0,0490	-20,538
PROKOM	-0,0096	0,0056	-1,707	-1,0811	0,0393	-27,504
SOFTBANK	-0,0044	0,0044	-0,992	-0,8848	0,0392	-22,570
SWIECIE	-0,0073	0,0042	-1,727	-0,9980	0,0394	-25,311
TPSA	-0,0093	0,0059	-1,579	-1,0319	0,0394	-26,170
WIG20	-0,0053	0,0043	-1,231	-1,0429	0,0394	-26,480
WIG	-0,0075	0,0048	-1,554	-1,0180	0,0394	-25,833

Źródło: D. Przekota, *Badanie słabej efektywności spółek wchodzących w skład indeksu WIG20 w okresie od 1999-07-2001*, praca magisterska napisana pod kierunkiem M. Osińskiej, UMK, Toruń 2002.

Przyjmując wartość krytyczną $-2,86$, możemy zauważyć, że wszystkie badane szeregi cen akcji zawierają pierwiastek jednostkowy, ich przyrosty są natomiast we wszystkich przypadkach stacjonarne.

Testowanie pierwiastków jednostkowych w przypadku zmiany strukturalnej

W celu identyfikacji procesu zintegrowanego rzędu 1 w porównaniu z modelem trendu deterministycznego, w którym nastąpiła pojedyncza zmiana strukturalna, można stosować test Perrona⁸. Metoda ta może być używana do wykrywania wpływu

⁸ Por. Perron [1989]. Więcej informacji na temat testu Perrona można znaleźć w pracach Osińskiej [1995], Płutowskiej [1995] oraz Syczewskiej [1999]. Pracą monograficzną opisującą ten rodzaj zagadnień w kontekście zarówno integracji, jak i kointegracji procesów stochastycznych jest publikacja Krauzego [2002].

pojedynczych wydarzeń lub decyzji o charakterze jakościowym (politycznym, ekonomicznym, społecznym itp.) na zmiany w poziomie zjawisk ekonomicznych i finansowych⁹. W przypadku wykrycia zmiany strukturalnej należy włączyć do modelu zmienną zero-jedynkową odpowiadającą momentowi zmiany.

Niech zmiany strukturalne będą zdefiniowane za pomocą następujących zmiennych:

$$D(TB)_t = \begin{cases} 1, & \text{dla } t = T_b + 1, \\ 0, & \text{dla } t \neq T_b + 1, \end{cases} \quad (2.70)$$

$$D(U)_t = \begin{cases} 1, & \text{dla } t > T_b, \\ 0, & \text{dla } t \leq T_b. \end{cases} \quad (2.71)$$

Hipotetyczne modele podlegające testowaniu (w rozumieniu hipotezy zerowej) są następujące:

$$1) y_t = \alpha + y_{t-1} + \delta D(TB)_t + \eta_t, \quad (2.72)$$

$$2) y_t = \alpha + y_{t-1} + (\alpha_2 - \alpha_1) \delta D(U)_t + \eta_t, \quad (2.73)$$

$$3) y_t = \alpha_1 + y_{t-1} + \delta D(TB)_t + (\alpha_2 - \alpha_1) D(U)_t + \eta_t, \quad (2.74)$$

przy czym η_t jest procesem ARMA(p, q) zdefiniowanym w równaniu (2.7).

Modele odpowiadające alternatywom są zdefiniowane jako:

$$1') y_t = \alpha_1 + \beta t + (\alpha_2 - \alpha_1) D(U)_t + \eta_t, \quad (2.75)$$

$$2') y_t = \alpha + \beta_1 t + (\beta_2 - \beta_1) \delta D(T^*)_t + \eta_t, \quad (2.76)$$

$$3') y_t = \alpha_1 + \beta t + (\alpha_2 - \alpha_1) D(U)_t + (\beta_2 - \beta_1) D(T)_t + \eta_t, \quad (2.77)$$

przy czym:

$$D(T^*)_t = \begin{cases} t - T_b, & \text{dla } t > T_b, \\ 0, & \text{dla } t \leq T_b, \end{cases} \quad D(T)_t = \begin{cases} t, & \text{dla } t > T_b, \\ 0, & \text{dla } t \leq T_b. \end{cases}$$

Hipoteza zerowa zakłada, że szereg y_t zawiera pierwiastek jednostkowy oraz dopuszcza jedną zmianę strukturalną w badanym okresie $1 < T_b < T$. W modelu (2.72) zakłada się pojedynczą zmianę szokową, natomiast w odpowiadającym mu modelu (2.75) nie ma zmiany szokowej, a jedynie pojedyncza zmiana w stałej funkcji trendu. Model (2.75) zakłada trend deterministyczny i stacjonarne odchylenia od tego trendu. Kolejne modele (2.73) i (2.76) przeciwstawiają zmianę parametru α , z poziomu α_1 na α_2 , zmianie współczynnika kierunkowego funkcji trendu. W modelu (2.74) zakłada się łączne zmiany szokowe i zmiany parametru α , natomiast model (2.77) odnosi to do zmiany wyrazu wolnego i współczynnika kierunkowego funkcji trendu liniowego.

⁹ W literaturze angielskojęzycznej określa się to mianem *event study*.

W celu testowania powyżej określonych zmian stosuje się następujące modele operacyjne:

$$1^*) y_t = \alpha + \beta t + \theta D(U)_t + \delta D(TB)_t + \alpha y_{t-1} + \sum_{i=1}^l c_i \Delta y_{t-i} + \eta_t, \quad (2.78)$$

$$2^*) y_t = \alpha + \beta t + \theta D(U)_t + \gamma D(T^*)_t + \alpha y_{t-1} + \sum_{i=1}^l c_i \Delta y_{t-i} + \eta_t, \quad (2.79)$$

$$3^*) y_t = \alpha + \beta t + \theta D(U)_t + \gamma D(T)_t + \delta D(TB)_t + \alpha y_{t-1} + \sum_{i=1}^l c_i \Delta y_{t-i} + \eta_t, \quad (2.80)$$

przy czym hipotezy podlegające testowaniu są następujące:

$$1^*) H_0: \theta = 0; \beta = 0; \delta \neq 0; \alpha = 1,$$

$$H_1: \theta \neq 0; \beta \neq 0; \delta = 0; \alpha < 1,$$

$$2^*) H_0: \theta \neq 0; \beta = 0; \gamma = 0; \alpha = 1,$$

$$H_1: \theta = 0; \beta \neq 0; \gamma \neq 0; \alpha < 1,$$

$$3^*) H_0: \theta = 0; \beta = 0; \gamma = 0; \delta \neq 0; \alpha = 1,$$

$$H_1: \theta \neq 0; \beta \neq 0; \gamma \neq 0; \delta = 0; \alpha < 1.$$

Jak widać, hipotezy dotyczące pierwiastka jednostkowego są podobne jak w teście Dickeya-Fullera. Perron [1989] proponuje zastosowanie tego testu dla parametru α oraz zwykłego testu t -Studenta dla badania istotności pozostałych parametrów. Tablice wartości krytycznych testu DF różnią się jednak w tym

Tablica 2.6. Wybrane wartości krytyczne testu Perrona przy 5-procentowym poziomie istotności

λ	Model 1*	Model 2*	Model 3*
0,1	-3,68	-3,65	-3,75
0,2	-3,77	-3,80	-3,99
0,3	-3,76	-3,87	-4,17
0,4	-3,72	-3,94	-4,22
0,5	-3,76	-3,96	-4,24
0,6	-3,76	-3,95	-4,24
0,7	-3,80	-3,85	-4,18
0,8	-3,75	-3,82	-4,04
0,9	-3,69	-3,68	-3,80

λ oznacza stosunek liczby obserwacji przed zmianą strukturalną do pełnej liczby obserwacji w szeregu czasowym, tak że $T_B = \lambda T$.
Źródło: Perron [1989].

przypadku, gdyż włączenie dodatkowych zmiennych do modelu w istotny sposób zmienia rozkład testu. Tablice wartości krytycznych są podane w pracach Perrona [1989] i [1993].

W przypadku tego testu istotne jest ustalenie momentu zmiany strukturalnej T_B . Na ogół proponuje się przyjęcie kilku potencjalnych momentów zmian i wybór tego, dla którego statystyka t -Studenta w odpowiednim modelu jest największa. Inne metody wyboru momentu T_B zostały opisane w pracy Perrona [1997].

2.7.3. Testowanie sezonowych pierwiastków jednostkowych

Sezonowe pierwiastki jednostkowe. Najprostszym testem pozwalającym na weryfikację sezonowości stochastycznej jest test Dickeya, Haszy i Fullera (por. Dickey, Hasza, Fuller [1984], Charemza, Deadman [1997]). Jego idea polega na tym, że:

1) konstruujemy zmienną v_t , spełniającą równanie:

$$v_t = y_t - \sum_{i=1}^k \hat{\lambda}_i y_{t-i}, \quad (2.81)$$

gdzie y_t jest oryginalnym szeregiem czasowym badanym ze względu na obecność pierwiastków sezonowych, $\hat{\lambda}_i$ są ocenami parametrów oszacowanych za pomocą KMNK w równaniu postaci:

$$\Delta_s y_t = \sum_{i=1}^k \lambda_i \Delta_s y_{t-i} + \xi_t, \quad (2.82)$$

przy czym $\Delta_s y_t = y_t - y_{t-s}$.

2) szacujemy parametry równania postaci:

$$\Delta_s v_t = \delta v_{t-s} + \sum_{i=1}^k \gamma_i \Delta_s v_{t-i} + \varepsilon_t, \quad (2.83)$$

3) testujemy hipotezę $H_0: \delta = 0$ wobec $H_0: \delta < 0$, korzystając z zależności opartej na statystyce t -Studenta:

$$DNF = \frac{\hat{\delta}}{S(\hat{\delta})}. \quad (2.84)$$

Podobnie jak to miało miejsce w poprzednich testach, rozkład statystyki DNF jest niestandardowy (tablice są podane w pracy Dickey, Hasza, Fuller [1984]). W celu ustalenia wartości D operator różnicowy Δ_s możemy zastosować więcej niż jeden raz. W praktyce ekonomicznej nie jest to jednak konieczne.

Tablica 2.7. Wybrane wartości krytyczne testu DHF przy 5-procentowym poziomie istotności

m	n	Model bez stałej	Model ze stałą	Model z sezonowością kwartalną
4	40	-1,37	-2,38	-4,21
	60	-1,39	-2,38	-4,14
	80	-1,39	-2,38	-4,11
	200	-1,90	-2,38	-4,06
	400	-1,90	-2,38	-4,05
12	120	-1,77	-2,01	-5,86
	180	-1,77	-2,02	-5,84
	240	-1,77	-2,02	-5,83
	600	-1,79	-2,04	-5,82

Źródło: Dickey, Hasza, Fuller [1984].

W niniejszym rozdziale przedstawiono tylko kilka — na ogół najprostszych — narzędzi weryfikujących obecność pierwiastków jednostkowych w szeregach czasowych. Temat ten był jednak szeroko omawiany w wielu publikacjach. Poza cytowanymi wyżej, na uwagę zasługują prace Syczewskiej [1999] oraz Maddali i Kima [2002].

Modele procesów ułamkowo zintegrowanych ARFIMA(p, d, q)

Istnieje klasa modeli, w których d jest ułamkiem — są to modele ARFIMA(p, d, q) — *autoregressive fractionally integrated moving average*. Modele te zostały wprowadzone m.in. przez Grangera i Joyeux w 1980 r. oraz Hoskinga w 1981 r. (por. Kwiatkowski [1999], Kwiatkowski, Osiewalski [2001], Gil-Alana, Toro [2002], Chaporale, Gil-Alana [2003]).

Definicja 2.8

Proces stochastyczny Y_t nazywamy ułamkowo zintegrowanym, jeżeli po zastosowaniu operatora $(1-B)^d$ zdefiniowanego przez rozwinięcie dwumianowe jako:

$$(1-B)^d = 1 - dB + d(d-1) \frac{B^2}{2!} \quad (2.85)$$

dla dowolnego $d \in R$ szereg ten można opisać za pomocą stacjonarnego i odwracalnego modelu ARMA.

Dla odpowiednich wartości parametru d procesy te zachowują jednocześnie własność stacjonarności oraz długiej pamięci. Pamięć procesu stochastycznego

oznacza zależność jego wartości bieżących od jego wcześniejszej historii. Białe szum charakteryzuje się zerową pamięcią, gdyż wszystkie jego wartości są niezależne, stacjonarne procesy ARMA opisują krótką pamięć procesu (funkcja kowariancyjna maleje wykładniczo), a procesy ARIMA charakteryzują się funkcją kowariancyjną malejącą w sposób liniowy. Długa pamięć, czyli zależność od odległych obserwacji (funkcja kowariancyjna procesu maleje hiperbolicznie, bardzo powoli), odpowiada niektórym hipotezom finansowym oraz faktom empirycznym (por. Weron, Weron [1999]).

Jeżeli $0 < d < 0,5$, to proces ARFIMA jest stacjonarny, ale jego funkcja autokorelacji zmniejsza się powoli i nie jest sumowalna. Dla $0,5 \leq d < 1$ wariancja jest nieskończona, zatem proces jest niestacjonarny, ale wciąż powracający do średniej, co oznacza, że wpływ jakiegokolwiek szoku zakłócającego system w długim okresie zaniknie. W przypadku gdy $-0,5 < d < 0$, mówimy o średniej pamięci procesu. Wreszcie dla $d \geq 1$ szereg jest niestacjonarny i niepowracający do średniej, stąd efekty szoku są trwale (persystentne). Można wówczas mówić o nieskończonej pamięci.

Można wykazać, że dla $d \in (0; 0,5)$ funkcja autokowariancyjna spełnia warunek:

$$K(\tau) \sim c_1 \tau^{2d-1}, \text{ przy } \tau \rightarrow \infty,$$


gdzie $|c_1| < \infty$.

Najbardziej interesujący jest zatem przypadek $0 < d < 0,5$ procesu stacjonarnego z długą pamięcią. Na wykresie 2.5 zostały przedstawione przykładowe realizacje takich procesów.

Rysunek 2.5. Przykładowo realizacje procesu ARFIMA

ARFIMA (1; 0,3; 1)

ARFIMA (0; 0,2; 0)

Źródło: Opracowanie własne¹⁰⁰.

Wybrane elementy dotyczące wnioskowania w zakresie modeli ARFIMA będą rozważane w rozdziale 5.

¹⁰⁰ Autorka dziękuje dr. Jackowi Kwiatkowskiemu za udostępnienie programu do generowania procesów ARFIMA.

Pytania i problemy

1. Wyjaśnij pojęcia stacjonarności i niestacjonarności procesów stochastycznych. Podaj przykłady stacjonarnych i niestacjonarnych procesów finansowych.
2. Model ARMA — własności, estymacja i prognozowanie.
3. Wykorzystanie kryteriów informacyjnych do identyfikacji modeli ARMA.
4. Modele autoregresyjne — własności, identyfikacja i metody estymacji.
5. Wyjaśnij pojęcia: funkcja autokorelacji i autokorelacji cząstkowej.
6. Wyjaśnij pojęcia: stochastyczny trend i stochastyczna sezonowość. Jak wyglądają funkcje autokorelacji w tych przypadkach?
7. Dlaczego w finansowych szeregach czasowych częściej obserwuje się trend stochastyczny niż deterministyczny?
8. Omów znane modele trendu deterministycznego i deterministycznej sezonowości.
9. Wyjaśnij źródła niestacjonarności w modelu błędzenia przypadkowego.
10. Co to jest pierwiastek jednostkowy?
11. Definicja i własności modelu SARIMA.
12. Wyjaśnij powstawanie sezonowego modelu błędzenia przypadkowego.
13. Zapisz hipotezy i równanie regresji w teście Dickeya-Fullera dla modelu postaci $Y_t = \alpha + Y_{t-1} + \varepsilon_t$.
14. Wyjaśnij, na czym polegają różnice w poszczególnych zmianach strukturalnych występujących w teście Perrona. Jakie są wnioski wynikające z tego testu?
15. Wyjaśnij zastosowanie testu Dickeya, Haszy i Fullera.
16. Porównaj własności modelu błędzenia przypadkowego i modelu ARFIMA. Co to jest długa pamięć procesu stochastycznego?

Rozdział 3

Jednowymiarowe modele zmienności

Słowa kluczowe: analiza krótkookresowa, wariancja warunkowa, ARCH, GARCH, GARCH-M, asymetryczne modele GARCH, modele zmienności stochastycznej, VaR, dane o ultrawysokiej częstotliwości

Rozważane w niniejszym rozdziale klasy modeli koncentrują się na opisie tych własności procesów finansowych, w tym zwłaszcza cen akcji, stóp zwrotu z akcji, kursów walut i stóp procentowych, które pojawiają się w przypadku dużej częstotliwości ich obserwacji, np. dziennej lub jeszcze częstszej. Modele jednowymiarowych szeregów czasowych zaprezentowane w rozdziale 2, jak również przyczynowo-skutkowe modele opisywane w rozdziale 7 służą na ogół analizom rozpatrywanym w dłuższym horyzoncie czasowym (zwykle miesięcznym, kwartalnym i rocznym), w którym można badać zależności przyczynowo-skutkowe, a także zależności długookresowych i krótkookresowych procesów dostosowawczych, których podstawą może być analiza fundamentalna. W przypadku okresów krótszych (tydzień, dzień, godzina itp.) możliwość analizy przyczynowo-skutkowej jest bardzo ograniczona, gdyż przyczyny pojawiają się impulsowo, często w pakietach, a ich oddziaływanie raz jest krótsze, raz dłuższe. Skutkiem tego są jednakże zmiany cen, które implikują dalsze zmiany np. horyzontu inwestycyjnego, cen instrumentów pochodnych, wartości narażonych na ryzyko.

Omawiane modele mają na ogół charakter nieliniowy, chociaż są one odmienne od modeli nieliniowych rozpatrywanych w rozdziale 4, dotyczą bowiem zmienności wyrażonej za pomocą wariancji warunkowej. Osobny podrozdział został poświęcony analizie mikrostruktury rynku, opartej na tzw. danych o ultrawysokiej częstotliwości, której modelowanie stanowi jeden z najbardziej aktualnych kierunków badawczych ekonometrii finansowej.


3.1. Cechy analizy krótkookresowej

Cechą procesów finansowych, obserwowanych z dużą częstotliwością, jest naprzemiennie występowanie okresów charakteryzujących się zwiększoną fluktuacją cen i okresów relatywnie spokojnych. Zmiany wariancji mają tendencję do skupiania się

w kolejnych jednostkach czasu, tzn. większa wartość wariancji pociąga za sobą kolejną większą wartość, a mniejsza — mniejszą. Podstawową przyczyną takiego stanu rzeczy jest krótki horyzont inwestycyjny. Dotyczy to zwłaszcza cen i stóp zmian tych aktywów finansowych, dla których naturalna jest dzienna lub częstsza obserwacja, tj. akcji, indeksów, kursów walutowych, stóp procentowych.

W opisanej sytuacji założenie stałej wariancji warunkowej procesu stochastycznego pozwala jedynie określać jego granice zmienności w długim okresie, co jest mało pomocne w zakresie przewidywania krótkookresowych zmian cen instrumentów finansowych oraz stóp zwrotu. Przyjęcie założenia o zmiennej wariancji warunkowej pozwala na bardziej precyzyjne przewidywanie zmienności z okresu t na $t+1$. W najprostszym przypadku skutkuje to wystąpieniem, poza modelem dla wartości średniej procesu, dodatkowego równania dla wariancji warunkowej procesu. Wariancja warunkowa może być zatem traktowana jako miara krótkookresowej zmienności procesu.

Rysunek 3.1. Wariancja warunkowa WIG w okresie 2.01.01-24.07.02



Źródło: Opracowanie własne.

Jeżeli proces Y_t zdefiniujemy za pomocą modelu postaci:

$$Y_t = \varepsilon_{t-1}^2 v_t, \quad (3.1)$$

przy czym v_t jest gaussowskim białym szumem, to jego brzegowa wartość oczekiwana jest dana jako:

$$E(Y_t) = E(\varepsilon_{t-1}^2 v_t) = E(\varepsilon_{t-1}^2) E(v_t) = 0, \quad (3.2)$$

co wynika z niezależności czynników ε_{t-1}^2 i v_t oraz z założenia, że $E(v_t) = 0$.

Wariancja brzegowa procesu jest odpowiednio dana jako:

$$D^1(Y_t) = E(\varepsilon_{t-1}^4 v_t^2) = E(\varepsilon_{t-1}^4) E(v_t^2) = 3\sigma^6, \quad (3.3)$$

gdyż kurtosa rozkładu normalnego¹ wynosi 3, natomiast wariancja białego szumu jest równa σ^2 .

¹ Obecność σ^6 wynika oczywiście z tego, że wzór na współczynnik kurtozy jest dany jako $K = \frac{E(v_{t-1}^4)}{\sigma^4}$. Dla rozkładu normalnego jest on równy 3.

3.3. Podstawowy model ARCH

Model autoregresyjny z warunkową heteroskedastycznością (*autoregressive conditional heteroscedasticity model*, w skrócie model ARCH) został wprowadzony przez Engle'a w 1982 r. (Engle [1982]). Opiera się on na obserwacji zmienności warunkowej wariancji składnika resztowego, pozostałego w modelu dla warunkowej wartości oczekiwanej. Dlatego model ARCH — mimo iż dotyczy zmienności w zakresie wariancji — na ogół jest podawany w postaci dwóch równań: równania opisującego warunkową średnią i równania opisującego warunkową wariancję.

Zapiszmy ogólną postać podstawowego modelu ARCH(q).

Niech:

$$y_t = x_t' \xi + \varepsilon_t, \quad (3.4)$$

gdzie:

x_t — $(k \times 1)$ wektor zmiennych objaśniających, który może także zawierać opóźnione zmienne endogeniczne,

ξ — $(k \times 1)$ wektor parametrów,

$t = 1, 2, \dots, T$.

Jeżeli przez zbiór informacji dostępny w momencie $t-1$ będziemy rozumieć $\Psi_{t-1} = [y_{t-1}, x_{t-1}, y_{t-2}, x_{t-2}, \dots]$, to model ARCH definiuje wariancję rozkładu resztowego procesu stochastycznego ε_t warunkowo od Ψ_{t-1} , czyli:

$$\varepsilon_t | \Psi_{t-1} \sim N(0, h_t), \quad (3.5)$$

gdzie:

$$h_t = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2, \quad (3.6)$$

przy założeniach $\alpha_0 > 0$ oraz $\alpha_i \geq 0$ dla $i = 1, 2, \dots, q$, które mają zapewnić dodatność warunkowej wariancji. Zapisując (3.6) z wykorzystaniem operatora przesunięcia wstecz, mamy:

$$h_t = \alpha_0 + \alpha(B) \varepsilon_{t-1}^2. \quad (3.7)$$

Model (3.6) jest modelem nieliniowym ze względu na zmiennę.

Model ARCH(q) generuje procesy stacjonarne w szerszym sensie, jeżeli wszystkie pierwiastki równania charakterystycznego $\alpha(B) = 0$ w (3.7) są co do modułu większe od jedności. Jest to równoznaczne z tym, że suma parametrów

modelu ARCH jest mniejsza od jedności², tj. $\sum_{i=1}^q \alpha_i < 1$.

² Wykazał to Nelson [1990]; patrz też Gouriéroux [1997], Bauwens, Lubrano, Richard [1999].

W praktyce w miejsce (3.4) najczęściej stosuje się stacjonarny model klasy ARMA, np. AR(1):

$$Y_t = \alpha_0 + \alpha_1 Y_{t-1} + \varepsilon_t, \quad (3.8)$$

do którego dołącza się równanie autoregresyjne dla zmiennej wariancji warunkowej postaci:

$$h_t = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_q \varepsilon_{t-q}^2. \quad (3.9)$$

Ścisłe stosowanie definicji martyngału dla cen instrumentów finansowych prowadzi wprost do następującej reprezentacji:

$$Y_t = v_t \sqrt{h_t}, \quad (3.10)$$

$$h_t = \alpha_0 + \alpha_1 Y_{t-1}^2 + \alpha_2 Y_{t-2}^2 + \dots + \alpha_q Y_{t-q}^2, \quad (3.11)$$

gdzie:

Y_t — logarytmiczna stopa zwrotu,

$v_t \sim N(0, 1)$.

Model ARCH(q) jest wówczas modelem autoregresyjnym dla Y_t^2 , co można wykazać dodając Y_t^2 do obu stron równania (3.11). Mamy wówczas:

$$Y_t^2 = \alpha_0 + \alpha_1 Y_{t-1}^2 + \alpha_2 Y_{t-2}^2 + \dots + \alpha_q Y_{t-q}^2 + \eta_t, \quad (3.12)$$

przy czym:

$$\eta_t = Y_t^2 - h_t.$$

W takim przypadku stopy zwrotu są modelowane tylko poprzez warunkową wariancję.


W charakterystyce procesu ARCH znajdują swe odzwierciedlenie empiryczne własności procesów finansowych: zmienna w czasie wariancja, skupianie danych i grube ogony rozkładów. Za własność skupiania się wariancji odpowiadają parametry α_i , tzn. jest prawdopodobne, że jeżeli Y_{t-1} było duże (małe), to wariancja warunkowa w okresie t będzie duża (mała) proporcjonalnie do wartości α_i .

Na rysunku 3.2 przedstawiono empiryczny rozkład sporządzony na podstawie 1000 obserwacji wygenerowanych z modelu ARCH(1) w porównaniu z rozkładem normalnym. Widoczne jest zwłaszcza silniejsze skupianie się danych wokół średniej (kurtoza tego rozkładu wynosi 6,7), a także wyższe niż w rozkładzie normalnym słupki dotyczące liczebności odpowiadającym wartościom skrajnym.

W literaturze najczęściej podaje się następujące przyczyny efektu ARCH:

1. Model z resztami ARCH może być aproksymacją bardziej złożonego modelu bez efektu ARCH, co sugeruje złą specyfikację zarówno co do struktury, jak i uwzględnionych zmiennych (zjawisko to dotyczy na ogół modelowania innych niż finansowe szeregów czasowych).

Rysunek 3.2. Porównanie rozkładu ARCH(1) z teoretycznym rozkładem normalnym



Źródło: Opracowanie własne.

2. Różnice występujące między czasem kalendarzowym a ekonomicznym. Dla zmiennych ekonomicznych właściwym czasem odniesienia jest ich czas „operacyjny”, czyli dokonania transakcji, podczas gdy powszechnie odnoszone są one do czasu kalendarzowego.

3. Sposób napływania informacji i dynamika reakcji rynku na te informacje. Jeżeli informacje napływają w pakietach, owocuje to skupianiem danych i efektem ARCH.

Testowanie obecności efektu ARCH. W odniesieniu do badania efektu ARCH są stosowane różne testy. W niniejszym podrozdziale zostaną zaprezentowane dwa spośród nich.

Test Engle’a. Jest to najprostszy i najbardziej popularny test odpowiadający konstrukcji testu według reguły mnożnika Lagrange’a, która głosi, iż do sformułowania wniosku wystarczy tylko znajomość postaci modelu zawierającego restrykcje, tj. odpowiadającego hipotezie zerowej (por. Charemza, Deadman [1997]). W sformułowaniu równania będącego podstawą testu pomocne jest przedstawienie modelu ARCH w postaci modelu AR dla kwadratów reszt (por. Engle [1982]). Zatem modelowi (3.6) jest równoważny następujący model opisujący wprost kwadraty reszt z równania (3.4)³:

$$\varepsilon_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + u_t. \quad (3.13)$$

³ W celu uzyskania reprezentacji (3.12) do równania (3.13) wstawiamy wprost Y_t^2 .

Parametry tego równania mogą być szacowane za pomocą metody najmniejszych kwadratów.

Hipoteza zerowa zakłada brak heteroskedastyczności wariancji warunkowej, tzn. w (3.13):

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_q = 0,$$

natomiast w hipotezie alternatywnej przyjmuje się, że:

$$H_1: \exists \alpha_i \neq 0.$$

Test ma postać:

$$LM = TR^2, \quad (3.14)$$

gdzie R^2 jest współczynnikiem determinacji równania (3.13), a jego rozkład jest zbliżony do χ^2 z q stopniami swobody.

Test McLeod i Li. W 1983 r. McLeod i Li udowodnili, że do testowania efektu ARCH można stosować statystykę postaci Boxa-Ljunga w celu zbadania autokorelacji kwadratów reszt z równania (3.4) — por. Alexander [2003]. Hipotezy oraz statystyka Q' są identyczne jak przedstawione w rozdziale drugim, natomiast współczynnik korelacji dla kwadratów reszt z równania (3.4) przyjmuje postać:

$$\hat{\rho}_j = \frac{\sum_{t=j+1}^T \varepsilon_t^2 \varepsilon_{t-j}^2}{\sum_{t=1}^T (\varepsilon_t^2)^2}, \quad (3.15)$$

gdzie:

T — liczba obserwacji,

j — testowany rząd autokorelacji kwadratów reszt, $j = 1, 2, 3, \dots, q$.

Nieuwzględnienie w modelu efektu ARCH wtedy, gdy on występuje, ma poważne skutki praktyczne. Jednym z nich jest przyjęcie zbyt wysokiego rzędu opóźnień AR i MA w modelu ARMA(p, q) opisującego warunkową wartość średnią (tzw. przeparametryzowanie modelu — *overparametrisation*).

3.3. Uogólniony model ARCH Bollersleva (GARCH)

W 1986 roku Bollerslev opublikował artykuł, w którym wprowadził uogólniony model ARCH (*generalized ARCH*, GARCH), wzorując się na relacji między modelami AR i ARMA. Okazało się, że model ten stał się bardziej przydatny w praktyce niż wcześniejszy ARCH na skutek tego, iż:

— procesy finansowe wymagają dużych rzędów opóźnień q dla prawidłowego modelowania,

— estymacja parametrów modelu ARCH prowadziła do złamania założeń o nieujemności wariancji warunkowej,

— model GARCH lepiej niż ARCH dostosowuje się do opisu rozkładów o grubych ogonach (por. Bauwens, Lubrano, Richard [1999]).

Można wykazać, że testowanie efektów ARCH i GARCH jest ekwiwalentne, a zatem przedstawione testy pozwalają na wskazanie efektu zmiennej wariancji, bez możliwości rozróżnienia, czy jest to ARCH, czy GARCH. Najczęściej model GARCH stosuje się wtedy, kiedy liczba opóźnień w modelu ARCH jest duża, a także wówczas, gdy kryteria doboru modeli, np. kryterium Schwarza, wskazują na przewagę modelu GARCH nad ARCH.

Model GARCH(q, p), podobnie jak ARCH(q), definiuje się w postaci dwóch równań.

Niech:

$$y_t = x_t' \xi + \varepsilon_t, \quad (3.16)$$

gdzie:

x_t — $(k \times 1)$ wektor zmiennych objaśniających, który może także zawierać opóźnione zmienne endogeniczne,

ξ — $(k \times 1)$ wektor parametrów,

$t = 1, 2, \dots, T$.

Model GARCH(q, p) dany jest przez:

$$\varepsilon_t | \Psi_{t-1} \sim N(0, h_t),$$

gdzie:

$$h_t = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{i=1}^p \beta_i h_{t-i}, \quad (3.17)$$

przy założeniach $p \geq 0, q \geq 0$ oraz $\alpha_0 > 0, \alpha_i \geq 0$ dla $i = 1, 2, \dots, q, \beta_i \geq 0$ dla $i = 1, 2, \dots, p$, które mają zapewnić dodatność warunkowej wariancji.

Jeżeli $p = 0$, to GARCH redukuje się do ARCH(q), a gdy $p = q = 0$, wtedy ε_t jest gaussowskim białym szumem.

Zapiszmy równanie wariancji warunkowej, wykorzystując operator przesunięcia wstecz (B):

$$h_t = \alpha_0 + \alpha(B) \varepsilon_t^2 + \beta(B) h_t. \quad (3.18)$$

Jeżeli pierwiastki równania $1 - \beta(z) = 0$ leżą poza kołem jednostkowym, wówczas:

$$h_t = \beta_0 [1 - \beta(B)]^{-1} + \sum_{i=1}^{\infty} \delta_i \varepsilon_{t-i}^2, \quad (3.19)$$

gdzie δ_i są współczynnikami przy B^i w rozwinięciu $\alpha(B) [1 - \beta(B)]^{-1}$.

Model GARCH(q, p) jest wówczas odwracalny i sprowadzalny do nieskończonego modelu ARCH(∞).

3.2.2. Równoważna reprezentacja modelu GARCH

Niech:

$$v_t = \varepsilon_t^2 - h_t = (\eta_t^2 - 1)h_t, \quad (3.20)$$

przy czym $\eta_t \sim N(0, 1)$.

Wówczas model GARCH(q, p) przyjmuje postać:

$$\varepsilon_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \varepsilon_{t-j}^2 - \sum_{j=1}^p \beta_j v_{t-j} + v_t \quad (3.21)$$

i może być interpretowany jako model ARMA(m, p) dla procesu ε_t^2 , gdzie $m = \max\{p, q\}$.

Przedstawiona reprezentacja ARMA może być wykorzystywana do prognozowania.

3.2.3. Stacjonarność modelu GARCH(q, p)

Proces GARCH(1, 1) jest stacjonarny przy następujących założeniach:

$$E(\varepsilon_t) = 0, \quad (3.22)$$

$$E(\varepsilon_t^2) = \alpha_0 / (1 - \alpha_1 - \beta_1)^{-1}, \quad (3.23)$$

$$\text{cov}(\varepsilon_t, \varepsilon_s) = 0, \quad \text{dla } t \neq s, \quad (3.24)$$

wtedy i tylko wtedy, gdy $\alpha_1 + \beta_1 < 1$.

Dla dowolnych q i p proces GARCH(q, p) jest stacjonarny w szerszym sensie, jeżeli (por. Osiewalski, Pipień [1999b]):

$$\alpha_1 + \alpha_2 + \dots + \alpha_q + \beta_1 + \beta_2 + \dots + \beta_p < 1.$$

Model IGARCH. Jeżeli suma parametrów $\alpha_1 + \beta_1$ jest bardzo bliska jedności, mamy do czynienia z osobną klasą modeli IGARCH (*integrated GARCH*), która wprost zakłada $\alpha_1 + \beta_1 = 1$. Ostatnie założenie sugeruje podobieństwo do modeli ARIMA rozważanych w rozdziale 1. Przeanalizujmy jednak własności modeli IGARCH(1, 1) (por. Nelson [1990], Gouriéroux [1997]). Rozważmy model postaci:

$$h_t = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1}, \quad (3.25)$$

przy czym $\alpha_1 \geq 0$, $\beta_1 \geq 0$.

Warunkowa wartość oczekiwana na k okresów w przód jest dana jako:

$$E(h_{t+k} | \varepsilon_t) = (\alpha_1 + \beta_1)^k h_t + \alpha_0 \left[\sum_{i=0}^{k-1} (\alpha_1 + \beta_1)^i \right]. \quad (3.26)$$

Jeżeli $\alpha_1 + \beta_1 < 1$, to proces ε_t jest stacjonarny, a szoki w wariancji zanikają wraz ze wzrostem k . Jeżeli natomiast $\alpha_1 + \beta_1 = 1$, to warunkową wartość oczekiwaną można zapisać jako:

$$E(h_{t+k} | \varepsilon_t) = h_t + \alpha_0 k, \quad (3.27)$$

z czego wynika, że efekt szoku w h_t nie wygasa asymptotycznie, co powoduje, że nie istnieje skończona wartość oczekiwana dla tego procesu. W literaturze własność ta jest nazywana persystencją i jest analogiczna do persystencji w modelu błędzenia przypadkowego (lub ogólnie ARIMA).

Nelson [1990] podaje jednak warunki, przy których proces GARCH (w tym IGARCH) jest stacjonarny. Okazuje się, że IGARCH(1, 1) może być procesem stacjonarnym, którego rozkład obejmuje grube ogony.

Na rysunku 3.3 zostały przedstawione przykładowe realizacje następujących procesów: gaussowskiego białego szumu, ARCH(1), GARCH(1, 1) oraz IGARCH(1, 1).

Biały szum został wygenerowany z rozkładu normalnego o średniej zero i odchyleniu standardowym równym jeden. Dla procesu ARCH(1) schemat generowania był następujący:

$$\varepsilon_t = v_t \sqrt{1 + 0.8 \varepsilon_{t-1}^2},$$

gdzie $v_t \sim N(0, 1)$, $\varepsilon_0 = 0$.


Proces GARCH(1, 1) został wygenerowany przy następujących parametrach:

$$\varepsilon_t = v_t \sqrt{h_t},$$

$$h_t = 1 + 0.6 \varepsilon_{t-1}^2 + 0.3 h_{t-1},$$

gdzie $\varepsilon_0 = 0$, $h_0 = 1$.

rysunek 3.3. Przykładowe realizacje procesów ARCH, GARCH i IGARCH w porównaniu do białego szumu



Źródło: Opracowanie własne.

Proces IGARCH(1, 1) został generowany tak samo jak GARCH(1, 1) z wyjątkiem h_t :

$$h_t = 1 + 0,5 \varepsilon_{t-1}^2 + 0,5 h_{t-1}.$$

Należy zwrócić uwagę na fakt, iż wraz ze wzrostem liczby opóźnień w modelu ARCH/GARCH można zaobserwować rosnące skupianie się danych. Modele ARCH lepiej odzwierciedlają okresy mniejszej zmienności, gdyż bardzo powoli reagują na pojedyncze duże (szokowe) zmiany stóp zwrotu.

3.4. Model GARCH-in-mean

Model ten pozwala na rozważenie problemu premii za ryzyko, czyli wzrostu oczekiwanej stopy zwrotu spowodowanego wzrostem wariancji stopy zwrotu. Model GARCH-M pozwala na testowanie istnienia i estymację zmiennej w czasie premii za

ryzyko. Został on wprowadzony przez Engle'a, Liliena i Robinsa w 1987 r. Jego prosta wersja jest dana przez:

$$y_t = x_t' \xi + \delta h_t + \varepsilon_t, \quad (3.28)$$

przy czym:

$$\varepsilon_t | \Psi_{t-1} \sim N(0, h_t),$$

gdzie:

x_t — $(k \times 1)$ wektor zmiennych objaśniających, który może także zawierać opóźnione zmienne endogeniczne,

ξ — $(k \times 1)$ wektor parametrów,

h_t — proces GARCH(q, p) dany równaniem (3.17),

$t = 1, 2, \dots, T$.

Model (3.28) często przyjmuje postać:

$$y_t = x_t' \xi + \delta \sqrt{h_t} + \varepsilon_t. \quad (3.29)$$

Ocena parametru δ powinna być dodatnia i statystycznie istotna⁴.

GARCH-M jest modelem wykorzystującym efekt tzw. dźwigni finansowej. Według Blacka [1976], co potwierdziły potem i inne prace (np. Christie [1982], Nelson [1991]), stopy zwrotu z akcji są ujemnie skorelowane z ich zmiennością. Zmienność rośnie w odpowiedzi na „złe wiadomości” i spada jako reakcja na „dobre wiadomości”. W efekcie następuje wzrost dźwigni finansowej, powodując wzrost ryzyka inwestycji w dany papier wartościowy, a w konsekwencji wzrost zmienności. Niektórzy autorzy twierdzą, że efekt ten jest zbyt silny, aby można było go wytłumaczyć działaniem dźwigni finansowej. Inne wyjaśnienie podają Campbell i Hentschel [1992], wskazując na istnienie zmiennej w czasie premii za ryzyko (por. Piontek [2002]).

Rozważmy następujący model GARCH-M:

$$y_t = a + b h_t + \varepsilon_t, \quad a > 0, \quad b > 0, \quad (3.30)$$

$$\varepsilon_t | \Psi_{t-1} \sim N(0, h_t),$$

$$\varepsilon_t = v_t \sqrt{h_t}, \quad v_t \sim N(0, 1).$$

Wyznaczmy v_t jako:

$$v_t = \frac{y_t - (a + b h_t)}{\sqrt{h_t}}.$$

⁴ Parametr powinien być dodatni i statystycznie istotny, gdyż odzwierciedla zależność: im większe ryzyko, tym wyższa premia.

Można sprawdzić, że zachodzi następująca nierówność:

$$\{ |y_t - (a + bh_t)| (r_t > 0) \} < \{ |y_t - (a + bh_t)| (r_t < 0) \}, \quad (3.31)$$

a zatem:

$$E[|\varepsilon_t| (r_t < 0)] > E[|\varepsilon_t| (r_t > 0)], \quad (3.32)$$

co wyjaśnia efekt dźwigni.

3.5. Inne modele klasy ARCH (GARCH)

3.5.1. Modele GARCH z asymetrią

Wśród modeli opisujących wariancję warunkową istnieje wielka różnorodność form. Nie jest naszą intencją opisywanie po kolei każdej z nich, dlatego też ograniczymy się do najważniejszych. Modele te są bardzo interesujące, ponieważ uwzględniają niesymetryczność reakcji zmienności na pozytywne i negatywne zmiany stóp zwrotu.

Najprostszym modelem, mało przydatnym w praktyce, lecz dobrze wyjaśniającym istotę zagadnienia, jest asymetryczny model ARCH (AARCH) Engle'a [1990]. Przeanalizujmy model AARCH(1, 1), który zapisuje się następująco:

$$h_t = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \delta \varepsilon_{t-1} + \beta_1 h_{t-1}. \quad (3.33)$$

Z (3.33) wynika, że tylko ε_{t-1} może przyjmować wartości dodatnie lub ujemne, zatem znak parametru δ określa charakter reakcji. Jeśli $\delta < 0$, to dodatnie stopy zwrotu zwiększają zmienność w stopniu mniejszym niż zwroty ujemne.

Drugim spośród omawianych modeli jest wykładniczy model GARCH (*exponential GARCH*, EGARCH(p)). Jego autorem jest Nelson [1991]. Przy założeniu, że:

$$\varepsilon_t | \Psi_{t-1} \sim N(0, h_t),$$

$$\varepsilon_t = v_t \sqrt{h_t}, \quad v_t \sim N(0, 1),$$

funkcja wariancji warunkowej jest dana wzorem:

$$\ln h_t = \alpha_0 + \sum_{i=1}^p \alpha_i [\delta_1 v_{t-i} + \delta_2 (|v_{t-i}| - \sqrt{2/\pi})], \quad (3.34)$$

gdzie $v_t = \frac{\varepsilon_t}{\sqrt{h_t}}$ i $\delta_2 (|v_{t-1}| - \sqrt{2/\pi})$ reprezentuje efekt ARCH.

Rozwinięciem powyższego modelu jest model EGARCH(p, q) postaci:

$$\ln h_t = \alpha_0 + \sum_{i=1}^p \alpha_i [\delta_1 v_{t-i} + \delta_2 (|v_{t-i}| - \sqrt{2/\pi})] + \sum_{i=1}^q \beta_i \ln h_{t-i}. \quad (3.35)$$

Z wykładniczego charakteru modelu wynika nieujemność wariancji warunkowej, co jest najistotniejszą cechą modelu. Model odzwierciedla asymetryczne reakcje w wariancji h_t poprzez iloczyn parametrów $\alpha_i \delta_i$. Dla $\alpha_i \delta_i < 0$ wariancja h_t spada, gdy ε_{t-i} rośnie, natomiast h_t rośnie, gdy ε_{t-i} maleje.

Threshold ARCH. Autorami progowego modelu TAR-ARCH są Rabemanjara i Zakoian [1993]. Przyjmując, że:

$$\varepsilon_t | \Psi_{t-1} \sim N(0, h_t),$$

$$\varepsilon_t = v_t \sqrt{h_t}, \quad v_t \sim N(0, 1),$$

funkcja wariancji warunkowej jest dana wzorem:

$$\sqrt{h_t} = \alpha_0 + \sum_{i=1}^q (\alpha_i^+ \varepsilon_{t-i}^+ + \alpha_i^- \varepsilon_{t-i}^-) + \sum_{i=1}^p \beta_i \sqrt{h_{t-i}}, \quad (3.36)$$

gdzie $\varepsilon_t^+ = \max(\varepsilon_t, 0)$ i $\varepsilon_t^- = \min(\varepsilon_t, 0)$.

W modelu TAR-ARCH efekty zmienności nie są stałe, a ponadto obejmuje on asymetryczny efekt autoregresyjny w wariancji warunkowej. Oznacza to, że inaczej opisuje on reakcje na informacje dodatnie, a inaczej na informacje ujemne. Zakłada się przy tym, że brak nowych informacji generuje minimalną zmienność.

Uproszczony model TAR-ARCH(1, 1) ma postać (por. Zakoian [1994]):

$$\sqrt{h_t} = \alpha_0 + \alpha^+ \varepsilon_{t-1}^+ + \alpha^- \varepsilon_{t-1}^- + \beta \sqrt{h_{t-1}}. \quad (3.37)$$

Zapisy (3.36) i (3.37) odnoszą się do warunkowego odchylenia standardowego, stąd nie wymaga się nałożenia żadnych restrykcji na to, aby wariancja była nieujemna. Istnieją jednak uogólnienia powyższych modeli odnoszące się bezpośrednio do wariancji, na przykład (patrz Bauwens, Lubrano, Richard [1999]):

$$h_t = \alpha_0 + \alpha^+ (\varepsilon_{t-1}^+)^2 + \alpha^- (\varepsilon_{t-1}^-)^2 + \beta h_{t-1}. \quad (3.38)$$

Zaletą powyższej relacji jest to, że model asymetryczny zawiera w sobie symetryczny model GARCH. W celu zapewnienia dodatności wariancji wymaga się, aby wszystkie parametry były większe od zera. Model (3.38) jest postacią zaproponowaną oryginalnie przez Głoseina, Jagannathana i Runkle'go [1993], która w literaturze nosi nazwę modelu GJR.

3.5.2. Modele GARCH z rozkładem innym niż normalny

Badania empiryczne wskazują, że normalność rozkładów zakładana we wszystkich rozważanych dotąd modelach GARCH nie jest wystarczająca do opisu tzw. grubych ogonów. Zjawisko grubych ogonów rozkładów stóp zwrotu z inwestycji w papiery wartościowe jest związane z tym, iż zachowania skrajne pojawiają się częściej aniżeli

wynikałoby to z reguły trzech sigma, kojarzonej słusznie z rozkładem normalnym. Dlatego też poszukuje się innych rozkładów warunkowych, które w lepszy sposób opisywałyby to zjawisko. Jednym z najczęściej stosowanych (por. Engle, Bollerslev [1986], Fiszeder [2001]) jest rozkład *t*-Studenta z niską liczbą stopni swobody ν .

Funkcja gęstości prawdopodobieństwa rozkładu *t*-Studenta jest dana wzorem:

$$f(\varepsilon_t) = \frac{\Gamma[(\nu+1)/2]}{\sqrt{\pi(\nu-2)} \Gamma(\nu/2)} \left[1 + \frac{\varepsilon_t^2}{(\nu-2)} \right]^{-(\nu+1)/2} \quad (3.39)$$

gdzie symbol Γ oznacza funkcję gamma. Liczba stopni swobody jest tu dodatkowym parametrem szacowanym łącznie z innymi parametrami modelu GARCH. Osiewalski i Pipień [1999a, 2000] proponują zastosowanie skośnego (asymetrycznego) rozkładu *t*-Studenta.

Innym rozkładem często rozważanym w kontekście modeli GARCH (por. np. Nelson [1991]) jest rozkład GED (*generalized error distribution*). Jego funkcja gęstości jest następująca:

$$f(\varepsilon_t) = \frac{\nu}{\lambda 2^{(\nu+1)/\nu} \Gamma(1/\nu)} e^{-0.5 |\varepsilon_t/\lambda|^\nu} \quad (3.40)$$

gdzie Γ oznacza funkcję gamma, natomiast $\lambda = \left[2^{(\nu-2)/\nu} \frac{\Gamma(1/\nu)}{\Gamma(3/\nu)} \right]^{0.5}$.

Estymacja parametrów modeli GARCH i ocena ich jakości

Estymacja. Do estymacji parametrów przedstawionych modeli stosuje się metodę największej wiarygodności. Logarytm naturalny funkcji wiarygodności jest dany wzorem:

$$L_n(\theta) = \sum_{i=1}^n l_i(\theta), \quad (3.41)$$

a logarytm naturalny wiarygodności *i*-tej obserwacji:

$$l_i(\theta) = \text{const} - \frac{1}{2} \ln h_i - \frac{\varepsilon_i^2}{2h_i}, \quad (3.42)$$

przy czym wektor parametrów θ zawiera zarówno parametry warunkowej średniej, jak i warunkowej wariancji. Pozwala to na łączną estymację parametrów równania dla warunkowej średniej i wariancji. Estymacja parametrów omawianych tu typów modeli GARCH jest dostępna w wielu ekonometrycznych pakietach komputerowych (np. Eviews 4.0).

Kryteria dobroci modeli ARCH/GARCH. Współczynnik determinacji liniowej R^2 , powszechnie stosowany jako kryterium dobroci modeli liniowych, jest niezbyt przydatny w przypadku modeli GARCH. Wynika to oczywiście z bardzo wysokiej zmienności wariancji warunkowej. Z reguły programy komputerowe podają R^2 dla modeli GARCH, przy czym jego wartość jest na ogół bliska zeru (nie przekracza 0,05). Autorzy (Andersen, Bollerslev [1997], Brzeszczyński, Kelm [2002]) zwracają uwagę, że w przypadku częstotliwości obserwacji wyższej niż dzienna (dane wewnątrzdzienne, dane tikowe — *intradaily data*) współczynnik determinacji lepiej odzwierciedla dopasowanie modelu GARCH. Wynika to z tego, że na przykład suma godzinowych stóp zwrotu zazwyczaj nie jest równa dziennej stopie zwrotu:

$$\sum_{a=1}^b y_{t+ab}^2 \neq y_{t+1}^2.$$

Do oceny jakości modeli występujących w postaci dwóch równań:

— równania dla warunkowej wartości oczekiwanej stopy zwrotu, np. AR(1):

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \varepsilon_t,$$

— równania dla wariancji warunkowej, np. GARCH(1, 1):

$$h_t = \alpha_0 + \alpha_1 \varepsilon_{t-1} + \beta_1 h_{t-1},$$

pomocne są miary zgodności kierunku zmian. Ich idea zasadza się na założeniu, że inwestorowi bardziej zależy na przewidywaniu wzrostu (spadku) kursu akcji (waluty itp.) w przyszłym okresie, niż na liczbowej ocenie wielkości tego kursu.

Najprostszą miarą jest (por. Brzeszczyński, Kelm [2002]):

$$Q1 = \frac{N(y_t \hat{y}_t > 0)}{N(y_t \hat{y}_t \neq 0)}, \quad (3.43)$$

gdzie:

$y_t, \hat{y}_t$ — odpowiednio wartość rzeczywista i teoretyczna stopy zwrotu,

$N(y_t \hat{y}_t > 0)$ — liczba obserwacji, dla których iloczyn wartości rzeczywistej i teoretycznej jest większy od zera, czyli nastąpiła poprawna ocena kierunku zmiany,

$N(y_t \hat{y}_t \neq 0)$ — liczba niezerowych iloczynów rzeczywistych i teoretycznych stóp zwrotu (wyklucza się obserwacje z zerową zmianą).

Inną — bardzo pomocną prognostycznie — jest miara opisująca zdolność prognozowania punktów zwrotnych postaci:

$$Q2 = \frac{N(y_t \hat{y}_t > 0 | y_{t-1} y_t < 0)}{N(y_t \hat{y}_t \neq 0 | y_{t-1} y_t < 0)}, \quad (3.44)$$

gdzie $N(y_t \hat{y}_t > 0 | y_{t-1} y_t < 0)$ jest liczbą obserwacji, dla których iloczyn $y_t \hat{y}_t > 0$, pod warunkiem, że $y_{t-1} y_t < 0$.

Modyfikacji miar zgodności kierunku jest więcej; są one opisane m.in. w książce Brzeszczyńskiego i Kelma [2002]. Warto zwrócić uwagę na dwie spośród nich:

1. W przypadku uwzględnienia kosztów transakcyjnych (np. prowizji maklerskich) wzór (3.43) przyjmuje postać:

$$Q1' = \frac{N(y_t \hat{y}_t > 0 | y_t > g)}{N(y_t \hat{y}_t \neq 0 | y_t > g)}, \quad (3.45)$$

przy czym g jest wartością graniczną ustaloną na podstawie doświadczenia, np. 1%.

2. W przypadku gdy model ARCH występuje samoistnie, tzn. bez równania dla średniej warunkowej stopy zwrotu, omówione powyżej miary nie znajdują zastosowania z uwagi na niemożność obliczenia $\hat{y}_t$. Wówczas miara $Q1$ przyjmuje postać:

$$QX1 = \frac{N(y_t(h_t - h_{t-1}) < 0)}{T} = \frac{N(y_t \Delta h_t < 0)}{T}, \quad (3.46)$$

3.7. Prognozowanie na podstawie modeli GARCH

Funkcja prognozy. Prognozę o najmniejszym błędzie średniokwadratowym w momencie T z wyprzedzeniem k uzyskujemy ze wzoru:

$$f_{T,k} = E \left(\sum_{i=1}^{p+d} \lambda_i y_{T+ik} + \sum_{i=1}^q \theta_i \varepsilon_{T+ik-i} + \varepsilon_{T+k} | \Psi_T \right) + E(\delta \varepsilon_{T+k}^2 | \Psi_T), \quad (3.47)$$

gdzie λ_i są współczynnikami stojącymi przy B^i w wielomianie $a(B) (1-B)^d$.

Przyjmujemy:

$$E(y_{T+j} | \Psi_T) = \begin{cases} y_{T+j}, & j \leq 0, \\ f_{T,j}, & j > 0, \end{cases}$$

$$E(\varepsilon_{T+j} | \Psi_T) = \begin{cases} \varepsilon_{T+j}, & j \leq 0, \\ 0, & j > 0, \end{cases}$$

$$E(\varepsilon_{T+j}^2 | \Psi_T) = \alpha_0 + \sum_{i=1}^m (\alpha_i + \beta_i) E(\varepsilon_{T+k-i}^2 | \Psi_T) - \sum_{i=1}^n \beta_i E(v_{T+k-i} | \Psi_T), \quad (3.48)$$

przy czym:

$$E(\varepsilon_{T+j}^2 | \Psi_T) = \begin{cases} \varepsilon_{T+j}^2, & j \leq 0, \\ E(\varepsilon_{T,j}^2 | \Psi_T), & j > 0 \wedge j < k, \end{cases}$$

$$E(v_{T+j} | \Psi_T) = \begin{cases} v_{T+j}, & j \leq 0, \\ 0, & j > 0. \end{cases}$$

Wariancja predykcji. W celu przedstawienia miar *ex ante* dla rozważanych modeli konieczna jest znajomość wag ψ . Wagi te wyznaczamy, porównując współczynniki przy jednakowych potęgach w :

$$a(1-B)^d (1 + \psi_1 B + \psi_2 B^2 + \dots) = \beta(B).$$

Wariancję predykcji, która mierzy średni kwadrat odchyleni zmiennej prognozowanej od wartości prognozy, dla modelu ARIMA-GARCH określamy wzorem:

$$V^2 = \sum_{i=0}^{h-1} \psi_i^2 E(\varepsilon_{T+ki}^2 | \Psi_T). \quad (3.49)$$

W przypadku modelu ARIMA-GARCH-M wariancja dana jest przez:

$$V^2 = \sum_{i=0}^{k-1} \psi_i^2 E(\varepsilon_{T+k-i}^2 | \Psi_T) + \delta^2 \sum_{i=0}^{k-1} \psi_i^2 E(v_{T+k-i} | \Psi_T), \quad (3.50)$$

przy czym:

$$u_i = h_i - E(\varepsilon_i^2 | \Psi_T).$$

3.8. Procesy zmienności stochastycznej (SV)

Proces zmienności stochastycznej stanowi alternatywę dla procesów generowanych przez modele GARCH. Istotna różnica polega tu na wprowadzeniu składnika losowego (procesu innowacyjnego, zakłócenia, szumu) do równania wariancji warunkowej (por. Clark [1973], Melino, Turnbull [1990], Danielsson [1994], Pajor [2003]). Wariancja warunkowa staje się zatem odrębnym procesem stochastycznym podlegającym zmianom losowym, których przyczyny nie muszą być utożsamiane z przyczynami zmian procesu cen. W modelach GARCH zmiany wariancji warunkowej są całkowicie wyjaśniane przez dotychczasową historię reprezentowaną przez ε_{t-i}^2 oraz h_{t-i} .

Proces stochastyczny ε_t jest podstawowym procesem zmienności stochastycznej (*basic stochastic volatility process*), jeżeli dla każdego t zachodzi:


$$\varepsilon_t = v_t \sqrt{h_t}, \quad (3.51)$$

$$\ln h_t = \gamma + \phi \ln h_{t-1} + \sigma_h \eta_t, \quad (3.52)$$

gdzie $v_t \sim N(0, 1)$, $\eta_t \sim N(0, 1)$, a ponadto zakłada się niekorelowanie v_t i η_t .

Na rysunku 3.4 przedstawiono przykładową realizację procesu SV przy założeniu, że $\gamma = 0.1$, $\phi = 0.95$ oraz $\sigma_h^2 = 0.06$ (por. Pajor [2003]).

Rysunek 3.4. Szeregi czasowe generowane przez podstawowy model SV



Źródło: Opracowanie własne.

Podobnie jak w modelach EGARCH, logarytm naturalny zapewnia, że wariancja jest nieujemna. Jest ona w modelu SV zmienną ukrytą⁵, a jej logarytm podlega mechanizmowi autoregresyjnemu AR(1). Proces AR(1) jest ściśle stacjonarny, jeżeli $|\varphi| < 1$. Wtedy także proces ε_t jest procesem ściśle stacjonarnym, ponieważ jest iloczynem dwóch procesów ściśle stacjonarnych. Z niezależności v_t i η_t wynika, że wszystkie kowariancje procesu ε_t są równe zero, zatem możemy stwierdzić, iż jest on białym szumem o niegaussowskim rozkładzie. Kurtóza rozkładu ε_t przekracza wartość 3, co wynika z zapisu:

$$\text{kurt}(\varepsilon_t) = E(\varepsilon_t^4)/[E(\varepsilon_t^2)]^2 = 3 \exp\{\sigma_h^2/(1-\varphi^2)\}, \quad (3.53)$$

a zatem rozkład bezwarunkowy ε_t ma grubsze ogony niż rozkład normalny, co zależy od wariancji $\ln h_t$.

Pomimo zerowych korelacji procesu ε_t istnieje niezerowa korelacja kwadratów procesu, a funkcja autokorelacji ma postać:

$$\text{cor}(\varepsilon_t^2 \varepsilon_{t-s}^2) = \{\exp[\sigma_h^2 \varphi^s / (1-\varphi^2)] - 1\} / \{3 \exp[\sigma_h^2 / (1-\varphi^2)] - 1\}. \quad (3.54)$$

Funkcja ta maleje wraz ze wzrostem odstępów s i — podobnie jak w przypadku procesów AR — tempo spadku jest zależne od wartości φ . Im parametr ten jest bliższy jedności, tym spadek wolniejszy.

⁵ Wynika to z dyskretyzacji modelu dyfuzji dla cen instrumentów finansowych do postaci $\ln P_t = \ln P_{t-1} + \mu + \sqrt{h_t} v_t$. Fakt ten sprawia, że model SV jest oparty na rzetelnych podstawach teoretycznych; por. Pajor [2003].

Za pomocą procesów SV można modelować zjawisko grubych ogonów rozkładów stóp zwrotu, zjawisko skupiania się zmienności oraz zmienność warunkowej wariancji. W pracy Pajor [2003] można znaleźć liczne uogólnienia modeli SV, jak również ich estymację i wnioskowanie oparte na narzędziach bayesowskich, a także wybrane zastosowania.

Estymacja parametrów modeli SV za pomocą metody największej wiarygodności naraża pewnych trudności numerycznych, w związku z tym przez długi czas nie były one praktycznie używane. W pracy Ruiza [1994] pojawiła się idea szacowania parametrów modeli SV za pomocą metody quasi-największej wiarygodności z filtrem Kalmana⁶. Metoda ta nie daje jednak estymatorów najefektywniejszych.

Przykłady zastosowań modeli SV wskazują na lepsze modelowanie rzeczywistej zmienności niż w przypadku modeli GARCH, trudno natomiast zauważyć istotną przewagę w zakresie wyników prognoz (patrz Doman [2002a], Tsay [2002]).

3.9. Analiza danych o ultrawysokiej częstotliwości i mikrostruktura rynku

Jednym z najnowszych kierunków badań nad istotą procesów finansowych jest analiza danych o ultrawysokiej częstotliwości, obserwowanych z dokładnością większą niż dzienna, najczęściej transakcja po transakcji na rynku papierów wartościowych. TAQ (*The Trades and Quotes*) — baza danych giełdy nowojorskiej — zawiera notowania wszystkich transakcji dotyczących NYSE, AMEX i NASDAQ, począwszy od 1992 r. do chwili obecnej. Także inne bazy zawierają dane giełdowe o ultrawysokiej częstotliwości (por. Tsay [2002]). Modele mikrostruktury rynku są bardzo pomocne w badaniu dynamiki rynku, a zwłaszcza jego płynności, rozumianej jako możliwość zakupu lub sprzedaży znacznej liczby papierów wartościowych w krótkim czasie, anonimowo i bez konieczności ingerencji w cenę. Z drugiej strony stawiają wobec ekonomistów i ekonometryków istotne wyzwania natury metodologicznej.

W przypadku posiadania danych o cenach oraz wolumenie obrotów transakcja po transakcji (dane tikowe, dane o ultrawysokiej częstotliwości — por. Engle [2000]) możliwa się staje budowa modeli uwzględniających różnice w czasie kalendarzowym i transakcyjnym.

Niech proces cen w czasie transakcyjnym będzie dany jako p_n^* , gdzie $n \in N$ oznacza moment transakcji, a N_t jest liczbą chwil obserwowanych przed i w momencie t , przy czym $t \in N$. Proces cen w czasie kalendarzowym jest dany jako:

$$p_t = \hat{p}_{N_t}^*. \quad (3.55)$$

Z powyższego wynika, iż proces cen w czasie kalendarzowym zawiera skumulowane informacje, które miały miejsce w czasie transakcyjnym, przy czym kumulacja ta jest nieregularna w kolejnych jednostkach czasu.

⁶ Idea tej metody została przedstawiona w rozdziale 7 niniejszego podręcznika.

3.2.1. Model niesynchronicznych transakcji

Zagadnieniom tym można by poświęcić osobny rozdział, jednak w niniejszej pracy ograniczymy się jedynie do ich zasygnalizowania. Rozważmy problem niesynchronicznych transakcji. Przez niesynchroniczne transakcje będziemy rozumieć fakt, że na każdej giełdzie transakcje odbywają się z różną intensywnością w ciągu dni tygodnia, w ciągu godzin w dniu, a także w zakresie momentu transakcji zamknięcia (czyli ostatniej transakcji w dniu) w różnych dniach. Posługując się zatem danymi dziennymi, przez które zwykle rozumie się kurs zamknięcia, mamy do czynienia z danymi niesynchronicznymi, ponieważ traktujemy je w ten sposób, jakby pomiędzy transakcjami zamknięcia upłynęły 24 godziny, a tak w istocie nie jest. Konsekwencją powyższego są korelacja wzajemna (*cross-correlation*) pierwszego rzędu między stopami zwrotu z akcji, autokorelacja rzędu pierwszego stóp zwrotu z portfeli akcji, a także ujemna autokorelacja rzędu pierwszego stóp zwrotu z pojedynczych akcji (por. Campbell, Lo, MacKinley [1997], Tsay [2002]).

Rozważmy następujący model opisujący niesynchroniczne transakcje. Niech r_t będzie ciągłą, skumulowaną stopą zwrotu z papieru wartościowego w czasie t . Przyjmijmy, że r_t jest ciągiem niezależnych zmiennych o średniej $E(r_t) = \mu$ i wariancji $\text{var}(r_t) = \sigma^2$. Oznaczmy przez r_t^0 stopę zwrotu obserwowaną w momencie t . Prawdopodobieństwo tego, że dany papier wartościowy nie będzie przedmiotem transakcji, jest stałe, niezależne od r_t i równe π .

Matematyczny model relacji między r_t i r_t^0 jest dany wzorem:

$$r_t^0 = \begin{cases} 0 & \text{z prawd. } \pi, \\ r_t & \text{z prawd. } (1-\pi)^2, \\ r_t + r_{t-1} & \text{z prawd. } (1-\pi)^2\pi, \\ r_t + r_{t-1} + r_{t-2} & \text{z prawd. } (1-\pi)^2\pi^2, \\ \vdots & \vdots \\ \sum_{i=0}^k r_{t-i} & \text{z prawd. } (1-\pi)^2\pi^{k-1}, \\ \vdots & \vdots \end{cases} \quad (3.56)$$

gdzie 0 oznacza brak transakcji (brak informacji), $r_t^0 = r_t + r_{t-1} + \dots + r_{t-k}$ oznacza skumulowane stopy zwrotu ze wszystkich poprzednich transakcji, przy czym k jest największą nieujemną liczbą całkowitą oznaczającą moment braku transakcji.

Interpretacja (3.56) jest następująca:

$r_t^0 = r_t$ wtedy i tylko wtedy, gdy transakcje były w momentach t i $t-1$,
 $r_t^0 = r_t + r_{t-1}$ wtedy i tylko wtedy, gdy transakcje były w momentach t i $t-2$,
nie było natomiast transakcji w chwili $t-1$

itd.

Suma wszystkich prawdopodobieństw w (3.56) jest równa 1.

Charakterystyki procesu (3.56) są następujące:

• wartość oczekiwana:

$$E(r_t^0) = (1-\pi)^2 E(r_t) + (1-\pi)^2 \pi E(r_t + r_{t-1}) + \dots = \mu, \quad (3.57)$$

• wariancja:

$$D^2(r_t^0) = E[(r_t^0)^2] - [E(r_t^0)]^2,$$

$$E[(r_t^0)^2] = (1-\pi)^2 E[(r_t)^2] + (1-\pi)^2 \pi E[(r_t + r_{t-1})^2] + \dots = \sigma^2 + \mu^2 \left[\frac{2}{1-\pi} - 1 \right],$$

$$[E(r_t^0)]^2 = \mu^2,$$

$$D^2(r_t^0) = E[(r_t^0)^2] - [E(r_t^0)]^2 = \sigma^2 + \mu^2 \left[\frac{2}{1-\pi} - 1 \right] - \mu^2 = \sigma^2 + \frac{2\pi\mu^2}{1-\pi}. \quad (3.58)$$

• funkcja autokowariancyjna:

$$\text{cov}(r_t^0, r_{t-1}^0) = E(r_t^0 r_{t-1}^0) - E(r_t^0) E(r_{t-1}^0) = E(r_t^0 r_{t-1}^0) - \mu^2,$$

$$r_t^0 r_{t-1}^0 = \begin{cases} 0 & \text{z prawd. } 2\pi - \pi^2, \\ r_{t-1} & \text{z prawd. } (1-\pi)^3, \\ r_t(r_{t-1} + r_{t-2}) & \text{z prawd. } (1-\pi)^3\pi, \\ r_t(r_{t-1} + r_{t-2} + r_{t-3}) & \text{z prawd. } (1-\pi)^3\pi^2, \\ \vdots & \vdots \\ r_t \left(\sum_{i=1}^k r_{t-i} \right) & \text{z prawd. } (1-\pi)^3\pi^{k-1}, \\ \vdots & \vdots \end{cases} \quad (3.59)$$

Suma prawdopodobieństw w (3.41) jest równa jeden.

Wiadomo, że $r_t^0 r_{t-1}^0 = r_t r_{t-1}$ tylko wtedy, gdy transakcje miały miejsce w kolejnych chwilach $t-2$, $t-1$ i t . Z braku autozależności rzeczywistych r_t wiemy, że $E(r_t r_{t-1}) = E(r_t) E(r_{t-1}) = \mu^2$.

Wyznaczmy:

$$\begin{aligned} E(r_t^0 r_{t-1}^0) &= (1-\pi)^3 \left\{ E(r_t r_{t-1}) + \pi E[r_t(r_{t-1} + r_{t-2})] + \pi^2 E \left[r_t \left(\sum_{i=1}^3 r_{t-i} \right) \right] + \dots \right\} = \\ &= (1-\pi)^3 \mu^2 [1 + 2\pi + 3\pi^2 + \dots] = (1-\pi)\mu^2, \end{aligned}$$

$$\text{cov}(r_t^0, r_{t-1}^0) = (1-\pi)\mu^2 - \mu^2 = -\pi\mu^2. \quad (3.60)$$

Należy zauważyć, że ponieważ $\mu^2 > 0$, niesynchroniczne transakcje mogą prowadzić do ujemnej autokorelacji stóp zwrotu obserwowanych w czasie kalen-

darzowym, a więc r_t^0 , podczas gdy w czasie rzeczywistym (handlowym, transakcyjnym) taka autokorelacja nie występuje.

Współczynnik autokorelacji rzędu 1 wynosi:

$$\rho_1(r_t^0) = \frac{-(1-\pi)\pi\mu^2}{(1-\pi)\sigma^2 + 2\pi\mu^2}. \quad (3.61)$$

Można także wykazać, że dla dowolnego odstepu $j > 0$:

$$\text{cov}(r_t^0, r_{t-j}^0) = -\pi^j \mu^2. \quad (3.62)$$

Autoregresyjny model warunkowego czasu trwania między transakcjami

W 1997 roku Engle i Russel opublikowali artykuł, w którym zaproponowali model mierzący intensywność transakcji w ciągu czasu handlowego, nazywając go autoregresyjnym modelem warunkowego czasu trwania (*autoregressive conditional duration* — ACD). Motywacją do takiej konstrukcji było zjawisko skupiania się odstępów czasu między transakcjami, kiedy analizie zostały poddane dane transakcyjne.

Niech $x_i = t_i - t_{i-1}$ będzie odstępem między dwoma momentami, w których dokonano transakcji, zwanym czasem trwania albo *duration*⁷. Dla tak określonej zmiennej można zdefiniować funkcję gęstości prawdopodobieństwa warunkowo względem poprzednich wartości. Warunkowa wartość oczekiwana i -tego czasu trwania jest wówczas równa:

$$E(x_i | x_{i-1}, \dots, x_1) = \psi_i(x_i | x_{i-1}, \dots, x_1; \theta) \equiv \psi_i. \quad (3.63)$$

Zakłada się, że czas trwania zmienia się według następującego wzoru:

$$x_i = \psi_i \varepsilon_i, \quad (3.64)$$

gdzie $\varepsilon_i \sim i.i.d.$ z funkcją gęstości $f(\varepsilon, \phi)$, przy czym θ i ϕ przyjmują dowolne wartości.

Wzory (3.63)–(3.64) określają klasę autoregresyjnych modeli warunkowego czasu trwania, które mogą być specyfikowane w różny sposób zależnie od warunkowej wartości oczekiwanej oraz rozkładu ε_i .

Najprostszym przykładem modelu ACD jest wykładniczy model EACD, w którym zakłada się, że rozkład ε_i jest wykładniczy. Kierując się założeniem, że tylko m ostatnich czasów trwania wpływa na warunkowy czas trwania, można zapisać model:

$$\psi_i = \omega + \sum_{j=0}^m \alpha_j x_{i-j}. \quad (3.65)$$

⁷ Łatwo zauważyć, że mimo zbieżnej nazwy pojęcie to nie jest równoważne pojęciu *duration* stosowanemu w analizie wrażliwości ceny obligacji i innych papierów dłużnych na zmianę stopy procentowej; por. np. Jajuga (red.) [2000].

Naturalne jest uogólnienie powyższego modelu jako EACD(m, q):

$$\psi_i = \omega + \sum_{j=0}^m \alpha_j x_{i-j} + \sum_{j=0}^q \beta_j \psi_{i-j}, \quad (3.66)$$

który nie uwzględnia już ograniczenia pamięci tak zdefiniowanego czasu trwania do m ostatnich obserwacji.

Rozważmy model EACD(1, 1) postaci:

$$\psi_i = \omega + \alpha x_{i-1} + \beta \psi_{i-1}, \quad (3.67)$$

dla $\alpha, \beta \geq 0$, $\omega > 0$, $i = 1, 2, \dots, N$.

Jego warunkowe średnia i wariancja są dane odpowiednio jako ψ_i i ψ_i^2 , natomiast bezwarunkowa średnia wynosi:

$$E(x_i) = \mu = \frac{\omega}{1 - (\alpha + \beta)}. \quad (3.68)$$

Jak widać ze wzoru (3.68), istnieje ona tylko w przypadku, gdy $\alpha + \beta \neq 1$. Z kolei bezwarunkowa wariancja modelu (3.67) jest równa:

$$D^2(x_i) = \sigma^2 = \mu^2 \left(\frac{1 - \beta^2 - 2\alpha\beta}{1 - \beta^2 - 2\alpha\beta - 2\alpha^2} \right). \quad (3.69)$$

Wzór (3.69) wskazuje, że jeżeli $\alpha > 0$, to mamy do czynienia z „nadwyżką dyspersji”, bowiem bezwarunkowe odchylenie standardowe przewyższa wartość średnią. Zjawisko to jest charakterystyczne dla obserwowanych czasów trwania.

Własności modelu ACD:

1. Model EACD(m, q) może być zapisany w wersji ARMA(m, q), jeżeli przyjmiemy, że $\eta_i = x_i - \psi_i$. Mamy wówczas:

$$x_i = \omega + \sum_{j=0}^{\max(m,q)} (\alpha_j + \beta_j) x_{i-j} - \sum_{j=0}^q \beta_j \eta_{i-j} + \eta_i, \quad (3.70)$$

gdzie x_i jest generowany przez model ARMA(m, q) z niegaussowskim rozkładem procesu resztowego. Specyfikacja powyższa pozwala na wykorzystanie procedur estymacji i prognozowania kolejnych czasów oczekiwania na transakcje zdefiniowanych dla konwencjonalnych modeli ARMA.

2. Widoczna jest analogia między modelami ACD a modelami ARCH i GARCH. Engle i Russell [1998] wykazali, że przyjmując za zmienną objaśnianą $\sqrt{x_i}$ i ustalając wartość średnią równą zero ($\omega = 0$), model EACD(1, 1) może być szacowany przy zastosowaniu oprogramowania dla modeli ARCH.

3. W związku z faktem empirycznym, że częstotliwość transakcji tuż po otwarciu oraz tuż przed zamknięciem sesji jest większa niż w pozostałych częściach dnia, sugeruje się wyeliminowanie efektu deterministycznego wynikającego z dzien-

nej sezonowości transakcji (Engle, Russell [1998]). Dane należy zatem transformować, na przykład, w następujący sposób:

$$\tilde{x}_t = \frac{x_t}{Z(t_t)}, \quad (3.71)$$

gdzie $Z(t_t)$ oznacza multiplikatywny czynnik sezonowy rozumiany jako średni czas trwania dla każdej jednostki czasu, w którym obserwujemy dane; na ogół jest to średni czas trwania dla każdej sekundy.

3.2.2. Empiryczna charakterystyka danych obserwowanych w czasie transakcyjnym

Po przeczytaniu dwóch poprzednich punktów nasuwa się wniosek, że charakterystyka procesów obserwowanych transakcja po transakcji odbiega od charakterystyki procesów zagregowanych, czyli obserwowanych w kalendarzowych jednostkach czasu. Rozważmy dokładniej, jakimi cechami charakteryzują się dane fikowe. Przez dane transakcyjne będziemy rozumieć takie dane, jak: cena transakcji, wielkość transakcji, ceny oferty kupna i sprzedaży itp. obserwowane w czasie kalendarzowym z dokładnością do jednej sekundy.

1. Transakcje nie zachodzą w równych odstępach czasu. Na przykład odstępy czasu między transakcjami dotyczącymi akcji tej samej spółki są ważną informacją na temat intensywności ich obrotów.

2. Ceny akcji mają charakter wartości dyskretnych. Zmiany między kolejnymi małymi jednostkami czasu są niewielkie i pojawiają się w istotny sposób tylko przy znacznych obrotach.

3. W normalnych warunkach gospodarczych transakcje wykazują dzienny składnik periodyczny. Transakcje jest więcej na początku i końcu sesji giełdowej, mniej zaś w środku sesji. Analogicznie, długości okresów przerw między transakcjami mają charakter periodyczny w ciągu dnia.

4. Może się pojawić wiele transakcji w ciągu jednej sekundy, nawet przy różnych cenach. Okazuje się, że w okresach intensywnego handlu walorami jedna sekunda jest już zbyt długim przedziałem czasu, żeby uchwycić zmiany.

5. Proces cen w czasie transakcyjnym nie posiada zmiennej w czasie wariancji, podczas gdy proces cen w czasie rzeczywistym ma tę własność. Wynika z tego, że różnice między czasem transakcyjnym a kalendarzowym generują zniekształcenia procesu cen.

Modele mikrostruktury rynku są „młodymi” narzędziami analitycznymi wykorzystywanymi w badaniach empirycznych i w wielu wypadkach nie mają one jeszcze w pełni operacyjnego charakteru użytkowego, chociaż wraz z rozwojem baz danych i coraz doskonalszą techniką informatyczną postęp w tej dziedzinie jest widoczny⁸.

⁸ W odniesieniu do rynku walut interesujące spostrzeżenia można znaleźć w pracy pod red. Dunisa [2001].

3.10. Zastosowania modeli zmienności

Modele GARCH w różnych postaciach są szeroko wykorzystywane do opisu i prognozowania zmienności stóp zwrotu z akcji i walut, a w konsekwencji mają zastosowanie w analizie portfelowej, modelach równowagi rynku, wycenie instrumentów pochodnych oraz w analizie zagrożenia (przy obliczaniu wartości narażonej na ryzyko). Podobne zastosowania mogą mieć modele zmienności stochastycznej, które dużo trafniej opisują rzeczywistą zmienność procesów finansowych, na co wskazują badania empiryczne (por. m.in. Alexander [2003]).

3.10.1. Model równowagi rynku CAPM i proces ARCH

Rozważmy prosty przykład zastosowania modelu ARCH w praktycznym zagadnieniu finansowym. Załóżmy liniową relację między stopą zwrotu z portfela papierów wartościowych a związanym z nim ryzykiem⁹:

$$R_p - r = \beta(R_M - r), \quad (3.72)$$

gdzie:

R_p — oczekiwana stopa zwrotu portfela efektywnego,

r — stopa zwrotu wolna od ryzyka,

R_M — oczekiwana stopa zwrotu portfela rynkowego,

$$\beta = \frac{\text{cov}(R_p, R_M)}{\text{var}(R_M)}.$$

Relacja (3.72) oznacza model równowagi rynku CAPM. $R_p - r$ i $R_M - r$ oznaczają odpowiednio premie za ryzyko z tytułu posiadania portfela p oraz portfela rynkowego M . Zapiszmy (3.72) w ekwiwalentnej postaci:

$$R_p - r = \lambda_M \text{cov}(R_p, R_M), \quad (3.73)$$

gdzie $\lambda_M = \frac{R_M - r}{\text{var}(R_M)}$ oznacza rynkową cenę ryzyka.

Niech $\text{var}(R_M) = \sigma_M^2$. Stosując (3.73) bezpośrednio do portfela rynkowego, otrzymamy relację:

$$R_M - r = \lambda \sigma_M^2. \quad (3.74)$$

Wyznamy prognozę dla (3.74) na jeden okres w przód:

$$E_t\{R_{M,t+1}\} - r_t = \lambda E_t\{\sigma_{M,t+1}^2\}. \quad (3.75)$$

⁹ Modele o charakterze przyczynowo-skutkowym będą rozważane w rozdziale 7. Model CAPM jest jednym z takich przykładów. Tu omawiamy go ze względu na dołączone równanie wariancji warunkowej.

z której wynika, że oczekiwana nadwyżka (premia za ryzyko) z portfela rynkowego zależy od oczekiwanej zmienności (wariancji) tego portfela. Subskrypt t został dodany w (3.75) dla podkreślenia, że wartości procesów są zmienne w czasie. Gdy przyjmimy, że wariancja stóp zwrotu z portfela rynkowego jest generowana przez model ARCH(1) postaci:

$$\sigma_{M,t+1}^2 = \alpha \sigma_{M,t}^2 + \nu_t, \quad (3.76)$$

wówczas najlepszą prognozą $\sigma_{M,t+1}^2$ w czasie t jest:

$$E_t[\sigma_{M,t+1}^2] = \alpha \sigma_t^2; \quad (3.77)$$

stad CAPM z efektem ARCH można zapisać jako:

$$E_t\{R_{M,t+1}\} - r_t = \lambda \alpha \sigma_{M,t}^2, \quad (3.78)$$

z czego wynika, że oczekiwana stopa zwrotu równowagi rynkowej jest:

- niestala w czasie,
- zależna od informacji posiadanej w czasie t , tj. od $\sigma_{M,t}^2$.

Z powyższego wynika możliwość przewidywania zmienności stóp zwrotu, a poprzez ten fakt także premii za ryzyko z posiadania portfela rynkowego.

3.10.2. Wykorzystanie ekonometrycznych modeli GARCH do wyznaczenia wartości zagrożonej

Wartość empiryczna modeli GARCH polega na możliwości ich implementacji do różnych hipotez finansowych. W poprzednim podrozdziale pokazaliśmy, jak można rozszerzyć klasyczny model CAPM, obecnie skupimy się na wyznaczeniu wartości narażonej na ryzyko, zwanej także wartością zagrożoną (VaR — *value at risk*). Popularność tej metody wynika z faktu, że:

- VaR jest dana w postaci jednej liczby, która w sposób zagregowany przedstawia możliwe straty inwestora, najczęściej instytucji finansowej. Łączy różne rodzaje ryzyka rynkowego w jedną całość,
- VaR to względnie prosta i łatwo interpretowalna miara określająca możliwą stratę w warunkach zwykłego funkcjonowania rynku.
- VaR jest rekomendowana przez wiele instytucji nadzorujących sektor bankowy oraz — ogólnie — rynek finansowy.


Definicja 3.1

Wartość zagrożona jest to taka strata wartości rynkowej (np. instrumentu, portfela instrumentów), że prawdopodobieństwo jej osiągnięcia lub przekroczenia w danym przedziale czasowym jest równe zadanemu poziomowi tolerancji.

VaR zależy od dwóch parametrów, które powinien określić decydent. Są to poziom ufności (lub zamiennie poziom tolerancji) oraz horyzont czasowy, zwany też okresem przetrzymania (*holding period*). Oznacza on przedział czasu, dla którego oblicza się VaR, tzn. okres, w którym może mieć miejsce obliczona potencjalna strata na portfelu. Inna definicja okresu przetrzymania podkreśla, że jest to czas, w którym skład portfela pozostaje praktycznie niezmienny (por. Best [2001]). Do najczęściej stosowanych horyzontów czasowych należą: 1 dzień, 5 dni, 10 dni, 1 miesiąc.

Modele różniące się okresem przetrzymania czy poziomem ufności dają oczywiście różne wartości VaR. Model używający prawdopodobieństwa 99% pokazuje większą stratę niż model z 95% prawdopodobieństwem. Z kolei model wykorzystujący okres przetrzymania $t > 1$ dnia uwiadamia wielkość straty o około $t^{1/2}$ większą od VaR jednodniowego. Ogólnie: im większe zakładane prawdopodobieństwo oraz dłuższy okres przetrzymania, tym większa możliwa wartość straty.

Rysunek 3.5. Graficzna interpretacja Value at Risk



Źródło: K. Jajuga [2000].

Na rysunku 3.5 widoczna jest powierzchnia (w przedziale od 0 do W_α), której odpowiada prawdopodobieństwo równe 0,05 (5%). Jest to prawdopodobieństwo, że wartość instrumentu będzie nie większa niż tzw. kwantyl rozkładu, równy W_α . Z rysunku wynika, że VaR jest różnicą między obecną wartością instrumentu finansowego a zaznaczonym kwantylem rozkładu oraz że jest 5% szans, iż stracimy więcej niż VaR (lub 95% szans, że wartość instrumentu finansowego zmniejszy się o wartość mniejszą niż VaR).

Formalnie wartość zagrożona jest określona w postaci następującego równania:

$$P(W \leq W_0 - \text{VaR}) = \alpha, \quad (3.79)$$

gdzie:

W_0 — obecna wartość (instrumentu, portfela, instytucji),

W — wartość na koniec okresu,

α — poziom tolerancji (jeden minus poziom ufności).

Powyższe równanie oznacza, że z prawdopodobieństwem równym poziomowi tolerancji, czyli bliskim zeru, wystąpi zdarzenie polegające na tym, że wartość na koniec zadanego okresu będzie mniejsza lub równa wartości dzisiejszej, pomniejszonej o wartość ryzykowną. Jeżeli się przyjmie, że kwantyl rozkładu wartości odpowiadający zadanemu prawdopodobieństwu W_α jest równy:

$$W_\alpha = W_0 - \text{VaR}, \quad (3.80)$$

wówczas:


$$P(W \leq W_\alpha) = \alpha. \quad (3.81)$$

Dla zwykłej stopy zwrotu kwantyl dany jest w postaci równania:

$$P(R \leq R_\alpha) = \int_{-\infty}^{R_\alpha} f(R) dR = \alpha, \quad (3.82)$$

co oznacza, że prawdopodobieństwo, iż stopa zwrotu nie przekroczy wartości równej kwantylowi rozkładu stopy zwrotu, jest niewielkie i równe zadanej wartości tolerancji (korzystając z logarytmicznej stopy zwrotu, we wzorze (3.82) zamiast 100% występuje $-\infty$).

Rysunek 3.6. Rozkład stopy zwrotu



Źródło: K. Jajuga, [2000].

Na rysunku 3.6 są przedstawione na osi odciętych — stopy zwrotu instrumentu finansowego w danym przedziale czasowym, na osi rzędnych — wartości funkcji gęstości obrazujące tzw. krzywą gęstości, a także powierzchnia, której odpowiada prawdopodobieństwo 0,05 (5%). Jest to prawdopodobieństwo, że stopa zwrotu instrumentu będzie nie większa niż kwantyl rozkładu stopy zwrotu R_α . Miejsce, w którym znajduje się kwantyl, zależy od przyjętego prawdopodobieństwa. Im wyższa jego wartość, tym wyższa wartość kwantyla.

Formalny wzór określający wartość zagrożoną jest dany jako (przy zastosowaniu zwykłej stopy zwrotu):

$$\text{VaR} = -R_\alpha W_0. \quad (3.83)$$

Ponieważ kwantyl rozkładu stopy zwrotu odpowiadający małowemu prawdopodobieństwu jest zazwyczaj ujemny, dlatego VaR we wzorze (3.83) jest wartością dodatnią. Tak zdefiniowana wartość zagrożoną określa się w literaturze mianem absolutnej (*VaR absolute*) — por. K. Dowd [1998].

Korzystając natomiast z logarytmicznej stopy zwrotu, wartość zagrożoną oblicza się na podstawie równania:

$$\text{VaR} = -R_\alpha W_0 + \mu W_0. \quad (3.84)$$

Podobnie jak w przypadku zwykłej stopy zwrotu, odpowiedni kwantyl jest z reguły ujemny, zatem VaR z równania (3.84) jest wartością dodatnią.

Oprócz absolutnej wartości narażonej na ryzyko występuje także względna VaR (*VaR relative*). Jest ona zdefiniowana w następujący sposób:

$$\text{VaR} = W_0(1 - e^{\alpha}). \quad (3.85)$$

Ze wzorów (3.84) oraz (3.85) wynika, że podstawową charakterystyką niezbędną do ustalenia VaR jest kwantyl rozkładu stóp zwrotu. Można go obliczyć bezpośrednio z rozkładu (tak jest określany w symulacji historycznej), jednak częściej przyjmuje się określone założenie co do funkcji $f(R)$, a mianowicie, że przedstawia ona rozkład normalny (założenie to jest podstawą podejścia wariancji-kowariancji). Przyjęcie normalności rozkładu sprawia, że założony poziom tolerancji określa jednocześnie odległość poszukiwanej wartości kwantyla od średniej w jednostkach odchylenia standardowego. Jednak konieczna jest transformacja losowej zmiennej R w standaryzowaną zmienną normalną Z o średniej 0 i odchyleniu standardowym 1.

Wyrażenie to dla $\alpha = 0,05$ równa się $-1,644853$ (najczęściej podaje się je w przybliżeniu do dwóch cyfr znaczących). Stąd:

$$R_\alpha = \mu + \alpha \sigma. \quad (3.86)$$

w szczególności dla poziomu tolerancji $\alpha = 0,05$ powyższy wzór przyjmuje postać:

$$R_\alpha = \mu - 1,65 \sigma. \quad (3.87)$$

A zatem, jeśli przyjmie się normalność rozkładu stóp zwrotu, to kwantyl jest funkcją średniej i odchylenia standardowego rozkładu stóp zwrotu.

Dysponując wzorem (3.86), można VaR absolutną oraz VaR względną opisać następującymi równaniami:

$$\text{VaR}(\text{absolutna}) = -\mu W_0 - \alpha \sigma W_0, \quad (3.88)$$

$$\text{VaR}(\text{względna}) = -\alpha \sigma W_0. \quad (3.89)$$

Absolutna VaR zależy od dwóch parametrów σ oraz μ , natomiast względna VaR tylko od σ , przy założonym poziomie tolerancji. W praktyce zamiast posługiwania się dwoma różnymi typami wartości narażonej na ryzyko korzysta się tylko z jednej.

tj. z VaR względnej. Jest ona prostsza w zastosowaniu, gdyż zależy tylko od jednego parametru. Poza tym w przypadku posługiwania się krótkim okresem (np. danymi dziennymi lub z kilku dni) zasadne jest przyjęcie, że średnia rozkładu wynosi 0. Wówczas:

$$\text{VaR}(\text{absolutna}) = W_0 \cdot 0 - c \sigma W_0 = -c \sigma W_0 \quad (3.90)$$

jest identyczna z VaR względną.

Przyjmowanie, że średnia wynosi zero, nie jest jednak dobrym założeniem przy liczeniu VaR dla dłuższego przedziału czasowego. Jest wręcz odwrotnie, przy dłuższych przedziałach konieczne należy uwzględnić fakt, że średnia różni się od zera.

Przyjęcie normalności rozkładu jest szczególnie korzystne ze względu na możliwość szybkiego określenia wartości narażonej na ryzyko przy innym poziomie ufności oraz okresie przetrzymania. Jeżeli $\text{VaR}_{0,95}$ oznacza wartość narażoną na ryzyko odpowiadającą poziomowi ufności 95%, to dzieląc tę wartość przez $-1,65$, otrzymamy odchylenie standardowe portfela. Dysponując wartością odchylenia standardowego, wystarczy pomnożyć ją przez iloczyn wartości $-2,33$, korespondującej z poziomem ufności 99%, i wartości początkowej portfela W_0 :

$$\text{VaR}_{0,99} = \text{VaR}_{0,95} \frac{C_{0,99}}{C_{0,95}}. \quad (3.91)$$

W powyższym — klasycznym już podejściu do wartości narażonej na ryzyko — zakładaliśmy stałość średniej i odchylenia standardowego. Z dotychczasowego wykładu wiemy już, że możemy przyjąć założenia bardziej realistyczne, które będą oparte na modelach zmienności.

Rozważmy model ARMA-GARCH dla logarytmicznych stóp zwrotu:

$$r_t = \alpha_0 + \sum_{i=1}^p \alpha_i r_{t-i} + \varepsilon_t + \sum_{i=1}^q \beta_i \varepsilon_{t-i}, \quad (3.92)$$

$$\varepsilon_t = v_t \sqrt{h_t},$$

$$h_t = \gamma_0 + \sum_{i=1}^k \gamma_i \varepsilon_{t-i}^2 + \sum_{i=1}^l \delta_i h_{t+i-i}. \quad (3.93)$$

Prognozy na 1 okres wartości oczekiwanej oraz zmienności można obliczyć jako:

$$r_{t+1} = \alpha_0 + \sum_{i=1}^p \alpha_i r_{t+1-i} + \varepsilon_t + \sum_{i=1}^q \beta_i \varepsilon_{t+1-i}, \quad (3.94)$$

$$h_{t+1} = \gamma_0 + \sum_{i=1}^k \gamma_i \varepsilon_{t+1-i}^2 + \sum_{i=1}^l \delta_i h_{t+1-i}. \quad (3.95)$$

Gdy przyjmimy, że warunkowy rozkład stopy zwrotu w okresie prognozowanym jest normalny, tzn. $N(r_{t+1}, h_{t+1})$, wówczas kwantyle tego rozkładu warunkowego mogą być wykorzystane do kalkulacji VaR. Na przykład 5% kwantyl jest równy:

$$r_{t+1} - 1,64 \sqrt{h_{t+1}}. \quad (3.96)$$

Przyjmując z kolei rozkład t -Studenta z ν stopniami swobody, mamy odpowiednio:

$$r_{t+1} - \frac{t_{\nu, \alpha}}{\sqrt{\nu/(\nu-2)}} \sqrt{h_{t+1}}, \quad (3.97)$$

gdzie $t_{\nu, \alpha}$ jest α -procentowym kwantylem rozkładu t -Studenta o ν stopniach swobody.

Analizując modele, na których opiera się wyznaczanie wartości zagrożonej, należy przyjąć pewne kryteria ich wyboru. Służy do tego testowanie wsteczne modelu (*backtesting*) (por. np. Haas [2001]). Najprostszym testem jest test liczby przekroczeń (*failure test*). Dla danej próby teoretyczna liczba przekroczeń N ma rozkład dwumianowy. Testowaniu podlega wartość oczekiwana liczby przekroczeń. W rozkładzie dwumianowym jest ona dana wzorem:

$$E(N) = Tp, \quad (3.98)$$

gdzie:

N — liczba przekroczeń VaR,

T — długość próby testowej,

p — przyjęty poziom tolerancji VaR.

Odpowiednią statystykę zaproponował Kupiec [1995]. Jej postać jest następująca:

$$LR_m = -2 \ln [(1-p)^{T-N} p^N] + 2 \ln \left\{ \left[1 - \left(\frac{N}{T} \right)^{T-N} \right] \left(\frac{N}{T} \right)^N \right\}, \quad (3.99)$$

przy czym oznaczenia są takie same jak we wzorze (3.98).

Statystyka LR_m jest zbieżna do rozkładu $\chi^2(1)$. Należy ją uzupełnić weryfikacją hipotezy o niezależności przekroczeń w czasie. Chodzi o to, aby na przykład 20 przekroczeń nie nastąpiło w ciągu jednego miesiąca (Kupiec [1995]). W tym przypadku wykorzystuje się łącznie dwa testy: test do pierwszego przekroczenia (*time until first failure test*) oraz test czasu między kolejnymi przekroczeniami (*time between failures test*). Odpowiednia statystyka ma postać:

$$LR_{mf} = -2 \ln \left(\frac{p(1-p)^{V-1}}{\hat{p}_1(1-\hat{p}_1)^{V-1}} \right) + \sum_{i=2}^N \left\{ -2 \ln \left(\frac{p(1-p)^{V_{i-1}}}{\hat{p}_i(1-\hat{p}_i)^{V_{i-1}}} \right) \right\}, \quad (3.100)$$

przy czym:

$$\hat{\rho}_i = \frac{1}{V_i}, \quad (3.101)$$

gdzie:

V_1 — czas w dniach do pierwszego przekroczenia,

V_i — czas w dniach między $(i-1)$ -ym a i -tym przekroczeniem.

Statystyka LR_{ind} na rozkład zbliżony do χ^2 z N stopniami swobody. Ponieważ statystyki LR_{uc} i LR_{ind} są niezależne, proponuje się także ich łączne stosowanie w postaci testu:

$$LR_{mix} = LR_{uc} + LR_{ind}, \quad (3.102)$$

którego rozkład jest zbliżony do $\chi^2(N+1)$.

Jak wskazują wyniki badań empirycznych, modele nieuwzględniające efektu GARCH są na ogół odrzucane przez testy (por. Piontek [2002]).

Przykład 3.1

Rozważmy model opisujący dzienne logarymiczne stopy zwrotu z akcji BRE od 6 października 1992 r. do 16 listopada 2000 r., postaci:

$$r_t = 0,0011 + 0,1466r_{t-1} - 0,0537r_{t-2} + \varepsilon_t,$$

$$\varepsilon_t = \sqrt{h_t}v_t, \quad v_t \sim N(0, 1),$$

$$h_t = 0,000063 + 0,2087\varepsilon_{t-1}^2 + 0,7578h_{t-1}.$$

Z danych wiadomo, że:

$$r_{1829} = 0,01724,$$

$$r_{1830} = -0,02598,$$

$$r_{1830} = 0,000620.$$

Prognoza na 1 okres w przód jest następująca:

$$r_p = -0,00363,$$

$$h_p = 0,000674,$$

a 5% kwantyl wynosi:

$$-0,00363 - 1,6449 \cdot \sqrt{0,000674} = -0,046329.$$

Wartość VaR dla długiej pozycji 10 mln PLN wynosi:

$$\text{VaR} = 10\,000\,000 \cdot 0,04633 = 463\,290.$$

co oznacza, że potencjalna strata wartości pozycji następnego dnia z prawdopodobieństwem 0,95 wyniesie 463,290 tys. PLN lub mniej, jeżeli model AR(2)-GARCH(1, 1) jest prawdziwy.

1% kwantyl wynosi odpowiednio:

$$-0,00363 - 2,3262 \cdot \sqrt{0,000674} = -0,0640127,$$

stad VaR jest równa $10\,000\,000 \cdot 0,0640127 = 640\,127$ PLN.

3.40.3. Porównanie empirycznych modeli ARCH/GARCH dla stóp zmian indeksu WIG oraz kontraktów futures

Przykład 3.2

Empiryczne modele ARCH (GARCH) zostały oszacowane dla stóp zmian indeksu WIG (r_t) obserwowanych w okresie 2.01.2001–24.07.2002 (372 obserwacje dzienne — tablice 3.1–3.4).

Tablica 3.1. Oszacowany model AR(1)-ARCH(5)

	Ocena parametru	Błąd oceny	Statystyka z	Wartość p
Stała	-17,3	10,2	-1,696	0,089
r_{t-1}	0,086	0,051	1,664	0,096
Równanie wariancji				
Stała	31 544,1	3 676,4	8,580	0,000
ε_{t-1}^2	0,041	0,048	0,856	0,392
ε_{t-2}^2	0,025	0,054	0,463	0,643
ε_{t-3}^2	0,054	0,070	0,776	0,438
ε_{t-4}^2	0,144	0,072	0,001	0,045
ε_{t-5}^2	0,087	0,036	-2,414	0,016
R kwadrat	0,005			
Błąd standardowy reszt	197,518			AIC 13,398
Suma kwadratów reszt	14083818			SC 13,483
Logarytm funkcji wiarygodności	-2464,0			QI 0,531
Durbin-Watson stat.	1,990			

Źródło: Opracowanie własne.

Tablica 3.2. Oszacowany model AR(1)-GARCH(1, 1)

	Ocena parametru	Błąd oceny	Statystyka z	Wartość p
Stała	-13,3	10,795	-1,235	0,217
r_{t-1}	0,087	0,053	1,641	0,101
Równanie wariancji				
Stała	1256,1	1066,4	1,178	0,239
ε_{t-1}^2	0,012	0,017	0,698	0,485
h_{t-1}	0,952	0,036	26,680	0,000
R-kwadrat	0,006			
Błąd standardowy reszt	196,665			AIC 13,401
Suma kwadratów reszt	14 078 486			SC 13,454
Logarytm funkcji wiarygodności	-2467,531			Q1 0,492
Durbin-Watson stat.	1,994			

Źródło: Opracowanie własne.

Tablica 3.3. Oszacowany model stała-GARCH-M

	Ocena parametru	Błąd oceny	Statystyka z	Wartość p
h_t	0,00027	0,002	0,127	0,899
Stała	-23,675	81,997	-0,289	0,773
Równanie wariancji				
Stała	2574,3	3382,6	0,761	0,446
ε_{t-1}^2	0,032	0,027	0,196	0,231
h_{t-1}	0,900	0,108	8,293	0,000
R-kwadrat	0,0001			
Błąd standardowy reszt	197,988			AIC 13,463
Suma kwadratów reszt	14 307 754			SC 13,471
Logarytm funkcji wiarygodności	-2477,447			Q1 0,507
Durbin-Watson stat.	1,835			

Źródło: Opracowanie własne.

Analiza porównawcza otrzymanych modeli wskazuje na to, iż:

— standardowe kryteria wyboru modeli takie jak współczynnik R^2 są zbliżone do siebie i bardzo niskie,

Tablica 3.4. Oszacowany model AR(1)-EGARCH

	Ocena parametru	Błąd oceny	Statystyka z	Wartość p
Stała	-13,5	9,6	-1,414	0,157
r_{t-1}	0,090	0,049	1,824	0,068
Równanie wariancji				
Stała	0,276	0,032	8,638	0,000
$ v_{t-1} $	-0,079	0,041	-1,908	0,057
v_{t-1}	0,003	0,012	0,280	0,779
$\ln h_{t-1}$	0,979	3,73E-05	26 279,0	0,000
R-kwadrat	0,0058			
Błąd standardowy reszt	196,902			AIC 13,371
Suma kwadratów reszt	14 079 120			SC 13,434
Logarytm funkcji wiarygodności	-2460,879			Q1 0,518
Durbin-Watson stat.	1,999			

Źródło: Opracowanie własne.

— kryteria informacyjne: AIC oraz SC najmniejsze, a więc najlepsze wartości przyjęły w przypadku modelu EGARCH,

— kierując się istotnością parametrów, należy wykluczyć model GARCH-M, którego parametry zarówno w równaniu r_t , jak i w równaniu wariancji warunkowej okazały się nieistotne.

Reasumując: najlepszym w badanym przypadku okazał się model AR(1)-EGARCH(1, 1). Wskaźniki zgodności kierunku zmian Q1 zachowały się najlepiej w przypadku modelu ARCH(5), który z uwagi na liczbę szacowanych parametrów lepiej zastąpić modelem GARCH. Model EGARCH nieco lepiej przewiduje kierunek zmian niż model GARCH(1, 1). Zgodność tych przewidywań w niewielkim stopniu przekracza 50%.

Przykład 3.3

Polski rynek derywatów, podobnie jak rynki światowe, podlega zjawiskom charakterystycznym dla procesów finansowych, takim jak grupowanie wariancji czy grube ogony rozkładów stóp zmian. Można to zaobserwować na przykładzie dziennych stóp zmian kontraktu futures na akcje AGORY w okresie 23.10.2001–21.05.2004, przedstawionych na rysunku 3.7.

W tablicy 3.5 przedstawiono oszacowane, najlepsze z punktu widzenia kryterium Schwarza, modele GARCH dla wybranych kontraktów futures, notowanych na Giełdzie Papierów Wartościowych w Warszawie.

Wyniki prognoz na krótki 5-dniowy horyzont czasowy zostały przedstawione w tabelicy 3.6. Prognozy należy uznać za dopuszczalne i trafne już przy 3% błędzie granicznym.

Tabela 3.6. Wyniki prognozy kursu USD/JPY

h	Prognoza wariancji warunkowej	Względny błąd średni predykcji <i>ex ante</i>	Prognoza	Realizacja	Błąd prognozy <i>ex post</i>	Względny błąd średni prognozy <i>ex post</i>
1	3,5696	0,0140	135,868	135,725	-0,143	0,0010
2	3,4092	0,0191	135,708	135,675	-0,033	0,0008
3	3,2633	0,0229	135,547	134,610	-0,937	0,0041
4	3,1307	0,0261	135,393	132,240	-3,153	0,0124
5	3,0101	0,0289	135,245	132,680	-2,565	0,0141

Źródło: Hryż, Osińska [1999].

Pytania i problemy

1. Cechy analizy krótkookresowej.
2. Model ARCH i jego własności.
3. Testowanie efektu ARCH.
4. Model GARCH — postać, estymacja i prognozowanie.
5. Stacjonarność modeli GARCH.
6. Interpretacja i zastosowanie modelu GARCH-M.
7. Jakie są przyczyny zastosowania modeli GARCH z asymetrią; jakie to modele?
8. Wymień kryteria dopasowania modeli GARCH do danych empirycznych.
9. Porównaj cechy modeli EGARCH i TARCH.
10. Jakie są cechy modelu zmienności stochastycznej i co odróżnia ten model od modeli GARCH?
11. Wyjaśnij znaczenie analizy mikrostruktury rynków finansowych.
12. Wykaż, że suma wszystkich prawdopodobieństw w modelu (3.56) wynosi 1, a wartość oczekiwana $E(r_t^0) = \mu$.
13. Omów konstrukcję modelu ACD.
14. Jaki jest wpływ zmiennej wariancji warunkowej na model równowagi rynkowej CAPM?
15. Czy możliwość przewidywania zmienności i premii za ryzyko w modelu CAPM-ARCH stoi w sprzeczności z hipotezą rynku efektywnego?
16. Co to jest wartość narażona na ryzyko?
17. Porównaj klasyczne podejście do VaR z zastosowaniem modeli GARCH.
18. Jak na przykładzie WIG można ogólnie scharakteryzować zmienność empirycznych stóp zwrotu?

Rozdział 4

Wybrane nieliniowe modele szeregów czasowych

Słowa kluczowe: nieliniowość w procesach finansowych, hipoteza rynku fraktalnego, jednowymiarowe modele nieliniowe szeregów czasowych, testy nieliniowości, modele progowe

Celem niniejszego rozdziału jest prezentacja wybranych nieliniowych modeli szeregów czasowych, służących głównie do opisu warunkowej wartości oczekiwanej zmiennej objaśnianej. Oznacza to, że warunkowa średnia jest nieliniową funkcją zmiennych egzogenicznych oraz opóźnionych wartości zmiennej endogenicznej. Przewaga modeli nieliniowych nad liniowymi wynika przede wszystkim z tego, że te pierwsze dotyczą powiązań między badanymi zmiennymi w przypadkach niegaussowskich rozkładów tych zmiennych. Jak wynika z wcześniejszej analizy, finansowe szeregi czasowe rzadko charakteryzują się rozkładami normalnymi. Wśród modeli nieliniowych można wyróżnić wiele form, ponieważ grupa nieliniowych zależności funkcyjnych jest bardzo liczna. Dla przejrzystości wywodu podzielimy je na modele nieliniowe jednej zmiennej oraz wielu zmiennych, a także wskażemy, jakie restrykcje pozwalają ograniczyć liczbę możliwych modeli nieliniowych do najbardziej uzasadnionych — z punktu widzenia modelowania — procesów ekonomicznych. Należy zauważyć, że modele zmienności omawiane w rozdziale 3 stanowią także grupę modeli nieliniowych. Nieliniowość może dotyczyć zarówno zmiennych, jak i parametrów. Ze względu na swoją specyfikę modele zmienności są rozważane osobno. Czasami jednak trudno rozdzielić nieliniowość w warunkowej wartości oczekiwanej i nieliniowość w warunkowej wariancji. Niektóre modele łączą możliwości opisu tych dwóch parametrów jednocześnie. Można rozważać sytuację, w której modele nieliniowe wręcz powinny wyjaśnić także dynamikę zmienności (takie zadanie stawia się przed modelami pochodzącymi z chaosu deterministycznego, który zasadniczo wyklucza losowość), oraz przypadki, w których średnia procesu jest opisywana za pomocą któregoś spośród omówionych modeli nieliniowych, wariancja zaś przez model GARCH. Ten ostatni przypadek dotyczy np. modeli progowych, które Hansen [1996] oraz Osińska i Witkowski [2003] łączą z modelami GARCH, a także modeli dwuliniowych i GARCH analizowanych z powodzeniem w pracach Weissa [1986] oraz Bruzdy [2003].

4.1. Nieliniowość w procesach finansowych

Nieliniowość w procesach finansowych pojawia się w dość naturalny sposób. Zachowania uczestników rynku są częstokroć tego rodzaju, że będące efektem tych zachowań procesy finansowe charakteryzują się nieliniowością. Nieliniowe są funkcje opisujące postawy inwestorów wobec ryzyka, oczekiwania co do stóp zwrotu z walorów giełdowych, interakcje między uczestnikami rynku czy wreszcie formuły wyceny instrumentów finansowych.

Na rzecz nieliniowych zależności w finansach przemawiają następujące fakty empiryczne:

1. Brak pełnego empirycznego potwierdzenia tego, że rynki kapitałowe są efektywne. We wcześniejszych badaniach nie brano pod uwagę, że rynki i papiery wartościowe są od siebie wzajemnie zależne, oraz tego, że uczestnicy rynku nie zachowują się tak, jakby to wynikało z teorii racjonalnych oczekiwań. Inwestorzy mają prawo nie wiedzieć, jak interpretować niektóre informacje, i reagować na trendy. Mogą natomiast nie zareagować na informację bezpośrednio po jej otrzymaniu, a dopiero wówczas, gdy informacja potwierdza zmianę niedawnego trendu. Jest to reakcja nieliniowa będąca przeciwieństwem reakcji liniowej zakładanej w pojęciu racjonalnego inwestora.

2. Porażka reguły $T^{1/2}$. Z założenia o stabilnej zmienności rozkładów stóp zwrotu wynika, że:

$$S(r_T) = \sqrt{T} S(r_t), \quad (4.1)$$

gdzie:

$S(r_T)$ — odchylenie standardowe dla T -okresowej stopy zwrotu,

$S(r_t)$ — odchylenie standardowe dziennej stopy zwrotu.

3. Bardzo wysoka zmienność stóp zwrotu oraz niestabilność tej zmienności (wariancja jest stała i skończona tylko dla rozkładów normalnych) podważa koncepcję racjonalnego inwestora oraz założenie, jakoby duża liczba inwestorów gwarantowała stabilność rynku. Dobre własności modeli typu ARCH potwierdzają założenie o niestabilności wariancji (zwłaszcza w krótkich okresach).

4. Brak normalności rozkładów stóp zwrotu:

- asymetria rozkładów dziennych stóp zwrotu, pogrubione ogony i leptokurtotza,
- grube ogony i wysokie szczyty pojawiają się na skutek tego, że informacje nie docierają do inwestorów w sposób ciągły, ale pojawiają się w pakietach.

5. Inwestorzy nie zawsze unikają ryzyka, a często wręcz go poszukują, zwłaszcza wtedy, gdy znajdują się w sytuacji, w której odmowa uczestnictwa w grze hazardowej wydaje się prowadzić do nieuchronnej straty.

6. Na ogół inwestorzy ufają własnym prognozom bardziej niż pozwalają na to posiadane przez nich informacje.

7. Brak dowodów na poparcie tezy, że zbiorowości są bardziej racjonalne niż jednostki (przykładem są społeczne wstrząsy, mody).

Wobec powyższych faktów empirycznych powstały liczne hipotezy zaprzeczające temu, że rynki finansowe są zawsze efektywne. Do najważniejszych z nich należą hipotezy rynku fraktalnego oraz niejednorodnego (por. Weron, Weron [1999]).

Hipoteza rynku fraktalnego (HRF), a następnie w pełni rozwinięta hipoteza rynku niejednorodnego (HFN) zostały opracowane w instytucie badawczym Olsen & Associates w Zurychu. Zaletą tej pierwszej jest to, że uwzględnia wpływ informacji i długości horyzontu czasowego na zachowanie się poszczególnych inwestorów, a także pozwala zrozumieć ruch cen nie tylko w okresie równowagi, ale także w okresach paniki oraz innych zaburzeń rynku, co daje jej przewagę nad hipotezą rynku efektywnego (HRE). Można ją traktować jako rozszerzenie hipotezy efektywności informacyjnej.

Do głównych cech HRF należą:

1. Globalny rynek składa się z dużej liczby uczestników o różnych horyzontach czasowych inwestycji.

2. Informacja ma różny wpływ na różne horyzonty czasowe.

3. Stabilność rynku jest głównie rezultatem jego płynności. Rynek złożony z wielu inwestorów o różnych horyzontach czasowych gwarantuje płynność.

4. Ceny walorów odzwierciedlają kombinację handlu krótkoterminowego (opartego na analizie technicznej) i długoterminowego (opartego na analizie fundamentalnej).

5. Jeśli instrument finansowy nie ma powiązań z cyklami ekonomicznymi, to nie ma szans na długoterminowy trend.

Najnowsze badania w zakresie charakterystyk szeregów finansowych pozwoliły na odkrycie nowych faktów empirycznych, do których należą:

- pozytywna korelacja między zmiennością a aktywnością rynku,
- długa pamięć zmienności,
- efekt gorącej fali polegający na tym, że pamięć w globalnym procesie zmienności jest relatywnie słabsza w przedziałach czasowych odpowiadających połowie oraz półtora dnia transakcyjnego oraz mocniejsza w przedziałach odpowiadających jednemu i dwóm dniom.

Hipoteza rynku niejednorodnego (HRN) wykorzystuje powyższe fakty i odnosi się głównie do rynku walutowego. Jej najważniejsze cechy to:

1. Na rynku istnieją różne typy inwestorów; różnią się one horyzontem czasowym oraz częstotliwością dokonywania transakcji, zatem rynek jest niejednorodny i każdy inwestor ma swój czas reakcji na informacje.

2. Istotny wpływ na dynamikę ma fakt, że uczestnicy globalnego rynku walutowego pracują na różnych kontynentach, w różnych strefach czasowych.

3. Różnice między uczestnikami rynków walutowych dotyczą nie tylko horyzontu czasowego i lokalizacji geograficznej, ale również awersji do ryzyka, powiązań instytucjonalnych oraz kosztów transakcji.

Jednorównaniowe modele nieliniowe szeregów czasowych

Charakterystyka nieliniowych modeli szeregów czasowych

Klasyczne podejście do modelowania procesów stochastycznych, opracowane przez Boxa i Jenkinsa, a oparte na twierdzeniu Wolda o dekompozycji stacjonarnego szeregu czasowego, zakłada liniową postać modeli autoregresyjnych, średniej ruchomej czy też modeli mieszanych (por. Potter [1999]). Modele te i ich własności zostały omówione w rozdziale 2 niniejszego podręcznika.

Pomimo wielu zalet, modele klasy ARMA mają także szereg ograniczeń, do których należą:

- niespełnienie założeń o normalności rozkładu,
- silne uzależnienie rozwiązania modelu ARMA od wartości początkowych,
- występowanie gwałtownych wahań amplitudy,
- cykliczność szeregów czasowych i cykliczność funkcji autokorelacji.

W nieliniowej analizie jednowymiarowych szeregów czasowych poszukuje się odpowiedniej funkcji wiążącej dany proces z ciągiem niezależnych zmiennych losowych o jednakowym rozkładzie:

$$y_t = f(\varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}, \dots). \quad (4.2)$$

Powyższa reprezentacja jest zbyt ogólna, aby można nią swobodnie operować. Dlatego najczęściej dokonuje się aproksymacji poprzez rozwinięcie funkcji f w szereg Taylora i przyjmuje się, że nieliniowy proces ekonomiczny ma postać:

$$y_t = g(\varepsilon_{t-1}, \varepsilon_{t-2}, \dots) + \varepsilon_t h(\varepsilon_{t-1}, \varepsilon_{t-2}, \dots). \quad (4.3)$$

Warunkowa średnia i warunkowa wariancja powyższego procesu wynoszą odpowiednio:

$$E(y_t | \Omega_{t-1}) = g(\varepsilon_{t-1}, \varepsilon_{t-2}, \dots), \quad (4.4)$$

$$D^2(y_t | \Omega_{t-1}) = h^2(\varepsilon_{t-1}, \varepsilon_{t-2}, \dots). \quad (4.5)$$

Definicja 4.1

Proces y_t będziemy nazywali nieliniowym, jeżeli jego warunkowa wartość średnia lub warunkowa wariancja są nieliniowymi funkcjami.

Prowadzi to do naturalnego podziału ekonomicznych procesów nieliniowych na procesy nieliniowe w wartości średniej (m.in. procesy i modele dwuliniowe, nieliniowe modele autoregresji, modele progowe, przełącznikowe, wygładzonego

przejścia, deterministyczne systemy nieliniowe) oraz na procesy nieliniowe w wariancji warunkowej (m.in. omówione w rozdziale 3 modele GARCH i modele stochastycznej zmienności).

4.2.2. Wybrane modele nieliniowe

Modele nieliniowej autoregresji (*non-linear autoregressive models*). Prosty nieliniowy model autoregresyjny rzędu 1 (NLAR(1)) ma postać:

$$y_t = f(y_{t-1}) + \varepsilon_t. \quad (4.6)$$

Model NLAR(1) jest procesem Markowa. Procesy Markowa mają tę własność, że warunkowy rozkład prawdopodobieństwa y_{t+1} względem wszystkich y_{t-j} ($j \geq 0$) jest identyczny jak rozkład warunkowy y_{t+1} względem y_t . Oznacza to, że cała informacja o przyszłości szeregu jest zawarta w jego ostatniej wartości. Najczęściej stosowany model tego typu ma postać:

$$y_t = g(y_{t-1}) y_{t-1} + \varepsilon_t, \quad (4.7)$$

gdzie część deterministyczna jest równa:

$$E(y_t) = g(\bar{y}_{t-1}) \bar{y}_{t-1}. \quad (4.7a)$$

Uogólnienie dla p opóźnień NLAR(p) jest oczywiste:

$$y_t = f(y_{t-1}, y_{t-2}, \dots, y_{t-p}) + \varepsilon_t. \quad (4.8)$$

Szczególnym przypadkiem modelu NLAR(p) jest model wykładniczej autoregresji EAR(p), postaci:

$$y_t = \sum_{j=1}^p \alpha_j y_{t-j} + \varepsilon_t, \quad (4.9)$$

przy czym:

$$\alpha_j = \phi_j + \pi_j \exp(-\alpha y_{t-j}^2). \quad (4.10)$$

Jeśli postać funkcji f lub g jest znana, to parametry modelu można szacować za pomocą metody najmniejszych kwadratów lub największej wiarygodności.

Nieliniowe modele średniej ruchomej (*non-linear moving average models*). Ogólny model NLMA ma postać:

$$y_t = h(\varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_{t-q}) + \varepsilon_t, \quad (4.11)$$

gdzie ε_t jest procesem białego szumu.

Jedna z możliwych wersji modelu NLMA(1) jest następująca:

$$y_t = \varepsilon_t + b \varepsilon_{t-1}^2. \quad (4.12)$$

Bardziej skomplikowanym przykładem jest model Rocke'a [1982], dany jako:

$$y_t = \varepsilon_t + b_1 \psi(\varepsilon_{t-1}) + b_2 \psi(\varepsilon_{t-2}) + \dots, \quad (4.13)$$

$$\forall_{x>0} \psi(x) \leq 0, \quad \psi(-x) = -\psi(x), \quad \psi(0) = 1.$$

Własnością modelu (4.13) jest to, że przy niewielkich zmianach zachowuje się jak model ARMA, natomiast słabiej reaguje na silne zmiany (szoki). Modele tej grupy mają niezbyt duże zastosowanie praktyczne z powodu nieodwracalności, co utrudnia prognozowanie.

Modele dwuliniowe (bilinear models). Model dwuliniowy można traktować jako pośredni między NLAR a NLMA lub jako nieliniowy odpowiednik modelu ARMA. Modele te zostały wprowadzone przez Grangera i Andersena [1978], a w literaturze polskiej są opisane w pracy Bruzdy [2003].

Model dwuliniowy jest modelem liniowym w zakresie y_t oraz ε_t , ale nieliniowym pod względem obu tych procesów jednocześnie. Jego postać jest następująca:

$$y_t = [1 + \sum_{i=1}^p a_i y_{t-i} + \sum_{j=0}^q \theta_j \varepsilon_{t-j} + \sum_{k=1}^p \sum_{l=1}^q c_{kl} y_{t-k} \varepsilon_{t-l}], \quad (4.14)$$

przy czym $\theta_0 = 1$.

Prostsze postaci modelu dwuliniowego można zapisać na przykład jako:

$$y_t = \varepsilon_t + b \varepsilon_{t-1} y_{t-2}$$

lub:

$$y_t = a y_{t-1} + \varepsilon_t + b \varepsilon_{t-2} y_{t-2}.$$


Modele dwuliniowe generują szeregi o własnościach białego szumu, które są nieprzewidywalne liniowo, ale przewidywalne nieliniowo. Ich własności są podobne do modelu ARCH, gdyż pozwalają one modelować skupianie się danych. Jak wynika z postaci (4.14), iloczyn dwóch procesów $y_{t-k} \varepsilon_{t-l}$ potęguje efekt zmienności. Można wykazać (por. Tong [1990]), że jeżeli proces $\varepsilon_t = v_t \sqrt{h_t}$ jest procesem ARCH, to proces $\varepsilon_t^2 = v_t^2 h_t$ jest procesem dwuliniowym.

Wyróżnia się trzy rodzaje procesów dwuliniowych:

- procesy naddiagonalne, dla których $c_{kl} = 0$ dla $k > l$,
- procesy poddiagonalne, dla których $c_{kl} = 0$ dla $k < l$,
- procesy diagonalne, dla których $c_{kl} = 0$ dla $k \neq l$.

Na rysunku 4.1 została przedstawiona przykładowa ścieżka procesu dwuliniowego wygenerowanego według następującego modelu $y_t = \varepsilon_t + 0,5 y_{t-2} \varepsilon_{t-1}$, dla 500 obserwacji.

Rysunek 4.1. Przykładowa realizacja modelu dwuliniowego



Źródło: Opracowanie własne.

Modele progowe. Ich istota polega na założeniu lokalnej aproksymacji stanów i przechodzenia z jednego stanu (reżimu) do drugiego poprzez parametr progowy (por. Tong [1990]). Pozwala on analizować system ekonomiczny poprzez jego dekompozycję na prostsze podsystemy.

Ogólny model TAR można zapisać jako:

$$Y_t + \theta_0 + \theta_1 Y_{t-1} + \dots + \theta_p Y_{t-p} + I(Y_{t-d} \leq r) \cdot (\phi_0 + \phi_1 Y_{t-1} + \dots + \phi_q Y_{t-q}) = \varepsilon_t, \quad (4.15)$$

gdzie:

d, p i q — nieujemne stałe,

ε_t — biały szum,

r — taki parametr progowy, że $I(z \leq r) = \begin{cases} 1, & \text{dla } z \leq r, \\ 0, & \text{dla } z > r. \end{cases}$

Model TAR, w którym zmienną progową jest opóźniona w czasie wartość procesu objaśnianego $z = Y_{t-d}$, nazywa się modelem SETAR (*Self-Exciting TAR*) (por. Tong [1990]).

Model (4.15) w wersji SETAR można także zapisać w następującej postaci:

$$Y_t = \begin{cases} a_0^1 + a_1^1 Y_{t-1} + \dots + a_{k_1}^1 Y_{t-k_1} + h_1 \varepsilon_t, & \text{dla } Y_{t-d} \in R_1, \\ a_0^2 + a_1^2 Y_{t-1} + \dots + a_{k_2}^2 Y_{t-k_2} + h_2 \varepsilon_t, & \text{dla } Y_{t-d} \in R_2, \\ \dots & \dots \\ a_0^s + a_1^s Y_{t-1} + \dots + a_{k_s}^s Y_{t-k_s} + h_s \varepsilon_t, & \text{dla } Y_{t-d} \in R_s, \end{cases} \quad (4.16)$$

gdzie:

$$R_1 = (-\infty, r_1); \quad R_2 = (r_1, r_2); \quad R_{s-1} = (r_{s-2}, r_{s-1}); \quad R_s = (r_{s-1}, +\infty).$$

Parametry $r_1, r_2, \dots, r_{s-1}$ noszą nazwę parametrów progowych i dzielą zbiór liczb rzeczywistych na rozłączne przedziały, tzn. reżimy lub stany, natomiast d jest parametrem opóźnienia.

Przykład prostego progowego modelu autoregresyjnego dla szeregu czasowego y_t można zapisać jako:

$$y_t = \begin{cases} a_1 y_{t-1} + \varepsilon_t, & \text{jeśli } y_{t-2} > 0, \\ a_2 y_{t-1} + \varepsilon_t, & \text{jeśli } y_{t-2} \leq 0, \end{cases} \quad (4.17)$$

gdzie $a_1 \neq a_2$.

Równania w poszczególnych reżimach są liniowe, a parametry modelu liniowego zmieniają się według reguły przełącznikowej. Zmiana parametrów jest tu raczej gwałtowna, co może odbiegać od rzeczywistości. Modele progowe będą przedmiotem szczegółowej analizy w dalszych podrozdziałach.

Modele wygładzonego przejścia. Lin i Teräsvirta [1994] (por. też Granger, Teräsvirta [1993]) wprowadzili modele, które można określić mianem modeli wygładzonego przejścia (*smooth transition regression* — STR). Należą one, podobnie jak modele progowe, do tzw. modeli regresji przełącznikowej (por. Pruska [1996]). Ich generalną cechą jest przechodzenie od stanu do stanu z określonym prawdopodobieństwem. Często liczba przełączeń jest nieznana.

Modele STR znajdują zastosowanie w opisie makroekonomicznych i finansowych szeregów czasowych (por. np. Osińska [1996]) wtedy, kiedy przejście z jednego reżimu do drugiego jest łagodne, a proces cechuje stopniowe dostosowywanie do nowego poziomu.

Ogólny zapis jednorównaniowego modelu wygładzonego przejścia jest następujący:

$$y_t = x_t' \pi_1 + x_t' \pi_2 F(z_t) + \varepsilon_t, \quad (4.18)$$

gdzie:

$x_t = [1 y_{t-1} \dots y_{t-p} x_{1t} \dots x_{qt}]$ — wektor $(m \times 1)$, przy czym $m = p + q + 1$,

π_1, π_2 — odpowiednie wektory parametrów o wymiarach $(m \times 1)$,

ε_t — i.i.d.,

$F(z_t)$ — funkcja transformacji, która przekształca zmienną endogeniczną z reżimu $E(y_t | x_t) = x_t' \pi_1$ do reżimu $E(y_t | x_t) = x_t' (\pi_1 + \pi_2)$ przy danym z_t .

$F(z_t)$ jest parzystą lub nieparzystą funkcją ciągłą. Istnieje zatem wiele form, które funkcja transformacji może przybierać. W praktyce najczęściej przyjmuje się następujące postaci:

$$F(z_t) = F(\gamma, t) = [1 + \exp \{-\gamma(t^k + \alpha_1 t^{k-1} + \dots + \alpha_{k-1} t + \alpha_k)\}]^{-1} \quad (4.19)$$

lub:

$$F(z_t) = F(\gamma, t) = 1 + \exp \{-\gamma(t - \alpha)^2\}. \quad (4.20)$$

Wzór (4.19) odpowiada funkcji logistycznej, natomiast wzór (4.20) funkcji wykładniczej. Zmienną transformacji w obu przypadkach jest zmienna czasowa ($z_t = t$). Rozważa się 3 przypadki:

1. W (4.19) $k = 1$; wówczas parametr nachylenia γ informuje, jak gwałtowna zmiana ma miejsce, a α_1 informuje o średnim poziomie zmiany. Zmiana jest monotoniczna w czasie t . Przy $\gamma \rightarrow \infty$ model (4.18) staje się modelem z pojedynczą zmianą strukturalną, natomiast przy $\gamma \rightarrow 0$ — modelem liniowym.

2. W (4.19) $k = 3$; w czasie t zmiana może być monotoniczna lub niemonotoniczna, a ponadto dopuszcza się więcej niż jedną zmianę struktury o charakterze ciągłym.

3. W (4.20) przyjęto $k = 2$; model opisuje niemonotoniczny typ zmiany.

Modele przełącznikowe. Modele tego typu, wykorzystujące łańcuchy Markowa (*Markov switching*), zostały wprowadzone przez Hamiltona [1994]¹. Zasadnicza różnica między nimi a modelami progowymi polega na tym, że w przypadku modeli progowych reżimy są określone przez przeszłe wartości szeregu czasowego, a w modelach przełącznikowych — przez egzogeniczny stan łańcucha Markowa. Ogólna postać modelu jest następująca:

$$y_t = \begin{cases} \alpha_1 + \sum_{i=1}^p \beta_{1i} y_{t-i} + \varepsilon_t, & \text{dla } z_t = 0, \\ \alpha_2 + \sum_{i=1}^p \beta_{2i} y_{t-i} + \varepsilon_t, & \text{dla } z_t = 1. \end{cases} \quad (4.21)$$

Zmiana reżimu jest stochastyczna i zazwyczaj zawiera autokorelację. Prawdopodobieństwa przejścia ze stanu do stanu są następujące:

$$\begin{aligned} P(z_t = 0 | z_{t-1} = 0) &= q, \\ P(z_t = 1 | z_{t-1} = 0) &= 1 - q, \\ P(z_t = 0 | z_{t-1} = 1) &= 1 - p, \\ P(z_t = 1 | z_{t-1} = 1) &= p, \end{aligned} \quad (4.22)$$

co można wyrazić w zapisie macierzowym:

$$P = \begin{bmatrix} q & 1-q \\ 1-p & p \end{bmatrix}. \quad (4.23)$$

Z punktu widzenia analizy szeregów finansowych model przełącznikowy ma wiele zalet:

¹ Przykłady empiryczne w zakresie analizy procesów finansowych można znaleźć m.in. w pracach: Mills [2002], Białkowski, Bohi, Serwa [2004].

- zmiany reżimu są często spowodowane czynnikami niezwiązanymi z szeregiem czasowym (w tym przypadku ze stanem łańcucha z_t),
- rzadko kiedy wiemy, w jakim reżimie znajdujemy się obecnie, ale możemy z dużym prawdopodobieństwem określić, w jakim stanie się znajdowaliśmy,
- estymacja macierzy prawdopodobieństw odbywa się za pomocą metody największej wiarygodności.

Chaos deterministyczny. Termin ten oznacza ruch nieregularny, chaotyczny, zachodzący w nieliniowym układzie deterministycznym, którego prawa dynamiki jednoznacznie określają ewolucję stanu układu w czasie, gdy znana jest jego wcześniejsza historia. Ważną cechą szeregów czasowych generowanych przez nieliniowy układ dynamiczny jest to, że wyglądają jak losowe².

Cechy chaosu deterministycznego:

- wrażliwość na warunki początkowe — bardzo małe różnice w warunkach początkowych prowadzą do całkowicie odmiennych zachowań systemu po pewnym czasie,
- dziwny atraktor — kolejne iteracje danego przekształcenia dla danych warunków początkowych tworzą bardzo skomplikowaną trajektorię o specyficznych własnościach.


Trajektoria jest to ciąg przekształceń postaci: $x_{t+1} = f(x_t)$, przy określonych warunkach początkowych. Atraktor jest zbiorem punktów, do którego dążą trajektorie danego układu. Dziwny atraktor jest fraktalem.

Nieliniowe równanie postaci:

$$x_{t+1} = 1 + bx_{t-1} - ax_t^2, \text{ dla } x_0 = 0,1; a = 1,4; b = 0,3,$$

generuje szereg chaotyczny, który pokazano na rysunku 4.2.

Rysunek 4.2. Przykład szeregu chaotycznego



Źródło: Opracowanie własne.

² Właśnie z tego powodu chaos deterministyczny cieszy się dużym zainteresowaniem badaczy w odniesieniu do szeregów finansowych. Wyniki empiryczne są jednak mało przekonujące; por. np. Liu, Granger, Heller [1993], Doman M. [2002], Doman R. [2004], Orzeszko [2004a, b].

Podobne zachowanie wykazuje tzw. odwzorowanie Hennona, którego postać jest dana przez układ równań postaci (por. np. Zwołankowska [2001]):

$$x_{t+1} = 1 + y_t - ax_t^2,$$

$$y_{t+1} = bx_t.$$

4.2.3. Kryteria wyboru funkcji nieliniowej

Teoretyczne podstawy wyboru funkcji nieliniowej sformułował Lau [1986]. Należą do nich:

- 1) zgodność teoretyczna, tj. odpowiedź na pytanie, czy wybrana forma charakteryzuje się własnościami wymaganymi przez zależności ekonomiczne,
- 2) dziedzina zmienności, tj. określenie, czy zmienne mogą przyjmować wartości z szerokiego i właściwego zakresu (niektóre wartości, takie jak zero czy nieskończoność, mogą powodować nieakceptowalne — z punktu widzenia interpretacji — formy zależności),
- 3) elastyczność, tzn. że wybrana forma powinna mieć zdolność aproksymacji innych podobnych form dla pewnych wartości parametrów,
- 4) własności obliczeniowe,
- 5) zgodność z faktami empirycznymi.

Chcąc ocenić ostatni — piąty — punkt, musimy się posłużyć pewnymi miarami. Okazuje się, że funkcja autokorelacji i funkcja korelacji wzajemnej $c_k = \text{cor}(y_t, x_{t-k})$ są dobre w przypadku liniowych procesów stacjonarnych, ale nie spełniają swego zadania w przypadku procesów nieliniowych. Dla modeli nieliniowych stosuje się:

— współczynnik maksymalnej korelacji:

$$mp = \text{cor}[g(y), f(x)], \quad (4.24)$$

gdzie f i g są funkcjami, które maksymalizują mp .

— maksymalną średnią korelację:

$$mm = \text{cor}[y, f(x)], \quad (4.25)$$

gdzie f maksymalizuje mm ,

— maksymalny współczynnik regresji:

$$mr = R^2, \text{ w regresji } y = f(x) + \varepsilon_t, \quad (4.26)$$

przy czym f maksymalizuje mr .

W przypadku wyboru liczby opóźnień w nieliniowych modelach NLAR i NLMA oraz w modelach dwuliniowych i progowych korzysta się z kryteriów informacyjnych — przede wszystkim z AIC oraz BIC .

Stacjonarność i stabilność w przypadku modeli nieliniowych

Stacjonarność. Warunki stacjonarności znane dla modeli liniowych:

$$E(y_t) = \text{constans},$$

$$D^2(y_t) = \text{constans},$$

$$\text{cov}(y_t, y_s) = \text{cov}(\tau)$$

są tylko warunkami koniecznymi. Warunki dostateczne zależą od postaci funkcji nieliniowych i od tego, czy na podstawie jednej realizacji można oszacować wymienione wyżej parametry: średnią, wariancję i kowariancję. Muszą być one określone dla konkretnych postaci funkcyjnych.

Stabilność, pamięć i równowaga. Problem stabilności jest związany z własnościami procesu w długim okresie. Rozważmy na przykład model NLAR(1):

$$y_t = f(y_{t-1}) + \varepsilon_t \quad (4.27)$$

z wartością początkową y_0 , gdzie ε_t jest białym szumem.

Niech rozwiązanie tego równania będzie dane jako:

$$y_t = g(\varepsilon_t, \varepsilon_{t-1}, \dots, \varepsilon_1, y_0) \quad (4.28)$$

i warunkowa funkcja rozkładu prawdopodobieństwa, zależnie od y_0 , jest równa:

$$P(y_t \leq x | y_0) = \phi_t(x, y_0). \quad (4.29)$$

1. Proces y_t jest procesem o krótkiej pamięci, jeśli:

$$\phi_t(x, y_0) \rightarrow \phi_h(x), \quad \text{gdy } t \rightarrow h, \quad (4.30)$$

dla dużych h , czyli w długim okresie wartość początkowa nie wpływa na rozkład brzegowy.

2. Proces jest stabilny, jeżeli:

$$\lim_t \phi_t(x, y_0) = \phi(x, y_0), \quad (4.31)$$

tzn. y_t, y_s mają takie same rozkłady brzegowe dla dużych t i s , ale rozkłady te mogą zależeć od y_0 .

Dla porównania, dla procesu liniowego AR(1) postaci:

$$y_t = \rho y_{t-1} + \varepsilon_t$$

dane jest rozwiązanie:

$$y_t = \rho^t y_0 + \sum_{k=0}^{t-1} \rho^k \varepsilon_{t-k}.$$

Jeśli $|\rho| < 1$, to pierwszy składnik sumy zmierza do zera, a proces jest procesem o krótkiej pamięci oraz stabilnym. Jeżeli natomiast $\rho > 1$, to pierwszy składnik rośnie wraz z t , a drugi składnik ma rosnącą wariancję, zatem proces nie jest stabilny i cechuje się długą pamięcią.

Dla procesu nieliniowego NLAR(1) postaci:

$$y_t = f(y_{t-1}, \varepsilon_t), \quad (4.32)$$

będącego uogólnieniem (4.26), możemy stwierdzić, że jeżeli są spełnione następujące warunki:

- 1) funkcja $f(y, \varepsilon)$ jest ciągle względem y ,
- 2) ε_t jest białym szumem,
- 3) $E \|f(x, \varepsilon_t) - f(z, \varepsilon_t)\| \leq \|x - z\|$,
- 4) $E \|f(x, \varepsilon_t)^2\| \leq \sigma \|x\|^2$,
- 5) $0 < x < 1$, $\delta > 0$,

gdzie $\|$ jest normą wektorową, to y_t posiada krótką pamięć i jest stabilny.

Testowanie nieliniowości

W literaturze przedmiotu można znaleźć wiele testów na badanie formy nieliniowej modelu szeregu czasowego. Najogólniej można je podzielić na dwie grupy: testy, w których hipoteza alternatywna nie precyzuje konkretnej postaci funkcji nieliniowej (test RESET, test BDS), oraz testy dostosowane do określonej postaci nieliniowości.

Test RESET (*regression error specification test*) Ramseya [1969] należy zaliczyć do pierwszej grupy testów, niewymagających znajomości konkretnej postaci funkcyjnej modelu nieliniowego.

Założmy, że liniowa część modelu jest następująca:

$$y_t = \beta' z_t + u_t, \quad (4.33)$$

gdzie: $z_t = [1 \ y_{t-1} \ y_{t-2} \dots \ y_{t-p} \ x_1 \ x_2 \dots \ x_k]$. Za pomocą KMNK szacujemy parametry β , a następnie wyznaczamy:

$$SSR_0 = \sum \hat{u}_t^2.$$

W kolejnym kroku za pomocą KMNK szacujemy parametry równania pomocniczego postaci:

$$\hat{u}_t = \delta' z_t + \sum_{j=2}^h \psi_j \hat{y}_t^j + v_t \quad (4.34)$$

oraz obliczmy:

$$SSR = \sum \hat{v}_t^2.$$

Następnie obliczamy wartość statystyki:

$$F = \frac{(SSR_0 - SSR)/(h-1)}{SSR/(T-m-h)}, \quad (4.35)$$

gdzie $m = p + k$. Wartości krytyczne znajdujemy w rozkładzie F -Snedecora.

Hipoteza zerowa podlegająca badaniu ma postać:

$$H_0: \psi_j = 0, \quad j = 2, 3, \dots, h,$$

wobec alternatywy:

$$H_1: \psi_j \neq 0.$$

Test BDS jest narzędziem trudnym do zastosowania, ale już dostępnym w licznych pakietach komputerowych, np. Eviews 4.0. Cieszy się on ostatnio dużym zainteresowaniem, co jest związane z popularnością chaosu deterministycznego i jego zastosowań na rynkach kapitałowych. W istocie nie jest to test na wykrywanie chaosu (jak się czasem sądzi), ale jest to efektywne narzędzie wykrywania nieliniowości dowolnego pochodzenia. Test został sformułowany przez Brocka, Decherta i Scheinkmana (por. Granger, Teräsvirta [1993], Bruzda [2003]), Orzeszko [2004b]. Hipoteza zerowa głosi, że badany szereg jest ciągiem niezależnych zmiennych losowych o jednakowym rozkładzie. W praktyce testowania nieliniowości oznacza to, że reszty z szeregu opisanego przez dobrze dopasowany model liniowy są i.i.d. Jeśli tak jest, to model jest liniowy, w przeciwnym wypadku kryje się w nim jakaś nieliniowość.

Oznaczmy przez $Y_{t,m}$ ciąg kolejnych wektorów pochodzących z szeregu y_t , takich że $Y_{t,m} = [y_t, y_{t+1}, \dots, y_{t+m-1}]$. Para wektorów $Y_{t,m}$ i $Y_{s,m}$ znajduje się w odległości nie większej niż ε , jeżeli:

$$|y_{t+j} - y_{s+j}| < \varepsilon, \text{ dla } j = 0, 1, \dots, m-1.$$

Niech:

$$C_m(\varepsilon) = \frac{1}{T^2} K,$$

gdzie K oznacza liczbę par (t, s) znajdujących się od siebie w odległości nie większej niż ε . Statystyka BDS postaci:

$$BDS = \sqrt{T} [C_m(\varepsilon) - C_1(\varepsilon)^m] \quad (4.36)$$

ma rozkład normalny o średniej zero i znanej, ale bardzo skomplikowanej wariancji, której wzór można znaleźć w pracy Brocka i in. [1987]. Test jest nieodpowiedni w przypadku próby mniejszej niż 200 obserwacji oraz wrażliwy na wybór m i ε . Badania wskazują również, że dobrze odróżnia on tylko niektóre formy nieliniowości

stochastycznej, na przykład w przypadku modeli dwuliniowych, jego moc jest natomiast niezbyt wysoka wobec nieliniowych modeli autoregresyjnych, nieliniowych modeli średniej ruchomej, a także modeli progowych (por. Liu, Granger, Heller [1993]).

► Przykład 4.1

Rozważmy logarytmiczne stopy zwrotu z indeksu WIG w okresie 2.01.2001–24.07.2002. Test BDS zastosowano w celu zbadania, czy stopy te są niezależne o jednakowym rozkładzie, a następnie — dla porównania — ten sam test zastosowano do reszt z modelu ARMA-EGARCH, przedstawionego w podrozdziale 3.11. Wyniki prezentuje tablica 4.1.

Tablica 4.1. Wyniki testu BDS dla stóp zwrotu z Indeksu WIG

m	Test BDS dla stóp zwrotu z WIG				Test BDS dla reszt z ARMA-EGARCH			
	BDS Statistic	błąd standardowy	statystyka z	wartość p	BDS Statistic	błąd standardowy	statystyka z	wartość p
2	0,0045	0,0039	1,16922	0,2423	0,0032	0,0039	0,8452	0,3980
3	0,0076	0,0061	1,2442	0,2134	0,0055	0,0061	0,9071	0,3643
4	0,0115	0,0072	1,5817	0,1137	0,0091	0,0073	1,2504	0,2111
5	0,0149	0,0075	1,9827	0,0474	0,0127	0,0076	1,6722	0,0945
6	0,0136	0,0072	1,8734	0,0610	0,0112	0,0073	1,5335	0,1251

Źródło: Opracowanie własne.

Wyniki testowania wskazują, że przy poziomie 5% odrzucamy H_0 dla stóp zwrotu, podczas gdy zastosowanie modelu ARMA-EGARCH wyeliminowało nieliniową zależność w badanym szeregu.

Testowanie liniowości wobec alternatywy STR. Model STR (4.18) reprezentuje stacjonarny jednowymiarowy przypadek ogólnej klasy modeli STR, stąd procedura testowania może zostać oparta na pracy Grangera i Teräsvirty [1993].

Niech (4.19) i (4.20) oznaczają odpowiednie funkcje transformacji. Hipoteza zerowa $H_0: \gamma = 0$, oznacza liniowość, podczas gdy alternatywa zakłada nieliniowość $H_1: \gamma > 0$. Przyjmijmy:

$$\bar{F}(z_t) = F(z_t) - 0,5.$$

Procedura testująca wymaga identyfikacji funkcji transformacji. Jest to możliwe przy użyciu rozwinięcia Taylora 3-rzędu:

$$T(z_t) = g_1 h_t + (g_2/6) h_t^3, \quad (4.37)$$

przy czym:

$$h_t = \gamma(a'z_t - c),$$

$$g_1 = \partial F(0)/\partial \gamma,$$

$$g_3 = \partial^3 F(0)/\partial \gamma^3.$$

Testowanie przebiega w następujących etapach:

1. Szacujemy parametry równania liniowego za pomocą KMNK:

$$y_t = \beta_1' w_t + \varepsilon_t \quad (4.38)$$

i obliczamy wektor reszt $\hat{\varepsilon}_t = y_t - \hat{\beta}_1' w_t$. Niech $SSR_0 = \sum \hat{\varepsilon}_t^2$.

2. Szacujemy równanie pomocnicze:

$$\hat{\varepsilon}_t = \beta_0 w_t + \beta_1 w_t z_{td} + \beta_2 w_t z_{td}^2 + \beta_3 w_t z_{td}^3 + v_t \quad (4.39)$$

oraz obliczamy $SSR = \sum \hat{v}_t^2$.

3. Hipoteza zerowa $\gamma = 0$ musi zostać teraz zmieniona na:

$$H_0: \beta_i = 0, \quad i = 1, 2, 3.$$

4. Statystyka LM ma postać:

$$LM = T(SSR_0 - SSR)/SSR_0 \quad (4.40)$$

i posiada rozkład zbieżny do χ^2 o $3m$ stopniach swobody. W praktyce poleca się wersję F tego testu z uwagi na większą moc w małych próbach.

Testowanie liniowości wobec alternatywy SETAR. Zapiszmy model progowy w postaci:

$$Y_t - \theta_0 - \theta_1 Y_{t-1} - \dots - \theta_p Y_{t-p} - I(Y_{t-d} \leq r) (\phi_0 + \phi_1 Y_{t-1} + \dots + \phi_q Y_{t-q}) = \varepsilon_t. \quad (4.41)$$

Hipoteza zerowa:

$$H_0: \phi_0 = \phi_1 = \dots = \phi_q = 0$$

określa, że model jest liniowy.

Przyjmijmy następujące oznaczenia:

$$Y = \begin{bmatrix} 1 & Y_{p-1} & \dots & Y_0 \\ 1 & Y_p & \dots & Y_1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & Y_{N-1} & \dots & Y_{N-p} \end{bmatrix}, \quad (4.42)$$

$$Y_r = \begin{bmatrix} I_r(Y_{p-d}) & Y_{p-1} I_r(Y_{p-d}) & \dots & Y_{p-q} I_r(Y_{p-d}) \\ \vdots & \vdots & \dots & \vdots \\ I_r(Y_{N-d}) & Y_{N-1} I_r(Y_{N-d}) & \dots & Y_{N-q} I_r(Y_{N-d}) \end{bmatrix}. \quad (4.43)$$

W macierzy Y_r wyrażenie $I(Y_{t-d} \leq r)$ zostało krótko oznaczone przez $I_r(Y_{t-d})$. Zdefiniujmy macierz P_w , zwaną macierzą projekcji:

$$P_w = W(W'W)^{-1}W', \quad (4.44)$$

przy czym W jest macierzą liniowo niezależnych wektorów kolumnowych.

Test oparty na zasadzie ilorazu wiarygodności jest następujący:

1. Szacujemy parametry równania liniowego:

$$Y_t - \theta_0 - \theta_1 Y_{t-1} - \dots - \theta_p Y_{t-p} = u_t \quad (4.45)$$

i obliczamy reszty u_t .

2. Szacujemy parametry równań, w których kolejne wektory kolumnowe macierzy Y_r są zmiennymi endogenicznymi, a Y jest macierzą zmiennych egzogenicznych, i wyznaczamy macierz reszt W_r .

3. Szacujemy równanie u_t w zależności od W_r . Macierz projekcji jest oznaczona jako $PW_w u$. Niech $Q(r)$ będzie normą euklidesową projekcji, tzn.

$$Q(r) = \|P_w u\|^2 = SSR_{AR} - SSR_{TAR(r)}, \quad (4.46)$$

gdzie:

SSR_{AR} — suma kwadratów reszt najlepszego modelu $AR(p)$,

$SSR_{TAR(r)}$ — odpowiednik powyższego dla najlepszego modelu TAR przy danym r ,

P_w — macierz idempotentna,

czyli relacja (4.46) przyjmuje postać:

$$Q(r) = \|P_w u\|^2 = u' P_w u. \quad (4.47)$$

4. Oznaczmy dalej $\hat{\sigma}^2 = \inf_{r \in R} SSR_{TAR(r)}/n$, gdzie $n = N - p + 1$ jest efektywną wielkością próby. Statystyka LR przyjmuje postać:

$$LR = \sup_{r \in R} Q(r)/\hat{\sigma}^2 \quad (4.48)$$

i jest zbieżna asymptotycznie do rozkładu χ^2 z $(q+1)$ stopniami swobody.

4.5. Estymacja i prognozowanie na podstawie modeli progowych

4.5.1. Estymacja modeli nieliniowych TAR

Estymacja modeli progowych odbywa się za pomocą warunkowej MNK lub MNW. Idea estymacji za pomocą pierwszej z wymienionych metod zostanie przedstawiona na podstawie prostego modelu dwureżimowego z jednym parametrem progowym postaci (por. Witkowski [1999]):

$$X_t = \begin{cases} a_0^1 + a_1^1 X_{t-1} + \dots + a_{k_1}^1 X_{t-k_1} + h_1 \varepsilon_t, & \text{dla } X_{t-d} < r, \\ a_0^2 + a_1^2 X_{t-1} + \dots + a_{k_2}^2 X_{t-k_2} + h_2 \varepsilon_t, & \text{dla } X_{t-d} \geq r. \end{cases} \quad (4.49)$$

Uproszczenie to nie zmienia ogólności rozważań. Estymacja parametrów odbywa się w kilku krokach:

1. Estymacja parametrów przy zmiennych opóźnionych i ustalonych wartościach parametrów d, r, k_1, k_2 . Przyjmijmy następujące oznaczenia:

$$\bar{\mathbf{a}}_i = [a_0^i, a_1^i, \dots, a_{k_i}^i], \quad i = 1, 2, \quad (4.50)$$

$$k = \max(k_1, k_2, d). \quad (4.51)$$

Z wektora $[x_{k+1} \dots x_N]$ utwórzmy dwa wektory $\bar{\mathbf{x}}_1, \bar{\mathbf{x}}_2$ w następujący sposób:

$$x_j \in \bar{\mathbf{x}}_1 \Leftrightarrow x_{j-d} < r, \quad (4.52)$$

$$x_j \in \bar{\mathbf{x}}_2 \Leftrightarrow x_{j-d} \geq r. \quad (4.52a)$$

Niech:

$$\bar{\mathbf{x}}_1 = [x_{j_1}^1, x_{j_2}^1, \dots, x_{j_{n_1}}^1], \quad \bar{\mathbf{x}}_2 = [x_{j_1}^2, x_{j_2}^2, \dots, x_{j_{n_2}}^2], \quad (4.53)$$

$$n_1 + n_2 = N - k$$

oraz:

$$\mathbf{A}_i = \begin{bmatrix} 1 & x_{j_1-1}^i & x_{j_1-2}^i & \dots & x_{j_1-k_i}^i \\ 1 & x_{j_2-1}^i & x_{j_2-2}^i & \dots & x_{j_2-k_i}^i \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{j_{n_i}-1}^i & x_{j_{n_i}-2}^i & \dots & x_{j_{n_i}-k_i}^i \end{bmatrix}, \quad i = 1, 2. \quad (4.54)$$

Szukany estymator wektora parametrów przedstawia się następująco:

$$\bar{\mathbf{a}}_i = (\mathbf{A}_i' \mathbf{A}_i)^{-1} \mathbf{A}_i' \bar{\mathbf{x}}_i, \quad i = 1, 2. \quad (4.55)$$

2. Estymacja wszystkich parametrów modelu. Niech parametry opóźnienia oraz progowy przyjmą wartości startowe d_0, r_0 . Przyjmijmy także maksymalny, dopuszczalny³ rząd autoregresji L . Oznaczmy:

$$AIC(d_0, r_0) = AIC(\hat{k}_1) + AIC(\hat{k}_2), \quad (4.56)$$

przy czym:

$$AIC(\hat{k}_1) = \min_{0 \leq k_1 \leq L} [n_1 \ln \{\|\varepsilon_1\|^2 / n_1\} + 2(k_1 + 1)], \quad (4.57)$$

$$AIC(\hat{k}_2) = \min_{0 \leq k_2 \leq L} [n_2 \ln \{\|\varepsilon_2\|^2 / n_2\} + 2(k_2 + 1)],$$

$$\bar{\varepsilon}_i = \bar{\mathbf{x}}_i - \mathbf{A}_i \bar{\mathbf{a}}_i, \quad i = 1, 2. \quad (4.58)$$

³ Wybór L jest subiektywny; zależy głównie od wielkości próby. Autorzy proponują $L = N^\alpha$, dla $\alpha < 0,5$.

A więc na podstawie konkretnych wartości d_0, r_0 znajdujemy rzędy autoregresji w poszczególnych reżimach, minimalizując wyrażenia (4.57) i (4.58) (wektory $\bar{\mathbf{a}}_i$ otrzymujemy z (4.55)). Następnie obliczamy wartość kryterium Akaike'a zgodnie z (4.56). Ostatecznie wyboru parametrów d i r dokonujemy następująco:

$$AIC(\hat{d}, \hat{r}) = \min_{d \in \{1, 2, \dots, T\}} \{ \min_{r \in \{\tau_1, \tau_2, \dots, \tau_m\}} AIC(d, r) \}, \quad (4.59)$$

gdzie T oznacza maksymalną, dopuszczalną wartość parametru opóźnienia d , a $\{\tau_1, \tau_2, \dots, \tau_m\}$ jest zbiorem potencjalnych „kandydatów” na parametr progowy.

4.5.2. Prognozowanie na podstawie modeli progowych

Wyróżnia się w zasadzie trzy metody prognozowania na podstawie modeli progowych. Dwie spośród nich są bardziej skomplikowane, gdyż wymagają wielokrotnego losowania informacji o przyszłych stanach. Są to metody: bootstrap i Monte Carlo (por. Osińska, Witkowski [2003] oraz Jeziorska-Papka, Osińska i Witkowski [2004]).

Metoda średniego błędu prognozy jest metodą najprostszą. Pozwala na wyznaczenie prognozy dla dowolnego modelu SETAR. W przypadku modelu opisanego równaniem (4.49) prognoza może być praktycznie ustalona jako średnia ważona z prognoz obliczonych oddzielnie dla reżimów pierwszego i drugiego. Wagami są wówczas prawdopodobieństwa tego, że w momencie wyznaczenia prognozy proces będzie w pierwszym bądź drugim reżimie. A więc:

$$\hat{Y}_{n+k} = p_{k-1} \hat{Y}_{1,n+k} + (1 - p_{k-1}) \hat{Y}_{2,n+k} + (a_{2,1} - a_{1,1}) \hat{\sigma}_{n+k-1} \Phi \left(\frac{r - \hat{Y}_{n+k-1}}{\hat{\sigma}_{n+k-1}} \right), \quad (4.60)$$

$$k = 2, 3, \dots,$$

gdzie:

$$p_{k-1} = \Phi \left(\frac{r - \hat{Y}_{n+k-1}}{\hat{\sigma}_{n+k-1}} \right).$$

W powyższych wzorach Φ oraz ϕ oznaczają odpowiednio dystrybuantę i funkcję gęstości standardowego rozkładu normalnego $N(0, 1)$. Wzór (4.60) jest wzorem rekurencyjnym, w którym krok pierwszy wygląda następująco:

$$\hat{Y}_{n+1} = a_0 + a_1 Y_n + (b_0 + b_1 Y_n) I_n(r).$$

Zastosowanie wzoru (4.60) wymaga oszacowania błędu standardowego predykcji $\hat{\sigma}_{n+k-1}$:

$$\begin{aligned}\hat{\sigma}_{n+k}^2 = & \{(a_{1,0} + a_{1,1} \hat{Y}_{n+k-1})^2 + a_{1,1}^2 \hat{\sigma}_{n+k-1}^2\} p_{k-1} + \\ & + \{(a_{2,0} + a_{2,1} \hat{Y}_{n+k-1})^2 + a_{2,1}^2 \hat{\sigma}_{n+k-1}^2\} (1 - p_{k-1}) + \\ & + \{a_{2,1}^2 (r - \hat{Y}_{n+k-1}) + 2a_{2,1} (a_{2,0} + a_{2,1} \hat{Y}_{n+k-1}) - [a_{1,1}^2 (r - \hat{Y}_{n+k-1}) + 2a_{1,1} (a_{1,0} + a_{1,1} \hat{Y}_{n+k-1})]\} \times \\ & \times \hat{\sigma}_{n+k-1} p_{k-1} + \sigma_v^2 - \hat{Y}_{n+k}^2.\end{aligned}$$

Powyższa formuła jest możliwa do zastosowania, jeśli wariancje składników losowych w poszczególnych reżimach są sobie równe i wynoszą σ_v^2 .

Zastosowanie modeli TAR do opisu finansowych szeregów czasowych

Asymetria rozkładów stóp zwrotu z inwestycji w akcje powoduje, że badacze skupiają uwagę na wykorzystaniu nieliniowych modeli progowych. Ich cechami charakterystycznymi są bowiem dekompozycja całego systemu stochastycznego na mniejsze podsystemy i analiza tego systemu w podsystemach. Można powiedzieć, że modele progowe to liniowe modele zagnieżdżone w strukturze nieliniowej, przy czym przejście z jednego podsystemu do drugiego odbywa się w sposób skokowy. Obecnie wykorzystuje się je szeroko, wraz z ich uogólnieniami — modelami wygładzonej regresji — do opisu asymetrycznych zachowań wielu zjawisk ekonomicznych, w tym zwłaszcza cykli koniunkturalnych (Teräsvirta, Anderson [1993], Proietti [1998]) oraz innych kategorii makroekonomicznych, np. bezrobocia (Hansen [1997]). Dobrym przykładem ich zastosowania w modelowaniu stóp zwrotu jest praca Cao, Tsay [1993].

Przykład 4.2

Prezentowany model dotyczy zwykłych tygodniowych stóp zwrotu z indeksu giełdowego WIG obserwowanych w okresie 2.01.1995–2.04.2003. Jako zmienna progowa została zastosowana opóźniona zmienna objaśniana (model SETAR). Najlepszy okazał się model 3-reżimowy, w którym podział wartości w reżimach najbardziej odpowiadał asymetrii rozkładów badanych stóp zwrotu. Reszty były obciążone efektem ARCH i dodatkowo opisane równaniem GARCH. Przyjęto, że wariancja warunkowa nie zmienia się w reżimach.

W przypadku modelu SETAR dla stóp zwrotu z indeksu WIG zmienna progowa była opóźniona o 3 okresy (3 tygodnie). W tabelicy 4.2 został przedstawiony model zredukowany do przypadku, w którym ostatnie opóźnienie było istotne statystycznie. Model ten pozwolił na redukcję stopnia asymetrii oraz kurtozy rozkładu stóp zwrotu. Jego przewaga nad modelem liniowym AR(2) została także potwierdzona niższą wartością kryterium informacyjnego Akaike'a. Poszczególnym reżimom odpowiadały różne liczby obserwacji, odpowiednio: 106, 284 i 35. Na rysunku 4.3 przedstawiono identyfikację reżimów przez model SETAR (dla przejrzystości podano jedynie wyniki dla pierwszych 100 obserwacji).


Tabela 4.2. Wyniki estymacji 3-reżimowego modelu SETAR dla indeksu WIG

	Reżim I		Reżim II		Reżim III	
	oceny parametrów	t-Student	oceny parametrów	t-Student	oceny parametrów	t-Student
Stała	0,0087	1,36	0,0016	0,35	-0,0102	1,07
Y_{t-1}	-0,0078	0,07	0,1357	2,38	-0,0328	0,23
Y_{t-2}	0,0814	0,62			0,2874	2,14
Y_{t-3}	0,2076	1,71				
R	-0,0075726				0,0214855	
N	106		284		35	
Błąd standardowy reszt w reżimach	0,232		0,348		0,038	
Błąd standardowy reszt ogólny			0,618			
Model*	$h_t = 0,518\varepsilon_{t-1}^2 + 0,481\varepsilon_{t-2}^2 + 0,351h_{t-1} + 0,625h_{t-2}$					
	(2,32)		(2,13)		(1,92) (3,00)	
GARCH (2,2)	SE = 0,0000					

* W nawiasach podano statystyki t-Studenta.

Źródło: Osińska, Witkowski [2003].

Rysunek 4.3. Identyfikacja reżimów przez model SETAR
Stopy zmian WIG w reżimach



Źródło: Opracowanie własne na podstawie Osińska, Witkowski [2003].

Analizując własności modeli progowych, należy stwierdzić, że stanowią one ważną alternatywę dla modeli liniowych. Ich stosowanie jest celowe w przypadkach, gdy rozkłady badanych procesów nie są zbliżone do rozkładu normalnego, a zwłaszcza gdy są to rozkłady wyraźnie niesymetryczne. Oddzielenie obserwacji typowych od nietypowych pozwala na odpowiednie wnioskowanie o historii oraz projekcję przyszłości. W przypadku danych giełdowych, gdzie wnioskowanie jest szczególnie trudne, właściwa identyfikacja wrażliwości stóp zwrotu poniżej/powyżej pewnych wartości granicznych informuje o tendencjach zachowań inwestorów.

Pytania i problemy

1. Jakie cechy empirycznych szeregów czasowych przemawiają za wykorzystaniem modeli nieliniowych?
2. Porównaj hipotezę rynku efektywnego z hipotezą rynku fraktalnego.
3. Scharakteryzuj nieliniowe modele AR.
4. Na przykładzie NLAR(1) wyjaśnij problem stacjonarności i stabilności modeli nieliniowych.
5. Zapisz po dwa przykłady modeli diagonalnych, naddiagonalnych i poddiagonalnych. Wygeneruj odpowiednie szeregi i sprawdź ich własności w zakresie średniej, wariancji, skośności i kurtozy. Oceń otrzymane wyniki.
6. Jakie są cechy chaosu deterministycznego i czym różnią się od modeli stochastycznych?
7. Losowość czy determinizm w analizach rynków finansowych? Przedstaw własną opinię, popartą przykładami.
8. Jakie są kryteria doboru funkcji nieliniowej?
9. Miary oceny jakości modeli nieliniowych.
10. Porównaj mechanizm przełącznikowy w modelach STR, TAR i *Markov Switching*.
11. Zapisz przykłady modeli SETAR i TAR dwureżimowych, z parametrem $d = 3$.
12. Rodzaje testów na nieliniowość.
13. Jaka jest interpretacja wyników testu BDS?
14. Na czym polega estymacja modeli progowych?
15. Prognozowanie za pomocą modeli TAR.
16. Wykorzystanie modeli progowych w analizie asymetrycznych rozkładów stóp zwrotu.

Rozdział 5

Modele szeregów czasowych z losowymi parametrami i reprezentacja przestrzeni stanów

Słowa kluczowe: modele autoregresyjne z losowymi parametrami, stochastyczne pierwiastki jednostkowe, testowanie, estymacja, przestrzeń stanów, filtr Kalmana, modele GARCH i SV w zapisie przestrzeni stanów

Reprezentacja przestrzeni stanów jest użyteczną formą zapisu wielu modeli ekonometrycznych, w tym modeli szeregów czasowych. Wychodząc od definicji i zapisów dla modeli ze stałymi parametrami, przechodzimy do modeli z losowymi parametrami, które są głównym przedmiotem zainteresowania w tym rozdziale. W ekonometrii najczęściej używa się pojęcia: modele ze zmiennymi parametrami, które mieści w sobie również zmienność według funkcji deterministycznej. W niniejszym rozdziale rozważamy modele, których schemat zmienności jest losowy, stąd będziemy używać określenia: modele z losowymi parametrami. Modele liniowe z losowymi parametrami stanowią alternatywę dla nieliniowych modeli, których postać analityczna często jest trudna do ustalenia. Niektóre z modeli nieliniowych, a zwłaszcza modele przedziałami liniowe, można traktować jako modele z losowymi parametrami, których zmiana została opisana przez funkcję (np. modele STR) lub jest uzależniona od poprzedniego stanu (np. *Markov switching*), czy wreszcie zależy od wartości zmiennej progowej (np. modele TAR). Modele z losowymi parametrami służą do opisu zarówno warunkowej średniej, jak i warunkowej wariancji.

W niniejszym rozdziale zostaną omówione jednowymiarowe modele z losowymi parametrami, a także metody estymacji ich parametrów i testowanie. Użytecznym narzędziem zapisu omawianych modeli jest tzw. reprezentacja przestrzeni stanów. Do estymacji parametrów omawianych modeli będziemy używać filtru Kalmana.

5.1. Reprezentacja przestrzeni stanów

Modele stacjonarnych¹ szeregów czasowych mogą być zasadniczo zapisane w postaci trzech równoważnych reprezentacji, tzn.: reprezentacji ARMA w dziedzinie

¹ Należy zauważyć, iż warunek stacjonarności jest nałożony przez wymogi analizy spektralnej. W kontekście reprezentacji ARMA i przestrzeni stanów mamy stosowne rozszerzenia na procesy niestacjonarne, np. model ARIMA.

czasu, reprezentacji przestrzeni stanów oraz reprezentacji w dziedzinie częstości (por. Górka [2001]). Pierwsza z nich — w postaci jednowymiarowych modeli szeregów czasowych — została zaprezentowana w rozdziale 2. Trzecia — tzw. reprezentacja spektralna — będzie przedmiotem analizy w rozdziale 6. Obecnie zajmiemy się zapisem modeli jednowymiarowych szeregów czasowych w postaci przestrzeni stanów.

Dla jednowymiarowego stacjonarnego szeregu czasowego y_t model przestrzeni stanów (PS) składa się z dwóch następujących równań²:

$$y_t = Hx_t + w_t, \quad (5.1)$$

$$x_{t+1} = Fx_t + Gv_t, \quad (5.2)$$

gdzie:

x_t — n -wymiarowy wektor stanów,

y_t — m -wymiarowy wektor wyjścia (obserwacji),

F — macierz stanów o wymiarach $(n \times n)$, przedstawiająca powiązania między poszczególnymi zmiennymi stanu,

G — macierz zakłócenia o wymiarach $(n \times p)$, reprezentująca sposób przenoszenia zakłóceń na poszczególne elementy,

H — macierz wyjścia o wymiarach $(m \times n)$, która pokazuje, w jaki sposób zmienne stanu są transformowane na zmienne wyjścia,

w_t — m -wymiarowy wektor błędów pomiaru, $w_t \sim N(0, R)$,

v_t — p -wymiarowy wektor zakłóceń, $v_t \sim N(0, Q)$,

$E(w_t, v_s') = 0$ dla każdego t i s .

Postać przestrzeni stanów zawsze wymaga zapisu w postaci dwóch równań macierzowych, stąd też (5.1) jest równaniem obserwacji (lub wyjścia), natomiast równanie (5.2) nosi nazwę równania stanu. W przypadku modeli ekonometrycznych wektor obserwacji bywa niekiedy równy wektorowi stanów.

Definicja 5.1

Szereg czasowy y_t posiada reprezentację przestrzeni stanów, jeżeli istnieje model przestrzeni stanów szeregu y_t opisany równaniami (5.1)–(5.2).

Definicja 5.2

Model opisany równaniami (5.1)–(5.2) jest stabilny wtedy i tylko wtedy, gdy wartości własne macierzy F leżą wewnątrz koła jednostkowego.

Stabilność modelu PS (przestrzeni stanów) jest własnością gwarantującą stacjonarność procesu x_t , a w konsekwencji i y_t (por. Brockwell, Davis [1996])³.

² Model taki bywa nazywany strukturalnym (por. Brockwell, Davis [1996]).

³ W przypadku modeli PS definiuje się ponadto własności: obserwowalności i sterowalności; por. Górka [2001].

► Przykład 5.1

W celu ilustracji rozważmy jako przykład stacjonarny model AR(1) szeregu czasowego y_t postaci:

$$y_t - \alpha_1 y_{t-1} = \varepsilon_t,$$

gdzie $|\alpha_1| < 1$.

Zapis tego modelu w postaci przestrzeni stanów jest dany jako:

$$y_t = x_t,$$

$$x_t = \alpha_1 x_{t-1} + \varepsilon_t,$$

gdzie y_t jest obserwowanym szeregiem czasowym w czasie $t = 1, 2, \dots, T$, a x_t jest nieobserwowaną zmienną stanu zależną od stanu poprzedniego. Jest to jednocześnie przypadek, kiedy wektor obserwacji jest równy wektorowi stanów.

► Przykład 5.2

Rozważmy dalej stacjonarny model AR(2) postaci:

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \varepsilon_t.$$

Model PS dla procesu AR(2) dany jest wzorami:

$$y_t = x_{1t},$$

$$x_{1t} = \alpha_1 x_{1,t-1} + \alpha_2 x_{2,t-1} + \varepsilon_t,$$

$$x_{2t} = x_{1,t-1}.$$

Powyższy model można zapisać w notacji macierzowej w postaci:

$$y_t = [1 \ 0] x_t,$$

$$x_t = \begin{bmatrix} \alpha_1 & \alpha_2 \\ 1 & 0 \end{bmatrix} x_{t-1} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \varepsilon_t,$$

gdzie $x_t = [x_{1t} \ x_{2t}]'$.

Najważniejszą cechą tego zapisu jest zależność tylko od stanu poprzedniego, stąd konieczność wprowadzenia dodatkowej zmiennej stanu x_{2t} .

► Przykład 5.3

Nieco trudniejszy w zapisie PS jest model ARMA. Rozważmy model ARMA(1, 1), postaci:

$$y_t = \alpha_1 y_{t-1} + \varepsilon_t + \beta_1 \varepsilon_{t-1}.$$

Zauważmy, że:

$$y_t = \beta(B) x_t = [\beta_1 \ 1] \begin{bmatrix} x_{t-1} \\ x_t \end{bmatrix},$$

gdzie x_t jest opisane przez model AR(1) postaci:

$$\alpha(B) x_t = \varepsilon_t,$$

czyli:

$$\begin{bmatrix} x_{t-1} \\ x_t \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & \alpha_1 \end{bmatrix} \begin{bmatrix} x_{t-2} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} 0 \\ \varepsilon_t \end{bmatrix}.$$

Reprezentacja PS modelu ARMA(p, q). Rozważmy model ARMA(p, q) postaci:

$$\alpha(B) y_t = \beta(B) \varepsilon_t \quad (5.3)$$

i przyjmijmy, że $r = \max(p, q + 1)$, $\beta_0 = 1$.

Niech u_t będzie kauzalnym procesem AR(p):

$$\alpha(B) u_t = \varepsilon_t, \quad (5.4)$$

stąd:

$$y_t = \beta(B) u_t. \quad (5.5)$$

Zatem równanie obserwacji jest następujące:

$$y_t = [B_{r-1} \ \beta_{r-2} \ \dots \ \beta_0] x_t, \quad (5.6)$$

$$\text{gdzie } x_t = \begin{bmatrix} u_{t-r+1} \\ u_{t-r+2} \\ \vdots \\ u_t \end{bmatrix}.$$

Równanie stanu można zapisać jako:

$$x_{t+1} = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \\ \alpha_r & \alpha_{r-1} & \alpha_{r-2} & \dots & \alpha_1 \end{bmatrix} x_t + \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix} \varepsilon_{t+1}. \quad (5.7)$$

Układ równań (5.6)–(5.7) jest uniwersalnym zapisem postaci PS dla modelu ARMA. W analogiczny sposób można zapisać model ARIMA (por. Brockwell, Davis [1996]).

5.2 Modele autoregresyjne z losowymi parametrami

Podstawowa postać modelu autoregresyjnego rzędu p z losowymi parametrami jest następująca (por. Nicholls, Quinn [1982], Tong [1990]):

$$y_t = \sum_{i=1}^p [\alpha_{0i} + \alpha_{it}] y_{t-i} + \varepsilon_t, \quad (5.8)$$

gdzie:

- ε_t — białe szum o średniej zero i wariancji σ_ε^2 ,
- $\alpha_{0i} (i = 1, 2, \dots, p)$ — stałe,
- $\alpha_{it} (i = 1, 2, \dots, p; t = 1, 2, \dots, T)$ — ciąg niezależnych wektorów parametrów o średniej zero i stałej macierzy kowariancji, przy czym α_{it} są niezależne od ε_t .

Z zapisu (5.8) wynika, że jeśli wariancja σ_ε^2 jest mała w porównaniu z wartościami przyjmowanymi przez α_{0i} , to realizacje y_t będą raczej zbliżone do szeregów czasowych generowanych przez modele autoregresyjne ze stałymi parametrami. Gdy jednak niektóre α_{it} przyjmują wartości duże w porównaniu z α_{0i} , wówczas można się spodziewać wysokich wartości y_t w długim okresie realizacji. Efekt ten może zostać dodatkowo spotęgowany przez wysoką wariancję σ_ε^2 .

Przykładem realizacji tak zdefiniowanego modelu jest:

$$y_t = [-0,1 + \alpha_{1t}] y_{t-1} + \varepsilon_t, \quad (5.9)$$

gdzie: $\varepsilon_t \sim N(0, \sigma_\varepsilon)$; $\alpha_{1t} \sim N(0, \sigma_\alpha)$; α_{1t} i ε_t są wzajemnie niezależne.

Przykład realizacji procesu (5.9) przy wariancji $\sigma_\varepsilon^2 = 1$ i $\sigma_\alpha^2 = 0,9^2$ został pokazany na rysunku 5.1.

Wniosek 5.1

Uogólnieniem modelu (5.8) jest przypadek dopuszczający skorelowanie α_{it} i ε_t .

Inna postać modelu AR ze zmiennymi parametrami pozwala na uwzględnienie innego — niż białoszumowy — modelu zmienności parametrów.

1. Przyjmijmy, że model zmienności parametrów jest dany w postaci stacjonarnego modelu autoregresyjnego. Model autoregresyjny rzędu 1, o średniej zero, z losowym parametrem spełniającym model AR(1), ma postać:

$$y_t = \alpha_t y_{t-1} + \varepsilon_t, \quad (5.10)$$

$$\alpha_t = \delta + \alpha_{t-1} + \eta_t, \quad (5.11)$$

przy czym $\varepsilon_t \sim N(0, \sigma_\varepsilon)$ oraz $\eta_t \sim N(0, \sigma_\eta)$ i są one wzajemnie niezależne. Podstawiając w (5.10) kolejno za α_t wyrażenie (5.11), otrzymujemy relację, którą wyjaśnia nakładanie się szumu η_t w sposób multiplikatywny:

$$y_t = (\delta_1 \alpha_{t-1} + \eta_t) y_{t-1} + \varepsilon_t. \quad (5.12)$$

Model (5.10)–(5.11) cechuje się następującymi własnościami:

a) nieliniowością zbliżoną do modeli dwuliniowych (zwłaszcza jeżeli dopuścimy korelację między η_t i ε_t),

b) wysoką zmiennością generowanych szeregów, spowodowaną poprzez multiplikatywny efekt szumu,

c) stacjonarność modelu (5.11) zapewnia warunek $|\delta_1| < 1$, a stacjonarność procesu Y_t zależy natomiast od wariancji σ_η^2 i σ_ε^2 oraz parametru δ_1 . Wynika to z faktu, że wariancja α_{1t} jest dana jako:

$$D^2(\alpha_{1t}) = \frac{\sigma_\eta^2}{1 - \delta_1^2}$$

i istnieje⁴ przy założeniu, że $|\delta_1| < 1$. Odpowiednio, wariancja szeregu y_t wynosi:

$$D^2(y_t) = \frac{\sigma_\varepsilon^2}{1 - D^2(\alpha_{1t})},$$

przy czym $D^2(\alpha_{1t}) < 1$.

Model autoregresyjny rzędu 1 o średniej zero z losowym parametrem spełniającym model AR(p) ma postać:

$$y_t = \alpha_t y_{t-1} + \varepsilon_t, \quad (5.13)$$

$$\alpha_t = \delta_1 \alpha_{t-1} + \delta_2 \alpha_{t-2} + \dots + \delta_p \alpha_{t-p} + \eta_t, \quad (5.14)$$

przy czym $\varepsilon_t \sim N(0, \sigma_\varepsilon)$ oraz $\eta_t \sim N(0, \sigma_\eta)$ i są one wzajemnie niezależne.

Analogiczne modele można zapisać, uwzględniając różną od zera średnią procesów, za co odpowiadają parametry α_0 , δ_0 np.:

$$Y_t = \alpha_0 + \alpha_t Y_{t-1} + \varepsilon_t, \quad (5.15)$$

$$\alpha_t = \delta_0 + \delta_1 \alpha_{t-1} + \delta_2 \alpha_{t-2} + \dots + \delta_p \alpha_{t-p} + \eta_t. \quad (5.16)$$

Odpowiednie konsekwencje statystyczne wynikają z przyjęcia założenia, że $E(\varepsilon_t \eta_t) \neq 0$.

2. Model zmienności parametrów jest modelem błędzenia przypadkowego. Prowadzi to do modelu postaci:

$$y_t = \alpha_t y_{t-1} + \varepsilon_t, \quad (5.17)$$

$$\alpha_t = \alpha_{t-1} + \eta_t, \quad (5.18)$$

⁴ W skończonej próbie wariancję można obliczyć zawsze, rozpatrując natomiast proces jako odpowiednik populacji generalnej musimy pamiętać, że w sensie ogólnym może nie być możliwe wyprowadzenie analitycznej wzoru na wariancję, która będzie skończona w każdej sytuacji. Przykładem takiego modelu jest błędzenie przypadkowe, gdzie przy $t \rightarrow \infty$ wariancja jest nieskończona (por. rozdział 2).

przy czym:

$$\begin{bmatrix} \varepsilon_t \\ \eta_t \end{bmatrix} \sim N \left\{ \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma_\varepsilon^2 & 0 \\ 0 & \sigma_\eta^2 \end{bmatrix} \right\}.$$


Stosowanie błędzenia przypadkowego jako modelu zmienności parametrów odnosi się do znanego w literaturze problemu uogólnionego trendu stochastycznego (por. Cuthbertson, Hall, Taylor [1992], Maddala, Kim [2002]). Model (5.18) nie jest stacjonarny w sensie wariancji, podczas gdy stacjonarność procesu y_t zależy od podobnych czynników jak w przypadku modelu (5.11). Zagadnienie to będzie przedmiotem szczegółowej analizy w podrozdziale o stochastycznych pierwiastkach jednostkowych.

3. Zmienność parametrów jest związana z obserwowalną zmienną losową. Mamy wtedy do czynienia z klasą modeli podwójnie stochastycznych. Ogólna postać dla modelu AR(p) jest następująca:

$$y_t = \alpha_0(z_{t-1}) + \sum_{i=1}^p \alpha_i(z_{t-1}) y_{t-i} + \varepsilon_t, \quad (5.19)$$

przy czym parametry $\alpha_0(z_{t-1})$ oraz $\alpha_i(z_{t-1})$ tworzą procesy stochastyczne. Model (5.19) obejmuje dość szeroką klasę modeli, która po nałożeniu restrykcji na parametry pozwala na pewne uszczegółowienia. Przyjmując na przykład, że α_0 i α_i są stałe, otrzymujemy model AR(p), przyjmując natomiast, że $\alpha_j(z_{t-1}) = \alpha_j(I < r)$ dla $j = 0, 1, 2, \dots, p$, definiujemy model progowy TAR.

Rysunek 5.1. Przykładowe realizacje procesów RCAR



Na wykresie z lewej strony przyjęto $\alpha_t \sim N(0; 0.9)$, natomiast na wykresie z prawej $\eta_t \sim N(0; 0.1)$; $\varepsilon_t \sim N(0, 1)$ w obu przypadkach.

Źródło: Opracowanie własne.

Reprezentacja przestrzeni stanów jest najbardziej naturalnym zapisem modeli z losowymi parametrami. Modele (5.1)–(5.2) przyjmują wtedy postać:

$$y_t = H_t x_t + w_t, \quad (5.20)$$

$$x_{t+1} = F_t x_t + G_t v_t, \quad (5.21)$$

przy czym $w_t \sim N(0, R)$, $v_t \sim N(0, Q)$, $E(w_t v_t') = 0$ dla każdego t i s .

Odpowiednie macierze parametrów z indeksem t oznaczają, że parametry modelu zmieniają się w czasie. Nie wszystkie macierze parametrów muszą zmieniać się w czasie. Na przykład dla modelu RCAR (5.13)–(5.14) zapis jest następujący:

$$y_t = \mathbf{H}_t \mathbf{x}_t + w_t, \quad (5.22)$$

$$\mathbf{x}_{t+1} = \mathbf{F} \mathbf{x}_t + \mathbf{G} v_t, \quad (5.23)$$

gdzie:

$$\mathbf{x}_t = \begin{bmatrix} \alpha_{t-p+1} \\ \alpha_{t-p+2} \\ \vdots \\ \alpha_t \end{bmatrix}, \quad \mathbf{F} = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \\ \delta_p & \delta_{p-1} & \delta_{p-2} & \dots & \delta_1 \end{bmatrix}, \quad \mathbf{G} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}, \quad \mathbf{H}_t = [0 \ 0 \ \dots \ y_{t-1}].$$

5.3. Filtr Kalmana jako narzędzie estymacji parametrów modeli przestrzeni stanów

Niech przedmiotem rozważań będzie model PS postaci (5.20)–(5.21). Estymacja jego parametrów jest rozumiana jako znalezienie najlepszego, w sensie błędu średniokwadratowego, wektora ocen zmiennych stanu $\mathbf{x}_t$, przy danym wektorze obserwacji y_t oraz założeniu niezależności w_t i v_t . Wykorzystanie filtru Kalmana odbywa się na ogół w trzech formach: predykcja, filtracja oraz wygładzanie. Wszystkie pojęcia oznaczają estymację $\mathbf{x}_t$ na podstawie różnych zbiorów obserwacji. Predykcja wymaga wykorzystania wektora $[y_0 \dots y_{t-1}]$. W procesie filtracji niezbędne są obserwacje $[y_0 \dots y_t]$, natomiast w przypadku wygładzania — obserwacje $[y_0 \dots y_n]$, gdzie $n > t$.

Rekursywność filtru Kalmana. Oznaczmy przez $\hat{\mathbf{x}}_{t-1}$ wektor stanu oszacowany na podstawie informacji dostępnych w chwili $t-1$ oraz przez $\mathbf{W}_{t-1}$ wariancję tego oszacowania:

$$\mathbf{W}_{t-1} = E[(\mathbf{x}_{t-1} - \hat{\mathbf{x}}_{t-1})(\mathbf{x}_{t-1} - \hat{\mathbf{x}}_{t-1})']. \quad (5.24)$$

Załóżmy, że szacujemy $\mathbf{x}_t$ na podstawie $\hat{\mathbf{x}}_{t-1}$. Korzystając z równania (5.21), prognozą $\mathbf{x}_t$ oznaczoną przez $\hat{\mathbf{x}}_t$ jest:

$$\hat{\mathbf{x}}_t = \mathbf{F}_{t-1} \hat{\mathbf{x}}_{t-1}, \quad (5.25)$$

przy czym wariancja błędu predykcji wynosi:

$$\mathbf{W}_t = E[(\mathbf{x}_t - \hat{\mathbf{x}}_t)(\mathbf{x}_t - \hat{\mathbf{x}}_t)'] = \mathbf{F}_{t-1} \mathbf{W}_{t-1} \mathbf{F}_{t-1}' + \mathbf{Q}. \quad (5.26)$$

Prognozę y_t przy danym $\hat{\mathbf{x}}_t$ uzyskuje się z równania (5.20):

$$\hat{y}_t = \mathbf{H}_t' \hat{\mathbf{x}}_t, \quad (5.27)$$

z błędem równym:

$$u_t = y_t - \hat{y}_t \quad (5.28)$$

i jego wariancją:

$$\mathbf{K}_t = E(u_t u_t') = \mathbf{H}_t' \mathbf{W}_t \mathbf{H}_t + R. \quad (5.29)$$

Filtr Kalmana oblicza zatem prognozę $\mathbf{x}_t$ w sposób rekurencyjny, przyjmując wartości początkowe dla $\mathbf{W}_0$ i $\mathbf{x}_0$. Więcej szczegółowych informacji na temat filtru Kalmana można znaleźć m.in. w pracach Hamiltona [1994], Brockwella i Davisa [1996], a także Durbina, Koopmana [2002].

Metoda największej wiarygodności. Filtr Kalmana jest podstawą wyznaczania parametrów w metodzie największej wiarygodności, która jest nazywana metodą quasi-największej wiarygodności (*quasi-maximum likelihood*). Metoda ta służy do estymacji parametrów wielu modeli omawianych w niniejszym podręczniku (m.in. modeli zmienności stochastycznej czy też modeli ze stochastycznym pierwiastkiem jednostkowym).

Jeżeli początkowy wektor stanu $\mathbf{x}_0$ oraz w_t i v_t mają wielowymiarowe rozkłady normalne, to warunkowy rozkład Y_t względem wcześniejszych obserwacji $y_{t-1} = [y_{t-1}' y_{t-2}' \dots y_0']'$ i nieznanymi wartościami parametrów θ znajdujących się w F , Q i R jest również rozkładem normalnym ze średnią i wariancją daną odpowiednio równaniami (5.27) i (5.29):

$$y_t | y_{t-1}, \theta \sim N(\mathbf{H}_t' \hat{\mathbf{x}}_{t-1}, \mathbf{H}_t' \mathbf{W}_t \mathbf{H}_t + R). \quad (5.30)$$

Oznaczając przez T liczbę obserwacji, logarytm funkcji wiarygodności dla obserwacji w chwili t można zapisać:

$$\ln L_t = -\frac{T}{2} \ln(2\pi) - \frac{1}{2} \ln |\mathbf{K}_t| - \frac{1}{2} u_t' \mathbf{K}_t^{-1} u_t, \quad \text{dla } t = 1, \dots, T. \quad (5.31)$$

5.4. Testowanie stabilności ocen parametrów

Testowanie stabilności ocen parametrów jest kluczowym zagadnieniem w analizach ekonometrycznych. Stabilność parametrów, nawet jeśli są one zmienne w czasie, pozwala na wnioskowanie co do przyszłych wartości modelowanych zjawisk. W przypadku braku stabilności ocen parametrów w próbie niemożliwe staje się nie tylko prognozowanie, ale także i jakiegokolwiek wnioskowanie w okresie objętym próbą.

Testowanie stabilności parametrów modelu RCAR postaci:

$$y_t = (\alpha_0 + \alpha_t) y_{t-1} + \varepsilon_t, \quad (5.32)$$

gdzie $\alpha_t \sim N(0, \sigma_\alpha)$

lub:

$$y_t = \alpha_t y_{t-1} + \varepsilon_t, \quad (5.33)$$

$$\alpha_t = \delta_t \alpha_{t-1} + \eta_t, \quad (5.34)$$

gdzie $\varepsilon_t \sim N(0, \sigma_\varepsilon)$ oraz $\eta_t \sim N(0, \sigma_\eta)$ i są one wzajemnie niezależne, polega na weryfikacji hipotezy, że wariancja modelu zmienności parametrów σ_η^2 jest równa zeru. Zakłada się w tym przypadku, że badane procesy są stacjonarne, tzn. $(\alpha_0^2 = \sigma_\eta^2) < 1$ w (5.32) i $\sigma_\eta^2 < 1$ w (5.33)–(5.34). Gdy model (5.33)–(5.34) rozszerzymy o stałą, wówczas warunek stacjonarności będzie taki sam jak dla (5.32).

Test zaproponowany przez Lee [1998] jest oparty na pracy McCabe'a, Tremayne'a [1995]. Dotyczy on modelu (5.32). Testowaniu podlegają następujące hipotezy:

$$H_0: \sigma_\eta^2 = 0, \quad (5.35)$$

$$H_1: \sigma_\eta^2 > 0. \quad (5.36)$$

Test Lee ma postać:

$$Z_T = \nu^{-1} T(T+2) \sum_{t=2}^T (y_t - \alpha_0 y_{t-1})^2 y_{t-1}^2 - \nu^{-2} T \sum_{t=2}^T y_{t-1}^2, \quad (5.37)$$

przy czym:

$$\nu^2 = \sum_{t=2}^T (y_t - \alpha_0 y_{t-1})^2 + y_1^2.$$

Statystyka $T^{-1/2} Z_T$ ma asymptotycznie rozkład normalny, zarówno przy założeniu niezerowych kowariancji między ε_t i η_t , jak i nawet przy założeniu, że ich rozkłady nie są normalne.

5.5. Procesy zawierające stochastyczne pierwiastki jednostkowe

5.5.1. Własności procesów zawierających pierwiastki jednostkowe

Procesy zawierające stochastyczne pierwiastki jednostkowe były po raz pierwszy rozważane w literaturze przedmiotu w połowie lat dziewięćdziesiątych (por. Leybourne, McCabe, Mills [1996], Leybourne, McCabe, Tremayne [1996], Granger, Swanson [1997]).

Model procesu typu STUR można zapisać w postaci ogólnej jako:

$$y_t = \alpha_t y_{t-1} + \varepsilon_t, \quad (5.38)$$

gdzie $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ oraz:

$$\alpha_t = \exp(\alpha_t), \quad (5.39)$$

gdzie α_t jest stacjonarnym procesem takim, że $\alpha_t \sim N(m, \sigma_\alpha^2)$, a jego spektrum⁵ jest równe $g_\alpha(\omega)$. Należy zauważyć, że tak określone ogólne własności dopuszczają istnienie procesów o charakterze wybuchowym, co jest mało prawdopodobne w ekonomii. Przyjęcie $m=0$ pozwala dokładnie zdefiniować proces y_t posiadający pierwiastek jednostkowy w średniej. Autorzy pierwszej pracy dotyczącej testowania stochastycznych pierwiastków jednostkowych (Leybourne, McCabe, Mills [1996]) proponują rozważenie następującego modelu autoregresyjnego ze zmiennymi parametrami:

$$y_t = \alpha_t y_{t-1} + \varepsilon_t, \quad (5.40)$$

gdzie:

$$\alpha_t = \alpha_0 + \delta_t,$$

$$\delta_0 = 0,$$


$$\delta_t = \rho \delta_{t-1} + \eta_t, \quad (5.41)$$

przy czym $\alpha_0 = 1$, a $|\rho| \leq 1$. Ponadto $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ i $\eta_t \sim N(0, \sigma_\eta^2)$ są od siebie niezależne.

Jeżeli $|\rho| < 1$, to α_t jest procesem stacjonarnym AR(1) o średniej równej jeden, natomiast w przypadku, gdy $\rho = 1$, jest to proces błędzenia losowego, podobnie jak ma to miejsce dla $\alpha_0 = 1$ i $\sigma_\eta^2 = 0$. Jeśli $\alpha_0 = 1$ i $\sigma_\eta^2 > 0$, to mamy do czynienia z procesem, którego średnia zawiera pierwiastek jednostkowy i który jest nazywany procesem ze stochastycznym pierwiastkiem jednostkowym.

Rysunek 5.2. Szeregi zawierające stochastyczny i dokładny pierwiastek jednostkowy

STUR a błędzenie przypadkowe



Źródło: Opracowanie własne.

⁵ Pojęcie spektrum zostanie wyjaśnione w rozdziale 6.

Interesujące jest oddziaływanie wartości sumy parametrów $\alpha_0 + \sigma_\eta^2$ na własności procesu i w konsekwencji na jego identyfikację. Jeśli jest ona większa od jedności, to proces jest niestacjonarny. Zatem przy $\alpha_0 < 1$ stacjonarność procesu jest uzależniona od wariancji σ_η^2 .

Na rysunku 5.2 zaprezentowano porównanie wybranych realizacji procesu ze stochastycznym oraz dokładnym pierwiastkiem jednostkowym (błądzenie przypadkowe). Wynika z niego, że proces ze stochastycznym pierwiastkiem jednostkowym cechuje się znacznie większą amplitudą zmian niż proces błądzenia przypadkowego.

5.5.2. Testowanie stochastycznych pierwiastków jednostkowych

Hipotezy w teście LMT (Leybourne, McCabe, Tremayne) dotyczą wariancji σ_η^2 , czyli modelu zmienności parametrów.

$H_0: \sigma_\eta^2 = 0$ (oznacza błądzenie przypadkowe lub w uogólnionym przypadku ARIMA($p, 1, 0$)).

$H_1: \sigma_\eta^2 > 0$ (interpretacja zależy od przyjętej wartości $|\rho| < 1$ lub $\rho = 1$).

Rozważa się przyjęcie różnych formuł testu zależnie od modelu będącego podstawą badania. W celu uniknięcia wpływu ewentualnego trendu deterministycznego, autorzy proponują rozszerzenie modelu o trend liniowy lub trend kwadratowy. Ponadto możliwe jest rozszerzenie specyfikacji równania poprzez włączenie do modelu opóźnionych wartości zmiennej endogenicznej.

Procedura testowania przebiega w kolejności opisanej poniżej. Niech:

$$y_t^* = \alpha_t y_{t-1}^* + \varepsilon_t, \quad (5.42)$$

gdzie:

$$y_t^* = y_t - P_t - \sum_{i=1}^p \varphi_i y_{t-i}, \quad (5.43)$$

przy czym P_t jest składnikiem deterministycznym, np. trendem postaci:

$$P_{1t} = \beta + \gamma t + \theta t(t+1)/2 \quad \text{lub} \quad P_{2t} = \beta + \gamma t,$$

natomiast część autoregresyjna w (5.43) jest stacjonarna i pełni rolę podobną jak rozszerzenie w teście ADF (*augmented Dickey Fuller*).

Jeżeli w H_1 $|\rho| < 1$, to statystykę Z oblicza się na podstawie następującej zależności oszacowanej KMNK:

$$\Delta y_t = \Delta P_t + \sum_{i=1}^p \varphi_i \Delta y_{t-i} + \varepsilon_t. \quad (5.44)$$

Statystyka Z ma postać:

$$Z = T^{-\frac{3}{2}} \sigma^{-2} \kappa^{-1} \sum_{t=1}^T \left(\sum_{j=1}^{t-1} \varepsilon_j \right)^2 (\varepsilon_t^2 - \sigma^2), \quad (5.45)$$

gdzie:

$$\sigma^2 = T^{-1} \sum_{t=1}^T \varepsilon_t^2 \quad \text{oraz} \quad \kappa^2 = T^{-1} \sum_{t=1}^T (\varepsilon_t^2 - \sigma^2)^2;$$

zależnie od wyboru postaci trendu P_{1t} lub P_{2t} oznacza się ją jako Z_1 lub Z_2 .

Dla $\rho = 1$ w H_1 proponuje się przyjęcie następującej statystyki E (por. Leybourne, McCabe, Mills [1996]):

$$E = T^{-3} \sigma^{-4} \sum_{t=1}^T \left\{ \left[\sum_{i=1}^T \varepsilon_i \left(\sum_{j=1}^{t-1} \varepsilon_j \right) \right]^2 - \sigma^2 \sum_{i=1}^T \left(\sum_{j=1}^{t-1} \varepsilon_j \right)^2 \right\} \quad (5.46)$$

i podobnie jak w poprzednim wypadku, zależnie od przyjętej funkcji trendu, powyższą statystykę oznacza się przez E_1 lub E_2 .

Omawiane testy są odporne na transformację logarytmiczną oraz efekt ARCH, z wyjątkiem IGARCH (por. Granger, Swanson [1997]). Wartości krytyczne generowane przy założeniu zerowej kowariancji między ε_t i ε_s dla wybranych poziomów istotności oraz liczebności próby zostały przedstawione w tablicy 5.1.

Tablica 5.1. Wybrane wartości krytyczne testów Z i E

N	Z			E_1			E_2		
	$\rho = 0,01$	$\rho = 0,05$	$\rho = 0,10$	$\rho = 0,01$	$\rho = 0,05$	$\rho = 0,10$	$\rho = 0,01$	$\rho = 0,05$	$\rho = 0,10$
50	0,349	0,215	0,161	0,078	0,063	0,054	0,090	0,077	0,070
100	0,320	0,192	0,142	0,072	0,060	0,052	0,081	0,072	0,067
200*	0,289	0,168	0,122	0,069	0,059	0,051	0,077	0,069	0,065
500	0,278	0,161	0,114	0,067	0,058	0,051	0,074	0,068	0,064
1000	0,261	0,149	0,104	0,067	0,057	0,050	0,073	0,068	0,064

* Dla statystyki Z $N = 250$.

Źródło: Leybourne, McCabe, Tremayne [1996], Leybourne, McCabe, Mills [1996], Granger, Swanson [1997].

Taylor i van Dijk [1999] przeprowadzili eksperyment Monte Carlo, badając między innymi wrażliwość testów Z i E ze względu na różne procesy generujące szeregi czasowe. Z ich raportu wynika, że jeżeli proces generujący dane jest w istocie procesem typu STUR, to test Z zachowuje swoją założoną moc. Jednakże odsetek odrzuceń hipotezy zerowej jest także znaczny w przypadku innych procesów (np. błądzenia przypadkowego ze zmianą wariancji czy też trendowo-stacjonarnego), co ogranicza zastosowanie testu do rzeczywistych ekonomicznych szeregów czasowych. Moc testu E została oceniona przez autorów znacznie wyżej aniżeli testu Z .

Zastosowania empiryczne modeli ze stochastycznym pierwiastkiem jednostkowym

Zastosowania empiryczne modeli STUR do opisu finansowych szeregów czasowych wydają się naturalne. Można wykazać, że gdy rozważamy ceny instrumentów finansowych lub wartości indeksów, wówczas oczekiwana stopa zwrotu jest równa:

$$E(r_t) = \frac{E(p_t) - p_{t-1}}{p_{t-1}},$$

gdzie:

p_t — cena papieru wartościowego,

r_t — stopa zwrotu;

tak więc oczekiwana cena wynosi:

$$E(p_t) = [1 + E(r_t)] p_{t-1}.$$

Oznaczając $\varepsilon_t = p_t - E(p_t)$ i $\delta_t = E(r_t)$, definiujemy model STUR(1) postaci (5.40)–(5.41). Jeżeli ε_t jest białym szumem, to poziomy cen zawierają stochastyczny pierwiastek jednostkowy.

Przykład 5.4

Należy zwrócić uwagę, że stosowanie modeli typu STUR do opisu finansowych szeregów czasowych modyfikuje hipotezę o efektywności rynku, zbliżając ją do hipotezy rynku fraktalnego. Cechy takie, jak zależność od wcześniejszych informacji

i persystencja, zostały potwierdzone na rynkach finansowych już dawno. Sollis, Leybourne i Newbold [2000] badali oraz szacowali modele STUR dla wybranych indeksów giełdowych. W czterech przypadkach na sześć została przyjęta hipoteza o stochastycznym pierwiastku jednostkowym.

W prezentowanym przykładzie posłużono się danymi dziennymi dotyczącymi różnych szeregów finansowych. Badaniu zostały poddane indeksy giełdowe WIG, DJIA, FTSE 100 oraz Nikkei. Ponadto testowano obecność STUR w szeregach czasowych dotyczących wybranych stóp procentowych na rynku międzybankowym WIBOR, a także kursów walutowych EURO/PLN i USD/PLN.


Wartości empiryczne testów Z oraz E przy określonej liczbie próby N przedstawia tablica 5.2.

Jak wynika z rezultatów zaprezentowanych w tablicy 5.2, stochastyczne pierwiastki jednostkowe zostały potwierdzone empirycznie tylko w trzech przypadkach: indeksu WIG, krótkookresowej stopy procentowej WIBOR T/N oraz kursu dolara amerykańskiego.

Przykład 5.5

Kwiatkowski i Osińska [2003] poddali analizie tygodniowy kurs indeksu WIG20 od lipca 1994 r. do końca marca 2002 r. w zakresie testowania i estymacji procesów ze stochastycznym pierwiastkiem jednostkowym. Analizowany szereg składał się z 380 obserwacji tygodniowych. Wartość statystyki Z dla tego szeregu wyniosła 0,219, co przy 5% poziomie istotności może wskazywać, że jest to proces, którego średnia zawiera pierwiastek jednostkowy. Wyniki ocen parametrów uzyskane za pomocą przedstawionej wcześniej metody największej wiarygodności dały następujące punktowe oceny parametrów: $\rho = -0,08794$; $\omega^2 = 1,51464E-06$; $\sigma^2 = 2,13929$. Rysunek 5.3 przedstawia punktową ocenę parametru $\alpha_t = 1 + \delta_t$, którą uzyskano za pomocą filtru Kalmana. Otrzymane wyniki są zbieżne z ocenami publikowanymi w pracy Sollis, Leybourne, Newbold [2000] dla danych giełdowych.

Rysunek 5.3. Ocena parametru alfa uzyskana MNW



Źródło: Kwiatkowski, Osińska [2003]

Tablica 5.2. Empiryczne wartości testów Z i E dla badanych szeregów finansowych

N_t	N	Z	E
WIG	200	-4,2 E-09	0,1958**
DJIA	200	-2 E-07	0,048
FTSE 100	200	5,7 E-07	-0,002
Nikkei	200	-3,8 E-10	-0,029
WIBOR 1R	500	-0,005	-0,010
WIBOR 3M	500	-0,005	-0,014
WIBOR T/N	1000	-0,119*	-0,019
EURO/PLN	1000	-96,83	0,013
USD/PLN	1000	5,55**	-0,027

* Istotne na poziomie 0,1.

** Istotne na poziomie 0,01.

Źródło: Opracowanie własne.

5.6. Wybrane modele zmienności w zapisie przestrzeni stanów

W rozpatrywanych modelach przestrzeni stanów, tzn. (5.1)–(5.2) oraz (5.20)–(5.21), zakładaliśmy stałą wariancję składnika losowego w równaniu obserwacji: $w_t \sim N(0, R)$. Jednakże w postaci przestrzeni stanów możemy zapisywać także modele zmienności, które były rozpatrywane w rozdziale 3. Rozpatrzmy dwa spośród nich: model stochastycznej zmienności oraz model GARCH.

Zapiszmy model PS w formie:

$$y_t = H_t x_t + w_t, \quad (5.47)$$

$$x_{t+1} = F_t x_t + G_t v_t, \quad (5.48)$$

przy czym $w_t \sim N(0, R_t)$, $v_t \sim N(0, Q_t)$, $E(w_t v_s') = 0$ dla każdego t i s . Zauważmy, że zmiana dotyczy tego, że wariancje R_t i Q_t mogą zmieniać się w czasie.

Model SV w postaci PS. Rozważmy podstawowy model zmienności stochastycznej (SV) postaci:

$$\varepsilon_t = \xi_t \sqrt{h_t}, \quad (5.49)$$

$$\ln h_t = \gamma + \phi \ln h_{t-1} + \sigma_h \eta_t, \quad (5.50)$$

gdzie $\xi_t \sim N(0, 1)$, $\eta_t \sim N(0, 1)$ oraz ξ_t i η_t są nieskorelowane.

Przyjmijmy dla uproszczenia, że stopy zwrotu z inwestycji w papiery wartościowe $r_t = \varepsilon_t$. Wówczas na mocy (5.49) i własności logarytmów mamy:

$$r_t = \exp\left(\frac{1}{2} \theta_t\right) \xi_t, \quad (5.51)$$

gdzie $\theta_t = \ln h_t$.

Ponieważ ξ_t jest gaussowskim białym szumem o stałej wariancji, r_t modelujemy za pomocą nieobserwowalnego logarytmu zmienności h_t danego równaniem (5.50). Stąd równanie obserwacji w postaci PS ma postać:

$$\theta_t = H_t x_t + w_t, \quad (5.52)$$

natomiast równanie stanów jest dane jako:

$$x_{t+1} = F_t x_t + G_t v_t. \quad (5.53)$$

Model GARCH(1, 1) w postaci PS. Zastosowanie postaci PS do modeli GARCH jest podobne jak w przypadku modeli zmienności stochastycznej (SV). Niech stopa zwrotu z inwestycji w papiery wartościowe będzie dana jako:

$$r_t = \xi \sqrt{h_t}, \quad (5.54)$$

gdzie $\xi_t \sim N(0, 1)$,

oraz niech model GARCH(1, 1) ma postać:

$$h_{t+1} = \alpha_1 r_t^2 + \beta_1 h_t. \quad (5.55)$$

Powyższy model można zapisać jako:

$$r_t = \xi_t \sqrt{h_t},$$

$$h_{t+1} = \phi h_t + \eta_t, \quad (5.56)$$

gdzie η_t może mieć dowolny niegaussowski rozkład oraz $\eta_t > 0$.

Zapiszmy model w postaci kwadratów:

$$r_t^2 = h_t + u_t, \quad (5.57)$$

gdzie:

$$u_t = h_t(\xi_t^2 - 1) \text{ i } E(u) = 0.$$

Filtr Kalmana pozwala na estymację zmiennej stanów $h_t = x_t$.

Pytania i problemy

1. Wyjaśnij, na czym polega zapis modelu w postaci przestrzeni stanów.
2. Na podstawie zapisów modeli omówionych w przykładach 5.1, 5.2 i 5.3 zapisz w postaci PS model AR(3).
3. Jakie nowe cechy wnoszą do modelowania modele autoregresyjne ze zmiennymi parametrami?
4. Wyjaśnij podobieństwo modelu RCAR(1) do modeli dwuliniowych.
5. Wyjaśnij sposób estymacji za pomocą filtru Kalmana; co jest wynikiem estymacji?
6. Wyjaśnij sposób testowania stabilności parametrów w modelu RCAR.
7. Jaka jest istota stochastycznych pierwiastków jednostkowych? Co odróżnia je od dokładnych pierwiastków jednostkowych?
8. Wyjaśnij zastosowanie modelu STUR, korzystając z definicji oczekiwanej stopy zwrotu i oczekiwanej ceny.
9. Na czym polega testowanie stochastycznych pierwiastków jednostkowych?
10. Na czym polega zapis w postaci PS i estymacja parametrów w modelu zmienności stochastycznej?
11. Na czym polega zapis w postaci PS i estymacja parametrów w modelu GARCH?

Analiza szeregów czasowych w dziedzinie częstości

Słowa kluczowe: częstotliwość, transformata Fouriera, funkcja gęstości spektralnej, periodogram, identyfikacja szeregów czasowych, dekompozycja falkowa

Materiał prezentowany w niniejszym rozdziale może być, bez utraty ogólności rozważań, pominięty przez Czytelników mniej zaawansowanych lub niezainteresowanych wnikaniem w częstościową, a więc harmoniczną strukturę szeregów czasowych. Niemniej jednak warto pamiętać, że omawiane metody analizy spektralnej już od dawna są obecne w literaturze ekonometrycznej (por. np. Zieliński [1979], Talaga, Zieliński [1986]). W dobie zaawansowanej techniki informatycznej wyznaczenie funkcji gęstości spektralnej czy periodogramu nie stanowi żadnego problemu. W rozdziale zostały pokazane, poza samymi narzędziami analizy spektralnej, ich praktyczne, użytkowe wartości, służące na przykład do identyfikacji szeregów częściowo zintegrowanych.

Cechą analizy spektralnej jest zwrócenie uwagi badacza na powtarzalność (cykliczność) pewnych zachowań procesów stochastycznych. W ekonomii szczególne zastosowanie znajduje ona w analizie sezonowości, która pojawia się w okresie rocznym, a także w analizie wahań koniunkturalnych. Dzięki transformacie Fouriera istnieje bezpośrednie przełożenie między dziedziną czasu a dziedziną częstości, stąd reprezentacja procesu stochastycznego, jeżeli jest on stacjonarny, w dziedzinie częstości jest równoważna reprezentacji w dziedzinie czasu (por. Górka [2001]). Z jednej strony, struktura harmoniczna procesów finansowych nie zawiera wyraźnie ustalonych cykli. Mówi się o efekcie stycznia czy też o efekcie dnia w tygodniu oraz godziny w dniu, ale nie zawsze znajdują one pełne potwierdzenie empiryczne. Z drugiej strony, istnieje teoria tzw. długiej pamięci, czyli wielookresowej autozależności procesów finansowych. Analiza spektralna z powodzeniem uzupełnia analizę w dziedzinie czasu, pozwalając te zależności identyfikować.

Analiza spektralna powinna być stosowana do procesów spełniających warunek stacjonarności. Powstaje zatem pytanie, jakie narzędzia mogą być użyte w przypadku niestacjonarności? Odpowiedź jest taka, że na ogół stosuje się wówczas transforma-

cje polegające na usunięciu tej niedogodności, na przykład poprzez oszacowanie trendu deterministycznego i odjęcie go od danych lub poprzez obliczenie różnic rzędu d (ta operacja także usuwa trend deterministyczny). Obecnie podejście to jest uważane za tradycyjne, bowiem najnowsze badania przynoszą inne narzędzia umożliwiające analizę szeregów niestacjonarnych w dziedzinie częstości. Jedną z grup stanowią narzędzia oparte na teorii ewoluujących spektrów, które są opisane w pracy Priestleya [1981]. Nie będą one omawiane w niniejszym rozdziale. Drugą grupę narzędzi dostarcza analiza falkowa, która pozwala na nieco inną dekompozycję szeregów czasowych. Wstępne informacje na temat tego rodzaju dekompozycji znajdzie Czytelnik w podrozdziale 6.4.

6.1. Podstawy analizy spektralnej szeregów czasowych

Wszyscy przyzwyczaili się już do falowej struktury sygnału radiowego czy dźwiękowego, natomiast falowa struktura fluktuacji cen na giełdzie papierów wartościowych czy giełdzie towarowej nie jest jeszcze intuicyjnie oczywista. Tymczasem przedstawienie szeregu czasowego w dziedzinie częstości pozwala analizować jego strukturę okresową. Jest to możliwe dzięki zastosowaniu złożenia wielu prostych funkcji trygonometrycznych, w postaci funkcji sinus i cosinus, nazywanych harmonikami. Omawiane metody analizy są możliwe do zastosowania w odniesieniu do procesów stacjonarnych, przynajmniej w szerszym sensie.

Podstawą analizy spektralnej jest przyjęcie, że każdą realizację stacjonarnego procesu stochastycznego w czasie dyskretnym można przedstawić jako:

$$y_t = \sum_{i=1}^{\infty} [a_i \cos(\omega_i t) + b_i \sin(\omega_i t)], \quad (6.1)$$

gdzie $a_1, b_1, a_2, b_2, \dots$ są stałymi, zaś $\omega = \frac{2\pi}{n}$ jest częstością związaną z okresem n .

Pojedyncza składowa harmoniczna ma postać:

$$a_i \cos(\omega_i t) + b_i \sin(\omega_i t) = A_i (\sin \omega_i t + \varphi_i), \quad (6.2)$$

przy czym: $A_i = \sqrt{a_i^2 + b_i^2}$ jest amplitudą wahań harmonicznnych (falowych), $\tan \varphi_i = \frac{a_i}{b_i}$, gdzie φ_i oznacza kąt fazowy danej składowej harmonicznej. Zarówno amplituda, jak i kąt fazowy są wielkościami stałymi.

Jeżeli szereg y_t jest stacjonarny, o funkcji autokowariancyjnej $K(\tau)$, spełniającej warunek bezwzględnej zbieżności, czyli $\sum_{\tau=-\infty}^{\infty} |K(\tau)| < \infty$, to dyskretna transformata Fouriera istnieje i wynosi:

$$f(\omega) = \frac{1}{2\pi} \sum_{\tau=-\infty}^{\infty} K(\tau) e^{-i\omega\tau} = \quad (6.3)$$

$$= \frac{1}{2\pi} \sum_{\tau=-\infty}^{\infty} K(\tau) \cos \omega\tau = \quad (6.4)$$

$$= \frac{1}{2\pi} K(0) + \frac{1}{\pi} \sum_{\tau=1}^{\infty} K(\tau) \cos \omega\tau, \quad -\pi \leq \omega \leq \pi, \quad (6.5)$$

przy czym $K(\tau) = K(-\tau)$.

Z kolei odwrotna transformata Fouriera ma postać:

$$K(\tau) = \int_{-\pi}^{\pi} f(\omega) e^{-i\omega\tau} d\omega. \quad (6.6)$$

Funkcja $f(\omega)$ nosi nazwę spektrum; ma ona następujące własności: jest ciągła i nieujemna, parzysta i okresowa o okresie 2π . Dla $\tau = 0$, na mocy (6.6) otrzymujemy:

$$K(0) = \int_{-\pi}^{\pi} f(\omega) d\omega = D^2(y). \quad (6.7)$$

Wzór (6.6) pozwala na następującą interpretację wariancji szeregu y . Otóż jest ona równa polu ograniczonemu krzywą $f(\omega)$ oraz osią ω w przedziale $[-\pi, \pi]$. Różniczka $f(\omega)d\omega$ określa udział częstości zawartych w przedziale $(\omega, \omega+d\omega)$ w ogólnej wariancji procesu, gdzie $d\omega$ jest dowolnie małym przyrostem częstości (por. Zieliński [1979], Talaga, Zieliński [1986], Stawicki [1993]).

Transformata Fouriera (6.3) i jej odwrotny odpowiednik (6.6) zapewniają równoważność reprezentacji szeregu czasowego w dziedzinie częstości oraz czasu (por. Górka [2001]). Niemniej jednak w praktyce proponuje się stosowanie zarówno jednej, jak i drugiej reprezentacji, albowiem jednostronne patrzanie na szereg czasowy powoduje utratę informacji. Analizując na przykład szereg w dziedzinie częstości, możemy wskazać jego okresowość, ale nie zawsze umiemy powiedzieć, w których jednostkach czasu ona wystąpi. Dotyczy to zwłaszcza szeregów przekształconych do stacjonarności.

Ogólna reprezentacja spektralna dowolnego (nie tylko bezwzględnie zbieżnego) ciągu autokowariancji $K(\tau)$ może zostać przedstawiona w postaci całki Fouriera-Stieltjesa:

$$K(\tau) = \int_{-\pi}^{\pi} e^{i\omega\tau} dF(\omega), \quad (6.8)$$

gdzie $F(\omega)$ jest *funkcją spektralną*. Funkcja spektralna jest interpretowana podobnie jak dystrybuenta rozkładu prawdopodobieństwa; jest ona funkcją rzeczywistą, nieujemną, ograniczoną i niemającą (por. Talaga, Zieliński [1986]).

Pomimo iż funkcja $F(\omega)$ jest nieujemna i niemająca, nie ma jednak wszystkich własności dystrybuenty rozkładu prawdopodobieństwa, gdyż $\int_{-\pi}^{\pi} dF(\omega) = K(0)$ nie zawsze jest równa 1. Można jednak zdefiniować taką funkcję $G(\omega)$, która będzie miała wszystkie własności funkcji rozkładu prawdopodobieństwa.

Przyjmijmy, że:

$$G(\omega) = \frac{F(\omega)}{K(0)}. \quad (6.9)$$

Wówczas $G(\omega) \geq 0$ oraz $\int_{-\pi}^{\pi} dG(\omega) = 1$. Jeżeli $dF(\omega) = f(\omega)d\omega$, to:

$$p(\omega)d\omega = dG(\omega) = \frac{f(\omega)}{K(0)} d\omega. \quad (6.10)$$

Korzystając z równań (6.3)–(6.6), otrzymuje się odpowiednie transformaty Fouriera:

$$p(\omega) = \frac{1}{2\pi} \sum_{\tau=-\infty}^{\infty} \rho_{\tau} e^{-i\omega\tau} = \quad (6.11)$$

$$= \frac{1}{2\pi} \sum_{\tau=-\infty}^{\infty} \rho_{\tau} \cos \omega\tau = \quad (6.12)$$

$$= \frac{1}{2\pi} + \frac{1}{\pi} \sum_{\tau=1}^{\infty} \rho_{\tau} \cos \omega\tau, \quad -\pi \leq \omega \leq \pi, \quad (6.13)$$

oraz:

$$\rho_{\tau} = \int_{-\pi}^{\pi} p(\omega) e^{i\omega\tau} d\omega, \quad (6.14)$$

gdzie ρ_{τ} jest współczynnikiem autokorelacji.

Funkcja $p(\omega)$ ma własności funkcji gęstości prawdopodobieństwa w przedziale $[-\pi, \pi]$ i nosi nazwę *funkcji gęstości spektralnej*. Między funkcją gęstości spektralnej i spektrum zachodzi związek:

$$p(\omega) = \frac{f(\omega)}{K(0)}.$$

Ponieważ wariancja $K(0)$ jest stała, spektrum często się utożsamia z funkcją gęstości spektralnej i odwrotnie¹.

¹ Dotychczasowe rozważania podlegają uogólnieniu na mocy twierdzenia Kolmogorowa-Cramera; por. np. Talaga, Zieliński [1986], Górka [2001].

Przykład 6.1

Rozważmy biały szum $\varepsilon_t \sim N(0, 1)$. Na mocy własności białego szumu $K(\tau) = 0$, dla wszystkich $\tau > 0$, $K(0) = \sigma^2$ oraz (6.5), funkcja gęstości spektralnej wynosi:

$$f(\omega) = \frac{1}{2\pi} K(0) + \frac{1}{\pi} \sum_{\tau=1}^{\infty} K(\tau) \cos \omega\tau = \frac{\sigma^2}{2\pi}.$$

Wypływa stąd wniosek, że funkcja gęstości spektralnej dla białego szumu jest stała i — odwrotnie — proces mający stałą funkcję gęstości spektralnej jest białym szumem.

6.1.1. Estymacja funkcji gęstości spektralnej

Periodogram. Niezgodnym estymatorem funkcji gęstości spektralnej jest periodogram. Informuje on o sile wahań o danym okresie (lub częstości) w szeregu. Niech będą dane: n obserwacji szeregu czasowego y_t oraz reprezentacja Fouriera tego szeregu postaci:

$$y_t = \sum_{i=1}^{n/2} (a_i \cos \omega_i t + b_i \sin \omega_i t), \quad (6.15)$$

gdzie $\omega_i = \frac{2\pi i}{n}$, $i = 0, 1, \dots, \frac{n}{2}$, przy czym a_i, b_i są odpowiednimi współczynnikami

Fouriera takimi, że:

$$a_i = \begin{cases} \frac{1}{n} \sum_{t=1}^n y_t \cos \omega_i t, & \text{dla } i=0 \text{ oraz } i=\frac{n}{2}, \text{ gdy } n \text{ jest parzyste,} \\ \frac{2}{n} \sum_{t=1}^n y_t \cos \omega_i t, & \text{dla } i=1, 2, \dots, \left(\frac{n-1}{2}\right), \end{cases} \quad (6.16)$$

$$b_i = \frac{2}{n} \sum_{t=1}^n y_t \sin \omega_i t, \quad \text{dla } i=1, 2, \dots, \left(\frac{n-1}{2}\right). \quad (6.17)$$

Definicja 6.1

Periodogramem szeregu $\{y_1, y_2, \dots, y_n\}$ przy częstości $\omega_i = \frac{2\pi i}{n}$, $i = 0, 1, \dots, \frac{n}{2}$, nazywamy funkcję:

$$I(\omega_i) = \frac{1}{n} \left| \sum_{t=1}^n y_t e^{-i\omega_i t} \right|^2. \quad (6.18)$$


Jeżeli ponadto $0 \leq \omega_i < \pi$, to wówczas wzór (6.18) przyjmuje postać:

$$I(\omega_i) = \frac{1}{n} \left| \sum_{t=1}^n y_t e^{-i\omega_i t} \right|^2 = \frac{n}{2} (a_i^2 + b_i^2), \quad (6.19)$$

gdzie a_i, b_i są współczynnikami Fouriera, zaś $i = 0, 1, \dots, \frac{n}{2}$.

Periodogram procesów liniowych cechuje się wysoką zmiennością — por. rysunek 6.1.

Rysunek 6.1. Periodogram dla białego szumu i szeregu AR(1)



Źródło: Opracowanie własne.

Estymator funkcji gęstości spektralnej. Naturalnym estymatorem spektrum (a zarazem i funkcji gęstości spektralnej) wyrażonego wzorem (6.3) jest:

$$\hat{f}(\omega) = \frac{1}{2\pi} \sum_{\tau=-(n-1)}^{n-1} \hat{K}(\tau) e^{-i\omega\tau} = \frac{1}{2\pi} \hat{K}(0) + \frac{1}{\pi} \sum_{\tau=1}^{n-1} \hat{K}(\tau) \cos \omega\tau, \quad (6.20)$$

gdzie: $\hat{K}(\tau)$ jest estymatorem funkcji autokowariancyjnej $K(\tau)$. Dla skończonej liczby n obserwacji szeregu czasowego można obliczyć $\hat{K}(\tau)$ tylko dla $k = 0, 1, 2, \dots, (n-1)$. Estymator dany wzorem (6.20) jest estymatorem asymptotycznie nieobciążonym, lecz niezgodnym.

Rozważmy $\hat{f}(\omega_i)$ przy $\omega_i = \frac{2\pi i}{n}$, $i = 0, 1, \dots, \frac{n}{2}$. Przy takich częstościach periodogram oraz gęstość spektralna pozostają w ścisłej relacji. Przekształcając wzór (6.19), otrzymujemy:

$$I(\omega_i) \frac{n}{2} (a_i^2 + b_i^2) = 2 \sum_{j=-(n-1)}^{n-1} \hat{K}(j) e^{-i\omega_i j} = 2 \left(\hat{K}(0) + 2 \sum_{j=1}^{n-1} \hat{K}(j) \cos \omega_i j \right), \quad (6.21)$$

a zatem można zapisać:

$$\bullet \text{ jeżeli } n \text{ jest nieparzyste, to } \hat{f}(\omega_i) = \frac{1}{4\pi} I(\omega_i), \quad i = 1, 2, \dots, \frac{n}{2}, \quad (6.22)$$

$$\bullet \text{ jeżeli } n \text{ jest parzyste, to } \hat{f}(\omega_{n/2}) = \frac{1}{2\pi} I(\omega_{n/2}). \quad (6.23)$$

6.1.2. Okno spektralne

Oszacowany periodogram wymaga wygładzenia, czyli zredukowania wariancji wokół konkretnych częstości ω_i . Jest to możliwe poprzez zastosowanie odpowiedniej funkcji wagowej. Estymator funkcji gęstości spektralnej jest otrzymywany dla średnich wag m wartości na lewo i prawo od częstości ω_i , tzn.:

$$\hat{f}_\lambda(\omega_i) = \sum_{j=-m_n}^{m_n} \lambda_M(\omega_j) \hat{f}(\omega_i - \omega_j), \quad (6.24)$$

gdzie $\omega_i = \frac{2\pi i}{n}$, dla $i = 0, \pm 1, \dots, \pm \frac{n}{4}$. Funkcja λ_M ma następujące własności:

$$\sum_{j=-m_n}^{m_n} \lambda_M(\omega_j) = 1, \quad (6.25)$$

$$\lim_{n \rightarrow \infty} \sum_{j=-m_n}^{m_n} \lambda_M^2(\omega_j) = 0.$$

Funkcja wagowa λ_M zwana jest *oknem spektralnym*. Wariancja funkcji opisanej wzorem (6.24) wynosi:

$$\text{var}[\hat{f}_\lambda(\omega_i)] \cong [f(\omega_i)]^2 \sum_{j=-m_n}^{m_n} \lambda_M^2(\omega_j). \quad (6.26)$$

Z własności okna spektralnego wynika, iż wariancja gęstości spektralnej maleje, gdy n rośnie. Wartość m_n oznacza liczbę częstości (szerokość pasma częstotliwości) użytych w wygładzaniu. Wartość ta ma bezpośredni związek z szerokością okna spektralnego. Gdy szerokość okna rośnie, wówczas otrzymany estymator jest bardziej stabilny (ma mniejszą wariancję).

Niezgodność estymatora $\hat{f}(\omega)$ można wyeliminować, wprowadzając do wzoru (6.20) funkcję wagową $\lambda_{M,j}$, gdzie stała M jest ustaloną liczbą opóźnień. Wówczas:

$$\hat{f}(\omega) = \frac{1}{2\pi} \sum_{j=-M}^M \lambda_{M,j} \hat{K}(\tau) e^{-i\omega k}. \quad (6.27)$$

Funkcja wagowa ma następujące własności:

$$|\lambda_{M,j}| \leq 1,$$

$$\lambda_{M,0} = 1,$$

$$\lambda_{M,-j} = \lambda_{M,j},$$

$$\lambda_{M,j} = 0, \quad |j| > M.$$

Wariancja estymatora gęstości spektralnej opisanego wzorem (6.27) wynosi:

$$\text{var}[\hat{f}(\omega)] \cong \frac{1}{n} f^2(\omega) \sum_{j=-M}^M \lambda_{M,j}^2. \quad (6.28)$$

Okno spektralne jest transformatą Fouriera funkcji wagowej $\lambda_{M,k}$:

$$\lambda_M(\omega) = \frac{1}{2\pi} \sum_{j=-M}^M \lambda_{M,j} e^{-i\omega k}. \quad (6.29)$$

Im więcej znamy punktów, dla których szacuje się gęstość spektralną, tym lepiej jest przedstawiona funkcja $f(\omega)$. Liczba M jest zależna od liczby obserwacji. Wynika z tego, że liczba obserwacji wykorzystywana w analizie spektralnej powinna być znaczna (powyżej 200). W przypadku finansowych szeregów czasowych nie stanowi to większego problemu. Na ogół liczba M stanowi od 10 do 30% długości szeregu.


W literaturze przedmiotu można spotkać różne okna spektralne. W niniejszej pracy podajemy dwa o najlepszych własnościach.

1. Okno Bartletta:

$$\lambda_M(\omega) = \frac{1}{2\pi M} \left[\frac{\sin(\omega M/2)}{\sin(\omega/2)} \right]^2, \quad (6.30)$$

które przyjmuje wartości nieujemne (por. rysunek 6.2). Zatem estymator funkcji gęstości spektralnej także jest nieujemny.

Rysunek 6.2. Okna spektralne Bartletta i Parzena



Źródło: Opracowanie własne.

2. Okno Parzena:


$$\lambda_{\text{Par}}(\omega) \equiv \frac{3}{8\pi M^3} \left[\frac{\sin(\omega M/4)}{1/2 \sin(\omega/2)} \right]^4 \quad (6.31)$$

gdzie M parzyste. Okno Parzena przyjmuje wartości dodatnie dla dowolnych częstości (por. rysunek 6.2). Stąd też estymator gęstości spektralnej przyjmuje wartości nieujemne.

Jakość estymatora gęstości spektralnej jest wyznaczona poprzez kształt (formę funkcji wagowej) i szerokość okna (lub, równoważnie, liczbę opóźnień). Kształt okna spektralnego zmienia się dla różnych szerokości okna.

Na rysunku 6.3 zostały przedstawione oszacowane funkcje gęstości spektralnej dla szeregów generowanych $\varepsilon_t = N(0, 1)$ oraz $y_t = 0,8y_{t-1} + \varepsilon_t$, a także dla dziennych stóp zwrotu z inwestycji w walutę euro oraz tygodniowych stóp zwrotu dla inwestycji w portfel rynkowy reprezentowany przez WIG.

Rysunek 6.3. Oszacowane funkcje gęstości spektralnej dla wybranych szeregów czasowych



Źródło: Opracowanie własne.

Z analizy wykresów wynika, że gęstość spektralna dla białego szumu, a także dla stóp zwrotu z WIG i EURO/PLN cechuje się niewielką zmiennością, podczas gdy dla szeregu z istotną autokorelacją (model AR(1) z dodatnim parametrem) przyjmuje relatywnie wyższe wartości w paśmie częstości bliskich zeru.

6.1.1. Weryfikacja istotności poszczególnych częstości

Weryfikacja hipotez w zakresie analizy spektralnej jest zagadnieniem bardzo szerokim². W tym miejscu zajmujemy się weryfikacją istotności poszczególnych częstości w periodogramie, w celu stwierdzenia, czy szereg wykazuje istotną okresowość przy danej częstości (por. Priestley [1981], Górka [2001], Górka, Osińska [2003]).

Periodogram składa się z $\frac{n}{2}$ wielkości opisanych równaniem (6.19). Pojedynczą wartość $I(\omega_i)$ związaną z częstością ω_i nazywamy *intensywnością* przy częstości ω_i . Istotność poszczególnych częstości sprawdza się, weryfikując hipotezy:

$$H_0: a_i = b_i = 0,$$

$$H_1: a_i \neq 0 \vee b_i \neq 0,$$

za pomocą statystyki:

$$F = \frac{(n-3) (a_i^2 + b_i^2)}{n/2 \sum_{i=1}^{n/2} (a_i^2 + b_i^2)}, \quad (6.32)$$

która ma rozkład $f(2, n-3)$ z 2 i $(n-3)$ stopniami swobody.

W praktyce w empirycznych szeregach czasowych występują składniki okresowe o nieznannej częstości. Dla szeregu generowanego przez model:

$$y_t = \alpha \cos \omega t + \beta \sin \omega t + \varepsilon_t, \quad (6.33)$$

gdzie ε_t jest białym szumem o rozkładzie $N(0, \sigma^2)$, zaś ω jest nieznaną częstością, stawiamy hipotezy:

$$H_0: \alpha = \beta = 0,$$

$$H_1: \alpha \neq 0 \vee \beta \neq 0. \quad (6.34)$$

Niech:

$$I^{(1)}(\omega_{(1)}) = \max \{I(\omega_i)\}, \quad (6.35)$$

wówczas statystyka Fishera ma postać:

$$T = \frac{I^{(1)}(\omega_{(1)})}{\sum_{i=1}^{n/2} I(\omega_i)}. \quad (6.36)$$

² Na podstawie analizy spektralnej powstało wiele testów statystycznych, na przykład test na istnienie pierwiastków jednostkowych opracowany przez Philipsa i Perrona (por. podrozdział 6.4).

Przy założeniu prawdziwości hipotezy zerowej (6.34), Fisher pokazał, że:

$$P(T > g) = \sum_{j=1}^m (-1)^{j-1} \binom{N}{j} (1-jg)^{N-1}, \quad (6.37)$$

gdzie $N = \frac{n}{2}$, $g > 0$, zaś m jest największą liczbą naturalną mniejszą od $1/g$. Zatem,

dla danego poziomu istotności α , w celu znalezienia wartości krytycznej g_α można użyć równania (6.37) oraz równania:

$$P(T > g_\alpha) = \alpha. \quad (6.38)$$

Jeżeli obliczona na podstawie danych wartość T jest większa od g_α , to odrzucamy hipotezę zerową.

Do obliczenia wartości krytycznej używa się równania (6.38) w postaci:

$$P(T > g) \cong N(1-g)^{N-1}. \quad (6.39)$$

6.2. Analiza spektralna stóp zwrotu z akcji i ich portfeli

W pracach Górki, Osińskiej [2001; 2003] przedmiotem zainteresowania były własności szeregów czasowych akcji obserwowanych na WGPW. Analizowane były stopy zwrotuienne, tygodniowe (każdy czwartek) i miesięczne (ostatnie notowanie z danego miesiąca) z poszczególnych akcji oraz ich portfeli, obserwowane w okresie 2.01.1995–31.12.2001. Otrzymane wyniki (por. tablicę 6.1) wskazują na duże zróżnicowanie okresowości występujących w poszczególnych akcjach, co potwierdza różny horyzont inwestycyjny poszczególnych inwestorów. Za pomocą analizy spektralnej można wyodrębnić akcje o podobnym horyzoncie inwestycyjnym. Jest to celowe, gdyż pozwala na specyfikowanie tych grup papierów wartościowych, w odniesieniu do których można zastosować te same narzędzia analizy (dla przykładu dla spółek wykazujących okresowość kilkudniową można zastosować metody analizy krótkookresowej, np. modele GARCH, dla szeregów wykazujących okresowość kilkumiesięczną celowe jest natomiast zastosowanie modeli opartych na analizach fundamentalnych), a także może być przydatne przy doborze akcji do portfeli. W tablicy 6.1 zostały przedstawione częstości, dla których wartości periodogramu były istotne w sensie testu F .

Spośród akcji, dla których przybliżona okresowość powtórzyła się w przypadku danych obserwowanych dziennie, tygodniowo lub miesięcznie, zostały utworzone — na podstawie miesięcznych i tygodniowych stóp zwrotu — przykładowe portfele efektywne. Roczną stopę wolną od ryzyka przyjęto a priori na poziomie 6%. Portfel 1 zawiera spółki, których okresowość, potwierdzona analizą przeprowadzoną w poprzednim punkcie, powtarzała się dla danych dziennych, tygodniowych i miesięcznych. W portfelu 2 znalazły się akcje z okresowością dla danych tygodniowych i miesięcznych, natomiast w portfelu 3 akcje z okresowością dzienną i tygodniową. Wyniki zostały zamieszczone w tablicy 6.2.

Tablica 6.1. Oceny periodogramu dla wybranych stóp zwrotu z akcji

Spółki	Dziennie stopy zwrotu			Tygodniowe stopy zwrotu			Miesięczne stopy zwrotu		
	częstotliwość	okresowość	periodyczność	częstotliwość	okresowość	periodyczność	częstotliwość	okresowość	periodyczność
Agros	0,0042	239	0,0178	0,0210	47,71	0,0940	0,0921	10,86	0,3290
Amerbank	0,4169	2	0,0166	0,4611	2,17	0,0630	0,1579	6,33	0,1316
BIG	0,4850	2	0,0155	0,0838	11,93	0,0778	0,3684	2,71	0,2353
BRE	0,1124	9	0,0156	0,0539	18,56	0,0488	0,2368	4,22	0,1526
Elektrim	0,0795	13	0,0176	0,4611	2,17	0,0649	0,4079	2,45	0,2299
Exbud	0,3254	3	0,0123	0,3054	3,27	0,0757	0,1711	5,85	0,2190
Kredytb	0,2727	4	0,0139	0,3054	3,27	0,0538	0,3158	3,17	0,0992
Okocim	0,4635	2	0,0191	0,3174	3,15	0,0333	0,4079	2,45	0,1511
WBK	0,1124	9	0,0201	0,4611	2,17	0,0685	0,2368	4,22	0,1734
WIG	0,0795	13	0,0069	0,4611	2,17	0,0231	0,4079	2,45	0,0766

Źródło: Opracowanie własne na podstawie Górka, Osińska [2001].

Tablica 6.2. Portfele budowane dla logarytmicznych stóp zwrotu z kryterium $\min(S_p)$

Portfele	Spółki	Dane tygodniowe		Dane miesięczne	
		udział %	okresowość	udział %	okresowość
Portfel 1	Irena	33,0	10,71**	45,8	2,48*
	Mostalwr	40,0		40,5	
	Rafako	27,0		13,7	
Portfel 2	Agros	14,3	52**	9,7	11,71**
	Jelfa	26,6		30,4	
	Krakenchem	21,2		19,4	
	Mostalex	21,7		32,7	
	Polifarb	16,2		7,7	
Portfel 3	BSK	7,0	24,3*		
	Dębica	15,0			
	Elektrim	—			
	Exbud	7,0			
	Kablehold	—			
	Kredytb	14,0			
	Optimus	3,0			
	Prochem	17,0			
	Żywiec	37,0			

* Istotna okresowość względem testu F .

** Istotna okresowość względem testu F i testu T .

Źródło: Górka, Osińska [2003].

Uzyskane wyniki pozwalają na sformułowanie następujących wniosków:

- portfele 1 i 2 przenoszą przybliżoną okresowość stóp zwrotu składających się na nie spółek na stopę zwrotu z portfeli akcji, tzn. na podstawie zachowania się jednej spółki inwestor może próbować przewidzieć zachowanie się portfela,
- w portfelu 2 okresowość została potwierdzona dwoma testami statystycznymi, tj. P oraz T ,
- w portfelu 3 widoczne są efekty dywersyfikacji, tzn. portfel jako agregat ma okresowość inną niż spółki wchodzące w jego skład.

Analiza spektralna jest narzędziem relatywnie rzadko wykorzystywanym w badaniach szeregów finansowych. Okazuje się jednak, że pozwala ona na wykrycie pewnych prawidłowości niemożliwych do opisanie innymi metodami. Pojawienie się tych prawidłowości jest dowodem na słabość hipotezy rynku efektywnego. Spostrzeżeń tych nie należy jednak traktować zbyt rygorystycznie. Wydaje się rozsądne przyjęcie hipotezy rynku efektywnego jako koncepcji granicznej, do której rynek finansowy dochodzi w niektórych okresach. Obecność inwestorów nieracjonalnych, przywiązanych do określonych spółek lub stosujących pewne strategie, np. kup i trzymaj, sprawia, że stosowanie ilościowych metod pozwalających na wykrywanie prawidłowości może przynieść wymierne efekty finansowe.

Wykorzystanie analizy spektralnej do testowania rzędu integracji szeregów czasowych

Zastosowanie funkcji gęstości spektralnej w testowaniu pierwiastków jednostkowych

Omówione w rozdziale 2 testy na obecność pierwiastka jednostkowego w równaniu $AR(1)$: $y_t = \rho y_{t-1} + \varepsilon_t$ były jednymi z pierwszych, jakie pojawiły się w literaturze ekonometrycznej (por. Dickey, Fuller [1979]). Zainteresowanie badaczy tą tematyką spowodowało wzrost liczby testów, które z różną mocą pozwalają weryfikować hipotezę o istnieniu pierwiastka jednostkowego, wobec hipotezy o stacjonarności szeregu. Niektóre z nich zostały oparte na narzędziach dostępnych tylko w analizie spektralnej. Jednym z przykładów, często występujących w oprogramowaniu, jest test Phillipsa-Perrona. Test ten (por. Phillips, Perron [1988]) wykazuje lepsze własności statystyczne niż testy DF i ADF w przypadku występowania autokorelacji składników losowych, aczkolwiek nadal cechuje się niską mocą wobec hipotez alternatywnych. Wykorzystywane są w nim nieparametryczne oceny gęstości spektralnej składnika losowego dla częstości równej zero, obliczone na podstawie ważonej autokowariancji.

Phillips i Perron proponują nieparametryczny test pierwiastka jednostkowego z hipotezą zerową o istnieniu pierwiastka. Podobnie jak w teście Dickeya-Fullera, stosujemy modyfikację równania $AR(1)$ postaci:

$$\Delta y_t = \delta y_{t-1} + \varepsilon_t \quad (6.40)$$

lub w przypadku stałej:

$$\Delta y_t = \mu + \delta y_{t-1} + \varepsilon_t. \quad (6.41)$$

Statystyka Phillipsa-Perrona ma następującą postać:

$$I_{PP} = I_\delta \sqrt{\frac{K(0)}{f(\omega)}} \frac{[f(\omega) - K(0)]T'}{2 \sqrt{f(\omega)} \sqrt{\sum_{t=1}^n (y_{t-1} - \bar{y}_{t-1})^2}}, \quad (6.42)$$

gdzie:

$f(\omega)$ — wartość funkcji gęstości spektralnej³ dla składnika resztowego z równania (przy szacowaniu funkcji gęstości spektralnej korzysta się z wag Bartletta),

$K(0)$ — wariancja szeregu ε_t ,

I_δ — statystyka t -Studenta oceny parametru δ ;

dla wariantu bez stałej $\bar{y}_{t-1} = 0$.

Test Phillipsa-Perrona uwzględnia ewentualną autokorelację reszt z równania poprzez funkcję gęstości spektralnej. Wartości krytyczne testu można odczytywać z tablic rozkładu Dickeya-Fullera. Ponadto, jeżeli statystyki podanych testów są obliczane dla regresji zawierającej stałą lub trend liniowy, to nie zmienia się interpretacja testów, zmieniają się jedynie asymptotyczne wartości krytyczne (por. Syczewska [1999]).

6.3.2. Identyfikacja szeregów ułamkowo zintegrowanych


W rozdziale 2 zostały wprowadzone pojęcia długiej pamięci i modelu ARFIMA, nie można jednak było wówczas omawiać metod identyfikacji tego modelu, a zwłaszcza ułamkowego parametru d , z powodu braku narzędzi z zakresu analizy spektralnej. W pierwszej kolejności przedstawimy na wykresach funkcję gęstości spektralnej dla dwóch wybranych procesów ARFIMA $(1; 0,3; 1)$ oraz $(0; 0,45; 0)$ (patrz rysunek 6.4). Modele generujące miały odpowiednio postaci:

$$(1 - 0,8B)(1 - B)^{0,3}y_t = (1 - 0,5B)\varepsilon_t \quad \text{oraz} \quad (1 - B)^{0,45}y_t = \varepsilon_t,$$

przy czym $\varepsilon \sim N(0, 1)$.

³ Pamiętajmy, że funkcja gęstości spektralnej białego szumu jest stała.

Rysunek 6.4. Generowane szeregi ARFIMA i ich gęstości spektralne



Źródło: Opracowanie własne.

Uwagę zwraca zwłaszcza wykres dotyczący ułamkowego białego szumu (ARFIMA (0; 0,45; 0)), gdyż wskazuje wyraźnie na zależność w częstościach bliskich zeru, a więc długookresowych, podczas gdy gęstość spektralna dla białego szumu powinna być stała.

W niniejszym podrozdziale rozważymy problem testowania rzędu integracji, dopuszczając, aby d było dowolną liczbą rzeczywistą. Rozważmy model postaci (por. Gil-Alana, Toro [2002], Caporale, Gil-Alana [2003]):

$$y_t = \beta x_t + u_t, \quad (6.43)$$

$$(1 - B)^d x_t = u_t, \quad (6.44)$$

gdzie:

 y_t — obserwowany szereg czasowy, β — wektor parametrów o wymiarach $(k \times 1)$, x_t — wektor składników deterministycznych, takich jak stała czy zmienna czasowa, u_t — szereg stacjonarny ($I(0)$), którego funkcja gęstości spektralnej jest dodatnia i skończona w częstości zerowej, $x_t \sim I(d)$, przy czym d jest przedmiotem testowania.

Robinson [1994] zaproponował test następującej hipotezy:

$$H_0: d = d_0,$$

dla dowolnej rzeczywistej wartości d_0 , wobec jednej z następujących hipotez alternatywnych $d \neq d_0$; $d > d_0$ oraz $d < d_0$. Statystyka Robinsona ma następującą postać:

$$s = \left(\frac{T}{\Lambda} \right)^{1/2} \frac{a}{\sigma^2}, \quad (6.45)$$

gdzie T oznacza wielkość próby, przy czym:

$$a = \frac{-2\pi}{T} \sum_{j=1}^{T-1} \psi(\omega_j) g(\omega_j, \tau)^{-1} I(\omega_j),$$

$$\Lambda = \frac{2}{T} \left\{ \sum_{j=1}^{T-1} \psi(\omega_j)^2 - \sum_{j=1}^{T-1} \psi(\omega_j) \varepsilon(\omega_j) \times \left(\sum_{j=1}^{T-1} \varepsilon(\omega_j) \varepsilon(\omega_j) \right)^{-1} \times \sum_{j=1}^{T-1} \varepsilon(\omega_j) \psi(\omega_j) \right\},$$

$$\psi(\omega_j) = \log \left| 2 \sin \frac{\omega_j}{2} \right|, \quad \varepsilon(\omega_j) = \left(\frac{\partial}{\partial \tau} \right) \ln g(\omega_j, \tau),$$

$$\omega_j = \frac{2\pi j}{T}.$$

Funkcja $g(\omega_j, \tau)$ jest znana i związana z funkcją gęstości spektralnej wzorem

$$f(\omega_j, \tau) = \frac{\sigma^2}{2\pi} g(\omega_j, \tau), \text{ ponadto } I(\omega_j) \text{ jest periodogramem dla } u_t.$$

Postać funkcji g zależy od modelu generującego u_t . Jeżeli $u_t = \varepsilon_t$, (tzn. że u_t jest białym szumem, wówczas $g \equiv 1$, natomiast dla u_t spełniającego własności procesu AR(1) $u_t = \tau u_{t-1} + \varepsilon_t$ postać funkcji jest następująca: $g(\omega_j, \tau) = [1 - \tau e^{i\omega_j}]^{-2}$, przy czym i jest częścią urojoną liczby zespolonej. Występująca we wzorze (6.45) wariancja σ^2 jest wariancją procesu u_t .

Pomimo dość skomplikowanej postaci, test Robinsona ma rozkład zbieżny do rozkładu normalnego $N(0, 1)$.

6.4. Podstawy dekompozycji falkowej

Dekompozycja falkowa jest narzędziem umożliwiającym przeskalowanie szeregu czasowego według czasu oraz odpowiedniego ciągu parametrów skali. Jest ona porównywana z analizą spektralną, aczkolwiek podobieństwa dotyczą jedynie stacjonarnych szeregów czasowych⁴. Zaletą dekompozycji (lub też reprezentacji)

⁴ Podobieństwo między analizą w dziedzinie częstości a przeskalowaniem za pomocą transformaty falkowej jest intuicyjne i prawdziwe tylko w najprostszych przypadkach; por. Priestley [1996].

falkowej jest możliwość zastosowania do szeregów niestacjonarnych, niestabilnych i niejednorodnych. Na przykład transformata Fouriera jest określona na przestrzeni dwuwymiarowej w przedziale częstotliwości $[0, 2\pi]$ i jest właściwa tylko dla szeregów charakteryzujących się stałą amplitudą wahań, natomiast w przypadku zmiennej amplitudy wahań pokazywane przez nią wyniki są nieprawdziwe. Funkcje reprezentowane przez falki są definiowane w przestrzeni dwuwymiarowej liczb rzeczywistych i nie są ograniczone do przypadków jednorodnych w czasie.

Koncepcja reprezentacji falkowej jest oparta na pojęciu tzw. falki podstawowej³, przez którą rozumie się funkcje postaci:

$$\phi_{jk} = 2^{-j/2} \phi(2^{-j}t - k), \quad (6.46a)$$

$$\psi_{jk} = 2^{-j/2} \psi(2^{-j}t - k), \quad (6.46b)$$

gdzie $k = \{0, 1, 2, \dots\}$ oznacza ciąg punktów, wokół których dokonujemy transformacji, zaś $2^j = s$ jest parametrem skali ($j = \{1, 2, 3, \dots\}$). Funkcje ϕ i ψ noszą nazwę funkcji skalujących. Zależnie od sposobu normalizacji funkcje (6.46) tworzą rodzinę funkcji postaci:

— falka „ojciec” (*father wavelet*):

$$\int \phi(t) dt = 1, \quad (6.47a)$$

— falka „matka” (*mother wavelet*):

$$\int \psi(t) dt = 0. \quad (6.47b)$$

Dekompozycja falkowa opiera się na analizie wielorozdzielczej (*multiresolution analysis*). Oznacza to, że za każdym razem dokonujemy podziału szeregu czasowego na część główną (zasadniczą, dotyczącą niskich częstotliwości) oraz część szczegółową (odpowiadającą częstotnościom wysokim). Falka „ojciec” umożliwia wyróżnienie zasadniczego składnika szeregu (odpowiednik filtru górnoprzepustowego), natomiast falka „matka” odpowiada za wahania szczegółowe (odpowiednik filtru dolnoprzepustowego). Bruzda [2003] nazywa to odpowiednio reprezentacją zgrubną i szczegółową. Zależnie od liczby poziomów reprezentacji s otrzymujemy odpowiednią liczbę par sygnałów zasadniczych i szczegółowych. Wielkość parametru skali jest zależna od liczby obserwacji w szeregu czasowym.

Niech będzie dany szereg czasowy y_t . Jego reprezentacja przy użyciu falek jest dana jako:

$$y_t = S_J + D_J + D_{J-1} + \dots + D_j + \dots + D_1, \quad (6.48)$$

przy czym:

$$S_J = \sum_k s_{Jk} \phi_{Jk}(t), \quad (6.49)$$

$$D_j = \sum_k d_{jk} \psi_{jk}(t), \quad j = \{1, 2, \dots, J\}, \quad (6.50)$$

a ponadto:

$$s_{Jk} = \int y_t \phi_{Jk}(t) dt \quad \text{oraz} \quad d_{jk} = \int y_t \psi_{jk}(t) dt, \quad j = \{1, 2, \dots, J\},$$

są współczynnikami ekspansji (siły sygnału) przy danej skali. Jeżeli liczba obserwacji n jest podzielna przez 2^J , to liczba współczynników każdego rodzaju jest odpowiednio równa:

— w skali 2^1 : $\frac{n}{2}$ współczynników d_{1k} ,

— w skali 2^2 : $\frac{n}{2^2}$ współczynników d_{2k} ,

— w skali 2^J : $\frac{n}{2^J}$ współczynników d_{Jk} ,

— w skali 2^J : $\frac{n}{2^J}$ współczynników s_{Jk} ;

stąd:

$$n = \frac{n}{2} + \frac{n}{4} + \dots + \frac{n}{2^{J-1}} + \frac{n}{2^J} + \frac{n}{2^J}. \quad (6.51)$$

Ciąg współczynników $\{s_J, d_J, d_{J-1}, \dots, d_1\}$ tworzy dyskretną⁴ transformatę falkową, którą można zapisać jako:

$$W_{jk} = \sum_{n=0}^{N-1} y_n \psi_{jk}\left(\frac{n}{N}\right), \quad (6.52)$$

gdzie $\psi_{jk}(\cdot)$ są przesuniętymi i przeskalowanymi wersjami falki podstawowej (6.46a)–(6.46b).

Użytecznym narzędziem analizy falkowej jest skalogram, który można traktować jako odpowiednik periodogramu. Niech:

$$E(j) = \sum_{k=0}^{2^{j-1}} W_{jk}^2 \quad (6.53)$$

będzie energią dyskretną transformaty falkowej na poziomie j . Wówczas skalogramem nazywamy wektor postaci:

$$[s_J^2 E(0) E(1) \dots E(n-1)]. \quad (6.54)$$

³ W literaturze przedmiotu wyróżnia się wiele falek podstawowych, np. falki Haar, Daubelet, Symmleeta; por. Ramsey, Lampart [1998], Bruzda [2003].


⁴ Odpowiednio definiuje się ciągłą transformatę falkową; por. Bruzda [2003].

Transformacja falkowa jest szeroko wykorzystywana w fizyce, aczkolwiek od niedawna znajduje zastosowanie również w analizach ekonomicznych, zwłaszcza finansowych. Falki są już obecne w niektórych pakietach komputerowych używanych głównie w ekonometrii, np. GAUSS.

► Przykład 6.2

Bruzda [2003] zastosowała transformację falkową w celu wyodrębnienia odpowiedniej siły sygnałów nadawanych przez szereg czasowy WIG20 w okresie 17.05.1999–20.06.2003. Aproksymacje sygnałów na poziomie zgrubnym i szczegółowym (detałicznym) zostały przedstawione na rysunku 6.5, na którym pokazano również skalogram WIG20, wskazujący na największy udział wahań długookresowych 2¹ reprezentowanych np. przez trend stochastyczny.

Rysunek 6.5. Dekompozycja falkowa szeregu WIG20



Źródło: Bruzda [2003].

Pytania i problemy

1. Dlaczego każdy stacjonarny szereg czasowy można przedstawić jako złożenie funkcji sinus i cosinus?
2. Do czego służy transformata Fouriera?
3. Wyjaśnij pojęcie funkcji gęstości spektralnej.

4. Wyjaśnij pojęcie i zinterpretuj periodogram.
5. Do czego służą okna spektralne?
6. Zapisz postać funkcji gęstości spektralnej dla szeregu generowanego przez model AR(1).
7. O czym informuje istotna wartość periodogramu dla częstości $\frac{\pi}{6}$? Wyjaśnij na przykładzie dziennych i miesięcznych stóp zwrotu.
8. Podaj zastosowania analizy spektralnej do identyfikacji szeregów czasowych.
9. Co to jest transformata falkowa?
10. Na czym polega analiza wielorozdzielcza?

Część druga

Rozdział 7

Modele regresji w analizie finansowych szeregów czasowych

Słowa kluczowe: modele dynamiczne, kointegracja procesów stochastycznych, mechanizm korekty błędem, czynniki fundamentalne, bąble spekulacyjne

Zastosowanie modeli regresji liniowej do opisu finansowych szeregów czasowych jest przedsięwzięciem dość trudnym, ale — jak wykażemy w dalszej części rozdziału — możliwym. Najwięcej problemów napotyka się na etapie specyfikacji modelu, kiedy należy ustalić zbiór zmiennych objaśniających wpływających np. na kurs akcji, stopę zwrotu czy też kurs walutowy. Czynniki uwzględniane w modelu regresji powinny mieć stały wpływ na zmienną objaśnianą oraz odzwierciedlać przyczynowo-skutkowy charakter zależności. Niezmiernie trudno jest takie czynniki wskazać, gdyż sytuacja na rynkach finansowych ulega częstym zmianom i zazwyczaj podlega działaniu przyczyn o charakterze impulsowym. Dzieje się tak zwłaszcza wtedy, kiedy dane są obserwowane w okresach dziennych i krótszych, a każda napływająca informacja może odmienić obraz rynku. W okresach dłuższych, miesięcznych, kwartalnych czy rocznych, większego znaczenia nabierają zmienne o charakterze fundamentalnym, powiązane bezpośrednio z sytuacją finansową firmy lub też sytuacją gospodarczą branży i całego kraju. Metodologia związana z budową i estymacją modeli opisujących finansowe szeregi czasowe opiera się głównie na analizie kointegracji procesów stochastycznych (por. Mills [2002]). Polska literatura ekonometryczna jest w tym ostatnim zakresie bardzo bogata (por. np. Strzała [1994], Charemza, Deadman [1997], Syczewska [1999], Brzeszczyński, Kelm [2002], Welfe [2003], Piłatowska [2003]).

W rozdziale zostanie także uwzględniony ekonometryczny punkt widzenia na takie znane narzędzia analizy procesów finansowych, jak model Sharpe'a, model APT i bąble spekulacyjne.

Modele regresji liniowej dla procesów stacjonarnych

Właściwości procesów stacjonarnych pozwalają na zastosowanie do ich opisu standardowych narzędzi statystyczno-ekonometrycznych i umożliwiają jednoznaczny sposób wnioskowania. Modele przedstawiane poniżej realizują zasadę od ogółu do szczegółu. Polega ona na tym, że na etapie specyfikacji ustalamy zbiór potencjalnych zmiennych objaśniających, a także przyjmujemy założenia co do ich struktury, reprezentowanej na przykład przez opóźnienia autoregresyjne. Jest to model ogólny, stanowiący bazę weryfikacji hipotez. Poprzez nakładanie restrykcji na parametry i ich testowanie dochodzimy do modelu szczegółowego, który możemy następnie wykorzystywać w praktyce¹.

Mając do czynienia z procesami stacjonarnymi, posługujemy się na ogół modelem autoregresyjnym z rozłożonymi opóźnieniami (ADL) lub modelem zgodnym. Postać modelu ADL jest następująca:

$$y_t = \alpha_0 + \sum_{i=1}^q \alpha_i y_{t-i} + \sum_{k=1}^m \sum_{l=0}^{p_k} \beta_{kl} x_{t-l} + \varepsilon_t, \quad (7.1)$$

gdzie:

y_t, x_{kt} — takie stacjonarne procesy stochastyczne o stałej średniej, że: $\alpha(B)y_t = \mu_y + \varepsilon_{yt}$,

$\beta_k(B)x_{kt} = \mu_{x_k} + \varepsilon_{x_k t}$,

α_i, β_{kl} — odpowiednie parametry rozkładu opóźnień autoregresyjnych,

ε_t — resztowy biały szum².

W przypadku modelu zgodnego w sensie Zielińskiego (por. Talaga, Zieliński [1986], Kufel [2002]) dochodzimy do efektu zbliżonego do (7.1), a nawet można zgłosić postulat, że poprawna specyfikacja obu modeli powinna doprowadzić do tego samego rezultatu. Warto zwrócić jednak uwagę, że dynamiczny model może dotyczyć zarówno modelowania zależności przyczynowych między ekonomicznymi procesami stochastycznymi, jak też modelowania jednowymiarowych i wielowymiarowych szeregów czasowych. Modelom jednowymiarowych szeregów czasowych został poświęcony rozdział drugi, natomiast zasady modelowania wielowymiarowych szeregów czasowych zostaną przedstawione w rozdziale ósmym. Każdy z tych modeli może spełniać warunki zgodności. W niniejszym rozdziale przez dynamiczny model będziemy rozumieli model przyczynowo-skutkowy uwzględniający wewnętrzną strukturę dynamiczną każdego z procesów objaśnianych i objaśniających. Rozważania ograniczymy do modeli jednorównaniowych.

U podstaw modelowania zgodnego leży jednakże filozofia, której istota zawiera się w stwierdzeniu, że struktura harmoniczna lewej i prawej strony modelu ekonometrycznego powinna być taka sama, przy zachowaniu procesu resztowego w postaci białego szumu³. Ogólnie powiemy, że każdy proces stacjonarny obserwowany w jakimś okresie ma swoją reprezentację w dziedzinie częstości powiązanej

z czasem następującą relacją: $\omega_i = \frac{2\pi i}{T}$, gdzie $i = 1, 2, \dots, \frac{T}{2}$, a T oznacza liczbę

obserwacji w szeregu czasowym. Struktura harmoniczna oznacza zatem, że struktura uwzględniająca częstości procesu objaśnianego i łączna struktura procesów objaśniających powinny być sobie równe. Jeżeli proces resztowy jest białym szumem, to jego struktura harmoniczna jest stała, a zatem jego dodanie nie wpływa na modelowaną relację. Stąd punktem wyjścia konstrukcji modelu zgodnego dla procesów stacjonarnych jest następująca relacja dla białych szumów:

$$\varepsilon_{yt} = \rho \varepsilon_{xt} + \varepsilon_t, \quad (7.2)$$

przy czym:

$$\alpha(B)y_t = \varepsilon_{yt}, \quad (7.3)$$

$$\beta(B)x_t = \varepsilon_{xt}, \quad (7.4)$$

gdzie ε_t jest resztowym białym szumem.

Zakładając autoregresyjną reprezentację procesów y_t i x_t postaci (7.3) i (7.4), zapisaną jako:

$$\sum_{i=0}^q \alpha_i y_{t-i} = \varepsilon_{yt} \quad \text{ i } \quad \sum_{i=0}^p \beta_i x_{t-i} = \varepsilon_{xt}, \quad \text{ dla } \alpha_0 = 1 \text{ i } \beta_0 = 1,$$

otrzymujemy:

$$\sum_{i=0}^q \alpha_i y_{t-i} = \rho \sum_{i=0}^p \beta_i x_{t-i} = \varepsilon_t. \quad (7.5)$$

Po uporządkowaniu mamy następujący model dla procesu y_t :

$$y_t = \sum_{i=0}^q \gamma_i y_{t-i} + \rho \sum_{i=0}^p \beta_i x_{t-i} = \varepsilon_t, \quad (7.6)$$

gdzie $\gamma_i = -\alpha_i$.

³ Pojęcie struktury harmonicznej zostało wyjaśnione w rozdziale 6 niniejszego podręcznika.

¹ Modelowanie „od ogółu do szczegółu” pochodzi od Hendry’ego i jest dokładnie opisane w pracy: Charemza, Demian [1997]; por. także Hendry, Meullbauer, Murphy [1990].

² Na temat własności reszt w złożeniach modeli autoregresyjnych por. Stawicki, Górka [1995].

Uogólniając procedurę na m procesów objaśniających, mamy:

$$\varepsilon_{yt} = \sum_{k=1}^m \rho_k \varepsilon_{x_{kt}} + \varepsilon_t. \quad (7.7)$$

Podstawiając jak poprzednio, otrzymujemy:
— w przypadku stałej równej zero:

$$y_t = \sum_{i=1}^q \alpha_i y_{t-i} + \sum_{k=1}^m \sum_{i=0}^{p_k} \beta_{ik}^* x_{kt-i} + \varepsilon_t, \quad (7.8)$$

gdzie $\beta_{ik}^* = \beta_i \rho_k$,

— w przypadku stałej różnej od zera:

$$y_t = \alpha_0 + \sum_{i=1}^q \alpha_i y_{t-i} + \sum_{k=1}^m \sum_{i=0}^{p_k} \beta_{ik}^* x_{kt-i} + \varepsilon_t, \quad (7.9)$$

gdzie $\beta_{ik}^* = \beta_i \rho_k$.

Przy identycznych q, m, p_i model (7.9) może być równoważny postaci (7.1). Postaci (7.8) i (7.9) są modelami ogólnymi zawierającymi pełną liczbę czynników, przy czym niektóre mogą się okazać nieistotne. Należy je zatem doprowadzić do postaci szczegółowych poprzez testowanie.

► Przykład 7.1

Badanie zależności między zjawiskami finansowymi obejmuje także analizę wpływu poszczególnych zdarzeń jakościowych (np. decyzje organizacyjne, wejście w życie nowych przepisów prawnych, ogłoszenia spółek o wypłacie dywidendy) na wysokość lub zmienność stóp zwrotu. W literaturze angielskojęzycznej określa się to mianem *event analysis* (por. Campbell, Lo, MacKinley [1997]).

Rozważmy jako przykład model postaci (por. Bohl, Brzeszczyński [2004]):

$$R_t = c + \beta_1 R_{t-1} + \beta_2 D_t R_{t-1} + \varepsilon_t,$$

gdzie R_t oznacza stopę zwrotu z akcji, natomiast wariancja warunkowa ε_t była opisana za pomocą modelu GARCH(1, 1) lub TARCH(1, 1). Zmienna D_t oznacza datę wejścia na rynek giełdowy inwestorów instytucjonalnych w postaci funduszy emerytalnych, co miało miejsce 19 maja 1999 r. Dodatkowo zbadano wpływ funduszy emerytalnych po jednym, dwóch, trzech i czterech miesiącach od uzyskania formalnej możliwości inwestowania na giełdzie. Zmienna D_t została zatem określona jako:

$$D_t = \begin{cases} 1, & \text{dla } t \geq 19 \text{ maja (lub 19 czerwca, 19 lipca, 19 sierpnia, 19 września),} \\ 0, & \text{w przeciwnym wypadku.} \end{cases}$$

Celem badania było ustalenie, czy wejście na wtórny rynek akcji inwestorów instytucjonalnych w postaci funduszy emerytalnych działa destabilizująco na stopy zwrotu z akcji. Gdyby fundusze kupowały akcje w sposób destabilizujący, wówczas typowym zjawiskiem byłby wzrost cen, a następnie ich spadek. Z ekonometrycznego punktu widzenia efektem byłaby ujemna autokorelacja stóp zwrotu. Zmienna zero-jedynkowa została do modelu wprowadzona po to, aby oddzielić ten efekt od „normalnej” autokorelacji występującej w warunkach niezakłóconych impulsami zewnętrznymi. Model przedstawiony na początku przykładu z dołączonym równaniem GARCH(1, 1) został oszacowany dla stóp zwrotu z akcji spółki Grajewo (RG_t):

Długość próby 2 1648

	Oceny parametrów	Błędy ocen	Statystyka z	Wartość p
C	0,000849	0,000758	1,119654	0,2629
β_1	0,098512	0,068511	1,437905	0,1505
β_2	-0,260588	0,081923	-3,180873	0,0015
Równanie wariancji				
C	0,000161	4,08E-05	3,942998	0,0001
ARCH(1)	0,316658	0,064347	4,921110	0,0000
GARCH(1)	0,556435	0,057288	9,712902	0,0000

Wyniki estymacji wskazują na niewielką dodatnią autokorelację w normalnych warunkach oraz silniejszą autokorelację ujemną z tytułu włączenia akcji spółki Grajewo do portfeli inwestycyjnych funduszy emerytalnych. Ujemny znak parametru β_2 sugeruje, że fundusze emerytalne nie destabilizowały rynku akcji spółki Grajewo w badanym okresie, jednak wartość bezwzględna tego parametru jest większa niż parametru β_1 . Analogiczne wyniki dla całego rynku reprezentowanego przez indeks WIG20 otrzymali Bohl i Brzeszczyński [2004]. Wiadomo jednak, że akcje poszczególnych spółek mogą zachowywać się inaczej niż cały rynek.

7.2. Modele regresji liniowej dla procesów niestacjonarnych

7.2.1. Niestacjonarność w wartości średniej procesu

Procesy niestacjonarne w wartości średniej mogą być — jak już wspomniano w rozdziale 2 — modelowane za pomocą modeli trendu deterministycznego oraz sezonowości deterministycznej. Stąd relacja przyczynowo-skutkowa wiążąca te procesy sprowadza się do modelu ADL lub modelu zgodnego, do których zostały dodane składniki deterministyczne.

Założenie: może się zmieniać wartość średnia badanych procesów ekonomicznych.

Pierwszym krokiem budowy modelu dynamicznego jest badanie struktury wewnętrznej procesów (m.in. w zakresie trendu, sezonowości oraz autoregresji). Przyjmijmy następującą reprezentację analizowanych procesów:

$$Y_t = P_t + S_t + \eta_t, \quad (7.10)$$

$$X_{kt} = P_{k,t} + S_{k,t} + \eta_{k,t}, \quad k = 1, 2, \dots, m. \quad (7.11)$$

Całą procedurę powtarzamy dla m procesów. Mając podstawowe modele trendu i sezonowości oraz modele autoregresyjne, można przejść do sformułowania modelu ogólnego, zawierającego maksymalny stopień wielomianu trendu, sezonowość oraz maksymalny rząd autoregresji dla każdego procesu, postaci:

$$Y_t = \sum_{s=1}^q \alpha_s Y_{t-s} + \sum_{k=1}^m \rho_k \sum_{i=0}^{p_k} \beta_{ki} X_{kt-i} + P_t + S_t + \varepsilon_t, \quad (7.12)$$

gdzie P_t oznacza łączny model trendu występujący w modelu. Podobnie S_t jest składnikiem sezonowym modelu, powstałym z połączenia i przekształcenia poszczególnych składników sezonowych.

Oznaczając $\gamma_{ki} = \rho_k \beta_{ki}$, można zapisać:

$$Y_t = \sum_{i=1}^q \alpha_i Y_{t-i} + \sum_{k=1}^m \sum_{i=0}^{p_k} \gamma_{ki} X_{kt-i} + P_t + S_t + \varepsilon_t. \quad (7.13)$$


Parametry powyższego modelu podlegają szacowaniu metodą najmniejszych kwadratów, zaś cały model — weryfikacji. Nie wszystkie parametry są istotne. Metodą a posteriori dokonujemy eliminacji czynników nieistotnych. Polega to na eliminacji najpierw tego czynnika, który jest najbardziej nieistotny, a następnie ponownym szacowaniu modelu itd., aż otrzyma się model ze wszystkimi składnikami istotnymi⁴.

Kointegracja procesów stochastycznych

Koncepcja kointegracji została wprowadzona do literatury przez Engle'a i Grangera [1987]. Jej istota zawiera się w tym, że między procesami ekonomicznymi można wyznaczyć pewną długookresową ścieżkę równowagi niezależną od czasu (*steady state*), natomiast wartości znajdujące się poza nią stanowią krótkookresowe odchylenia od stanu równowagi, które zależą od czasu. Na rysunku 7.1 zostały przedstawione przykładowe realizacje szeregów skointegrowanych i nieskointegrowanych.

⁴ Należy zwrócić uwagę, że metoda weryfikacji elementów nieistotnych za pomocą testu t -Studenta jest niewystarczająca. Można weryfikować także inne hipotezy, np. łącznie o nieistotności wszystkich i -tych opóźnień w modelu. Stosuje się wówczas test F ; por. Charemza, Deadman [1997].

Rysunek 7.1. Szeregi skointegrowane i nieskointegrowane



Źródło: Opracowanie własne.

Jak wynika z rysunku 7.1, procesy skointegrowane charakteryzują się wspólną długookresową ścieżką wzrostu, a różnica między nimi wykazuje niemal stały poziom w czasie. Z kolei procesy nieskointegrowane rozbiegają się w długim okresie, a różnica między nimi zmienia się (tutaj zwiększa się) w czasie.

Definicja 7.1

Dwa procesy x_t i y_t są skointegrowane rzędu d, b , tzn. $x_t, y_t \sim CI(d, b; d \geq b > 0)$, jeżeli:

- są one zintegrowane tego samego rzędu d ,
- istnieje kombinacja liniowa tych procesów:

$$u_t = \alpha_1 x_t + \alpha_2 y_t, \quad (7.14)$$

która jest zintegrowana rzędu $d-b$. Wektor $[\alpha_1 \alpha_2]$ jest nazywany wektorem kointegrującym.

Powyższą definicję można uogólnić na dowolną liczbę procesów.

Definicja 7.2

Niech x_t będzie wektorem procesów o wymiarach $(n \times 1)$. Jeśli każda składowa tego wektora jest zintegrowana rzędu $d(I(d))$ oraz istnieje wektor α taki, że $x_t' \alpha \sim I(d-b)$, to elementy wektora x_t są skointegrowane rzędu d, b , czyli $x_t \sim CI(d, b; d \geq b > 0)$.

Inne uogólnienie dotyczy sytuacji, gdy mamy do czynienia z wieloma procesami o różnych rzędach zintegrowania. Mając na przykład trzy szeregi, z których dwa są zintegrowane w stopniu 2, natomiast jeden w stopniu pierwszym, można uzyskać efekt kointegracji w następujący sposób: niech $w_t \sim I(2)$ i $z_t \sim I(2)$, a $v_t \sim I(1)$. Jeżeli istnieje wektor kointegrujący $[\beta_1 \beta_2]$ taki, że: $u_t = \beta_1 w_t + \beta_2 z_t$ jest zintegrowane w stopniu 1, to w następnym kroku można badać kointegrację szeregów v_t i u_t . Gdy $[\gamma_1 \gamma_2]$ będzie wektorem kointegrującym, to $e_t = \gamma_1 v_t + \gamma_2 u_t$ będzie

zintegrowane w stopniu 0. Powiemy wtedy, że procesy w_t , z_t są skointegrowane rzędu (2, 1), natomiast procesy v_t , u_t są skointegrowane rzędu (1, 1), a cała relacja długookresowa połączy trzy procesy.

Z ekonomicznego i finansowego punktu widzenia najbardziej interesujący jest przypadek, kiedy szeregi transformowane przy użyciu wektora kointegrującego są stacjonarne, tj. wtedy, gdy $d = b$. Praktyka ekonomiczna wskazuje, że najczęściej mamy do czynienia z przypadkiem, gdy $d = b = 1$. Jeżeli procesy x_t i y_t są zintegrowane rzędu 1 ($I(1)$) i ich kombinacja liniowa może być wyrażona jako:

$$y = \alpha x \quad (7.15a)$$

lub:

$$y - \alpha x = 0, \quad (7.15b)$$

to (7.15b) może być traktowane jako równanie opisujące długookresową ścieżkę równowagi procesów x_t i y_t . Jak już wspomniano, ścieżka długookresowa jest niezależna od czasu, stąd w równaniu został pominięty subskrypt t .

Dla dwóch procesów mają miejsce następujące możliwości w zakresie wystąpienia kointegracji:

- a) $y_t \sim I(1)$ i $x_t \sim I(0)$, wtedy $u_t \sim I(1)$, zatem procesy nie są skointegrowane,
- b) $y_t \sim I(0)$ i $x_t \sim I(1)$, wtedy $u_t \sim I(1)$, zatem procesy nie są skointegrowane,
- c) $y_t \sim I(1)$ i $x_t \sim I(1)$, wtedy:
 $u_t \sim I(1)$, procesy nie są skointegrowane
 lub
 $u_t \sim I(0)$, procesy są skointegrowane,
- d) $y_t \sim I(0)$ i $x_t \sim I(0)$, wtedy $u_t \sim I(0)$, a zatem procesy nie są skointegrowane — kointegracja nie ma sensu.

Regresja pozorna. W ekonomii istnieje potrzeba rozróżniania rzeczywistych relacji długookresowych i regresji pozornych. Przez regresję pozorną będziemy rozumieć model postaci $y_t = \alpha_0 + \alpha_1 x_t + u_t$ oszacowany dla dwóch (lub większej liczby) niezależnych procesów błędzenia przypadkowego, których indywidualne reprezentacje są następujące: $y_t = y_{t-1} + v_t$ oraz $x_t = x_{t-1} + w_t$. Regresja pozorna charakteryzuje się zazwyczaj dobrymi własnościami statystycznymi, w postaci istotności parametrów w świetle testu t -Studenta oraz wysoką wartością współczynnika R^2 . Ważnym wskaźnikiem sugerującym, że mamy do czynienia z regresją pozorną, jest niska wartość statystyki Durбина-Watsona, a ściślej relacja $DW < R^2$. Wnioskowanie oparte na regresji pozornej jest nieuzasadnione. Sposobem na jej uniknięcie jest — poza porównaniem relacji między DW i R^2 — analiza rzędu

integracji badanych szeregów czasowych oraz — w przypadku spełnienia założeń — weryfikacja hipotezy o ich kointegracji. Do opisu relacji między szeregami skointegrowanymi stosuje się odpowiedni model, zawierający mechanizm korekty błędem, który zostanie opisany w punkcie 7.2.4. W przypadku gdy mimo jednakowego rzędu integracji badane szeregi nie tworzą relacji długookresowej, należy dokonać odpowiednich transformacji w celu sprowadzenia ich do stacjonarności, a następnie zbudować dla nich liniowy model ADL lub zgodny, albo też — w uzasadnionych przypadkach — budować modele nieliniowe.

7.2.3. Testowanie kointegracji szeregów czasowych

W przypadku testowania kointegracji szeregów czasowych stosuje się te same narzędzia, z których korzystaliśmy w badaniu stopnia integracji tych szeregów. Tak więc spośród omawianych w rozdziałach 2 i 6 testów z powodzeniem możemy się tutaj posłużyć testem Dickeya-Fullera, rozszerzonym testem Dickeya-Fullera, a także testem Philipasa-Perrona⁵. Istotna różnica polega na tym, że testy te będziemy odnosić do szeregu reszt z równania kointegrującego postaci:

$$y_t = \alpha x_t + u_t \quad (7.16)$$

lub:

$$y_t = \alpha_0 + \alpha_1 x_t + u_t, \quad (7.17)$$

lub:

$$y_t = \alpha_0 + \alpha_1 x_{1t} + \dots + \alpha_k x_{kt} + u_t, \quad (7.18)$$

Dla przykładu, stosując test Dickeya-Fullera dla reszt z regresji (7.16)–(7.18) za podstawę przyjmujemy równanie:

$$\Delta u_t = \delta u_{t-1} + \varepsilon_t, \quad (7.19)$$

a w przypadku wyraźnej autokorelacji reszt:

$$\Delta u_t = \delta u_{t-1} + \sum_{i=1}^k \Delta u_{t-i} + \varepsilon_t \quad (7.20)$$

stosujemy test ADF.

Zasady wnioskowania są podobne jak w przypadku testowania integracji, z tym że przy odczytywaniu z tablic wartości krytycznych należy uwzględnić liczbę wektorów kointegrujących, up. $m = 1$, $m = 2$ itd.

⁵ Oprócz wymienionych wieloma innymi; por. Syczewska [1999], Maddala-Kim [2002].

Tablica 7.1. Wybrane (dolne) wartości krytyczne testu DF/ADF dla 1, 2 i 3 wektorów kointegrujących

N	Model bez stałej	Model ze stałą	Model z sezonowością kwartalną
$m = 1$			
30	-2,87	-3,37	-3,39
40	-2,87	-3,38	-3,40
50	-2,87	-3,39	-3,40
75	-2,87	-3,41	-3,41
100	-2,87	-3,42	-3,42
150	-2,87	-3,43	-3,42
300	-2,87	-3,44	-3,43
$m = 2$			
30	-3,34	-3,71	-3,78
40	-3,33	-3,74	-3,80
50	-3,33	-3,76	-3,82
75	-3,35	-3,79	-3,85
100	-3,36	-3,81	-3,87
150	-3,37	-3,83	-3,89
300	-3,38	-3,86	-3,92
$m = 3$			
30	-3,71	-3,98	-4,04
40	-3,73	-4,02	-4,10
50	-3,75	-4,04	-4,13
75	-3,77	-4,08	-4,19
100	-3,78	-4,10	-4,22
150	-3,80	-4,13	-4,26
300	-3,82	-4,16	-4,31

Źródło: Charemza, Deadman [1997].

Jednorównaniowy model korekty błędem

Jednorównaniowy model dla skointegrowanych szeregów czasowych jest modelem z mechanizmem korekty błędem. Model ten składa się z dwóch równań:

- 1) równania długookresowego postaci (7.16)–(7.18),
- 2) równania krótkookresowego opartego na przyrostach badanych szeregów.

Rozważmy następujące szeregi czasowe $y_t \sim I(1)$, $x_t \sim I(1)$, $y_n, x_t \sim CI(1, 1)$. Model korekty błędem budujemy według procedury dwustopniowej Engle'a i Grangera [1987].

1. Definiujemy równanie kointegrujące:

$$y_t = \alpha_0 + \alpha_1 x_t + u_t, \quad (7.21)$$

którego parametry przyjmujemy na poziomie z góry zadany lub szacujemy na podstawie danych za pomocą klasycznej MNK. Przyjmujemy parametry jako dane, opierając się na hipotezach teoretycznych. W przypadku braku takich informacji — co najczęściej ma miejsce — szacujemy parametry modelu (7.21).

2. Budujemy równanie krótkookresowe dla przyrostów badanych zmiennych postaci:

$$\begin{aligned} \Delta y_t &= \beta_0 + \beta_1 \Delta x_t + \gamma(y - \alpha_0 - \alpha_1 x)_{t-1} + \eta_t = \\ &= \beta_0 + \beta_1 \Delta x_t + \gamma u_{t-1} + \eta_t = \\ &= \beta_0 + \beta_1 \Delta x_t + \gamma ECM_{t-1} + \eta_t. \end{aligned} \quad (7.22)$$

Model (7.22) jest w istocie modelem dla procesów stacjonarnych, ponieważ zarówno przyrosty badanych szeregów, jak i wyrażenie w nawiasie są procesami $I(0)$. Wyrażenie w nawiasie reprezentuje relację długookresową (stan równowagi długookresowej) i nazywa się *mechanizmem korekty błędem* (ECM — *error correction mechanism*). Należy zwrócić uwagę, że mechanizm korekty błędem występuje z indeksem $t-1$. Oznacza to stan równowagi w okresie poprzednim w stosunku do t . Przyrosty zmiennych są indeksowane w czasie t , co sprawia, że parametry stojące przy przyrostach zmiennych, w tym przypadku β_1 , informują o dostosowaniach krótkookresowych w czasie t do stanu równowagi w czasie $t-1$. W interpretacji modelu ważny jest znak parametru γ . Chodzi o to, by był ujemny ($\gamma < 0$), gdyż tylko taka relacja zapewnia dochodzenie do poziomu równowagi z okresu na okres.

W przypadku gdy w modelu (7.22) występuje autokorelacja, należy zmodyfikować go do postaci:

$$\Delta y_t = \beta_0 + \beta_1 \Delta x_t + \gamma(y - \alpha_0 - \alpha_1 x)_{t-1} + \sum_{i=1}^p b_i \Delta y_{t-i} + \sum_{i=1}^q c_i \Delta x_{t-i} + \varepsilon_t, \quad (7.23)$$

gdzie ε_t jest białym szumem.

Budowa modelu korekty błędem (ECM) powinna zatem być poprzedzona wnikliwą analizą wewnętrznej struktury modelowanych szeregów czasowych, zwłaszcza w zakresie badania rzędu zintegrowania oraz autokorelacji. Jest to jednocześnie wymóg właściwej specyfikacji modeli dynamicznych. Parametry modelu ECM mogą zostać oszacowane za pomocą metody najmniejszych kwadratów. Dotyczy to zarówno relacji długookresowej, jak i krótkookresowej. Modele (7.22) i (7.23) można rozszerzyć na większą liczbę zmiennych objaśniających.

Związek modelu ECM z modelem ADL. Model korekty błędem można uzyskać także z modelu ADL poprzez testowanie odpowiednich restrykcji. Rozważmy prosty przypadek modelu (7.1), dla $p = q = 1$, postaci:

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \beta_0 x_t + \beta_1 x_{t-1} + \varepsilon_t. \quad (7.24)$$

Dokonując następujących przekształceń:

- odejmujemy y_{t-1} od obu stron równania,
 - odejmujemy i dodajemy wyrażenie $\beta_0 x_{t-1}$ po prawej stronie równania,
- otrzymujemy:

$$\Delta y_t = \alpha_0 + (\alpha_1 - 1) y_{t-1} + \beta_0 \Delta x_t + (\beta_0 + \beta_1) x_{t-1} + \varepsilon_t. \quad (7.25)$$

Model (7.25) zawiera mechanizm korekty błędem typu $y_{t-1} - x_{t-1}$, jeżeli zachodzi:

$$\alpha_1 - 1 = -(\beta_0 + \beta_1). \quad (7.26)$$


Warunek (7.26) jest przedmiotem testowania (por. Charemza, Deadman [1997]).

➤ Przykład 7.2

Pytanie, które można zadać sobie na gruncie teorii finansów, brzmi: czy istnieje długookresowa zależność stóp procentowych dla depozytów na okresy krótkie i długie? Jest to istotne, ponieważ mimo krótkookresowych fluktuacji taka długoterminowa zależność gwarantuje stabilność rynku (zob. Kunst [1992]).

Rozważmy stopy procentowe obserwowane na polskim rynku międzybankowym. Oznaczamy przez $1W$ stopę WIBOR dla depozytów jednotygodniowych, natomiast przez $1R$ dla depozytów rocznych. Obserwacje dzienne pochodzą z okresu od 2.01.01 do 30.03.03. Na rysunku 7.2 zostały przedstawione empiryczne szeregi czasowe.

Rysunek 7.2. Kointegracja stóp procentowych na rynku międzybankowym



Źródło: Opracowanie własne.

Wyniki indywidualnego testowania rzędu integracji badanych szeregów przedstawia tablica 7.2.

Tablica 7.2. Wyniki testowania rzędu integracji stóp procentowych testem ADF

ADF	1W	1R
$H_0: I(1)$	-0,7375	-0,4098
$H_0: I(2)$	-10,2452	-9,9602

Źródło: Opracowanie własne.

Mając informację o tym, że obydwa szeregi są zintegrowane w stopniu 1, oszacowano relację długookresową, która przyjęła postać:

$$1W = 1,446 + 1,015 \times 1R + u_t$$

i zbadano kointegrację stóp procentowych. Relacja kointegrująca nie zakłada przyczynowo-skutkowego kierunku od zmiennej objaśniającej do objaśnianej, niemniej jednak wydaje się, że stopa depozytów rocznych jest punktem odniesienia (benchmarkiem) dla stopy oprocentowania depozytów krótkoterminowych.

Na podstawie wyników testu ADF możemy przyjąć, że szeregi $1W$ i $1R$ są skointegrowane przy poziomie istotności 0,1, gdyż wartość testu wyniosła -3,1278. Została podjęta próba oszacowania modelu korekty błędem dla badanych szeregów:

$$\Delta 1W_t = 0,004 - 0,141 \Delta 1W_{t-1} + 1,357 \Delta 1R_t - 0,094 ECM_{t-1} + \varepsilon_t,$$

(0,028) (0,050) (0,260) (0,024)

$$R^2 = 0,136, \quad DW = 2,029.$$

Jak wskazują otrzymane rezultaty, wszystkie parametry — oprócz stałej — są statystycznie istotne, reszty nie zawierają autokorelacji, natomiast dopasowanie do danych empirycznych jest bardzo niskie. Sugeruje to, że w krótkich okresach (dzienne przyrosty stóp procentowych) WIBOR roczny w niewielkim stopniu ma wpływ na WIBOR tygodniowy i że główną rolę odgrywają tutaj siły rynkowe (popyt i podaż depozytów tygodniowych). Nie mając danych dotyczących wielkości popytu i podaży, bardzo trudno znaleźć inne przyczyny mające wpływ na kształtowanie się stopy procentowej w krótkich okresach, stąd w krótkookresowych analizach procesów finansowych współczynnik determinacji znajdujący się na niskim poziomie należy uznać za standard.

Uzupełniając przedstawiony powyżej model, należy wziąć pod uwagę, że realna stopa procentowa dla inwestycji wolnych od ryzyka zależy głównie od stopy wzrostu gospodarczego oraz jej oddziaływania na procesy zachodzące na rynku kapitałowym w krótkim okresie. Duże znaczenie ma polityka banku centralnego, który poprzez wybrane stopy procentowe, zależnie od sytuacji w gospodarce, reguluje podaż

pieniądza. Ponadto istotne okazują się wzorce zachowań inwestorów — w gospodarce polskiej często inwestorów zagranicznych. Popyt na fundusze pożyczkowe zależy z kolei głównie od poziomu konsumpcji, zarówno gospodarstw domowych, jak i instytucji rządowych, samorządów lokalnych, firm itp.

Prezentowane w literaturze (Milo [2000]) modele pozwalające ustalić prognozy stóp procentowych w Polsce zakładają, że wśród zmiennych objaśniających znajdują się: stopa procentowa banku centralnego (lombardowa, kredytu refinansowego, redyskontowa), wskaźnik wzrostu cen, konsumpcja prywatna, popyt na pieniądz gotówkowy, średni kurs walutowy (USD/PLN, EURO/PLN), a także średnia rentowność bonów skarbowych. W polskiej rzeczywistości lat 90. XX w. najistotniejsze znaczenie regulacyjne miała 3-miesięczna stopa oprocentowania kredytów na rynku międzybankowym (WIBOR 3M). Jednak duża liczba modeli opisujących kształtowanie się WIBOR 3M sugeruje, że trafne prognozowanie stopy procentowej nie jest przedsięwzięciem prostym, ponieważ trudno ustalić, które czynniki będą w danym momencie miały największe znaczenie.

Wykorzystanie modeli regresji w analizach finansowych

Model pojedynczego indeksu

Wśród modeli regresji liniowej opisujących stopy zwrotu z akcji najbardziej popularnym jest model pojedynczego indeksu Sharpe'a. Założenia leżące u jego podstaw wywodzą się z hipotezy rynku efektywnego. Można je sformułować następująco:

1. Inwestorzy mają awersję do ryzyka i maksymalizują swoją stopę zwrotu w dłuższym horyzoncie czasowym.
2. Inwestorzy w swoich decyzjach są racjonalni i dokonują wyboru sposobu pomnażania bogactwa na podstawie wiedzy o ryzyku (odchylenie standardowe od stopy zwrotu) i spodziewanej stopy zwrotu.
3. Na zwiększenie aktywów inwestora nie wpływają podatki i koszty transakcji, które w analizach są równe zero.
4. Wszystkie aktywa mogą być kupowane i sprzedawane bez ograniczeń.
5. Na rynku nie ma barier wejścia i wyjścia dla kapitałów, a informacja jest jednakowo dostępna dla wszystkich jego uczestników.
6. W tym samym czasie wszyscy inwestorzy kierują się takimi samymi zasadami dotyczącymi spodziewanej stopy zwrotu, ryzyka i kowariancji. Oczekiwana stopa zwrotu i ryzyko są jedyną podstawą do podejmowania decyzji inwestycyjnych.
7. Transakcje pojedynczego inwestora nie mogą mieć wpływu na cenę instrumentu finansowego.
8. Na rynku są nieograniczone możliwości udzielania i zaciągania kredytu przy stopie wolnej od ryzyka.

Postać modelu jest bardzo prosta:

$$R_{it} = \alpha_i + \beta_i R_{Mt} + u_{it}, \quad (7.27)$$

gdzie:

- R_{it} — stopa zwrotu z i -tego papieru wartościowego,
- R_{Mt} — stopa zwrotu z indeksu giełdowego (rynkowa stopa zwrotu),
- β_i — współczynnik określający ryzyko inwestycji w dany papier wartościowy.

Należy zauważyć, że w warunkach spełnienia hipotezy rynku efektywnego model ten jest modelem dla procesów stacjonarnych (białych szumów), jakimi są stopy zwrotu. Parametry α_i i β_i można oszacować za pomocą KMNK. Szczególną interpretację finansową ma parametr β_i , który mierzy wrażliwość stopy zwrotu z danej akcji (lub portfela akcji) na jednostkową zmianę wartości portfela rynkowego:

- $\beta_i = 1$ — ryzyko inwestycji w i -ty papier wartościowy jest identyczne z ryzykiem rynkowym; papier neutralny,
- $\beta_i > 1$ — ryzyko inwestycji w i -ty papier wartościowy jest większe od ryzyka rynkowego; papier agresywny,
- $0 < \beta_i < 1$ — ryzyko inwestycji w i -ty papier wartościowy jest mniejsze od ryzyka rynkowego; papier defensywny,
- $\beta_i = 0$ — brak jakiegokolwiek ryzyka w inwestycji na rynku finansowym,
- $\beta_i < 0$ — stopa zwrotu danej spółki ma tendencję odwrotną do pozostałych.

Model Sharpe'a może być wykorzystany do prognozowania cen akcji na podstawie czynnika rynku, reprezentowanego przez portfel rynkowy (indeks rynku), jeżeli oczywiście możliwe jest ustalenie prognozy dla zmiennej objaśniającej. Z punktu widzenia interpretacji o wiele ciekawsze jest zastosowanie tego modelu do oceny ryzyka inwestycyjnego oraz do budowy portfeli akcji. Konstrukcja portfeli papierów wartościowych jest opisana w wielu publikacjach (np. Elton, Gruber [1995], Tarczyński [2001] i [2002], Jajuga, Jajuga [2001], Milo [2002]).

Przykład 7.3

Oszacowano jednowskaźnikowy model dla tygodniowych stóp zwrotu z akcji wybranych banków obserwowanych w okresie 4.01.1995–17.09.2003. Otrzymane wyniki przedstawiono w tablicy 7.3.

Tablica 7.3. Oceny parametrów modelu Sharpe'a

Spółka	Ocena α	Ocena β	R^2	$Q^*(8)$	ARCH(8)
BIG-BG	-0,0010	1,185	0,341	8,922	10,050*
BRE	0,0003	0,961	0,354	4,387	1,733
BSK	0,0002	0,006	0,436	11,999	1,119
Kredybank	-0,0013	0,810	0,338	17,128*	1,816

* Odrzucenie hipotezy zerowej.

Źródło: Opracowanie własne.

Wszystkie oceny parametru β okazały się statystycznie istotne. Jak widać, spółki defensywne to BRE i Kredybanku, spółką neutralną jest BSK oraz spółką agresywną — BIG-BG. Warto podkreślić, że reszty na ogół nie zawierają autokorelacji (poza Kredybankiem) oraz efektu ARCH (poza BIG-BG). Jest to zjawisko typowe dla tygodniowych stóp zwrotu.

7.3.2. Model wyceny arbitrażowej

Model wyceny arbitrażowej (APM — *arbitrage pricing model*)⁶ jest jednym z modeli równowagi rynku kapitałowego. Opiera się na dwóch założeniach: 1) obowiązują prawo jednej ceny i arbitraż oraz 2) stopy zwrotu z akcji kształtują się zależnie od czynników rynkowych. Pierwsze mówi, że jeden instrument finansowy na różnych rynkach powinien mieć tę samą cenę, bowiem w przeciwnym wypadku pojawiają się arbitrażyści z kapitałem spekulacyjnym. Arbitraż polega na wykorzystaniu różnicy cen: kupowaniu po niższej cenie na jednym rynku i jednoczesnym sprzedawaniu po wyższej cenie na innym. Pojawienie się arbitrażystów powoduje w praktyce wzrost ceny poprzez napędzenie popytu na rynek z niższą ceną. Z kolei zwiększona podaż na rynku z wyższą ceną powoduje spadek ceny. Konsekwencje są zatem takie, że możliwość spekulacyjna trwa krótko i w rezultacie całej sytuacji ceny się wyrównują. Arbitraż zakłada, że w praktyce różnice cenowe wyrównują się natychmiast.

Drugie założenie umożliwia przedstawienie wartości stóp zwrotu za pomocą modelu składającego się z dwóch równań wieloczynnikowych. Wartości teoretyczne uzyskane z oszacowanych modeli, opartych na czynnikach rynkowych, pozwalają ustalić stopy zwrotu w warunkach równowagi. Daje to w efekcie możliwość oceny niedoszacowania lub przeszacowania poszczególnych akcji (por. Jajuga, Jajuga [2001]).

Pierwsze równanie modelu APM ma wieloczynnikową postać:

$$R_{it} = \alpha_i + \beta_1 F_{1t} + \beta_2 F_{2t} + \dots + \beta_k F_{kt} + u_{it}, \quad (7.28)$$

gdzie:

R_{it} — stopa zwrotu z akcji i lub z i -tego portfela akcji,

k — liczba czynników,

F_i — i -ty czynnik ryzyka, $i = \{1, 2, \dots, k\}$,

β_i — współczynnik wrażliwości stopy zwrotu akcji względem i -tego czynnika, $i = \{1, 2, \dots, k\}$,

u_i — składnik losowy.

Parametry modelu (7.28) estymuje się za pomocą klasycznej MNK. Dla stóp zwrotu poszczególnych akcji uzyskuje się zatem oceny współczynników wrażliwości na te same czynniki rynkowe. Następnie uzyskane współczynniki wrażliwości służą

⁶ W literaturze spotyka się równoważny termin: teoria arbitrażu cenowego (*arbitrage pricing theory* — APT).

jako zmienne objaśniające do właściwego równania APM, które przedstawia się następująco:

$$E(R_i) = \lambda_0 + \lambda_1 \beta_1 + \lambda_2 \beta_2 + \dots + \lambda_k \beta_k. \quad (7.29)$$

Powyższe równanie przedstawia zależność wartości stopy zwrotu (pojedynczej akcji lub portfela) od współczynników wrażliwości na określone czynniki rynkowe (czynniki ryzyka). Znalezienie wartości współczynników λ jest możliwe za pomocą kilku metod. Jedną z ich jest analiza czynnikowa (por. Kuziak [1999]). W przykładzie 7.3 została zastosowana klasyczna metoda najmniejszych kwadratów, pozwalająca na potraktowanie równania (7.29) jako równania regresji (por. Cuthbertson [1997]). Na podstawie modelu APM można wyciągnąć wnioski dotyczące bieżącej wyceny rynkowej akcji. Jeżeli spodziewana stopa zwrotu jest równa stopie zwrotu obliczonej za pomocą modelu APM, to znaczy, że akcja jest dobrze wyceniona. Jeśli okazałoby się, że spodziewana stopa zwrotu jest wyższa niż obliczona z modelu, to będzie oznaczało, że stopa z modelu jest niedowartościowana, gdy natomiast obliczenia dadzą wyższą wartość, wówczas stopa teoretyczna z modelu jest przewartościowana.

Przykład 7.4

Na podstawie tygodniowych stóp zwrotu wybranych akcji obserwowanych w latach 2001–2002 obliczono współczynniki wrażliwości (bety) na dwa czynniki rynkowe, tj. WIG i WIBOR 1M. Czynniki te mają w założeniu przedstawiać ogólną tendencję rynkową (WIG) oraz stopy procentowe (WIBOR 1M). Następnie obliczone dla poszczególnych akcji współczynniki wrażliwości posłużyły do drugiej części modelu APM jako zmienne objaśniające. Oszacowana funkcja regresji liniowej (7.29) jest następująca:

$$E(R) = 0,0041 - 0,0057 \beta_1 - 0,0061 \beta_2.$$

(0,0017) (0,0032)

Wartość $\lambda_0 = 0,0041$ obrazuje tzw. stopę zwrotu wolną od ryzyka. Ponieważ jest to wartość tygodniowa, można uznać, że jest ona właściwa. Mając oszacowany model APM oraz wartości teoretyczne średnich stóp zwrotu z poszczególnych akcji obliczone z modelu, możemy porównać je do empirycznych wartości stóp zwrotu po ostatnim notowaniu. Na tej podstawie określimy, czy dana akcja jest przez model przeszacowana, czy niedoszacowana. Ogólna zasada APM głosi, że jeżeli model przeszacowuje akcję, to na najbliższych notowaniach można się spodziewać wzrostu stopy zwrotu; takie akcje należy zatem kupować. W przypadku gdy porównanie wykazuje niedoszacowanie przez model, można się spodziewać spadku stopy zwrotu, co sugeruje, że dana akcja nie jest bezpieczna.

W tablicy 7.4 zostało przedstawione niedoszacowanie i przeszacowanie akcji, których przewidywana stopa zwrotu jest dodatnia. Wśród 41 badanych spółek akcji o przewidywanej dodatniej stopie zwrotu jest 23, z czego model niedoszacowuje 10,

Tabela 7.4. Wyniki wyceny akcji wybranych spółek według modelu APM

Spółka	Średnia stopa zwrotu	β_1 (WIG)	β_2 (WIBOR 1M)	Przewidy- wana stopa zwrotu	Stopa z ostatniego notowania	Odczylenie APM	Wycena
Agora	-0,00073	1,6547	0,0865	-0,0059	-0,00292	0,0030	—
Apator	0,00413	0,5245	-0,2443	0,0026	0,00000	-0,0026	przesz.
Handlowy	0,00396	0,1993	-0,2061	0,0042	-0,05225	-0,0565	przesz.
BPH	0,00118	0,7969	-0,0893	0,0001	-0,03070	-0,0308	przesz.
BRE	0,00131	0,9163	-0,2492	0,0004	-0,02963	-0,0300	przesz.
Comarch	-0,00134	1,7465	0,2632	-0,0075	-0,07018	-0,0627	—
Debiec	0,00474	0,6950	0,0369	-0,0001	0,00000	0,0001	—
Fortis	0,00019	0,0158	0,2661	0,0024	0,15175	0,1493	niedosz.
Swiecie	0,00695	0,5514	-0,1201	0,0017	0,03051	0,0788	niedosz.
Indykpol	-0,00218	0,1034	0,2195	0,0022	0,03586	0,0337	niedosz.
INGBSK	0,00486	0,1962	-0,0868	0,0035	-0,07197	-0,0755	przesz.
InteriaPL	-0,00525	2,8467	-0,4583	-0,0094	-0,06637	-0,0569	—
Jelfa	0,00735	0,3654	0,0692	0,0016	0,04762	0,0460	niedosz.
Jutrzenka	0,00963	0,7797	0,0919	-0,0009	-0,02055	-0,0196	—
Kable	-0,00554	0,1957	0,2079	0,0017	0,01105	0,0093	niedosz.
Kety	0,00414	0,3612	0,2035	0,0008	0,06183	0,0610	niedosz.
LG Petro	0,00699	0,4087	0,6172	-0,0020	-0,00606	-0,0041	—
Macrosol	-0,01025	1,5733	-0,1190	-0,0042	-0,04483	-0,0406	—
Mennica	0,00568	0,3040	0,4667	-0,0005	-0,00437	-0,0039	—
Mieszko	0,00131	-0,0017	-0,2889	0,0059	-0,06286	-0,0687	przesz.
Mostostal War	-0,00730	0,7844	-0,1531	0,0005	0,01931	0,0188	niedosz.
Mostostal Zab	-0,00495	0,9194	0,0852	-0,0017	-0,03409	-0,0324	—
Nafta	-0,01122	0,5505	-0,8348	0,0060	-0,07563	-0,0817	przesz.
Netia	-0,03759	3,4323	0,5944	-0,0192	-0,03927	-0,0201	—
Okocim	0,00320	0,9571	0,3568	-0,0035	0,01310	0,0166	—
Optimus	-0,03227	1,2771	1,3291	-0,0113	-0,04661	-0,0353	—
Orbis	0,00054	1,3919	-0,1286	-0,0031	-0,00840	-0,0053	—
Pekao	0,00780	0,8581	-0,0409	-0,0006	-0,02597	-0,0254	—
Polfa Kut	0,01728	0,3539	0,0232	0,0019	0,04839	0,0464	niedosz.
Polifarb Cie	-0,00127	1,1158	0,1343	-0,0031	-0,01942	-0,0163	—
Prokom	0,00222	2,0008	0,0664	-0,0078	0,02190	0,0297	—
Prosper	0,00006	0,4743	0,0831	0,0009	-0,02381	-0,0247	przesz.
Softbank	-0,00533	2,1950	-0,0249	-0,0083	0,03400	0,0423	—
Sokolow	0,00596	1,3065	-0,1361	-0,0026	0,00995	0,0125	—
Stomil	0,00381	0,2647	-0,1829	0,0037	-0,03516	-0,0389	przesz.
Swarzedz	-0,00639	0,3533	-0,0461	0,0024	0,00806	0,0057	niedosz.
Szeptel	-0,00039	0,0528	-0,3014	0,0056	-0,03488	-0,0405	przesz.
Tonsil	-0,01234	-0,0752	-0,5518	0,0079	-0,13008	-0,1380	przesz.
Wawel	0,00648	0,1575	0,1553	0,0023	0,01425	0,0120	niedosz.
Wolczanka	0,00205	0,8138	-0,3961	0,0019	-0,04721	-0,0491	przesz.
Zywiec	0,00607	0,2313	-0,3709	0,0050	-0,01250	-0,0175	przesz.

Źródło: L. Sygula, Ocena ryzyka inwestowania w akcje notowane na GPW w Warszawie, praca magisterska napisana pod kierunkiem M. Osińskiej, UMK, Toruń 2002.

a przeszacowuje 13. Analiza autokorelacji składnika resztowego za pomocą testu⁷ DW wykazała, że w 27 przypadkach autokorelacja reszt rzędu pierwszego nie występuje, w jednym występuje słaba, dodatnia autokorelacja, natomiast w 13 przypadkach test DW nie rozstrzyga problemu.

Racjonalne błędy spekulacyjne

Zalóżmy, że cenę instrumentu finansowego (akcji, obligacji, kursu walutowego) p_t można wyrazić w postaci modelu z racjonalnymi oczekiwaniami:

$$p_t = \delta E(p_{t+1} | \Omega_t) + \delta E(x_{t+1} | \Omega_t), \quad (7.30)$$

przy czym $\delta = 1/(1+r)$,

gdzie:

r — stopa procentowa,

x_t — zmienne egzogeniczne mające wpływ na cenę.

Zgodnie z koncepcją racjonalnych oczekiwań wartość oczekiwaną p_{t+1} , x_{t+1} wyznacza się warunkowo względem całego dostępnego zbioru informacji w okresie t i w przeszłości Ω_t (por. Osińska [2000]).

Rozwiązanie modelu (7.30) ze względu na p_t — poprzez sekwencyjne podstawianie — jest następujące:

$$p_t = \sum_{i=0}^n \delta^{i+1} E(x_{t+i} | \Omega_t) + \delta^n E(p_{t+n} | \Omega_t). \quad (7.31)$$

Przyjmując graniczny warunek, że drugi składnik sumy w (7.31) dąży do 0 przy $n \rightarrow \infty$ oraz dalej, że⁸ $E(x_{t+i} | \Omega_t) = x_t$, otrzymujemy następującą wersję modelu (7.30):

$$p_t = \delta x_t + \delta E(p_{t+1} | \Omega_t). \quad (7.32)$$

Gdy w równaniu (7.31) przyjmiemy warunek graniczny postaci:

$$\lim_{n \rightarrow \infty} \delta^n E(p_{t+n} | \Omega_t) = 0, \quad (7.33)$$

wówczas $p_t = p_t^f$, gdzie p_t^f jest jedynym rozwiązaniem, znanym jako *rozwiązanie fundamentalne*, t.j.:

$$p_t^f = \sum_{i=1}^{\infty} \delta^{i+1} E(x_{t+i} | \Omega_t). \quad (7.34)$$

⁷ Stosowanie tego testu jest uzasadnione, ponieważ w modelu nie występuje opóźniona zmienna zależna.

⁸ Warunek ten oznacza, że proces x_t jest martyngałem.

Dopuszcza się niespełnienie warunku (7.33), w wyniku czego istnieje wiele możliwych rozwiązań dla równania (7.31). Zatem można zapisać, że dowolne p_t spełnia równanie:

$$p_t = p_t^f + B_t, \quad (7.35)$$

przy czym:

$$E(B_{t+1} | \Omega_t) = \delta^{-1} B_t = (1+r) B_t. \quad (7.36)$$

Ponieważ (7.35) jest jednocześnie rozwiązaniem modelu z racjonalnymi oczekiwaniami, stąd B_t jest określane jako *racjonalny bąbel*, przy czym r oznacza stałą realną stopę zwrotu wymaganą przez inwestorów. W przypadku racjonalnego bąbla spekulacyjnego zachodzą następujące cechy rynku słabo efektywnego:

- inwestorzy nie przestają wykorzystywać całej dostępnej informacji w celu przewidywania cen i stóp zwrotu,
- błąd prognozy jest niezależny od posiadanej informacji (tzn. zachodzi własność ortogonalności racjonalnych oczekiwań),
- zarówno bąbel, jak i informacje co do przyszłych wartości dywidendy są zawarte w cenie i w tym sensie bąbel spełnia wymogi gry fair.

Racjonalny bąbel może być opisany przez następujący model (zob. Blanchard, Watson [1982] i West [1987]):

$$B_t = \begin{cases} (B_{t-1} - \bar{B})/\pi\delta & \text{z prawdopodobieństwem } \pi, \\ \bar{B}/(1-\pi)\delta & \text{z prawdopodobieństwem } 1-\pi, \end{cases} \quad (7.37)$$

dla $0 < \pi < 1$, $\bar{B} > 0$. Należy zauważyć, że w (7.37) bąbel B_t spełnia własności martynału, a zatem najlepsza prognoza wszystkich przyszłych wartości bąbla zależy tylko od jego bieżącej wartości. Według (7.37) prawdopodobieństwo tego, że bąbel pęknie, wynosi $1-\pi$. Kiedy bąbel się tworzy, to jego wzrost następuje przy stopie $(\delta\pi)^{-1} = (1+r)/\pi > 1+r$. Inwestorzy uzyskują wówczas nadzwyczajne zyski, które kompensują im straty, które pojawiłyby się, gdyby bąbel pękł.

Z (7.36) wynika, że wartość oczekiwana racjonalnego bąbla jest dana jako:

$$E(B_{t+1} | \Omega_t) = (1+r)^t B_t, \quad (7.38)$$

gdyż $r > 0$.

Inny model proponują Diba i Grossman [1988]:

$$B_t = \theta B_{t-1} + \varepsilon_t, \quad (7.39)$$

przy czym θ i ε_t są wzajemnie niezależne i nie zawierają autokorelacji. Zakładając $\theta \sim N(\bar{\theta}, \sigma_\theta)$, można wskazać na podobieństwo tego procesu do procesu STUR (por. Charemza [1994]), omawianego w rozdziale 5.

Warunki niezbędne, aby mógł zajść racjonalny bąbel (dodatni), podali Diba i Grossman [1988]:

- niewielkie znaczenie procesów fundamentalnych dla danego rynku,
- niewielkie prawdopodobieństwo, że bąbel stanie się wyjątkowo duży,
- jeżeli dany bąbel nie istnieje w czasie t , to nie może się on zacząć w czasie $t+i$ ($i > 0$); jeżeli bąbel istnieje, to musiał on powstać w czasie $t=0$, tzn. pierwszego dnia notowań tego waloru,
- jeżeli istnieje bąbel w cenie akcji, to akcja ta jest stale przeszacowywana w stosunku do rynku.

Weryfikacja racjonalnych bąbli. Sprawdzając hipotezę o bąblach spekulacyjnych, analizuje się, na ile aktualna cena instrumentu finansowego odbiega od ceny fundamentalnej. Jeden z zaproponowanych testów (Diba, Grossman [1988]) opiera się na badaniu długookresowej zależności między procesami cen instrumentów finansowych a procesami fundamentalnymi. W celu ekonometrycznej weryfikacji korzysta się z pojęcia kointegracji procesów stochastycznych omówionego w podrozdziale 7.2. Okazuje się, że takie podejście może dać tylko przybliżoną informację na temat bąbli spekulacyjnych (por. Charemza [1994]). Jedną z propozycji jest zastosowanie symulacji do szacowania parametrów modelu postaci (7.35) zawierającego bąbel spekulacyjny, np.:

$$p_t = p_t^f + \phi B_t + u_t, \quad (7.40)$$

gdzie:

$$p_t^f = f(x_t, \alpha),$$

B_t — proces Diba-Grossmana (7.38),

u_t — składnik losowy.

Generujemy wielokrotnie realizację procesu (7.39) i podstawiamy do równania (7.40). Za każdym razem szacujemy model (7.40), w wyniku czego otrzymujemy ciąg oszacowań parametru ϕ . Obliczamy średnią z tych ocen:

$$\hat{\phi} = \frac{1}{n} \sum_{i=1}^n \phi_i, \quad (7.41)$$

gdzie ϕ_i oznacza ocenę parametru otrzymaną w i -tej symulacji. Statystyką służącą do weryfikacji hipotezy, że nie mamy do czynienia z bąblem spekulacyjnym, czyli: $H_0: \phi = 0$, jest:

$$z[t(\phi)] = \frac{p[t(\phi)] - \alpha}{\sqrt{\frac{\alpha(1-\alpha)}{n}}}, \quad (7.42)$$

gdzie $p[t(\phi)]$ jest udziałem przypadków w ogólnej liczbie symulacji, kiedy statystyka t -Studenta dotycząca parametru ϕ jest istotna przy poziomie istotności α .

Statystyka $z[t(\varphi)]$ dla dużych n posiada rozkład normalny $N(0, 1)$ (por. Charemza [1994]).

Do zbadania występowania bąbla spekulacyjnego można, korzystając z najnowszej metodologii, użyć testów na stochastyczne pierwiastki jednostkowe, które zostały omówione w rozdziale 5.

Empiryczna weryfikacja bąbli spekulacyjnych. Historia światowych rynków kapitałowych dostarcza wielu przykładów spekulacji cenowych powodujących nagły, niezwiązany z koniunkturą wzrost cen akcji niektórych firm bądź cen towarów na giełdach towarowych. Należą do nich m.in.:

- Znaczne wzrosty cen oraz następujące po nich załamania kursów akcji notowanych na NYSE w latach 20. oraz 80. XX wieku. Santoni i Dwyer Jr. [1990] porównali wielkie krachy giełdowe lat 1924–1929 i 1982–1987, znajdując mimo upływu czasu wiele analogii. W obydwu przypadkach indeks Dow-Jones spadł o ponad 20%. Znaczenie bąbli, czyli odchyleń cen od poziomu wynikającego z procesów fundamentalnych, jest duże, ponieważ rzutują one na politykę oszczędnościową oraz stabilizacyjną państwa. Opisane wyżej wydarzenia miały również określone konsekwencje legislacyjne.

- W Polsce przełomu lat 80. i 90. XX w. bąbel cenowy zaobserwowany i potwierdzony w badaniach empirycznych dotyczył wolnorynkowego kursu dolara amerykańskiego (por. Charemza [1990]). Sytuacja na polskim rynku walutowym była w analizowanym okresie niejednoznaczna, gdyż obok oficjalnego rynku walutowego, reprezentowanego przez nowo powstałe kantory, nadal funkcjonował obieg tzw. czarnorynkowy.

Przykład 7.5

Bąble spekulacyjne mogą pojawić się na każdym rynku finansowym. W polskiej rzeczywistości lat 90. można było zaobserwować kilka przykładów wzrostów cen akcji niepokrywających się z procesami fundamentalnymi. W związku z ograniczeniami analizy wynikającymi z:


- krótkiego okresu działalności WGPW,
 - nie w pełni wykształconych zwyczajów giełdowych, znajdujących wyraz m.in. w ograniczeniu dziennego wahanía cen,
 - niewielkiego znaczenia dywidendy,
- uzyskane wyniki należy traktować jako symptomy bąbli, a nie jako ich jednoznaczne potwierdzenie.

Badaniu podlegałyienne notowania następujących walorów:

- Bank Śląski w okresie 30.01.1995–30.12.1997,
- Polfa Kutno w okresie 8.12.1995–30.07.1998,
- Universal w okresie 30.01.1995–28.07.1998,
- Żywiec w okresie 8.11.1996–28.07.1998.

Na rysunku 7.3 zostały przedstawione dwa spośród badanych szeregów cen.

Rysunek 7.3. Szeregi cen BSK i Polfy Kutno w badanym okresie



Źródło: Opracowanie własne.

Jako proces fundamentalny przyjęto międzybankową stopę procentową (WIBOR 3M). Na podstawie badania przeprowadzonego za pomocą testów Dickeya i Fullera (DF i ADF) stwierdzono, że wszystkie ceny akcji oraz wartości WIBOR 3M były zintegrowane rzędu 1, co pozwoliło na testowanie kointegracji $CI(1, 1)$ tych procesów.

Równanie kointegrujące dla par procesów miało następującą postać:

$$p_{it} = \hat{\mu} + \hat{\beta}x_t + v_t,$$

gdzie:

- p_{it} — logarytm ceny danego waloru w badanym okresie,
- x_t — proces fundamentalny,
- $\hat{\mu}, \hat{\beta}$ — estymatory KMNK parametrów równania,
- v_t — stacjonarny proces resztowy.

Wyniki analizy kointegracji cen oraz procesów fundamentalnych za pomocą testów DF i ADF zawiera tablica 7.5

Tablica 7.5. Wyniki testowania bąbli spekulacyjnych na WGPW

Nazwy procesów	DF/DW	ADF/DW
BŚK — WIBOR 3M	DF = -0,57	ADF = -1,77
Wektor kointegrujący	DW = 0,33	DW = 1,98
[1 -642,79 18,05]	N = 725	N = 724
POLFA Kutno — WIBOR 3M	DF = -4,49	ADF = -2,43
Wektor kointegrujący	DW = 0,45	DW = 2,30
[1 15,21 -4,28]	N = 652	N = 651
UNIVERSAL — WIBOR 3M	DF = 1,53	ADF = -1,70
Wektor kointegrujący	DW = 0,14	DW = 1,91
[1 -6,30 -0,080]	N = 867	N = 866
ŻYWIEC — WIBOR 3M	DF = -1,00	ADF = -2,43
Wektor kointegrujący	DW = 0,15	DW = 2,30
[1 -487,29 0,013]	N = 499	N = 498

Źródło: P. Przytylski, *Testowanie racjonalnych bąbli spekulacyjnych na przykładzie GPW*, w: *Warczawie*, praca dyplomowa napisana pod kierunkiem M. Osińskiego, UMK, Toruń 1999.

Wyniki zamieszczone w tablicy potwierdzają brak kointegracji procesów cenowych i fundamentalnych. Można to uznać za symptom bąbli spekulacyjnych w analizowanych cenach akcji.

7.5. Porównywanie modeli niezagnieżdżonych

W niniejszym rozdziale zajęliśmy się omawianiem budowy różnych jednorównaniowych modeli regresji służących jako narzędzie opisu finansowych szeregów czasowych. Powstaje jednak problem, która ze specyfikacji jest lepsza, która ma przewagę nad konkurencyjną. Rozstrzygnięcie tego problemu na gruncie teoretycznym jest łatwiejsze niż na gruncie empirycznym. W przypadku budowy modeli ekonometrycznych często mamy do czynienia z alternatywnymi modelami o dobrych własnościach statystycznych i interpretacyjnych. Powstaje zatem pytanie, który z modeli wybrać. Jedną z metod porównywania alternatywnych modeli dla tego samego procesu objaśnianego są testy oparte na koncepcji obejmowania (*encompassing*) przez dany model specyfikacji modelu konkurencyjnego, który z założenia musi być niezagnieżdżony. Istota tego zagadnienia nie jest wprowadzić równoważną pełnej dominacji jednego modelu nad drugim, jednakże często w tym właśnie sensie jest wykorzystywana. Wobec braku praktycznej możliwości jednoznacznego określenia, że dany model dominuje nad innym (bądź innymi) w sensie ogólnym, wyróżnia się najczęściej następujące sfery dominacji danej specyfikacji modelu: w zakresie wariancji, w zakresie parametrów oraz w zakresie własności prognostycznych.

Rozważmy następujące hipotezy modelowe:

$$H_1: y_t = \phi' z_t + \varepsilon_t, \quad (7.43)$$

gdzie $E_{\varepsilon_t}(z_t \varepsilon_t) = 0$ oraz $\varepsilon_t \sim IN(0, \sigma_\varepsilon^2)$,

$$H_2: y_t = \delta' w_t + v_t, \quad (7.44)$$

gdzie $v_t \sim IN(0, \sigma_v^2)$.

$H_1 D H_2$ oznacza, że model (7.43) dominuje nad modelem (7.44), zaś $H_2 D H_1$ oznacza, że model (7.44) dominuje nad modelem (7.43). Symbol D oznacza dominację jednego modelu nad drugim. W literaturze angielskojęzycznej spotykamy ε , co oznacza *encompassing*, czyli obejmowanie. Testowanie powyższych hipotez nie zawsze prowadzi do jednoznacznych rozstrzygnięć. W literaturze można znaleźć wiele testów dotyczących adekwatności niezagnieżdżonych specyfikacji modeli ekonometrycznych (por. np. Chow [1995], Charemza, Deadman [1997]). Jednym z prostszych jest test J , zaproponowany przez Davidsona i MacKinnona [1981].

Test J odpowiada sytuacji, kiedy badamy dominację (obejmowanie) modeli w zakresie wariancji, tzn. stawiamy pytanie, czy wariancja błędu w modelu drugim może być wyjaśniona przez model pierwszy, i odwrotnie.

Niech modele rywalizujące mają postaci:

$$H_1: y_t = \alpha x_t + \varepsilon_t, \quad (7.45)$$

$$H_2: y_t = \beta z_t + \eta_t. \quad (7.46)$$

Test J polega na zbadaniu, czy model H_2 jest prawdziwy, a kolejne etapy obliczeń są następujące:

1. Szacujemy parametr β w modelu (7.46) i obliczamy wartości teoretyczne $\hat{y}_t = \hat{\beta} z_t$.

2. Następnie szacujemy parametry równania:

$$y_t = \alpha x_t + \gamma \hat{\beta} z_t + \varepsilon_t.$$

3. Ocena, czy model określony w H_2 dominuje nad modelem danym w H_1 jest równoznaczna ze zbadaniem, czy parametr γ jest statystycznie istotny w sensie np. testu t -Studenta.

Badanie, czy model (7.45) dominuje nad (7.46), jest analogiczne. Powyższa procedura może zostać rozszerzona na dowolną liczbę zmiennych objaśniających, a także na modele nieliniowe.

Pytania i problemy

1. Wyjaśnij pojęcie modelowania od ogółu do szczegółu.
2. Specyfikacja modeli dla procesów stacjonarnych.
3. Na czym polega konstrukcja modelu zgodnego?
4. Warunki kointegracji procesów stochastycznych.
5. Jakie są cechy i konsekwencje regresji pozornej?
6. Testowanie kointegracji.
7. Na czym polega budowa modelu korekty błędem?
8. Jak zbudować model korekty błędem dla trzech procesów zintegrowanych rzędu 1?
9. Na czym polega znaczenie pojęcia kointegracji w ekonometrii finansowej?
10. Zaproponuj specyfikację jednorównaniowego modelu ECM dla:
 - rynkowej ceny obligacji,
 - rynkowej ceny akcji wybranej spółki.
11. Istota modelu Sharpe'a.
12. Ekonometryczne aspekty modelu wyceny arbitrażowej.
13. Na czym polega wykorzystanie modelu APM do wyceny akcji?
14. Wyjaśnij pojęcie bąbli spekulacyjnych. W jaki sposób powstaje bąbel?
15. Podaj przykłady znanych Ci procesów spekulacyjnych.
16. Na czym polega porównywanie modeli niezagnieżdżonych?

Analiza wielowymiarowych szeregów czasowych

Słowa kluczowe: modele VAR, VARMA, przyczynowość, kointegracja, model VEC, analiza odpowiedzi na impuls, reprezentacja spektralna wielowymiarowych szeregów czasowych

Przesłanki rozważania modeli wielowymiarowych szeregów czasowych w analizach finansowych leżą w globalizacji rynków, przez którą należy rozumieć proces wzmacniania się światowych powiązań we wszystkich aspektach współczesnego życia politycznego, społecznego, ekonomicznego i kulturowego. Procesy te były widoczne na rynkach finansowych w latach osiemdziesiątych i dziewięćdziesiątych XX w., kiedy nastąpiło otwarcie światowych giełd papierów wartościowych. Sprzyjały temu m.in. zastosowanie informatyki w operacjach kapitałowych i przyspieszenie obrotów, a zarazem zwiększenie płynności rynków finansowych, liberalizacja przepisów finansowych oraz znaczny wzrost kapitalizacji i wolumenu transakcji giełdowych.

Rozpatrywane modele opisują zależności między różnymi, często pozornie niepowiązanymi między sobą zjawiskami, a także są narzędziem weryfikacji tych powiązań. Sytuacja na rynkach finansowych wymaga umiejętności kojarzenia bardzo różnych zjawisk występujących często w pewnych odstępach czasu. Obserwuje się bowiem zjawisko przenoszenia się w czasie pozytywnych i negatywnych aspektów funkcjonowania rynków finansowych (a zwłaszcza giełd), zarówno w zakresie wartości oczekiwanej, jak i zmienności. Wielowymiarowym modelom zmienności zostanie poświęcony rozdział następny, natomiast w tym rozdziale będą przedstawione zagadnienia z zakresu modelowania wektorowo-autoregresyjnego dla procesów stacjonarnych, a także zintegrowanych, jak również elementy analizy przyczynowych w celu strukturalizacji modelu VAR. Zagadnienia teoretyczne zostaną zilustrowane przykładami zastosowań.

Reprezentacja modelowa wielowymiarowych procesów stochastycznych

Modele wielowymiarowych procesów stochastycznych zostały wprowadzone do literatury ekonometrycznej jako alternatywa dla modeli strukturalnych, zawierających współzależności między zmiennymi objaśnianymi obserwowanymi w tym samym czasie. Najczęściej były wykorzystywane w skali makroekonomicznej, ale stanowiły również alternatywę dla modeli jednowymiarowych — opisujących pojedyncze zjawiska — w przypadku, gdy należało zbudować model opisujący jednocześnie wiele powiązanych ze sobą zjawisk, jak na przykład sprzedaż firmy i branży, do której należy. Było to ważne zwłaszcza dla prognozowania, gdyż ten cel stawiano głównie modelom procesów stochastycznych.

Podstawowym modelem wielowymiarowych szeregów czasowych stał się model VAR (model wektorowej autoregresji), który należy do szerszej klasy modeli VARMA (wektorowe modele ARMA). Ekonometryczne modelowanie wielowymiarowych szeregów czasowych opiera się na następujących zasadach (Sims [1980]):

- nie istnieje *a priori* żadne rozróżnienie między zmiennymi endogenicznymi i egzogenicznymi,
- nie istnieją żadne uzasadnione ograniczenia co do wartości parametrów modelu, w tym zwłaszcza założenie, że niektóre parametry muszą być równe zero,
- nie istnieje ścisła i pierwotna dla modelowania teoria ekonomiczna, na podstawie której model jest budowany.

Powyższe zasady stały się podstawą ateoretycznego podejścia do modelowania ekonometrycznego. Jak zostanie to wykazane poniżej, dotyczy ono tylko podstawowego modelu VAR.

Reprezentacja VAR. Podstawowy model VAR ma postać:

$$z_t = \sum_{i=1}^q A_i z_{t-i} + \varepsilon_t, \quad (8.1)$$

gdzie:

- z_t — kolumnowy wektor obserwacji bieżących wartości badanych procesów o wymiarach $N \times 1$,
- A_i — macierze autoregresyjnych operatorów poszczególnych procesów, w których *a priori* nie zakłada się żadnych elementów zerowych,
- ε_t — wektor procesów resztowych, w odniesieniu do którego przyjmuje się, że poszczególne składowe są jednocześnie skorelowane ze sobą, ale nie zawierają autokorelacji,
- q — rząd modelu VAR.

Rozważmy jako przykład dwurównaniowy ($N = 2$) model VAR(2), którego postać jest następująca:

$$\begin{bmatrix} z_{1t} \\ z_{2t} \end{bmatrix} = \begin{bmatrix} A_{11,1} & A_{12,1} \\ A_{21,1} & A_{22,1} \end{bmatrix} \begin{bmatrix} z_{1t-1} \\ z_{2t-1} \end{bmatrix} + \begin{bmatrix} A_{11,2} & A_{12,2} \\ A_{21,2} & A_{22,2} \end{bmatrix} \begin{bmatrix} z_{1t-2} \\ z_{2t-2} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{bmatrix}. \quad (8.2)$$

Własności modelu (8.1) są analogiczne do własności jednowymiarowego modelu AR (por. Lütkepohl [1991]), tzn. model ten jest zawsze odwracalny, mając reprezentację wektorowej średniej ruchomej VMA(∞) postaci:

$$z_t = \sum_{i=0}^{\infty} \Psi_i \varepsilon_{t-i},$$

natomiast dla określenia stacjonarności wymagany jest warunek, aby pierwiastki równania wyznacznikowego:

$$|I - A_1 B - A_2 B^2 - \dots - A_q B^q| = 0,$$

gdzie B jest operatorem przesunięcia wstecz, leżały poza okręgiem jednostkowym. Identyfikacji modelu VAR dokonuje się najczęściej na podstawie kryteriów informacyjnych Akaike'a lub Schwarza.

Nietrudno zauważyć, że model VAR jest przykładem postaci zredukowanej modelu wielorównaniowego, ponieważ nie zawiera żadnych jednoczesnych powiązań między zmiennymi endogenicznymi. Powstaje zatem pytanie, czy ekonometrykowi wolno uogólniać jednowymiarowy model autoregresyjny na przypadek wielowymiarowy, chociaż operacja ta jest poprawna pod względem formalnym. Odpowiedź na to pytanie jest oczywiście twierdząca, co uzasadnia wiele pozytywnych przykładów zastosowań tego modelu w praktyce¹. Trzeba jednak wyraźnie zaznaczyć, że wszelkie aplikacje muszą być poparte wiedzą ekonomiczną i nie można polegać wyłącznie na procedurach statystycznych.

Jeśli badane procesy są trendowo-stacjonarne², to komponenty w postaci stałej, deterministycznego trendu lub/i deterministycznej sezonowości mogą addytywnie zostać włączone do modelu, który przybierze wtedy formę:

$$z_t = A_0 D_t + \sum_{i=1}^q A_i z_{t-i} + \varepsilon_t, \quad (8.3)$$

gdzie:

D_t — składnik zawierający średnią procesu, deterministyczny trend lub/i deterministyczną sezonowość,

A_0 — macierz odpowiednich parametrów.

¹ Por. Enders [1995], Churemza, Makarova [1999], Majsterek, Welfe [2000], Kusidel [2000], Welfe, Majsterek [2002].

² Termin ten jest zarezerwowany dla szeregów doprowadzonych do stacjonarności po usunięciu trendu deterministycznego.

Strukturalny model VAR. Przy spełnieniu pewnych założeń modele (8.1) i (8.3) można sprowadzić do postaci strukturalnej³. Zapiszmy model (8.3) jako:

$$z_t = A_0 D_t + A_1 z_{t-1} + A_2 z_{t-2} + \dots + A_q z_{t-q} + \varepsilon_t, \quad (8.4)$$

przy czym $\text{cov}(\varepsilon_{it}, \varepsilon_{jt}) \neq 0$.

Jeżeli jest spełniony warunek niezerowych kowariancji między składnikami losowymi poszczególnych równań, to możliwe jest przeniesienie tych powiązań bezpośrednio na wektor z_t . Model postaci:

$$\Phi z_t = \Gamma_0 D_t + \Gamma_1 z_{t-1} + \Gamma_2 z_{t-2} + \dots + \Gamma_q z_{t-q} + \xi_t, \quad (8.5)$$

gdzie:

Φ — macierz parametrów stojących przy nieopóźnionych wartościach składowych wektora z_t ,

Γ_0 — macierz parametrów przy składnikach deterministycznych,

Γ_i ($i = 1, 2, \dots, q$) — macierze parametrów przy opóźnionych wartościach systemu,

ξ_t — wektor składników resztowych,

będziemy nazywać strukturalnym modelem VAR.

Jeżeli istnieje macierz odwrotna do Φ , to między modelami (8.4) i (8.5) zachodzi następujący związek:

$$z_t = \Phi^{-1} \Gamma_0 D_t + \Phi^{-1} \Gamma_1 z_{t-1} + \Phi^{-1} \Gamma_2 z_{t-2} + \dots + \Phi^{-1} \Gamma_q z_{t-q} + \Phi^{-1} \xi_t. \quad (8.6)$$

Oznaczając:

$$A_0 = \Phi^{-1} \Gamma_0, \quad (8.7)$$

$$A_i = \Phi^{-1} \Gamma_i \quad (i = 1, 2, \dots, q), \quad (8.8)$$

$$\varepsilon_t = \Phi^{-1} \xi_t, \quad (8.9)$$

otrzymujemy model (8.4).

Model VARMA. Naturalnym rozszerzeniem podstawowego modelu VAR, zwłaszcza o wysokim, a nawet nieskończonym rzędzie autoregresji jest reprezentacja VARMA(q, p), która ma postać:

$$z_t = A_0 D_t + A_1 z_{t-1} + A_2 z_{t-2} + \dots + A_q z_{t-q} + \varepsilon_t + M_1 \varepsilon_{t-1} + M_2 \varepsilon_{t-2} + \dots + M_p \varepsilon_{t-p}, \quad (8.10)$$

gdzie M_i ($i = 1, 2, \dots, p$) oznaczają macierze operatorów średniej ruchomej poszczególnych procesów. Postać VARMA pozwala na ograniczenie liczby szacowanych parametrów i umożliwia wnioskowanie podobne jak dla modelu VAR.

³ Postać strukturalna charakteryzuje się tym, że zawiera powiązania między zmiennymi endogenicznymi obserwowanymi w tym samym czasie. Jest ona podstawową formą modelowania wielorównaniowego.

Jeśli część VMA jest odwracalna, to model VARMA(q, p) można zapisać w postaci nieskończonego modelu VAR (∞). Z praktycznego punktu widzenia ważniejsza wydaje się nieskończona postać VMA, która jest czystą lub też kanoniczną postacią modelu VARMA (por. Lütkepohl [1991]), za pomocą której można wyprowadzić funkcję autokowariancyjną wielowymiarowego procesu stochastycznego generowanego przez ten model, a także dokonywać analiz o charakterze strukturalnym.

Model VARX (VARMAX). Model VAR może zawierać zmienne egzogeniczne działające na wszystkie lub na niektóre zmienne systemu. Zmienne objaśniające mogą mieć różny charakter i zawierać zarówno wartości bieżące, historyczne, jak i racjonalne oczekiwania co do przyszłości (por. Lütkepohl [1991], Osińska [2000]).

Analiza strukturalna w modelu VAR

Podstawowy model VAR jest bardzo ogólny i może nie być właściwy dla konkretnej sytuacji ekonomicznej. Wynika to z jednej strony z konieczności szacowania dużej liczby parametrów, a z drugiej z dążenia badacza do wykrycia bądź potwierdzenia prawidłowości gospodarczych. Procedury dostosowawcze polegają na testowaniu ograniczeń na parametry.

Badanie zależności przyczynowych opisywanych przez model VAR

Odpowiedź na pytanie, czy zależności przyczynowe procesów ekonomicznych mogą być wykrywane w drodze weryfikacji hipotez, jest niejednoznaczna. W powszechnie akceptowanym pojęciu (por. Zieliński [1991], Osińska [1994]) zależność przyczynową charakteryzują następujące cechy: obiektywność, powtarzalność i siła sprawcza. Jeżeli natomiast związek przyczynowy będziemy rozpatrywać jako relację, to jej najważniejszymi cechami są: przeciwzrotność, asymetryczność i przechodniość. Cechy, które mogą być wykryte w drodze obserwacji, to powtarzalność oraz asymetryczność. Omawiane w dalszej części rozdziału testy przyczynowości mogą być wykorzystane z jednej strony jako narzędzia weryfikacji teorii ekonomicznej, a z drugiej jako narzędzia wykrywania zależności przyczynowych w przypadkach, o których teoria wypowiada się w niewielkim stopniu lub w ogóle milczy.

Pierwszym spośród testów prowadzących do ekonomicznej interpretacji modeli VAR jest test przyczynowości. Należy podkreślić, że test ten określa jedynie przyczynowość w sensie Grangera (por. np. Osińska [1994], Charemza, Daedman [1997]), którą — jak zobaczymy poniżej — należy rozumieć w kontekście korelacji między badanymi procesami ekonomicznymi, zatem decyzję o tym, czy badana

relacja ma charakter przyczynowy, podejmuje badacz na podstawie wiedzy i doświadczenia. Istota testowania przyczynowości procesów ekonomicznych sprowadza się do operacyjnego zastosowania definicji przyczynowości w sensie Grangera.

Pojęcie przyczynowości w sensie Grangera. Niech $A_t = \{X_t, Y_t\}$ będzie zbiorem procesów stochastycznych stacjonarnych w szerszym sensie. Niech $A'_t = \{A_{t-j}, j = 1, 2, \dots, \infty\}$ oznacza odpowiednie wartości tych procesów pochodzące z przeszłości, natomiast $A''_t = \{A_{t-j}, j = 0, 1, 2, \dots, \infty\}$ zawiera dodatkowo ich wartości bieżące. Oznaczenia X'_t, Y'_t, X''_t, Y''_t są analogiczne do oznaczeń A'_t i A''_t . Oznaczmy dalej przez $P(A_t | B_t)$ nieobciążony predyktor wartości A_t wyznaczony metodą najmniejszych kwadratów warunkowo względem ciągu wartości B_t i przez $\sigma^2(A_t | B_t)$ — wariancję błędu predykcji. Niech Ω_t oznacza wszystkie informacje dostępne w czasie t i niech $\Omega_t \setminus X_t$ oznacza te same informacje z wykluczeniem zawartych w procesie X_t .

Definicja 8.1

Jeżeli:

$$\sigma^2(Y_t | \Omega'_t) < \sigma^2(Y_t | \Omega'_t \setminus X'_t), \quad (8.11)$$

to X_t jest przyczyną Y_t .

Definicja 8.2

Jeżeli:

$$\sigma^2(Y_t | \Omega'_t, X''_t) < \sigma^2(Y_t | \Omega'_t), \quad (8.12)$$

to mówimy, że X_t jest jednoczesną przyczyną Y_t .

Definicja 8.3

Jeżeli zachodzi równocześnie:

$$\sigma^2(X_t | \Omega'_t) < \sigma^2(X_t | \Omega'_t \setminus Y'_t) \quad (8.13)$$

oraz:

$$\sigma^2(Y_t | \Omega'_t) < \sigma^2(Y_t | \Omega'_t \setminus X'_t), \quad (8.14)$$

to mówimy, że między procesami X_t i Y_t zachodzi sprzężenie zwrotne.

Definicje 1 i 2 dotyczą jednokierunkowej zależności przyczynowej, tzn. $X_t \rightarrow Y_t$, natomiast definicja 3 opisuje przypadek, kiedy procesy wzajemnie na siebie oddziałują, czyli $X_t \leftrightarrow Y_t$.

Metody testowania przyczynowości obejmują wszystkie trzy aspekty definicji Grangera. Najbardziej dyskusyjna jest kwestia przyczynowości jednoczesnej, gdyż

w tym przypadku nie jest spełniony warunek asymetryczności zależności przyczynowej. W praktyce w celu ustalenia tego warunku można przeprowadzić analizę słabej egzogeniczności jako uzupełnienie badań związku przyczynowego.

Testowanie przyczynowości. W literaturze ekonometrycznej spotyka się dwa główne podejścia do testowania przyczynowości procesów ekonomicznych. Pierwsze z nich nie wymaga określenia postaci modelu ekonometrycznego, gdyż opiera się na analizie współczynników korelacji wzajemnych par procesów. Podejście drugie, reprezentowane przez większość badaczy, odwołuje się do ekonometrycznych modeli procesów stochastycznych jako podstawy konstrukcji testów. W najprostszym przypadku przyjmuje się, że modele te powinny spełniać następujące założenia (por. Geweke, Meese, Dent [1983]):

- modele dotyczą dwóch procesów: procesu-skutku Y_t oraz procesu-przyczyny X_t , które stanowią wszystkie dostępne informacje,
- rozpatrywane procesy Y_t i X_t są procesami stacjonarnymi w szerszym sensie, niedeterministycznymi oraz mają reprezentację autoregresyjną postaci:

$$A(B)Y_t = \varepsilon_{yt},$$

$$B(B)X_t = \varepsilon_{xt},$$

przy czym pierwiastki równań $A(B) = 0$ i $B(B) = 0$ leżą poza okręgiem jednostkowym oraz $E(Y_{t-s}, \varepsilon_{yt}) = 0$ i $E(X_{t-s}, \varepsilon_{xt}) = 0$,

- zależność między badanymi procesami jest liniowa,
- kryterium porównań modeli stanowi średni błąd kwadratowy reszt.

Testowanie przyczynowości w powyższym zakresie jest możliwe w odniesieniu do procesów stacjonarnych. W przypadku procesów niestacjonarnych jest ono dopuszczalne, jeżeli niestacjonarność może być usunięta przez wprowadzenie składowych deterministycznych (trend, sezonowość) lub przez transformację procesów (np. obliczenie przyrostów), jak również w odniesieniu do procesów skointegrowanych. W innych formach niestacjonarności prezentowane podejście może być niewystarczające lub właściwe tylko w przybliżeniu (patrz Lütkepohl [1991]). Uzupełnienia wymaga także pierwsze założenie dotyczące analizy w zakresie tylko dwóch procesów: przyczyny i skutku. Warunek ten należy rozumieć w ten sposób, że jeżeli na dany skutek wpływa więcej niż jedna przyczyna, przy czym wszystkie badane procesy mają stacjonarną reprezentację autoregresyjną, to możliwe jest badanie zależności jednego skutku od wektora przyczyn rozłożonych w czasie.

Rozważmy ogólny model VAR postaci (8.1). W celu zweryfikowania hipotezy strukturalnej o braku zależności przyczynowej podzielmy wektor z_t na dwa podwektory tak, że: $z_t' = [y_t, x_t]'$. Model (8.1) przyjmie wtedy postać:

$$\begin{bmatrix} y_t \\ x_t \end{bmatrix} = \begin{bmatrix} A_{11,1} & A_{12,1} \\ A_{21,1} & A_{22,1} \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \dots + \begin{bmatrix} A_{11,q} & A_{12,q} \\ A_{21,q} & A_{22,q} \end{bmatrix} \begin{bmatrix} y_{t-q} \\ x_{t-q} \end{bmatrix} + \begin{bmatrix} \varepsilon_t \\ \eta_t \end{bmatrix}. \quad (8.15)$$

Hipoteza zerowa mówiąca, że wektor x_t nie jest przyczyną y_t w sensie definicji Grangera, jest spełniona, gdy zachodzi $A_{12,i} = 0$ dla wszystkich $i = 1, 2, \dots, q$. Z kolei, aby y_t nie było przyczyną x_t , potrzeba i wystarcza, żeby $A_{21,i} = 0$ dla wszystkich $i = 1, 2, \dots, q$.

Test Pierce'a-Haughta. Pierwsze podejście do konstrukcji testów przyczynowości oparte na współczynniku korelacji wzajemnej reprezentuje test Pierce'a-Haughta, opublikowany w pracy: Pierce, Haugh [1977]. Praktyczne zastosowanie tego testu można znaleźć m.in. w pracach: Rogalski, Vinso [1977], Osińska [1994], Bruzda [2001].

Rozważmy dwa stacjonarne procesy stochastyczne X_t i Y_t mające stacjonarną i odwracalną reprezentację ARMA. Pierwszym krokiem, który należy wykonać, jest „wybielenie” tych procesów za pomocą odpowiednich filtrów, np. autoregresyjnych, postaci:

$$R_1(B)X_t = \varepsilon_{xt}, \quad (8.16)$$

$$R_2(B)Y_t = \varepsilon_{yt}. \quad (8.17)$$

W wyniku tej operacji otrzymujemy procesy ε_{xt} i ε_{yt} , które — mimo zastosowanych przekształceń liniowych badanych procesów — nie zmieniają charakteru ich zależności przyczynowej. Oznaczmy przez $\rho(k)$ współczynnik korelacji wzajemnej procesów ε_{xt} i ε_{yt} postaci:

$$\rho(k) = \frac{E(\varepsilon_{xt-k}, \varepsilon_{yt})}{[E(\varepsilon_{xt}^2)E(\varepsilon_{yt}^2)]^{0.5}}. \quad (8.18)$$

Na podstawie wartości, jakie przyjmuje $\rho(k)$, można określić typ zależności przyczynowej, np. X_t jest przyczyną Y_t , jeżeli $\rho(k) \neq 0$ dla niektórych $k > 0$, zaś w przypadku sprzężenia zwrotnego $\rho(k) \neq 0$ dla niektórych $k > 0$ i jednocześnie dla pewnych $k < 0$, natomiast niezależność procesów X_t i Y_t jest równoznaczna z tym, że $\rho(k) = 0$ dla wszystkich k .

Estymatorem współczynnika korelacji wzajemnej w próbie jest:

$$r_k = \frac{\sum (\hat{\varepsilon}_{xt-k}, \hat{\varepsilon}_{yt})}{(\sum \hat{\varepsilon}_{xt}^2 \sum \hat{\varepsilon}_{yt}^2)^{0.5}}, \quad (8.19)$$

gdzie $\hat{\varepsilon}_{xt}$ i $\hat{\varepsilon}_{yt}$ oznaczają procesy wyjściowe powstałe z procesów X_t i Y_t w wyniku zastosowania filtrów „wybielających” $R_1(u)$ i $R_2(u)$.

W hipotezie zerowej zakłada się niezależność procesów X_t i Y_t , czyli:

$$H_0: \rho(k) = 0, \quad (8.20)$$

wobec alternatywy, że X_t jest przyczyną Y_t , tzn.:

$$H_1: \rho(k) \neq 0, \quad \text{dla } k > 0. \quad (8.21)$$

Postać testu przyczynowości Pierce'a-Haughla jest dana wzorem:

$$T^{PH} = T \sum_{k=1}^m r_k^2, \quad (8.22)$$

gdzie T oznacza liczebność próby i ma rozkład zbieżny do $\chi^2(m)$. W przypadku testowania alternatywy o przyczynowości jednoczesnej $k = 0, \dots, m$, natomiast dla sprzężenia zwrotnego przyjmuje się $k = -l, \dots, m$.

Test Grangera. Test ten jest oparty na koncepcji modelowej i wynika wprost z definicji przyczynowości. Rozważmy przypadek dwuwymiarowy. Niech:

$$y_t = A(B)y_t + \varepsilon_t, \quad (8.23)$$

$$x_t = \Gamma(B)y_t + B(B)x_t + \eta_t, \quad (8.24)$$

oznaczają modele oszacowane za pomocą klasycznej metody najmniejszych kwadratów, z których pierwszy jest modelem AR(p) dla szeregu y_t , natomiast drugi jest modelem autoregresyjnym z rozłożonymi opóźnieniami zawierającym strukturę

autoregresyjną szeregu x_t , przy czym $B(B) = \sum_{i=1}^q \beta_i \beta^i$.

Hipoteza zerowa dla jednokierunkowej zależności przyczynowej zakłada, że x_t nie jest przyczyną y_t , tzn.:

$$H_0: B(B) = 0, \quad (8.25)$$

co jest równoważne założeniom $\varepsilon_t = \eta_t$ lub $A(B) = \Gamma(B)$.

Załóżmy, że $S^2(\varepsilon_t)$ i $S^2(\eta_t)$ są estymatorami odpowiednich wariancji resztowych w równaniach (8.23)–(8.24). Test Grangera (por. Geweke, Meese, Dent [1983], Osińska [1994]) może być przedstawiony w postaci trzech najczęściej stosowanych wariantów (por. Charemza, Deadman [1997]):

— wariant Walda:

$$T_G^W = \frac{T[S^2(\varepsilon_t) - S^2(\eta_t)]}{S^2(\eta_t)}, \quad (8.26)$$

gdzie T oznacza liczebność próby,

— wariant ilorazu wiarygodności:

$$T_G^{LR} = \frac{T \ln[S^2(\varepsilon_t)]}{S^2(\eta_t)}, \quad (8.27)$$

— wariant mnożnika Lagrange'a:

$$T_G^{LM} = \frac{T[S^2(\varepsilon_t) - S^2(\eta_t)]}{S^2(\varepsilon_t)}. \quad (8.28)$$

Wszystkie powyższe statystyki są asymptotycznie zbieżne do rozkładu $\chi^2(q)$.

Powyższe statystyki mogą być stosowane do dużej próby, co oznacza, że szeregi czasowe powinny mieć co najmniej 100 obserwacji. Dla małej próby mnożenie przez T należy zastąpić mnożeniem przez wyrażenie $(T-k/q)$, co oznacza sprowadzenie statystyk (8.26)–(8.28) do postaci testu $F(q, T-k)$, gdzie q oznacza liczbę parametrów, dla których przyjmujemy wartość zero, T — liczebność próby, zaś k — liczbę wszystkich szacowanych parametrów modelu (8.22).

W przypadku testowania hipotezy o przyczynowości jednoczesnej model (8.24) przyjmuje postać:

$$y_t = \Gamma(B)y_t + B_1(B)x_t + \eta_t, \quad (8.29)$$

przy czym:

$$B_1(B) = \sum_{i=0}^q \beta_i \beta^i.$$

Hipotezę zerową można wówczas zapisać jako $\beta_0 = 0$.

Z kolei, gdy analizowane jest sprzężenie zwrotne między procesami, wówczas oddzielnie należy testować hipotezy: x_t nie jest przyczyną y_t oraz y_t nie jest przyczyną x_t . W tym celu modele (8.22) i (8.23) należy odpowiednio zmodyfikować.

Analiza mocy prezentowanych testów wskazuje na to, że test Grangera w wariancie Walda ma najlepszą moc spośród wszystkich testów Grangera. Z kolei z porównania testów Grangera oraz Pierce'a i Haughla wynika, że w przypadku małych prób lepszym testem okazuje się ten drugi, gdyż nie wymaga szacowania równania regresji i pozwala na większą liczbę stopni swobody (por. Geweke [1981]). Dla dużej próby lepsze własności wykazuje test Grangera w wariancie Walda⁴.

Analiza egzogeniczności w modelu VAR

Kolejnym przybliżeniem modelu (8.1) jest podział zmiennych modelu na endogeniczne i egzogeniczne. Można tego dokonać na podstawie koncepcji Engle'a, Hendry'ego i Richarda [1983]⁵. Problem polega na takim podziale wektora z_t na dwa podwektory, aby procesy resztowe, które powstaną w jego wyniku, były nieskorelowane ze sobą.

Niech łączna funkcja gęstości prawdopodobieństwa modelu (8.1) będzie dana jako:

$$D(z_t | z_{t-i}, \emptyset) = D_1(y_t | y_{t-i}, x_t, \lambda_1) \times D_2(x_t | z_{t-i}, \lambda_2), \quad (8.30)$$

⁴ W przypadku estymacji łącznej modelu VAR można zastosować modyfikację testu Grangera w wariancie Walda zaproponowaną przez Lütkepohla [1991].

⁵ Wyróżnia się trzy rodzaje egzogeniczności, jednakże rodzaj trzeci, tzw. superegzogeniczność, nie wchodzi w zakres omawiany w tym podręczniku; por. Strzała [1994].

gdzie:

$\mathbf{z}'_t = [y_t, x_t]'$, $\mathbf{z}'_{t-i} = [y_{t-i}, x_{t-i}]'$, $\boldsymbol{\theta} = [\lambda_1, \lambda_2]$ — odpowiednie wektory parametrów,
 $D_1(\cdot | \cdot)$ — warunkowa gęstość prawdopodobieństwa procesu y_t ,
 $D_2(\cdot | \cdot)$ — brzegowa gęstość prawdopodobieństwa procesu x_t .

Oznaczmy wszystkie parametry biorące udział w badaniu przez $\boldsymbol{\psi}$. Ze względu na pojęcie egzogeniczności można rozróżnić następujące typy procesów:

- procesy, które zawierają wszystkie niezbędne informacje dla efektywnej estymacji modeli,
- procesy, których wartości muszą być znane, aby możliwe było prognozowanie na podstawie oszacowanych modeli.

Ze względu na cel badania, którym jest estymacja lub predykcja, można mówić o słabej lub silnej egzogeniczności.

Słaba egzogeniczność. Proces x_t jest słabo egzogeniczny dla wektora parametrów $\boldsymbol{\psi}$, jeżeli brzegowa gęstość prawdopodobieństwa $D_2(x_t | z_{t-i}, \lambda_2)$ nie zawiera istotnych informacji dla estymacji parametrów $\boldsymbol{\psi}$, tzn. jeśli do ich oszacowania wystarczy model odpowiadający gęstości warunkowej, tj. $D_1(y_t | y_{t-i}, x_t, \lambda_1)$.

Silna egzogeniczność. Dla określenia silnej egzogeniczności wymaga się dodatkowo, aby proces y_t nie był przyczyną w sensie Grangera procesu x_t .

Testowanie słabej egzogeniczności. Procedura polega na oszacowaniu następujących równań:

- warunkowego dla y_t :

$$\mathbf{y}'_t \boldsymbol{\Theta} + \mathbf{x}'_t \boldsymbol{\Gamma}_0 + \sum_{i=1}^p \mathbf{y}'_{t-i} \boldsymbol{\Gamma}_i = w_t, \quad (8.31)$$

gdzie: $\boldsymbol{\Theta}$, $\boldsymbol{\Gamma}_0$, $\boldsymbol{\Gamma}_i$ oznaczają odpowiednie macierze parametrów;

- brzegowego dla x_t :

$$x_t = \sum_{i=1}^g c_i y_{t-i} + \sum_{i=1}^h d_i x_{t-i} + v_t, \quad (8.32)$$

przy czym w równaniu brzegowym x_t zależy tylko od wcześniejszych wartości y_t i x_t .

W hipotezie zerowej zakłada się, że $E(w_t, v_t) = 0$. Testowanie polega na zastosowaniu procedury polegającej na oszacowaniu parametrów modelu brzegowego i obliczeniu reszt $\hat{v}_t$, a następnie wstawieniu ich do równania warunkowego jako zmiennej objaśniającej i testowanie istotności stojącego przy nich parametru (por. Engle, Hendry, Richard [1983]). Testowanie silnej egzogeniczności polega na sekwencyjnym zastosowaniu testu słabej egzogeniczności, a następnie jednego z testów przyczynowości.

8.2.3. Analiza odpowiedzi na impuls

Załóżmy model VAR(q) postaci:

$$\mathbf{A}(B) \mathbf{z}_t = \boldsymbol{\varepsilon}_t, \quad (8.33)$$

gdzie:

$$\mathbf{A}(B) = \mathbf{I} - \mathbf{A}_1 B - \mathbf{A}_2 B^2 - \dots - \mathbf{A}_q B^q.$$

Reprezentacja średniej ruchomej dla powyższego modelu jest następująca:

$$\mathbf{z}_t = \mathbf{A}^{-1}(B) \boldsymbol{\varepsilon}_t = \boldsymbol{\psi}(B) \boldsymbol{\varepsilon}_t = \boldsymbol{\varepsilon}_t + \sum_{i=1}^{\infty} \boldsymbol{\psi}_i \boldsymbol{\varepsilon}_{t-i}, \quad (8.34)$$

$$\text{przy czym } \boldsymbol{\psi}_i = \sum_{j=1}^i \mathbf{A}_j \boldsymbol{\psi}_{i-j}, \quad \boldsymbol{\psi}_0 = \mathbf{I}_n.$$

W powyższej reprezentacji nie ma podziału na zmienne endogeniczne i egzogeniczne, stąd macierze parametrów $\boldsymbol{\psi}_i$ mogą być interpretowane jako dynamiczne mnożniki modelu, wyrażające reakcję modelu na jednostkowy szok każdej ze zmiennych (por. Mills [2002]). Poszczególne elementy macierzy: $\psi_{y1}, \psi_{y2}, \dots$ tworzą funkcję odpowiedzi zmiennej z_t na impuls ze strony zmiennej z_j . Jeśli w systemie (8.33) możemy wyróżnić blok zmiennych ściśle egzogenicznych, to nie będą one reagowały na szoki ze strony zmiennych endogenicznych.

Ponieważ między składnikami resztowymi poszczególnych równań systemu zachodzi $\text{cov}(\varepsilon_{it}, \varepsilon_{jt}) \neq 0$, to wyznaczone w powyższy sposób mnożniki mogą być błędne. W celu oczyszczenia składników losowych ze wzajemnych jednoczesnych powiązań założmy, że macierz wariancji-kowariancji składników losowych ma postać:

$$\boldsymbol{\Sigma}_{\varepsilon\varepsilon} = E(\boldsymbol{\varepsilon}_t \boldsymbol{\varepsilon}'_t).$$

Niech $\boldsymbol{\Sigma}_{\varepsilon\varepsilon} = \mathbf{S} \mathbf{S}'$, gdzie $\mathbf{S}$ i $\mathbf{S}'$ oznaczają odpowiednio dolną i górną macierz trójkątną z dodatnimi elementami (na ogół równymi jeden) na głównej przekątnej⁶. Wektor składników losowych przekształcony za pomocą macierzy $\mathbf{S}$ ma postać: $\boldsymbol{\xi}_t = \mathbf{S}^{-1} \boldsymbol{\varepsilon}_t$, przy czym $E(\boldsymbol{\xi}_t \boldsymbol{\xi}'_t) = \mathbf{I}_n$. Stąd przekształcone szoki systemu są wzajemnie ortogonalne. Przekształcając równanie postaci VMA (8.34) w postać rekursywną, a więc wskazującą na kierunek zależności, otrzymujemy:

$$z_t = \sum_{i=0}^{\infty} \boldsymbol{\psi}_i \mathbf{S} (\mathbf{S}^{-1} \boldsymbol{\varepsilon}_{t-i}) = \sum_{i=0}^{\infty} \boldsymbol{\phi}_i \boldsymbol{\xi}_{t-i}, \quad (8.35)$$

przy czym macierze $\boldsymbol{\phi}_i$ są dolnymi macierzami trójkątnymi.

⁶ Wynika to z dekompozycji Choleskiego; por. Lütkepohl [1991].

Funkcja odpowiedzi na impuls ma teraz postać: $\phi_{ij,0}, \phi_{ij,1}, \phi_{ij,2}, \dots$, gdzie:

$$\phi_{ij,h} = \mathbf{e}_j \Phi_h \mathbf{S} \mathbf{e}_i, \quad (8.36)$$

przy czym $\mathbf{e}_i$ i $\mathbf{e}_j$ są wektorami wyboru o wymiarach $(N \times 1)$ zawierającymi 1 w i -tym lub j -tym miejscu i zera w pozostałych.

Stosowanie powyższej dekompozycji, zwanej dekompozycją Choleskiego, wymaga często od ekonometryka znajomości bądź przyjęcia założenia co do powiązań strukturalnych między składowymi wektora $\mathbf{z}_t$, które pozwalają na ograniczenie mniej ważnych sprzężeń zwrotnych. Można wykazać, że macierz $\mathbf{B}$ powinna mieć taką samą strukturę powiązań jak macierz Θ z postaci strukturalnej (8.5) — por. Mills [2002].

Analogiczne badania można przeprowadzić na podstawie modelu VARMA (q, p) (por. Lütkepohl [1991]).

8.3. Model VAR dla procesów skointegrowanych (VEC)

Model VAR dla procesów skointegrowanych został stworzony przez Johansena (por. Johansen [1988], [1991], [1992] oraz Johansen, Juselius [1990]).

8.3.1. Wektorowy model korekty błędem

Punktem wyjścia budowy modelu VEC (*vector error correction*) jest wielowymiarowa reprezentacja postaci:

$$\mathbf{z}_t = \sum_{i=1}^k \pi_i \mathbf{z}_{t-i} + \varepsilon_t, \quad (8.37)$$

gdzie:

$\mathbf{z}_t$ — N -wymiarowy proces stochastyczny, którego wszystkie składowe są generowane przez model ARIMA $(q, 1, 0)$,

ε_t — N -wymiarowy biały szum,

π_i — macierze współczynników autoregresji o wymiarach $(N \times N)$.

Niech:

$$\mathbf{A}(B) = \mathbf{I} - \pi_1 B^1 - \pi_2 B^2 - \dots - \pi_k B^k$$

oznacza macierz, której wyznacznik posiada pierwiastki jednostkowe. Dla procesów zintegrowanych rzędu 1 przyjmuje ona postać:

$$\mathbf{A}(B) = \mathbf{I} - \pi_1 - \pi_2 - \dots - \pi_k = \pi;$$

wtedy model (8.37) można przedstawić w postaci wektorowego modelu korekty błędem, (VEC), tj.:

$$\Delta \mathbf{z}_t = \Gamma_1 \Delta \mathbf{z}_{t-1} + \Gamma_2 \Delta \mathbf{z}_{t-2} + \dots + \Gamma_{k-1} \Delta \mathbf{z}_{t-k+1} - \pi \mathbf{z}_{t-k} + \varepsilon_t, \quad (8.38)$$

przy czym $\Gamma_i = -\pi_i$, $i = 1, 2, \dots, k-1$.

System równań (8.38) jest ogólnym modelem VEC dla procesów skointegrowanych $CI(1, 1)$. Jego interpretacja jest analogiczna do jednorównaniowego modelu korekty błędem, a mianowicie informacje długookresowe są zawarte w rzeczywistych wartościach procesu $\mathbf{z}_{t-k}$, pod warunkiem, że macierz π istnieje, natomiast odchylenia od długookresowej ścieżki rozwoju są reprezentowane przez pierwsze różnice badanego procesu wielowymiarowego.

Macierz π może występować w trzech następujących przypadkach:

- 1) rząd π jest równy N , zatem proces $\mathbf{z}_t$ jest stacjonarny w zakresie wariancji,
- 2) rząd π jest równy 0, wtedy składnik długookresowy w modelu (8.38) zanika,
- 3) rząd π jest równy r , $0 < r < N$, co oznacza, że istnieją macierze α i β o wymiarach $(N \times r)$ takie, że:

$$\pi = \alpha \beta', \quad (8.39)$$

gdzie α jest macierzą dostosowań (współczynników modelu), natomiast β jest macierzą kointegrującą, co odpowiada przypadkowi istnienia r pierwiastków jednostkowych w systemie VAR, czyli kointegracji procesów.

Rozważmy jako przykład model (8.38), w którym $r(\pi) = 1$, co oznacza, że istnieje jeden wektor kointegrujący. Symbol $r(\pi)$ oznacza rząd macierzy π . Odpowiedni model VEC ma wtedy postać:

$$\begin{aligned} \Delta z_{1t} &= \dots + \pi_{11} z_{1t-k} + \pi_{12} z_{2t-k} + \dots + \pi_{1n} z_{nt-k} + \varepsilon_{1t}, \\ \Delta z_{2t} &= \dots + c_2 (\pi_{11} z_{1t-k} + \pi_{12} z_{2t-k} + \dots + \pi_{1n} z_{nt-k}) + \varepsilon_{2t}, \\ &\dots \end{aligned} \quad (8.40)$$

$$\Delta z_{nt} = \dots + c_n (\pi_{11} z_{1t-k} + \pi_{12} z_{2t-k} + \dots + \pi_{1n} z_{nt-k}) + \varepsilon_{nt},$$

gdzie c_i są skalarami⁷, natomiast trzykropek na początku każdego równania oznacza, że dla uproszczenia zapisu zostały pominięte składniki $\Gamma_i \Delta z_{t-i}$. Przyjmując, że $\alpha_i = c_i \pi_{ij}$, każde równanie systemu może być zapisane jako:

$$\Delta z_{it} = \dots + \alpha_i (z_{1t-k} + \beta_2 z_{2t-k} + \dots + \beta_n z_{nt-k}) + \varepsilon_{it}, \quad \text{dla } i = 1, 2, \dots, n. \quad (8.41)$$

W zapisie macierzowym mamy ostatecznie:

$$\Delta \mathbf{z}_t = \sum_{i=1}^{k-1} \Gamma_i \Delta \mathbf{z}_{t-i} + \alpha \beta' \mathbf{z}_{t-k} + \varepsilon_t, \quad (8.42)$$

⁷ Z faktu, że rząd macierzy π jest równy jeden, wynika, iż poszczególne wiersze tej macierzy różnią się tylko o wartości skalarne.

gdzie $\beta = [\beta_1 \beta_2 \beta_3 \dots \beta_n]'$ jest pojedynczym wektorem kointegrującym, zaś $\alpha = [\alpha_1 \alpha_2 \dots \alpha_n]$ jest wektorem współczynników dostosowań.

8.3.2. Testowanie kointegracji w modelach VAR

Testowanie kointegracji polega na ustaleniu, czy istnieje macierz $\pi = \alpha\beta'$ i przebiega według procedury Johansena [1988] — zob. także Charemza, Deadman [1997]. Hipoteza zerowa zakłada, że π jest macierzą dowolną, natomiast w hipotezie alternatywnej przyjmuje się, że $\pi = \alpha\beta'$. Zakłada się przy tym, że macierz kointegrująca jest nieznana. Weryfikacja powyższych hipotez wiąże się ze znalezieniem estymatora MNW macierzy α i β . W tym celu należy dokonać następujących obliczeń:

1. Oszacowanie parametrów równań, oddzielnie dla każdej składowej wektora z_t :

$$\Delta z_t = \sum_{i=1}^k a_i \Delta z_{t-i} + e_t,$$

$$z_{t-k} = \sum_{i=1}^k a_i \Delta z_{t-i} + u_t$$

oraz wyznaczenie wektorów reszt $e_t = [R_{0t}]$ i $u_t = [R_{kt}]$. Wektory te mają wymiary $(N \times 1)$, gdzie T oznacza liczebność próby.

2. Wyznaczenie czterech macierzy postaci:

$$S_{ij} = T^{-1} \sum_{t=1}^T R_{it} R_{jt},$$

przy czym $i, j = \{0, k\}$, które oznaczmy odpowiednio S_{00} , S_{0k} , S_{k0} , S_{kk} .

3. Rozwiązanie równania wyznacznikowego postaci:

$$|\mu S_{kk} - S_{k0} S_{00}^{-1} S_{0k}| = 0$$

i wyznaczenie wartości własnych oraz odpowiadających im wektorów własnych $V = [v_1 v_2 \dots v_n]$. Oszacowane wartości własne należy uporządkować w kolejności malejącej. Jeśli szeregi są skointegrowane, tzn. $r(\beta) = r < N$, wówczas r pierwszych wektorów własnych tworzy macierz kointegrującą β .

Test Johansena oparty na maksymalnej wartości własnej (*maximum eigenvalue test*), służący do badania kointegracji w systemach VAR, ma postać:

$$LR_p = -T \ln(1 - \hat{\mu}_{r+p}). \quad (8.43)$$

Statystykę tę oblicza się dla każdej wartości własnej, począwszy od największej. Zwykle przyjmuje się na początku hipotezę zerową: $H_0: r = 0$, co oznacza, że nie

istnieje żaden wektor kointegrujący⁸, a następnie — w przypadku jej odrzucenia — zakłada się kolejno: $r \leq 1$, $r \leq 2$ itd. Odpowiadające hipotezy alternatywne są następujące: $r = 1$, $r = 2$ itd. Statystyka LR_p posiada niestandardowy rozkład; tablice wartości krytycznych znajdują się w pracy Osterwalda-Lenum [1992]. Wartości te różnią się zależnie od specyfikacji deterministycznej części modelu VEC. W tablicy 8.1 zostały przedstawione wybrane wartości krytyczne dla testu maksymalnej wartości własnej. Test Johansena ma lepsze własności statystyczne niż omawiane wcześniej testy pierwiastków jednostkowych Dickeya-Fullera i Philipisa-Perrona (por. Maddala, Kim [2002]).

Na podstawie modelu VEC $\Delta z_t = \Gamma_1 \Delta z_{t-1} + \Gamma_2 \Delta z_{t-2} + \dots + \Gamma_{k-1} \Delta z_{t-k+1} - \pi z_{t-k} + e_t$ możemy testować przyczynowość w systemach skointegrowanych, egzogeniczność oraz badać odpowiedzi na impuls (por. Mills [2002]).

Tablica 8.1. Wybrane wartości krytyczne dla testu Johansena LR_p przy 5% poziomie istotności

$N-r$	1	2	3	4	5	6	7	8	9	10
A	3,84	11,44	17,89	23,80	30,04	36,36	41,51	47,99	53,69	59,06
B	3,76	14,07	20,97	27,07	33,46	39,37	45,28	51,42	57,12	62,81

A: brak stałej w modelu VEC, tzn. że wszystkie zmienne mają średnią zero:

$$\Delta z_t = \sum_{i=1}^{k-1} \Gamma_i \Delta z_{t-i} + \alpha\beta' z_{t-k} + e_t,$$

B: występują stałe w każdym równaniu VEC, tzn. że każda zmienna może mieć inny poziom średni, natomiast mogą mieć wspólną ścieżkę wzrostu:

$$\Delta z_t = \sum_{i=1}^{k-1} \Gamma_i \Delta z_{t-i} + \alpha\beta' z_{t-k} + \mu + e_t,$$

$N-r$ — liczba wektorów kointegrujących.

Źródło: Osterwald-Lenum [1992]; por. także także Maddala, Kim [2002].

8.4. Estymacja parametrów modeli VAR

Zależnie od postaci modelu wielowymiarowych procesów stochastycznych stosuje się różne metody estymacji. Ogólny model VAR, będący z punktu widzenia powiązań między zmiennymi endogenicznymi modelem prostym, może być szacowany za pomocą klasycznej metody najmniejszych kwadratów dla każdego równania oddzielnie. Jeżeli jednak występują powiązania między składnikami resztowymi poszczególnych równań, to należy zastosować estymację łączną za pomocą uogólnionej metody najmniejszych kwadratów. W przypadku modelu (8.1), w którym zestaw zmiennych objaśnianych jest identyczny, UMNK jest równoważna klasycznej MNK (por. np. Greene [1993]). W modelu VAR zawierającym dodatkowe

⁸ Hipotezą alternatywną jest w tym przypadku $H_1: r > 1$.

zmienne objaśniające (VARX) metoda estymacji zależy niekiedy od rodzaju uwzględnionych zmiennych. Na przykład w przypadku włączenia do modelu racjonalnych oczekiwań niezbędne jest zastosowanie odpowiedniej modyfikacji metody zmiennych instrumentalnych lub metody największej wiarygodności (por. Osińska [2000]). Parametry modeli VARMA (VARMAX) muszą być szacowane za pomocą metody największej wiarygodności, podobnie jak parametry wektorowego modelu korekty błędem. Estymacji modeli VAR poświęcono wiele miejsca w literaturze ekonometrycznej, rozważając często bardzo szczególne przypadki modeli (patrz np. Judge i in. [1985], Lütkepohl [1991]).

Jedną z wielu metod estymacji modeli VAR jest opracowana przez Phillipsa [1995] metoda FM-VAR (*fully-modified VAR estimation*). Jest to zmodyfikowana metoda najmniejszych kwadratów dająca zgodne estymatory modeli VEC.

Zapiszmy model VEC w postaci:

$$z_t = A(B) z_{t-1} + \pi z_{t-1} + \varepsilon_t \quad (8.44)$$

i dalej:

$$z_t = \Gamma w_t + \varepsilon_t, \quad (8.45)$$

gdzie: $w_t = [\Delta z_{t-1} \dots \Delta z_{t-q+1} z_{t-1}]$, $\Gamma = [A_1 \dots A_{q-1} \pi]$.

W pełni zmodyfikowany estymator FM-VAR ma postać:

$$\hat{\Gamma}^* = \hat{\Gamma} - [\hat{\Omega}_{\varepsilon z} \hat{\Omega}_{\varepsilon \varepsilon}^{-1} (\Delta Z_{-1} Z_{-1}' - T \hat{\Omega}_{\Delta Z \Delta Z})] (W' W)^{-1}, \quad (8.46)$$

gdzie:

$\hat{\Gamma} = Z' W (W' W)^{-1}$ — zmodyfikowany estymator KMNK,

$W, \Delta Z_{-1}, Z_{-1}$ — odpowiednie macierze skonstruowane na podstawie danych,

$\hat{\Omega}_{\varepsilon z}, \hat{\Omega}_{\varepsilon \varepsilon}, \hat{\Omega}_{\Delta Z \Delta Z}$ — odpowiednie oszacowane macierze wariancji-kowariancji.

Empiryczne modele wielowymiarowe finansowych szeregów czasowych

Modele wektorowo-autoregresyjne są szeroko wykorzystywane w ekonometrycznych analizach szeregów finansowych. Dla przykładu, badanie przyczynowości oraz odpowiedzi na impuls było przedmiotem badań w pracy: Granger, Huang, Yang [2000], dotyczącej relacji między rynkiem walut a rynkiem akcji w Azji Pd.-Wsch. W kolei Mills [2002] prezentuje przykład analizy relacji między rynkiem akcji a rynkiem obligacji w USA na podstawie modelu VAR. W niniejszym podrozdziale omówimy przykład modelu VEC dla dwóch kursów walutowych: PLN/EURO oraz PLN/USD⁹.

⁹ Więcej informacji na temat modelowania kursów walutowych można znaleźć w pracy: Grzechczyński, Kelm [2002].


Przykład 8.1

Dane dzienne dotyczące kursów walutowych PLN/EURO oraz PLN/USD pochodziły z okresu 1.01.1999–25.04.2003. Przedmiotem zainteresowania były relacja przyczynowa oraz badanie odstępu czasowego między reakcją notowania jednej waluty na zmianę notowania drugiej. Oszacowany model VEC został przedstawiony w tablicy 8.2.

Tablica 8.2. Oszacowany model VEC dla walut

Równanie długookresowe		
EURO	1,000	
USD	4,888	
	(1,314)	
	[3,719]	
Stała	-24,043	
VEC	deuro	dusd
ECM(-1)	-0,003 (0,0009) [-2,864]	-0,004 (0,0008) [-3,667]
deuro(-1)	-0,116 (0,037) [-3,156]	-0,105 (0,034) [-3,074]
deuro(-2)	-0,0955 (0,037) [-2,584]	-0,062 (0,034) [-1,810]
dusd(-1)	0,0297 (0,039) [0,751]	0,030 (0,037) [0,830]
dusd(-2)	0,139 (0,039) [3,510]	0,0966 (0,037) [2,627]
Stała	0,0002 (0,0009) [0,224]	0,0004 (0,0008) [0,485]
R^2	0,028	0,027
Błąd standardowy reszt	0,031	0,029
Akaike AIC*	-4,107	-4,253
Kryterium Schwarz SC*	-4,079	-4,225
AIC VEC**	-8,731	
SC VEC**	-8,667	

* Dotyczy równań. ** Dotyczy całego dwurównaniowego modelu.
Źródło: Opracowanie własne.

Rysunek 8.1. Reszty z równania kointegrującego PLN/EURO i PLN/USD

Źródło: Opracowanie własne.

Tablica 8.3. Wyniki testu na kointegrację

HIPOTEZA				
liczba wektorów	wartość własna	LR_c	wartość krytyczna 5%	wartość krytyczna 1%
0*	0,013138	14,34928	14,07	18,63
najwyżej 1	0,002806	3,048415	3,76	6,65

* Odrzucenie hipotezy na poziomie 5%.


Źródło: Opracowanie własne.

Tablica 8.4. Wyniki testu przyczynowości Grangera

Zmienna zależna deuro				Zmienna zależna dusd			
przyczyna	chi kwadrat	stopnie swobody	prawdopodobieństwo	przyczyna	chi kwadrat	stopnie swobody	prawdopodobieństwo
dusd	12,939	2	0,001	deuro	12,209	2	0,002

Źródło: Opracowanie własne.

Na podstawie przykładu 8.1 można stwierdzić istotne powiązania między kursami walutowymi kształtującymi rynek walutowy w Polsce. Test kointegracji na poziomie 5% sugeruje długookresową zależność między szeregami, test przyczynowości Grangera wskazuje natomiast na istotną zależność przyczynową w obu kierunkach. Analiza odpowiedzi na impuls wskazuje na długość czasu trwania i skalę reakcji na wzajemne szoki. Okazuje się, że początkowy impuls ze strony USD implikuje długotrwały wzrost kursu EURO, podczas gdy reakcja ze strony USD

Rysunek 8.2. Analiza odpowiedzi na impuls

Źródło: Opracowanie własne.

na zmianę kursu EURO trwa krótko i szybko przyjmuje kierunek przeciwny. Analogiczne analizy można przeprowadzić na podstawie danych tygodniowych lub miesięcznych.

8.6. Reprezentacja spektralna wielowymiarowych szeregów czasowych

Reprezentację spektralną wielowymiarowych szeregów czasowych definiuje się podobnie jak w przypadku jednowymiarowym. Rozważmy wielowymiarowy proces stochastyczny o średniej zero, wyrażony w postaci wektora $z_t = [z_{1t} z_{2t} \dots z_{mt}]$.

W takim przypadku oprócz charakterystyk pojedynczych składowych wektora, takich jak średnia, wariancja, funkcja autokowariancyjna i funkcja gęstości spektralnej, rozważa się także wzajemne relacje między poszczególnymi elementami

wektora z_t . Należą do nich funkcja kowariancji wzajemnej oraz funkcja wzajemnej gęstości spektralnej.

Dla dwóch procesów z_{jt} , $z_{kt+\tau}$ funkcja kowariancji wzajemnej ma postać:

$$K_{jk}(\tau) = E[(z_{jt} - m_{jt})(z_{kt+\tau} - m_{kt+\tau})], \quad (8.47)$$

gdzie m_{jt} , $m_{kt+\tau}$ oznaczają odpowiednie wartości średnie.

Korzystając z transformaty Fouriera, mamy:

$$K_{jk}(\tau) = \int_{-\pi}^{\pi} e^{i\omega\tau} dF_{jk}(\omega), \quad (8.48)$$

gdzie $F_{jk}(\omega)$ jest wzajemną funkcją spektralną. Jeśli jest ona różniczkowalna, to zachodzi:

$$dF_{jk}(\omega) = f_{jk}(\omega)d\omega, \quad (8.49)$$

gdzie f_{jk} jest funkcją wzajemnej gęstości spektralnej.

Mamy zatem:

$$K_{jk}(\tau) = \int_{-\pi}^{\pi} e^{i\omega\tau} df_{jk}(\omega)d\omega, \quad (8.50)$$

przy czym $j, k = \{1, 2, \dots, \tau\}; j \neq k$.

Funkcję wzajemnej gęstości spektralnej możemy wyrazić w postaci zespolonej jako:

$$f_{jk}(\omega) = c_{jk}(\omega) - iq_{jk}(\omega), \quad (8.51)$$

gdzie $\text{Re} f_{jk}(\omega) = c_{jk}(\omega)$ nazywa się kospektrum, zaś $\text{Im} f_{jk}(\omega) = q_{jk}(\omega)$ — kwadrospektrum (por. Talaga, Zieliński [1986]). Na podstawie powyższej zależności można wyznaczyć współczynnik koherencji dla dwóch procesów, który przyjmuje postać:

$$R_{jk}(\omega) = \frac{|f_{jk}(\omega)|}{\sqrt{f_{jj}(\omega)f_{kk}(\omega)}} = \left[\frac{c_{jk}^2(\omega) + q_{jk}^2(\omega)}{f_{jj}(\omega)f_{kk}(\omega)} \right]^{1/2}. \quad (8.52)$$

Współczynnik koherencji informuje o sile zależności liniowej między procesami z_{jt} , $z_{kt+\tau}$ dla częstotliwości ω . Przyjmuje on wartości z przedziału $[0, 1]$. W paśmie $[0, \pi]$ wartości współczynnika koherencji tworzą szereg wartości odpowiadających tym punktom, dla których zostały obliczone.

Odpowiednio definiuje się współczynnik kąta fazowego postaci:

$$\varphi_{jk}(\omega) = \arctg \frac{-q_{jk}(\omega)}{c_{jk}(\omega)}, \quad (8.53)$$


który mierzy różnice w fazie między składowymi harmonicznymi procesów z_{jt} i $z_{kt+\tau}$. Współczynnik ten jest pomocny w ustaleniu opóźnień i wyprzedzeń czasowych, charakteryzujących każdą parę ortogonalnych składowych dla danej częstotliwości z pasma $[0, \pi]$.

Do analizy siły zależności korelacyjnej więcej niż dwóch procesów z wektora z_t służą współczynniki koherencji wielorakiej i cząstkowej, których interpretacja jest analogiczna do interpretacji współczynników korelacji wielorakiej i cząstkowej (por. Talaga, Zieliński [1986]). Włączenie omówionych wyżej mierników do analizy zależności przyczynowych w dziedzinie częstotliwości pozwala uszczegółowić i wzbogacić proces identyfikacji zależności przyczynowych występujących na przykład w ekonomii i finansach. Oczywiście ich prawidłowa interpretacja jest możliwa w ścisłym związku z jakościową teorią ekonomii oraz finansów (por. Osińska [1994]).

Przykład 8.2

Rozważmy przyrosty dzienne logarytmów kursów walutowych EURO/PLN oraz USD/PLN i zbadajmy koherencję, a także współczynnik kąta fazowego dla obydwu szeregów. Pytanie badawcze może brzmieć: kurs której waluty jest wiodący dla transakcji finansowych realizowanych w obu walutach?

Rysunek 8.3. Analiza relacji między kursami EURO i USD według częstotliwości



Źródło: Opracowanie własne.

Analizując otrzymane wyniki, można stwierdzić, że:

1. Obserwujemy wyraźną przewagę części rzeczywistej (kospektrum) w wartościach wzajemnej funkcji gęstości spektralnej.

2. W całym paśmie częstości obserwujemy bardzo silną zależność korelacyjną (kwadrat współczynnika koherencji jest równy 0,999).
3. Kąt fazowy wskazuje na zależności jednocześnie w całym przedziale częstości, gdyż mimo zmiany kierunku w paśmie częstości wyższych wartości tego współczynnika są bardzo bliskie zeru.

Pytania i problemy

1. Zapisz podstawowy model VAR i wyjaśnij jego cechy.
2. Zapisz trzyrównaniowy model VAR(2) z trendem liniowym w każdym równaniu.
3. Na czym polega modelowanie atoretyczne?
4. W jaki sposób tworzy się strukturalny model VAR?
5. Wyjaśnij potrzebę testowania przyczynowości i egzogeniczności w modelach VAR i VARMA.
6. Na czym polega przyczynowość w sensie Grangera?
7. Na czym polega wykorzystanie bezmodelowego podejścia do testowania przyczynowości?
8. Testowanie przyczynowości w sensie Grangera na podstawie modelu VAR.
9. Na czym polega koncepcja egzogeniczności?
10. Jaki jest cel analizy odpowiedzi na impuls w modelach VAR?
11. Budowa wektorowego modelu korekty błędem.
12. Testowanie kointegracji w systemach VAR.
13. Oceń przydatność modeli VEC w analizach rynków finansowych.
14. Jakie są cechy empirycznych modeli VAR dla finansowych szeregów czasowych?
15. Jakie cechy współzależności szeregów czasowych można badać przy zastosowaniu wielowymiarowej analizy spektralnej?

Rozdział 9

Wielowymiarowe modele GARCH

Słowa kluczowe: wektorowe modele GARCH, model stałej warunkowej korelacji, zmienne korelacje, BEKK, przyczynowość w wariancji

Jak wspomniano w rozdziale poprzednim, w ostatnim czasie szczególnie istotne stały się liczne współzależności zachodzące w ramach rynków finansowych oraz między rynkami. Najczęściej stosowane narzędzia koncentrują się wokół modeli opisujących warunkowe średnie. Korzysta się z metodologii związanej z kointegracją, mówi się o krótkookresowych dostosowaniach do długookresowej ścieżki wyznaczającej równowagę, o badaniu reakcji na impuls itp. Zagadnienia te zostały już wcześniej omówione. Okazuje się, że istnieją jeszcze bardziej subtelne narzędzia umożliwiające badanie wzajemnych powiązań między zjawiskami zachodzącymi na tym samym rynku, a w szczególności pomiędzy rynkami. Przykładem pierwszego rodzaju powiązań są analizy dotyczące długo- i krótkookresowej stopy procentowej oraz jej wpływu na rynkowe kursy papierów wartościowych. Przykładem drugiego — analiza zależności między wschodzącymi a rozwiniętymi rynkami finansowymi, a zwłaszcza efekty przenoszenia się negatywnych wpływów kryzysów zachodzących na pewnych rynkach na pozostałe rynki oraz wynikających z tego tytułu strat (ang. *contagion* tłumaczy się także jako zarażanie; por. np. Fiszeder, Razik [2003]).

Odpowiednie instrumentarium stwarzają wielowymiarowe modele GARCH, uwzględniające nie tylko zmienną wariancję, ale także kowariancję, odpowiadające za opis wzajemnych relacji między badanymi zjawiskami. Wnioskowanie na poziomie wariancji i warunkowych kowariancji wzbogaca analizy prowadzone na podstawie warunkowych średnich, ale także umożliwia uchwycenie niezależnych relacji między drugimi momentami w sytuacji, gdy wartości oczekiwane są identyfikowane jako niezależne. Zastosowanie wielowymiarowych modeli GARCH stało się popularne w końcu lat 90. XX w., gdy OECD i MFW zaczęły badać skutki kryzysu azjatyckiego, który poprzez powiązania handlowe miał wpływ na wzrost gospodarczy państw industrialnych. Z innych badań wynika ponadto, że rozprzestrzenianie się negatywnych skutków kryzysów poprzez globalne rynki finansowe

znajduje także wyraz w większej korelacji pomiędzy rynkami w okresie turbulencji, w porównaniu do okresów spokoju. Okazuje się, że efekt rozprzestrzeniania nie jest łatwy do zidentyfikowania. Nie do końca wiadomo, czy wysoka korelacja między rynkami jest wynikiem powiązań fundamentalnych czy właśnie zarażania. Jednakże w kontekście rosnącej integracji rynków finansowych efekt przenoszenia kryzysów staje się coraz bardziej istotny. Do tej pory ustalono, że kryzysy na rozwijających się rynkach finansowych (np. Meksyk — 1994 r., Azja Płd. — 1997 r.) — przed rozprzestrzenieniem się na rynki rozwinięte — skutkowały zwiększoną zmiennością cen akcji. Jest to wystarczający powód, by analizie zmienności poświęcić więcej uwagi i monitorować tę zmienność w sposób systematyczny. Wielowymiarowe modele GARCH wydają się do tego celu najbardziej odpowiednim narzędziem, chociaż wciąż sprawiają wiele problemów estymacyjnych, zwłaszcza w przypadkach systemów o wymiarach większych niż dwa.

Powstaje także pytanie, jaka częstotliwość danych jest odpowiednia dla wykrycia relacji zarówno między poziomami zmiennych, jak i zmiennością wariancji. Granger i in. [2000] argumentują, że dane dzienne (w przeciwieństwie do miesięcznych) są bardziej adekwatne, by uchwycić efekty ruchów kapitału na rynkach międzynarodowych, a także by szacować pierwiastki jednostkowe oraz relacje długookresowe w celu opisu tych rynków. W literaturze polskiej również pojawiło się w ostatnim czasie wiele prac rozwijających teorię wielorównaniowych modeli GARCH, zwłaszcza z rozkładem *t*-Studenta (por. Osiewalski, Pipień [2001], [2002]), oraz stosujących te modele w analizach empirycznych m.in. do badania efektów zarażania (por. Fiszeder [2001], Fiszeder, Razik [2003], Doman [2004]).

Ogólna postać wielorównaniowego modelu GARCH(*p*, *q*)

Ogólna postać wielorównaniowego modelu GARCH(*p*, *q*) została wprowadzona przez Engle'a i Krafra [1982]. Można ją zdefiniować w następujący sposób.

Niech $\mathbf{Y}_t$ oznacza wielowymiarowy ($N \times 1$) proces stochastyczny o warunkowej średniej równej $\boldsymbol{\mu}_t$ i wariancji $\mathbf{H}_t$. Warunkową średnią procesu $\mathbf{Y}_t$ można opisać, na przykład, za pomocą modelu VAR. Niech:

$$\mathbf{Y}_t | \mathbf{Y}_{t-1} \sim N(\boldsymbol{\mu}_t, \mathbf{H}_t),$$

$$\varepsilon_t | \mathbf{Y}_{t-1} \sim N(0, \mathbf{H}_t).$$

Formuła:

$$\text{vech}(\mathbf{H}_t) = \mathbf{W} + \sum_{i=1}^q \mathbf{A}_i \text{vech}(\boldsymbol{\varepsilon}_{t-i}, \boldsymbol{\varepsilon}'_{t-i}) + \sum_{j=1}^p \mathbf{B}_j \text{vech}(\mathbf{H}_{t-j}), \quad (9.1)$$

gdzie:

$\mathbf{Y}_t, \boldsymbol{\mu}_t$ i $\boldsymbol{\varepsilon}_t$ — wektory o wymiarach ($N \times 1$),

$\mathbf{H}_t$ — symetryczna macierz warunkowych wariancji i kowariancji o wymiarach ($N \times N$),

$\mathbf{W}_t$ — wektor o wymiarach $[N(N+1)/2 \times 1]$,

$\mathbf{A}_i, \mathbf{B}_j$ — macierze o wymiarach $[N(N+1)/2 \times N(N+1)/2]$,

$\text{vech}(\cdot)$ — operacja polegająca na przekształceniu macierzy w wektor w ten sposób, że elementy diagonalne i znajdujące się poniżej głównej przekątnej tworzą wektor kolumnowy,

definiuje ogólną postać wielorównaniowego modelu GARCH, tzw. VechGARCH.

Przykładowo dla $N = 2$ i $p = q = 1$ model (9.1) można zapisać jako:

$$\text{vech}(\mathbf{H}_t) = \begin{bmatrix} h_{11,t} \\ h_{21,t} \\ h_{22,t} \end{bmatrix} = \begin{bmatrix} w_{11} \\ w_{21} \\ w_{22} \end{bmatrix} + \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \begin{bmatrix} \varepsilon_{1,t-1}^2 \\ \varepsilon_{2,t-1} \varepsilon_{1,t-1} \\ \varepsilon_{2,t-1}^2 \end{bmatrix} + \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{bmatrix} \begin{bmatrix} h_{11,t-1} \\ h_{21,t-1} \\ h_{22,t-1} \end{bmatrix}. \quad (9.2)$$

Macierz $\mathbf{H}_t$ powinna być dodatnio określona dla wszystkich możliwych realizacji. Jednak liczba parametrów, które należy oszacować w modelu (9.1), wynosi $[N(N+1)/2] \times [1 + (p+q) \times N(N+1)/2]$, stąd sformułowanie i zapewnienie warunków dodatniej określoności macierzy jest bardzo trudne. Dlatego też postać (9.1), zwana też postacią Vech, nie znajduje szerszego zastosowania w praktyce¹.

Model stałych warunkowych korelacji

Najprostszym modelem wielowymiarowym opisującym łączną zmienność wariancji warunkowych, przy założeniu stałości kowariancji (i tym samym korelacji), jest model stałych warunkowych korelacji Bollersleva (*constant conditional correlations*) (por. Bollerslev [1990]²). W literaturze (por. np. Gourioux [1997]) rozważa się czasem osobno model diagonalny (o zerowych korelacjach). Model ten będziemy traktować jako szczególny przypadek modelu stałych warunkowych korelacji (por. przykład 9.1).

¹ Przykład oszacowanego modelu VechGARCH można znaleźć w pracy: Osiewalski, Pipień [2001].

² Odmienne podejście proponuje Engle [2002]; por. także Doman [2004].

W modelu tym zakłada się, że zmieniające się w czasie warunkowe kowariancje są proporcjonalne do iloczynu odpowiednich odchyłeń standardowych:

$$\mathbf{H}_t = \sqrt{\mathbf{D}_t} \mathbf{\Gamma} \sqrt{\mathbf{D}_t}, \quad (9.3)$$

gdzie:

$\mathbf{D}_t$ — macierz diagonalna warunkowych wariancji o wymiarach $(N \times N)$,

$\mathbf{\Gamma}$ — macierz stałych warunkowych współczynników korelacji.

Na to, aby macierz $\mathbf{H}_t$ była dodatnio określona, potrzeba i wystarcza, aby wariancje warunkowe były większe od zera, a macierz $\mathbf{\Gamma}$ była dodatnio określona.

Dla $N = 2$ możemy zapisać:

$$\mathbf{H}_t = \begin{bmatrix} \sqrt{h_{11,t}} & 0 \\ 0 & \sqrt{h_{22,t}} \end{bmatrix} \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix} \begin{bmatrix} \sqrt{h_{11,t}} & 0 \\ 0 & \sqrt{h_{22,t}} \end{bmatrix}, \quad (9.4)$$

gdzie:

ρ — współczynnik korelacji między ε_{1t} a ε_{2t} ,


$h_{11,t}$, $h_{22,t}$ — warunkowe wariancje jednorównaniowych modeli GARCH.

Powyższy model — z uwagi na swoją prostą formę — znalazł wiele zastosowań praktycznych (por. np. Bera, Higgins [1993]). Należy jednak pamiętać, że założenie o stałych warunkowych korelacjach w praktyce może się okazać zbyt silne.

9.3. Modele ze zmienną w czasie korelacją

Często założenie stałej korelacji między badanymi szeregami zmian cen instrumentów finansowych jest zbyt restrykcyjne. Rozważmy dla przykładu szeregi dziennych zmian kursów walut EURO/PLN i USD/PLN obserwowane w latach 1999–2003. Oszacowany współczynnik korelacji został przedstawiony na rysunku 9.1.

Rysunek 9.1. Zmienność współczynnika korelacji w próbie



Źródło: Opracowanie własne.

Współczynnik korelacji między zmianami cen walut, który został oszacowany w oknach, przy stałej długości okna $n = 100$, wykazuje dość dużą zmienność w czasie. Należy zauważyć, że siła korelacji jest w większości okresów dość duża ($\rho > 0,5$).

Najprostszym sposobem uwzględnienia zmiennej w czasie korelacji jest dołączenie do modelu równania dla współczynnika korelacji (por. Tsay [2002]) w następujący sposób:

$$\rho_{21,t} = \frac{\exp(q_t)}{1 + \exp(q_t)}, \quad (9.5)$$

przy czym:

$$q_t = \bar{\omega}_0 + \bar{\omega}_1 \rho_{21,t} + \bar{\omega}_2 \frac{\varepsilon_{1,t-1} \varepsilon_{2,t-1}}{\sqrt{h_{11,t-1} h_{22,t-1}}}, \quad (9.6)$$

gdzie:

$\bar{\omega}_0$, $\bar{\omega}_1$, $\bar{\omega}_2$ — parametry podlegające oszacowaniu,

$h_{ii,t-1}$ — wariancja warunkowa zakłóceń losowych $\varepsilon_{i,t-1}$.

Model (9.6) będziemy nazywać modelem GARCH(1, 1) dla współczynnika korelacji. Równanie (9.5) stosujemy wówczas, gdy współczynnik korelacji powinien być nieujemny, co zapewnia zastosowanie funkcji wykładniczych. W przypadku gdy wiemy, że współczynnik korelacji powinien przyjmować wartości ujemne, możemy wstawić znak minusa przed wyrażeniem znajdującym się po prawej stronie równania (9.5). Jeżeli znak współczynnika korelacji jest nieznanym, to stosujemy przekształcenie:

$$\rho_{21,t} = \frac{\exp(q_t) - 1}{\exp(q_t) + 1}. \quad (9.7)$$

9.3.1. Model BEKK i jego własności

Model (9.1) był impulsem do dalszych prac nad wielorównaniowymi modelami opisującymi warunkowe kowariancje, przy czym główny nacisk został położony na:

- zapewnienie dodatniej określoności macierzy $\mathbf{H}_t$,
- oszczędną parametryzację modelu.

Jednym z najlepszych okazał się model znany jako BEKK (Baba, Engle, Kraft i Kroner [1990]), którego ogólna postać jest następująca:

$$\mathbf{H}_t = \mathbf{C}^* \mathbf{C}^{*'} + \sum_{k=1}^K \sum_{i=1}^q \mathbf{D}_{ik}^* \varepsilon_{t-i} \varepsilon_{t-i}' \mathbf{D}_{ik}^{*'} + \sum_{k=1}^K \sum_{j=1}^p \mathbf{E}_{jk}^* \mathbf{H}_{t-j} \mathbf{E}_{jk}^{*'}, \quad (9.8)$$

przy czym $\mathbf{C}^*$, $\mathbf{D}_{ik}^*$ oraz $\mathbf{E}_{jk}^*$ są macierzami o wymiarach $(N \times N)$.

Postać (9.8) zapewnia dodatnią określoność macierzy $\mathbb{H}_t$ i wymaga oszacowania $N(N+1)/2 + (p+q)KN^2$ parametrów.

Ze względu na liczbę szacowanych parametrów najczęściej stosuje się dwuwymiarowy model BEKK(1, 1). Dla $K=1$ przyjmuje on następującą postać:

$$\begin{bmatrix} h_{1,t} & h_{12,t} \\ h_{21,t} & h_{22,t} \end{bmatrix} = \begin{bmatrix} c_{11}^* & c_{12}^* \\ c_{21}^* & c_{22}^* \end{bmatrix} \begin{bmatrix} c_{11}^* & c_{12}^* \\ c_{21}^* & c_{22}^* \end{bmatrix} + \begin{bmatrix} d_{11}^* & d_{12}^* \\ d_{21}^* & d_{22}^* \end{bmatrix} \begin{bmatrix} \varepsilon_{1,t-1}^2 & \varepsilon_{1,t-1}\varepsilon_{2,t-1} \\ \varepsilon_{2,t-1}\varepsilon_{1,t-1} & \varepsilon_{2,t-1}^2 \end{bmatrix} \times \\ \times \begin{bmatrix} d_{11}^* & d_{12}^* \\ d_{21}^* & d_{22}^* \end{bmatrix} + \begin{bmatrix} e_{11}^* & e_{12}^* \\ e_{21}^* & e_{22}^* \end{bmatrix} \begin{bmatrix} h_{1,t-1} & h_{12,t-1} \\ h_{21,t-1} & h_{22,t-1} \end{bmatrix} \begin{bmatrix} e_{11}^* & e_{12}^* \\ e_{21}^* & e_{22}^* \end{bmatrix}, \quad (9.9)$$

przy warunku $c_{12}^* = c_{21}^*$.

Model (9.9) opisuje dynamikę dwuwymiarowego procesu $\mathbb{H}_t$ jako liniową funkcję jego wcześniejszych wartości $\mathbb{H}_{t-1}$ oraz wcześniejszych wartości kwadratów procesów resztowych ($\varepsilon_{1,t-1}^2, \varepsilon_{2,t-1}^2$), pozwalając w obu przypadkach na uwzględnienie wpływu zarówno wariancji na poszczególnych rynkach, jak i kowariancji między rynkami. Ważną cechą tej specyfikacji jest to, że nie wymaga ona estymacji zbyt wielkiej liczby parametrów, a także i to, że jest ona wygodną formą stanowiącą podstawę testowania hipotez o wzajemnych powiązaniach badanych rynków (podobnie jak analizowane w rozdziale poprzednim modele VAR).

Parametry modelu BEKK szacuje się najczęściej metodą największej wiarygodności. Logarytm funkcji wiarygodności dla wielowymiarowego modelu GARCH, przy założeniu normalności rozkładu warunkowego, jest dany wzorem:

$$L_T(\varepsilon_T, \varepsilon_{T-1}, \dots, \varepsilon_1, \Psi) = -\frac{1}{2} \left[TN \ln(2\pi) + \sum_{t=1}^T |\mathbb{H}_t| + \varepsilon_t' \mathbb{H}_t^{-1} \varepsilon_t \right]. \quad (9.10)$$

Więcej szczegółowych informacji na temat estymacji parametrów wielowymiarowych modeli GARCH znajdzie Czytelnik w pracy Gouriéroux [1997].

Wielowymiarowe modele GARCH z rozkładem t -Studenta

Podobnie jak w modelach jednowymiarowych, przyjęcie założenia o normalności wielowymiarowego rozkładu składnika resztowego może się okazać niewystarczające w przypadku leptokurtozy stóp zwrotu z aktywów finansowych. Istnieje wiele wersji wielowymiarowego rozkładu t -Studenta. Prosta wersja dla modelowania zmienności jest następująca: Niech N -wymiarowy wektor x posiada wielowymiarowy rozkład t -Studenta o ν stopniach swobody i parametrach: $\mu = 0$ i $\mathbb{H}$. Wektor parametrów położenia $\mu = 0$ świadczy o symetrii rozkładu, natomiast macierz $\mathbb{H}$ jest odwrotną macierzą precyzji.

Funkcja gęstości rozkładu prawdopodobieństwa wektora x jest dana jako:

$$f(x | \nu) = \frac{\Gamma[(\nu + N)/2]}{(\pi\nu)^{N/2} \Gamma(\nu/2)} (1 + \nu^{-1} x'x)^{-(\nu+N)/2}, \quad (9.11)$$

gdzie $\Gamma(*)$ oznacza funkcję gamma.

Wariancja każdego elementu wektora x jest równa $\nu/(\nu-2)$, stąd możemy przyjąć, że $a_t = \sqrt{\nu/(\nu-2)} x$ posiada standaryzowany wielowymiarowy rozkład t -Studenta z ν stopniami swobody. Funkcja gęstości prawdopodobieństwa dla a_t jest następująca:

$$f(a | \nu) = \frac{\Gamma[(\nu + N)/2]}{[\pi(\nu-2)]^{N/2} \Gamma(\nu/2)} [1 + (\nu-2)^{-1} a'a]^{-(\nu+N)/2}. \quad (9.12)$$

Z kolei w celu modelowania zmienności stosujemy przekształcenie $\varepsilon_t = H_t^{1/2} a_t$. Zakładając, że a_t ma rozkład wielowymiarowy o funkcji gęstości danej wzorem (9.12), otrzymujemy następującą funkcję gęstości prawdopodobieństwa dla ε_t , która jest zależna od ν i H_t :

$$f(\varepsilon | \nu, \mathbb{H}_t) = \frac{\Gamma[(\nu + N)/2]}{[\pi(\nu-2)]^{N/2} \Gamma(\nu/2) |\mathbb{H}_t|^{1/2}} [1 + (\nu-2)^{-1} \varepsilon' \mathbb{H}_t^{-1} \varepsilon]^{-(\nu+N)/2}. \quad (9.13)$$

Estymacja parametrów modeli z warunkowym rozkładem t -Studenta wymaga szacowania większej liczby parametrów, niż ma to miejsce w przypadku rozkładu normalnego, gdyż dodatkowo szacujemy tutaj liczbę stopni swobody.

Powyższe specyfikacje zakładają symetryczny rozkład t -Studenta. W literaturze (por. Osiewalski, Pipień [2001]) rozważa się także niesymetryczne rozkłady z wektorem parametrów położenia $\mu \neq 0$. Tematyka ta wykracza poza ramy naszych rozważań.

Przykład 9.1

Osiewalski i Pipień [2002] za pomocą metod bayesowskich³ porównywali różne specyfikacje wielowymiarowych modeli GARCH na przykładzie kursów walutowych. Były to w szczególności: wielowymiarowe modele ARCH i GARCH z rozkładem normalnym, GARCH z rozkładem t -Studenta oraz (nieomawiany tutaj) model GARCH z rozkładem t -Studenta zawierający dwa czynniki ukryte. Modele te były analizowane w kilku wariantach, m.in. ze stałą i zmienną korelacją. Wyniki empiryczne wskazują na to, że:

³ W prezentowanej pracy przedstawiamy tzw. klasyczne narzędzia wnioskowania. Wnioskowanie bayesowskie, oparte na twierdzeniu Bayesa, zakłada inną filozofię postępowania. Rezultaty takich badań są bardzo cenne zarówno dla strony klasycznej, jak i bayesowskiej; por. np. Judge i In. [1985], Bauwens, Lubrano, Richard [1999], Osiewalski [2001].

- modele GARCH zawierające znacznie więcej informacji o długiej pamięci w wariancji są lepsze niż modele ARCH,
- korelacje między zmiennością różnych kursów walut są zmienne w czasie,
- warunkowy rozkład normalny jest odrzucany przez dane i może być z powodzeniem zastąpiony przez rozkład t -Studenta,
- z porównania wynika, że najlepszym modelem jest model BEKK(1, 1) z rozkładem t -Studenta, który jest lepszy od postaci Vech z tym samym rozkładem; wszystkie pozostałe specyfikacje były gorsze.

9.4. Testowanie stałości korelacji

Literatura dotycząca testowania stałości korelacji w wielowymiarowych modelach GARCH nie jest zbyt bogata. Sformułowanie problemu jest dość proste, chociaż wyprowadzenie testu i jego własności nie jest już tak oczywiste. Przyjmijmy, że korelacje (zmienne w czasie) można opisać za pomocą następującego równania:

$$\rho_{ij,t} = \rho_{ij} + d_{ij} \varepsilon_{i,t-1} \varepsilon_{j,t-1}, \quad (9.14)$$

gdzie:

ρ_{ij} — stały współczynnik korelacji,

$d_{ij,t}$ — odpowiada za zmienność w czasie współczynnika $\rho_{ij,t}$.

Tak więc równanie (9.14) obejmuje zarówno przypadek stałej, jak i zmiennej korelacji. W hipotezie zerowej głoszącej stałość korelacji zakłada się, że:

$$H_0: d_{ij,t} = 0, \quad \text{dla } 1 \leq i < j \leq K, \quad (9.15)$$

co jest równoważne zapisowi:

$$H_0: \Gamma_t = \Gamma, \quad \text{dla każdego } t.$$

Zależność między korelacją warunkową i kowariancją warunkową jest dana wzorem:

$$\sigma_{ij,t} = \rho_{ij,t} \sigma_{ii} \sigma_{jj},$$

gdzie:

$\sigma_{ij,t}$ — warunkowa kowariancja, zmienna w czasie,

σ_{ii}, σ_{jj} — warunkowe odchylenia standardowe.

Niektórzy autorzy sugerują testowanie hipotezy o stałości korelacji dla reszt standaryzowanych postaci: $v_{it} = \varepsilon_{it}/\sigma_{ii}$, stąd równanie (9.14) przyjmuje postać:

$$\rho_{ij,t} = \rho_{ij} + d_{ij} v_{i,t-1} v_{j,t-1}. \quad (9.16)$$

Do testowania hipotezy o stałości współczynników korelacji stosuje się najczęściej dwa testy: test Bery i Kima oraz test Tse.

Test Bery i Kima. Został on sformułowany w 1996 r. Jego postać jest następująca:

$$C_1 = \frac{\left[\sum_{t=1}^T (\xi_{1t}^2 \xi_{2t}^2 - 1 - 2r^2) \right]}{4T(1 + 4r^2 + r^4)}, \quad (9.17)$$

gdzie:

r — oszacowany stały współczynnik korelacji w dwurównaniowym modelu GARCH,

ξ_{it} , dla $i = 1, 2$ — oszacowane standaryzowane reszty z modelu GARCH:

$$\xi_{1t} = \frac{\varepsilon_{1t} - r\varepsilon_{2t}}{\sqrt{1 - r^2}},$$

$$\xi_{2t} = \frac{\varepsilon_{2t} - r\varepsilon_{1t}}{\sqrt{1 - r^2}}.$$

Tse [2000] zwraca uwagę na to, że test zachowuje dobre własności przy próbie 1000 obserwacji i większej, ale jest wrażliwy na brak normalności rozkładu. Statystyka C_1 ma rozkład zbliżony do $\chi^2(1)$.

Test Tse. Drugi z omawianych testów został wyprowadzony przez Tse w 2000 r. Jest to test postaci LM, który oznaczmy jako C_2 . Przyjmuje on postać:

$$C_2 = \mathbf{l}' \hat{\mathbf{S}} (\hat{\mathbf{S}}' \hat{\mathbf{S}})^{-1} \hat{\mathbf{S}}' \mathbf{l}, \quad (9.18)$$

gdzie:

$\mathbf{l}$ — $(T \times 1)$ -wymiarowy wektor jedynek,

$\hat{\mathbf{S}} = \partial \mathcal{L} / \partial \theta'$, dla $t = 1, 2, \dots, T$.

Macierz $\hat{\mathbf{S}}$ ma wymiary $(T \times N)$ i jest macierzą pierwszych pochodnych funkcji wiarygodności względem wektora szacowanych parametrów $\theta = [\alpha_i \beta_i \rho_{ij} \delta_{ij}]$, dla $t = 1, 2, \dots, T$.

Statystyka C_2 ma rozkład zbliżony do $\chi^2(M)$, gdzie $M = K(K-1)/2$, zaś K oznacza liczbę równań w wielorównaniowym modelu GARCH. Test Tse, podobnie jak test Bery i Kima zachowuje dobre własności dla próby większej lub równej 1000 obserwacji, ale ma przewagę nad nim w dwóch istotnych elementach:

- może być stosowany dla dowolnej liczby równań,
- jest odporny na brak normalności rozkładu.

Testowanie przyczynowości w zakresie wariancji

Zastosowanie wielowymiarowych modeli GARCH pozwala na badanie relacji przyczynowych między wariancjami warunkowymi różnych zmiennych. Badania takie zyskują na popularności, ponieważ sam opis mechanizmu generującego wariancje nie wystarczy do zrozumienia ich wzajemnych wpływów. Przyczynowość w zakresie wariancji może występować łącznie, z przyczynowością w wartości oczekiwanej lub samoistnie. W niniejszym podrozdziale zostaną przedstawione dwa podejścia do testowania przyczynowości w wariancji.

Test Cheunga i Ng. Cheung i Ng [1996] zmodyfikowali definicję przyczynowości Grangera w następujący sposób.

Niech X_t i Y_t oznaczają stacjonarne procesy stochastyczne i niech $\Omega_t = \{X_{t-j}, Y_{t-j}; j \geq 0\}$ oznacza wszystkie informacje z przeszłości dostępne w czasie t oraz niech $\Omega_t \setminus X_t$ zawiera te same informacje, z wykluczeniem zawartych w procesie X_t . Określenie: X_t jest przyczyną Y_t w wariancji, jeżeli:

$$E\{(Y_t - \mu_{Y_t})^2 | \Omega_t \setminus X_t\} \neq E\{(Y_t - \mu_{Y_t})^2 | \Omega_t\}, \quad (9.19)$$

gdzie μ_{Y_t} jest warunkową średnią procesu Y_t przy założeniu zbioru informacji $\Omega_t \setminus X_t$.

W przypadku sprzężenia zwrotnego wymagana jest jednoczesna zależność przyczynowa X_t od Y_t oraz Y_t od X_t , natomiast dla przyczynowości jednoczesnej wymaga się włączenia do zbioru informacji Ω_t wartości X_t , tzn. $\{\Omega_t \cup X_t\}$.

Podobnie jak w przypadku przyczynowości w wartości oczekiwanej, powyższa definicja nie ma charakteru operacyjnego. Wymaga się dodatkowych założeń co do struktury procesów. Przyjmijmy, że:

$$X_t = \mu_{X_t} + \sqrt{h_{X_t}} \varepsilon_t, \quad (9.20)$$

$$Y_t = \mu_{Y_t} + \sqrt{h_{Y_t}} \xi_t, \quad (9.21)$$

gdzie ε_t i ξ_t są gaussowskimi białymi szumami o średniej zero i wariancji jeden.

Załóżmy, że średnie procesów (9.20) i (9.21) są opisane modelami ARMA, natomiast wariancje h_{X_t} , h_{Y_t} — modelami GARCH. Niech dalej U_t i V_t oznaczają kwadraty standaryzowanych reszt:

$$U_t = (X_t - \mu_{X_t})^2 / h_{X_t} = \varepsilon_t^2, \quad (9.22)$$

$$V_t = (Y_t - \mu_{Y_t})^2 / h_{Y_t} = \xi_t^2, \quad (9.23)$$

natomiast $\rho(k) = \frac{E(U_{t-k} V_t)}{[E(U_t^2)E(V_t^2)]^{0.5}}$, $k = 0, \pm 1, \pm 2, \dots$ jest współczynnikiem korelacji wzajemnej. Koncepcja Cheunga i Ng [1996] opiera się na teście Pierce'a-

-Haugha [1977], tzn. że przyczynowość w wariancji można wykryć na podstawie korelacji wzajemnych kwadratów standaryzowanych reszt. Zaletą tej metody jest to, że w celu wykrycia przyczynowości w wariancji nie wymaga ona szacowania wielowymiarowych modeli GARCH. Szacowanie systemów większych niż dwuwymiarowe nie jest zadaniem łatwym, stąd ważność tej własności.

Test hipotezy o braku przyczynowości w wariancji bazuje na estymatorach szeregów U_t i V_t , a także estymatorach odpowiednich modeli dla średnich i wariancji oraz współczynnika korelacji wzajemnej $r(k) = \hat{\rho}(k)$. Postać testu, zbieżna do rozkładu $\chi^2(k-j+1)$, jest następująca:

$$S = T \sum_{i=j}^k r(i)^2, \quad (9.24)$$

gdzie T oznacza liczebność próby. Test jest odporny na leptokurtyczne rozkłady i odpowiedni do zastosowania przy próbie przekraczającej 100 obserwacji.

Test Caporale'a, Pittisa i Spagnolo. Trudniejszym zadaniem jest testowanie przyczynowości w wariancji na podstawie wielorównaniowego modelu GARCH. Caporale, Pittis i Spagnolo [2002a] zaproponowali test przyczynowości dla dwuwymiarowego modelu BEKK(1, 1).

Model (9.9) zapiszmy w formie

$$\mathbb{H}_t = C_0' C_0 + \begin{bmatrix} d_{11}^* & d_{12}^* \\ d_{21}^* & d_{22}^* \end{bmatrix} \begin{bmatrix} \varepsilon_{1,t-1}^2 & \varepsilon_{1,t-1} \varepsilon_{2,t-1} \\ \varepsilon_{2,t-1} \varepsilon_{1,t-1} & \varepsilon_{2,t-1}^2 \end{bmatrix} \begin{bmatrix} d_{11}^* & d_{12}^* \\ d_{21}^* & d_{22}^* \end{bmatrix}' + \\ + \begin{bmatrix} e_{11}^* & e_{12}^* \\ e_{21}^* & e_{22}^* \end{bmatrix} H_{t-1} \begin{bmatrix} e_{11}^* & e_{12}^* \\ e_{21}^* & e_{22}^* \end{bmatrix}'. \quad (9.25)$$

Hipoteza o braku przyczynowości ma postać odpowiednich restrykcji tak nałożonych na macierze D^* i E^* , aby stały się one odpowiednio górnymi lub dolnymi macierzami trójkątnymi. W szczególności, zapisując hipotezę postaci:

$$H_0: d_{21}^* = e_{21}^* = 0, \quad (9.26)$$

zakładamy, że h_{2t} nie jest przyczyną h_{1t} , podczas gdy h_{1t} jest przyczyną h_{2t} .

Test oparty na zasadzie ilorazu wiarygodności porównuje maksymalne wartości funkcji wiarygodności dla przypadku, kiedy prawdziwa jest hipoteza zerowa, a także dla przypadku niezawierającego restrykcji zerowych co do wartości parametrów. Ma on postać:

$$LR = -2(L_R - L_U), \quad (9.27)$$

gdzie L_R , L_U oznaczają odpowiednio funkcje wiarygodności z restrykcjami i bez restrykcji nałożonych na parametry.

Analiza mocy powyższego testu wskazuje, że jego zbieżność do rozkładu $\chi^2(j)$, gdzie j oznacza liczbę nałożonych restrykcji, ma miejsce w przypadku prób bardzo dużych, tj. przekraczających 3000 obserwacji.

9.6. Zastosowania wielowymiarowych modeli GARCH

► Przykład 9.2

Tsay [2002] omawia przykład dwuwymiarowego modelu GARCH(1, 1) ze stałym współczynnikiem korelacji. Przykład dotyczy współzależności między indeksami giełdowymi Hongkongu i Japonii w okresie od 1.01.1996 do 16.10.1997, co daje 469 dziennych obserwacji. Okres ten nie obejmował azjatyckiego kryzysu finansowego. Do modelowania wykorzystano stopy zysku z portfeli rynkowych obu giełd. Przez r_{1t} oznaczono zwrot z indeksu w Hongkongu, zaś przez r_{2t} stopę zwrotu z indeksu w Japonii.

W pierwszej fazie badania do opisu warunkowej średniej użyto modeli AR, natomiast do opisu wariancji warunkowych wykorzystano jednowymiarowe modele GARCH(1, 1). Oszacowane modele miały postać:

$$\begin{aligned}r_{1t} &= 0,137r_{1t-1} + \varepsilon_{1t}, \\h_{1t} &= 0,164 + 0,142\varepsilon_{1t-1}^2 + 0,765h_{1t-1}, \\r_{2t} &= \varepsilon_{2t}, \\h_{2t} &= 0,085 + 0,128\varepsilon_{2t-1}^2 + 0,807h_{2t-1}.\end{aligned}$$

Wszystkie oceny parametrów są statystycznie istotne, a statystyka Boxa-Ljunga nie wskazuje na złą specyfikację modeli. Mimo to oszacowano dwuwymiarowy model GARCH(1, 1) przy założeniu stałych korelacji. Otrzymano następujący model:

— dla warunkowej średniej:

$$\begin{aligned}r_{1t} &= -0,118r_{1t-6} + \varepsilon_{1t}, \\r_{2t} &= \varepsilon_{2t},\end{aligned}$$

— dla warunkowej wariancji:

$$\begin{bmatrix} h_{11,t} \\ h_{22,t} \end{bmatrix} = \begin{bmatrix} 0,275 \\ 0,051 \end{bmatrix} + \begin{bmatrix} 0,112 & 0 \\ 0 & 0,091 \end{bmatrix} \begin{bmatrix} \varepsilon_{1t-1}^2 \\ \varepsilon_{2t-1}^2 \end{bmatrix} + \begin{bmatrix} 0,711 & 0 \\ 0 & 0,869 \end{bmatrix} \begin{bmatrix} h_{11,t-1} \\ h_{22,t-1} \end{bmatrix}.$$

Oszacowany współczynnik korelacji między ε_{1t} i ε_{2t} przyjął wartość 0,226 z błędem standardowym 0,047.

Jak widać, wszystkie parametry są statystycznie istotne, a łączne statystyki Boxa-Ljunga dla modeli opisujących warunkową średnią i wariancję wskazują brak autokorelacji zarówno stóp zwrotu, jak i indeksów. Obydwie macierze ocen parametrów w modelu warunkowej wariancji są diagonalne, co wskazuje, że zmienność obu rynków nie jest dynamicznie powiązana, ale jest w danym czasie skorelowana. Model taki nazywa się *diagonalnym modelem stałych korelacji*.

► Przykład 9.3

Fiszeder [2001] szacował dwuwymiarowe modele t -BEKK opisujące relacje między indeksem WIG a innymi indeksami dotyczącymi wybranych segmentów polskiego rynku giełdowego. W badanych modelach przyjęto, że warunkowy rozkład stóp zwrotu ma postać t -Studenta.

Przykładowo, model opisujący relację stóp zysku z portfeli reprezentowanych przez WIG (r_{1t}) oraz WIGbanki (r_{2t}), na podstawie danych dziennych z okresu 5.01.1998–29.02.2000, przedstawia się następująco:

— dla warunkowej średniej:

$$\begin{aligned}r_{1t} &= 0,0004 + 0,0882r_{1t-1} + \varepsilon_{1t}, \\r_{2t} &= 0,0009 + 0,1062r_{2t-1} + \varepsilon_{2t},\end{aligned}$$

— dla warunkowej wariancji:

$$\begin{bmatrix} h_{11,t} & h_{12,t} \\ h_{21,t} & h_{22,t} \end{bmatrix} = \begin{bmatrix} 0,030 & 0,030 \\ 0,030 & 0,016 \end{bmatrix} \begin{bmatrix} 0,030 & 0,030 \\ 0,030 & 0,016 \end{bmatrix}' +$$

$$+ 0,0759 \begin{bmatrix} \varepsilon_{1,t-1}^2 & \varepsilon_{1,t-1}\varepsilon_{2,t-1} \\ \varepsilon_{2,t-1}\varepsilon_{1,t-1} & \varepsilon_{2,t-1}^2 \end{bmatrix} + 0,8839 \begin{bmatrix} h_{11,t-1} & h_{12,t-1} \\ h_{21,t-1} & h_{22,t-1} \end{bmatrix},$$

$$v = 13,44,$$

$$Q_1(12) = 16,06, \quad Q_1^2(12) = 8,73,$$

$$Q_2(12) = 5,33, \quad Q_2^2(12) = 12,18.$$

Interpretacja: należy zauważyć, że oszacowany model uprościł się w taki sposób, że zamiast macierzy $\mathbb{D}_{jk}^*$ i $\mathbb{E}_{jk}^*$ otrzymano składowe, czyli zarówno wariancje, jak i kowariancje zmieniały się w tych samych proporcjach. Wszystkie oszacowane parametry modelu są istotne statystycznie, co świadczy o tym, że omawiane

powiązania są wiarygodne. Przy prezentacji wyników pominięto błędy szacunku parametrów macierzy C^0 , ale oszacowania te również okazały się istotne.

Reszty modelu nie wykazują autokorelacji zarówno w swych poziomach, jak i w kwadratach, o czym świadczą wartości statystyk Boxa-Ljunga, przy czym Q_1 odnosi się odpowiednio do pierwszego równania dla stóp zwrotu z indeksu WIG, a Q_1^2 do reszt z pierwszego równania modelu t -BEKK. Analogicznie interpretujemy Q_2 .

Liczba stopni swobody wyniosła 13,44, co oznacza, że rozkład warunkowy stóp zwrotu ma grubsze ogony niż rozkład normalny, czyli przypadków nietypowych jest więcej niż wynikałoby to z rozkładu normalnego. Należy pamiętać, że zbieżność rozkładu t -Studenta do normalnego następuje przy 30 stopniach swobody.

Interakcje między indeksem WIG zawierającym cały skład portfela rynkowego a indeksem branżowym sektora bankowego wydają się naturalne. Sektor bankowy ma znaczny udział w kapitalizacji giełdy warszawskiej, stąd jego wpływ na indeks WIG. O wpływie rynku na poszczególne portfele wnioskujemy zwykle na podstawie jednorównaniowych modeli Sharpe'a. Wpływ ten, jak się okazuje, dotyczy nie tylko wartości oczekiwanych, ale również wariancji i kowariancji.

Przykład 9.4

Badanie empiryczne dotyczyło analizy zależności przyczynowych w zakresie powiązań między wybranymi giełdami światowymi i walutami, ze szczególnym uwzględnieniem ich związku z Warszawską Giełdą Papierów Wartościowych. Przedmiotem analizy były następujące szeregi czasowe: DAX, DJIA, FTSE, HSI, WIG oraz kursy walut PLN/EURO i PLN/USD, rozpatrywane w okresie 01.1999–31.12.2003, co dawało łącznie 1296 obserwacji dziennych. Analiza przyczynowości została przeprowadzona za pomocą testu Cheunga i Nga (z uwagi na liczbę obserwacji pominięto test Caporale'a i in.) dla szeregów przefiltrowanych poprzednio za pomocą modeli ARIMA-GARCH. Wykryte powiązania dają podstawę do budowy wielowymiarowych modeli GARCH.

Tabela 9.1. Wyniki testu Cheunga i Nga dla badanych zależności przyczynowych; $i \in (-36, 36)$

Kierunek zależności	Przyczynowość	Przyczynowość jednoczesna
WIG $\rightarrow$ USD	35,87	38,74
USD $\rightarrow$ WIG	29,00	31,87
WIG $\rightarrow$ EURO	18,46	26,39
EURO $\rightarrow$ WIG	38,90	46,83
WIG $\rightarrow$ DAX	37,95	48,53

cd. tablicy 9.1

Kierunek zależności	Przyczynowość	Przyczynowość jednoczesna
DAX $\rightarrow$ WIG	48,12	58,70*
WIG $\rightarrow$ DJIA	49,88	52,98*
DJIA $\rightarrow$ WIG	53,98*	57,07*
WIG $\rightarrow$ FTSE	36,39	56,32*
FTSE $\rightarrow$ WIG	31,05	50,98
WIG $\rightarrow$ HSI	43,40	96,46**
HSI $\rightarrow$ WIG	31,06	84,12**
DJIA $\rightarrow$ DAX	25,98	123,84**
DAX $\rightarrow$ DJIA	99,77**	196,63**
USD $\rightarrow$ EURO	32,74	320,04**
EURO $\rightarrow$ USD	30,23	317,54**
FTSE $\rightarrow$ DAX	36,45	262,75**
DAX $\rightarrow$ FTSE	149,23**	375,54**
HSI $\rightarrow$ DAX	25,35	27,27
DAX $\rightarrow$ HSI	146,53**	148,46**
FTSE $\rightarrow$ DJIA	92,72**	175,36**
DJIA $\rightarrow$ FTSE	115,56**	198,20**
HSI $\rightarrow$ DJIA	102,04**	102,51**
DJIA $\rightarrow$ HSI	111,98**	112,45**
HSI $\rightarrow$ FTSE	52,93*	84,62**
FTSE $\rightarrow$ HSI	145,77**	177,47**

* Zależność przyczynowa istotna na poziomie 5%.

** Zależność istotna na poziomie 1%.

Źródło: Opracowanie własne.

Pytania i problemy

1. Wyjaśnij istotę wielorównaniowego modelu GARCH na przykładzie VechGARCH.
2. Wyjaśnij istotę i zastosowanie modelu ze stałymi współczynnikami korelacji.
3. Model BEKK w analizie zmienności.
4. Na czym polega przyczynowość w zakresie wariancji warunkowej?
5. Zapisz definicję przyczynowości jednoczesnej w wariancji. Jaka jest jej interpretacja?
6. Testowanie przyczynowości w zakresie wariancji.
7. Na czym polega zjawisko zarażania? Jak zbadać wpływ kryzysu w jednym kraju na rynki finansowe w innych gospodarkach?

- Alexander C. [2003], *Market Models*, John Wiley, New York.
- Andersen T., Bollerslev T. [1997], *Answering the Critics: Yes ARCH Models do Provide Good Volatility Forecasts*, National Bureau of Economic Research Working Paper, 6023.
- Baba Y., Engle R.F., Kraft D., Kroner K.F. [1990], *Multivariate Simultaneous Generalised ARCH*, Department of Economics, University of California, San Diego.
- Baillie R.T., Bollerslev T. [1989], *The Message in Daily Exchange Rates: a Conditional Variance Tale*, „Journal of Business and Economic Statistics”, No. 7.
- Baillie R.T., Bollerslev T. [1992], *Prediction in Dynamic models with Time-Dependent Conditional Variances*, „Journal of Econometrics”, vol. 52.
- Bauwens L., Lubrano M., Richard J.-F. [1999], *Bayesian Inference in Dynamic Econometric Models*, Oxford University Press, Oxford.
- Bera A.K., Higgins M.L. [1993], *ARCH Models: Properties, Estimation and Testing*, „Journal of Economic Surveys”, vol. 7.
- Best P. [2001], *Wartość narażona na ryzyko. Obliczanie i wdrażanie modelu*, Oficyna Ekonomiczna, Kraków.
- Białkowski J., Bohl M.T., Serwa D. [2004], *Testing for Financial Spillovers in Calm and Turmoil Periods*, Uniwersytet Europejski Viadrina, Frankfurt nad Odrą.
- Bień K. [2004], *Wykorzystanie modeli autoregresywnego warunkowego czasu trwania do analizy intensywności transakcyjnej na GPW w Warszawie. Metody ilościowe w badaniach ekonomicznych*, cz. 4, pod red. A. Orlowskiego, Wyd. SGGW, Warszawa.
- Black F. [1976], *The Pricing of Commodity Contracts*, „Journal of Financial Economics”, vol. 3.
- Bollerslev T. [1986], *Generalized Autoregressive Conditional Heteroskedasticity*, „Journal of Econometrics”, vol. 31.
- Bollerslev T. [1988], *On the Correlation Structure of the Generalized Conditional Heteroscedastic Process*, „Journal of Time Series Analysis”, vol. 9.
- Bollerslev T. [1990], *Modelling the Coherence in Short Run Nominal Exchange Rates: a Multivariate Generalized ARCH Model*, „Review of Economics and Statistics”, vol. 72.
- Bollerslev T. [2001], *Financial Econometrics: Past Developments and Future Challenges*, „Journal of Econometrics”, vol. 100.
- Bollerslev T., Chou R.Y., Kroner K.F. [1992], *ARCH Modelling in Finance. A Review of the Theory and Empirical Evidence*, „Journal of Econometrics”, vol. 52.
- Bollerslev T., Engle R.F., Wooldridge J.M. [1988], *A Capital Asset Pricing Model with Time-Varying Covariances*, „Journal of Political Economy”, vol. 96.
- Bohl M.T., Brzeszczyński J. [2004], *Do Institutional Investors Destabilize Stock Prices? Emerging Market's Evidence Against a Popular Belief*, Uniwersytet Europejski Viadrina, Frankfurt nad Odrą.
- Bolt T., Miłobędzki P. [1994], *Empiryczna analiza procesów zachodzących na Warszawskiej Giełdzie Papierów Wartościowych w latach 1991–1993*, GAB, Gdańsk.
- Box G.E.P., Jenkins G.M. [1983], *Analiza szeregów czasowych: Prognozowanie i sterowanie*, PWN, Warszawa.
- Brock W.A., Dechert W.D., Scheinkman J.A. [1986], *A Test for Independence Based on Correlation Dimension*, Discussion Paper, Department of Economics, University of Wisconsin, Madison.
- Brockwell P.J., Davis R.A. [1996], *Introduction to Time Series and Forecasting*, Springer-Verlag, New York–Berlin.
- Bruzda J. [2001], *Metody identyfikacji kauzalnych odstępów czasowych w liniowych zależnościach ekonomicznych*, rozprawa doktorska, UMK, Toruń.
- Bruzda J. [2003], *Analiza falkowa — alternatywa dla spektralnej analizy procesów ekonomicznych? W: Dynamiczne modele ekonometryczne. Materiały zgłoszone na VIII Ogólnopolskie Seminarium Naukowe, 9–11 września 2003*, pod red. T. Kufla, M. Piłatowskiej, Wyd. UMK, Toruń.
- Bruzda J. [2003], *Procesy dwuliniowe i procesy GARCH w modelowaniu finansowych szeregów czasowych*, „Przegląd Statystyczny”, nr 2.
- Brzeszczyński J., Kelm R. [2002], *Ekonometryczne modele rynków finansowych*, WIG-Press, Warszawa.
- Campbell J.Y., Hentschel L. [1992], *No News is Good News: an Asymmetric Model of Changing Volatility in Stock Returns*, „Journal of Financial Economics”, vol. 31.
- Campbell J.Y., Lo A.W., MacKinlay A.C. [1997], *The Econometrics of Financial Markets*, Princeton University Press, Princeton.
- Cao C.Q., Tsay R.S. [1993], *Nonlinear Time Series Analysis of Stock Volatilities*, W: *Nonlinear Dynamics, Chaos and Econometrics*, M.H. Pesaran, S.M. Potter (red.), Wiley, New York.
- Caporale G.M., Gil-Alana L.A. [2003], *Long Range Dependence in Daily Stock Returns*, Centre for Monetary and Financial Economics, South Bank University, London.
- Caporale G.M., Pittis N., Spagnolo N. [2002a], *Testing for Causality-in-Variance: an Application to the East Asian Markets*, „International Journal of Finance and Economics”, vol. 7.
- Caporale G.M., Pittis N., Spagnolo N. [2002b], *Volatility transmission and financial crises*, Centre for Monetary and Financial Economics, South Bank University, London.
- Charemza W.W. [1990], *The Free Market for Foreign exchange in Poland: Cointegration, Speculative Bubbles and Error Correction*, Discussion Paper, No 133, University of Leicester, Leicester.
- Charemza W.W. [1994], *Detecting Stochastic Bubbles on an East European Foreign Exchange Market: an Estimation/Simulation Approach*, University of Leicester, Leicester.
- Charemza W.W., Deadman D. [1997], *Nowa ekonometria*, PWE, Warszawa.
- Charemza W.W., Makarova S. [1999], *The LAM-3 Model of East European Economies: Foundations and Specification*, W: *Macromodels '98: Proceedings of the XXV Conference*, pod red. W. Welfe, Absolwent, Łódź.

- Chung Y.-V., Ng L.K. [1996], *A Causality-in-Variance Test and its Application Financial Market Prices*, „Journal of Econometrics”, vol. 72.
- Chow G. [1995], *Ekonometria*, Wyd. Nauk. PWN, Warszawa.
- Christie A. [1982], *The Stochastic Behavior of Common Stock Variances. Value Leverage and Interest Rate Effect*, „Journal of Financial Economics”, vol. 10.
- Clark P.K. [1973], *A Subordinated Stochastic Process Model with Finite Variance for Speculative Prices*, „Econometrica”, vol. 41.
- Clements M.P., Hendry D.F. [1999], *Forecasting Non-stationary Economic Time Series*, MIT Press, Cambridge, Mass.
- Cuthbertson K. [1997], *Quantitative Financial Economics*, John Wiley, New York.
- Cuthbertson K., Hall S.G., Taylor M.P. [1992], *Applied Econometric Techniques*, Philip Allan, Harvester Wheatsheaf, London.
- Czekaj J., Woś M., Żarnowski J. [2001], *Efektywność giełdowego rynku akcji w Polsce. Z perspektywy dziesięciolecia*, Wyd. Nauk. PWN, Warszawa.
- Danielsson J. [1994], *Stochastic volatility in asset prices: estimation with simulated maximum likelihood*, „Journal of Econometrics”, vol. 64.
- Davidson R., MacKinnon J. [1981], *Several Tests for Model Specification in the Presence of Alternative Hypotheses*, „Econometrica”, vol. 49.
- DiBa T.B., Grossman H.I. [1988], *The Theory of Rational Bubbles in Stock Prices*, „Economic Journal”, vol. 98.
- Dickey D.A., Fuller W.A. [1979], *Distributions of the Estimators for Autoregressive Time Series with a Unit Root*, „Journal of the American Statistical Association”, vol. 74.
- Dickey D.A., Hasza D.P., Fuller W.A. [1984], *Testing for Unit Roots in Seasonal Time Series*, „Journal of the American Statistical Association”, vol. 79.
- Doman M. [2002], *Volume's and Volatility of Stock Returns on the Warsaw Stock Exchange*. W: *Macromodels 2001: Proceedings of the XXVI Conference*, pod red. W. Welfe, Łódź.
- Doman M. [2004], *Co-Movement Between Returns of Foreign Exchange Rates in the Central European Countries*, referat wygłoszony na Konferencji Międzynarodowej — Forecasting Financial Markets and Economic Decision-making (FindEcon 2004), Łódź.
- Doman R. [2002a], *Classification of Complexity of Polish Stock Returns and Exchange Rates*. W: *Macromodels 2001: Proceedings of the XXVI Conference*, pod red. W. Welfe, Łódź.
- Doman R. [2002b], *Forecasting the Polish Stock Market Volatility: a Comparison Between GARCH and SV Models' Abilities*. W: *Macromodels 2002: Proceedings of the XXVI Conference*, pod red. W. Welfe, A. Welfe, Wyd. UE, Łódź.
- Doman R. [2004], *Forecasting the Polish Stock Market Volatility With Hamilton's Markov Switching Models*. W: *Macromodels 2003*, pod red. W. Welfe, A. Welfe, Wyd. UE, Łódź.
- Dowd K. [1998], *Beyond Value at Risk. The New Science of Risk Management*, John Wiley, New York.
- Domis Ch. (red.) [2001], *Prognozowanie rynków finansowych. Kursy walutowe, stopy procentowe, zarządzanie aktywami*, Oficyna Ekonomiczna, Kraków.
- Durbin J., Koopman S.J. [2002], *Time Series Analysis by State Space Methods*, Oxford University Press, Oxford.
- Eltis E.J., Gruber M.J. [1995], *Modern Portfolio Theory and Investment Analysis*, John Wiley, New York.
- Enders W. [1995], *Applied Econometric Time Series*, John Wiley, New York.

- Engle R.F. [1982], *Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation*, „Econometrica”, vol. 50.
- Engle R.F. [1990], *Discussion: Stock Market Volatility and the Crash of 1987*, „Review of Financial Studies”, vol. 3.
- Engle R.F. [2001], *Financial Econometrics — A New Discipline with New Methods*, „Journal of Econometrics”, vol. 100.
- Engle R.F. [2002], *Dynamic Conditional Correlation — a Simple Class of Multivariate GARCH Models*, „Journal of Business and Economic Statistics”, vol. 20.
- Engle R.F., Bollerslev T. [1986], *Modelling the Persistence of Conditional Variances*, „Econometric Reviews”, vol. 5.
- Engle R.F., Granger C.W.J. [1987], *Cointegration and Error Correction: Representation, Estimation and Testing*, „Econometrica”, vol. 55.
- Engle R.F., Hendry D.F., Richard J.-F. [1983], *Exogeneity*, „Econometrica”, vol. 51.
- Engle R.F., Kraft D. [1982], *Autoregressive Conditional Heteroskedasticity in Multiple Time Series Models*, Discussion Papers, 82-2, University of California, San Diego.
- Engle R.F., Kroner K.F. [1995], *Multivariate Simultaneous Generalised ARCH*, „Journal of Economic Theory”, vol. 11.
- Engle R.F., Lilien D.M., Robins R.P. [1987], *Estimating Time Varying Risk Premia in the Term Structure: The ARCH-M Model*, „Econometrica”, vol. 55.
- Engle R.F., Russell J.R. [1998], *Autoregressive Conditional Duration: a New Approach for Irregularly Spaced Transaction Data*, „Econometrica”, vol. 66.
- Ericsson N.R., Hendry D.F. [1989], *Encompassing and Rational Expectations: How Sequential Corroboration Can Imply Refutation?*, Board of Governors of the Federal Reserve System. Discussion Paper, No 354.
- Fama E. F. [1965], *The Behaviour of Stock Market Prices*, „Journal of Business”, vol. 38.
- Fama E.F. [1970], *Efficient Capital Markets: a Review of Theory and Empirical Work*, „Journal of Finance”, vol. 26.
- Fama E.F. [1991], *Efficient Capital Markets: II*, „Journal of Finance”, vol. 46.
- Feller W. [1987], *Wstęp do rachunku prawdopodobieństwa*, wyd. 5, PWN, Warszawa.
- Fisz M. [1969], *Rachunek prawdopodobieństwa i statystyka matematyczna*, PWN, Warszawa.
- Fiszeder P. [2001], *Zastosowania modeli GARCH w ekonometrycznej analizie procesów giełdowych*, rozprawa doktorska, UMK, Toruń.
- Fiszeder P., Razik W. [2003], *Analiza efektu zarażania na przykładzie zależności pomiędzy indeksem WIG a indeksami wybranych rynków akcji na świecie*, Acta Universitatis Nicolai Copernici, Ekonomia XXXIII, Wyd. UMK, Toruń.
- Franses P.F. [1996], *Periodicity and Stochastic trends in Economic Time Series*, Oxford University Press, Oxford.
- Fuller W.A. [1976], *Introduction to Statistical Time Series*, John Wiley, New York.
- Gajda J.B. [2002], *Ekonometria praktyczna*, wyd. 3, Absolwent, Łódź.
- Geweke J., Meese R., Dent W. [1983], *Comparing Alternative Tests for Causality in Temporal Systems*, „Journal of Econometrics”, vol. 21.
- Ghysels E., Osborn D.B., Rodrigues P.M.M. [1999], *Seasonal Nonstationarity and Near-nonstationarity*, CIRANO, Montreal.
- Gil-Alana L.A., Toro J. [2002], *Estimation and Testing of ARFIMA Models in the Real Exchanger Rate*, „International Journal of Finance and Economics”, vol. 7.

- Glostein L., Jagannathan R., Runkle D.E. [1993], *On the Relation Between the Expected Value and the Volatility on the Nominal Excess Return on Stocks*, „Journal of Finance”, vol. 48.
- Gourieroux C., [1997], *ARCH Models and Financial Applications*, Springer-Verlag, New York–Berlin.
- Gourieroux C., Jasiak J. [2001], *Financial Econometrics. Problems, Models and Methods*, Princeton University Press, Princeton.
- Gourieroux C., Monfort A. [1997], *Time Series and Dynamic Models*, Cambridge University Press, Cambridge.
- Górka J. [2001], *Wybrane reprezentacje stochastyczne ekonomicznych szeregów czasowych*, rozprawa doktorska, UMK, Toruń.
- Górka J., Osińska M. [2001], *Efekty agregacji czasowej szeregów finansowych w świetle analizy spektralnej*. W: *Dynamiczne Modele Ekonometryczne. Materiały zgłoszone na VII Ogólnopolskie Seminarium Naukowe, 4–6 września 2001*, Wyd. UMK, Toruń.
- Górka J., Osińska M. [2003], *Analiza spektralna stóp zwrotu z inwestycji w akcje*. „Nasz Rynek Kapitałowy”, nr 1.
- Granger C.W.J. [1969], *Investigating Causal Relations by Econometric Models and Cross-Spectral Methods*, „Econometrica”, vol. 37.
- Granger C.W.J., Andersen A.P. [1978], *An Introduction to Bilinear Time Series Models*, Vandenhoeck and Ruprecht, Göttingen.
- Granger C.W.J., Huang B.-N., Yang C.-W. [2000], *A Bivariate Causality Between Stock Prices and Exchange Rates: Evidence from Recent Asian Flu*, „The Quarterly Review of Economics and Finance”, vol. 40.
- Granger C.W.J., Joyeux J. [1980], *An Introduction to Long Memory Time Series and Fractional Differencing*, „Journal of Time Series Analysis”, vol. 1.
- Granger C.W.J., Swanson N.R. [1997], *An Introduction to Stochastic Unit-Root Process*, „Journal of Econometrics”, vol. 80.
- Granger C.W.J., Teräsvirta T. [1993], *Modelling Nonlinear Economic Relationships*, Oxford University Press, Oxford.
- Greene W.H. [1994], *Econometric Analysis*, Macmillan Publishing Company, New York.
- Greń J. [1979], *Statystyka matematyczna. Model i zadania*, PWN, Warszawa.
- Haas M. [2001], *New Methods in Backtesting*, Financial Engineering Research Center, Bonn.
- Hamilton J.D. [1994], *Time Series Analysis*, Princeton University Press, Princeton.
- Hansen B.E. [1996], *Inference When a Nuisance Parameter is Not Identified Under the Null Hypothesis*, „Econometrica”, vol. 64.
- Hansen B.E. [1997], *Inference in TAR Models*, „Studies in Nonlinear Dynamics and Econometrics”, vol. 2.
- Harvey A.C. [1993], *Time Series Models*, Harvester Wheatsheaf, London.
- Haugen R.A. [1996], *Teoria nowoczesnego inwestowania*, WIG-Press, Warszawa.
- Hendry D.F., Muellbauer J.H., Murphy A. [1990], *The Econometrics of DHSY*. W: *A Century of Economics: 100 Years of the Royal Society and the Economic Journal*, J.D. Hey, O. Winch (red.), Basil Blackwell, Cambridge, Mass.-Oxford.
- Hendry D.F., Richard J.-F. [1982], *On the Formulation of Empirical Models in Dynamic Econometrics*, „Journal of Econometrics”, vol. 20.
- Hendry D.F., Richard J.-F. [1983], *The Econometric Analysis of Economic Time Series*, „International Statistical Review”, vol. 51.

- Hendry D.F., Richard J.-F. [1989], *Recent Developments in Theory of Encompassing*. W: *Contributions to Operations Research and Economics*, B. Cornet, H. Tulkens (red.), MIT Press, Cambridge, Mass.
- Hyżyk S., Osińska M. [1999], *Wykorzystanie zmienności wariancji warunkowej do opisu i prognozowania kursów walutowych*, przyjęte do druku w *Acta Universitatis Nicolai Copernici, Oeconomia XXX*, UMK, Toruń.
- Jajuga K. [2000], *Metody ekonometryczne i statyczne w analizie rynku kapitałowego*, Wyd. AE, Wrocław.
- Jajuga K. [2001a], *Podstawy analizy wartości ekstremalnych na rynkach finansowych*, „Rynek Terminowy”, nr 11.
- Jajuga K. [2001b], *Value at risk*, „Rynek Terminowy”, nr 13.
- Jajuga K., Jajuga T. [1996], *Inwestycje*, PWN, Warszawa.
- Jajuga K., Jajuga T. [2001], *Inwestycje. Instrumenty finansowe, ryzyko finansowe, inżynieria finansowa*, Wyd. Nauk. PWN, Warszawa.
- Jeziorska-Papka M., Osińska M., Witkowski M. [2004], *Forecasting returns using threshold models*, referat wygłoszony na Konferencji Międzynarodowej Forecasting Financial Markets and Economic Decision-making (FindEcon 2004), Łódź.
- Johansen S. [1988], *Statistical Analysis of Cointegration Vectors*, „Journal of Economic Dynamics and Control”, vol. 12.
- Johansen S. [1991], *Estimation and Hypothesis Testing of Cointegration Vectors in Gaussian Vector Autoregressive Models*, „Econometrica”, vol. 59.
- Johansen S. [1992], *Determination of Cointegration Rank in the Presence of a Linear Trend*, „Oxford Bulletin of Economics and Statistics”, vol. 54.
- Johansen S., Juselius K. [1990], *Maximum Likelihood Estimation and Inference on Cointegration — with Applications to the Demand for Money*, „Oxford Bulletin of Economics and Statistics”, vol. 52.
- Judge G.G., Griffiths W.E., Hill R.C., Lee T.C. [1985], *The Theory and Practice of Econometrics*, John Wiley, New York.
- Krauze K. [2002], *Modelowanie ekonometryczne i weryfikacja hipotez dotyczących integracji i kointegracji szeregów czasowych w warunkach występowania załamania strukturalnych*, Wyd. UG, Gdańsk.
- Kufel T. [2002], *Postulat zgodności w dynamicznych modelach ekonometrycznych*, Wyd. UMK, Toruń.
- Kufel T. [2004], *Ekonometria. Rozwiązywanie problemów z wykorzystaniem programu Gretl*, Wyd. Nauk. PWN, Warszawa.
- Kunst R.M. [1992], *Cointegrated ARCH Systems: Dynamic Patterns in Interest Rates. Proceedings of the XXXIInd AEA International Conference „Econometrics of Europe 2000”*, Brussels.
- Kupiec P. [1995], *Techniques for Verifying the Accuracy of Risk Measurement Models*, „Journal of Derivatives”, winter.
- Kusidł E. [2000], *Modele wektorowo-autoregresyjne VAR. Metodologia i zastosowania*, Absolutent, Łódź.
- Kuziak K. [1999], *Model wyceny arbitrażowej (APM) — ujęcie dynamiczne*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na VI Ogólnopolskie Seminarium Naukowe, 7–9 września 1999*, Wyd. UMK, TNOiK „Dom Organizatora”, Toruń.

- Kwiatkowski J. [1999], *Bayesowska analiza modeli ARFIMA i persystencji na przykładzie kursu jednostek uczestnictwa funduszu Pioneer*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na VI Ogólnopolskie Seminarium Naukowe*, 7–9 września 1999, Wyd. UMK, TNOiK „Dom Organizatora”, Toruń.
- Kwiatkowski J., Osiewalski J. [2001], *Modele ARFIMA: podstawowe własności i analiza bayesowska*, „Przegląd Statystyczny”, nr 1.
- Kwiatkowski J., Osieńska M. [2003], *Procesy zawierające stochastyczne pierwiastki jednostkowe — identyfikacja i zastosowanie*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na VIII Ogólnopolskie Seminarium Naukowe*, 9–11 września 2003, pod red. T. Kufla, M. Piłatowskiej, Wyd. UMK, Toruń.
- Lamoureux C.G., Lastrapes W.D. [1990], *Heteroscedasticity in Stock Return Data: Volume Versus GARCH Effects*, „Journal of Finance”, vol. 45.
- Lau L.J. [1986], *Functional Forms in Econometric Model Building*, W: *Handbook of Econometrics*, Z. Griliches, M.D. Intriligator (red.), Elsevier North Holland, Amsterdam.
- Lee S. [1998], *Coefficient Constancy Test in a Random Coefficient Autoregressive Model*, „Journal of Statistical Planning and Inference”, vol. 74.
- LeRoy S.F. [1989], *Efficient Capital Markets and Martingales*, „Journal of Economic Literature”, vol. 27.
- Leysbourne S.J., McCabe B.P.M., Mills T.C. [1996], *Randomized Unit Root Processes for Modeling and Forecasting Financial Time Series: Theory and Applications*, „Journal of Forecasting”, vol. 15.
- Leysbourne S.J., McCabe B.P.M., Tremayne A.R. [1996], *Can Economic Time Series be Differenced to Stationarity?*, „Journal of Business and Economic Statistics”, vol. 14.
- Liberańska B. [2002], *Globalizacja. Mechanizmy i wyzwania*, PWE, Warszawa.
- Lilliefors H.W. [1967], *On the Kolmogorov-Smirnov Test for Normality with Mean and Variance Unknown*, „Journal of the American Statistical Association”.
- Lin C.-F.J., Teräsvirta T. [1994], *Testing the Constancy of Regression Parameters Against Continuous Structural Change*, „Journal of Econometrics”, vol. 62.
- Lin T., Granger C.W.J., Heller W.P. [1993], *Using the Correlation Exponent to Decide Whether an Economic Series is Chaotic*. W: *Nonlinear Dynamics, Chaos and Econometrics*, M.H. Pesaran, S.M. Potter (red.), John Wiley, New York.
- Lütkepohl H. [1991], *Introduction to Multiple Time Series*, Springer-Verlag, New York–Berlin.
- Maddala G.S., Kim I.-M. [2002], *Unit Roots, Cointegration and Structural Change*, Cambridge University Press, Cambridge.
- Majsterek M., Welfe A. [2000], *Analiza kointegracyjna. Sprzężenie inflacyjne*. W: *Gospodarka polska w okresie transformacji*, PWE, Warszawa.
- Mandelbrot B. [1963], *The Variation of Certain Speculative Prices*, „Journal of Business”, vol. 36.
- Marcinkowska-Lewandowska W., Serwa D. [2002], *Dwa przykłady wykorzystania modeli progowych do analizy rynków finansowych*. W: *Rynek kapitałowy. Skuteczne inwestowanie*, pod red. W. Tarczyńskiego, Wyd. Nauk. USz, Szczecin.
- McCabe B.P.M., Tremayne A.R. [1995], *Testing a Time Series for Difference Stationarity*, „Annals of Statistics”, vol. 23.
- Melino A., Turnbull S. [1990], *Pricing Foreign Currency Options with Stochastic Volatility*, „Journal of Econometrics”, vol. 45.

- Mills T.C. [2002], *The Econometric Modelling of Financial Time Series*, Cambridge University Press, Cambridge.
- Milo W. [2002], *Wybór portfela inwestycyjnego*, Wyd. UŁ, Łódź.
- Muth J.F. [1961], *Rational expectations and the theory of price movement*, „Econometrica”, vol. 29.
- Nelson D. [1990], *Stationarity and Persistence in GARCH(1, 1) Model*, „Econometric Theory”, vol. 6.
- Nelson D. [1991], *Conditional heteroscedasticity in asset returns: A new approach*, „Econometrica”, vol. 59.
- Nicholls D.F., Quinn B.G. [1982], *Random Coefficient Autoregressive Models: An Introduction*, Lecture Notes in Statistics, vol. 11, Springer-Verlag, New York–Berlin.
- Nonlinear Dynamics, Chaos and Econometrics*, M.H. Pesaran, S.M. Potter (red.) [1993], John Wiley, New York.
- Nowak E. [2002], *Zarys metod ekonometrii. Zbiór zadań*, Wyd. Nauk. PWN, Warszawa.
- Orzeszko W. [2004a], *Identyfikacja i prognozowanie chaosu deterministycznego w ekonomicznych szeregach czasowych*, rozprawa doktorska, UMK, Toruń.
- Orzeszko W. [2004b], *Metody identyfikacji i prognozowania chaotycznych szeregów czasowych*. W: *Metody ilościowe w naukach ekonomicznych. Czwarte Warsztaty Doktorskie z Zakresu Ekonometrii i Statystyki*, pod red. A. Welfe, Oficyna Wyd. SGH, Warszawa.
- Osiewalski J. [2001], *Ekonometria bayesowska w zastosowaniach*, Wyd. AE, Kraków.
- Osiewalski J., Pipień M. [1999a], *Bayesian Forecasting of Exchange Rates Using GARCH Models with Skewed t Conditional Distribution*. W: *Macromodels '98. Conference Proceedings*, pod red. W. Welfe, Absolwent, Łódź.
- Osiewalski J., Pipień M. [1999b], *Bayesowskie wnioskowanie o stacjonarności procesów GARCH (1, 1)*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na VI Ogólnopolskie Seminarium Naukowe*, 7–9 września 1999, Wyd. UMK, TNOiK „Dom Organizatora”, Toruń.
- Osiewalski J., Pipień M. [2000], *GARCH-in-Mean Through Skewed t Conditional Distributions — Bayesian Inference for Exchange Rates*. W: *Macromodels '99. Conference Proceedings*, Absolwent, Łódź.
- Osiewalski J., Pipień M. [2001], *Multivariate i-Garch Models — Bayesian Analysis for Exchange Rates*. W: *Modelling Economies in Transition. Proceedings of the Sixth AMFET Conference*, pod red. W. Welfe, Krag-Poland, Łódź.
- Osiewalski J., Pipień M. [2002], *Multivariate Arch-Type models: A Bayesian Comparison*. W: *Dynamic Econometric Models*, vol. 5 pod red. Z. Zielińskiego, UMK, Toruń.
- Osińska M. [1994], *Metody testowania przyczynowości zjawisk gospodarczych*, rozprawa doktorska, UMK, Toruń.
- Osińska M. [1995], *Ekonometryczna analiza zmian struktury trendowo-stochastycznej procesów makroekonomicznych w okresie transformacji*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na IV Ogólnopolskie Seminarium Naukowe*, 12–14 września 1995, Wyd. UMK, Toruń.
- Osińska M. [1996], *Modelling Structural Changes Using Smooth Transition Regression: a Case of Poland*, Research Memorandum 96/10, University of Leicester, Leicester.
- Osińska M. [2000], *Ekonometryczne modelowanie oczekiwań gospodarczych*, Wyd. UMK, Toruń.

- Osińska M. [2002], *Modele wielowymiarowych szeregów czasowych*. W: *Dynamiczne modele ekonometryczne u progu XXI wieku. Konferencja Naukowa, Analiza szeregów czasowych na początku XXI wieku, 3–4 września 2002*, Wyd. UMK, Toruń.
- Osińska M. [2003], *Stochastic Unit Roots Processes — Properties and Application*, referat prezentowany na XXX Międzynarodowej Konferencji Macromodels, Warszawa 2003.
- Osińska M. [2004], *Procesy zawierające stochastyczne pierwiastki jednostkowe — identyfikacja i zastosowanie*, Acta Universitatis Nicolai Copernici, *Ekonomia* XXXIV, Wyd. UMK, Toruń.
- Osińska M. (red.) [2005], *Wybrane zagadnienia z ekonometrii*, Wyd. Wyższej Szkoły Informatyki i Ekonomii TWP, Olsztyn.
- Osińska M., Pączka P. [1999], *Prognozowanie kursów walut w oparciu o modele ARIMA-ARCH*, Acta Universitatis Nicolai Copernici, *Ekonomia* XXIX, Wyd. UMK, Toruń.
- Osińska M., Romański J. [1994], *Testing for ARCH effects at the Warsaw Stock Exchange*. W: *Problems of Building and Estimation of Econometric Models, Proceedings of Macromodels '93*, part B, Absolwent, Łódź.
- Osińska M., Witkowski M. [2003], *Zastosowanie modeli progowych do analizy finansowych szeregów czasowych*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na VIII Ogólnopolskie Seminarium Naukowe, 9–11 września 2003*, pod red. T. Kufla, M. Piłatowskiej, Wyd. UMK, Toruń.
- Osterwald-Lenum M. [1992], *A Note with Fractiles of the Asymptotic Distribution of the Maximum Likelihood Cointegration Rank Test Statistics: Four Cases*, „Oxford Bulletin of Economics and Statistics”, vol. 54.
- Pajor A. [2003], *Procesy zmienności stochastycznej SV w bayesowskiej analizie szeregów czasowych*, Wyd. AE, Kraków.
- Perron P. [1989], *The great Crash, the Oil Price Shock and the Unit Root Hypothesis*, „Econometrica”, vol. 57.
- Perron P. [1993], *Erratum*, „Econometrica”, vol. 61.
- Perron P. [1997], *Further Evidence on Breaking Trend Function in Macroeconomic Variables*, „Journal of Econometrics”, No. 80.
- Peters E.E. [1997], *Teoria chaosu a rynki kapitałowe*, WIG-Press, Warszawa.
- Phillips P.C.B. [1995], *Fully Modified Least Squares and Vector Autoregression*, „Econometrica”, vol. 63.
- Phillips P.C.B., Perron P. [1988], *Testing for Unit Roots in Time Series Regression*, „Biometrika”, vol. 75.
- Pierce D.A., Haugh L.D. [1977], *Causality in Temporal Systems*, „Journal of Econometrics”, No. 5.
- Piłatowska M. [1995], *Identyfikacja procesów stochastycznych typu random walk*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na IV Ogólnopolskie Seminarium Naukowe, 12–14 września*, Wyd. UMK, Toruń.
- Piłatowska M. [2003], *Modelowanie niestacjonarnych procesów ekonomicznych. Studium metodologiczne*, Wyd. UMK, Toruń.
- Piontek K. [2002], *Modelowanie i prognozowanie zmienności instrumentów finansowych*, rozprawa doktorska, AE, Wrocław.
- Potter S.M. [1999], *Nonlinear Time Series Modelling*, John Wiley, New York.
- Priestley M.B. [1996], *Wavelets and Time-Dependent Spectral Analysis*, „Journal of Time Series Analysis”, vol. 17(1).

- Priestley M.B. [1981], *Spectral Analysis and Time Series*, Academic Press, London.
- Proietti T. [1998], *Characterizing Asymmetries in Business Cycles Using Smooth-Transition Structural Time-Series Models*, „Studies in Nonlinear Dynamics and Econometrics”, vol. 3.
- Pruska K. [1996], *Modele regresji przełącznikowej i ich zastosowanie*, Wyd. UL, Łódź.
- Rabemananjara R., Zakoian J.-M. [1993], *Threshold ARCH Models and Asymmetries in Volatility*, W: *Nonlinear Dynamics, Chaos and Econometrics*, M.H. Pesaran, S.M. Potter (red.), John Wiley, New York.
- Ramsey J. [1969], *Test for Specification Errors in Classical Linear Least Squares Regression Analysis*, „Journal of the Royal Statistical Society”, series B, vol. 31.
- Ramsey J.B., Lampart C. [1998], *The Decomposition of Economic Relationships by Time Scale Using Wavelets: Expenditure and Income*, „Studies in Nonlinear Dynamics and Econometrics”, vol. 3(1).
- Robinson P. [1994], *Efficient test of Nonstationary Hypotheses*, „Journal of the American Statistical Association”, vol. 89.
- Rocke D.M. [1982], *Inference for Response-Limited Time Series Models*, „Communications in Statistics, Theory and Methods”, vol. 11.
- Rogalski R.J., Vinso J.D. [1977], *Stock Returns, Money Supply and the Direction of Causality*, „Journal of Finance”, vol. 32.
- Romański J. [1995], *Testowanie bąbli spekulacyjnych — zagadnienia specyfikacji i estymacji na przykładzie WGPW*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na IV Ogólnopolskie Seminarium Naukowe, 12–14 września 1995*, Wyd. UMK, Toruń.
- Ruiz E. [1994], *Quasi-Maximum Likelihood Estimation of Stochastic Volatility Models*, „Journal of Econometrics”, vol. 63.
- Santoni G.J., Dwyer Jr. G.P. [1990], *Bubbles or Fundamentals: New Evidence from the Great Bull Markets*. W: *Crashes and Panics: The Lessons from History*, Wyd. E. White, Homewood.
- Shapiro S.S., Wilk M.B. [1965], *An Analysis of Variance Test for Normality*, „Biometrika”, vol. 52.
- Sims C.A. [1980], *Macroeconomics and Reality*, „Econometrica”, vol. 48.
- Sollis R., Leybourne S.J., Newbold P. [2000], *Stochastic Unit Roots Modeling of Stock Price Indices*, „Applied Financial Economics”, vol. 10.
- Stawicki J. [1993], *Metody filtracji w modelowaniu procesów ekonomicznych*, Rozprawy UMK, Toruń.
- Stawicki J., Górka J. [1995], *Reprezentacja ARMA procesów stochastycznych*. W: *Dynamiczne Modele Ekonometryczne. Materiały zgłoszone na IV Ogólnopolskie Seminarium Naukowe 12–14 września*, Wyd. UMK, Toruń.
- Strzala K. [1994], *Zastosowanie uogólnionych metod sterowania optymalnego do podejmowania decyzji gospodarczych*, Wyd. UG, Gdańsk.
- Szczewska E.M. [1999], *Analiza relacji długookresowych. Estymacja i weryfikacja*, Monografie i Opracowania, Oficyna Wyd. SGH, Warszawa.
- Szafarczyk E. [2001], *Metoda Value at Risk*, NBP, Materiały i Studia, z. 152.
- Szyska A. [1999], *Efektywność rynku a anomalie w rozkładach stóp zwrotu w czasie*, „Nasz Rynek Kapitałowy”, nr 12.
- Talaga L., Zieliński Z. [1986], *Analiza spektralna w modelowaniu ekonometrycznym*, PWN, Warszawa.

- Tarczyński W. [2001], *Rynki kapitałowe. Metody ilościowe*, wyd. 2, Placet, Warszawa.
- Tarczyński W. [2002], *Fundamentalny portfel papierów wartościowych*, PWE, Warszawa.
- Taylor A.M.R., van Dijk D. [1999], *Testing for Stochastic Unit Roots. Some Monte Carlo Evidence*, Econometric Institute Research Report, EI-9922/A.
- Teräsvirta T., Anderson H.M. [1993], *Characterizing Nonlinearities in Business Cycles Using Smooth Transition Autoregressive Models*. W: *Nonlinear Dynamics, Chaos and Econometrics*, M.H. Pesaran, S.M. Potter (red.), John Wiley, New York.
- Tong H. [1990], *Non-Linear Time Series*, Oxford Science Publications, New York.
- Tsay R.S. [2002], *Analysis of Financial Time Series*, John Wiley, New York.
- Tse Y.K. [2000], *A Test for Constant Correlations in a Multivariate GARCH Model*, „Journal of Econometrics”, vol. 98.
- Wei W.W.S. [1990], *Time Series Analysis*, Addison-Wesley Publishing Company, Amsterdam.
- Weiss A.A. [1986], *ARCH and Bilinear Time Series Models: Comparison and Combination*, „Journal of Business and Economic Statistics”, vol. 4.
- Welfe A. [2002], *Współczesne makroekonometryczne modele dynamiczne*, Rector's Lectures, nr 55, Wyd. AE, Kraków.
- Welfe A. [2003], *Ekonometria*, wyd. 3, PWE, Warszawa.
- Welfe A., Majsterk M. [2002], *Wage and Price Inflation in Poland in the Period of Transition: the Cointegration Analysis*, „Economics of Planning”, vol. 35.
- Weron A., Weron R. [1999], *Inżynieria finansowa. Wycena instrumentów pochodnych, symulacje komputerowe, statystyka rynku*, WNT, Warszawa.
- West K.D. [1987], *A Specification Test for Speculative Bubbles*, „The Quarterly Journal of Economics”, vol. 102.
- Wiśniewski J.W., Zieliński Z. [1998], *Elementy ekonometrii*, wyd. 3, Wyd. UMK, Toruń.
- Witkowski M. [1999], *Estymacja modeli nieliniowych SETAR z zastosowaniem do badania koniunktury gospodarki polskiej*. W: *Dynamiczne modele ekonometryczne. Materiały zgłoszone na VI Ogólnopolskie Seminarium Naukowe, 7–9 września 1999*, Wyd. UMK, TNOiK „Dom Organizatora”, Toruń.
- Zakoian J.-M. [1994], *Threshold Heteroscedastic Models*, „Journal of Economic Dynamics and Control”, vol. 18.
- Zeliasz A. [1997], *Teoria prognozy*, PWE, Warszawa.
- Zeliasz A., Pawelek B., Wanat S. [2003], *Prognozowanie ekonomiczne. Teoria, przykłady*, Wyd. Nauk. PWN, Warszawa.
- Zellner A. [1988], *Causality and Causal Laws in Econometrics*, „Journal of Econometrics”, vol. 39.
- Zieliński Z. [1979], *Metody analizy dynamiki i rytmiczności zjawisk gospodarczych*, PWN, Warszawa.
- Zieliński Z. [1991], *Liniowe modele ekonometryczne jako narzędzie opisu i analizy przyczynowych zależności zjawisk ekonomicznych*, Wyd. UMK, Toruń.
- Zieliński Z. [2002a], *Analiza wybranych koncepcji modelowania dynamicznego w ekonometrii*, Wyd. AE, Kraków.
- Zieliński Z. [2002b], *Analiza ekonomicznych procesów stochastycznych. Pisma wybrane*, Wyd. UMK, Toruń.
- Zwolankowska M. [2001], *Fraktalna geometria polskiego rynku akcji*, Rozprawy i Studia, nr 382, Wyd. USz, Szczecin.

Indeks

- Absolutna VaR 107, 108
- Amplituda wahań harmoniczných 157
- Analiza
- falkowa 157, 173
 - fundamentalna 16, 32
 - krótkookresowa, cechy 79
 - odpowiedzi na impuls 215
 - portfelowa 17
 - spektralna 156, 157
 - stóp zwrotu 166
 - strukturalna w modelu VAR 208
 - techniczna 16
 - wielorozdzielcza 172
 - zdarzeń jakościowych 182
- Arbitraż cenowy 194
- Asymetria rozkładów stóp zwrotu 136
- Asymetryczny model ARCH 90
- Ateoretyczne podejście do modelowania 205
- Autokorelacja 71, 98
- cząstkowa 52
 - stóp zwrotu 39, 41
- Autoregresyjny model warunkowego czasu trwania między transakcjami 100
- Badanie
- normalności 40
 - zależności przyczynowych 208
- Bayesowskie
- kryterium Schwartza 54
 - rozszerzenie minimum AIC 54
- Bąbel spekulacyjny, racjonalny 197, 198
- Biały szum 35, 36, 48, 49, 77, 80, 87, 96, 152, 164, 181
- Błądzenie
- losowe 34, 40
 - przypadkowe 32, 65
- Brzegowa wartość oczekiwana 80
- CAMP z efektem ARCH 104
- Cechy
- analizy krótkookresowej 79
 - procesów finansowych 79
- Cena
- akcji 79, 80
 - sprawiedliwa 16
- Ceny instrumentów finansowych 34, 80, 152
- Chaos deterministyczny 17, 126
- Cykliczność zachowań procesów stochastycznych 156
- Czas
- handlowy 100
 - kalendarzowy 99-100
 - rzeczywisty 100
 - trwania 100
 - transakcyjny 100
- Dane
- o ultrawysokiej częstotliwości 97
 - obserwowane w czasie transakcyjnym 102
 - tykowe 97, 102
 - transakcyjne 102
- Dekompozycja falkowa 171, 172
- Długa pamięć 76, 156
- Dodatność
- wariancji 91

warunkowej wariancji 81, 85
 Duration 100
 Dwuwymiarowy model BEKK 232
 Dyskretna transformata Fouriera 157
 Dyskretyzacja modelu dyfuzji 96
 Dzienna sezonowość transakcji 101–102
 Dźwignia finansowa 89

Efekt
 dnia w tygodniu 43, 156
 dźwigni 90
 godziny w dniu 43, 156
 miesiąca w roku 43
 poniedziałku 43
 stycznia 43, 156

Efekty
 kalendarzowe 14, 43
 sezonowe 43

Efektywność
 rynków finansowych 31
 rynku 26, 43
 silna 32
 słaba 31
 średnia 32

Egzogeniczność
 silna 214
 słaba, testowanie 214
 w modelu VAR 213

Ekonometria finansowa 15, 16, 17

Ekonomiczne
 procesy stochastyczne 48
 szeregi czasowe 48

Estymacja
 funkcji gęstości spektralnej 160
 parametrów modeli
 ARMA 55
 GARCH 92
 nieliniowych TAR 133
 VAR 219
 współczynników autokorelacji częstotkowej 52

Estymator
 funkcji
 gęstości spektralnej 161
 kowariancyjnej 51
 współczynnika autokorelacji 51

Falka
 „matka” 172
 „ojciec” 172

Filtr
 Kalmana 146
 rekursywność 146
 różnicowy 67

Filtracja 146

Finansowe szeregi czasowe 21, 30

Funkcja
 autokorelacji 35, 51, 71, 77
 cząstkowej 35, 51, 52, 71
 autokowariancyjna 77
 gęstości spektralnej 159, 160
 dla białego szumu 160
 zastosowania 168
 kowariancji wzajemnej 224
 kowariancyjna 48, 51
 nieliniowa, kryteria wyboru 127
 spektralna 158
 wzajemnej gęstości spektralnej 224

Gęstość spektralna 161

Gruby ogon rozkładu 28, 41, 82, 91, 97

Grupowanie wariancji 26

Hipoteza
 rynku
 efektywnego 30, 119
 fraktalnego 119
 niejednorodnego 119
 słabej efektywności rynku 42

Identyfikacja
 modeli ARMA 51, 52
 kryteria informacyjne 54
 procesu ARIMA 68
 szeregów ułamkowo zintegrowanych 169

Indeksy giełdowe 80

Integracyjna statystyka Durbina-Watsona 68

Intensywność przy danej częstotliwości 165

Inżynieria finansowa 17

Jednoczesna przyczyna 209

Jednorównaniowe modele nieliniowe szeregów czasowych 120

Jednorównaniowy model korekty błędem 188

Jednowymiarowe
 modele zmienności 79
 szeregi czasowe 47

Kąt fazowy 157

Klasyczna metoda najmniejszych kwadratów 55, 219

Kointegracja
 procesów stochastycznych 184, 199
 w modelach VAR, testowanie 218

Korelacja
 wzajemna 98
 zmienna w czasie 231

Kospektrum 224

Kowariancja 227

Krótkookresowa zmienność procesu 80

Kryteria
 dobroci modeli ARCH/GARCH 93
 informacyjne 71, 127
 wyboru funkcji nieliniowej 127

Kryterium
 błędu predykcji 54
 Hannana-Quinna 54
 informacyjne Akaike'a 54

Kurs walut 79, 80

Kurtoza rozkładu 96

Kwadorspektrum 224

Kwantyl rozkładu stóp zwrotu 106, 107

Logarytmiczna stopa zwrotu 22, 82

Losowość stóp zwrotu 39

Macierz
 dostosowań 217
 kointegrująca 217

Martyngal 32, 65, 82, 197

Matematyka finansowa 16

Mechanizm korekty błędem 188, 189

Metoda
 FM-VAR 220
 najmniejszych kwadratów 52, 55
 klasyczna 219
 uogólniona 219
 zmodyfikowana 220

największej wiarygodności 23, 55, 56, 92, 147, 220
 zmiennych instrumentalnych 220

Miara opisująca zdolność prognozowania punktów zwrotnych 93

Miary
 zgodności kierunku zmian 93, 94
 zmienności 23

Mikrostruktura rynku 79, 97

Minimalna reprezentacja modelu 50

Model
 AARCH 90
 ACD 100, 101
 ADL 180
 APM 194, 195
 APT 17
 AR 65, 145
 ARCH 17, 28, 81, 82, 101, 104
 Bollersleva 84
 ARFIMA 76, 169
 ARIMA 62, 71
 sezonowy 66
 ARMA 49, 65, 84, 86, 101, 122
 estymacja parametrów 55
 identyfikacja 52
 wektorowy 205
 ARMA-GARCH 108
 autoregresyjny 49, 144
 z losowymi parametrami 143
 z rozłożonymi opóźnieniami 180
 z warunkową heteroskedastycznością 81

BEKK 231
 dwuwymiarowy 232

Blancharda, Watsona i Westa 198

błądzenia przypadkowego 63, 144

CAPM 17

Diba i Grossmana 198

dla wartości średniej procesu 80

dwuliniowy 122

dynamiczny 47

EACD 101

ECM, związek z modelem ADL 190

EGARCH 90, 96

GARCH 17, 84, 85, 86, 93, 95, 104
 równoważna reprezentacja 86

stacjonarność 86
 w postaci PS 154
 wielorównaniowy 228, 229
 z asymetrią 90
 z rozkładem innym niż normalny 91
 GARCH-in-mean 88
 GARCH-M 88, 89
 generujący 33
 GJR 91
 IGARCH 87
 jednowymiarowy 79, 205
 korekty błędem, jednorównaniowy 188
 MA 65
 niestacjonarnych procesów stochastycznych 60
 niesynchronicznych transakcji 98
 NLAR 121, 129
 NLMA 121
 opisujący niesynchroniczne transakcje 98
 pojedynczego indeksu Sharpe'a 192
 progowy TAR 145
 przełącznikowy 125
 przestrzeni stanów, stabilność 140
 regresji liniowej 179
 dla procesów niestacjonarnych 183
 dla procesów stacjonarnych 180
 równowagi rynków kapitałowych 17
 równowagi rynku CAPM 103
 SARIMA 65, 67
 SETAR 123
 sezonowości 61
 stabilny 140
 stałych warunkowych korelacji 229
 stochastycznej zmienności 17
 STR 124
 STUR 148, 152
 SV 96
 w postaci PS 154
 szeregów czasowych 47, 79, 120
 średniej ruchomej MA 49
 TAR 123
 TARCH 91
 trendu 60
 VAR 205, 206
 analiza egzogeniczności 213

dla procesów skointegrowanych 216
 estymacja parametrów 219
 strukturalny 207
 VARMA 205, 207
 VARMAX 208
 VARX 208
 VEC 216, 217, 220
 VechGARCH 229
 wektorowej autoregresji 205
 wyceny arbitrażowej 194
 wygładzonego przejścia 124
 wykładniczy GARCH 90
 z racjonalnymi oczekiwaniami 197
 zgodny 180
 dla procesów stacjonarnych 181
 zmienności parametrów 143, 144
Modele
 ARCH/GARCH, praktyczne zastosowania 111
 GARCH
 wielowymiarowe z rozkładem t -Studenta 232
 własności prognostyczne 115
 zastosowania 238
 jednowymiarowych szeregów czasowych 47
 mikrostruktury rynku 28, 97, 102
 nieliniowej autoregresji 121
 niezagnieżdżone, porównywanie 202
 podwójnie stochastyczne 145
 procesów
 niestacjonarnych w zakresie
 funkcji kowariancyjnej 62
 wariancji 62
 wartości średniej 60
 ułamkowo zintegrowanych 76
 progowe 123
 rozkładów stóp zwrotu 26
 stacjonarnych procesów stochastycznych 49
 trendu deterministycznego 61
 uwzględniające różnice w czasie kalendarzowym i transakcyjnym 97
 wahań sezonowych 61
 ze zmienną w czasie korelacją 230, 231
 zmienności, zastosowania 103

Modelowanie
 danych o ultrawysokiej częstotliwości 17
 zgodne 181
 Nadwyżka stopy zwrotu 23
 Neutralne rozumienie ryzyka 23
 Niegaussowski rozkład 96, 117
 Nieliniowość w procesach finansowych 118
 Nieliniowy model
 szeregów czasowych 117
 średniej ruchomej 121
 Nieskończona średnia ruchoma MA 50
 Nieskończony model
 autoregresyjny 50
 średniej ruchomej 50
 Niestacjonarne procesy stochastyczne 60
 Niestacjonarność w wartości średniej procesu 183
 Niesynchroniczne transakcje 98
 Normalność rozkładu 41, 107, 108
 testowanie 38
Oczekiwania
 cena instrumentu finansowego 30
 przyszła stopa zwrotu 30
 Odchylenie standardowe 23
 Odpowiedź na impuls 215
 Odwracalność modelu 50
 Odwrotna transformata Fouriera 158
Okno
 Bartletta 163
 Parzena 163, 164
 spektralne 162, 163
Pakiet komputerowy Eviews 4.0 92
 Pamięć procesu stochastycznego 51, 76
 Parametr β , interpretacja finansowa 193
 Periodogram 160, 161, 162
 procesów 161
 szeregu 160
 Pierwiastek jednostkowy 67, 73, 148, 217
 Podstawowy proces zmienności stochastycznej 95

Portfel
 aktywów 24
 rynkowy 103, 104
 Postać przestrzeni stanów 140
Pozycja
 długa 28
 krótka 28
 Predykcja 146
 Premia za ryzyko 88, 103, 104
 Procedura dwustopniowa Engle'a i Granger 188
Proces
 ARCH 82, 87, 103
 ARFIMA 77
 ARIMA 77
 identyfikacja 68
 sezonowy 66
 ARMA 73
 błędzenia przypadkowego 64
 z dryfem 64
 GARCH 86, 87, 88
 IGARCH 88
 kauzalny 50
 Markowa 121
 niekointegrowany 186
 nieliniowy 120
 niestacjonarny 48
 o krótkiej pamięci 128, 129
 odwracalny 50
 stabilny 129
 stacjonarny 49
 w szerszym sensie 157
 z długą pamięcią 77
 stochastyczny 47, 48, 95, 145
 niestacjonarny 60
 składnikowa reprezentacja 60
 stacjonarny 48
 SV 97
 zintegrowany 64
 zmienności stochastycznej 95
Procesy
 dwuliniowe, rodzaje 122
 finansowe 16, 79
 niestacjonarne w wartości średniej 183
 skointegrowane 185
 stacjonarne w szerszym sensie 81

- zawierające stochastyczne pierwiastki jednostkowe 148
- Prognozowanie na podstawie modeli
 - ARMA 56
 - GARCH 94
 - progowych 135
- Przyczyna 209
- Przyczynowość w sensie Grangera 209
- Racjonalne oczekiwania 32, 33
 - hipoteza 32
 - wady 33, 34
 - własności 33
- Racjonalny bąbel spekulacyjny 197, 198
- Regresja pozorną 186
- Rekursywność filtru Kalmana 146
- Reprezentacja
 - ARMA 139
 - modelu minimalna 50
 - przestrzeni stanów 139, 140
 - PS modelu ARMA 142
 - spektralna 140, 158
 - wielowymiarowych szeregów czasowych 223
 - szczegółowa 172
 - VAR 205
 - w dziedzinie czasu 156
 - częstości 156
 - zgrubna 172
- Reprezentacje równoważne 139
- Rozkład
 - Cauchiego 27
 - chi-kwadrat 36, 39
 - GED 92
 - λ -Kolmogorowa 38
 - logarytmiczno-normalny 27
 - normalny 26, 28, 82, 107
 - standaryzowany 37
 - stóp zwrotu 43
 - t -Studenta 27, 92, 97, 109
- Rozkłady
 - normalne skalowane mieszane 27
 - stabilne 27
 - stóp zwrotu, asymetria 136
 - wartości ekstremalnych 28
- Rozszerzony test Dickeya-Fullera 71, 187
- Rozwiązanie fundamentalne 197
- Równania Yule'a-Walkera 52, 55
- Równanie
 - dla wariancji warunkowej procesu 80
 - dla współczynnika korelacji 231
 - długookresowe 188, 189
 - kointegrujące 187, 189
 - krótkookresowe 188, 189
 - obserwacji 140, 142
 - stanu 140, 142
 - wyjścia 140
- Równoważna reprezentacja modelu GARCH 86
- Równoważność reprezentacji w dziedzinie częstości oraz czasu 158
- Rynek efektywny 34
- Ryzyko
 - papieru wartościowego 23
 - portfela 24
 - w rozumieniu neutralnym 23
- Semiodychlenie standardowe 24
- Semiwariancja 24
- Sezonowe pierwiastki jednostkowe 75
- Sezonowość stochastyczna 75
- Sezonowy proces ARIMA 66
- Silna
 - efektywność rynku 32
 - egzogeniczność 214
- Skalogram 173
- Skalowane mieszane rozkłady normalne 27
- Składnik
 - niestochastyczny 60
 - sezonowy 60
 - stochastyczny 60
 - trendu 60
- Składnikowa reprezentacja procesu stochastycznego 60
- Składowa harmoniczna 157
- Skupianie danych 82
- Skupianie się zmienności 97
- Słaba
 - efektywność rynku 31
 - weryfikacja hipotezy 34
 - egzogeniczność 214

- Spektrum 149, 158, 159
- Sprzężenie zwrotne 209
- Stabilność
 - modeli nieliniowych 128
 - modelu przestrzeni stanów 140
- Stacjonarne procesy ARMA 77
- Stacjonarność
 - modeli nieliniowych 128
 - modelu 50, 76, 156
 - GARCH 86
- Stacjonarny model
 - autoregresyjny 143
 - klasy ARMA 82
- Standaryzowany rozkład normalny 37
- Statystyka
 - Bery-Jarque'a 39
 - Boxa-Ljunga 35, 84
 - Dickeya, Haszy i Fullera 75
 - λ -Kolmogorowa 38
 - Robinsona 171
 - t -Studenta 75
- Stochastyczna sezonowość 60
- Stochastyczne pierwiastki sezonowe 65
- Stochastyczny pierwiastek jednostkowy 152
- Stopa
 - procentowa 79, 80
 - zwrotu 80
 - logarytmiczna 22
 - nadwyżka 23
 - portfela 24
 - z akcji 79, 89
 - z inwestycji 21, 35
 - zwykła 22
- zysku 22
- Stopy zwrotu
 - autokorelacja 39, 41
 - modele rozkładów 26
 - rozkład 43, 136
 - testowanie
 - autokorelacji 35, 39
 - losowości 36, 39
- Strukturalny model VAR 207
- Szereg
 - czasowy 47, 48
 - wartość początkowa 63
 - w dziedzinie częstości 157
- w postaci przestrzeni stanów 140
- niekointegrowany 185
- skointegrowany 185
- zintegrowany 35
- Średnia efektywność rynku 32
- Test
 - ADF 187
 - BDS 130
 - Bery i Kima 235
 - Bery-Jarque'a 38
 - Boxa-Ljunga 39
 - Caporale'a, Pittisa i Spagnolo 237
 - Cheunga i Ng 236
 - czasu między kolejnymi przekroczeniami 109
 - Dickeya, Haszy i Fullera 75
 - Dickeya-Fullera 69, 70, 71, 74, 187
 - rozszerzony 71
 - do pierwszego przekroczenia 109
 - Engle'a 83
 - Grangera 212
 - J (jot) 202, 203
 - Johansena oparty na maksymalnej wartości własnej 218
 - Lee 147
 - liczby przekroczeń 109
 - Lillieforsa 38, 42
 - LMT 150
 - McLeod i Li 84
 - na równość dwóch średnich 43
 - normalności 41
 - Perrona 72, 74
 - Phillipsa-Perrona 168, 187
 - Pierce'a-Haughta 211
 - Quinille'a 53
 - RESET 129
 - serii 40
 - Walda-Wolfowitza 36
 - Shapiro-Wilka 38, 42
 - Tse 235
 - t -Studenta 74
 - znaków 37
- Testowanie
 - autokorelacji stóp zwrotu 35, 39

- kointegracji
 - szeregów czasowych 187
 - w modelach VAR 218
- liniowości wobec alternatywy
 - SETAR 132
 - STR 131
- losowości stóp zwrotu 36, 39
- nieliniowości 129
- normalności rozkładu 38, 42
- obecności efektu ARCH 83
- pierwiastków jednostkowych 72, 168
- przyczynowości 210
 - w zakresie wariancji 236
- rzędu integracji szeregów 168, 170
- sezonowych pierwiastków jednostkowych 75
- słabej egzogeniczności 214
- stabilności
 - ocen parametrów 147
 - parametrów modelu RCAR 147
- stałości korelacji 234
- stochastycznych pierwiastków jednostkowych 149, 150
- wsteczne modelu 109
- Testy
 - pierwiastka jednostkowego 68
 - statystyczne 34
- Threshold ARCH 91
- Transformacja falkowa 174
- Transformacje Fouriera 156
- Transformata Fouriera 158, 159, 224
 - dyskretna 157
 - odwrotna 158
- Trend stochastyczny 60, 65
- Uogólniona metoda najmniejszych kwadratów 219
- Uogólniony
 - model ARCH 84
 - trend stochastyczny 145
- Var 104, 105, 107
- Wariancja 23, 48, 51
 - brzegowa 80
 - warunkowa 80, 82, 95
- zmiennosc 97
- zmienna w czasie 82
- Wartość
 - oczekiwana 48
 - brzegowa 80
 - warunkowa 117
- początkowa szeregu czasowego 63
- średnia, zmiana 183
- zagrożona 104, 105, 106
- Warunek stacjonarności 139
- Warunkowa
 - wariancja, dodatniość 85
 - wartość oczekiwana 47, 117
- Wektor
 - kointegrujący 185, 187
 - obserwacji 141
 - stanów 141
- Wektorowy model
 - ARMA 205
 - korekty błędem 216
- Weryfikacja
 - bąbli spekulacyjnych 200
 - hipotezy słabej efektywności rynku 34
 - istotności poszczególnych częstotliwości w periodogramie 165
 - racjonalnych bąbli 199
- Wielorównaniowy model GARCH 227, 228, 229
 - z rozkładem t -Studenta 232
- Wielowymiarowe procesy stochastyczne 205
- Wspólne pierwiastki 50
- Współczynnik
 - autokorelacji, estymator 51
 - kąta fazowego 224
 - koherencji 224
- Współczynniki autokorelacji cząstkowej 52
- Wygladzanie 146
- Wykładniczy model
 - EACD 100
 - GARCH 90
- Wzajemna funkcja spektralna 224
- Względna VaR 107, 108

- Zależności
 - długookresowych procesów dostosowawczych 79
 - krótkookresowych procesów dostosowawczych 79
 - przyczynowo-skutkowe 79
- Zasada
 - od ogółu do szczegółu 180
 - predykcji nieobciążonej 56
- Zjawisko skupiania się odstępów czasu między transakcjami 100
- Zmiana wartości średniej 183
- Zmienna
 - ukryta w modelu 96
 - wariancja 227
 - warunkowa 80
- Zmienność warunkowej wariancji 97
- Zmodyfikowana metoda najmniejszych kwadratów 220
- Zwykła stopa zwrotu 22

Praca zbiorowa pod redakcją Tadeusza Trzaskalika

Metody wielokryterialne na polskim rynku finansowym




Metody wielokryterialne są w Polsce stosunkowo mało znane, niewiele jest również prac opisujących zastosowanie tych metod do badania rynków finansowych. Celem publikacji jest zaprezentowanie wybranych metod podejmowania decyzji (m.in. wielokryterialnej analizy decyzyjnej) oraz możliwości ich wykorzystania do rozwiązywania problemów z zakresu analizy rynku kapitałowego, ubezpieczeń majątkowych oraz zarządzania ryzykiem finansowym w banku komercyjnym. Do najbardziej przydatnych metod można zaliczyć: wielokryterialne programowanie liniowe, metody filtracji, programowanie celowe (interaktywne i hierarchiczne), metody Electre i Bipolar, procedurę dwureferencyjną, analizę wieloatrybutową, teorię zbiorów przybliżonych oraz metodę AHP. Książka jest przeznaczona dla studentów uczelni ekonomicznych, a także analityków finansowych i menedżerów odpowiedzialnych za zarządzanie ryzykiem finansowym w banku lub ryzykiem na rynku ubezpieczeń majątkowych.

Janina Józwiak, Jarosław Podgórski

Statystyka od podstaw

Wydanie VI zmienione



Książka jest nowoczesnym podręcznikiem przeznaczonym dla studentów uczelni i wydziałów ekonomicznych. Wykład podzielono na cztery części. W pierwszej przedstawiono metody statystycznego opisu rozkładu cechy oraz podstawowe zagadnienia dotyczące rozkładów zmiennej losowej i twierdzeń granicznych. Drugą część poświęcono metodom wnioskowania statystycznego, tzn. estymacji parametrów oraz weryfikacji hipotez statystycznych. Omówiono w niej także wybrane testy nieparametryczne. W części trzeciej przedstawiono metody analizy wariancji, korelacji i regresji, z uwzględnieniem klasycznego modelu regresji liniowej. Podstawowe wiadomości z zakresu analizy szeregów czasowych oraz teorii indeksów statystycznych zawarto w czwartej, ostatniej części książki. Uzupełnienie wykładu stanowią przykłady rozwiązań uzyskanych za pomocą najbardziej popularnych komputerowych pakietów statystycznych: Statgraphics, SPSS, SAS, STATISTICA™PL.