

SIECI NEURONOWE



Dotychczas ukazały się:

Esmé Faerber • *Wszystko o obligacjach*
Steve Nison • *Świece i inne japońskie techniki analizowania wykresów*
Christopher Carolan • *Kalendarz spiralny*
Jake Bernstein • *Cykle giełdowe*
Alan Lavine • *Wszystko o funduszach powierniczych*
Robert Fischer • *Liczby Fibonacciego na giełdzie*
Richard W. Arms • *Znaczenie wolumenu*
Robert W. Kolb • *Wszystko o instrumentach pochodnych*
Michael D. Sheimo • *Reguły gry na giełdzie*
Joe Krutsinger • *Systemy transakcyjne – sekrety mistrzów*
Ed Gately • *Cena i czas. Zarys metod analizy technicznej*
Mark Etzkorn • *Oscylatory*

ED GATELY

SIECI NEURONOWE

PROGNOZOWANIE FINANSOWE I PROJEKTOWANIE SYSTEMÓW TRANSAKCYJNYCH

Przełożył
ADAM OLEJNICZAK



WARSZAWA 1999



Tytuł oryginału:
Neural Networks for Financial Forecasting

Copyright © 1996 by Edward J. Gately
All Rights Reserved.
Authorised translation from English language edition
published by John Wiley & Sons, Inc.

Copyright © for the Polish edition by WIG-Press
Copyright © for the Polish translation by Adam Olejniczak

Opracowanie redakcyjne:
Wojciech Madej

Redakcja techniczna:
Paweł Dąbrowski

Korekta:
Lucyna Zbucka

WIG-Press Warszawa 1999
tel.: (022) 844-2573
(022) 646-0986
faks: (022) 646-0988
e-mail: poczta@wig-press.com.pl

Skład: Alpha +
Druk i oprawa: Drukarnia Wydawnictw Naukowych w Łodzi SA

ISBN 83-87014-45-1

Spis treści

Przedmowa do wydania polskiego IX

Przedmowa XVII

Podziękowania XIX

Rozdział pierwszy:

Mózg biologiczny a sztuczne sieci neuronowe (SSN) 1

Makrostruktura mózgu 1
Krótką historią mechaniczno-elektronicznych
analogowych i cyfrowych urządzeń do przetwarzania danych 2
Rozwój sztucznych sieci neuronowych 2
Zastosowanie sieci neuronowych 4
Mikrostruktura mózgu 5
Do jakich problemów można stosować sieci neuronowe 7

Rozdział drugi:

Wprowadzenie do problematyki sztucznych sieci neuronowych 9

Sieci neuronowe a ludzki mózg 9
Wybór prognozowanej zmiennej 12
Dobór danych wejściowych 13
Wstępne przetworzenie danych 13

Architektura sieci 14
Algorytm uczenia 16
Uczenie i testowanie 16
Rzeczywistość 17

Rozdział trzeci:

Wybór prognozowanego zjawiska i odpowiednich zmiennych 21

Prognozowanie szeregów czasowych – wartość absolutna 22
Sieć odniesienia 23
Względny wkład 25
Prognozowanie kierunku szeregu czasowego 25
Procentowa zmiana kierunku szeregu czasowego 26
Horyzont czasowy 29
Inne zastosowania sieci neuronowych 31

Rozdział czwarty:

Wybór zmiennych wejściowych 33

Wybór odpowiednich zmiennych wejściowych 33
Korelacja i wkład 34
Poręczenia pożyczek hipotecznych 36
Bankructwa banków 39
Bankructwa przedsiębiorstw 40
Klasyfikacja obligacji 40
Wycena nieruchomości/analiza podatku majątkowego 41
Prognozowanie szeregów czasowych 43

Rozdział piąty:

Przygotowanie danych 51

Arkusze kalkulacyjne 51
Tworzenie arkusza kalkulacyjnego 52
Wstępne przetworzenie danych 54
Zdania warunkowe 61

Rozdział szósty:

Inne sposoby manipulowania danymi 65

Sezonowość 65
Wartości minimalne i maksymalne 66
Wyodrębnienie testowego zbioru danych 72
Jaka liczba danych jest wystarczająca? 72
Wpływ nietypowych wydarzeń 73

Rozdział siódmy:

Proces uczenia i taksonomia sieci 75

Proces uczenia 75
Algorytmy uczenia 76
Architektury sieci 77
Funkcje aktywacji 82

Sieci typu Ward 84
Samoorganizujące się sieci Kohonena 88
Probabilistyczne sieci neuronowe – PNN 89
Sieci GRNN z dołączonym algorytmem genetycznym 92

Rozdział ósmy:

Rozpoczynanie i zatrzymywanie uczenia 93

Rozpoczynanie treningu 93
Zatrzymywanie treningu 94
Odpowiedni poziom dokładności 97
Użytkowanie sieci 98

Rozdział dziewiąty:

Budowa sieci prognozującej S&P z 10-dniowym wyprzedzeniem 101

Zmienne początkowe 102
Gromadzenie danych 102
Przetwarzanie danych 103
Ustalanie wkładów zmiennych wejściowych 107
Dobór odpowiedniej średniej kroczącej obrotów 109
Wybór zmiennych opóźnionych i ustalanie liczby dni wstecz 112
Wyznaczanie średniej kroczącej o największym wkładzie 118
Wskaźniki techniczne 122
Wybór ostatecznego zestawu zmiennych wejściowych 125
Sieć docelowa 131
Algorytm genetyczny – sieć GRNN 132
Inwestowanie na podstawie sieci neuronowych 135

Dodatek:

Studium przypadku 137

Słownik 141

Bibliografia 145

Bibliografia polska 154

Przedmowa do wydania polskiego

Bezpowrotnie minęły już czasy, kiedy do zarabiania na giełdzie wystarczała znajomość adresu biura maklerskiego i sposobu wypełnienia zlecenia kupna. Pojawiła się normalność, a wraz z nią sytuacja, gdy efektywność inwestowania, pomijając przysłowiowe szczęście, zależy od samego inwestora, a ściślej mówiąc od jakości jego pracy.

Analiza techniczna, fundamentalna czy portfelowa muszą być żelazną podstawą, bez której nie można liczyć na zyski. Aby zapewnić sobie choćby nieznaczną przewagę nad innymi uczestnikami rynku, warto poznawać i stosować różne techniki analityczne. Racjonalny inwestor powinien choć pobieżnie poznać także rzadziej stosowane metody, takie jak teoria Ganna, kalendarz spiralny Carolana czy teoria chaosu. Osiągnięcie satysfakcjonujących zysków uzależnione jest jednak nie tylko od znajomości wymienionych metod, ale przede wszystkim od właściwego ich stosowania. I tu pojawia się miejsce na zastosowanie sztucznych sieci neuronowych. Dzięki nim inwestor jest w stanie wyciągać właściwe wnioski bez ulegania niepotrzebnym emocjom, które mogą zniekształcić wynik analiz. Książka Eda Gately'ego (autora znanego już czytelnikom tej serii¹) *Sieci neuronowe* powinna umożliwić zwiększenie trafności prognoz

¹ Ed Gately, *Cena i czas. Zarys metod analizy technicznej*, WIG-Press, Warszawa 1999.

dzięki odcięciu się od subiektywnych, a więc często błędnych, odczuć i przewidywań.

Aby w pełni zrozumieć przydatność sieci neuronowych w analizie rynku, należy sięgnąć pamięcią do tych wszystkich zdarzeń, które zaowocowały podjęciem błędnej decyzji. Spróbujcie przypomnieć sobie, ile razy trzymaliście akcje, których cena spadała, w niezachwianym przekonaniu, że dziś jest już ostatni dzień spadku. Ile razy sprzedaliście akcje po silnym wzroście, a one, zamiast natychmiast spaść, pięły się jeszcze wyżej i wyżej. Błędne decyzje można czasami wytłumaczyć zastosowaniem niewłaściwej metody bądź użyciem niewłaściwych parametrów. Najczęściej jednak błędy wynikają z braku obiektywizmu. Czy nigdy nie zdarzyło się Wam, że z perspektywy czasu sygnał zakupu lub sprzedaży był oczywisty, jednak we właściwym momencie nie widzieliście go? Może przyczyną była wizja niebotycznych zysków, a może wręcz przeciwnie – zniechęcenie po drastycznej deprecjacji posiadanych walorów? Cokolwiek się stało, kierowaliście się emocjami w chwili, w której nie było na nie miejsca. Zamiast obiektywnie i racjonalnie ocenić sytuację, uwzględniliście nieświadomie zdarzenie nie mające żadnego wpływu na sytuację na rynku. Takie podświadome działanie jest często przyczyną błędnej decyzji.

Czy jesteśmy w stanie zapobiec opisywanym przypadkom? Czy jesteśmy w stanie wyeliminować subiektywne i emocjonalne decyzje? W stu procentach raczej nie. Niektórzy inwestorzy silniej, inni słabiej, wszyscy jednak podlegają wpływom czynników powodujących zwiększenie ryzyka podjęcia błędnej decyzji. I tu pojawia się miejsce na zastosowanie sztucznej sieci neuronowej. Ponieważ nie ulega ona emocjom, jej wskazania są w pełni obiektywne. Ponadto istnieje szansa na to, że sieć neuronowa zauważy zależność, która umknęła naszej uwadze tylko dlatego, że jeden z neuronów naszego mózgu był zaspany, drugi podtruty jakimś lekarstwem, a następny zajęty czymś zupełnie innym. Może się też okazać, że związek przyczynowo-skutkowy, dla nas niemal oczywisty, w rzeczywistości nie występuje bądź jest na tyle nikły, że nie wart uwzględnienia.

Sztuczna sieć neuronowa jest pewnego rodzaju modelem ludzkiego mózgu przystosowanym do rozwiązywania ograniczonego zestawu problemów. Dzięki temu model sieci neuronowych może być znacznie prostszy od struktury mózgu człowieka. Ten ostatni musi rozwiązywać codziennie (często równolegle) setki różnych zadań, od prostych do bardzo skomplikowanych. Natomiast sztuczny mózg jest skoncentrowany tylko na jednym problemie – kupnie lub sprzedaży akcji. Wszystkie pozostałe zagadnienia są mu całkowicie obce.

Jak zbudowana jest taka sieć i jakie są wewnętrzne uwarunkowania jej działania? Tu dochodzimy do sedna zagadnień omawianych w książce Gatel'ego. Otóż nie znajdziecie w niej dywagacji na temat wpływu gładkości drugiej pochodnej funkcji aktywacji na szybkość uczenia sieci. Ominie was również bardzo ciekawa dyskusja na temat aproksymacji Hesjanu na podstawie informacji zawartej w gradiencie z uwzględnieniem czynnika regularyzującego. Nie dowiecie się również z tej książki, dlaczego kierunek zmian minimalizacyjnych powinien być ortogonalny i sprzężony ze wszystkimi poprzednimi kierunkami. Wszystkie te i inne

niezwykle ciekawe informacje można znaleźć w kilku innych wydanych dotychczas w Polsce pozycjach o sieciach neuronowych². Niestety, książki te są tak gęsto naładowane wzorami, że ciekawa dla inwestora giełdowego informacja, umieszczona między dwoma równaniami macierzowymi, może umknąć nawet przy uważnej lekturze.

Czytelnicy tej książki znajdą się w dużo bardziej komfortowej sytuacji. Autor zakłada, że inwestor rozważa możliwość użycia jednego z dostępnych na rynku symulatorów sieci neuronowych i nie interesuje go wewnętrzna budowa sieci, a jedynie jej praktyczne zastosowanie w inwestycjach giełdowych. Inwestor nie podaje wszak w wątpliwość faktu, że sieci neuronowe potrafią się czegoś nauczyć, korzystając z różnych architektur bądź różnych algorytmów uczenia. Interesuje go natomiast, jak zmusić tę czarną skrzynkę do tego, by była dla niego przydatna w giełdowej spekulacji. Omawiając przykłady i sposoby korzystania ze sztucznej sieci neuronowej, Gatel pokazuje rozwiązania, które osiągnął z użyciem symulatora NeuroShell firmy Ward. Przykłady będą jednak miały taką samą wagę również dla polskich użytkowników programów BrainMaker czy Statistica Neural Networks. Co więcej, będą też bardzo pouczające nawet dla osób, które nie zamierzają stosować symulatora sieci neuronowej. Pamięamy wszak przecież, że prawdziwą sieć, której ustępują wszystkie, nawet najlepsze symulatory, mamy zawsze przy sobie. Wiedząc jak ją lepiej wykorzystać, możemy osiągnąć rezultaty lepsze od dotychczasowych. Pomogą w tym sugestie autora, na które czynnik zwracać największą uwagę, a jakie ignorować. Czytelnik znajdzie tu przykłady bazujące na analizie technicznej. Nie ma jednak żadnych merytorycznych przeszkód, aby przedstawione tu przykłady przenieść na analizę fundamentalną czy portfelową.

Czytelnicy, którzy pierwszy raz stykają się z pojęciem sztucznych sieci neuronowych, nie zostają tu rzućni od razu na głęboką wodę. Pierwsze rozdziały zawierają wprowadzenie całkowicie wystarczające dla potrzeb nawet bardzo wymagającego inwestora.

Wiele miejsca w książce zajmują rozważania na temat kodowania zmiennych. Dobrze przedstawiona zmienna prognozowana pozwala na wielokrotne zmniejszenie błędu działania, z kolei źle opisana zmienna może w polskich warunkach doprowadzić do sytuacji, w której dobrze nauczona sieć będzie prognozować zmiany cen akcji z dokładnością dopuszczalnego przedziału zmian kursów na sesji (± 10 procent). Gatel radzi, co zrobić, żeby dokładność zbliżyła się do rozsądnego poziomu. Niezwykle istotny jest jego zdaniem dobór czynników wpływających na prognozowane zjawisko. Prezentacja procedur wyboru czynników, które należy uwzględnić w budowaniu sieci, może być interesująca nawet dla osób, które nie zamierzają stosować symulatora sieci neuronowych. Na przykładzie systemu prognozującego indeks S&P500 autor książki pokazuje, jak interaktywnie modyfikować architekturę sieci i które zmienne mają największe znaczenie, a które, mimo pozornej przydatności, zakłócają obraz sytuacji.

² Po spisie literatury proponowanym przez autora tej książki (w języku angielskim) znajdziecie państwo spis pozycji specjalistycznych o sieciach neuronowych wydanych w języku polskim.

Książka jest cenną pozycją dla inwestorów korzystających z sieci neuronowych. Jednak należy pamiętać, że napisana została pod kątem giełdy nowojorskiej, a nie warszawskiej. Czytelnik powinien zdawać sobie sprawę z konsekwencji czynników różnicujących te giełdy. Jednym z najważniejszych jest zakres zmienności cen. Gatelý dostrzega potrzebę normalizacji ceny i proponuje stosowanie danych wejściowych w postaci różnicy ceny i długiej średniej. Rezultaty mogą być obiecujące w przypadku NYSE, jednak dla WGPW lepiej stosować iloraz zamiast różnicy.

Biorąc pod uwagę powyższe spostrzeżenia oraz specyfikę rynku amerykańskiego trzeba wyraźnie podkreślić, że możliwości wykorzystania zaprezentowanego w książce materiału przy obsłudze dostępnego na polskim rynku oprogramowania giełdowego nie są nieograniczone. Wiąże się to także z narzuconymi przez producenta gotowymi rozwiązaniami. Przykładem może być program ASHER NPG, bez wątpienia najpopularniejszy system neuronowy w Polsce. Stanowi on interesujące połączenie silnego programu do analizy technicznej z aparatem prognostycznym bazującym na modelu sieci neuronowej. Aparat ten jest dość specyficzny. Program został wyposażony w jedną sieć trenowaną na podstawie notowań wybranych przez użytkownika akcji. Można także wskazać okres, na podstawie którego program wykona trening. Sieć jest dość duża, składa się bowiem z 357 komórek, z których każda ma około 400 powiązań. Trenowanie tak dużej sieci wymaga wykorzystania obszernego zbioru danych uczących, a więc notowań wielu spółek.

Inne podejście do zastosowań sieci neuronowych w analizie rynku kapitałowego reprezentuje program NeuroMAKLER dla Windows opracowany przez warszawską firmę ZETO RODAN. Stanowi on zintegrowane środowisko do tworzenia, testowania i uczenia sieci neuronowych na podstawie danych giełdowych. Pozwala to wykorzystać przy budowie sieci własne, a więc często unikalne doświadczenia, które mogą przyczynić się do zwiększenia skuteczności prognoz. Co ciekawe, każdą sieć neuronową można potraktować jako nowy wskaźnik analizy technicznej. Chociaż możliwość konstruowania sieci neuronowych jest najważniejszą cechą tego programu, jest on dodatkowo wyposażony także w pełen zestaw klasycznych narzędzi analizy technicznej. W porównaniu z zagranicznymi programami do budowy sieci neuronowych NeuroMAKLER dysponuje skromniejszymi możliwościami w zakresie wstępnego przygotowania danych.

Emocje i subiektywizm to dwie kategorie psychologiczne nieodłącznie związane z inwestowaniem na rynku kapitałowym. Każdy gracz giełdowy chciałby je wyeliminować, aby lepiej oceniać zachowanie akcji i zwiększać zyski z inwestycji. Po przeczytaniu książki Gatelý'ego jesteśmy znacznie bliżej tej sytuacji. Czy oznacza to, że automatyczne będziemy podejmowali zawsze trafne decyzje? Niestety nie. Liczba trafnych decyzji znacząco wzrosła, nie można jednak gwarantować, że nie przytrafią się nam porażki. Sieci neuronowe potrafią wyłapywać generalne zależności między najważniejszymi zjawiskami z przeszłości i przyszłości. Istnieje jednak wiele zdarzeń, których jednostkowy wpływ jest na tyle niewielki, że sieci nie są w stanie go uwzględnić. Pozytywne bądź negatywne skumulowanie takich czynników może zachwiać nawet najsilniejszą

zależnością. Należy też pamiętać o wydarzeniach wyjątkowych lub przypadkowych, których nie da się przewidzieć, posiadając nawet najszybszy komputer i najlepszą sieć neuronową. Mimo to warto zainteresować się sztucznymi sieciami neuronowymi, które postawią nas w gronie skuteczniejszych i efektywniejszych inwestorów. I chociaż dzięki tej książce nie nauczymy się eliminować całkowicie wpływu emocji, będzie to jednak duży krok we właściwym kierunku.

Karol Jarzyński

*Susan Lynn Gately i Louise Marie Gately,
miłościom mojego życia, oraz Robynowi Gately
– część jego pamięci.*

Przedmowa

Szybki rozwój architektur sieci neuronowych i algorytmów uczenia połączony z gwałtownym wzrostem mocy obliczeniowej komputerów osobistych doprowadził do powstania wielu nowych potężnych sieci neuronowych do prognozowania finansowego.

Wiele sprzedawanych obecnie pakietów oprogramowania modelującego sieci neuronowe trafia w końcu na półkę, ponieważ nie przynosi efektów obiecanych przez producentów. Książka ta ma pomóc w uzyskaniu pożądaných rezultatów osobom od niedawna zajmującym się sieciami neuronowymi.

Z dyskusji prowadzonych przeze mnie na seminariach wynika, że początkujący użytkownicy często popełniają klasyczne błędy – nie przywiązują należytej wagi do integralności danych lub posługują się danymi nietypowymi, na przykład danymi na temat zachowania rynku w czasie wojny w Zatoce Perskiej. Owych powszechnych błędów nie omawia żaden ze znanych mi tekstów poświęconych problematyce sieci neuronowych.

Większość książek na ten temat to albo pozycje akademickie, albo teksty wprowadzające. W tekstach dla początkujących nie poświęca się uwagi klasycznym błędom ani potrzebie testowania zmiennych wejściowych,

architektur i algorytmów uczenia; pozycje akademickie poruszają wprawdzie takie kwestie, ale zawierają zwykle dużo trudnej do przyswojenia matematyki. Moja książka ma za zadanie wypełnić lukę między tymi dwoma podejściami.

Ed Gately
Mahwah, New Jersey

Podziękowania

Chciałbym podziękować następującym osobom, które bezpośrednio i pośrednio przyczyniły się do powstania tej książki.

Johnowi P. Glassowi i Davidowi Haflerowi, którzy byli moimi mentorami przez większą część mego dorosłego życia.

Steve'owi Wardowi z firmy Ward Systems, który na liczne sposoby inspirował mnie do działania i pokazał, jak wiele można osiągnąć dzięki sieciom neuronowym.

Timowi Slaterowi z firmy Computrac, który służył mi zachętą w początkach mego zainteresowania sieciami neuronowymi.

Perry'emu Kaufmanowi, którego znajomość angielszczyzny w wielkim stopniu wpłynęła na przystępność tej książki i któremu winien jestem wyrazy wdzięczności za okazane mi wsparcie.

Jaqueline Urinyi, mojemu wydawcy z John Wiley and Sons.

Randallowi B. Caldwellowi z magazynu *NeuroVe\$st Journal*.

Anicie Greiter – za fachową edycję tekstu.

Rozdział pierwszy

Mózg biologiczny a sztuczne sieci neuronowe (SSN)

W rozdziale tym przedstawimy makro- i mikrostrukturę mózgu. Po krótkim omówieniu historii analogowego i cyfrowego przetwarzania danych przejdziemy do historii sztucznych sieci neuronowych. Zaprezentujemy ich strukturę, a następnie porównamy z sieciami neuronowymi pochodzenia biologicznego. Zastanowimy się, jakiego rodzaju problemy można rozwiązać za pomocą sztucznych sieci neuronowych, a jakie nie.

MAKROSTRUKTURA MÓZGU

Wszystkie żywe istoty posiadają mózgi złożone z komórek zwanych *neuronami*. Ich unikalną własnością, która wyróżnia je na tle innych komórek organizmu, jest to, że nie umierają. Być może właśnie dlatego możemy pamiętać rzeczy, które zdarzyły się przed kilkudziesięcioma laty. Szacuje się, że mózg ludzki może się składać nawet ze 100 miliardów neuronów. Nawet niepozorny ślimak ma ich 20 000.

Mózg ludzki podzielony jest pionowo na dwie części o mniej więcej takiej samej wielkości. Każda półkula pełni odmienne, lecz uzupełniające się funkcje w życiu człowieka (diagram 1.1). Badania wykazują, że lewa półkula specjalizuje się w operacjach logicznych i matematycznych, podczas gdy domeną prawej są emocje, rozpoznawanie wzorów i poznanie intuicyjne. Mimo iż wszyscy korzystamy z obu części naszych mózgów, u większości z nas jedna z nich odgrywa dominującą rolę. Naukowców i matematyków uważa się, na przykład, za ludzi o dominującej lewej, zaś artystów i pisarzy – prawej stronie mózgu. Książka *Drawing On the Right Side of the Brain* skierowana jest do artystów i ma pomagać w rozwijaniu wrażliwości, reakcji i myślenia abstrakcyjnego. W świecie finansów, w analizie fundamentalnej i technicznej korzystamy z lewej półkuli, ponieważ wykonujemy operacje matematyczne. Sieci neuronowe działają natomiast tak, jakby były zorientowane na prawą stronę mózgu, albowiem generowane przez nie prognozy bazują na ukrytych zależnościach i rozpoznawaniu wzorów.

KRÓTKA HISTORIA MECHANICZNO-ELEKTRONICZNYCH ANALOGOWYCH I CYFROWYCH URZĄDZEŃ DO PRZETWARZANIA DANYCH

Aby zmniejszyć wysiłek potrzebny do rozwiązywania intelektualnych problemów, wiele trudu włożono w rozwój mechanicznych i elektronicznych urządzeń naśladujących pracę ludzkiego mózgu. Prymitywne mechaniczne urządzenia liczące pojawiły się już pod koniec osiemnastego stulecia. W latach trzydziestych naukowcy z Bell Laboratories konstruowali elektroniczne komputery analogowe, które wykonywały nie tylko cztery podstawowe działania matematyczne, ale także zaawansowane obliczenia, takie jak różniczkowanie i całkowanie. Jednym z owoców tej pracy badawczej były systemy naprowadzania inercyjnego, które sterowały samolotami i pociskami raketowymi lecącymi przez oceany z dokładnością mierzoną ułamkami kilometra.

ROZWÓJ SZTUCZNYCH SIECI NEURONOWYCH

Do końca lat czterdziestych stworzono skomplikowane urządzenia mechaniczne, za pomocą których można było dodawać, odejmować, mnożyć i dzielić. Szczytem wyrafinowania, obiektem zazdrości ze strony każdego księgowego i inżyniera lat pięćdziesiątych, był biurkowy kalkulator




Diagram 1.1 Mózg ludzki widziany z góry. Podział na lewą i prawą półkulę.

Friedena, który nie tylko umożliwiał wykonywanie czterech podstawowych działań, ale obliczał pierwiastki kwadratowe za naciśnięciem jednego klawisza.

W tym samym okresie naukowcy z University of Pennsylvania skonstruowali pierwszy cyfrowy komputer. Owo bardzo prymitywne urządzenie nazwano ENIAC. ENIAC stał się protoplastą potężnych komputerów typu *mainframe*. Cały rozwój tej gałęzi systemów miał na celu odwzorowanie funkcji lewej półkuli mózgu.

W 1943 roku Warren McCullock i Walter Pitts opublikowali pracę zatytułowaną „A Logical Calculus of Ideas Immanent in Nervous Activity” (*Bulletin of Mathematical Biophysics*, vol. 5, s. 115–133). Praca ta stała się teoretycznym fundamentem późniejszego rozwoju sztucznych sieci neuronowych. W roku 1951 student MIT Marvin Minsky zbudował neuronowy komputer i zaprogramował go tak, by uczył się rozkładu labiryntu. Były to narodziny badań nad sztuczną inteligencją, a Minsky’ego, który nadal pracuje na MIT, często określa się mianem ojca systemów ekspertowych.

Pod koniec lat siedemdziesiątych komputery dysponowały już wystarczającą mocą obliczeniową, by można było rozpocząć praktyczne badania nad sztucznymi sieciami neuronowymi (SSN). Jednak dopiero datujący się od 1986 roku rozwój sieci opartych na algorytmie wstecznej propagacji błędu (*back-propagation networks*) sprawił, że sieci neuronowe zaczęto stosować do rozwiązywania codziennych problemów ekonomicznych, naukowych i przemysłowych.

Sztuczna sieć neuronowa to program komputerowy, który naśladuje zdolność ludzkiego mózgu do klasyfikacji wzorów i sporządzania prognoz

lub podejmowania decyzji na bazie przeszłych doświadczeń. Tak jak mózg ludzki opiera swe działanie na informacjach rejestrowanych przez pięć zmysłów, tak sztuczne sieci neuronowe korzystają ze zbiorów danych.

Ponieważ sieci neuronowe są dostępne, praktycznie rzecz biorąc, dopiero od lat siedemdziesiątych i ponieważ ich rozwój związany jest między innymi z mocą obliczeniową komputerów, nadal znajdują się one we wczesnej fazie rozwoju. Prędkość rozwiązywania problemu oraz sama możliwość zastosowania sieci neuronowych zależą od rozmiarów sieci będących pochodną złożoności problemu i liczby zaprezentowanych przypadków, jak również mocy obliczeniowej komputera. Zastosowanie szybszych komputerów oznacza możliwość rozwiązywania bardziej złożonych problemów w tym samym czasie lub tych samych w czasie krótszym. Różnica mocy obliczeniowej między komputerem generacji 286 (taktowanym zegarem 8 lub 12MHz) a maszyną wyposażoną w procesor 486DX33 kształtuje się jak osiem do jednego. Komputer oparty na procesorze Pentium-90 jest czterokrotnie szybszy. Nowe procesory znajdujące się obecnie w fazie projektowania mają osiągać dwukrotnie lepsze wyniki. Mogą być one 32 razy szybsze od układu 286, a będą dostępne jeszcze w tym stuleciu.

ZASTOSOWANIE SIECI NEURONOWYCH

Sieci neuronowe stosuje się do rozwiązywania wielu praktycznych problemów. Korzysta się z nich w diagnozie lekarskiej, kontroli jakości, poszukiwaniu złóż ropy naftowej, rozpoznawaniu mowy, kontroli lotów, rozpoznaniu terenu, klasyfikacji monet, prognozowaniu stanu alarmowego na rzekach, projektowaniu układów sterowniczych obrabiarek, grze na wyścigach i prognozowaniu finansowym. Dziedziny finansów, w których na szeroką skalę stosuje się sieci neuronowe, to:

- Oszustwa związane z kartami kredytowymi
- Prognozowanie bankructw
- Analiza wniosków o wydanie kart kredytowych
- Analiza wniosków o udzielenie pożyczki hipotecznej
- Marketing produktu
- Klasyfikacja obligacji przedsiębiorstw
- Klasyfikacja obligacji municypalnych
- Prognozowanie zachowania rynku akcji
- Prognozowanie upadłości banków
- Selekcja akcji
- Przewidywanie kursów walutowych
- Wycena nieruchomości
- Przewidywanie zbiorów
- Obrót towarowy
- Wycena arbitrażowa




Diagram 1.2 Budowa biologicznego neuronu.

- Analiza kondycji finansowej przedsiębiorstw
- Wycena opcji
- Wybór strategii sprzedaży
- Analiza rynków kapitałowych
- Podejmowanie decyzji na szczeblu menedżerskim
- Analiza kondycji biur turystycznych
- Szacowanie ryzyka papierów wartościowych
- Prognozowanie wskaźników ekonomicznych
- Analiza podatku majątkowego
- Przewidywanie przepływów gotówkowych
- Lokalizowanie podmiotów uchylających się od płacenia podatków
- Wybór funduszu powierniczego
- Przewidywanie zmian trendu rynkowego
- Prognozowanie zapotrzebowania na pracowników
- Prognozowanie obciążenia obrabiarek

MIKROSTRUKTURA MÓZGU

Jak wspomnieliśmy wcześniej, mózgi biologiczne składają się z komórek zwanych *neuronami*. Każdy neuron (diagram 1.2) posiada ciało komórkowe, z którego wyrasta pojedynczy akson. Kiedy ciało komórkowe zostanie dostatecznie silnie pobudzone przez nadchodzące impulsy, przekazuje je wzdłuż aksonu do innych neuronów. Impulsy takie neuron odbiera za pomocą receptorów zwanych *dendrytami*. Obszar, na którym odbierane są impulsy, określa się mianem *synapsy*. To właśnie za ich pośrednictwem impulsy nerwowe przekazywane są z jednego neuronu na drugi. Struktury neuronu działają na zasadzie elektrochemicznej. Oznacza to, że działanie




Diagram 1.3 Schemat biologicznego neuronu. Widzimy jak neuron łączy różne wejścia w pojedyncze wyjście powiązane z wieloma innymi neuronami. W celu zachowania przejrzystości schematu zaznaczyliśmy tylko jedno z wielu wyjść. Litera X reprezentują wejścia, a W powiązania między wejściami.

mózgu opiera się na przepływie impulsów elektrycznych wyzwolonych na skutek reakcji chemicznych. Kiedy wskutek połączonego oddziaływania wielu nadchodzących impulsów zostanie osiągnięty odpowiedni poziom pobudzenia (czyli zgromadzony ładunek elektryczny określany mianem ładunku progowego), ciało komórkowe wyzwala swój ładunek (ulega depolaryzacji) i wysyła go wzdłuż aksonu do innych komórek nerwowych i ich dendrytów. Przekazywanie impulsów nerwowych przez szczelinę synaptyczną odbywa się za pośrednictwem chemicznych przekazników – biogenicznych aminów utworzonych z aminokwasów.

Neuron można przedstawić schematycznie jako komórkę o określonej liczbie wejść i wyjściu połączonym z innymi neuronami (diagram 1.3). Kiedy zatem neuron ulega depolaryzacji i przesyła ładunek wzdłuż aksonu, wysyła sygnał do wielu neuronów.

Sztuczne sieci neuronowe modelowane na komputerach bardzo przypominają budowę schemat ludzkiego mózgu. Porównajmy diagramy 1.3 i 1.4. W sztucznych sieciach neuronowych odpowiednik szczeliny synaptycznej stanowi waga (miara znaczenia) powiązań między sztucznymi neuronami. Nieliniowe własności neuronów wchodzących w skład mózgu modeluje się w sztucznych sieciach za pomocą nieliniowych połączeń neuronowych.

Sztuczne sieci neuronowe składają się z trzech bądź większej liczby warstw neuronów. Pierwsza warstwa, określana mianem *warstwy wejściowej*, zawiera tyle neuronów, ile jest zmiennych wejściowych (po jednym na każdą). Każdy neuron z warstwy wejściowej łączy się ze wszystkimi neuronami z obszaru ukrytego. Obszar ukryty składa się niekiedy z więcej niż jednej warstwy; każdy neuron z pierwszej warstwy ukrytej powiązany jest wówczas ze wszystkimi neuronami warstwy drugiej. Jeżeli obszar ukryty składa się z więcej niż dwóch warstw, neurony z drugiej warstwy łączą się ze wszystkimi neuronami z warstwy trzeciej. Ostatnia warstwa wchodząca w skład obszaru ukrytego połączona jest z *warstwą wyjściową*. Diagram 1.4 przedstawia prostą sieć trzywarstwową




Diagram 1.4 Prosta trzywarstwowa sztuczna sieć neuronowa prognozująca wartość indeksu S&P 500 z pięciodniowym wyprzedzeniem na bazie obecnej wartości indeksu, relacji wzrostów do spadków (wskaźnika A/D), MACD oraz RSI.

złożoną z warstw wejściowej, ukrytej i wyjściowej. Każdy neuron z warstwy wejściowej łączy się ze wszystkimi neuronami z warstwy ukrytej, te zaś w podobny sposób łączą się z neuronem wyjściowym.

Siła powiązań między różnymi neuronami zależy od zastosowań sieci. To właśnie ona sprawia, że dwie na pozór identyczne sieci różnią się od siebie. Siłę powiązań między dwoma neuronami określa się mianem *wagi*. Mocne powiązanie ma większą wagę niż słabe. Ważne zmienne wejściowe otrzymują duże wartości wag. Tak jak mózg biologiczny odcedza nieistotne informacje usuwając je, tak sieć neuronowa przypisuje im zerowe wagi.

Zapewne najważniejszą różnicą między naturalnymi sieciami neuronowymi (czyli mózgiem) a sieciami sztucznymi jest to, że mózg odbiera dane wejściowe za pośrednictwem pięciu zmysłów. W przypadku sztucznych lub komputerowych sieci neuronowych dane wejściowe są liczbami, tak więc chcąc użyć jakichkolwiek danych, musimy najpierw zamienić je na postać cyfrową. W wielu zastosowaniach sztuczne sieci neuronowe operują jedynie zerami i jedynekami, które oznaczają, że dana zmienna jest obecna lub nie, jednak, co może się wydawać zaskakujące, nie obniża to ich zdolności prognostycznych.

DO JAKICH PROBLEMÓW MOŻNA STOSOWAĆ SIECI NEURONOWE

Tak jak mózg ludzki może się nauczyć rozwiązywać wiele zadań, tak sztuczną sieć neuronową można nauczyć rozwiązywania przynajmniej pewnego rodzaju problemów. W obu przypadkach proces uczenia odbywa się bardzo podobnie; polega na wielokrotnej prezentacji uczonego materiału i wzmacnianiu poprawnej odpowiedzi.

Mózg ludzki bez trudu obliczy, ile jest $2 + 2$. Nie ma również problemów z odróżnieniem jabłka od kwiatu. Sztucznej sieci neuronowej (którą odtąd będziemy nazywać siecią neuronową lub, w skrócie, SSN) bardzo trudno obliczyć *dokładny* wynik działania $2 + 2$. Czasami będzie to 3,993, a czasami 4,008. Ponieważ SSN rozumuje raczej w sposób intuicyjny niż racjonalny, bardzo rzadko udaje jej się udzielić *dokładnej* odpowiedzi. Zadania matematyczne tego rodzaju najlepiej rozwiązywać za pomocą tradycyjnych kalkulatorów i komputerów.

Jednak sieć neuronowa bez trudu wychwyci różnicę między jabłkiem a kwiatem. Oba są okrągłe, ale jabłko ma gładką, względnie twardą powierzchnię, podczas gdy kwiat posiada płatki, a jego powierzchnia jest delikatna.

W rozdziale drugim wprowadzimy Czytelnika w problematykę sztucznych sieci neuronowych oraz opiszemy, jak się je konstruuje, uczy i wykorzystuje.

Rozdział drugi

Wprowadzenie do problematyki sztucznych sieci neuronowych

SIECI NEURONOWE A LUDZKI MÓZG

Sztuczna sieć neuronowa to program komputerowy, który naśladuje zdolność ludzkiego mózgu do klasyfikacji wzorów, sporządzania prognoz lub podejmowania decyzji na bazie przeszłych doświadczeń. Mózg ludzki odbiera i przetwarza bodźce nerwowe, natomiast działanie sieci neuronowej opiera się na matematycznych zbiorach danych (wektorach), które przybierają postać określonych porcji informacji.

Różnic między sztucznymi sieciami neuronowymi a mózgiem ludzkim jest kilka. Sieci nie nudzą się, nie potrzebują przerwy na kawę, nie trzeba im płacić czy wysyłać na urlop; po prostu wykonują swoje zadania. W porównaniu z mózgiem człowieka ich rozmiary są bardzo niewielkie – składają się z około kilkuset neuronów, podczas gdy mózg zawiera ich miliardy. Fakt ten można wytłumaczyć współczesnym poziomem technologii i prędkością komputerów. Niewielkie gabaryty oznaczają, że jeśli sieć neuronowa ma dobrze pełnić swoją funkcję, musi być

Tabela 2.1 Różnice między mózgiem ludzkim a siecią neuronową.

Czynnik	Mózg	Sieć neuronowa
Rozmiary	bardzo duże, do 100 miliardów neuronów	względnie niewielkie, rzadko przekraczające kilkaset neuronów
Dane wejściowe	pięć zmysłów	zbiory danych zredukowane do liczb (digitalizacja)
Dyscyplina pracy	dobra, jednak łatwo się nudzi i często ma trudności z koncentracją	mechaniczna, rozwiązuje tylko zadane problemy
Specjalizacja	istnieje, jednak poszerzona o wiele zainteresowań i umiejętności; łatwo się rozprasza	tylko jedno zadanie
Liczba powiązań pojedynczego neuronu	nawet powyżej 1000	ograniczona współczesnym stanem wiedzy, rzadko sięga 100
Półkule	dwie, prawa i lewa (analityczna i intuicyjna)	tylko prawa (intuicyjna)

bardzo wyspecjalizowana. Właśnie dzięki specjalizacji sieci neuronowe koncentrują się na wykonywanym zadaniu. Ograniczenie to ma jeszcze jedną zaletę – sprawia, że rozwiązanie wygenerowane przez sieć nie jest zbyt ścisłe, tak więc szybciej otrzymujemy logiczniejszą i ogólniejszą odpowiedź na zadane pytanie.

Inną różnicą jest to, że komputerowe sieci neuronowe operują tylko liczbami, podczas gdy mózg ludzki odbiera jednocześnie sygnały z pięciu zmysłów. Powiązania między komórkami sieci neuronowej są znacznie bardziej ograniczone niż między neuronami wchodzącymi w skład ludzkiego mózgu. Biologiczny neuron powiązany jest z tysiącem lub jeszcze większą liczbą neuronów, wyidealizowany neuron z sieci neuronowej – z niewielką liczbą zawartych w sieci neuronów ukrytych. Liczba takich połączeń rzadko sięga stu, zwykle waha się w granicach dziesięciu. Wszystkie różnice podsumowuje tabela 2.1.

Uczenie i stosowanie sztucznych sieci neuronowych wymaga postępowania według specjalnego schematu działania złożonego z wielu etapów. Realizacja każdego z nich wpływa na powodzenie całej operacji. Poszczególne etapy omówimy szeroko w następnych rozdziałach; w tym miejscu scharakteryzujemy je jedynie pobieżnie.

- *Etap 1 – Określenie prognozowanej zmiennej.* Prognozowanie opadów śniegu w Vermont w listopadzie, choć trochę interesujące z ekonomicznego punktu widzenia, nie ma nic wspólnego z grą giełdową na indeksie S&P 500.

- *Etap 2 – Gromadzenie zbiorów danych lub szeregów liczbowych związanych z prognozowanym zjawiskiem.* Informacje te zostaną użyte w celu sporządzenia prognozy. Rezultat, z jakim zakończyliśmy w niedzielę grę w golfa, będzie miał niewielki wpływ na wartość S&P 500 za tydzień, jednak obecna cena ropy może bardzo silnie wpływać na S&P 500 w ciągu następnych kilku tygodni.
- *Etap 3 – Wstępne przetworzenie danych (preprocessing) tak, by łączyły informacje lub przedstawiały je w bardziej użyteczny sposób.* Dostarczając sieci danych na temat dzisiejszej ceny złota, możemy pomóc jej przewidzieć poziom S&P 500 za tydzień; jednak informacją dużo bardziej użyteczną, z punktu widzenia sieci, są zmiany ceny złota w poprzednim tygodniu.
- *Etap 4 – Ustalenie wartości minimalnych i maksymalnych.* Sprawdzamy, w jakim przedziale oscylują zgromadzone dane, a następnie określamy wartości minimalne i maksymalne. Pozwala to zwiększyć efektywność przetwarzania danych, ponieważ sieć koncentruje się na odpowiednich liczbach. Jeżeli dane mieszczą się w przedziale od 100 do 200, to wartości minimalne i maksymalne powinny wynosić odpowiednio 100 i 200, a nie na przykład -100 i 1000.
- *Etap 5 – Wyodrębnienie testowego zbioru danych.* Aby przetestować sieć za pomocą danych, z którymi jeszcze nie miała styczności, czyli danych stosowanych do jej uczenia, często część zbioru przeznacza się do przyszłego testowania. W efekcie zbiór danych dzielimy na dwa różne podzbiory, z których jeden służy do uczenia sieci, a drugi do jej testowania.
- *Etap 6 – Wybór odpowiedniej architektury sieci.* Sieci mogą być dwu-, trzy-, cztero-, a nawet pięciowarstwowe, zaś liczba neuronów w warstwach ukrytych waha się od jednego do kilkuset. Ową konstrukcję sieci określamy mianem *architektury sieci*. Istnieje ponad tuzin architektur sieci; jedne lepiej nadają się do rozwiązywania określonych problemów niż inne.
- *Etap 7 – Wybór odpowiedniego algorytmu uczenia (algorytmu treningowego).* Istnieje kilka algorytmów (metod treningowych), które można wykorzystać niezależnie od zastosowanej architektury sieci. Jedne są lepsze, inne gorsze – zależy to od konkretnego problemu.
- *Etap 8 – Uczenie sieci.* Aplikujemy sieci dane treningowe w połączeniu z określoną architekturą i algorytmem uczenia. Korygujemy w ten sposób wagi łączące neurony, dzięki czemu sieć będzie w stanie dokładnie prognozować interesujące nas zjawisko, gdy przedstawimy jej ten sam lub podobny zbiór danych.
- *Etap 9 – Zastosowanie sieci.* Do przyuczonej już sieci wczytujemy nowe zbiory danych lub dane bieżące w celu otrzymania prognozy.

Pomimo fascynujących możliwości, jakie oferują sieci neuronowe, nie nadają się one do rozwiązywania wszystkich problemów. Jak wspomnieliśmy w rozdziale pierwszym, jeżeli istnieje ścisłe matematyczne rozwiązanie problemu, użycie do jego rozwiązania sieci neuronowej jest błędem.

Sieci neuronowe najlepiej sprawdzają się tam, gdzie trzeba dopasować wzory, wykrywać złożone współzależności lub korzystać z danych w sposób selektywny. Często wzory zachowań, które odkrywa sieć, nie są dla ludzkiego obserwatora oczywiste. To, że rynek akcji podąża za rynkiem obligacji, jest w finansach zjawiskiem powszechnie znanym. Jednak zależność między ceną złota a rynkiem akcji nie jest już tak oczywista. Działanie sieci neuronowych prognozujących zachowanie rynku akcji można często usprawnić, włączając do zmiennych wejściowych cenę złota. W ten sposób, uwzględniając ukrytą zależność między ceną złota a zachowaniem rynku akcji, zwiększamy trafność przewidywań, nawet jeśli jako ludzie nie jesteśmy w stanie tej zależności uchwycić.

WYBÓR PROGNOZOWANEJ ZMIENNEJ

Prawidłowe określenie przewidywanej zmiennej jest bardzo ważne i odgrywa zasadniczą rolę w procesie formułowania prognozy. Załóżmy na przykład, że chcemy oszacować wartość indeksu Dow Jones Industrial Average (DJIA) podczas zamknięcia jutrzejszej sesji. Jeżeli wartość indeksu wynosi obecnie 3800 punktów i zmienia się codziennie o mniej więcej 10 punktów, to zmiana wynosi około 0,263 procent. Jeżeli zamierzamy przewidywać poziom DJIA z dokładnością do 2 punktów, dokładność musi wynosić 0,05 procent (2 punkty na 3800). Kiedy jednak próbujemy oszacować *zmianę* DJIA na koniec jutrzejszej sesji, a nie jego wartość, wystarczy jedynie 20-procentowa dokładność (2 punkty na 10). Jest to znaczna różnica, która wynika *po prostu z odmiennego podejścia do problemu*.

A gdybyśmy chcieli jedynie wiedzieć, czy jutro rynek pójdzie *w górę* czy *w dół* i nie interesowała nas skala wzrostu lub spadku? Wówczas mielibyśmy do czynienia z sytuacją prostszą niż w poprzednich dwóch przypadkach, ponieważ wybór ograniczałby się do dwóch możliwości.

Z wyborem prognozowanego zjawiska wiąże się wiele różnych problemów. Czy gdybyśmy chcieli wiedzieć, ile za tydzień będzie wynosić S&P 500, lepiej byłoby prognozować wartość z tygodniowym wyprzedzeniem na podstawie danych tygodniowych, czy z wyprzedzeniem pięciodniowym, opierając się na danych dziennych? Może się wydawać, że dane dzienne będą bardziej dokładne, jednak dane tygodniowe zawierają mniej „szumu”, co ma znaczenie, kiedy myślimy w kategoriach długookresowych. Najlepszym rozwiązaniem tego problemu jest budowa dwóch sieci, poddanie ich optymalizacji i treningowi oraz porównanie wyniku wygenerowanego przez sieć bazującą na danych dziennych z wynikiem sieci, której dostarczyliśmy danych tygodniowych.

Wybór prognozowanej zmiennej może prowadzić do dużych rozbieżności w uzyskanych wynikach. Zagadnienie to omówimy szerzej w rozdziale trzecim.

DOBÓR DANYCH WEJŚCIOWYCH

Wybór odpowiednich zmiennych wejściowych, podobnie jak wybór zmiennej prognozowanej, może być przyczyną dużych różnic wyników. Wybierając odpowiednie zmienne wejściowe, powinniśmy upewnić się, że dane są dostępne na czas. Cena mongolskich obligacji może wywierać duży wpływ na zachowanie rynku akcji, jednak dane mogą nie być dostępne wtedy, gdy są nam potrzebne. Ponieważ amerykańskie dane historyczne są łatwo dostępne, wiele osób zapomina, że analogiczne dane dla innych krajów bywają publikowane z opóźnieniem, bądź też są mało wiarygodne.

Jeżeli mamy zamiar poddać analizie wnioski o przyznanie kredytu hipotecznego, to za dane wejściowe mogą nam posłużyć wnioski już złożone. Dane z formularzy można wprowadzić do arkusza kalkulacyjnego, na przykład Lotusa, czy Excela. Kolumny arkusza reprezentować będą różne kategorie. Pierwszą kolumną może być „wynagrodzenie”, drugą „staż pracy”, a następną „inne dochody”. Każdy z wierszy odzwierciedlałby jeden wniosek.

Jednak danych wejściowych potrzebnych do prognozowania zachowania rynku akcji nie znajdziemy raczej w szafce na akta. Dane takie ściąga się zwykle przez modem od firm zajmujących się ich dystrybucją, na przykład Dow Jones lub Dial Data, a następnie importuje do arkusza kalkulacyjnego. W kolumnach znajdują się różne zmienne, a w wierszach czas.

WSTĘPNE PRZETWORZENIE DANYCH

Pliki arkuszy kalkulacyjnych mogą być bardzo duże. Często zdarza się, że zawierają nawet 50 kolumn i 1000 wierszy, co daje w sumie 50 000 komórek. Kiedy wszystkie dane znajdują się już w arkuszu, przystępujemy do ich wstępnego przetworzenia. W kontekście prognozowania zachowania rynku przykładem takiej operacji może być podzielenie liczby papierów, których kurs wzrósł, przez liczbę papierów, których kurs spadł. Powstały tak współczynnik zawiera informacje o dwóch zmiennych wejściowych. Testy wykazały, że większość sieci generuje dokładniejsze prognozy wtedy, gdy posługujemy się ilorazem waleorów zwyżkujących i zniżkujących, a nie zmiennymi indywidualnymi.

Innym przykładem wstępnego przetworzenia danych może być podanie sieci zarówno dzisiejszej wartości DJIA, jak i wartości sprzed pięciu lub dziesięciu dni. Stosuje się też 5-, 20- i 50-dniowe średnie kroczące (MA) DJIA. Często przetwarza się pierwotne dane tak, by wycisnąć z nich więcej informacji. W ten sposób tworzy się techniczne wskaźniki takie jak wskaźnik względnej siły rynku (RSI) czy wstęgi Bollingera. (Czytelników, którym obce są te terminy odsyłamy do słowniczka na końcu książki.)

Kolejnym krokiem w procesie wstępnego przetworzenia danych bywa niekiedy *normalizacja*. Dziesięć lat temu wartość indeksu Dow Jones wynosiła około 1000 punktów, podczas gdy jego wartość obecna to prawie 4000 punktów. Jednym ze sposobów zmniejszenia rozpiętości przedziału, w którym znajdują się dane, jest ich normalizacja. W większości przypadków dokonujemy tego, odejmując od danych długoterminową średnią kroczącą. Diagramy 2.1 oraz 2.2 przedstawiają typowe dane przed i po normalizacji. Zwróćmy uwagę, że dzięki normalizacji usunęliśmy długoterminowe obciążenie danych w górę, przez co wahania krótkoterminowe stały się znacznie lepiej widoczne.

WARTOŚCI MINIMALNE I MAKSYMALNE

Po zakończeniu wstępnego przetwarzania danych plik z arkusza kalkulacyjnego wczytuje się zwykle do programu modelującego sieć neuronową, lub też ten ostatni bezpośrednio korzysta z danych arkusza kalkulacyjnego, tworząc wokół niego tzw. *shell*. Na tym etapie program modelujący bada dane oraz określa minimalną i maksymalną wartość zmiennych wejściowych, co ma na celu ich wyskalowanie do przedziału akceptowanego przez sieć.

WYODRĘBNIENIE TESTOWEGO ZBIORU DANYCH

Następnie dane dzielimy na dwa lub więcej zbiorów. Pierwszy z nich służy do *uczenia*, natomiast drugi do *testowania* sieci. Zazwyczaj około 10 procent danych przeznaczają się na zbiór testowy. Zbiór przeznaczony do *uczenia* sieci to dane, na bazie których sieć wykrywa wzory i współzależności. W skład *zbioru testowego* wchodzi dane odłożone w celu weryfikacji nauczonej sieci, z którymi sieć nie miała do tej pory kontaktu. Jedynie przetestowanie nauczonej sieci za pomocą świeżych danych daje projektantowi lub użytkownikowi gwarancję, że sieć nauczyła się wykonywać zadanie z oczekiwaną dokładnością. Niekiedy wyodrębnia się również trzeci zbiór danych, który służy do dalszego testowania. Dane testowe można wybierać losowo: może to być na przykład co dziesiąta próbka lub wszystkie próbki między dwiema datami. Każda z metod ma swoje zalety, w zależności od tego, co chcemy udowodnić.

ARCHITEKTURA SIECI

Kolejnym etapem jest wybór odpowiedniej sieci. Około 85 procent wszystkich problemów rozwiązuje się za pomocą sieci trzywarstwowej opartej



Diagram 2.1 Typowy szereg czasowy danych. Widoczny długoterminowy trend.
Źródło: Ward Systems Group, Inc.




Diagram 2.2 Szereg czasowy danych po usunięciu długoterminowego trendu. Otrzymujemy go odejmując od danych długoterminową średnią kroczącą (20 do 50 okresów).
Źródło: Ward Systems Group, Inc.

na algorytmie wstecznej propagacji błędu (*back-propagation*). Sieć taka porównuje prognozę z wartością rzeczywistą i na bazie uzyskanej różnicy koryguje siłę powiązań między neuronami. Jeden z pakietów oprogramowania oferuje 15 różnych architektur sieci, z których część jest wysoko wyspecjalizowana. Zazwyczaj na początku uczymy sieć trzywarstwową ze wsteczną propagacją błędu, ponieważ jest ona najprostsza, a osiągnięte przez nią wyniki stały się podstawą oceny wyników innych architektur.

ALGORYTM UCZENIA

Następnie musimy wybrać *algorytm uczenia*, czyli formułę służącą do wykrywania zależności i wzorów. Najbardziej popularnym jest *momentum*, jednak często dostawcy oprogramowania posiadają własne zastrzeżone prawnie algorytmy. Większość sieci uczy się w oparciu o jakąś odmianę algorytmu *momentum*. Po dokonaniu wyboru możemy rozpocząć uczenie sieci.

UCZENIE I TESTOWANIE

W procesie uczenia dane wejściowe z arkusza kalkulacyjnego wiersz za wierszem wczytujemy do sieci. Sieć szacuje odpowiedź i porównuje ją z odpowiedzią prawidłową znajdującą się w jednej z kolumn. Zapisuje błąd, koryguje siłę powiązań między neuronami, po czym przechodzi do następnego wiersza danych i cała operacja się powtarza. Po przebadaniu wszystkich danych, sieć zaczyna od początku i skanuje je jeszcze wiele razy. Każde takie „przejście” przez pełny zbiór danych nazywamy *epoką* (diagram 2.3). Nierzadko zdarza się, że w procesie porównywania wyników sieć analizuje kilka tysięcy epok i milion wierszy danych. Część dostawców oprogramowania określa owe wiersze mianem „faktów”, a część mianem „próbek”. Cały proces bardzo silnie angażuje moc obliczeniową komputera.

Powiązania między neuronami noszą nazwę *wag*. Siła tych powiązań sprawia, że każda sieć jest jedyna w swoim rodzaju. Dwie na pozór identyczne sieci trzywarstwowe, obie zawierające 6 wejść, 6 neuronów ukrytych i jedno wyjście, różnią się właśnie siłą powiązań między neuronami.

Część programów testuje sieć co pewien czas w trakcie jej uczenia, co ma na celu ustalenie, czy nabyte przez nią umiejętności prognostyczne są zadowalające. Raz na jakiś czas (na przykład po analizie każdego 200 wierszy zbioru danych) program zatrzymuje trening i wykorzystując dane testowe, kontroluje postępy poczynione przez sieć. Takie okresowe zatrzymywanie procesu uczenia i testowanie sieci trwa tak długo,




Diagram 2.3 Sposób uporządkowania danych dla potrzeb mózgu. Widzimy jak dane mogłyby zostać zaprezentowane człowiekowi, by pomóc mu w ich szybkim przyswojeniu. Każda strona reprezentuje pojedynczy fakt (próbkę). W trakcie uczenia sztucznej sieci neuronowej każdy wiersz arkusza kalkulacyjnego reprezentuje fakt lub próbkę.

Źródło: Ward Systems Group, Inc.

aż sieć nie będzie w stanie poprawić swoich wyników na bazie danych testowych. Kiedy dalszy trening nie może już udoskonalić sieci, zapisujemy jej konfigurację, a proces uczenia dobiega końca. Jeżeli program nie dysponuje taką opcją, uczący, który chce śledzić postępy sieci, musi raz na jakiś czas zatrzymać trening i testować sieć własnoręcznie.

W diagramach 2.4 oraz 2.5 przedstawiono rozkład błędu popełnianego przez sieć względem czasu treningu. Zwróćmy uwagę, że błąd jest duży w początkowej fazie, po czym gwałtownie maleje, osiągając poziom, którego, w miarę jak proces uczenia dobiega końca, nie daje się już zmniejszyć. W tym punkcie sieć przestaje się uczyć.

Jeżeli mimo to będziemy kontynuować trening, sieć zacznie uczyć się na pamięć poprawnych odpowiedzi, a błąd wzrośnie. Kiedy taką przećwiczoną treningiem sieć przetestujemy za pomocą nowych danych, jej wyniki będą słabe. W takich przypadkach mówi się, że sieć *nie uogólnia dobrze*.

RZECZYWISTOŚĆ

Często sieci nie spełniają pokładanych w nich nadziei, czyli nie są wystarczająco dokładne i projektant musi ponownie zastanowić się, co jest




Diagram 2.4 Krzywa błędu po 6912 prezentacjach próbek uczących. Poprawa wyników następuje równomiernie w początkowej fazie treningu.




Diagram 2.5 Krzywa błędu po 12 900 prezentacjach próbek uczących. Mimo iż liczba testów jest dwukrotnie większa niż na diagramie 2.4, następuje tylko niewielka poprawa.

prognozowanym zjawiskiem, jakie należy wybrać zmienne wejściowe oraz jak powinno się przygotować dane. Wiele pakietów oprogramowania posiada opcje umożliwiające obliczenie wkładu poszczególnych zmiennych wejściowych do rozwiązania, co bardzo pomaga raz jeszcze prze-myśleć problem.

Gdy umiejętności prognostyczne sieci nabyte podczas treningu od-powiadają oczekiwaniom projektanta, sieć jest gotowa do użytku.

Rozdział trzeci

Wybór prognozowanego zjawiska i odpowiednich zmiennych

Ludzie kupują pakiety oprogramowania, wybierają bez głębszego namysłu zmienną wyjściową, wprowadzają szeroki wachlarz zmiennych wejściowych, uczą niewyspecjalizowaną sieć za pomocą algorytmu ogólnego zastosowania, jednak, choć odnotowują pewne sukcesy, podejście takie w większości przypadków nie przynosi pożądanych rezultatów.

Dużo lepsze efekty osiągniemy:

1. Uważnie selekcionując zmienną wyjściową.
2. Wybierając zmienne wejściowe, które pozostają w predyktywnej zależności ze zmienną wyjściową.
3. Wybierając optymalną architekturę sieci neuronowej i algorytm uczenia.

PROGNOZOWANIE SZEREGÓW CZASOWYCH – WARTOŚĆ ABSOLUTNA

Jak już wspomnieliśmy w rozdziale drugim, prognozowanie *wartości* indeksów DJIA, OEX lub S&P 500 z 5- czy 10-okresowym wyprzedzeniem nie daje zazwyczaj zbyt dobrych rezultatów. Na przykład Dow Jones, którego wartość w chwili pisania tej książki oscyluje w przedziale od 4000 do 4400 punktów, średnio zmienia się tygodniowo o około 20 punktów procentowych, czyli o 0,5 procent. Mimo iż w niektórych tygodniach zmiany te są znacznie większe, przeciętnie rzecz biorąc wahają się w granicach 20–40 punktów. Aby prognozy sieci miały jakąkolwiek wartość, musiałaby ona przewidywać wartość indeksu z dokładnością do około 0,1 procent, czyli 4 punktów. Biorąc pod uwagę dynamikę i zmienność nastrojów na rynku akcji, jest to nieosiągalne. Lepiej więc prognozować wartość, w której przypadku możemy sobie pozwolić na większy margines błędu.

Margines ten byłby większy, gdybyśmy na przykład przewidywali nie wartość, lecz *zmianę* indeksu Dow Jones. Jeżeli przeciętna zmiana indeksu wynosi 20 punktów, a nasza prognoza obarczona jest 20-procentowym błędem, to nadal przewidujemy z dokładnością do 4 punktów, tyle że tolerowany błąd wzrasta nam gwałtownie z 0,1 do 20 procent. Dużo łatwiej sporządzić prognozę przy dopuszczalnym 20-procentowym marginesie błędu niż wówczas, gdy wymagana dokładność musi wynosić co najmniej 0,1 procent.

Poniżej przedstawiamy część zmiennych, które w prognozowaniu szeregów czasowych można podstawić za bezwzględny poziom cen:

1. Ostatnia zmiana ceny.
2. Wskaźnik pokazujący, czy najświeższe dane reprezentują maksimum, czy też minimum rynku.
3. Wskaźnik sygnalizujący, czy należy kupować, sprzedawać, czy też trzymać.
4. Wskaźnik pokazujący, czy data prognozy reprezentuje globalne maksimum, czy też minimum.
5. Zmiana wartości w prognozowanym okresie.
6. Wskaźnik trendu.
7. Zmiana wyrażona w procentach.
8. „Jakość” zawarcia transakcji w danym czasie.
9. Wskaźnik pokazujący, czy najświeższe dane reprezentują zmianę trendu.
10. Podatność na gwałtowne wahania (*volatility*).
11. Zmiana podatności na gwałtowne wahania.

SIEĆ ODNIESIENIA

Aby zilustrować wpływ różnych parametrów sieci neuronowych, posłużymy się *siecią odniesienia* i danymi zebranymi w szeregach czasowych. Na dane te składa się sześć pozycji, których wartości odczytywaliśmy co godzinę przez 238 godzin:

1. Kontrakt *futures* na indeks S&P (SPY).
2. Indeks New York Stock Exchange 100 (YXY).
3. Liczba akcji zwiększających (ADV).
4. Liczba akcji zmniejszających (DEC).
5. *Tick volume* (aktualizowana na bieżąco różnica między wolumenem transakcji zawartych po cenie wyższej a wolumenem transakcji zawartych po cenie niższej).
6. Iloraz proporcji walorów zyskujących na wartości do walorów zmniejszających oraz proporcji wolumenu walorów zwiększających do wolumenu walorów, których cena spadła (TRIN).

Powyższe szeregi danych posłużą bezpośrednio za zmienne wejściowe sieci neuronowej. W przyszłych zastosowaniach naszej sieci odniesienia będziemy zmieniać tylko określone, aktualnie omawiane, zmienne.

Sieć odniesienia opierać się będzie na sześciu zmiennych – (1) SPY, (2) XYX, (3) ADV, (4) DEC, (5) TICK oraz (6) TRIN, zaś jej własności są następujące:

- Sieć prognozuje SPY z pięciogodzinnym wyprzedzeniem.
- W warstwie ukrytej znajduje się 6 neuronów.
- Sieć posiada jeden neuron wyjściowy.
- Sieć bazuje na algorytmie wstecznej propagacji błędów.
- Sieć poddajemy treningowi, opierając się na algorytmie *momentum*; współczynnik uczenia wynosi 0,05, a współczynnik *momentum* 0,5.
- Za każdym razem, gdy sieć przeanalizuje 200 próbek, prezentujemy jej dane testowe (świeże dane, które odłożyliśmy wcześniej); kiedy wyniki sieci uzyskane na bazie danych testowych nie ulegają dalszej poprawie, proces uczenia ulega zatrzymaniu.

Pierwszy przykład wyników sieci odniesienia uczoney w opisywany wyżej sposób przedstawia diagram 3.1. W kolumnie A mamy *wartość rzeczywistą* szeregu czasowego, w kolumnie B – *wartość przewidywaną przez sieć* w chwili, gdy dalsze postępy w nauce nie są już możliwe, natomiast kolumna C zawiera *błąd prognozy*. Ponieważ wybraliśmy bardzo typową architekturę sieci i algorytm uczenia, wyniki te stanowiąc będą również kryterium oceny. Opierając się na tych samych zmiennych wejściowych, przetestujemy wiele sieci różniących się architekturą, algorytmami uczenia i prognozowanymi zmiennymi, a następnie porównamy je z siecią odniesienia, by sprawdzić, czy wprowadzone zmiany poprawiają wyniki sieci.

	A	B	C
1	Actual(1)	Network(1)	Act-Net(1)
2	448.64	449.47	-0.83
3	448.23	449.78	-1.55
4	448.04	450.28	-2.24
5	447.94	449.82	-1.88
6	448.41	449.40	-0.99
7	448.66	449.76	-1.10
8	449.22	449.38	-0.16
9	448.38	449.01	-0.63
10	447.29	448.74	-1.45
11	447.57	448.38	-0.81
12	447.55	448.26	-0.71
13	446.92	448.75	-1.83
14	446.55	448.86	-2.31
15	445.75	449.20	-3.45
16	446.30	447.89	-1.59
17	445.31	447.08	-1.77
18	445.34	447.21	-1.87
19	445.18	447.22	-2.04
20	445.70	446.82	-1.12
21	445.85	446.51	-0.66
22	446.02	445.70	0.32
23	444.22	446.58	-2.36
24	445.79	446.00	-0.21
25	446.75	446.21	0.54
26	447.49	446.13	1.36
27	447.08	446.39	0.69
28	447.08	446.63	0.45
29	447.31	446.76	0.55
30	446.14	445.67	0.47
31	446.48	446.85	-0.37
32	446.26	447.68	-1.42
33	446.46	448.27	-1.81
34	446.23	447.87	-1.64
35	446.39	447.98	-1.59
36	447.18	447.98	-0.80
37	446.44	446.43	0.01
38	447.00	446.80	0.20
39	446.76	446.77	-0.01
40	446.52	447.08	-0.56
41	446.20	446.86	-0.66
42	444.11	446.92	-2.81
43	444.51	447.52	-3.01
44	446.58	446.76	-0.18
45	445.79	447.43	-1.64
46	445.26	446.97	-1.71
47	445.27	446.89	-1.62
48	446.21	446.56	-0.35
49	446.83	445.07	1.76
50	447.10	445.25	1.85
51	448.75	446.61	2.14
52	448.32	445.92	2.40
53	448.42	445.57	2.85
54	448.62	445.65	2.97

Diagram 3.1 Wyniki testu sieci odniesienia. Wydruk prognozowanych wyników. Kolumna A zawiera wartość rzeczywistą, kolumna B wartość przewidywaną przez sieć, zaś kolumna C różnicę między wartością rzeczywistą a wartością oszacowaną w prognozie. Kolumnę C określa się również mianem błędu sieci.




Diagram 3.2 Względny wkład poszczególnych zmiennych wejściowych do sieci odniesienia. Oznaczenia: zmienna 1 – ADV, zmienna 2 – DEC, zmienna 3 – TICK, zmienna 4 – TRIN, zmienna 5 – SPY oraz zmienna 6 – YXY.

WZGLĘDNY WKŁAD

Diagram 3.2 przedstawia względny wkład poszczególnych zmiennych wejściowych do sieci. Względny wkład obliczamy, sumując siłę powiązań między neuronami wejściowymi a neuronami w warstwie ukrytej. Wejścia wywierające słaby wpływ na wyjścia są słabo związane z warstwą ukrytą i, odwrotnie, wejścia, których wpływ na wyjścia jest znaczny, są silnie połączone z tą warstwą.

W rozdziale czwartym do sieci odniesienia będziemy dodawać różne zmienne wejściowe i wskaźniki, co pozwoli nam ustalić, w jakim stopniu zwiększają dokładność wyników sieci.

PROGNOZOWANIE KIERUNKU SZEREGU CZASOWEGO

Często nie jest nam potrzebna dokładna wartość szeregu czasowego w ściśle określonej przyszłości, tylko chcemy wiedzieć, czy jest ona wyższa, czy też niższa od wartości bieżącej. Aby przewidzieć, czy po upływie 5 okresów kurs gotówkowy S&P (SPY) wyznaczony przez sieć odniesienia będzie niższy czy wyższy, wprowadzamy nową zmienną prognozowaną. Ma ona charakter zerojedynkowy: gdyby w ciągu 5 dni S&P miał się zmniejszyć, jej wartość wyniosłaby 0, zaś gdyby w tym samym

czasie nastąpił wzrost S&P, zmienna przybrała wartość 1. Konstruując sieć odniesienia, wykorzystujemy te same sześć zmiennych wejściowych (diagram 3.3). Wartość zmiennej wyjściowej wynosi 0 lub 1, w zależności od tego, czy oczekiwany jest spadek, czy wzrost. Treningowi poddaliśmy sieć neuronową realizującą regresję uogólnioną (GRNN), którą opiszemy dokładniej w kolejnych rozdziałach. (Sieci ze wsteczną propagacją błędów, uczone za pomocą algorytmu *momentum*, które pełnią zwykle funkcję systemu odniesienia, niezbyt dobrze nadają się do rozwiązywania rozważanego problemu, tak więc sieć typu GRNN zastosowaliśmy jedynie dla celów ilustracyjnych.) Wyniki przedstawia diagram 3.3. Dla celów interpretacji przyjęliśmy, że wartości z przedziału od 0 do 0,3 będziemy interpretować jako sygnał spadku, wartości z przedziału od 0,31 do 0,69 jako brak wyraźnego sygnału, zaś wartości powyżej 0,7 jako sygnał wzrostu.

Spośród 54 przedstawionych wyników 23 wskazywały na wzrost, 20 na spadek, a 11 nie dawało się jednoznacznie zinterpretować. Uzyskaliśmy doskonałą korelację z danymi wejściowymi, a prognoza sieci okazała się trafna w 80 procentach przypadków.

PROCENTOWA ZMIANA KIERUNKU SZEREGU CZASOWEGO

Innym sposobem jest prognozowanie procentowej zmiany w ustalonym przyszłym okresie. W celu oszacowania procentowej zmiany w ciągu pięciu okresów wykorzystaliśmy sześć zmiennych wejściowych, architekturę i algorytm uczenia sieci odniesienia (diagram 3.4).

Wartości z kolumny A reprezentują rzeczywistą zmianę w 5-dniowym okresie. Kolumna B przedstawia wartości prognozowane przez sieć, zaś kolumna C różnice między zmianą rzeczywistą a zmianą przewidywaną, czyli błąd. W kolumnie D przewidywana zmiana procentowa została przeliczona na zmianę wyrażoną w punktach indeksu S&P, co ma na celu porównanie z prognozą sieci odniesienia szacującej wartość absolutną z 5-dniowym wyprzedzeniem (diagram 3.1). Kolumna E z diagramu 3.4 przedstawia błąd prognozy wyrażony w punktach S&P.

W przypadku sieci odniesienia błąd oscylował w przedziale od -3,45 do 2,97, co odpowiadało 6,42 punktu. Dla sieci prognozującej błąd wyrażony w procentach (diagram 3.4) błąd zawierał się w przedziale od -1,89 do 2,48. Rozpiętość wahań wynosiła 4,37 punktu, tak więc w porównaniu z siecią prognozującą zmianę w kategoriach absolutnych uzyskaliśmy 32-procentową poprawę. Możemy skonstatować, że w tym konkretnym przypadku szacowanie zmiany procentowej daje lepszą dokładność niż szacowanie ceny wyrażonej wartością absolutną.

Wybór prognozowanej zmiennej może stanowić przyczynę dużych rozbieżności w otrzymanych wynikach. Często należy przetestować kilka różnych zmiennych, aby sprawdzić, która nadaje się najlepiej. Nierzadko

	A	B
1	Actual(1)	Network(1)
2	1.00	1.00
3	1.00	0.99
4	1.00	1.00
5	1.00	0.99
6	1.00	1.00
7	1.00	0.99
8	1.00	0.99
9	1.00	0.49
10	1.00	0.47
11	1.00	0.34
12	1.00	0.32
13	1.00	0.39
14	1.00	0.43
15	1.00	0.51
16	1.00	0.91
17	1.00	0.98
18	1.00	0.90
19	1.00	0.91
20	1.00	0.97
21	1.00	0.63
22	0.00	0.00
23	1.00	0.72
24	0.00	0.06
25	0.00	0.13
26	0.00	0.17
27	0.00	0.14
28	0.00	0.25
29	0.00	0.32
30	0.00	0.0000
31	0.00	0.51
32	1.00	0.96
33	1.00	0.91
34	1.00	0.87
35	1.00	0.89
36	1.00	0.92
37	0.00	0.05
38	0.00	0.19
39	0.00	0.15
40	0.00	0.28
41	1.00	0.26
42	1.00	0.32
43	1.00	0.58
44	0.00	0.19
45	1.00	0.63
46	1.00	0.42
47	1.00	0.39
48	0.00	0.25
49	0.00	0.000000
50	0.00	0.0000
51	0.00	0.12
52	0.00	0.00
53	0.00	0.01
54	0.00	0.12

Diagram 3.3 Prognoza wzrostu/spadku. Kolumna B przedstawia wyniki uczenia sieci odniesienia. Zadaniem sieci było przewidzieć, czy wartość SPY po upływie 5 okresów będzie wyższa, czy też niższa. Kolumna A zawiera wartości rzeczywiste: 1 oznacza wzrost, a 0 spadek.

	A	B	C	D	E
1	Actual(1)	Network(1)	Act-Net(1)	VALUE	ERROR
2	0.00	0.47	-0.47		
3	0.00	0.38	-0.38		
4	0.00	0.36	-0.36		
5	0.00	0.27	-0.27		
6	0.00	0.20	-0.20		
7	0.06	0.22	-0.16	0.99	-0.72
8	-0.04	0.19	-0.23	0.86	-1.04
9	-0.52	-0.14	-0.39	-0.63	-1.76
10	-0.55	-0.13	-0.42	-0.59	-1.89
11	-0.58	-0.16	-0.42	-0.72	-1.89
12	-0.57	-0.17	-0.40	-0.77	-1.80
13	-0.37	-0.12	-0.25	-0.54	-1.13
14	0.00	-0.07	0.07	-0.32	0.32
15	0.22	-0.02	0.25	-0.09	1.13
16	0.08	-0.14	0.21	-0.63	0.95
17	-0.15	-0.26	0.11	-1.17	0.50
18	-0.19	-0.24	0.05	-1.08	0.23
19	-0.25	-0.24	-0.00	-1.08	0.00
20	-0.51	-0.29	-0.23	-1.31	-1.04
21	-0.41	-0.24	-0.17	-1.08	-0.77
22	-0.34	-0.22	-0.12	-0.99	-0.54
23	-0.28	-0.12	-0.17	-0.54	-0.77
24	-0.50	-0.22	-0.28	-0.99	-1.26
25	-0.35	-0.15	-0.21	-0.67	-0.95
26	-0.31	-0.17	-0.14	-0.77	-0.63
27	-0.01	-0.12	0.11	-0.54	0.50
28	-0.10	-0.11	0.01	-0.50	0.05
29	0.16	-0.07	0.23	-0.32	1.04
30	-0.25	-0.22	-0.03	-0.99	-0.14
31	0.14	-0.04	0.18	-0.18	0.81
32	0.24	0.08	0.16	0.36	0.72

Diagram 3.4 Prognoza zmiany procentowej. Wyniki przyuczenia sieci do prognozowania oczekiwanej zmiany procentowej w odróżnieniu od wartości absolutnej lub jej zmiany. Szczegółowy opis poszczególnych kolumn znajduje się w tekście rozdziału.

Tabela 3.1 Porównanie dwóch architektur sieci dla różnej liczby okresów objętych prognozą. Przedstawiono współczynniki determinacji reprezentujące korelację między wartościami rzeczywistymi a prognozowanymi przy zwiększającej się liczbie okresów.

Liczba okresów objętych prognozą	Typ prognozy	
	GRNN	Wsteczna propagacja błędu
1	0,9740	0,9810
2	0,9695	0,9650
3	0,9495	0,9230
4	0,9564	0,9120
5	0,9509	0,9090
6	0,9766	0,9000
8	0,9893	(0,8870)
10	0,9850	0,8730
15	0,9760	0,8550
20	0,9590	0,8520
35	0,9520	0,8690
50	0,9100	0,7880
100	0,8040	0,6840

odpowiednie dane wejściowe nie są dostępne na czas lub w ogóle trudno je zdobyć. Niekiedy w takiej sytuacji należy tak zmodyfikować zmienną prognozowaną, by pasowała do dostępnych danych. Choć wybór odpowiedniej zmiennej prognozowanej odgrywa bardzo ważną rolę, należy pamiętać, że jest on w dużym stopniu uzależniony od dostępności zmiennych wejściowych pozostających w predyktywnym związku ze zmienną wyjściową.

HORYZONT CZASOWY

Wybór zmiennej prognozowanej zależy również od horyzontu czasowego, czyli faktu, czy jest ona krótko-, czy też długoterminowa. W tabeli 3.1 ukazano wyniki sieci GRNN i sieci opartej na algorytmie wstecznej propagacji błędu dla prognoz sporządzanych z wyprzedzeniem od 1 do 100 dni. Wyniki sieci wyrażone są współczynnikiem determinacji (R^2); im większa jego wartość, tym większa dokładność prognozy. Za dane wejściowe posłużyły nam dane opisanej wcześniej sieci odniesienia. Na diagramie 3.5 na osi pionowej znajduje się współczynnik determinacji, zaś na osi poziomej liczba pokazująca, na ile okresów naprzód sporządzona jest prognoza. Aby pokazać, jak ważną rolę odgrywa wybór prawidłowych lub optymalnych zmiennych, na diagramie 3.5 przedstawiliśmy rezultaty obu sieci. Wyniki systemu odniesienia opartego na algorytmie wstecznej propagacji błędu zaznaczyliśmy na wykresie wypełnionymi




Diagram 3.5 Wartości współczynnika determinacji dla dwóch różnych architektur sieci, gdy opracowujemy prognozy o różnym horyzoncie czasowym. Od szóstego okresu dokładność przewidywań sieci opartej na algorytmie wstecznej propagacji błędu zaczyna gwałtownie spadać. Im dłuższy okres, tym mniejsza trafność prognozy.

kwadratami. Jak można się było spodziewać, wartość współczynnika determinacji spada wraz z wydłużaniem się horyzontu czasowego prognozy, co oznacza, że trudniej opracować prognozę, gdy liczba objętych nią okresów jest większa.

Linia zaznaczona pustymi kwadratami przedstawia wartości współczynnika determinacji dla sieci GRNN korzystającej z danych wejściowych sieci odniesienia (architektury sieci omówimy szerzej w rozdziale piątym). Od drugiego okresu sieć GRNN uzyskuje znacznie wyższe współczynniki determinacji niż sieć odniesienia. Zauważmy, że po nieznacznym spadku współczynników determinacji dla prognoz sporządzanych na 2, 3 i 4 okresy naprzód, ich wartość zaczyna wzrastać i osiąga maksimum dla prognozy 8-okresowej, po czym powoli maleje, aż do 15 okresów. Jednak tak naprawdę wyniki sieci GRNN dla 15 okresów są lepsze od wyników sieci odniesienia dla liczby okresów z przedziału od 1 do 5.

Na efektywność danej sieci neuronowej wpływa nie tylko wybór prognozowanej zmiennej, ale również horyzont czasowy prognozy i wybrana architektura. Optymalny horyzont czasowy można ustalić jedynie badając korelacje dla różnych okresów. Jak zobaczymy w rozdziale piątym, rodzaj zastosowanej architektury i algorytmu uczenia w bardzo dużym stopniu determinują dokładność przewidywań sieci. Jedynym sposobem wyznaczenia *optymalnej* sieci jest wielokrotne testowanie różnych podejść. Choć zastosowanie pośpiesznie skleconej, pierwszej lepszej sieci przynosi niekiedy niezłe efekty, użycie sieci, w której wszystkie zmienne zostały zoptymalizowane, może być źródłem wielokrotnie większych korzyści, które z nawiązką zrekompensują nam koszty badania rozmaitych opcji.

INNE ZASTOSOWANIA SIECI NEURONOWYCH

SELEKCJA AKCJI

Bardzo owocnym zastosowaniem sieci neuronowych w dziedzinie prognozowania finansowego jest dobór akcji rokujących największe szanse na wzrost. Jednym z możliwych podejść jest prognozowanie względnych ocen. Akcjom o słabych perspektywach wzrostu można przypisać oceny od 0 do 3, akcjom, których aprecjacja jest prawdopodobna – od 7 do 10.

ANALIZA WNIOSKÓW O UDZIELENIE KREDYTÓW HIPOTECZNYCH

Sieci neuronowe stanowią również użyteczne narzędzie oceny wniosków o udzielenie kredytów hipotecznych. W tym przypadku zmienna prognozowana przyjmuje wartość 0 (dla wnioskodawców z przeszłości, którzy nie spłacili pożyczki) lub 1 (dla tych, którzy uregulowali swe zobowiązania). Problem ten bardzo przypomina prognozowanie, czy rynek akcji pójdzie w górę, czy w dół.

PROGNOZOWANIE BANKRUCTW

Prognozowanie upadłości banków i bankructw jest bardzo podobne do prognozowania kierunku rynku i wiarygodności osób starających się o kredyt hipoteczny. Prawdopodobnie najlepszym sposobem jest zastosowanie zmiennej prognozowanej przyjmującej wartości 0 i 1, które reprezentują odpowiednio bankructwo lub kontynuowanie działalności przez przedsiębiorstwo.

KLASYFIKACJA OBLIGACJI

Klasyfikację obligacji, która przypomina prognozowanie bankructw banków i przedsiębiorstw, komplikuje fakt, że możliwe do zaakceptowania obligacje mogą otrzymać jedną z pięciu ocen. W tabeli 3.2 przedstawiliśmy system oceny wykorzystywany przez agencję ratingową Standard

Tabela 3.2 Możliwy system oceny obligacji.

	Jednakowe przedziały dla każdej grupy	Przedziały faworyzujące obligacje śmieciowe
AAA	4,00	7,00 i więcej
AA	3,00–3,99	6,00–6,99
A	2,00–2,99	5,00–5,99
BBB	1,00–1,99	4,00–4,99
CCC	0,00–0,99	0,00–3,99

and Poors. Moody, inna agencja zajmująca się klasyfikacją obligacji, stosuje podobną skalę różniącą się oznaczeniami literowymi. My posłużymy się następującą notacją:

- AAA Obligacje o najwyższej jakości
 AA Obligacje o jakości bardzo zbliżonej do AAA
 A Obligacje dobrej klasy, podatne na niekorzystne zmiany warunków
 BBB Obligacje zadowalającej jakości, bardziej wrażliwe na niekorzystne zmiany warunków
 CCC Obligacje „śmieciowe”

Szukając odpowiedniej zmiennej prognozowanej, moglibyśmy wykorzystać jeden z wariantów przedstawionych w tabeli 3.2.

W kolumnie z możliwymi parametrami wyjściowymi oznaczonej etykiety „jednakowe przedziały dla każdej grupy” każdej kategorii obligacji przypisaliśmy mniej więcej równe przedziały wartości, podczas gdy w kolumnie „przedziały faworyzujące obligacje śmieciowe” większy nacisk położyliśmy na obligacje śmieciowe. Bardzo możliwe, że żaden z przedstawionych systemów ocen nie jest optymalny. Niewykluczone, że stosując system kładący nacisk na kategorie od AA do BBB uzyskalibyśmy dokładniejsze wyniki. Jedynym sposobem sprawdzenia, która z metod jest najlepsza, jest przetestowanie różnych wariantów.

Poddając sieci tego rodzaju treningowi, powinniśmy zwrócić uwagę na to, by każdą kategorię reprezentowała taka sama liczba próbek uczących. Oznacza to, że liczba próbek z kategorii AAA powinna równać się liczbie próbek z kategorii AA i tak dalej. Jeżeli większość prezentowanych próbek należeć będzie do kategorii AAA, AA i A, a tylko nieliczne reprezentować będą kategorie BBB i CCC, sieć nie dowie się wiele o próbkach z kategorii BBB i CCC drogą bezpośredniego kontaktu z materiałem treningowym i będzie „skazana” na wnioskowanie.

Rozdział czwarty

Wybór zmiennych wejściowych

W rozdziale przedstawimy zasady selekcji odpowiednich zmiennych i metody ich testowania pozwalające nam upewnić się, że zmienne te pozostają w predyktywnej zależności ze zmienną prognozowaną. Dodatkowo zaprezentujemy zmienne wejściowe, które nadają się do wykorzystania w wielu powszechnie spotykanych problemach decyzyjnych.

WYBÓR ODPOWIEDNICH ZMIENNYCH WEJŚCIOWYCH

Wybór zmiennych wejściowych pozwalających dobrze przewidywać wartość zmiennej prognozowanej jest równie ważny jak wybór najlepszej możliwej zmiennej prognozowanej. Wybór zmiennych, które w największym stopniu determinują prawdopodobieństwo bankructwa osoby ubiegającej się o kredyt hipoteczny, stanowi względnie łatwe zadanie. Trudniej zdecydować, które zmienne są potrzebne do przewidywania indeksu S&P z pięciodniowym wyprzedzeniem, ponieważ zarówno zmienne

wejściowe, jak i wyjściowe stosowane do prognozowania szeregów czasowych charakteryzują się dużym „szumem”. Oznacza to, że dane są „zanieczyszczone” dodatkowymi lub losowymi wahaniami, nie mającymi nic wspólnego z ogólną tendencją lub trendem.

Dane wykorzystywane w ocenie wiarygodności kredytowej osób ubiegających się o kredyt hipoteczny mają zwykle charakter bardziej ogólny. Jeżeli nie będzie dochodu potrzebnego do uregulowania miesięcznych płatności, ubiegający się o pożyczkę nie będzie jej w stanie spłacić, a sieć względnie łatwo wychwyci tę prawidłowość. W przypadku, gdy prognozujemy szeregi czasowe, wartość zmiennej wejściowej może w dniu dzisiejszym wzrosnąć, po czym następnego dnia powrócić do początkowego poziomu i pozostać na nim przez kolejny miesiąc. Czy dzisiejsza aprecjacja stanowi ważną informację, czy jest tylko szumem? Ponieważ wartość zmiennej wejściowej utrzymywała się przez miesiąc na niskim poziomie, możemy domniemywać, że wzrost był szumem lub losowym wahaniami, jednak jesteśmy w stanie to stwierdzić dopiero *po fakcie*.

KORELACJA I WKŁAD

Wiele programów modelujących sieci neuronowe zawiera jeden lub większą liczbę podprogramów ułatwiających wybór odpowiednich zmiennych wejściowych. Podprogramy te umożliwiają porównanie danej zmiennej wejściowej ze zmienną prognozowaną w celu ustalenia, czy istnieje między nimi predykcyjna zależność, czyli wyznaczenia *korelacji* oznaczonej zmiennej wejściowej ze zmienną, którą zamierzamy prognozować. Rezultat zastosowania tego rodzaju podprogramu stanowi często wykres punktowy przedstawiający relację dwóch testowanych zmiennych, dzięki któremu łatwiej zobaczyć i przeanalizować zależność. Diagram 4.1 przedstawia indeks Gold and Silver Mining na tle wolumenu obrotów giełdy nowojorskiej. Jak widać, nie ma tu żadnej korelacji, ponieważ punkty na wykresie nie układają się w wyraźną strukturę. Z klasycznym brakiem korelacji mamy do czynienia wówczas, gdy punkty na wykresie tworzą koło. Diagram 4.2 przedstawia indeks Dow Transportation na tle indeksu OEX (S&P 100). Tu, jak widzimy, korelacja jest bardzo silna, o czym świadczy wydłużony układ punktów gromadzących się ukośnie w kierunku prawego górnego rogu wykresu.

Drugim narzędziem dołączanym niekiedy do pakietów oprogramowania jest podprogram obliczający, jaką część zmiennej prognozowanej wyjaśniają *po* treningu poszczególne zmienne wejściowe, czyli ich *wkład*. Zazwyczaj dokonuje się tego, dodając wszystkie wagi powiązane z każdą ze zmiennych wejściowych. Zmienne wejściowe o większej sumie wag mają większe znaczenie niż zmienne wejściowe, których zsumowane wagi dają niewielką wartość.




Diagram 4.1 Wykres punktowy przedstawiający wskaźnik obrotów DJIA na tle indeksu Gold and Silver Mining. Zbiór punktów nie ma wyraźnego kształtu, tak więc możemy wnioskować, że nie istnieje zależność między porównywanymi pozycjami.




Diagram 4.2 Relacja między indeksami OEX i Dow Transportation naniesiona na wykres punktowy. Wydłużony kształt powstały z punktów figury wskazuje na zależność między dwoma przedstawionymi zmiennymi. Gdyby zależność była doskonała, otrzymalibyśmy linię prostą. Szerokość wstęgi stanowi miarę szumu i realnych różnic między indeksami.

Tabela 4.1 Korelacja zmiennych wejściowych ze zmienną wejściową sieci odniesienia oraz wkład poszczególnych zmiennych wejściowych do rozwiązania. Pełne objaśnienia znajdują się w tekście.

	Zmienna wejściowa	Korelacja	Wkład
(1)	ADV	8,2%	1,7, czyli 13%
(2)	DEC	3,2%	1,5, czyli 12%
(3)	TRIN	8,9%	1,4, czyli 11%
(4)	TICK	5,6%	1,6, czyli 13%
(5)	SPY	96,0%	3,2, czyli 25%
(6)	YXY	96,0%	3,3, czyli 26%

W tabeli 4.1 przedstawiono wyniki uzyskane po uruchomieniu podprogramów obliczających korelację i wkład (wykorzystaliśmy przykład z rozdziału trzeciego). Prognozowaliśmy rzeczywistą wartość SPY na 5 okresów naprzód.

Zmienne ADV, DEC, TRIN i TICK z racji niskiej, mniejszej niż 10 procent, korelacji nie kwalifikowałyby się normalnie jako zmienne wejściowe sieci. Jednak biorąc pod uwagę, że ich wkład równy jest w przybliżeniu połowie wkładu najlepszej zmiennej, powinno się je uwzględnić. Widzimy zatem, że wybierając zmienne wejściowe sieci neuronowej, należy użyć każdego narzędzia selekcji i przetestować każdą zmienną, która może pozostawać w logicznym związku ze zmienną prognozowaną. Diagram 4.3 ilustruje w formie wykresu słupkowego względny wkład każdej zmiennej wejściowej sieci odniesienia.

Diagram 4.4 przedstawia względny wkład tych samych zmiennych, kiedy prognozujemy procentową zmianę SPY w ciągu pięciu dni. Zwróćmy uwagę, jak względne wkłady poszczególnych zmiennych zmieniły się w porównaniu z siecią odniesienia. Wynika stąd, że zmienna wejściowa, która nie jest szczególnie dobra do prognozowania jednej zmiennej wyjściowej, może stać się najważniejsza, jeśli użyjemy jej do prognozowania zmiennej tylko niewiele się od niej różniacej.

PORĘCZENIA POŻYCZEK HIPOTECZNYCH

Chociaż problem oceny wniosków o udzielenie kredytów hipotecznych wydaje się względnie prosty, szczególnie w kwestii wyboru zmiennych wejściowych, zdefiniowanie „dobrych” i „złych” długów wymaga nie lada umiejętności. Oto niektóre zmienne, które można zastosować w sieci:

Dochód rodziny
Wydatki rodziny
Posiadanie poprzedniego domu
Czas zamieszkania pod obecnym adresem




Diagram 4.3 Wkład poszczególnych zmiennych wejściowych sieci odniesienia. Względny wkład zmiennych wejściowych sieci odniesienia, gdy prognozujemy wartość SPY na 5 okresów naprzód. Numeracja zmiennych jak w tabeli 4.1.




Diagram 4.4 Zmienne wejściowe sieci odniesienia prognozujące procentową zmianę SPY. Względny wkład zmiennych wejściowych sieci odniesienia, kiedy prognozujemy procentową zmianę SPY w ciągu 5 okresów. Porównaj diagram 4.3.

Staż pracy w obecnym miejscu zatrudnienia
 Perspektywy związane z obecnym miejscem pracy
 Raport kredytowy
 Stosunek wartości nieruchomości do kwoty pożyczki
 Stosunek dochodu do wydatków rodziny
 Stosunek kosztów utrzymania domu do dochodu
 Stosunek sumy płatności z tytułu pożyczki do dochodu
 Udział dochodów nie będących wynagrodzeniem
 Prawdopodobieństwo dalszego otrzymywania takich dochodów
 Źródło pierwszej wpłaty: oszczędności? rodzice?
 Stosunek pierwszej wpłaty do ceny zakupu
 Historia wiarygodności kredytowej
 Liczba osób pozostających na utrzymaniu
 Rodzaj zatrudnienia (własne przedsiębiorstwo, pracownik najemny)
 Osoby, które będą zamieszkiwać nieruchomość
 Kwota pożyczki
 Wiek nieruchomości
 Liczba jednostek mieszkalnych
 Szacowana wartość
 Położenie nieruchomości

Ponieważ hipoteki są zobowiązaniami długoterminowymi, a w trakcie ich spłaty może wystąpić wiele niekorzystnych okoliczności, zdefiniowanie dobrego lub złego wniosku kredytowego stanowi trudne zadanie. Jeżeli dług okaże się w końcu nieściągalny, mogą upłynąć lata, zanim dłużnik ogłosi bankructwo. Poniżej przedstawiamy kilka możliwych podejść do wyboru zmiennej wejściowej:

1. Definiując dobre i złe wnioski kredytowe, oprzyj się na opiniach jednego lub większej liczby wysoko postawionych i doświadczonych urzędników wyspecjalizowanych w tej dziedzinie.
2. W ciągu pierwszych trzech miesięcy nie ma zwykle problemów ze ściagalnością pożyczek. Bardziej prawdopodobne, że kłopoty pojawiają się w ciągu trzech do pięciu lat, dlatego też należy posługiwać się wnioskami sprzed pięciu lub nawet dziesięciu lat. Według jakich kryteriów definiujemy nieściągalną pożyczkę? Kryterium takim może być na przykład opóźnienie w spłacie jednej raty lub wniesienie zastrzeżenia w celu zabezpieczenia należności z tytułu hipoteki mającej pierwszeństwo. Przypomnijmy raz jeszcze, że ustalając kryteria definiujące nieściągalną pożyczkę, należy korzystać z porady doświadczonych urzędników.
3. Jeżeli uczymy sieć, używając wniosków sprzed pięciu lat, musimy wziąć pod uwagę, jak od tamtego czasu zmieniła się sytuacja ekonomiczna. Czy ówczesne warunki umowy, stopy procentowe i wymogi pierwszej wpłaty są porównywalne z dzisiejszymi? Czy perspektywy gospodarcze są takie same jak przed pięcioma laty?

Aby odpowiednio wyćwiczyć sieć, powinniśmy jej przedstawić taką samą liczbę danych na temat wniosków możliwych do przyjęcia (takich, które przyjąłby wysoki rangą, doświadczony urzędnik) i wniosków nie-możliwych do realizacji (które ten sam urzędnik odrzuciłby). Warto nie-co poeksperymentować i oprócz tradycyjnych trzywarstwowych sieci opartych na algorytmie wstecznej propagacji zastosować w procesie uczenia także inne rodzaje sieci: sieci Kohonena, sieci probabilistyczne (PNN) lub sieci realizujące regresję uogólnioną (GRNN). W ten sposób przekonamy się, czy możliwe jest uzyskanie lepszych współczynników determinacji, czyli bardziej dokładnych prognoz. Architektury sieci omówimy bardziej szczegółowo w rozdziale siódmym.

BANKRUCTWA BANKÓW

Przedstawione poniżej pozycje doskonale nadają się jako zmienne wejściowe do sieci prognozujących bankructwa banków i kas oszczędnościowo-pożyczkowych. Zmienne te najlepiej spełniają swoją funkcję, gdy odnosimy je, tam gdzie jest to logicznie uzasadnione, do aktywów, sumy udzielonych pożyczek i sumy depozytów. W porównaniu z surowymi zmiennymi zastosowanie wskaźników daje lepsze efekty, ponieważ otrzymujemy wówczas wartości uogólnione.

Kapitał
 Kredyty rolnicze
 Kredyty handlowe
 Kredyty osobiste
 Kredyty hipoteczne
 Kredyty przeterminowane
 Rezerwa na nieściągalne kredyty
 Koszty odsetkowe
 Zysk netto
 Aktywa ogółem
 Koszty ogółem
 Gotówka lub jej ekwiwalenty
 Kapitał własny
 Aktywa odzyskane

Wartość zmiennej prognozowanej powinna zawierać się przedziale od 0 do 1, gdzie 0 oznacza bank postawiony w stan upadłości, a 1 bank lub kasę oszczędnościowo-pożyczkową w najlepszej możliwej kondycji, której, według naszych oczekiwań, w bliższej lub nieco bardziej odległej przyszłości nie zagraża bankructwo. Ucząc sieć prognozującą bankructwa banków warto, jak zawsze, przetestować różne architektury.

Podobnie jak w przypadku oceny wniosków kredytowych, ważne jest, by dobre i upadłe banki były w takim stopniu reprezentowane w danych, dzięki czemu sieć otrzyma dostęp do takiej samej liczby przypadków obu rodzajów. Projektanci sieci wykazują skłonność do uczenia sieci za pomocą danych, które w ogromnej większości dotyczą banków znajdujących się w dobrej kondycji, ponieważ taki jest naturalny rozkład danych. Do tego dochodzi zjawisko "błędu selekcji", które sprawia, że informacje o bankach postawionych w stan upadłości są trudniejsze do zdobycia.

BANKRUCTWA PRZEDSIĘBIORSTW

Prognozowanie bankructw przedsiębiorstw bardzo przypomina prognozowanie bankructw banków. Znajdują tu zastosowanie te same uwagi odnośnie do zmiennej wyjściowej i architektury. Typowe zmienne prezentujemy w relacji do sumy aktywów, wartości sprzedaży bądź sumy zobowiązań. Wykaz możliwych do zastosowania zmiennych obejmuje między innymi takie pozycje:

- Suma aktywów
- Kapitał obrotowy
- Dochód
- Sprzedaż
- Zysk zatrzymany
- Gotówka i jej ekwiwalenty
- Zapasy
- Majątek trwały
- Zobowiązania krótkoterminowe
- Zobowiązania długoterminowe
- Aktywa krótkoterminowe
- Aktywa długoterminowe

KLASYFIKACJA OBLIGACJI

Klasyfikację obligacji, która przypomina prognozowanie bankructw banków i przedsiębiorstw, komplikuje fakt, że potrzebne są przynajmniej cztery różne kategorie. Stosujemy zmienne wejściowe podobne do tych, które wymieniliśmy przy okazji omawiania bankructw przedsiębiorstw. Część użytkowników może uznać za stosowne stworzenie kilku sieci, z których jedna będzie przyporządkowywać obligacje do jednej z czterech grup (AA, A, B i C), a pozostałe przypisywać im rangi w obrębie poszczególnych kategorii.

WYCENA NIERUCHOMOŚCI/ ANALIZA PODATKU MAJĄTKOWEGO

Zmienną wyjściową sieci stanowi cena sprzedaży. Aby pokazać jak bardzo złożony bywa ten problem, spójrzmy na niektóre zmienne, które mogą zostać użyte:

- Powierzchnia działki (w metrach kwadratowych)
- Przestrzeń mieszkalna (w metrach kwadratowych)
- Przestrzeń mieszkalna (w metrach sześciennych)
- Liczba łazienek
- Liczba pryszniców
- Liczba sypialni
- Kuchnia z jadalnią
- Wnęka „śniadaniowa”
- Pokój stołowy
- Salon
- Pokój wypoczynkowy
- Przedpokój
- Patio
- Piętro
- Dom wolnostojący
- Bliźniak
- Apartament otoczony ogrodem
- Wysoko położony apartament
- Kamienica
- Piwnica
- Wykończenie piwnicy
 - przecieki
 - pompa
- Stan dachu
- Centralnie sterowana klimatyzacja
 - gruntowa pompa ciepła
 - chłodnia kominowa
 - chłodzenie powietrzem
- Pokojowa klimatyzacja
 - liczba pokoi
 - cała przestrzeń mieszkalna
- Rodzaj ogrzewania
 - gorące powietrze
 - podłogowe
 - grzejniki
- Okna ze skrzydłami o podwójnym oszkleniu
- Garaż – na ile samochodów

Układ ogrodu
 słabo dostrzegalny
 do przyjęcia
 przyjemny dla oka
 opracowany przez architekta
 Sąsiedztwo, w skali od 1 do 10
 Porównywalne transakcje w dolarach
 Wygląd, w skali od 1 do 10
 Wyposażenie
 kuchenka
 kuchenka mikrofalowa
 lodówka
 zmywarka do naczyń
 pralka
 suszarka do ubrań
 Cechy szczególne
 owalny podjazd
 staw
 strumień
 z dala od sąsiadów
 oświetlenie zewnętrzne
 bezpieczeństwo
 ozdoby
 basen
 wejście na dach
 szafa na wierzchnie okrycia
 obszerne szafy
 szafa cedrowa
 oddzielna pralnia
 ujęcie wody w piwnicy
 zewnątrzny kran
 wybrukowana droga dojazdowa
 ogrzewanie promiennikowe
 Nawilżacz powietrza
 Osuszacz powietrza
 Rodzaj paliwa do pieca
 benzyna
 olej
 węgiel
 drewno
 propan
 Koszt ogrzewania
 Koszt chłodzenia
 Chodniki
 Kanały burzowe
 Kanały ściekowe
 Krawężniki
 Alarm przeciwwłamaniowy

Kominek
 Alarm przeciwpożarowy
 Czujniki dymu

W celu uwzględnienia inflacji należy raz na jakiś czas dodawać nowe dane i uczyć na nich sieć.

PROGNOZOWANIE SZEREGÓW CZASOWYCH

Dane wejściowe do prognozowania szeregów czasowych, czyli w naszym przypadku prognozowania kursów akcji lub wartości indeksów, można podzielić na dwie grupy. Zmienne z pierwszej grupy oparte są na czynnikach fundamentalnych. Do grupy tej zalicza się cenę złota, kursy dolara do jena, funta i marki, cenę ropy, kurs 3-miesięcznego weksla i 30-letniej obligacji skarbowej, produkt narodowy brutto (PNB), inflację, politykę rządu i inne podobne wskaźniki i wartości.

Druga grupa obejmuje *wskaźniki techniczne*, takie jak stabilność rynku, indeks względnej siły rynku (RSI), średni ruch kierunkowy (ADV), dzienne maksimum, dzienne minimum, kurs zamknięcia, wskaźnik impetu, *money flow index*, średnie kroczące, *on-balance volume*, oscylator stochastyczny, wstęgi Bollingera i podobne mierniki wyprowadzane na podstawie zachowania cen i obrotów pozycji, którą zamierzamy prognozować.

Budowa udanej sieci neuronowej tylko na podstawie wskaźników technicznych stanowi trudne zadanie (przykład takiej sieci znajduje się w studium przypadku zamieszczonym w dodatku A). Większe szanse powodzenia – pod warunkiem, że przetestujemy i zoptymalizujemy wszystkie parametry – ma budowa sieci bazującej na danych fundamentalnych. W niektórych wypadkach wyniki takiej sieci można poprawić, dodając do niej wskaźniki techniczne.

Aby zilustrować wpływ różnych wskaźników technicznych, będziemy pojedynczo dodawać je do naszej sieci odniesienia jako siódmą zmienną, a następnie obserwować rezultat na wykresie przedstawiającym wkład poszczególnych zmiennych. Ponieważ zwiększyliśmy liczbę zmiennych wejściowych z 6 do 7, o tyle samo zwiększymy liczbę neuronów w warstwie ukrytej. Dla porównania, współczynnik determinacji dla sieci odniesienia złożonej z sześciu zmiennych wejściowych wynosił 0,9262.

Diagramy 4.4–4.14 przedstawiają wkłady sześciu pierwotnych zmiennych i zmiennej siódmej opartej na wskaźniku technicznym (tabela 4.2).

Porównajmy diagram 4.4, przedstawiający 6 zmiennych wejściowych z sieci odniesienia z pozostałymi diagramami. Porównując diagramy 4.6 i 4.4 widzimy znaczną różnicę. Łatwo zauważyć, że wkład danej zmiennej zależy od obecności innych zmiennych. Zwróćmy też uwagę, że trzy sieci uzyskały gorsze współczynniki determinacji niż sieć odniesienia,

Tabela 4.2 Współczynnik determinacji dla różnych zmiennych wejściowych. Każdą z nich dołączaliśmy do sieci odniesienia jako siódmą zmienną.

Nr testu	Siódma zmienna	Współczynnik determinacji
1	5-okresowe opóźnienie SPY	0,9327
2	Różnica między 10- i 5-okresową średnią kroczącą	0,9302
3	Wskaźnik impetu	0,9302
4	Szerokość wstęgi Bollingera (w procentach)	0,9284
5	Oscylator stochastyczny	0,9283
6	10-okresowa średnia krocząca	0,9292
7	Konwergencja/dywergencja średnich kroczących	0,9278
8	10-okresowe opóźnienie SPY	0,9278
9	5-okresowa średnia krocząca	0,9240
10	12-okresowa średnia krocząca RSI	0,9169
11	12-okresowy wskaźnik względnej siły (RSI)	0,9167




Diagram 4.5 Pierwszy z serii wykresów przedstawiających rezultat dodania różnych wskaźników technicznych do sieci odniesienia. We wszystkich przypadkach siódma kolumna reprezentuje dodany wskaźnik. Pozostałe sześć zmiennych pochodzi z sieci odniesienia. Podane są wartości współczynnika determinacji dla każdej sieci. Współczynnik determinacji dla sieci odniesienia wynosi 0,9262. W tym przypadku siódmą zmienną wejściową jest 5-okresowe opóźnienie SPY. Współczynnik determinacji równa się 0,9327.




Diagram 4.6 5-okresową średnią kroczącą SPY odjęliśmy od analogicznej średniej 10-okresowej, a różnica posłużyła za siódmą zmienną. Współczynnik determinacji wynosi 0,9302.




Diagram 4.7 Sieć odniesienia poszerzona o wskaźnik impetu. Za siódmą zmienną posłużył 12-okresowy wskaźnik impetu SPY. Współczynnik determinacji wynosi 0,9302. Zauważmy, że względny wkład drugiej i trzeciej zmiennej ulega znacznym zmianom (porównaj diagramy 4.5 i 4.6).




Diagram 4.8 Sieć odniesienia poszerzona o 14-okresowy oscylator stochastyczny. Siódmą zmienną wejściową jest 14-okresowy oscylator stochastyczny wygładzony 3-okresową średnią kroczącą. Współczynnik determinacji równa się 0,9283.




Diagram 4.9 Sieć odniesienia poszerzona o 10-dniową średnią kroczącą SPY. Siódmą zmienną wejściową stanowi 10-okresowa średnia krocząca SPY. Współczynnik determinacji wynosi 0,9292. Porównajmy względne wkłady przedstawionych dotychczas siódmych zmiennych – trudno sobie wyobrazić większe rozbieżności. Jednak różnice we współczynnikach determinacji pojawiają się dopiero na drugim miejscu po przecinku. Zwróćmy też uwagę na różnice między trzecią i piątą zmienną.




Diagram 4.10 Sieć odniesienia poszerzona o MACD. Siódmą zmienną wejściową jest wskaźnik konwergencji/dywergencji średnich kroczących (MACD). Zwróćmy uwagę na różnice względnych wkładów w porównaniu z poprzednim wykresem (diagram 4.9). Współczynnik determinacji równy jest 0,9278.




Diagram 4.11 Tak przedstawia się sieć odniesienia, kiedy siódmą zmienną jest 10-okresowe opóźnienie SPY. Współczynnik determinacji wynosi 0,9278.




Diagram 4.12 Siódmą zmienną jest 5-okresowa średnia krocząca SPY. Współczynnik determinacji wynosi 0,9240.




Diagram 4.13 Tu siódmą zmienną stanowi 12-okresowa średnia krocząca 12-okresowego indeksu względnej siły rynku (RSI). Współczynnik determinacji wynosi zaledwie 0,9169.




Diagram 4.14 Sieć odniesienia poszerzona o 12-okresowy RSI. Siódmą zmienną jest 12-okresowy indeks względnej siły rynku (RSI), a współczynnik determinacji wynosi 0,9167. Porównajmy względne wkłady z tego diagramu z niektórymi wcześniejszymi diagramami. Zwróćmy uwagę, jak względne wkłady poszczególnych zmiennych różnią się w zależności od zastosowanej dodatkowej zmiennej. Jak widać, wartość każdej zmiennej wejściowej uzależniona jest od wyboru pozostałych.

co wskazuje na fakt, iż dodanie pewnych zmiennych w rzeczywistości obniża skuteczność systemu. Przyjmuje się za aksjomat, że dodawanie zmiennych jest dopuszczalne, ponieważ sieć sama nauczy się pomijać te, które nic nie wnoszą do rozwiązania, tak więc zmienne, które obniżyły skuteczność sieci, pozostawały w zależności liniowej z jedną z pozostałych zmiennych.

Raz jeszcze widzimy, że aby stworzyć optymalną sieć, należy uważnie wybrać zmienne wejściowe, a następnie je przetestować w celu ustalenia najlepszej kombinacji. Logiczny, inteligentny wybór zmiennych jest podstawowym warunkiem uzyskania miarodajnego rozwiązania.

Rozdział piąty

Przygotowanie danych

Rozdział ten wypełnia lukę między wyborem zmiennych wejściowych a uczeniem sieci. Pokażemy w nim, jak importować dane wejściowe do arkusza kalkulacyjnego oraz przedstawimy różne sposoby modyfikacji danych mające na celu poprawę ostatecznych wyników sieci.

ARKUSZE KALKULACYJNE

Dane wejściowe i wyjściowe prezentujemy sieci w formie arkusza kalkulacyjnego. Kolumny reprezentują zmienne wejściowe takie jak kurs złota, srebra, wartość S&P 500 czy cena kukurydzy. W wierszach znajdują się dane dotyczące poszczególnych okresów, czyli wartości dla każdego kwartału, miesiąca, dnia, czy godziny.

Diagram 5.1 przedstawia pierwsze 50 wierszy arkusza kalkulacyjnego dla sieci odniesienia. Zauważmy, że w kolumnie o nazwie „SPY przed 5 okresami” wiersze 2–6 nie zawierają danych. Wynika to stąd, że opóźnienia tworzymy, przesuwając dane w dół o liczbę wierszy potrzebną do

wykonania obliczeń lub nawiązania do wcześniejszych danych. Użyty program do modelowania sieci neuronowych komunikuje sieci za pomocą gwiazdki, że powinna pominąć te wiersze. Zastosowanie części programów wiąże się z koniecznością usunięcia niekompletnych wierszy. Wiersze takie powstają także wówczas, gdy wykorzystujemy średnie kroczące. Jeżeli stworzymy 10-dniową średnią kroczącą, pierwsze 9 wierszy danych będą niekompletne i trzeba będzie podjąć odpowiednie działania, by sieć nie korzystała z nich.

W podobny sposób tworzymy prognozowaną pozycję. Różnica polega tylko na tym, że teraz dane przenosimy 5 wierszy w górę, ponieważ prognoza sporządzana jest z 5-dniowym wyprzedzeniem. W efekcie na samym dole pojawia się 5 niepełnych wierszy, które również należy odpowiednio zabezpieczyć, by sieć nie miała do nich dostępu.

Tworzenie arkusza kalkulacyjnego

Aby skonstruować arkusz kalkulacyjny, musimy najpierw zebrać dane. W tym celu łączymy się zazwyczaj za pomocą modemu z dostawcą danych (jak Dow Jones lub Dial Data) i ściągamy interesujący nas materiał informacyjny (na przykład dane na temat ceny złota w okresie od 1 marca 1990 roku do chwili obecnej). Dane zapisywane są w pliku. Jeżeli potrzebujemy również danych na temat ceny srebra, to znajdziemy i ściągniemy je w postaci osobnego pliku. Kolejny plik będzie nam potrzebny, jeśli zmienną wejściową będzie cena kukurydzy. Niekiedy dostawca nie dysponuje potrzebnymi danymi i musimy wprowadzić je do komputera ręcznie. Bywa to bardzo pracochłonne, choć fakt ten może równie dobrze oznaczać, że dysponujemy cennym materiałem informacyjnym.

Dane często otrzymujemy z programu do analizy technicznej (na przykład pakietu MetaStock), stosując opcję EXPORT; w ten sposób skracamy proces gromadzenia danych. Wyeksportowane dane mają z reguły postać pliku tekstowego i nie są podzielone na kolumny. Plik tekstowy można przekonwertować na użyteczny plik danych za pomocą funkcji PARSE, rozbijającej dane na kolumny, która znajduje się w arkuszu kalkulacyjnym. Działa ona nad wyraz dobrze i jest w stanie rozróżnić między danymi liczbowymi, datami i informacjami tekstowymi. Jednak daty nie będą zapisane w zwykłym formacie dzień-miesiąc-rok, lecz jako kolejny dzień stulecia, czyli w formacie pokazującym, ile dni upłynęło od 1 stycznia 1900 roku.

Po zebraniu plików zawierających dane wejściowe, za pomocą funkcji FILE COMBINE arkusza kalkulacyjnego umieszczamy je w sąsiadujących ze sobą kolumnach.

Bardzo ważne jest, by danym liczbowym towarzyszyły daty. Kiedy wszystkie pliki zostaną połączone w jeden wielki arkusz kalkulacyjny,

	A	B	C	D	E	F	G	H
	ADV	DEC	TICK	TRIN	SPY	YXY	Lead(5) of SPY	Lag(5) of SPY
1								
2	994.00	540.00	426.00	0.86	450.23	249.42	450.50	
3	1070.00	625.00	88.00	0.79	450.28	249.41	450.08	
4	1144.00	663.00	248.00	0.81	451.00	249.71	448.64	
5	1122.00	687.00	153.00	0.95	450.70	249.58	448.23	
6	1201.00	703.00	252.00	1.06	450.65	249.57	448.04	
7	1213.00	740.00	112.00	0.88	450.50	249.49	447.94	450.23
8	1214.00	781.00	31.00	0.91	450.08	249.26	448.41	450.28
9	668.00	809.00	-39.00	0.91	448.64	248.69	448.66	451.00
10	729.00	924.00	-12.00	0.91	448.23	248.50	448.22	450.70
11	777.00	965.00	12.00	1.01	448.04	248.44	448.38	450.65
12	790.00	1012.00	-2.00	1.02	447.94	248.31	447.29	450.50
13	838.00	1048.00	28.00	0.98	448.41	248.52	447.57	450.08
14	892.00	1008.00	85.00	0.98	448.66	248.70	447.55	448.64
15	938.00	1002.00	109.00	0.97	449.22	248.83	446.92	448.23
16	688.00	764.00	-74.00	1.31	448.38	248.62	446.55	448.04
17	718.00	919.00	-125.00	1.52	447.29	248.10	445.75	447.94
18	774.00	961.00	38.00	1.45	447.57	248.20	446.30	448.41
19	807.00	976.00	-36.00	1.52	447.55	248.21	445.31	448.66
20	804.00	1043.00	-94.00	1.60	446.92	247.90	445.34	449.22
21	812.00	1071.00	84.00	1.71	446.55	247.76	445.18	448.38
22	904.00	1005.00	115.00	1.80	445.75	247.42	445.70	447.29
23	724.00	763.00	40.00	1.00	446.30	247.59	445.85	447.57
24	724.00	926.00	-110.00	1.08	445.31	247.15	446.02	447.55
25	760.00	989.00	-32.00	0.96	445.34	247.11	444.22	446.92
26	786.00	1038.00	-153.00	0.97	445.18	246.99	445.79	446.55
27	809.00	1046.00	61.00	0.98	445.70	247.20	446.75	445.75
28	834.00	1070.00	-63.00	0.93	445.85	247.23	447.49	446.30
29	855.00	1060.00	-10.00	0.90	446.02	247.32	447.08	445.31
30	544.00	985.00	-235.00	0.90	444.22	246.41	447.08	445.34
31	675.00	1031.00	0.00	0.78	445.79	247.04	447.31	445.18
32	722.00	1010.00	104.00	0.69	446.75	247.47	446.14	445.70
33	777.00	1025.00	28.00	0.70	447.49	247.78	446.48	445.85
34	821.00	1049.00	7.00	0.71	447.08	247.58	446.26	446.02
35	830.00	1075.00	-54.00	0.68	447.08	247.57	446.46	444.22
36	871.00	1056.00	88.00	0.71	447.31	247.69	446.23	445.79
37	648.00	831.00	-119.00	1.03	446.14	247.20	446.39	446.75
38	729.00	923.00	-31.00	0.97	446.48	247.34	447.18	447.49
39	740.00	995.00	-80.00	0.96	446.26	247.24	446.44	447.08
40	787.00	1044.00	-91.00	0.88	446.46	247.29	447.00	447.08
41	802.00	1085.00	-182.00	0.93	446.23	247.16	446.76	447.31
42	842.00	1078.00	-103.00	0.91	446.39	247.22	446.52	446.14
43	903.00	1054.00	40.00	0.86	447.18	247.61	446.20	446.48
44	672.00	808.00	-45.00	0.90	446.44	247.27	444.11	446.26
45	750.00	878.00	8.00	0.79	447.00	247.53	444.51	446.46
46	813.00	918.00	-114.00	0.92	446.76	247.37	446.58	446.23
47	811.00	974.00	-171.00	0.92	446.52	247.26	445.79	446.39
48	820.00	1035.00	-165.00	0.99	446.20	247.08	445.26	447.18
49	757.00	1199.00	-535.00	1.19	444.11	246.12	445.27	446.44
50	770.00	1207.00	-265.00	1.17	444.51	246.17	446.21	447.00

Diagram 5.1 Niewielki wycinek typowego arkusza kalkulacyjnego z danymi dla sieci neuronowej.

dane badamy linia po linii, by upewnić się, że wszystkie daty i godziny pokrywają się ze sobą. Każdy rynek ma indywidualny rozkład sesji, tak więc nie otrzymamy kompletnych danych na temat wszystkich okresów. Dni, w których nie odbywa się obrót, są na przykład na japońskich giełdach inne niż na ich amerykańskich odpowiednikach i musimy sobie jakoś z tym poradzić. Zwykle postępuje się w ten sposób, że w puste miejsce kopiuje się dane z ostatniego wiersza przed luką; inną popularną metodą jest uśrednienie danych po obu stronach przerwy. Część architektur sieci neuronowych wymaga prezentowania pełnych wierszy danych, stąd też szacowanie danych stanowi znacznie lepsze rozwiązanie niż usunięcie całego wiersza, które prowadzi do powstania sztucznej luki i utraty informacji.

WSTĘPNE PRZETWORZENIE DANYCH

Po wczytaniu pliku do arkusza kalkulacyjnego, rozbiciu danych tekstowych na kolumny i sprawdzeniu ich poprawności przystępujemy do wstępnego przetworzenia zebranego materiału informacyjnego. Możemy tego dokonać za pomocą zwykłego arkusza, lub też wprowadzić dane do arkusza kalkulacyjnego zawartego w pakiecie oprogramowania modelującego sieci neuronowe i dopiero tam poddać je obróbce. Część pakietów potrafi korzystać z danych tradycyjnego arkusza, inne zaś zawierają specjalne arkusze kalkulacyjne, bądź też posiadają opcje pozwalające importować dane z arkusza zewnętrznego. Jeżeli konkretny pakiet do modelowania sieci neuronowych nie zawiera programu do analizy technicznej i niemożliwy jest import wskaźników technicznych z takiego programu, odpowiednie formuły trzeba samodzielnie wpisywać do arkusza kalkulacyjnego.

W rozdziale trzecim pokazaliśmy, że skuteczność sieci z reguły poprawia się, kiedy zamiast *wartości absolutnych* stosujemy *zmiany wartości zmiennych wejściowych*. Podobnie prognozy znacznie zyskują na dokładności, gdy zmienne wejściowe wyrażone są raczej w postaci *zmian* niż *wartości absolutnych*. Ten typ modyfikacji zmiennych wejściowych określa się mianem *wstępnego przetwarzania*. Wstępne przetwarzanie danych znacznie wpływa na rezultaty sieci. Bywa, że to właśnie ono decyduje, czy sieć jest dobra, czy zła.

A oto kilka korzyści związanych ze wstępnym przetwarzaniem danych:

1. *Pozwala wydobyć informacje, które mają rzeczywistą wartość dla sieci*
Na przykład prezentując sieci zmianę wartości zamiast wartości absolutnej, zwiększamy jej zdolności prognostyczne. Dzięki temu sieć jest w stanie opracować lepszą prognozę. Kiedy stosujemy wartości absolutne, znaczenie dla sieci ma jedynie ułamek wartości liczbowych.

2. *Dwie zmienne można sprowadzić do jednej, mającej dla sieci większą wartość niż dwie zmienne pierwotne*
Na przykład, współczynnik powstały po podzieleniu liczby emisji ulegających aprecjacji przez liczbę emisji ulegających deprecjacji może dostarczyć sieci więcej informacji niż dwie składające się na niego oddzielne zmienne wejściowe. Proces ten często prowadzi do uogólnienia danych, a dodatkowo udaje nam się zredukować dwie zmienne do jednej. Ponieważ liczba zmiennych wejściowych ma raczej tendencję do zwiększania się niż do zmniejszania, powinno się wykorzystywać każdą możliwość połączenia dwóch zmiennych, albowiem skraca to czas przetwarzania.

Możliwych metod wstępnego przetwarzania danych jest wiele: rozciąganie, odejmowanie, dzielenie, obliczanie średnich kroczących, mnożenie i dodawanie. Istnieją też liczne zmienne techniczne, które można wykorzystać jako zmienne wejściowe.

ROZCIĄGANIE ZMIENNYCH WEJŚCIOWYCH – OPÓŹNIENIA

Termin *rozciąganie* zmiennych wejściowych oznacza prezentację danych z poprzednich okresów. Na przykład, jeżeli prognozujemy cenę złota na pięć dni naprzód, możemy wykorzystać następujące zmienne rozciągnięte:

Obecna cena złota
Cena sprzed 5 dni
Cena sprzed 10 dni
Cena sprzed 15 dni
Cena sprzed 20 dni

Diagram 5.2 przedstawia rezultat dodania 5-okresowego opóźnienia do każdej z 6 zmiennych wejściowej sieci odniesienia. Innymi słowy, na dane sieci składa się teraz 6 pierwotnych zmiennych wejściowych oraz ich wartości sprzed 5 okresów. Zauważmy, że zmienne opóźnione (oznaczone liczbami od 7 do 12) dostarczają sieci niemal tyle informacji, co pierwsze 6 zmiennych.

ŚREDNIE KROCZĄCE

Przydatną techniką wstępnego przetwarzania danych jest obliczanie średnich kroczących. Surowe dane często zastępuje się krótkoterminowymi 2-, 3-, 4- lub 5-okresowymi średnimi kroczącymi, ponieważ wygładzają one „szum”, czyli losowe wahania danych. Z drugiej strony, dłuższe średnie kroczące mogą symulować fundamentalny trend. Diagram 5.3 przedstawia




Diagram 5.2 Rezultat rozszerzenia sieci odniesienia o zmienne opóźnione. Wykres wkładu przedstawia efekt dodania 5-okresowych zmiennych opóźnionych do zmiennych pierwotnych (1–6). Zwróćmy uwagę, że zmienne opóźnione (7–12) wnoszą do rozwiązania prawie tyle samo, co zmienne pierwotne. Zmienna 7 jest opóźnioną wersją zmiennej 1 i tak dalej.

Wykres wkładu

Wykresy wkładu pokazują, ile każda ze zmiennych wnosi do rozwiązania sieci. Wkłady oblicza się, sumując wagi (wskaźniki siły powiązań) połączone z daną zmienną. Wartość większa niż 5 wskazuje na bardzo dużą, a mniejsza od 2 na małą siłę powiązań. Wykresy te znajdują szerokie zastosowanie w procesie oceny zmiennych wejściowych, jak również podczas porównywania rezultatów wstępnego przetwarzania danych. Stanowią one potężne narzędzie, ponieważ umożliwiają znacznie bardziej wnikliwe, w porównaniu z intuicją, przetestowanie koncepcji. Ułatwiają również rozpoznanie zmiennych wejściowych pozostających ze sobą w zależności liniowej (skorelowanych), czyli zmiennych bardzo do siebie podobnych, choć nie identycznych. Na przykład indeks Dow Jones Industrial Average pozostaje w zależności liniowej z indeksem S&P 500, ten ostatni zaś z indeksem OEX. Stosowanie takich zmiennych bardziej niż jakiegokolwiek inny błąd szkodzi sieciom tworzonym przez początkujących, albowiem nie są one w stanie zdecydować, która ze skorelowanych zmiennych jest zmienną właściwą.




Diagram 5.3 Rezultat dołączenia średnich kroczących. Wykres przedstawia wkłady zmiennych pierwotnych (1–6) i średnich kroczących SPY (7–9). Zastosowano średnie 4-, 9- i 18-okresowe. Jak widać, średnie kroczące wnoszą do rozwiązania tyle samo, ile zmienne pierwotne.

wkład 4-, 9- i 18-okresowych średnich kroczących, gdy dołączymy je do sieci odniesienia. Zauważmy, że średnia 18-okresowa wnosi do rozwiązania tyle samo, co SPY.

Inny przykład pokazujący rezultat wprowadzenia średnich kroczących stanowi studium przypadku zamieszczone w dodatku na końcu książki. Do sieci odniesienia dołączyliśmy 12-okresowe średnie kroczące wyznaczone na bazie 6 pierwotnych zmiennych wejściowych, co zaowocowało znaczną poprawą końcowych wyników sieci. Celem ustalenia, która ze średnich kroczących będzie miała największy wpływ na dokładność systemu odniesienia, przebadaliśmy sieć złożoną z 12 zmiennych wejściowych – 6 zmiennych początkowych i 6 średnich kroczących tych zmiennych. W pierwszym teście posłużyliśmy się średnią 1-okresową (czyli danymi pierwotnymi), w drugim 2-okresową, potem kolejno 3-, 4-, 5-, 8-, 10-, 12- i 15-okresową. Wyniki tych testów ilustruje diagram 5.4. Widzimy wyraźnie, że najlepsza okazała się średnia 12-okresowa.

W innym teście mającym sprawdzić skutki zastosowania średnich kroczących każdą z 6 zmiennych wejściowych systemu odniesienia wygładziliśmy za pomocą 15-dniowej średniej kroczącej i użyliśmy ich zamiast zmiennych pierwotnych. Wkłady wszystkich nowo utworzonych zmiennych przedstawia diagram 5.5. Zwróćmy uwagę, że zmienną najwięcej wnoszącą do rozwiązania stała się 15-okresowa średnia krocząca TICK. Kiedy korzystaliśmy z surowych danych (diagram 4.2), zmienna TICK plasowała się na trzeciej pozycji, a jej wkład stanowił około połowę wkładu zmiennych SPY i YXY.




Diagram 5.4 Ustalanie optymalnej średniej kroczącej. Wpływ wprowadzenia różnych średnich kroczących do sieci opisanej w dodatku na końcu książki. Nagły przeskok między średnią 8- i 10-okresową nie jest wynikiem błędu. Dane zostały przetestowane kilka razy, co pozwala nam sądzić, że nieciągłość ta jest faktem.




Diagram 5.5 Rezultat wygładzenia zmiennych wejściowych. Zmienne z systemu odniesienia wygładzone za pomocą 15-okresowej średniej kroczącej. Porównaj diagram 4.2 przedstawiający zmienne niewygładzone.



Diagram 5.6 Dane niewygładzone użyte w sieci odniesienia (zmienna SPY). Porównaj diagram 5.7 przedstawiający 50-dniową średnią krocząca.

RÓŻNICE

Inną metodą wstępnego przetwarzania danych jest zastosowanie różnic. Możemy na przykład odjąć wartość dzisiejszą od wartości sprzed 5, 10, 15 i 20 okresów. Różnice można również rozpatrywać jako odpowiednik technicznego wskaźnika określanego mianem *impetu*.

NORMALIZACJA DANYCH

Doskonałym sposobem normalizacji danych jest odjęcie wartości obecnej (lub wartości sprzed n okresów) od aktualnej wartości średniej kroczącej. Diagram 5.6 przedstawia wartości SPY zastosowane w sieci odniesienia, a diagram 5.7 wyznaczoną na ich podstawie 50-dniową średnią krocząca. Wartości otrzymane po odjęciu tej średniej od pierwotnych danych przedstawia diagram 5.8.

Dane można również poddać normalizacji, obliczając relację ceny do indeksu, absolutną lub procentową zmianę ceny, bądź też iloraz dwóch zmiennych, o czym napiszemy szerzej w kolejnym podrozdziale.




Diagram 5.7 Dane sieci odniesienia wygładzone za pomocą 50-dniowej średniej kroczącej. Porównaj wykres przedstawiający dane niewygładzone (diagram 5.6).




Diagram 5.8 Rezultat usunięcia długoterminowego trendu. Od początkowych danych (diagram 5.6) odjęliśmy 50-dniową średnią krocząca (diagram 5.7). Technika ta eliminuje trend długookresowy, uwypuklając wahania krótkoterminowe.




Diagram 5.9 Rezultat zmniejszenia liczby zmiennych wejściowych metodą wprowadzenia współczynnika. Zmienne ADV i DEC zamieniliśmy na iloraz A/D. Zmiennymi wejściowymi są teraz TICK, SPY, YXY i A/D. Porównaj diagram 5.11.

WSPÓŁCZYNNIKI

Często zdarza się, że sieci łatwiej posłużyć się ilorazem dwóch zmiennych wejściowych niż tymi samymi zmiennymi występującymi indywidualnie. Dodatkową zaletą wprowadzenia takiego ilorazu jest to, że z dwóch zmiennych tworzymy jedną. Aby pokazać, jak to działa, z sieci odniesienia usunęliśmy zmienne wejściowe ADV i DEC i zastąpiliśmy je współczynnikiem A/D. Sieć składa się teraz z następujących zmiennych wejściowych: 1-TICK, 2-TRIN, 3-SPY, 4-YXY i 5-A/D. Wkład nowo utworzonej zmiennej A/D przedstawia diagram 5.9, natomiast diagram 5.10 pokazuje wkłady poszczególnych zmiennych z systemu odniesienia.

ZDANIA WARUNKOWE

W skład niektórych programów modelujących sieci neuronowe wchodzi moduł o nazwie *If-Then-Else*. Dodaje on do arkusza kalkulacyjnego kolumnę i generuje wartości na podstawie zdania warunkowego. Na przykład:




Diagram 5.10 Wkłady zmiennych ADV, DEC, TICK, TRIN, SPY i YXY przedstawione dla porównania z diagramem 5.11.




Diagram 5.11 Rezultat dołączenia zdań warunkowych jako zmiennych wejściowych (zmienne 7 i 8). Zwróćmy uwagę, jak zmniejszyły się wkłady pierwszych czterech zmiennych. Porównaj diagram 5.10.

Jeżeli (IF) 4-okresowa średnia krocząca SPY jest równa lub większa od 18-okresowej średniej kroczącej SPY, to (THEN) wartość kolumny wynosi 1, w przeciwnym razie (ELSE) wynosi ona 0.

Diagram 5.11 przedstawia wkłady do sieci odniesienia dwóch zdań warunkowych. Pierwsze z nich przedstawiliśmy wyżej, drugie różni się od niego tylko pierwszą średnią krocząca, która jest 9-okresowa.

Rozdział szósty

Inne sposoby manipulowania danymi

Rozdział ten mógłby równie dobrze nosić tytuł „Techniki handlu” lub „Sekrety kuchni”. Dotyczy on zjawisk fundamentalnych, takich jak sezonowość, które można wykorzystać w celu zaprojektowania lepszej sieci. Powtarzające się regularnie wydarzenia lub czynniki sezonowe mogą wpływać na kursy akcji, tworząc wzorce. W rozdziale tym ukażemy, jak wykorzystywać te czynniki i jak uwzględniać w prognozach wydarzenia będące dziełem człowieka.

SEZONOWOŚĆ

Niektóre rynki akcji i towarów ulegają bardzo silnym wahaniom sezonowym. Informację taką można przekazać sieci, wprowadzając do arkusza kalkulacyjnego kolumnę „sezonowość”. W porach roku, w których ceny nie ulegają znacznym wahaniom (dla rynku kukurydzy będzie to na przykład środek zimy), do kolumny wpisujemy zero. Latem, kiedy ceny gwałtownie się zmieniają na wieść o opadach lub wskutek pogłosek o suszy,

w kolumnie umieszczamy wartość 1. W ten sposób sieć otrzymuje informację, czy w danym okresie ma się spodziewać dużych, czy też małych wahań.

IDENTYFIKACJA DNI I MIESIĘCY

Projektując sieć prognozującą liczbę kasjerów potrzebnych każdego dnia, musimy postarać się o to, by mogła rozróżniać między różnymi dniami tygodnia. Z reguły najmniejszy ruch w bankach jest we wtorek, natomiast największy w piątek. W pozostałych dniach aktywność rozkłada się różnie, w zależności od regionu.

Jednym ze sposobów uwzględnienia tego aspektu jest wprowadzenie kolumn dla każdego dnia tygodnia. Dniom, w których ruch jest największy, można przypisać wartość 1, a dniom, w których jest on niewielki, zero. W ten sposób sieć będzie w stanie rozpoznać, z jakim dniem tygodnia ma do czynienia.

Innym sposobem zakomunikowania sieci działania czynnika sezonowego jest stworzenie kolumn reprezentujących miesiące lub pory roku, a następnie oznaczenie danych etykietami pokazującymi sieci, jakiego miesiąca lub pory roku dotyczy. Część programów modelujących sieci neuronowe zawiera moduły ułatwiające wykonanie tego zadania.

WARTOŚCI MINIMALNE I MAKSYMALNE

Większość programów pozwala w jakiś sposób ocenić i ustalić maksymalne oraz minimalne wartości danych wejściowych i wyjściowych. Jeżeli w rozważanym okresie dane wahają się w granicach od 390 do 460, sensownie jest ograniczyć ich zakres do tego właśnie przedziału, a nie na przykład przedziału od 0 do 460 czy 0 do 1000. Kiedy stosujemy dokładne wartości maksymalne i minimalne, sieć jest w 100 procentach dostosowana do zakresu danych. Gdybyśmy podali przedział od 0 do 460, rzeczywiste dane reprezentowałyby jedynie 18 procent, a w przypadku przedziału od 0 do 1000 tylko 5 procent oznaczonego zakresu. Większość programów modelujących sieci neuronowe automatycznie ustala wartości maksymalne i minimalne zmiennych wejściowych. Ograniczenie dopuszczalnego przedziału do wartości rzeczywistych zwiększa wrażliwość sieci na zmiany wartości. Kiedy szerokość przedziału wynosi 1000 punktów, zmiana o 1 punkt reprezentuje zmianę o 0,1 procent. Kiedy rozpiętość przedziału wynosi 70 punktów, zmiana taka to 1,4 procent, tak więc różnica jest 14-krotna.




Diagram 6.1 Wartość oddalona w przypadku, gdy większość danych zawiera się w przedziale od 0 do 1. Wartość oddalona wynosi 3 i występuje w czasie T.

Źródło: Ward Systems Group.

WARTOŚCI ODDALONE

Wartość oddalona to wartość, która wykracza poza zwykły zakres danych (patrz diagram 6.1). Patrząc na diagram widzimy, że większość danych mieści się w przedziale od 0 do 1, a tylko w jednym przypadku, w czasie T, wartość zmiennej wynosi 3. Wartość tę należy uznać za oddaloną, ponieważ jest ona 3 razy większa od pozostałych wartości. Diagram 6.2 przedstawia dane na temat SPY wykorzystane w sieci odniesienia. Mamy trzy potencjalne wartości oddalone dla okresów o numerach 27, 46 i 265. Diagram 6.3 to powiększony wycinek diagramu 6.2 obejmujący pierwsze 56 okresów, na którym można wyraźniej zaobserwować wartości oddalone dla okresów 27 i 46.

Istnienie wartości oddalonych uzależnione jest od położenia wartości minimalnych i maksymalnych. Kiedy zawężamy przedział danych, część wartości oddalonych automatycznie ulega eliminacji, w wyniku czego zwiększa się prędkość przetwarzania i zmienia się rozwiązanie wygenerowane przez sieć.

PRZYKŁADY MANIPULOWANIA WARTOŚCIAMI MAKSYMALNYMI I MINIMALNYMI

Aby zilustrować wpływ ustawień wartości maksymalnych i minimalnych, sieć poddaliśmy treningowi, stosując różne ich konfiguracje, przedstawiliśmy nowe dane, a następnie zaznaczyliśmy na wykresach błąd prognozy. Diagram 6.4 przedstawia krzywą błędów, gdy ustawienia wartości




Diagram 6.2 Wartości oddalone w szeregu danych sieci odniesienia. Potencjalne wartości oddalone (zaznaczone kółkiem) występują dla okresów oznaczonych numerami 27, 46 i 265.



Diagram 6.3 Szczegółowy wykres przedstawiający okresy od 1 do 56. Zwróćmy uwagę na potencjalne wartości oddalone (okresy 27 i 46).




Diagram 6.4 Krzywa błędów dla systemu odniesienia, gdy ustawienia wartości maksymalnych i minimalnych odpowiadają wartościom rzeczywistym.

maksymalnych i minimalnych pokrywają się z wartościami rzeczywistymi, a weryfikacja została przeprowadzona na bazie wyodrębnionych wcześniej danych testowych. Zwróćmy uwagę, że błąd nie przekracza $\pm 2,5$, a oś krzywej mniej więcej odpowiada osi poziomej układu współrzędnych.

Diagramy 6.5 i 6.6 przedstawiają rezultat zwiększenia i zmniejszenia wartości maksymalnych i minimalnych o 40 procent. Zwiększając przedział, otrzymaliśmy krzywą prawie identyczną z krzywą uzyskaną na bazie wartości maksymalnych i minimalnych pokrywających się z wartościami rzeczywistymi (diagram 6.5).

Diagram 6.6 przedstawia rezultat zmniejszenia wartości maksymalnych i minimalnych o 40 procent. W tym przypadku błąd wzrósł do ± 3 , a krzywa przestała układać się symetrycznie względem osi poziomej układu współrzędnych.

Oprócz ręcznego i automatycznego ustalania wartości minimalnych i maksymalnych oraz ich zwiększania lub zmniejszania o zadany procent, część programów oferuje możliwość ustalania tych wartości jako wielokrotności *odchylenia standardowego* po obu stronach średniej. *Odchylenie standardowe* to termin statystyczny opisujący rozkład danych względem średniej wartości. Niskie odchylenie standardowe wskazuje na koncentrację danych w okolicach średniej. Na przykład w obrębie jednego odchylenia standardowego zgrupowanych jest 68 procent wszystkich danych, 95 procent danych mieści się w przedziale od -2 do $+2$ odchylenia standardowych, a 99 procent w przedziale od -3 do $+3$ odchylenia standardowych. W celu sprawdzenia rezultatu zastosowania tej metody ustalania wartości maksymalnych i minimalnych wybraliśmy przedział



Diagram 6.5 Rezultat zwiększenia wartości maksymalnych i minimalnych o 40 procent względem wartości rzeczywistych.




Diagram 6.6 Rezultat zmniejszenia wartości maksymalnych i minimalnych o 40 procent względem wartości rzeczywistych. Porównaj diagram 6.4.




Diagram 6.7 Krzywa błędu powstała po ustaleniu wartości minimalnych i maksymalnych na 2 odchylenia standardowe od średniej.

o szerokości 2 odchylenia standardowych obejmujący 95 procent danych i powtórzyliśmy test, którego wyniki przedstawia diagram 6.7. Są one najgorsze z dotychczas uzyskanych – wartość błędu sięga $\pm 3,5$, a wykres nie jest symetryczny względem osi poziomej układu współrzędnych.

Reasumując, można bezpiecznie postawić tezę, że dla rozpatrywanych danych i sieci najlepsze wyniki daje ustalenie wartości maksymalnych i minimalnych zgodnie z wartościami rzeczywistymi. W wielu przypadkach, jeżeli chcemy stworzyć najlepszą możliwą sieć, konieczne jest ręczne ustawienie zakresu na mniej niż 100 procent lub wielokrotność odchylenia standardowego w celu wyeliminowania wartości oddalonych. W celu ustalenia optymalnego przedziału danych należy przeprowadzić testy podobne do tu przedstawionych. Gdy przedział jest zbyt szeroki, czułość sieci zmniejsza się, a wartości oddalone wprowadzają ją w błąd. Kiedy z kolei jest on zbyt wąski, eliminacji ulegają dane, które mogą być cenne dla sieci.

WYODRĘBNIE TESTOWEGO ZBIORU DANYCH

Powszechną praktyką jest odkładanie przed treningiem części zbioru danych w celu późniejszego przetestowania sieci za pomocą materiału informacyjnego, z którym nie miała dotąd kontaktu. Proces ten określa się mianem testowania na podstawie danych spoza próby (*out-of-sample testing*). Najbardziej popularną metodą tworzenia zbioru testowego jest wybór co dziesiątej próbki lub wiersza i usunięcie ich ze zbioru uczącego. Inne metody polegają na wylosowaniu 10 procent próbek lub po prostu zapisaniu ostatnich 10 procent pliku (najnowszych danych). Każde podejście poparte jest przekonującymi argumentami. Część autorów zaleca nawet stworzenie dwóch zbiorów testowych, by można było dokonać porównania.

Konstruując system odniesienia służący do celów ilustracyjnych, do zbioru testowego przeznaczyliśmy co dziesiątą próbkę. Podejście takie wybraliśmy dlatego, że chcieliśmy, by sieć była testowana za pomocą tych samych danych, co umożliwia porównania różnych sieci odniesienia. W normalnych warunkach, gdy nie trzeba dokonywać porównań, autor preferuje testowanie sieci przy wykorzystaniu 10 procent danych wyodrębnionych drogą losową.

JAKA LICZBA DANYCH JEST WYSTARCZAJĄCA?

W większości książek i artykułów wyraża się pogląd, że na każdą zmienną wejściową powinno przypadać 10 wierszy danych (niekiedy określanych mianem *próbek* lub *faktów*). System odniesienia zawiera jedynie 6 zmiennych wejściowych, tak więc jeśli owa szeroko rozpowszechniona w literaturze zasada jest prawdziwa, rozszerzenie zbioru do więcej niż 60 próbek nie powinno poprawić osiągnięć sieci. Diagram 6.8 pokazuje jednak, że jest inaczej: wraz z dodawaniem nowych danych wejściowych skuteczność sieci nadal wzrasta. Najpierw poddawaliśmy sieć treningowi (liczba prezentowanych próbek uczących znajduje się na osi poziomej), a następnie obliczaliśmy współczynniki determinacji na podstawie danych testowych spoza próby. W skład sieci wchodziło 6 zmiennych wejściowych. Dla maksymalnej liczby dostępnych próbek (250) liczba próbek uczących była ponad 40 razy większa od liczby zmiennych wejściowych i nadal można było odnotować poprawę wyników wraz z dodawaniem nowych danych. Powiększenie zbioru danych uczących zaowocowałoby lepszymi rezultatami. Wyniki tego testu zgodne są z ogólną statystyczną zasadą stwierdzającą,




Diagram 6.8 Poprawa osiągnięć sieci (wyrażonych współczynnikiem determinacji) wraz ze zwiększaniem liczby próbek uczących. Sieć składała się z 6 zmiennych wejściowych.

że im więcej danych, tym lepiej. Pozorne ułatwienia często prowadzą do niekompletnych lub błędnych rezultatów.

WPLYW NIETYPOWYCH WYDARZEŃ

KRACH Z 1987 ROKU I WOJNA W ZATOCE PERSKIEJ

Krach na rynku akcji z 1987 roku i gwałtowna wyprzedaż w okresie od sierpnia do października 1990 roku na początku wojny w Zatoce Perskiej nie są wydarzeniami typowymi. Gdyby występowały powszechnie i dysponowaliśmy kilkuset przypadkami do wykorzystania w treningu, sieci neuronowe mogłyby z powodzeniem prognozować, kiedy należy się ich spodziewać. Skoro jednak zachodzą one bardzo rzadko, a my nie umiemy prognozować zjawisk losowych, musimy podjąć decyzję czy włączyć je do danych, za pomocą których będziemy uczyć sieć. W większości zastosowań wyłączenie wpływu wojny w Zatoce Perskiej nie prowadzi do znacznego ograniczenia zbioru danych.

Problem pojawia się wówczas, gdy mamy zamiar korzystać z danych tygodniowych lub miesięcznych. W przypadku danych tygodniowych liczba dostępnego materiału informacyjnego kurczy się 5-krotnie, a w przypadku danych miesięcznych 22-krotnie, co może nie wystarczyć do uzyskania statystycznie ugruntowanego rozwiązania. Jednym z innych rozwiązań jest uczenie sieci za pomocą danych zarówno obejmujących ich okresy przejściowe, jak i nie obejmujących.

DANE Z POCZĄTKU LAT SIEDEMDZIESIĄTYCH

Powszechnie uważa się, że rynek akcji zmienił się, odkąd na początku lat siedemdziesiątych wprowadzono obrót opcjami. Jest to kolejne wydarzenie, które podobnie jak krach z 1987 roku i wojnę w Zatoce Perskiej, należy wziąć pod uwagę i z którym trzeba sobie jakoś poradzić. Ma ono znaczenie prawdopodobnie tylko dla projektantów sieci opartych na danych miesięcznych i dla tych, którzy opracowują prognozy długoterminowe.

Rozdział siódmy

Proces uczenia i taksonomia sieci

W tym rozdziale zajmiemy się treningiem sieci i przedstawimy wiele algorytmów uczenia. Oprócz tego omówimy wiele architektur sieci neuronowych.

PROCES UCZENIA

Uczenie sieci to proces, w którym uczymy ją tego, co uważamy za pożądane. Gdybyśmy chcieli nauczyć osobę zbioru faktów, moglibyśmy pierwszy fakt (często określany mianem „próbki”) zapisać na kartce papieru, drugi na drugiej, i tak dalej, a następnie prezentować je pojedynczo tej osobie tak długo, aż się ich nauczy. Technikę tę ilustruje diagram 7.1.

Kiedy chcemy, by sztuczna sieć neuronowa symulowała ludzki mózg, robimy to samo, tyle że w tym przypadku dane prezentujemy za pośrednictwem arkusza kalkulacyjnego, wiersz za wierszem. Wiersze możemy prezentować porządku losowym bądź sekwencyjnym, metodą tak zwaną *rotacją*. Niektóre architektury sieci neuronowych wymagają prezentacji próbek metodą rotacji; w przypadku innych sieci możemy stosować obie metody.




Diagram 7.1 Uczenie faktów – w trakcie treningu przypadki prezentujemy jeden za drugim tak długo, aż uczący się opanuje materiał.

Źródło: Ward Systems Group.

ALGORYTMY UCZENIA

Słowo *algorytm* oznacza metodę uczenia sieci. Najpopularniejszym algorytmem jest *momentum*. Można w nim zmieniać zarówno współczynnik uczenia, czyli prędkość nauki sieci, jak i jego „bezwładność”, czyli stopień, w jakim poprzednie działanie wpływa na obecne. Większość pakietów oprogramowania modelującego sieci neuronowe zawiera również inne prawnie zastrzeżone algorytmy uczenia, które często zachwala się jako wyróżniające się pod względem dokładności, prędkości uczenia lub innych właściwości.

W celu sprawdzenia wpływu algorytmu uczenia na wyniki sieć odniesienia poddaliśmy treningowi za pomocą różnych algorytmów. Rozważana sieć była siecią trzywarstwową o wstecznej propagacji błędów, zaś miernik dokładności stanowił minimalny średni błąd z testów przeprowadzonych na bazie świeżych danych. Wyniki owych testów przedstawia tabela 7.1.

Jak widać, w przypadku danych z sieci odniesienia wybór współczynnika uczenia nie ma większego znaczenia – różnica wynosi ± 6 procent. Jednak w niektórych zastosowaniach różnica między 0,00456 a 0,00403 może decydować o sukcesie lub porażce. Podkreślimy raz jeszcze, że każde zastosowanie i architekturę sieci należy przetestować za pomocą różnych algorytmów uczenia w celu ustalenia, który z nich daje najlepsze rezultaty.

Tabela 7.1 Wpływ algorytmu uczenia na dokładność.

Algorytm uczenia	Prezentacja	Minimalny średni błąd
Momentum (Współczynnik uczenia 0,05; współczynnik <i>momentum</i> 0,5)	losowa rotacyjna	0,00435 0,00417
Momentum (Współczynnik uczenia 0,1; współczynnik <i>momentum</i> 0,1)	losowa rotacyjna	0,00434 0,00403
Algorytm zastrzeżony 1	losowa rotacyjna	0,00434 0,00424
Algorytm zastrzeżony 2	losowa rotacyjna	nie dot. 0,00456

ARCHITEKTURY SIECI

Chociaż około 90 procent wszystkich sieci to sieci trzywarstwowe oparte na algorytmie wstecznej propagacji błędów, istnieje wiele innych rodzajów sieci, niekiedy bardzo wyspecjalizowanych. W tym miejscu zbadamy kilka architektur sieci, poddając je treningowi na bazie danych sieci odniesienia.

SIECI TRZYWARSTWOWE OPARTE NA ALGORYTMIE WSTECZNEJ PROPAGACJI BŁĘDÓW

Używając sieci trzywarstwowej opartej na algorytmie wstecznej propagacji błędów, musimy ustalić dwie rzeczy: rodzaj algorytmu uczenia i liczbę neuronów w warstwie ukrytej (czyli drugiej, patrz diagram 7.2). Algorytmy uczenia omówiliśmy w poprzedniej części rozdziału, w podrozdziale zatytułowanym „Algorytmy uczenia”.

Wpływ liczby neuronów w warstwie ukrytej zbadaliśmy, ucząc sieci, w których liczba ta wahała się od 1 do 40. W analizie zastosowaliśmy dane sieci odniesienia, a kryterium oceny stanowił średni minimalny błąd wyznaczony na bazie 31 (nowych) próbek testowych. Użyliśmy algorytmu *momentum* dla współczynnika uczenia 0,05 i współczynnika *momentum* 0,5. Wyniki przedstawia tabela 7.2.

Zwróćmy uwagę, że różnica błędów wynosi tylko 5 procent i że nawet wyniki sieci zawierającej zaledwie *jeden* neuron w warstwie ukrytej nie różniły się bardziej od wyników najlepszej z sieci. Specjaliści od sieci neuronowych sugerują różne formuły ustalania liczby neuronów w warstwie ukrytej. Najbardziej popularna z nich mówi, że należy rozpocząć od sieci, w której liczba neuronów w warstwie ukrytej równa się sumie




Diagram 7.2 Schemat sieci trzywarstwowej. Blok oznaczony liczbą 1 reprezentuje warstwę wejściową neuronów, blok 2 warstwę ukrytą, a blok 3 warstwę wyjściową.

Tabela 7.2 Liczba neuronów w warstwie ukrytej a dokładność sieci.

Liczba neuronów w warstwie ukrytej	Minimalny średni błąd
Jeden (sic!)	0,00446
Dwa	0,00441
Trzy	0,00425
Cztery	0,00433
Pięć	0,00440
Siedem	0,00435
Dziesięć	0,00430
Piętnaście	0,00431
Dwadzieścia	0,00426
Trzydzieści	0,00425
Czterdzieści	0,00426

zmiennych wejściowych i wyjściowych. Dla rozpatrywanego przypadku byłoby to siedem neuronów, tak więc stosując tę formułę, otrzymalibyśmy sieć o mniej więcej przeciętnych osiągnięciach.

Liczba neuronów w warstwie ukrytej nie wydaje się kluczowym zagadnieniem – za pomocą testów takich jak przedstawiony powyżej można bez trudu wyznaczyć optimum. Diagram 7.3 przedstawia w formie graficznej dane z diagramu 7.2.

SIECI CZTEROWARSTWOWE

Sieci czterowarstwowe są podobne do sieci trzywarstwowych, z tą różnicą, że zawierają dodatkową warstwę znajdującą się między warstwą ukrytą a wyjściową (diagram 7.4). Kilku badaczy zajmujących się z szeregiem danych ogłosiło, że wyniki sieci ulegają poprawie, gdy dodać czwartą warstwę o liczbie neuronów równej jednej dziesiątej łącznej liczby neuronów w warstwach ukrytej i wyjściowej. Aby zweryfikować tę tezę na bazie danych odniesienia, dodaliśmy czwartą warstwę do sieci zawierających w drugiej warstwie 3 i 30 neuronów. Wyniki serii testów przedstawia tabela 7.3.




Diagram 7.3 Rozkład błędów względem liczby neuronów w warstwie ukrytej.




Diagram 7.4 Schemat sieci czterowarstwowej. Bloki 2 i 3 reprezentują warstwy ukryte.

Tabela 7.3 Wpływ dodania drugiej warstwy ukrytej na dokładność sieci.

Architektura sieci			Średni błąd
Warstwa wejściowa	Pierwsza warstwa ukryta	Druga warstwa ukryta	
6	3	3	0,00449
6	3	2	0,00458
6	30	30	0,00432
6	30	15	0,00430
6	30	7	0,00438
6	30	3	0,00454

Z danych na temat konfiguracji sieci możemy wywnioskować, że wyniki nie są lepsze od tych uzyskanych przez standardową sieć trzywarstwową opartą na algorytmie wstecznej propagacji błędów.

Chociaż możliwa jest budowa sieci pięciwarstwowej, nie poddaliśmy analizie tego rodzaju konfiguracji, albowiem ze względu na liczbę zmiennych konieczna byłaby ogromna liczba testów.

SIECI REKURENCYJNE

Sieci rekurencyjne, znane również pod nazwą *sieci Jordana Elmana*, posiadają umiejętność rozpoznawania wzorów. Typowymi wzorami mogą być formacje „podwójnego dna” lub „głowy i ramion”, często wykorzystywane w sieciach finansowych i przynoszące doskonałe wyniki. Sieci rekurencyjne mają jedną wadę: ich uczenie trwa bardzo długo. Nie jest to problemem, gdy mamy do czynienia ze względnie niewielką siecią i małym, podobnym do używanego w sieci odniesienia, zbiorem danych. Inaczej jednak mają się rzeczy, kiedy liczba zmiennych wejściowych wzrasta z 6 do 25, a wierszy danych z 327 do 900. Trening sieci trzywarstwowych w oparciu o dane odniesienia trwa poniżej trzech minut; dla porównania czas uczenia każdej z trzech sieci rekurencyjnych wynosił około 30 minut. Dane te odnoszą się do komputera wyposażonego w procesor 486DX taktowany zegarem 33MHz.

Sieci rekurencyjne przypominają nieco sieci trzywarstwowe oparte na algorytmie wstecznej propagacji błędów, z tą różnicą, że zawierają czwarte skupisko neuronów, do którego wybiegają połączenia z pozostałych trzech skupisk. Owe skupiska neuronów określa się mianem bloków (patrz diagram 7.4). Sieć trzywarstwowa ze wsteczną propagacją błędów zawiera tylko 3 bloki: warstwa wejściowa stanowi blok pierwszy, warstwa ukryta drugi, a warstwa wyjściowa trzeci.

Przyjmując za kryterium rodzaj sprzężenia zwrotnego łączącego czwarty blok (wejścia z jednej z pozostałych trzech warstw lub bloków), możemy wyróżnić trzy typy sieci rekurencyjnych. Sprzężenie zwrotne może zachodzić między blokiem czwartym a warstwą wejściową (diagram 7.5), warstwą ukrytą (diagram 7.6) lub warstwą wyjściową (diagram 7.7).

Aby przekonać się, czy zastosowanie sieci rekurencyjnych zaowocuje w przypadku danych odniesienia poprawą wyników, dane zainstalowaliśmy na wszystkich trzech typach sieci rekurencyjnych. Liczbę neuronów w każdym bloku (warstwie) ustaliliśmy, akceptując wartość domyślną generowaną przez użyty pakiet oprogramowania modelującego sieci neuronowe. Dla sieci, w której sprzężenie zwrotne wychodziło z warstwy wejściowej, dane przedstawiały się następująco: warstwa wejściowa (blok 1) – 6 neuronów, warstwa ukryta (blok 2) – 20 neuronów, warstwa wyjściowa (blok 3) – 1 neuron, blok rekurencyjny (blok 4) – 6 neuronów. Kiedy sprzężenie zwrotne wychodziło z warstwy ukrytej, liczba neuronów w bloku rekurencyjnym wynosiła 20, a kiedy z warstwy wyjściowej – 6.




Diagram 7.5 Sieć rekurencyjna o sprzężeniu zwrotnym biegnącym z warstwy wejściowej (blok 1) do rekurencyjnej (blok 4).




Diagram 7.6 Sieć rekurencyjna o sprzężeniu zwrotnym biegnącym z warstwy ukrytej (blok 2) do rekurencyjnej (blok 4).




Diagram 7.7 Sieć rekurencyjna o sprzężeniu zwrotnym wychodzącym z warstwy ukrytej (blok 3) do rekurencyjnej (blok 4).

Rodzaj sieci rekurencyjnej	Minimalny średni błąd
Sprzężenie zwrotne z warstwą wejściową	0,00440
Sprzężenie zwrotne z warstwą ukrytą	0,00385
Sprzężenie zwrotne z warstwą wyjściową	0,00402

Sieci rekurencyjne zawierające sprzężenia zwrotne z warstwą wyjściową lub warstwą ukrytą okazały się lepsze od wszystkich testowanych wcześniej sieci trzy- i czterowarstwowych.

SIECI SKOKOWE

Sieć skokowa to odmiana sieci ze wsteczną propagacją błędów, w której każda warstwa jest połączona lub powiązana ze wszystkimi warstwami poprzednimi. Gdy stosujemy więcej niż jedną warstwę ukrytą, czas uczenia zwykle ulega wydłużeniu.

Trzywarstwowa sieć skokowa

Trzywarstwową sieć tego typu (patrz diagram 7.8) przetestowaliśmy za pomocą danych odniesienia. Minimalny średni błąd wyniósł 0,00481.

Czterowarstwowa sieć skokowa

Schemat czterowarstwowej sieci skokowej przedstawia diagram 7.9. Sieć uzyskała złe wyniki – minimalny średni błąd wyniósł 0,0054.

Pięciowarstwowa sieć skokowa

Diagram 7.10 ilustruje rozkład połączeń pięciowarstwowej sieci skokowej. Jest to najgorsza z dotychczas badanych sieci – gdy poddaliśmy ją treningowi i przetestowaliśmy za pomocą danych odniesienia, minimalny średni błąd wyniósł 0,00633.

FUNKCJE AKTYWACJI

Funkcje aktywacji to matematyczne funkcje przeniesienia decydujące o tym, któremu poziomowi danych przypisuje się największą wagę. Na przykład, jeżeli stosujemy funkcję liniową, wszystkie dane traktowane są jednakowo (diagram 7.11). W funkcji tanh (tangens hiperboliczny) dużo większy nacisk kładzie się na informacje zgrupowane wokół 0, a bardzo niewielki na wartości położone w pobliżu +1 i -1 (diagram 7.13).




Diagram 7.8 Trzywarstwowa sieć skokowa.




Diagram 7.9 Czterowarstwowa sieć skokowa.




Diagram 7.10 Pięciowarstwowa sieć skokowa. W testach przeprowadzonych na bazie danych odniesienia sieć osiągnęła bardzo słabe wyniki.

A oto matematyczne formuły reprezentujące różne funkcje aktywacji:

Funkcja logistyczna

$$f(x) = 1/(1 + e^{-x})$$

Funkcja liniowa

$$f(x) = x$$

Tangens hiperboliczny

$$f(x) = \tanh x$$

Tangens hiperboliczny 1,5x

$$f(x) = \tanh(1,5x)$$

Sinus

$$f(x) = \sin x$$

Symetryczna funkcja logistyczna

$$f(x) = 2/(1 + e^{-x}) - 1$$

Funkcja Gaussa

$$f(x) = e^{-x^2}$$

Dopełnienie funkcji Gaussa

$$f(x) = 1 - e^{-x^2}$$




Diagram 7.11 Logistyczna funkcja aktywacji.

Wykresy tych funkcji przedstawiają diagramy 7.11–7.18.

Większość programów modelujących sieci neuronowe korzysta z funkcji logistycznej, chyba że użytkownik sam wybierze inną. Część programów umożliwia dokonanie wyboru spośród różnych funkcji. Poniżej przedstawiamy wyniki uczenia trzywarstwowej sieci ze wsteczną propagacją błędów za pomocą rozmaitych funkcji aktywacji:

Funkcja aktywacji	Minimalny średni błąd
Logistyczna	0,00403
Liniowa	0,00416
Tanh	0,00394
Gausa	0,00400
Sinus	0,00396
Tanh (1,5x)	0,00394
Symetryczna logistyczna	0,00397
Dopełnienie funkcji Gausa	0,00387

SIECI TYPU WARD

Sieci typu Ward wyposażone są w dodatkowe bloki, które mogą mieć różne funkcje aktywacji. Na przykład sieć typu Ward przedstawiona na diagramie 7.19 przypomina standardową sieć trzywarstwową, tyle że obok zwykłej warstwy ukrytej (blok 2) znajduje się blok dodatkowy (oznaczony liczbą 3). W efekcie sieć posiada dwie warstwy ukryte, z których każda może mieć odmienną funkcję aktywacji. Dla celów analizy trenin-gowej na bazie danych odniesienia poddaliśmy sieć, w której funkcją aktywacji jednego bloku była funkcja Gausa, a drugiego dopełnienie funkcji




Diagram 7.12 Liniowa funkcja aktywacji.




Diagram 7.13 Funkcja aktywacji – tanh.




Diagram 7.14 Funkcja aktywacji – tanh (1,5x).




Diagram 7.15 Sinusowa funkcja aktywacji.




Diagram 7.16 Symetryczna logistyczna funkcja aktywacji.




Diagram 7.17 Funkcja aktywacji – funkcja Gaussa.




Diagram 7.18 Funkcja aktywacji – dopełnienie funkcji Gaussa.




Diagram 7.19 Schemat podstawowej sieci Ward. Sieć zawiera dwa ukryte bloki, z których każdy posiada odmienną funkcję aktywacji.

Gaussa. Minimalny średni błąd wyniósł 0,00431. Zastosowaliśmy algorytm uczenia *momentum* – współczynnik uczenia wyniósł 0,05, a współczynnik *momentum* 0,5.

Sieć przedstawiona na diagramie 7.20 posiada dodatkowe połączenie pozwalające na bezpośrednie kontaktowanie się wejścia (bloku 1) z wyjściem (blokiem 4). Sieć wykorzystuje te same co wyżej funkcje aktywacji – funkcję Gaussa i dopełnienie funkcji Gaussa – a po zakończeniu treningu jej minimalny średni błąd wyniósł 0,00395.

Treningowi poddaliśmy również sieć zawierającą trzy równoległe warstwy ukryte (patrz diagram 7.21). Trzecią, oprócz funkcji Gaussa i dopełnienia funkcji Gaussa, funkcją aktywacji był tangens hiperboliczny. Minimalny średni błąd nauczonej sieci wyniósł w tym wypadku 0,00403.




Diagram 7.20 Zmodyfikowana sieć Ward. Sieć zawiera dwa ukryte bloki o różnych funkcjach aktywacji oraz kanał łączący bezpośrednio blok 1 z blokiem 4.




Diagram 7.21 Sieć Ward zawierająca trzy bloki ukryte o różnych funkcjach aktywacji.

SAMOORGANIZUJĄCE SIĘ SIECI KOHONENA

Sieci Kohonena służą do klasyfikacji zmiennych wyjściowych. Gdybyśmy na przykład zastosowali dane na temat nieruchomości podobne do opisanych w rozdziale czwartym, sieć Kohonena mogłaby rozbić je na grupy reprezentujące domy o cenie wysokiej, średniej i niskiej. Sieci Kohonena określane są mianem sieci *nie nadzorowanych*, czyli takich, które nie dysponują wartością wyjściową ze zbioru uczącego dla celów porównań w trakcie uczenia.

Sieci Kohonena składają się z dwóch warstw (diagram 7.22): warstwy wejściowej złożonej z n zmiennych oraz warstwy wyjściowej, w której każde wyjście reprezentuje jedną kategorię. W trakcie uczenia próbki




Diagram 7.22 Schemat nienadzorowanej sieci neuronowej (sieci Kohonena).




Diagram 7.23 Schemat probabilistycznej sieci neuronowej.

prezentowane są w porządku rotacyjnym bądź sekwencyjnym, a następnie przesyłane do warstwy wyjściowej i poddawane ewaluacji. Proces ten powtarza się tyle razy, ile wybraliśmy wcześniej prezentacji całego zbioru danych.

Sieć jest bardzo wrażliwa na współczynnik uczenia; lepsze programy powoli obniżają jego wartość w miarę, jak postępuje trening. Sieć koryguje wagi biegnące do neuronów wyjściowych w tak zwanym *sąsiedztwie* neuronu. Rozmiar sąsiedztwa zmienia się; na początku jest ono bardzo duże, po czym powoli maleje do zera. Sieci Kohonena grupują próbki na bazie ich wzajemnego oddalenia. Test sieci Kohonena w oparciu o dane odniesienia nie był możliwy, ponieważ sieci tego rodzaju nie stosuje się w połączeniu z szeregami danych.

PROBABILISTYCZNE SIECI NEURONOWE – PNN

Probabilistyczne sieci neuronowe (PNN) dzielą zbiór danych na ustaloną liczbę kategorii wyjściowych. Są one znane ze względu na swoją zdolność szybkiego uczenia się na niewielkich zbiorach danych. Sieci PNN są sieciami trzywarstwowymi (diagram 7.23); liczba neuronów wyjściowych pokrywa się z liczbą kategorii, liczba neuronów ukrytych równa jest liczbie próbek uczących.

Zastosowanie zarówno sieci PNN, jak i GRNN wiąże się z koniecznością użycia współczynnika wygładzającego.




Diagram 7.24 Wyjście i wejście przy współczynniku wygładzającym równym 0,05. Porównaj diagramy 7.25 i 7.26.

WSPÓŁCZYNNIKI WYGŁADZAJĄCE

Sieci PNN i GRNN wymagają zastosowania współczynnika wygładzającego. Na diagramach 7.24–7.26 próbki 25, 50 i 75 mają wartość 1, a wszystkie inne wartości są równe 0. Na diagramie 7.24 zastosowano współczynnik wygładzający równy 0,05, a wartości skupiają się w okolicach 1 i 0. Kiedy współczynnik wygładzający podniesiemy do 0,08 (co pokazuje diagram 7.25), wartości znajdują się w przedziale od 0,5 do 1. Gdy natomiast zwiększymy go do 0,1 (diagram 7.26), wszystkie wartości bliskie są 1, a różnice między wartościami ulegną „wygładzeniu” lub zniwelowaniu. Tu również nie mogliśmy użyć danych odniesienia, ponieważ podobnie jak sieci Kohonena sieci PNN służą do klasyfikacji.

SIECI NEURONOWE REALIZUJĄCE REGRESJĘ UOGÓLNIONĄ – GRNN

Sieci neuronowe realizujące regresję uogólnioną (GRNN), podobnie jak sieci typu PNN, znane są ze swojej zdolności operowania na niewielkich zbiorach danych. W odróżnieniu od sieci PNN, które klasyfikują dane, sieci GRNN potrafią generować ciągłe wartości wyjściowe. Sieci GRNN to sieci trzywarstwowe (diagram 7.27), zawierające w warstwie ukrytej tyle neuronów, ile jest próbek uczących. W ich przypadku nie stosuje się parametrów uczenia takich jak współczynniki uczenia czy *momentum*, używa się natomiast współczynnika wygładzającego.

W porównaniu z sieciami ze wsteczną propagacją błędów, czas treningu sieci GRNN jest krótki, a gdy porównać go z czasem uczenia sieci rekurencyjnych – bardzo krótki. Kiedy sieć GRNN poddaliśmy treningowi w oparciu o dane odniesienia, wyniki były rozczarowujące: średni błąd wyniósł 0,00634. Kiedy jednak dołączyliśmy 12-okresowe średnie kroczone każdej ze zmiennych wejściowych, minimalny średni błąd spadł




Diagram 7.25 Wyjście i wejście dla współczynnika wygładzającego równego 0,08. Porównaj diagramy 7.24 i 7.26.




Diagram 7.26 Wyjście i wejście przy współczynniku wygładzającym równym 0,05. Porównaj diagramy 7.24 i 7.25.




Diagram 7.27 Schemat sieci neuronowej realizującej regresję uogólnioną (GRNN).

do 0,00115, czyli był 4 razy niższy niż w przypadku najlepszej sieci rekurencyjnej (patrz dodatek na końcu książki). Wynik ten pokazuje zarówno wagę wstępnego przygotowania danych, jak i umiejętności sieci GRNN w zakresie operowania szeregami danych. Sieci GRNN, gdy dostarczymy im odpowiednio przetworzone dane, dystansują na tym polu większość, jeśli nie wszystkie pozostałe typy sieci neuronowych.

Diagram 7.28 przedstawia błąd sieci GRNN w miarę jak postępuje trening. Zauważmy, że sieć wypróbowuje różne współczynniki wygładzające tak długo, aż błąd osiągnie minimalną wartość. Czas uczenia




Diagram 7.28 Błąd sieci a współczynnik wygładzający.

sieci odniesienia na komputerze wyposażonym w procesor 486DX33 wynosił około półtorej minuty. Dla porównania, trening sieci rekurencyjnej na tych samych danych i sprzęcie trwał mniej więcej pół godziny.

SIECI GRNN Z DOŁĄCZONYM ALGORYTMEM GENETYCZNYM

W połowie 1994 roku firma Ward Systems Group wprowadziła nowy rodzaj sieci GRNN określanych mianem sieci z dołączonym algorytmem genetycznym. Różnią się one od zwykłych sieci GRNN tym, że posiadają kilka współczynników wygładzających, po jednym na każdą zmienną wejściową oraz jeden tradycyjny współczynnik ogólny. W trakcie treningu współczynniki wygładzające dla każdej zmiennej wejściowej oraz tradycyjny współczynnik ogólny korygowane są w taki sposób, by podczas weryfikacji za pomocą danych testowych błąd osiągnął najniższą wartość. Mówi się, że nowa sieć opracowana przez Ward Systems jest około dwa razy dokładniejsza od sieci GRNN, co w świetle pierwszych testów wydaje się prawdą. W testach przeprowadzonych na bazie szeregów czasowych danych sieć ta uzyskała najlepsze wyniki spośród wszystkich badanych dotąd sieci i algorytmów.

Wadę sieci tego rodzaju stanowi długi czas treningu. Dla porównania, tam gdzie nauka zwykłej sieci GRNN trwałaby dwie minuty, trening sieci z dołączonym algorytmem genetycznym może zająć całą godzinę.

Rozdział ósmy

Rozpoczynanie i zatrzymywanie uczenia

W rozdziale tym omówimy zagadnienia związane z rozpoczynaniem i zatrzymywaniem treningu oraz powiemy, co robić, gdy sieć nie uczy się. Pod koniec rozdziału pokażemy, jak należy posługiwać się siecią.

ROZPOCZYNANIE TRENINGU

Po zebraniu danych, zaimportowaniu ich do arkusza kalkulacyjnego, wstępnym przetworzeniu, ustaleniu wartości minimalnych i maksymalnych, wyborze architektury sieci i algorytmu uczenia rozpoczęcie treningu stanowi najprostszy etap całego procesu. W programach modelujących sieci neuronowe działających pod systemem DOS trening uruchamiamy, wciskając kombinację dwóch klawiszy, na przykład „Control” i „T”; w programach pracujących w środowisku Windows należy w tym celu dwukrotnie kliknąć na odpowiedniej ikonie.

Jak już wyjaśniliśmy w rozdziale siódmym, trening to wielokrotna prezentacja danych (w postaci próbek lub wierszy) sieci, której celem

jest nauczanie sieci rozpoznawania wzajemnych zależności między różnymi zmiennymi. Diagramy 8.1–8.4 przedstawiają postępy w nauce sieci trzywarstwowej w miarę jak przyswaja sobie ona treningowy zbiór danych utworzony na bazie danych odniesienia. Zastosowaliśmy algorytm uczenia *momentum*; współczynnik uczenia wynosił 0,05, a współczynnik *momentum* 0,5. Na osi pionowej zaznaczyliśmy błąd popełniony przez sieć, natomiast oś pozioma reprezentuje liczbę prezentacji pojedynczych próbek. Diagram 8.1 ukazuje, jak miały się rzeczy, gdy zaprezentowaliśmy sieci zaledwie 1772 próbek. Patrząc na diagram 8.2, przedstawiający błąd po prezentacji 2583 próbek, widzimy niewielki postęp. Zauważmy, że między 1772 i 2583 próbą tempo uczenia osłabło. Diagram 8.3 przedstawia błąd po prezentacji 4305 próbek. Zwróćmy uwagę, że tempo uczenia znacznie się zmniejszyło i że sieć nadal szuka rozwiązania. Diagram 8.4 prezentuje krzywą błędów po zatrzymaniu treningu po prezentacji 104 400 próbek.

ZATRZYMYWANIE TRENINGU

Kiedy uczymy sieci ze wsteczną propagacją błędów, w pewnym punkcie procesu uczenia sieć osiąga maksimum swoich możliwości. Jak ukazują wykresy (diagramy 8.1–8.4), na początku sieć uczy się bardzo szybko. W miarę postępowania treningu tempo nauki spada (co pokazuje spłaszczona krzywa). Ostatecznie sieć przestaje pogłębiać swoją wiedzę i zaczyna uczyć się na pamięć. Jest to zjawisko negatywne – mimo iż niekiedy sprawia ono, że sieć lepiej radzi sobie z danymi uczącymi, przyczynia się do pogorszenia wyników sieci podczas kontaktu ze świeżymi danymi testowymi spoza próby.

Diagram 8.5, który jest powiększeniem prawego krańca krzywej z diagramu 8.4, przedstawia krzywą błędów dla danych testowych pod koniec procesu uczenia i bardzo wyraźnie ilustruje powyższe zjawisko. Proces uczenia przebiega zgodnie z oczekiwaniami aż do punktu oznaczonego pionową strzałką, od którego osiągi sieci zaczynają się pogarszać. Wynika to stąd, że od tego momentu sieć uczy się danych na pamięć, a nie stara się zrozumieć związku między nimi i w efekcie gorzej sobie radzi z danymi testowymi.

Naszym celem jest zatrzymanie treningu w miejscu, w którym sieć zaczyna się uczyć na pamięć. Niektóre programy samodzielnie zatrzymują proces uczenia, badają wyniki sieci za pomocą danych testowych i zapisują konfigurację sieci tylko wówczas, gdy uzyska lepsze wyniki niż w poprzednim teście. Jeżeli wyniki nie ulegają poprawie, program nie zapisuje konfiguracji. Potem proces uczenia przebiega dalej. Zazwyczaj trening jest zatrzymywany w celu weryfikacji umiejętności sieci co 50 do 200 prezentacji próbek uczących. Częstsze testowanie przynosi poprawę dokładności sieci, następuje to jednak kosztem wydłużenia czasu uczenia. Rozwiązaniem kompromisowym jest sprawdzanie postępów sieci




Diagram 8.1 Błąd a czas uczenia. Wykres przedstawia błąd sieci (wyznaczony na bazie testowego zbioru danych) w miarę jak postępuje trening. Po 1772 prezentacjach próbek uczących tempo nauki zaczyna spadać.




Diagram 8.2 Zależność między błędem a czasem uczenia. Wykres analogiczny do wykresu przedstawionego na diagramie 8.1, z tą różnicą, że trening rozszerzyliśmy do 2583 prezentacji. Zwróćmy uwagę, że prędkość uczenia uległa dalszemu zmniejszeniu.




Diagram 8.3 Zależność między błędem a czasem uczenia. Tu trening rozszerzyliśmy do 4503 prezentacji próbek uczących, a tempo nauki uległo dalszemu zmniejszeniu.




Diagram 8.4 Trening rozciągnięty na 104 400 prezentacji próbek uczących. Sieć uczy się bardzo powoli, ale, jak się okazuje, nawet po tak długim czasie nadal odnotowuje postępy.




Diagram 8.5 Powiększony koniec krzywej przedstawionej na diagramie 8.4. Sieć nie jest w stanie poprawić wyniku uzyskanego w punkcie oznaczonym strzałką. Zazwyczaj jeżeli sieć nie uzyska lepszych osiągnięć po prezentacji 10 000 pojedynczych próbek, trening uznaje się za zakończony.

co 200 prezentacji próbek uczących we wczesnej fazie uczenia i co 50, gdy zaczynamy się zbliżać do punktu, od którego sieć zaczyna uczyć się na pamięć (co sygnalizuje spadek tempa uczenia). Normalnie proces uczenia jest kontynuowany także po wyznaczeniu „najlepszej” sieci; prezentujemy wówczas dodatkowo 10 000 do 20 000 próbek uczących, aby upewnić się, czy dalszy trening nie zaowocuje poprawą wyników.

Jeżeli zastosowany program modelujący nie posiada opisanej wyżej funkcji wykrywającej automatycznie „najlepszą” sieć, to musimy samodzielnie zatrzymywać trening i badać sieć za pomocą danych testowych.

ODPOWIEDNI POZIOM DOKŁADNOŚCI

Czasami zbiór danych nie pozwala wyćwiczyć sieci tak, by jej dokładność zadowalała użytkownika. Oto kilka możliwości, które można wypróbować w takiej sytuacji:

1. Zastanów się raz jeszcze nad prognozowanym zjawiskiem. Może staryś się być zbyt dokładny?
2. Zwiększ lub zmniejsz liczbę neuronów w warstwie ukrytej.
3. Rozważ ponownie zmienne wejściowe. Czy nadają się one do prognozowania interesującego Cię zjawiska? Czy zostały poddane odpowiedniej obróbce wstępnej?

4. Spróbuj zastosować sieć innego rodzaju, na przykład sieć rekurencyjną lub GRNN.
5. Zastanów się ponownie nad zjawiskiem reprezentowanym przez zmienną wyjściową.
6. Spróbuj użyć innego algorytmu uczenia.
7. Przeanalizuj ponownie zmienne wejściowe.
8. Zwiększ lub zmniejsz liczbę warstw ukrytych.
9. Przemyśl raz jeszcze cały problem.
10. Ustal, które zmienne wejściowe wnoszą najwięcej do rozwiązania, a które mogą hamować proces uczenia.
11. Zmniejsz lub zwiększ rozmiary przedziału między wartością minimalną a maksymalną.
12. Zmień przedmiot prognozy – na przykład, przewiduj raczej zmianę indeksu S&P niż jego wartość.
13. W przypadku, gdy mamy tylko jedną zmienną wyjściową, warto pomnożyć ją przez -1 , a następnie prognozować obie zmienne, prawdziwą i pomnożoną. Zdarza się, że kiedy zmusimy sieć do cięższej pracy, potrafi opracować bardziej dokładne rozwiązanie. Jeżeli wartości bezwzględne dwóch zmiennych wyjściowych znacznie się od siebie różnią, coś jest z siecią nie w porządku.
14. Przeanalizuj raz jeszcze zmienną wyjściową, zmienne wejściowe, postawiony problem, architekturę sieci, algorytm uczenia, wartości minimalne i maksymalne oraz zastanów się, czy zmienne zostały odpowiednio przetworzone.

UŻYTKOWANIE SIECI

W większości programów modelujących sieci neuronowe użycie sieci wiąże się z koniecznością wprowadzenia nowych danych do arkusza kalkulacyjnego. Czasami nowe dane umieszcza się w dodatkowym wierszu na dole arkusza. W niektórych przypadkach tworzy się w tym celu osobny plik.

Wprowadzając nowe dane, z których ma korzystać sieć, należy sprawdzić, czy zostały umieszczone w odpowiednich kolumnach. Większość plików przeznaczonych dla sieci neuronowych zawiera wiele kolumn z danymi, które nigdy nie są prezentowane sieci (na przykład daty), stąd też należy upewnić się, czy nowe dane nie trafiły przez pomyłkę właśnie do tych kolumn.

Jako że sieci rekurencyjne potrafią zapamiętywać wzorce występujące w danych, potrzebują nie tylko nowych danych, ale także i tych sprzed 10 lub 20 okresów. Sieć można wyuczyć na przykład w taki sposób, by rozpoznawała formacje podwójnego dna lub szczytu. Do powstania takich formacji potrzeba trochę czasu, warunkiem ich rozpoznania jest zatem dostarczenie sieci wystarczającej liczby danych.

Kiedy już wprowadzimy nowe dane do odpowiedniego pliku arkusza kalkulacyjnego, czy to dopisując je do istniejącego pliku, czy też tworząc nowy, sieć wczytuje plik i rozpoczyna działanie. Gdy je skończy, sprawdzamy dane, aby zobaczyć prognozowane wyniki. Podczas gdy sieć można uruchomić względnie szybko i łatwo, zebranie potrzebnych danych bywa niekiedy stosunkowo czasochłonne. Jest to z reguły największy zarzut padający ze strony osób użytkujących na co dzień sieci neuronowe.

Rozdział dziewiąty

Budowa sieci prognozującej S&P z 10-dniowym wyprzedzeniem

Podstawowym celem tego rozdziału jest omówienie budowy sieci prognozującej indeks S&P 500 na 10 dni naprzód. Prognoza 10-dniowa stanowi względnie długoterminową informację na temat prawdopodobnego zachowania rynku.

Drugim celem jest przedstawienie konstruowania sieci opartej na jak najmniejszej liczbie zmiennych wejściowych charakteryzującej się jednocześnie pożądaną dokładnością. Zbyt duża liczba zmiennych wejściowych utrudnia użytkowanie sieci i zwiększa prawdopodobieństwo jej przetrenowania. Operowanie przez sieć wielkimi zbiorami danych prowadzi również do wzrostu ryzyka błędu. Często nieprofesjoniści czują się sfrustrowani i porzucają swoje sieci ze względu na wysiłek potrzebny do zebrania, przetworzenia i użycia danych wejściowych w trakcie codziennej eksploatacji. Sieć o minimalnej liczbie zmiennych wejściowych, która spełnia wymogi dokładności, ma dużo większe szanse być wykorzystywana na co dzień.

Droga rozumowania, którą będziemy podążać w celu zbudowania ostatecznej wersji sieci, jest tylko jednym z wielu możliwych podejść. Najważniejsze jest ogólne podejście, logika kryjąca się za różnymi decyzjami, metoda rozwiązywania problemów, drogi, którymi podążyliśmy

w punktach decyzyjnych na tle dróg, które zignorowaliśmy, oraz przyczyny podjęcia tych decyzji. Każdy projektant sieci posiada pewne przyjęte z góry opinie i uprzedzenia, które odbijają się na jego pracy. Każdy projektant zupełnie inaczej korzysta z tych samych danych, z lepszym lub gorszym rezultatem. O tym, czy praca zakończyła się sukcesem, decyduje ostateczna dokładność prognozy.

Przystępując do napisania tego rozdziału, odrzuciliśmy pomysł zaplanowania całego procesu z góry, przez co wydawałby się przebiegać bez zakłóceń. Mimo iż łatwiej byłoby wówczas uchwycić jego istotę, nie położylibyśmy dostatecznego nacisku na odzwierciedlenie realnych warunków modelowania. Więcej możemy się nauczyć, analizując ślepe uliczki, w które często zdarza nam się zawędrować w trakcie wstępnego przetwarzania danych. Dlatego też, dążąc do zaprezentowania na praktycznym przykładzie budowy sieci neuronowej, zdecydowaliśmy się przedstawić „falstarty” i proces prób i błędów.

ZMIENNE POCZĄTKOWE

Z firmy Dial Data ściągnęliśmy za pomocą modemu dane na temat następujących zmiennych wejściowych:

- Indeks ropy – Oil Index (XOI)
- Dow Jones Industrial Average (DOW-30)
- Dow Jones Transportation Average
- Dow Jones Utility Average
- Indeks S&P 500
- Indeks CRB
- Indeks dolara amerykańskiego (US Dollar Index)
- Oprocentowanie 3-miesięcznych weksli skarbowych
- Oprocentowanie jednorocznych weksli skarbowych
- Indeks Gold and Silver Mining
- Indeks S&P 100 (OEX)
- Wskaźnik A/D
- TRIN

GROMADZENIE DANYCH

Chociaż niekiedy dane wpisuje się ręcznie do pliku, najczęściej ściąga się je przez modem od firmy zajmującej się ich dystrybucją, co umożliwia automatyczną aktualizację cen i statystyk. W tym przypadku dane ściągnęliśmy za pomocą programu Equis Down Loader i zapisaliśmy w pliku programu Metastock, w formacie CompuTrac/Metastock. Dane

odnoszą się do okresu od 1 marca 1991 roku do 25 kwietnia 1994 roku, czyli obejmują ponad 800 dni. Dane sprzed 1 marca 1991 roku zostały umyślnie pominięte ze względu na gwałtowne wahania rynku w okresie od 1 sierpnia 1990 roku do końca lutego 1991 roku będące rezultatem wojny w Zatoce Perskiej. Wahania takie nie były dla rynku czymś typowym, zarówno przed, jak i po wojnie, tak więc powinno się je wyeliminować z materiału przeznaczonego do uczenia sieci.

PRZETWARZANIE DANYCH

Każdy z 13 plików wczytaliśmy po kolei do programu Equis Metastock (MS). Każdy został przekonwertowany na plik tekstowy i automatycznie zapisany w katalogu MS. Następnie 13 oddzielnych plików tekstowych zaimportowaliśmy do Lotus 1-2-3. Plik tekstowy zawierający wartości DOW-30 po załadowaniu go do arkusza przedstawia diagram 9.1. Potem plik ten przekształciliśmy za pomocą dostępnej w większości arkuszy kalkulacyjnych funkcji *parse*. Zamienia ona pliki tekstowe na pliki, w których dane ułożone są w oddzielnych kolumnach (pliki tekstowe nie zawierają wyodrębnionych kolumn). Zwróćmy uwagę, że funkcja *parse* zmienia format daty, z amerykańskiego miesiąc-dzień-rok na kolejny numer dnia w tym stuleciu.

Diagram 9.2 przedstawia ten sam plik po przekonwertowaniu go funkcją *parse* i usunięciu nagłówka tekstowego. Dodano etykiety kolumn. Ostatecznie dane na temat DOW-30 obejmują kolumny zawierające datę, kurs maksymalny, minimalny i zamknięcia oraz wartość obrotów. Zwróćmy uwagę, że data została zapisana w formacie numeru kolejnego dnia stulecia. Jest rzeczą bardzo ważną, by w tym punkcie zapisać dane dotyczące dat. Później większość tych danych zostanie usunięta, tak więc zanim do tego dojdzie, należy zapisać je jako część pliku.

Po przekonwertowaniu 13 plików za pomocą funkcji *parse* usunęliśmy wartości minimalne i maksymalne wszystkich wskaźników z wyjątkiem S&P 500. Usunęliśmy również wszystkie dane na temat obrotów, oprócz tych, które odnosiły się do DOW-30. W efekcie wszystkie pliki, z wyjątkiem S&P 500, zawierały tylko kursy zamknięcia, nie zawierały natomiast wartości minimalnych lub maksymalnych. Pełen zestaw danych obejmujący obroty, wartości minimalne, maksymalne oraz kursy zamknięcia znalazł się jedynie w pliku indeksu DOW-30.

Po zakończeniu procesu rozbijania danych na kolumny i usunięciu zbędnych informacji, za pomocą polecenia *File Combine* pliki wczytaliśmy do jednego wielkiego arkusza. Gdy wprowadzimy zmienne prognozowane, opóźnienia i średnie kroczące, liczba wierszy dostępnych do uczenia i testowania zmniejszy się o około 40. Diagram 9.3 ukazuje połączone pliki przed usunięciem kolumn z datami.

W tej właśnie chwili należy upewnić się, czy kolumny z datami pokrywają się ze sobą. Trudno przecenić wagę tej czynności. W tym przypadku

MetaStock

Price and Indicator Data
03/01/91 to 07/22/94

Security: DOW JONES IND 30 Indicator: NONE

Date	High	Low	Close	Volume Indicator Last M.A.
03/01/91	2923.51	2846.78	2909.90	272470
03/04/91	2950.74	2897.03	2914.11	214530
03/05/91	2995.54	2913.86	2972.52	283650
03/06/91	3017.82	2957.67	2973.27	312750
03/07/91	2998.51	2948.51	2963.37	212890
03/08/91	3003.47	2934.90	2955.20	243280
03/11/91	2975.50	2923.27	2939.36	165280
03/12/91	2962.13	2906.68	2922.52	182990
03/13/91	2967.82	2910.89	2955.20	190200
03/14/91	3000.00	2925.74	2952.23	250040
03/15/91	2966.58	2918.81	2948.27	383820
03/18/91	2960.64	2899.75	2929.95	170370
03/19/91	2908.17	2840.84	2867.82	252890
03/20/91	2897.03	2840.84	2872.03	257190
03/21/91	2907.92	2841.58	2855.45	237240
03/22/91	2879.95	2829.21	2858.91	174330
03/25/91	2897.52	2837.87	2865.84	167890
03/26/91	2924.01	2848.02	2914.85	256330
03/27/91	2956.93	2886.14	2917.57	252850
03/28/91	2942.08	2893.32	2913.86	178990
04/01/91	2919.31	2868.32	2881.19	162160
04/02/91	2951.98	2878.22	2945.05	210660
04/03/91	2970.54	2915.84	2926.73	206520
04/04/91	2959.41	2899.75	2924.50	221630
04/05/91	2949.26	2876.98	2896.78	201700
04/08/91	2929.21	2877.72	2918.56	139630
04/09/91	2932.43	2863.37	2873.02	173840
04/10/91	2902.48	2848.51	2874.50	170130
04/11/91	2937.62	2877.72	2905.45	239430
04/12/91	2946.53	2884.16	2920.79	229420
04/15/91	2957.18	2896.29	2933.17	218910
04/16/91	2995.79	2912.13	2986.88	257900
04/17/91	3030.45	2963.12	3004.46	327500
04/18/91	3027.72	2976.24	2999.26	252520
04/19/91	3000.25	2943.56	2965.59	237760
04/22/91	2962.13	2911.63	2927.72	211280
04/23/91	2957.92	2905.94	2930.45	185520
04/24/91	2965.10	2913.37	2949.51	202080

Diagram 9.1 Plik tekstowy programu Metastock zawierający wartości indeksu DOW-30 po zaimportowaniu go do arkusza Lotus 1-2-3.

DATE	HIGH	LOW	CLOSE	VOLUME
33298	2923.51	2846.78	2909.9	272470
33301	2950.74	2897.03	2914.11	214530
33302	2995.54	2913.86	2972.52	283650
33303	3017.82	2957.67	2973.27	312750
33304	2998.51	2948.51	2963.37	212890
33305	3003.47	2934.9	2955.2	243280
33308	2975.5	2923.27	2939.36	165280
33309	2962.13	2906.68	2922.52	182990
33310	2967.82	2910.89	2955.2	190200
33311	3000	2925.74	2952.23	250040
33312	2966.58	2918.81	2948.27	383820
33315	2960.64	2899.75	2929.95	170370
33316	2908.17	2840.84	2867.82	252890
33317	2897.03	2840.84	2872.03	257190
33318	2907.92	2841.58	2855.45	237240
33319	2879.95	2829.21	2858.91	174330
33322	2897.52	2837.87	2865.84	167890
33323	2924.01	2848.02	2914.85	256330
33324	2956.93	2886.14	2917.57	252850
33325	2942.08	2893.32	2913.86	178990
33329	2919.31	2868.32	2881.19	162160
33330	2951.98	2878.22	2945.05	210660
33331	2970.54	2915.84	2926.73	206520
33332	2959.41	2899.75	2924.5	221630
33333	2949.26	2876.98	2896.78	201700
33336	2929.21	2877.72	2918.56	139630
33337	2932.43	2863.37	2873.02	173840
33338	2902.48	2848.51	2874.5	170130
33339	2937.62	2877.72	2905.45	239430
33340	2946.53	2884.16	2920.79	229420
33343	2957.18	2896.29	2933.17	218910
33344	2995.79	2912.13	2986.88	257900
33345	3030.45	2963.12	3004.46	327500
33346	3027.72	2976.24	2999.26	252520
33347	3000.25	2943.56	2965.59	237760
33350	2962.13	2911.63	2927.72	211280
33351	2957.92	2905.94	2930.45	185520
33352	2965.1	2913.37	2949.51	202080
33353	2958.42	2905.2	2921.04	174770
33354	2934.9	2888.61	2912.38	173310
33357	2941.09	2869.55	2876.98	163820
33358	2929.21	2859.41	2887.87	266030
33359	2945.3	2882.43	2930.2	215330
33360	2966.34	2917.33	2938.61	182340
33361	2959.9	2906.93	2938.86	171260
33364	2956.84	2911.45	2941.64	151990

Diagram 9.2 Plik tekstowy z danymi na temat indeksu DOW-30 po konwersji za pomocą funkcji *parse* i usunięciu nagłówka. Format dat zmieniono na kolejny numer dnia w stuleciu.

DATE	S&P-HIGH	S&P-LOW	S&P-CLOS	OIL	CRB	GOLD	OEX	DOW-VOL	UTILI	TRANSP
33343	361.67	358.01	33343	256.49	33343	220.56	33343	361.67	33343	218.81
33344	361.67	358.01	33344	256.49	33344	220.56	33344	361.67	33344	218.81
33345	361.67	358.01	33345	256.49	33345	220.56	33345	361.67	33345	218.81
33346	361.67	358.01	33346	256.49	33346	220.56	33346	361.67	33346	218.81
33347	361.67	358.01	33347	256.49	33347	220.56	33347	361.67	33347	218.81
33348	361.67	358.01	33348	256.49	33348	220.56	33348	361.67	33348	218.81
33349	361.67	358.01	33349	256.49	33349	220.56	33349	361.67	33349	218.81
33350	361.67	358.01	33350	256.49	33350	220.56	33350	361.67	33350	218.81
33351	361.67	358.01	33351	256.49	33351	220.56	33351	361.67	33351	218.81
33352	361.67	358.01	33352	256.49	33352	220.56	33352	361.67	33352	218.81
33353	361.67	358.01	33353	256.49	33353	220.56	33353	361.67	33353	218.81
33354	361.67	358.01	33354	256.49	33354	220.56	33354	361.67	33354	218.81
33355	361.67	358.01	33355	256.49	33355	220.56	33355	361.67	33355	218.81
33356	361.67	358.01	33356	256.49	33356	220.56	33356	361.67	33356	218.81
33357	361.67	358.01	33357	256.49	33357	220.56	33357	361.67	33357	218.81
33358	361.67	358.01	33358	256.49	33358	220.56	33358	361.67	33358	218.81
33359	361.67	358.01	33359	256.49	33359	220.56	33359	361.67	33359	218.81
33360	361.67	358.01	33360	256.49	33360	220.56	33360	361.67	33360	218.81
33361	361.67	358.01	33361	256.49	33361	220.56	33361	361.67	33361	218.81
33362	361.67	358.01	33362	256.49	33362	220.56	33362	361.67	33362	218.81
33363	361.67	358.01	33363	256.49	33363	220.56	33363	361.67	33363	218.81
33364	361.67	358.01	33364	256.49	33364	220.56	33364	361.67	33364	218.81
33365	361.67	358.01	33365	256.49	33365	220.56	33365	361.67	33365	218.81
33366	361.67	358.01	33366	256.49	33366	220.56	33366	361.67	33366	218.81
33367	361.67	358.01	33367	256.49	33367	220.56	33367	361.67	33367	218.81
33368	361.67	358.01	33368	256.49	33368	220.56	33368	361.67	33368	218.81
33369	361.67	358.01	33369	256.49	33369	220.56	33369	361.67	33369	218.81
33370	361.67	358.01	33370	256.49	33370	220.56	33370	361.67	33370	218.81
33371	361.67	358.01	33371	256.49	33371	220.56	33371	361.67	33371	218.81
33372	361.67	358.01	33372	256.49	33372	220.56	33372	361.67	33372	218.81

Diagram 9.3 Arkusz z Lotus 1-2-3 po połączeniu wszystkich plików poleceniem File Combine.

DATE	OEX-HIGH	OEX-LOW	OEX	MA-VOL	TRANSP	LEAD5	OEX-CL
33340	360.13	355.73	33340	220.56	33340	360.13	355.73
33341	360.13	355.73	33341	220.56	33341	360.13	355.73
33342	360.13	355.73	33342	220.56	33342	360.13	355.73
33343	360.13	355.73	33343	220.56	33343	360.13	355.73
33344	360.13	355.73	33344	220.56	33344	360.13	355.73
33345	360.13	355.73	33345	220.56	33345	360.13	355.73
33346	360.13	355.73	33346	220.56	33346	360.13	355.73
33347	360.13	355.73	33347	220.56	33347	360.13	355.73
33348	360.13	355.73	33348	220.56	33348	360.13	355.73
33349	360.13	355.73	33349	220.56	33349	360.13	355.73
33350	360.13	355.73	33350	220.56	33350	360.13	355.73
33351	360.13	355.73	33351	220.56	33351	360.13	355.73
33352	360.13	355.73	33352	220.56	33352	360.13	355.73
33353	360.13	355.73	33353	220.56	33353	360.13	355.73
33354	360.13	355.73	33354	220.56	33354	360.13	355.73
33355	360.13	355.73	33355	220.56	33355	360.13	355.73
33356	360.13	355.73	33356	220.56	33356	360.13	355.73
33357	360.13	355.73	33357	220.56	33357	360.13	355.73
33358	360.13	355.73	33358	220.56	33358	360.13	355.73
33359	360.13	355.73	33359	220.56	33359	360.13	355.73
33360	360.13	355.73	33360	220.56	33360	360.13	355.73
33361	360.13	355.73	33361	220.56	33361	360.13	355.73
33362	360.13	355.73	33362	220.56	33362	360.13	355.73
33363	360.13	355.73	33363	220.56	33363	360.13	355.73
33364	360.13	355.73	33364	220.56	33364	360.13	355.73
33365	360.13	355.73	33365	220.56	33365	360.13	355.73
33366	360.13	355.73	33366	220.56	33366	360.13	355.73
33367	360.13	355.73	33367	220.56	33367	360.13	355.73
33368	360.13	355.73	33368	220.56	33368	360.13	355.73
33369	360.13	355.73	33369	220.56	33369	360.13	355.73
33370	360.13	355.73	33370	220.56	33370	360.13	355.73
33371	360.13	355.73	33371	220.56	33371	360.13	355.73
33372	360.13	355.73	33372	220.56	33372	360.13	355.73

Diagram 9.4 Pierwsze 22 wiersze arkusza kalkulacyjnego po usunięciu wszystkich, oprócz jednej, kolumn z datami. Cały arkusz zawiera ponad 800 wierszy, spośród których przedstawił tylko 22.

daty były niekompletne w kolumnach z danymi na temat 3-miesięcznych i jednorocznych weksli skarbowych, indeksu dolara i wskaźnika A/D. Jako że dysponowaliśmy dużym materiałem informacyjnym, kolumny te zostały usunięte. Innym sposobem rozwiązania tego problemu byłoby zlokalizowanie miejsc, w których brakuje danych, i wstawienie średnich z wartości poprzedniej i następnej.

Po uzgodnieniu dat usunęliśmy wszystkie, z wyjątkiem jednej, zawierające je kolumny. Tę jedną kolumnę pozostawiliśmy po to, by w przyszłości w razie potrzeby można było dołączyć dodatkowe dane. Diagram 9.4 przedstawia 22 wiersze ukończonego arkusza kalkulacyjnego. Na tym etapie analizy dysponujemy następującymi zmiennymi wejściowymi:

S&P 500 (wartość maksymalna, minimalna i zamknięcia)
Indeks ropy (Oil Index)
Dow Jones Industrial Average
Obroty na Dow Jones Industrial Average
Dow Jones Utilities
Dow Jones Transportation
Indeks CRB
Indeks Gold and Silver Mining
OEX
TRIN

USTALANIE WKŁADÓW ZMIENNYCH WEJŚCIOWYCH

Aby ustalić, które zmienne wejściowe wnoszą najwięcej do rozwiązania, poddaliśmy treningowi trzywarstwową sieć ze wsteczną propagacją błędów. Współczynnik uczenia wynosił 0,05, a współczynnik *momentum* 0,5. Tabela 9.1 ilustruje uszeregowany wkład 10 zmiennych wejściowych. Wartości minimalne i maksymalne zmiennych wejściowych ustaliliśmy tak, by pokrywały się z wartościami rzeczywistymi. Co dziesiąty wiersz zapisaliśmy w pliku testowym; do celów weryfikacji za pomocą danych spoza próby przeznaczyliśmy łącznie 78 wierszy. Liczba próbek uczących wynosiła 688.

Po 300 200 prezentacjach pojedynczych próbek proces uczenia sieci zakończył się, czyli, innymi słowy, dalszy trening nie przynosił poprawy wyników sieci w testach na bazie danych spoza próby. W testach opartych na tych danych sieć uzyskiwała współczynnik determinacji równy 0,09549. Wkłady poszczególnych zmiennych prezentuje tabela 9.1. Najlepsze znajdują się u dołu, natomiast gorsze na górze. Diagram 9.5 przedstawia te same dane w postaci wykresu słupkowego.

Słabe wyniki Dow Jonesa, OEX oraz wskaźnika obrotów nie są niczym niezwykłym. Dow Jones i OEX są skorelowane liniowo zarówno ze sobą nawzajem, jak i z S&P 500, stąd też ich obecność komplikuje sieci

Tabela 9.1 Względny wkład poszczególnych zmiennych wejściowych po zastosowaniu ich do treningu sieci ze wsteczną propagacją błędów. Zmienne uszeregowaliśmy w kolejności odwrotnej, według rosnącego wkładu. Zmienne o największym wkładzie znajdują się na dole tabeli.

Wkład	Zmienna
1,22976	Obroty
1,31203	OEX
1,76214	TRIN
1,97092	S&P 500 (minimum)
2,21308	DOW-30
2,41897	UTIL
2,41966	TRANS
3,02431	GOLDSILV
3,20924	S&P 500 (zamknięcie)
3,57766	S&P 500 (maksimum)
3,69604	CRB
3,87979	Ropa




Diagram 9.5 Dane z tabeli 9.1 przedstawione w formie graficznej. Oto oznaczenia poszczególnych zmiennych: (1) S&P (maksimum), (2) S&P (minimum), (3) S&P (zamknięcie), (4) Ropa, (5) Dow-30, (6) Dow-30 (obroty), (7) Utility, (8) Transport, (9) CRB, (10) Gold and Silver, (11) OEX, (12) TRIN.

obliczenia. Zmienne skorelowane liniowo zawierają w gruncie rzeczy te same informacje, tyle że w nieco odmiennej formie. Przykład takich zmiennych stanowią indeksy S&P 500 i Dow-30. Są one prawie takie same, ale nie identyczne. Sieć gubi się w obliczeniach; ze względu na niewielkie różnice nie wie, którą ze zmiennych zastosować, i może na przemian wybierać raz jedną, raz drugą.

Zazwyczaj w sieciach neuronowych nie stosuje się surowego wskaźnika obrotów, ponieważ jest bardzo „zanieczyszczony” różnymi zakłóceniami i charakteryzuje się wielką niestabilnością. Często natomiast wprowadza się do zestawu zmiennych wejściowych jedną lub wiele średnich kroczących obrotów.

Kolejną zmienną o niskim wkładzie do rozwiązania jest wartość minimalna S&P 500. W przyszłości może nam ona posłużyć za dolny limit dla wstęgi Bollingera, stąd też na razie nie będziemy jej usuwać z zestawu zmiennych wejściowych.

DOBÓR ODPOWIEDNIEJ ŚREDNIEJ KROCZĄCEJ OBROTÓW

Kolejnym etapem jest trening sieci po usunięciu surowego wskaźnika obrotów, OEX, TRIN i Dow-30. Do zestawu zmiennych wejściowych dołączymy 3-, 5- i 10-dniową średnią kroczącą obrotów, a sieć poddamy powtórnemu treningowi w celu ustalenia, które ze zmiennych wnoszą najwięcej do rozwiązania.

Wkłady nowego zestawu zmiennych wejściowych przedstawiają tabela 9.2 i diagram 9.6. Jak widać, wkład średnich kroczących obrotów przewyższa teraz wkład wartości minimalnej S&P 500. Nadal jednak nie wiemy, czy wybraliśmy odpowiednią długość średniej kroczącej, ponieważ wkład najdłuższej średniej jest największy. Jako że nie dotarliśmy do optymalnego rezultatu, nie wiemy, czy średnia 10-dniowa stanowi najlepsze rozwiązanie. Może się bowiem okazać, że średnia o długości 20, czy nawet 100 dni jest lepsza.

Dlatego też, w celu ustalenia optymalnej średniej kroczącej obrotów, sieć poddamy treningowi raz jeszcze, tym razem używając średnich 10-, 20-, 30- i 40-dniowych. Wyniki testów tej nowej sieci przedstawiają tabela 9.3 i diagram 9.7. Zwróćmy uwagę, że 30-dniowa średnia krocząca obrotów stała się czwartą pod względem ważności zmienną, pozostawiając daleko w tyle średnie 20- i 40-dniowe. Ponieważ średnia 40-dniowa okazała się gorszym predyktorem niż 30-dniowa, możemy przyjąć, że znaleźliśmy optimum. Trening zakończył się po prezentacji 639 200 próbek uczących; średni błąd nauczonej sieci wyznaczony w oparciu o plik z danymi nie wchodzącymi w skład próby, czyli za pomocą nowych, świeżych danych, wyniósł 0,00178.

Tabela 9.2 Ranking wkładów zmiennych wejściowych po usunięciu surowego wskaźnika obrotów, OEX i TRIN oraz dodaniu 3-, 5- i 10-dniowych średnich kroczących obrotów.

Wkład	Zmienna
1,74687	S&P 500 (minimum)
1,80293	5-dniowa średnia krocząca obrotów
1,87156	3-dniowa średnia krocząca obrotów
2,31732	10-dniowa średnia krocząca obrotów
2,79877	S&P 500 (maksimum)
3,35121	S&P 500 (zamknięcie)
3,46610	TRANS
3,59537	GOLDSILV
3,95347	CRB
4,33959	UTIL
5,46879	OIL




Diagram 9.6 Dane z tabeli 9.2 przedstawione graficznie. Trzy średnie kroczące obrotów zajmują trzy ostatnie pozycje (numery 9, 10 i 11).

Tabela 9.3 Trzy średnie kroczące obrotów z tabeli 9.2 i diagramu 9.6 zastąpione analogicznymi średnimi 10-, 20-, 30- i 40-dniowymi.

Wkład	Zmienna
1,86366	S&P 500 (minimum)
2,18126	10-dniowa średnia krocząca obrotów
2,74433	20-dniowa średnia krocząca obrotów
2,83724	TRANS
2,96086	40-dniowa średnia krocząca obrotów
3,11930	S&P 500 (maksimum)
3,15833	S&P 500 (zamknięcie)
3,31325	UTIL
3,58407	30-dniowa średnia krocząca obrotów
3,61497	CRB
4,01614	GOLDSILV
5,45404	OIL




Diagram 9.7 Dane z tabeli 9.3 przedstawione w postaci graficznej. Cztery nowe średnie kroczące oznaczone są numerami 9, 10, 11 i 12. Maksymalny wkład ma zmienna 11, czyli średnia 30-dniowa.

WYBÓR ZMIENNYCH OPÓŹNIONYCH I USTALANIE LICZBY DNI WSTECZ

Opóźnione zmienne wejściowe, czyli zmienne sprzed 5, 10 lub nawet 50 dni, często posiadają wielką wartość prognostyczną. W celu sprawdzenia, które ze zmiennych po przekształceniu w zmienne opóźnione mogą posiadać taką wartość, treningowi poddamy sieć złożoną wyłącznie z następujących zmiennych:

- 10-dniowe opóźnienie wartości maksymalnej S&P 500
- 10-dniowe opóźnienie wartości minimalnej S&P 500
- 10-dniowe opóźnienie wartości zamknięcia S&P 500
- 10-dniowe opóźnienie indeksu ropy naftowej (Oil Index)
- 10-dniowe opóźnienie indeksu Dow Jones Utility
- 10-dniowe opóźnienie indeksu Dow Transportation
- 10-dniowe opóźnienie indeksu CRB
- 10-dniowe opóźnienie indeksu Gold and Silver Mining
- 10-dniowe opóźnienie 30-dniowej średniej kroczącej obrotów

Rezultat tego ćwiczenia przedstawiają tabela 9.4 i diagram 9.8. Zwróćmy uwagę, jak duży jest wkład najważniejszej ze zmiennych, czyli indeksu ropy naftowej: jest ona 60 lub 70 procent lepsza o dwóch kolejnych, indeksu Dow Transportation i indeksu Gold and Silver. O wartości zmiennych opóźnionych niech poświadczy fakt, że kiedy po prezentacji 880 600 próbek sieć przestała się uczyć, średni błąd na danych testowych wyniósł 0,00174, czyli był nieco niższy niż w przypadku poprzedniej sieci.

W celu ustalenia najlepszego opóźnienia indeksu ropy naftowej do zestawu zmiennych wejściowych dołączyliśmy wartości tego indeksu sprzed 5, 10, 15 i 20 dni. W skład sieci wchodziły następujące zmienne wejściowe:

- S&P 500 (maksimum)
- S&P 500 (minimum)
- S&P 500 (zamknięcie)
- Indeks ropy
- Indeks Dow Jones Transportation
- Indeks CRB
- Indeks Gold and Silver Mining
- 30-dniowa średnia krocząca obrotów
- Wartość indeksu ropy naftowej sprzed 5 dni
- Wartość indeksu ropy naftowej sprzed 10 dni
- Wartość indeksu ropy naftowej sprzed 15 dni
- Wartość indeksu ropy naftowej sprzed 20 dni

Tabela 9.4 Ranking względnych wkładów zmiennych opóźnionych o 10 dni. Porównaj z tabelą 9.1.

Wkład	Zmienna
3,95614	UTIL sprzed 10 dni
4,11610	S&P 500 (zamknięcie) sprzed 10 dni
4,33969	S&P 500 (minimum) sprzed 10 dni
4,34565	S&P 500 (maksimum) sprzed 10 dni
4,58643	Indeks CRB sprzed 10 dni
4,79716	30-dniowa średnia krocząca obrotów sprzed 10 dni
5,14433	GOLDSILV sprzed 10 dni
5,36414	TRANS sprzed 10 dni
7,45319	Indeks ropy sprzed 10 dni




Diagram 9.8 Dane z tabeli 9.4 przedstawione w formie graficznej. Wykaz zmiennych znajduje się w tekście.

Spośród czterech testowanych zmiennych opóźnionych najlepsza okazała się wartość indeksu ropy sprzed 10 dni, która zajęła w rankingu trzecie miejsce. Tabela 9.5 przedstawia wyniki uczenia sieci w celu ustalenia optymalnego opóźnienia indeksu ropy. Porównując ją z tabelą 9.3, zwróćmy uwagę na przetarasowania, jakie dokonały się w rankingu. Diagram 9.9 przedstawia dane z tabeli 9.4 w postaci graficznej. Porównajmy go z diagramem 9.7.

W trakcie treningu tej najnowszej sieci dokonaliśmy 543 000 prezentacji próbek uczących, a testy wykazały, że średni błąd wynosi 0,00154. Był to najniższy odnotowany dotychczas błąd; wynik ten okazał się ponad 25 procent lepszy w porównaniu z siecią, w której zastosowaliśmy jedynie 8 podstawowych zmiennych wejściowych.

W tym miejscu Czytelnik powinien już zorientować się, dokąd zmierzamy. Najpierw wyznaczaliśmy optymalną liczbę dni potrzebną do uśrednienia obrotów. Następnie ustaliliśmy, że najlepsze jest 15-dniowe opóźnienie indeksu ropy. Potem wyznaczymy optymalne opóźnienie indeksów Gold and Silver Mining oraz Dow Jones Transportation oraz wyznaczymy wartości średnich kroczących dla zmiennych wejściowych wnoszących najwięcej do rozwiązania. Na końcu wypróbujemy kilka wskaźników technicznych w celu sprawdzenia, czy możliwa jest dalsza poprawa wyników sieci. Do tego czasu będziemy dysponować dość szerokim wachlarzem zmiennych wejściowych, zarówno w stanie „surowym”, jak i przetworzonych. Później część tych zmiennych usuniemy, by otrzymać ich optymalną kombinację.

Teraz, w celu ustalenia optymalnego opóźnienia indeksu Gold and Silver Mining, do sieci wprowadzimy jego wartości sprzed 5, 10, 15 i 20 dni. Jak możemy się przekonać analizując tabelę 9.6 i diagram 9.10, wkłady zmiennych 10, 11, 12 i 13 reprezentujące odpowiednio opóźnienia 5-, 10-, 15- i 20-dniowe nie tworzą wzoru, który pozwoliłby jasno uznać, że któryś z nich stanowi optimum. Innymi słowy, nie jest tak, że wkład na początku jest niewielki, osiąga maksimum, po czym zaczyna spadać. Na razie nie wiemy, czy optymalne jest opóźnienie 20-, czy też 100-dniowe, stąd też musimy przeprowadzić analizę od nowa, tym razem testując wartości indeksu sprzed 10, 20, 30 i 40 dni.

Problemy takie jak ten są w projektowaniu sieci neuronowych rzeczą normalną. Tylko za pomocą prób i testów możemy dowiedzieć się, które rozwiązania się sprawdzają, a które nie. To właśnie czas poświęcony na testowanie i analizę decyduje o tym, czy sieć będzie taka sobie, czy też będzie zdolna do formułowania niezawodnych prognoz. Poszukujemy wielu różnicowanych zmiennych wejściowych o dużej wartości prognostycznej; jedynym sposobem uzyskania sieci zbliżonej do optymalnej jest pomysłowe przetwarzanie danych wejściowych i testowanie wymyślonych koncepcji. Tak jak w przypadku wszystkich innych ideałów, nigdy nie uda się stworzyć sieci optymalnej, co najwyżej sieć do niej zbliżoną. Im więcej poświęcimy wysiłku, tym bardziej opracowana sieć będzie przypominać sieć optymalną.

Tabela 9.7 i diagram 9.11 przedstawiają wyniki treningu naszej nowej sieci. Porównajmy diagram 9.11 z diagramem 9.10. Wygląda na to,

Tabela 9.5 Ranking zmiennych wejściowych po wprowadzeniu 5-, 10-, 15- i 20-dniowego opóźnienia indeksu ropy.

Względny wkład	Zmienna
2,22390	S&P 500 (minimum)
2,75325	Indeks ropy przed 5 dniami
3,00056	Indeks CRB
3,17198	30-dniowa średnia krocząca obrotów
3,42611	Indeks ropy
3,45828	Indeks ropy przed 20 dniami
3,56932	S&P 500 (maksimum)
3,61248	Indeks Dow Jones Transportation
3,61321	Indeks ropy przed 15 dniami
3,61448	S&P 500 (zamknięcie)
3,78064	Indeks ropy przed 10 dniami
4,06948	Indeks Dow Jones Utilities
4,42846	Indeks Gold and Silver Mining




Diagram 9.9 Wkłady poszczególnych zmiennych wejściowych uszeregowanych w tabeli 9.5. Pierwsze 10 zmiennych to zmienne standardowe, natomiast zmienne o numerach 10–13 to opóźnione indeksy ropy.

Tabela 9.6 Tabela przypominająca tabelę 9.5, tyle że w tym przypadku wprowadziliśmy 5-, 10-, 15- i 20-dniowe opóźnienia indeksu Gold and Silver Mining.

Względny wkład	Zmienna
1,62168	Indeks Gold and Silver Mining przed 5 dniami
1,86548	Indeks Gold and Silver Mining przed 15 dniami
2,15252	Indeks Gold and Silver Mining przed 10 dniami
3,44518	S&P 500 (minimum)
3,63554	Indeks Gold and Silver Mining przed 20 dniami
3,74607	Indeks Dow Jones Transportation
3,83964	S&P 500 (zamknięcie)
3,85705	Indeks Gold and Silver Mining
3,93033	S&P 500 (maksimum)
4,46468	30-dniowa średnia krocząca obrotów
4,53664	Indeks Dow Jones Utilities
5,38466	Indeks ropy
5,40981	Indeks CRB




Diagram 9.10 Indeks Gold and Silver Mining opóźniony o 5, 10, 15 i 20 dni. Nie udało się ustalić maksimum.

Tabela 9.7 Tak przedstawia się sytuacja po wprowadzeniu indeksów Gold and Silver Mining opóźnionych o 10-, 20-, 30- i 40 dni. Zauważmy, że żaden z opóźnionych indeksów nie wnosł wiele do rozwiązania, co można wytłumaczyć wzajemnym skorelowaniem owych czterech zmiennych.

Wkład	Zmienna
1,51651	Indeks Gold and Silver Mining przed 10 dniami
2,38571	Indeks Gold and Silver Mining przed 30 dniami
2,51152	Indeks Gold and Silver Mining przed 40 dniami
2,54426	Indeks Gold and Silver Mining przed 20 dniami
2,73408	S&P 500 (minimum)
2,77273	Dow Jones Transportation
3,46385	S&P 500 (maksimum)
3,55830	Indeks Gold and Silver Mining – wartość bieżąca
3,60025	Indeks S&P 500 (zamknięcie)
3,73590	30-dniowa średnia krocząca obrotów
4,07699	Indeks Dow Jones Utilities
4,16612	Indeks CRB
5,09664	Indeks ropy




Diagram 9.11 Dane z tabeli 9.7 przedstawione graficznie.

że wkłady zmiennych oznaczone numerami 10, 11, 12 i 13 uległy, na tle diagramu 9.10, „spłaszczeniu”. Wynika stąd, że zmienne z diagramu 9.11, prezentującego wkłady po ostatnim treningu, są ze sobą przypuszczalnie skorelowane i że najprawdopodobniej nie otrzymujemy tu prawdziwych informacji co do tego, które zmienne wnoszą do rozwiązania najwięcej.

Jednym z rozwiązań tego problemu jest przetestowanie sieci cztery razy za pomocą każdej zmiennej wejściowej z osobna, a następnie porównanie średnich błędów ze wszystkich testów. Niestety, trening sieci ze wsteczną propagacją błędów na komputerze wyposażonym w procesor 486DX-33 trwa 2 do 3 godzin, stąd też musielibyśmy na to poświęcić od 8 do 12 godzin. Jednak sieć GRNN uczy się w ciągu trzech minut, tyle że nie generuje liczbowych ani graficznych danych na temat względnych wkładów. W sieciach tego rodzaju otrzymujemy jedynie średni błąd z testu; im jest on niższy, tym dokładniejsza sieć. W celu wyznaczenia najlepszego opóźnienia indeksu Gold and Silver (GSI), sieć GRNN podaliśmy najpierw treningowi bez zmiennych opóźnionych, a potem z GSI opóźnionym o kolejno 10, 20, 30, 40 i 50 dni (niespodziewanie, w tym ostatnim przypadku błąd wcale nie był najmniejszy).

Jak ukazują tabela 9.8 i diagram 9.12, optymalne opóźnienie indeksu Gold and Silver Mining to 40 dni.

WYZNACZANIE ŚREDNIEJ KROCZĄCEJ O NAJWIĘKSZYM WKŁADZIE

W celu wyznaczenia, która ze średnich kroczących zmiennych wejściowych posiada największy wkład, sieć poddamy treningowi za pomocą 10-dniowych średnich kroczących wszystkich zmiennych z wyjątkiem obrotów, następnie analogicznych średnich 20-dniowych itd. W sieci wykorzystamy tylko średnie kroczące zmiennych pierwotnych; samych zmiennych pierwotnych nie będziemy stosować.

Tabela 9.9 przedstawia wyniki treningu sieci za pomocą 10-dniowych średnich kroczących każdej ze zmiennych wejściowych. Wydaje się, że najczęściej wnoszą do rozwiązania średnie kroczące indeksów Dow Jones Utilities, ropy, CRB i Dow Jones Transportation. Następnie wypróbujemy średnie 20-dniowe.

Tabela 9.10 i diagram 9.14 przedstawiają wkłady 20-dniowych średnich kroczących zmiennych wejściowych. Wyniki stanowią niemal kopię wyników z tabeli 9.9 i 9.13. Jedyną realną zmianą jest wzrost wkładu indeksu Dow Jones Transportation. Ma to znaczenie, kiedy przychodzi do selekcji zmiennych; 20-dniowa średnia krocząca indeksu Dow Jones Transportation jest lepszą zmienną niż analogiczna średnia 10-dniowa.

Wyniki testu 30-dniowych średnich kroczących przedstawia tabela 9.11. Wyniki niemal pokrywają się z wynikami średnich 20-dniowych i bardzo przypominają rezultaty uzyskane na bazie średnich 10-dniowych.

Tabela 9.8 Wyniki treningu sieci z dołączoną jedną zmienną opóźnioną. Jak widać, najlepszą zmienną wejściową jest indeks Gold and Silver Mining opóźniony o 40 dni.

Indeks Gold and Silver Mining	
Długość opóźnienia (w dniach)	Średni błąd
0	0,000553
10	0,000522
20	0,000504
30	0,000507
40	0,000455
50	0,000494




Diagram 9.12 Dane z tabeli 9.8 przedstawione graficznie. Dołek taki jak ten, który widzimy na wysokości 40 dni, jest w eksperymentach z sieciami neuronowymi zjawiskiem typowym.

Tabela 9.9 Testujemy 10-dniowe średnie kroczące wszystkich zmiennych wejściowych.

Wkład	Zmienna
2,09745	10-dniowa średnia krocząca S&P 500 (minimum)
2,48538	10-dniowa średnia krocząca indeksu Gold and Silver Mining
2,77351	10-dniowa średnia krocząca S&P 500 (zamknięcie)
3,14686	10-dniowa średnia krocząca S&P 500 (maksimum)
3,34438	10-dniowa średnia krocząca indeksu Dow Jones Transportation
3,37550	10-dniowa średnia krocząca indeksu CRB
3,95879	10-dniowa średnia krocząca indeksu ropy
4,15924	10-dniowa średnia krocząca indeksu Dow Jones Utilities




Diagram 9.13 Dane z tabeli 9.10 przedstawione graficznie. Porównaj diagram 9.14.

Tabela 9.10 Tabela podobna do tabeli 9.9, tyle że w tym przypadku zamiast średniej 10-dniowej zastosowaliśmy średnią 20-dniową.

Wkład	Zmienna
2,05892	20-dniowa średnia krocząca indeksu Gold and Silver Mining
2,13794	20-dniowa średnia krocząca S&P 500 (minimum)
2,86380	20-dniowa średnia krocząca S&P 500 (zamknięcie)
3,03801	20-dniowa średnia krocząca S&P 500 (maksimum)
3,37122	20-dniowa średnia krocząca indeksu CRB
3,89471	20-dniowa średnia krocząca indeksu Dow Jones Transportation
3,93819	20-dniowa średnia krocząca indeksu ropy
4,36914	20-dniowa średnia krocząca indeksu Dow Jones Utilities




Diagram 9.14 Dane z tabeli 9.11 przedstawione graficznie. Porównaj diagram 9.13.

Tabela 9.11 Rezultat zastosowania 30-dniowej średniej kroczącej.

Wkład	Zmienne wejściowe
1,89894	30-dniowa średnia krocząca indeksu Gold and Silver Mining
2,12143	30-dniowa średnia krocząca S&P 500 (minimum)
2,80172	30-dniowa średnia krocząca S&P 500 (zamknięcie)
2,98514	30-dniowa średnia krocząca S&P 500 (maksimum)
3,51706	30-dniowa średnia krocząca indeksu CRB
3,81150	30-dniowa średnia krocząca indeksu ropy
3,99805	30-dniowa średnia krocząca indeksu Dow Jones Transportation
4,43341	30-dniowa średnia krocząca indeksu Dow Jones Utilities

Wygląda na to, że kiedy średnia krocząca zmiennej wejściowej wносиła wkład do rozwiązania, długość średniej nie miała znaczenia.

WSKAŹNIKI TECHNICZNE

Liczba wskaźników technicznych, które można zastosować w sieci, jest niemal nieograniczona. Prawie wszystkie wskaźniki można w jakiś sposób zmodyfikować, zmieniając na przykład przedział czasowy, do którego się je odnosi. Ponadto sygnały kupna i sprzedaży mogą być generowane na skutek przebicia każdego limitu z dowolną dokładnością zaprogramowaną przez projektanta. Na przykład możemy kupować, kiedy 7-dniowy RSI spadnie poniżej 20 punktów i sprzedawać, gdy wzrośnie powyżej 80 lub kupować, kiedy 14-dniowy oscylator stochastyczny spadnie poniżej 15 punktów i sprzedawać, gdy przekroczy poziom 85 punktów.

Aby zaprezentować możliwości zastosowania wskaźników technicznych jako zmiennych wejściowych sieci neuronowych, wyznaczmy wkłady kilku powszechnie używanych wskaźników technicznych. Najpierw przetestujemy 12-dniowy wskaźnik RSI Wildera, a potem dodatkowo zbadamy jego 12-dniową średnią kroczącą, która często sygnalizuje zmiany kierunku.

Tabela 9.12 i diagram 9.15 przedstawiają wkłady owych dwóch wskaźników. Niespodziewanie ich wyniki okazały się bardzo słabe. Wynika to przypuszczalnie stąd, że oba wskaźniki są ze sobą skorelowane, co wprowadza zamęt w obliczenia sieci. Spróbujmy zatem zbadać je pojedynczo. Wyniki testu 12-dniowego RSI ilustrują tabela 9.13 i diagram 9.16.

W pojedynkę RSI spisywał się znacznie lepiej: zajął czwarte miejsce i, jak się zdaje, przyczynił się do powiększenia wkładów innych wskaźników, o czym można się przekonać, porównując diagramy 9.16 i 9.15.

Tabela 9.12 Zestaw podstawowych zmiennych rozszerzony o 12-dniowy wskaźnik RSI i jego 12-dniową średnią kroczącą.

Wkład	Zmienna
1,40279	Indeks CRB
1,73755	Dow Jones Transportation
1,81674	12-okresowy RSI Wildera na bazie kursu zamknięcia S&P 500
1,86036	12-okresowa średnia krocząca RSI Wildera
1,97205	Dow Jones Utilities
2,21270	Indeks Gold and Silver Mining
2,50631	Indeks ropy
2,91393	S&P 500 (minimum)
3,38531	S&P 500 (zamknięcie)
3,98386	S&P 500 (maksimum)




Diagram 9.15 Dane z tabeli 9.12 przedstawione w formie wykresu. Zmienna oznaczona numerem 9 to 12-dniowy RSI, a zmienna 10 to 12-dniowa średnia krocząca 12-dniowego RSI.

Tabela 9.13 Tak przedstawia się sytuacja, gdy do zestawu podstawowych zmiennych dołączymy tylko 12-dniowy RSI. Zwróćmy uwagę, że stanowi on teraz czwartą zmienną pod względem wkładu.

Wkład	Zmienna
2,35697	S&P 500 (kurs minimalny)
2,55498	Dow Jones Transportation
2,84366	Dow Jones Utilities
2,92278	Indeks CRB
2,94794	Indeks Gold and Silver Mining
2,95302	12-dniowy RSI Wildera na bazie kursu zamknięcia S&P 500
3,14279	Indeks ropy
3,56224	S&P 500 (kurs zamknięcia)
3,60003	S&P 500 (kurs maksymalny)




Diagram 9.16 Dane z tabeli 9.13 przedstawione graficznie. Dziewiątą zmienną jest RSI.

Ponadto błąd testowy sieci z dwoma wskaźnikami technicznymi wyniósł 0,00218, podczas gdy w przypadku sieci zawierającej tylko RSI był on równy 0,00190.

Rezultaty testu sieci z 12-dniową średnią kroczącą 12-dniowego RSI przedstawiają tabela 9.14 i diagram 9.17. Wyniki są znacznie lepsze niż dla sieci zawierającej zarówno RSI, jak i jego średnią kroczącą, jednak nie aż tak dobre, jak sieci zawierającej tylko RSI. Zgodnie z oczekiwaniami średni błąd testowy lokował się pomiędzy wartościami dla dwóch pozostałych sieci i wyniósł 0,00206. Na tym etapie rozważań najlepszym rozwiązaniem jest sieć zawierająca tylko 12-dniowy RSI. Analizę można by ciągnąć dalej, testując najpierw RSI o różnych długościach, a następnie różne średnie kroczące każdego z RSI.

Następnie sprawdzimy, czy dobrą zmienną wejściową mogą być wstęgi Bollingera. Wstęgi Bollingera to linie rysowane powyżej i poniżej danych cenowych. Zazwyczaj nakreśla się je w odległości 2 odchyłeń standardowych od 20-okresowej średniej kroczącej. Diagram 9.18 przedstawia wykres indeksu S&P 500 i naniesione na niego wstęgi Bollingera znajdujące się po obu stronach dziennych danych cenowych. Przebiecie wstęg przez wykres ceny prowadzi zwykle, choć nie zawsze, do odwrócenia trendu.

Tabela 9.15 i diagram 9.19 przedstawiają wyniki uczenia sieci za pomocą danych o położeniu dolnej i górnej wstęgi Bollingera. Wstęgi te umieściliśmy w odległości 2 odchyłeń standardowych od 20-dniowej średniej kroczącej S&P 500. Zwróćmy uwagę, że wnoszą one do rozwiązania więcej niż Dow Jones Transportation lub wartość minimalna S&P 500.

Następnie wypróbujemy wskaźnik impetu mierzący zmianę kursu zamknięcia S&P 500 w ciągu ostatnich 12 dni, czyli różnicę między ceną dzisiejszą a ceną sprzed tego okresu. Wyniki tego testu przedstawiają tabela 9.16 i diagram 9.20. Zwróćmy uwagę, że wskaźnik impetu wnosi do rozwiązania dość dużo i zajmuje czwartą pozycję na liście, wyprzedzając między innymi indeksy Gold and Silver Mining, CRB oraz Dow Jones Transportation. Co więcej, jego względny wkład jest o jednostkę większy od wkładu wstęgi Bollingera.

WYBÓR OSTATECZNEGO ZESTAWU ZMIENNYCH WEJŚCIOWYCH

Testując sieć, stworzyliśmy wiele możliwych do wykorzystania mierników, od średnich kroczących i zmiennych opóźnionych do wskaźników technicznych. Teraz musimy wyselekcjonować wąską grupę zmiennych, które w największym stopniu przyczyniają się do rozwiązania problemu. Podstawowy zestaw zmiennych wejściowych przedstawia się następująco:

Kurs maksymalny S&P 500
Kurs minimalny S&P 500

Tabela 9.14 Rezultat dołączenia do podstawowego zestawu zmiennych 12-dniowej średniej kroczącej 12-dniowego RSI. Jak się okazuje, wskaźnik ten nie jest tak dobry, jak sam RSI.

Wkład	Zmienna
2,09485	S&P 500 (minimum)
2,12979	12-dniowa średnia krocząca 12-dniowego RSI Wildera
2,37479	Dow Jones Transportation
2,92374	S&P 500 (zamknięcie)
3,14522	Indeks Gold and Silver Mining
3,18821	Indeks CRB
3,25310	Indeks ropy naftowej
3,52732	Dow Jones Utilities
3,76387	S&P 500 (maksimum)




Diagram 9.17 Dane z tabeli 9.14 przedstawione w postaci graficznej. Dziewiątą zmienną stanowi 12-okresowa średnia krocząca 12-dniowego RSI.



Diagram 9.18 Wykres indeksu S&P 500 ze wstęgami Bollingera (zaznaczonymi strzałkami), które znajdują się powyżej i poniżej danych cenowych.

Kurs zamknięcia S&P 500
Indeks ropy
Indeks Dow Jones Utilities
Indeks CRB
Indeks Gold and Silver Mining

Do tego zbioru dołączymy cztery zmienne, które w połączeniu ze zmiennymi pierwotnymi uzyskały najlepsze wyniki:

Dołączona zmienna	Wkład
10-dniowe opóźnienie CRB	5,11
10-dniowe opóźnienie indeksu Gold and Silver Mining	5,14
10-dniowe opóźnienie indeksu Dow Transportation	5,36
10-dniowe opóźnienie indeksu ropy naftowej	7,45

Ponadto do zbioru zmiennych dodamy 30-dniową średnią kroczącą obrotów. Zwróćmy uwagę, że jest to jedyna średnia krocząca oraz że w sieci brak wskaźników technicznych. Wkłady wszystkich wyselekcjonowanych zmiennych opóźnionych były wyższe od 5,00; były to jedyne

Tabela 9.15 Względne wkłady zestawu podstawowych zmiennych wejściowych poszerzonego dodatkowo o wstęgi Bollingera. Zwróćmy uwagę, że wstęgi lokują się na siódmym i ósmym miejscu pod względem wkładu.

Wkład	Zmienna
1,84469	S&P 500 (minimum)
2,41241	Dow Jones Transportation
2,51149	Dolna wstęga Bollingera (20-dniowa średnia krocząca kursu zamknięcia S&P 500, 2 odchylenia standardowe)
2,56522	Górna wstęga Bollingera (20-dniowa średnia krocząca kursu zamknięcia S&P 500, 2 odchylenia standardowe)
2,57661	S&P 500 (kurs zamknięcia)
2,76961	S&P 500 (maksimum)
3,33409	Dow Jones Utilities
3,74759	Indeks ropy naftowej
3,87163	Indeks Gold and Silver Mining
4,08155	Indeks CRB




Diagram 9.19 Dane z tabeli 9.15 przedstawione w postaci graficznej. Wstęgi Bollingera to zmienne oznaczone numerami 9 i 10.

Tabela 9.16 Rezultat dołączenia do sieci 12-okresowego wskaźnika impetu liczonego na podstawie kursu zamknięcia S&P 500. Wskaźnik ten lokuje się na czwartym miejscu pod względem wkładu.

Wkład	Zmienna
2,22728	S&P 500 (kurs minimalny)
2,82420	Dow Jones Transportation
3,11503	CRB
3,20623	S&P 500 (kurs zamknięcia)
3,32080	Indeks Gold and Silver Mining
3,50186	Zmiana kursu zamknięcia S&P 500 w ciągu 12 dni
3,53974	Indeks ropy
3,55968	Dow Jones Utilities
3,59859	S&P 500 (kurs maksymalny)




Diagram 9.20 Dane z tabeli 9.16 przedstawione w formie wykresu. Dziewiątą zmienną jest wskaźnik impetu.

Tabela 9.17 Wkłady w prawie ukończonej sieci. Sieć składa się z 13 zmiennych wejściowych. Jak wyjaśniliśmy w tekście, z ostatecznej wersji sieci zostanie usunięte opóźnienie indeksu Gold and Silver Mining.

Wkład	Zmienna
1,96568	Wartość indeksu Gold and Silver Mining sprzed 10 dni
2,65485	Kurs zamknięcia S&P 500
2,68148	Kurs maksymalny S&P 500
2,84308	Kurs minimalny S&P 500
3,07333	Dow Jones Transportation
3,33825	30-dniowa średnia krocząca obrotów
3,34365	Indeks CRB
3,65791	10-dniowe opóźnienie CRB
3,73944	Gold and Silver Mining
3,82980	Dow Jones Utilities
4,70225	Indeks ropy
4,72849	10-dniowe opóźnienie indeksu ropy
4,75725	10-dniowe opóźnienie Dow Jones Transportation




Diagram 9.21 Dane z tabeli 9.17 przedstawione graficznie. Zmienna 11 to indeks Gold and Silver Mining.




Diagram 9.22 Wykres zależności między błędem średniokwadratowym a współczynnikiem wygładzającym.

zmienne, których wkłady przekraczały tę wartość. Wkłady wskaźników technicznych zawierały się w przedziale od 2,5 do 3,5, a średnich kroczących od 3,00 do 4,00.

Wszystkie owe zmienne przetestowaliśmy razem na sieci ze wsteczną propagacją błędów. Wyniki testu przedstawia tabela 9.17 i diagram 9.21. Zwróćmy uwagę, że wkład zmiennej 11, czyli 10-dniowego opóźnienia indeksu Gold and Silver Mining, jest znacznie niższy od wkładów pozostałych zmiennych. Zmienną tę pominiemy w ostatnim treningu, albowiem chcemy użyć wyłącznie zmiennych o największej wartości prognostycznej.

SIEĆ DOCELOWA

Jak wykazaliśmy wcześniej, sieci oparte na szeregu danych finansowych działają najlepiej, gdy zastosujemy architekturę realizującą regresję uogólnioną (GRNN), stąd też ostateczny zestaw zmiennych zainstalowaliśmy na sieci tego typu. Liczba próbek testowych spoza zbioru uczącego wynosiła 96. Diagram 9.22 przedstawia wykres zależności między średnim kwadratem błędów a współczynnikiem wygładzającym sieci. W trakcie treningu sieć dobiera czynnik wygładzający, testuje go, następnie dobiera nowy, również go testuje, i cały proces trwa tak długo, aż uda się znaleźć najniższy błąd średniokwadratowy.

Współczynnik wygładzający sieci GRNN wyniósł 0,04551, a błąd średniokwadratowy 0,000505. Średni błąd wyniósł 1,965. Dla porównania, gdy te same zmienne wejściowe zainstalowaliśmy na trzywarstwowej sieci ze wsteczną propagacją błędów złożoną z 12 neuronów ukrytych, średni błąd wyniósł 4,038, tak więc sieć GRNN okazała się ponad dwa razy dokładniejsza. Fakt ten zasługuje na szczególną uwagę, ponieważ to właśnie sieć ze wsteczną propagacją błędów posłużyła nam za narzędzie oceny i selekcji zmiennych wejściowych.

ALGORYTM GENETYCZNY – SIEĆ GRNN

Firma Ward Systems Group wypuściła ostatnio wersję 2.0 programu *Neural Shell*, która zawiera model sieci oparty na nowym algorytmie genetycznym (GA). W połączeniu z sieciami PNN i GRNN, wyznacza on indywidualny współczynnik wygładzający dla każdej ze zmiennych wejściowych oraz współczynnik wygładzający dla całej sieci. Mówi się, że model ten pozwala dwukrotnie zwiększyć dokładność, gdy stosować go z sieciami operującymi szeregami czasowymi. Zawiera on również funkcję wrażliwości, mierzącą wkład każdej zmiennej, czyli narzędzie, którego pozbawione są tradycyjne sieci PNN i GRNN. Ceną za wzrost dokładności jest wydłużony czas treningu, który wynosi kilka godzin, a nie, jak wcześniej, 2–3 minuty.

Na sieci GA-GRNN zainstalowaliśmy te same zmienne, które zastosowaliśmy w połączeniu z ostateczną wersją sieci opartą na architekturze GRNN. Błąd średniokwadratowy wyniósł 0,0004181, a błąd średni 1,843. Wprawdzie nastąpiła 20-procentowa poprawa, ale nie udało się podwoić dokładności. Jednak przebieg funkcji wrażliwości sygnalizował, że można usunąć kurs zamknięcia S&P 500, indeks Dow Jones 30 oraz wskaźnik TRIN. Kiedy tego dokonaliśmy, błąd średniokwadratowy spadł do 0,000235, a funkcja wrażliwości zasygnalizowała, że do poprawy wyników przyczyni się również usunięcie OEX. Usunęliśmy więc zbędny indeks i sieć poddaliśmy powtórnemu treningowi. Kolejna analiza funkcji wrażliwości wykazała, że można wyeliminować również indeks Dow Jones Transportation, co też uczyniliśmy, a następnie raz jeszcze powtórzyliśmy trening. Tym razem okazało się, że konieczne jest usunięcie opóźnienia indeksu Gold and Silver Mining.

Po przeprowadzeniu treningu sieć przestała zgłaszać zastrzeżenia co do pozostałych zmiennych. Błąd średniokwadratowy wyniósł 0,0002992, czyli był blisko dwa razy mniejszy od błędu sieci GRNN (0,0004551). Niższy był również błąd średni: wyniósł 1,53, podczas gdy dla sieci GRNN osiągał poziom 1,843. Diagram 9.23 przedstawia błąd sieci testowanej za pomocą świeżych danych.

Ujmując rzecz inaczej, gdy prognozowaliśmy S&P 500 na *dziesięć* dni naprzód, w 38 procent przypadków wartość prognozowana nie różniła się od wartości rzeczywistej o więcej niż jeden punkt indeksu. W 76

	A	B	C
	Actual(1)	Network(1)	Act-Net(1)
1			
2			
3			
4			
5	360.529998779297	353.294708251953	7.235290527344
6	360.309997558594	357.920196533203	2.389801025391
7	366.500000000000	366.160888671875	0.339111328125
8	367.010009765625	369.484771728516	-2.474761962891
9	356.910003662109	360.088043212891	-3.178039550781
10	370.399993896484	368.547821044922	1.852172851563
11	364.989990234375	365.711242675781	-0.721252441406
12	364.940002441406	363.374633789063	1.565368652344
13	366.809997558594	367.782897949219	-0.972900390625
14	367.760009765625	367.006958007813	0.753051757813
15	370.290008544922	368.756195068359	1.533813476563
16	353.820007324219	352.563262939453	1.256744384766
17	353.190002441406	356.158172607422	-2.968170166016
18	376.850006103516	372.762023925781	4.087982177734
19	385.750000000000	386.841888427734	-1.091888427734
20	386.730010986328	386.431457519531	0.298553466797
21	382.459991455078	384.964874267578	-2.504882812500
22	385.149993896484	384.944305419922	0.205688476563
23	378.790008544922	378.052581787109	0.737426757813
24	383.239990234375	382.199035644531	1.040954589844
25	381.269989013672	375.641418457031	5.628570556641
26	385.769989013672	386.662506103516	-0.892517089844
27	391.609985351563	391.492584228516	0.117401123047
28	392.809997558594	390.733764648438	2.076232910156
29	390.059997558594	389.030151367188	1.029846191406
30	381.500000000000	381.180969238281	0.319030761719
31	387.359985351563	385.000854492188	2.359130859375
32	390.160003662109	389.026611328125	1.133392333984
33	395.899993896484	393.755859375000	2.144134521484
34	390.230010986328	391.077148437500	-0.847137451172
35	384.029998779297	385.232543945313	-1.202545166016
36	388.630004882813	389.655578613281	-1.025573730469
37	382.049987792969	386.282958984375	-4.232971191406
38	368.570007324219	373.397491455078	-4.827484130859

Diagram 9.23 Błąd sieci wyrażony w punktach indeksu S&P 500 wyliczony w testach na bazie świeżych danych. Pierwsza kolumna zawiera wartość rzeczywistą, druga wartość prognozowaną, a trzecia różnicę między pierwszymi dwoma kolumnami. Zwróćmy uwagę, że jest to prognoza na 10 dni naprzód.

	A	B	C
	Actual(1)	Network(1)	Act-Net(1)
1			
2			
3			
4			
5	364.279998779297	362.152130126953	2.127868652344
6	353.109985351563	356.289672851563	-3.179687500000
7	364.279998779297	363.466827392578	0.813171386719
8	366.390014648438	366.526123046875	-0.136108398438
9	368.279998779297	369.120361328125	-0.840362548828
10	372.359985351563	371.735626220703	0.624359130859
11	363.450012207031	364.362365722656	-0.912353515625
12	365.660003662109	364.732727050781	0.927276611328
13	357.730010986328	356.172149658203	1.557861328125
14	363.970001220703	363.599639892578	0.370361328125
15	363.799987792969	366.048217773438	-2.248229980469
16	355.559997558594	358.859527587891	-3.299530029297
17	354.839996337891	355.485748291016	-0.645751953125
18	358.869995117188	358.247985839844	0.622009277344
19	388.880004882813	387.594970703125	1.285034179688
20	392.829986572266	389.974639892578	2.855346679688
21	380.209991455078	383.875762939453	-3.665771484375
22	384.269989013672	383.539123535156	0.730865478516
23	384.649993896484	383.187225341797	1.462768554688
24	380.390014648438	382.448181152344	-2.058166503906
25	378.040008544922	378.218780517578	-0.178771972656
26	380.649993896484	380.900146484375	-0.250152587891
27	383.540008544922	384.393402099609	-0.853393554688
28	391.019989013672	390.416442871094	0.603546142578
29	388.660003662109	390.437500000000	-1.777496337891
30	385.230010986328	386.936645507813	-1.706634521484
31	381.070007324219	380.756439208984	0.313568115234
32	387.070007324219	386.716979980469	0.353027343750
33	384.890014648438	384.777160644531	0.112854003906
34	392.160003662109	391.416137695313	0.743865966797
35	389.709991455078	387.924865722656	1.785125732422
36	387.390014648438	386.829376220703	0.560638427734
37	392.299987792969	388.498504638672	3.801483154297
38	376.700012207031	377.882629394531	-1.182617187500
39	377.359985351563	375.857482910156	1.502502441406

Diagram 9.24 Dane przypominają nieco dane z diagramu 9.23, tyle że tym razem prognoza sporządzana jest tylko na 5 dni. Są one oczywiście dokładniejsze od danych z poprzedniego diagramu reprezentujących prognozę 10-dniową.

procent prognoz różnica ta wynosiła nie więcej niż dwa, a w 93 procent – nie więcej niż cztery punkty.

Następnie ów zredukowany zestaw zmiennych zainstalowaliśmy na sieci typu GA-GRNN zaprogramowanej na prognozowanie S&P 500 na pięć dni naprzód. Wyniki były imponujące. Błąd średniokwadratowy wyniósł 0,000217, a błąd średni 1,268 punktu indeksu. W 56 procent przypadków różnica między wartością rzeczywistą a prognozowaną nie przekraczała jednego, w 77 procent – dwóch, a w 99 procent – czterech punktów. Dane na temat błędów można prześledzić na diagramie 9.24.

INWESTOWANIE NA PODSTAWIE SIECI NEURONOWYCH

Postęp w dziedzinie architektur i algorytmów uczenia sieci neuronowych jest niezwykle szybki. W przyszłości będą one stanowić fundament automatycznego systemu inwestycyjnego. Jednak obecnie najlepiej stosować je w połączeniu z innym wskaźnikiem bądź większą ich liczbą, tak, by pełniły funkcję weryfikatora.

System służący do gry na indeksie S&P 500 lub OEX mógłby składać się ze wstęg Bollingera (wskaźnika podstawowego), 5-dniowego oscylatora stochastycznego lub 7-dniowego RSI (wskaźnika potwierdzającego) oraz 5- i 10-dniowych prognoz wygenerowanych przez sieć neuronową weryfikujących pierwsze dwa wskaźniki. Schemat postępowania wyglądałby następująco: czekamy aż kurs S&P 500 przebieje górną wstęgę Bollingera wykreśloną w odległości 2 odchyleń standardowych od 20-dniowej średniej kroczącej. Oznacza to zmianę trendu ze wzrostowego na spadkowy i pozwala przygotować się na sygnał sprzedaży. Następnie czekamy na potwierdzenie wykupienia przez, w zależności od dokonanego wyboru, oscylator stochastyczny lub wskaźnik RSI. Sprawdzamy zarówno 5-, jak i 10-dniową prognozę sieci neuronowej. Jeżeli na przykład sieć przewiduje, że w ciągu 5 dni nastąpi spadek o 7, a w ciągu 10 dni o 12 punktów, to oznacza to, że właśnie nadarzyła się doskonała okazja do sprzedaży. Jeśli jednak prognoza sieci sygnalizuje, że rynek pójdzie w górę o 7 i 12 punktów, należy wstrzymać się z decyzją tak długo, aż sieć i wskaźniki techniczne zaczną generować spójne sygnały.

W przypadku, gdy handlujemy opcjami, warunkiem wyboru odpowiedniej strategii jest znajomość przybliżonej przyszłej wartości waloru będącego przedmiotem kontraktu opcyjnego. Istnieje wprawdzie wiele doskonałych programów do ustalania właściwej strategii, ale ich wartość jest ściśle uzależniona od jakości prognoz użytkownika odnośnie do czasu i wartości. Prognozy sieci neuronowych powinny przewyższać pozostałe metody ustalania szacowania wartości waloru będącego przedmiotem opcji na 5 lub 10 dni naprzód.

Ważne jest, by stosować prognozy krótko- i długoterminowe, ponieważ te pierwsze są dokładniejsze i służą do weryfikacji drugich. Jeżeli

prognoza długoterminowa mówi, że nastąpi wzrost o 10 punktów, a krótkoterminowa, że w tym samym dniu rynek będzie się znajdował o 10 punktów niżej, najlepiej albo dać wiarę prognozie krótkoterminowej, albo powstrzymać się od działania tak długo, aż sytuacja stanie się bardziej klarowna.

Jeżeli prognozy 5- i 10-dniowe przewidują, że nastąpi wzrost, a wskaźniki techniczne sygnalizują to samo, wchodzimy na rynek.

Dodatek

Studium przypadku

W celu zilustrowania w książce różnych zagadnień posługiwaliśmy się siecią określaną mianem *sieci odniesienia*. Wybraliśmy ją dlatego, że względnie szybko się uczyła, jak również dlatego, że opierała się na najpopularniejszych i dobrze znanych algorytmach: algorytmie wstecznej propagacji błędów i algorytmie uczenia *momentum*. Ponadto, sieć osiągała dość dobre rezultaty.

Bazując na lekcjach udzielonych w książce, na podstawie tych samych danych stworzyliśmy sieć, której osiągi znacznie przewyższają osiągi sieci odniesienia. Liczbę zmiennych wejściowych zwiększyliśmy do dwunastu, dołączając 20-dniowe średnie kroczące wszystkich sześciu pierwotnych zmiennych. Oprócz tego, dwanaście zmiennych zastosowaliśmy nie na popularnej sieci ze wsteczną propagacją błędów, lecz na sieci realizującej regresję uogólnioną (GRNN).

Prognozowane wartości wyjściowe i błędy przedstawiają diagramy D.1 i D.2. Tabele D.1 i D.2 zawierają statystyki obu sieci. Wyniki nowej sieci są niemal o rząd wielkości lepsze od wyników sieci pierwotnej.

	A	B	C
1	Actual(1)	Network(1)	Act-Net(1)
2	450.50	450.05	0.45
3	450.08	449.90	0.18
4	448.64	450.69	-2.05
5	448.23	450.10	-1.87
6	448.04	449.97	-1.93
7	447.94	450.05	-2.11
8	448.41	449.58	-1.17
9	448.66	448.74	-0.08
10	449.22	448.59	0.63
11	448.38	448.37	0.01
12	447.29	448.26	-0.97
13	447.57	448.72	-1.15
14	447.55	448.93	-1.38
15	446.92	449.28	-2.36
16	446.55	447.90	-1.35
17	445.75	447.08	-1.33
18	446.30	447.45	-1.15
19	445.31	447.31	-2.00
20	445.34	446.88	-1.54
21	445.18	446.73	-1.55
22	445.70	446.21	-0.51
23	445.85	447.06	-1.21
24	446.02	446.53	-0.51
25	444.22	446.74	-2.52
26	445.79	446.58	-0.79
27	446.75	446.96	-0.21
28	447.49	447.01	0.48
29	447.08	447.17	-0.09
30	447.08	446.15	0.93
31	447.31	447.13	0.18
32	446.14	447.86	-1.72
33	446.48	448.25	-1.77
34	446.26	447.94	-1.68
35	446.46	447.95	-1.49
36	446.23	448.16	-1.93
37	446.39	446.76	-0.37
38	447.18	447.12	0.06

Diagram D.1 Wartości wyjściowe i błąd pierwotnej sieci odniesienia. Kolumna A zawiera dane rzeczywiste zgromadzone przed treningiem, kolumna B – wartości prognozowane przez sieć, a kolumna C błąd, czyli różnicę między wartościami z kolumn A i B. Błąd średniokwadratowy wyniósł 2,447, błąd średni 1,265 procent. Trening trwał 5 minut i 42 sekundy.

	A	B	C
1	Actual(1)	Network(1)	Act-Net(1)
2			
3			
4			
5			
6			
7			
8			
9			
10			
11			
12			
13			
14			
15			
16			
17			
18			
19			
20			
21	445.18	445.70	-0.52
22	445.70	445.70	0.00
23	445.85	445.85	0.00
24	446.02	445.99	0.03
25	444.22	444.29	-0.07
26	445.79	445.77	0.02
27	446.75	446.80	-0.05
28	447.49	447.34	0.15
29	447.08	447.19	-0.11
30	447.08	447.08	0.00
31	447.31	446.17	1.14
32	446.14	446.19	-0.05
33	446.48	446.39	0.09
34	446.26	446.35	-0.09
35	446.46	446.40	0.06
36	446.23	446.24	-0.01
37	446.39	446.40	-0.01
38	447.18	447.07	0.11
39	446.44	446.59	-0.15
40	447.00	446.94	0.06
41	446.76	446.65	0.11
42	446.52	446.37	0.15
43	446.20	446.20	-0.00
44	444.11	444.12	-0.01
45	444.51	444.53	-0.02
46	446.58	446.37	0.21
47	445.79	445.86	-0.07
48	445.26	445.48	-0.22

Diagram D.2 Wartości wyjściowe i błąd zmodyfikowanej sieci odniesienia. Liczbę zmiennych wejściowych podwoiliśmy, dodając 20-okresowe średnie kroczące każdej ze zmiennych. Zmienne zainstalowaliśmy na sieci realizującej regresję uogólnioną (GRNN). Średni błąd spadł z 1,265 procent do 0,092 procent, a błąd średniokwadratowy z 2,447 do 0,52, podczas gdy czas treningu uległ skróceniu z ponad 5 minut do 32 sekund. Błąd średniokwadratowy wyniósł 0,052, błąd średni 0,092 procent, a trening trwał 32 sekundy.

Tabela D.1 Porównanie zmiennych wejściowych pierwotnej i nowej sieci.

	Sieć pierwotna	Nowa sieć złożona z 12 zmiennych wejściowych
Zmienne wejściowe	ADV, DEC, TICK, TRIN, SPY, YXY	ADV, DEC, TICK, TRIN, SPY, YXY, MA(20)-ADV, MA(20)-DEC, MA(20)-TICK, MA(20)-TRIN, MA(20)-SPY, MA(20)-YXY

Tabela D.2 Porównanie statystyk sieci ze wsteczną propagacją błędu i sieci GRNN.

Typ sieci Algorytm uczenia	Wsteczna propagacja błędu <i>Momentum</i> (0,05; 0,5)	Sieć realizująca regresję uogólnioną
Czas treningu	5:42	0:32
Współczynnik determinacji	0,9262	0,9984
Błąd średniokwadratowy	2,447	0,052
Średni błąd	1,265	0,092

Słownik

Architektura. Schemat opisujący liczbę warstw sieci neuronowej, rodzaje funkcji przeniesienia dla każdej warstwy, liczbę neuronów w poszczególnych warstwach oraz powiązania między warstwami.

Błąd bezwzględny. Wartość bezwzględna różnicy między wartością wyjściową prognozowaną przez sieć a wartością rzeczywistą.

Epoka. Pełna prezentacja całego zbioru próbek uczących.

Horyzont czasowy. Okres, na który sporządza się prognozę szeregu czasowego.

Impet. Impet papieru wartościowego to stosunek ceny sprzed kilku dni do ceny obecnej.

Indeks siły względnej (RSI). Wskaźnik mierzący wewnętrzną siłę danego waloru. Gdy porównujemy dwa walory, określa się go mianem komparatywnej siły względnej.

Metoda spadku gradientu. Proces modyfikacji wag i obciążeń; zmiany są proporcjonalne do pochodnych błędu sieci względem owych wag i obciążeń. Ma to na celu minimalizację błędu sieci.

Minimum globalne. Najniższa wartość funkcji w całej jej dziedzinie. Metoda spadku gradientu polega na korygowaniu wag i obciążeń w celu wyznaczenia globalnego minimum błędu sieci.

- Minimum lokalne.** Wartość minimalna funkcji w wycinku jej dziedziny. Minimum lokalne może nie pokrywać się z minimum globalnym.
- Neuron.** 1. Podstawowy budulec mózgu, komórka, której działanie opiera się na danych płynących z pięciu zmysłów.
2. Neuron biologiczny wymodelowany za pomocą programu komputerowego, którego danymi wejściowymi są liczby.
- Opóźnienie.** Liczba pokazująca, o ile okresów cena lub średnia krocząca jest opóźniona względem danych pierwotnych.
- Oscylator stochastyczny.** Oscylator porównujący amplitudę wahań cen waloru w ciągu ostatnich n okresów z ceną bieżącą.
- Próbka.** Pojedynczy rekord (wiersz) zmiennych stanowiący dla sieci podstawę prognoz lub klasyfikacji. W skład próbki wchodzi zmienne wejściowe i wyjściowe.
- Próbka ucząca.** Próbkę danych składającą się ze zmiennych wejściowych (w przypadku sieci nadzorowanych również ze zmiennych wyjściowych) służącą do uczenia sieci.
- Punkt odniesienia.** Przedmiot lub proces, do którego porównuje się inne przedmioty lub procesy. W wielu przypadkach punkt odniesienia reprezentuje najlepszy możliwy rezultat. Może być ideałem, realistycznym celem bądź średnim wynikiem stosowanym w celu porównania.
- Sieci realizujące regresję uogólnioną (GRNN).** Sieci trzywarstwowe, w których na każdą próbkę uczącą przypada jeden neuron ukryty. Ich działanie opiera się na pomiarze odległości danej próbki od próbek ze zbioru uczącego w przestrzeni n -wymiarowej, gdzie n oznacza liczbę zmiennych wejściowych dla postawionego problemu. Sieci tego rodzaju uczą się niezmiennie szybko.
- Sieć neuronowa.** Oparty na sztucznej inteligencji program komputerowy przeznaczony do rozwiązywania zadanych problemów, który uczy się metodą prób i błędów.
- Sieć rekurencyjna.** Sieć, w której warstwa wejściowa, ukryta lub wyjściowa stanowi sprzężenie zwrotne dla warstwy dodatkowej. Sieci tego rodzaju umieją zapamiętywać wzory, tak więc doskonale spisują się w połączeniu z szeregami czasowymi danych.
- SPX.** Oznaczenie indeksu S&P 500 Cash.
- SPY.** Oznaczenie indeksu S&P 500 Futures.
- Szereg czasowy.** Ciąg danych opisujący właściwości danego przedmiotu w regularnych odstępach czasu. Przykładem są tu rejestrowane codziennie ceny na rynku akcji.
- Sztuczna sieć neuronowa (ANN).** Program komputerowy mający za zadanie symulowanie zdolności ludzkiego mózgu do klasyfikacji wzorów lub prognozowania przyszłości na bazie doświadczeń z przeszłości.
- Średni błąd.** Średnia ze współczynników błędu dla wszystkich próbek.
- Średnia krocząca (MA).** Metoda obliczania średniej ceny waloru w danym okresie. Wyznacza się ją, sumując cenę obecną i $n - 1$ wartości poprzednich i dzieląc następnie przez n . Podążając za zmianami ceny waloru w czasie, średnia krocząca wzrasta lub maleje. Symbol MA(5) oznacza 5-okresową średnią krocząca. Chociaż średnie kroczące

- odnoszą się zwykle do cen walorów, można je również zastosować we wskaźnikach takich jak RSI.
- Tick.** Różnica liczby transakcji zawartych po cenie wyższej i liczby transakcji zawartych po cenie niższej.
- Trening.** Proces, w którym wagi znajdujące się wewnątrz sieci neuronowej korygowane są w taki sposób, by sieć generowała dla zadanego zbioru zmiennych wejściowych poprawne dane wyjściowe. Trening często określa się mianem „uczenia”.
- TRIN.** Indeks znany także pod nazwą wskaźnika Armsa. Informuje on, czy aktywność rynku ogniskuje się na akcjach zwyżkujących, czy też zniżkujących.
- Warstwa.** Zgrupowanie bloków (czyli grup neuronów) w sieci. Warstwa może się składać z jednego bądź kilku bloków. Każda sieć zawiera tylko jedną warstwę wejściową i jedną warstwę wyjściową. Warstw ukrytych może być kilka.
- Wskaźnik emisji zniżkujących (DEC).** Liczba walorów, których cena w danym okresie spadła.
- Wskaźnik emisji zwyżkujących (ADV).** Liczba papierów wartościowych, których kurs w danym czasie wzrósł.
- Wskaźnik konwergencji i dywergencji średnich kroczących (MACD).** Oblicza się go, odejmując od 26-dniowej średniej kroczącej analogiczną średnią 12-dniową. 9-dniową średnią krocząca różnicy nanosi się na linię równowagi, gdzie sygnalizuje przecięcie się dwóch średnich kroczących.
- Współczynnik determinacji.** Miernik statystyczny stosowany zwykle w analizie regresji wielokrotnej. Porównuje on dokładność modelu z dokładnością prostego modelu odniesienia, w którym wartość prognozowana stanowi po prostu średnią ze wszystkich próbek. Współczynnik determinacji dla doskonałych prognoz wynosi 1. Współczynniki determinacji dla słabych prognoz przyjmują wartości bliskie zera.
- Współczynnik korelacji.** Statystyczny miernik siły zależności między rzeczywistymi a prognozowanymi zmiennymi wyjściowymi. Współczynnik korelacji przybiera wartości od -1 do $+1$. Im bliższy jest wartości $+1$, tym silniejsza liniowa zależność dodatnia; im bliższy wartości -1 , tym silniejsza liniowa zależność ujemna. Kiedy współczynnik korelacji waha się w granicach 0, zależność nie istnieje.
- Współczynnik momentum.** Duże współczynniki uczenia często prowadzą do oscylacji zmian wag, w wyniku czego proces uczenia nie może dobiec końca, bądź też model generuje rozwiązanie nieoptymalne. Jednym ze sposobów umożliwiających szybsze uczenie bez oscylacji jest powiązanie zmiany wagi ze zmianą poprzednią w celu uzyskania efektu wygładzania. Współczynnik *momentum* wskazuje, jaką część ostatniej zmiany wagi dodaje się do nowej zmiany wagi.
- Współczynnik uczenia.** W trakcie procesu uczenia, za każdym razem, gdy sieci prezentowana jest próbka, wagi prowadzące do węzła wyjściowego ulegają niewielkiej modyfikacji w taki sposób, by zmniejszyć błąd podczas kolejnej prezentacji tej samej próbki. Siła modyfikacji wagi równa się iloczynowi współczynnika uczenia i błędu.

Współczynnik wkładu. Liczba przypisana każdej zmiennej wejściowej stanowiąca przybliżony miernik wagi tej zmiennej dla prognozy zmiennej wyjściowej sieci, w stosunku do pozostałych zmiennych wejściowych tej samej sieci. Im wyższa liczba, tym większy wkład zmiennej do prognozy lub klasyfikacji.

Wsteczna propagacja błędu (*back-propagation*). Architektura sieci neuronowych, w której porównywanie wartości wyjściowej prognozowanej przez sieć z wartością rzeczywistą pełni funkcję sprzężenia zwrotnego korygującego proces uczenia.

Wstęgi Bollingera. Koperta rysowana jako wartość odległości odchylenia standardowego powyżej i poniżej średniej kroczącej. Zazwyczaj nanosi się je w odległości 2 odchylen standardowych, a długość średniej kroczącej wynosi 20 okresów.

YXY. Oznaczenie indeksu Dow Jones 100 (NYSE).

Zdolność uogólniania. Własność sieci, z którą mamy do czynienia wówczas, gdy wyjście dla nowych wektorów wejściowych jest zbliżone do wyjścia dla podobnych wektorów wejściowych ze zbioru uczącego.

Zmienna wejściowa. Zmienna, która służy sieci do celów klasyfikacji lub prognozowania. Naukowcy określają ją mianem zmiennej niezależnej.

Zmienna wyjściowa. Wartość lub wartości, które ma za zadanie prognozować sieć lub, w przypadku, gdy sieć służy do klasyfikacji próbek, wartości będące podstawą klasyfikacji.

Bibliografia

- Abramowitz Milton, Irene A. Stegun (red.), *Handbook of Mathematical Functions*, Dover Publications, New York 1972.
- Adler P.A., P. Adler, *The Social Dynamics of Financial Markets*, JAI Press, Greenwich, CT 1984.
- Anderson James A., Edward Rosenfeld (red.), *Neurocomputing*, MIT Press, Cambridge, Mass. 1987.
- Anderson James A., Andras Pellionisz, Edward Rosenfeld (red.), *Neurocomputing 2*, MIT Press, Cambridge, Mass. 1990.
- Anderson Philip W., Kenneth Arrow, David Pines (red.), *The Economy as an Evolving Complex System*, Santa Fe Institute Proceedings, vol. 5, Addison-Wesley, Redwood City, CA 1988.
- Ariel Robert A., „High Stock Returns before Holidays: Existence and Evidence on Possible Causes”, *Journal of Finance*, vol. 45, no. 5, December 1990, s. 1611–1626.
- Azoff M., „Neural Network Principal Components Preprocessing and Diffraction Tomography”, *Neural Computing and Applications*, vol. 1, 1993, s. 107–114.
- Azoff E.M., „Reducing Error in Neural Network Time Series Forecasting”, *Neural Computing and Applications*, vol. 1, 1993, s. 240–247.
- Babcock Bruce Jr., *The Dow Jones-Irwin Guide to Trading Systems*, Dow Jones-Irwin, Homewood 1989.

- Bailey T.J., *The Elements of Stochastic Processes with Applications to the Natural Sciences*, John Wiley, New York 1964.
- Balsara Nauzer J., *Money Management Strategies for Future Traders*, John Wiley, New York 1992.
- Band R.E., *Contrary Investing*, Viking Penguin, New York 1986.
- Battiti Roberto, „First- and Second-Order Methods for Learning, Between Steepest Descent and Newton's Method”, *Neural Computation*, vol. 4, 1992, s. 141–166.
- Battley Nick, *An Introduction to Commodity Futures and Options*, McGraw-Hill, London 1989.
- Bergenson Karl, Donald C. Wunsch, „A Commodity Trading Model Based on a Neural Network-Expert System Hybrid”, *Proc. IJCNN*, vol. 1, Seattle 1991, s. 289–293, IEEE, Piscataway, NJ 1991.
- Bloomfield Peter, *Fourier Analysis of Time Series*, John Wiley, New York 1976.
- Blum Adam, *Neural Networks in C++*, John Wiley, New York 1992.
- Boashash Boualem, „Estimating and Interpreting the Instantaneous Frequency of a Signal-Part 2: Algorithms and Applications”, *Proceedings of the IEEE*, vol. 80, no. 4, April 1992, s. 540–568.
- Bourlard H., Y. Kamp, „Autoassociation by Multilayer Perceptrons and Singular Value Decomposition”, *Biological Cybernetics*, vol. 59, 1988, s. 291–294.
- Brock William, Josef Lakonishok, Blake LeBaron, „Simple Technical Trading Rules and the Stochastic Properties of Stock Returns”, *Social Systems Research Institute Workshop Series*, no. 9022, October 1990, University of Wisconsin, Madison, WI.
- Brock William A., „Causality, Chaos, Explanation and Prediction in Economics and Finance”, w: John L. Casti, Anders Karlquist (red.), *Beyond Belief: Randomness, Prediction and Explanation in Science*, rozdz. 10, CRC Press, Boca Raton, FL 1991.
- Brock William A., David A. Hsieh, Blake LeBaron, *A Test for Nonlinear Dynamics*, MIT Press, Cambridge, Mass. 1990.
- Burke Gibbons, „The Computerised Trader”, *Futures*, vol. 21, s. 74, May 1992; s. 68, July 1992.
- Burke Gibbons, „Perils, Pitfalls and Stumbling Blocks”, *Futures*, vol. 22, no. 3, March 1993, s. 30–34.
- Burrascano P., „Learning Vector Quantization for the Probabilistic Neural Network”, *IEEE Transactions on Neural Networks*, 2, July 1991, s. 458–461.
- Burton Robert M. Jr., George J. Mpitos, „Event-Dependent Control of Noise Enhances Learning in Neural Networks”, *Neural Networks*, vol. 5, 1992, s. 627–637.
- Callen Earl, Don Shapero, „A Theory of Social Imitation”, *Physics Today*, July 1974, s. 23–28.
- Casdagli M., S. Eubank (red.), *Nonlinear Modeling and Forecasting*, Sante Fe Institute Proceedings, vol. 12, Addison-Wesley, Redwood City, CA 1992.
- Casti John L., *Searching for Certainty*, Morrow, New York 1991.
- Caudill M., C. Butler, *Understanding Neural Networks: Computer Explorations*, vol. 1-2, MIT Press, Cambridge, Mass. 1992.

- Caudill M., *Neural Networks Primer*, Miller Freeman Publications, San Francisco 1989.
- Chakraborty K. i in., „Forecasting the Behaviour of Multivariate Time Series Using Neural Networks”, *Neural Networks*, vol. 5, 1992, s. 961–970.
- Chen J.R., P. Mars, „Stepsize Variation Methods for Accelerating the Back-propagation Algorithm”, *Proc. IJCNN Washington 1990*, vol. 1, IEEE, New York 1990, s. 601–604.
- Chen Ping, „Emphirical and Theoretical Evidence of Economic Chaos”, *System Dynamics Review*, 4, 1988, s. 81–108.
- Chen S., C.F.N. Cowan, P.M. Grant, „Orthogonal Least Squares Learning Algorithm for Radial Basis Function Networks”, *IEEE Transactions on Neural Networks*, vol. 2, no. 2, March 1991, s. 302–309.
- Cootner P. (red.), *The Random Character of Stock Market Prices*, MIT Press, Cambridge, Mass. 1964.
- DARPA, *Neural Network Study*, MIT Lincoln Laboratories, Lexington 1988.
- Dayhoff Judith, *Neural Network Architectures: An Introduction*, Van Nostrand Reinhold, New York 1990.
- Dimson E. (red.), *Stock Market Anomalies*, Cambridge University Press, Cambridge 1988.
- Mark Douglas, *The Disciplined Trader*, NYIF, New York 1990.
- Dreman David M., *The New Contarian Investment Strategy*, Random House, New York 1982.
- Duda R., P. Hart, *Pattern Classification and Scene Analysis*, wydanie drugie, John Wiley, New York 1993.
- Dwyer G.P., R.W. Hafer (red.), *The Stock Market: Bubbles, Volatility and Chaos*, Kluwer Academic, Lancaster 1989.
- Eberhart Russell C., Roy W. Dobbins (red.), *Neural Network PC Tools*, Academic Press, London 1990.
- Efron B., *The Jackknife, the Bootstrap and Other Resampling Plans*, SIAM, Philadelphia 1982.
- Elman J.L., „Finding Structure in Time”, *Cognitive Science*, vol. 14, 1980, s. 179–211.
- Elman J.L., David Zipser, „Learning the Hidden Structure of Speech”, *Journal of the Acoustical Society of America*, vol. 83, 1988, s. 1615–1626.
- Elton E., M. Gruber, *Modern Portfolio Theory and Investment Analysis*, wydanie czwarte, John Wiley, New York 1991. Wyd. polskie: *Nowoczesna teoria portfelowa i analiza papierów wartościowych*, WIG-Press, Warszawa 1998.
- Epstein Richard A., *The Theory of Gambling and Statistical Logic*, wydanie zmienione, Academic Press, New York 1977.
- Farmer J. Doyne, John J. Sidorowich, „Predicting Chaotic Time Series”, *Physical Review Letters*, vol. 59, 24 August 1987, s. 845–848.
- Feller William, *An Introduction to Probability Theory and its Applications*, wydanie trzecie, John Wiley, New York 1986.
- Fishman M.B., D.S. Barr, „Using Neural Nets in Market Analysis”, *Technical Analysis of Stocks and Commodities*, vol. 9, no. 4, April 1991, s. 18.
- Fishman M.B., D.S. Barr, „A Hybrid System for Market Timing”, *Technical Analysis of Stocks and Commodities*, vol. 9, no. 8, August 1991, s. 26.

- Freedman Roy S., „AI on Wall Street”, *IEEE Expert*, April 1991, s. 3–9.
- Gabr M.M., T. Subba Rao, „The Estimation and Prediction of Subset Bilinear Time Series Models with Applications”, *Time Series Analysis*, vol. 2, 1981, s. 155–171.
- Goonatilake Susan, Philip Treleaven (red.), *Intelligent Systems for Finance and Business*, John Wiley, Chichester.
- Greising David, Laurie Morse, *Brokers, Bagmen, & Moles*, John Wiley, New York 1991.
- Grossberg S., *Studies of the Mind and Brain*, Reidel Press, Dordrecht 1982.
- Hadady R.E., I.L. Finberg, D. Rahfeld, *Winning with the Insiders*, Weiss Research, West Palm Beach, Florida 1987.
- Hammerstrom Dan, „Working with Neural Networks”, *IEEE Spectrum*, July 1993, s. 43–45.
- Haugen Robert A., Josef Lakonishok, *The Incredible January Effect*, Dow Jones-Irwin, Homewood 1989.
- Hawley D.D., J.D. Johnson, D. Raina, „Artificial Neural Systems: A New Tool for Financial Decision-Making”, *Financial Analysts Journal*, November–December 1990, s. 63.
- Haykin S., *Adaptive Filter Theory*, wydanie drugie, Prentice-Hall, Englewood Cliffs 1991.
- Hebb D.O., *The Organization of Behavior*, Wiley, New York 1949.
- Hecht-Neilsen R., *Neurocomputing*, Addison-Wesley, Menlo Park 1990.
- Henon M., „A Two-Dimensional Map with a Strange Attractor”, *Communications in Mathematical Physics*, vol. 50, 1970, s. 69.
- Hertz John, Anders Krogh, Richard G. Palmer, *Introduction to the Theory of Neural Computation*, Lecture Notes Volume 1, Sante Fe Institute, Addison-Wesley, Redwood City 1991.
- Hirsch Yale, *Don't Sell Stocks on Mondays*, Facts on File Publication, New York 1986.
- Hlawatsch Franz, G. Faye Bordreaux-Bartels, „Linear and Quadratic Time-Frequency Signal Representations”, *IEEE Signal Processing Magazine*, vol. 9, no. 2, April 1992, s. 21–67.
- Howrey E. Philip, „A Spectrum Analysis of the Long-Swing Hypothesis”, *Internal Economic Review*, vol. 9, 1968, s. 228–252.
- Hsieh David A., „Testing for Nonlinear Dependence in Daily Foreign Exchange Rates”, *Journal of Business*, vol. 62, 1989, s. 339–369.
- Hull John, *Options, Futures, and other Derivative Securities*, wydanie drugie, Prentice-Hall, Englewood Cliffs 1993.
- Hush Don R., Bill G. Horne, „Progress in Supervised Neural Networks”, *IEEE Signal Processing Magazine*, vol. 10, no. 1, January 1993, s. 8–39.
- Hutton L., „Using Statistics to Assess the Performance of Neural Network Classifiers”, *Johns Hopkins Applied Physics Lab Technical Digest*, vol. 13, no. 1, 1992.
- Johnson M., *The Random Walk and Beyond*, John Wiley, New York 1988.
- Jolliffe I.T., *Principal Component Analysis*, Springer-Verlag, Berlin 1986.
- Jurik Mark, „The Care and Feeding of a Neural Network”, *Futures*, vol. 21, no. 12, October 1992, s. 40–44.

- Jurik Mark, „Consumer's Guide to Neural Network Software”, *Futures*, vol. 22, no. 8, July 1993, s. 36–42.
- Karlin S., H.M. Taylor, *A First Course in Stochastic Processes*, wydanie drugie, Academic Press, New York 1975.
- Katz Jeffrey Owen, „Developing Neural Network Forecasters for Trading”, *Technical Analysis of Stocks and Commodities*, vol. 10, no. 4, April 1992, s. 58.
- Kaufman Perry J., *The New Commodity Trading Systems and Methods*, John Wiley, New York 1987.
- Kean John, „Using Neural Nets for Intermarket Analysis”, *Technical Analysis of Stocks and Commodities*, vol. 10, no. 11, November 1992, s. 58.
- Kelly J.L., „A New Interpretation of Information Rate”, *Bell System Technical Journal*, vol. 35, 1956, s. 917–926.
- Kendall Maurice, J. Keith Ord, *Time Series*, wydanie trzecie, Edward Arnold, Sevenoaks, Kent 1993.
- Kindleberger C.P., *Manias, Panics and Crashes*, Basic Books, New York 1978. Wyd. polskie: *Szaleństwo, panika, krach. Historia kryzysów finansowych*, WIG-Press, Warszawa 1999.
- Klimasaukas Casey, „Neural Nets and Noise Filtering”, *Dr Dobb's Journal*, January 1989, s. 32–48.
- Knight Sheldon, „Tips, Tricks and Tactics for Developing Trading Systems”, *Futures*, vol. 22, no. 1, January 1993, s. 38–40.
- Koeckelenberger Andre, Sunspot Index Data Center, 3 Avenue Circulaire, 1180, Bruxelles, Belgium.
- Kohonen T., *Self Organization and Associative Memory*, wydanie drugie, Springer-Verlag, Berlin 1987, wydanie trzecie, 1989.
- Kolb Robert W., *Options: The Investor's Complete Toolkit*, New York Institute of Finance, New York 1991.
- Kolmogorov A., *Foundations of the Theory of Probability*, Trans. N. Morrison, New York, Chelsea 1956.
- Korenberg Michael J., Larry D. Paarmann, „Orthogonal Approaches to Time Series Analysis and System Identification”, *IEEE Signal Processing Magazine*, vol. 8, no. 3, July 1991, s. 29–43.
- Kosko Bart, *Neural Networks and Fuzzy Systems*, Prentice-Hall, Englewood Cliffs 1992.
- Kurkova Vera, „Kolmogorov's Theorem Is Relevant”, *Neural Computation*, vol. 3, 1991, s. 617–622.
- Lashonishok Josef, Edwin Maberly, „The Weekend Effect: Trading Patterns of Individual and Institutional Investors”, *Journal of Finance*, vol. 45, no. 1, March 1990, s. 231–243.
- Lang K., M. Whitbrock, „Learning to Tell Two Spirals Apart”, *Proceedings of the 1988 Connectionist Models Summer School*.
- Lapedes Alan, Rober Farber, „Nonlinear Signal Processing Using Neural Networks, Prediction and System Modelling”, Los Alamos Report LA-UR-87-2662, Los Alamos National Laboratory, Los Alamos, NM 1987.
- Larrain Maurice, „Testing Chaos and Nonlinearities in T-Bill Rates”, *Financial Analysts Journal*, vol. 47, no. 5, September–October 1991, s. 51–62.

- Le Cun, Yann, John S. Denker, Sara A. Solla, „Optimal Brain Damage”, w: D. S. Touretzky (red.), *Advances in Neural Information Processing Systems 2*, Morgan Kaufmann, San Mateo, CA 1990, s. 598–605.
- Li J., A.N. Michel, W. Porod, „Analysis and Synthesis of a Class of Neural Networks: Linear Systems Operating on a Closed Hypercube”, *IEEE Transactions on Circuits and Systems*, vol. 36, no. 11, November 1989, s. 1405–1422.
- Lipmann R.P., „An Introduction to Computing with Neural Nets”, *IEEE ASSP Magazine*, April 1987, s. 4–22.
- Lorenz H.W., *Nonlinear Dynamical Economics and Chaotic Motion*, Lecture Notes In Economics and Mathematical Systems No. 334, Springer Verlag, Berlin 1989.
- Luenberger D.G., *Introduction to Linear & Nonlinear Programming*, Addison-Wesley, Reading, MA 1973.
- Lutzy Ottmar, Andreas Dengel, „A Comparison of Neural Net Simulators”, *IEEE Expert*, August 1993, s. 43–51.
- Mackay C., *Extraordinary Popular Delusions and Madness of Crowds*, Noonday Press, New York 1974. Wyd. polskie: *Niezwykłe złudzenia i szaleństwa tłumów*, WIG-Press, Warszawa 1999.
- Maren Alianna, Craig Harston, Robert Pap, *Handbook of Neural Net Computing Applications*, Academic Press, London 1990.
- Markowitz Harry, *Portfolio Selection: Efficient Diversification of Investments*, John Wiley, New York 1964.
- Marple S. Lawrence Jr., *Digital Spectral Analysis*, Prentice-Hall, Englewood Cliffs, NJ 1987.
- Masters Timmothy, *Practical Neural Network Recipes in C++*, Academic Press, Orlando, FL 1993.
- Mathews V. John, „Adaptive Polynomial Filters”, *IEEE Signal Processing Magazine*, vol. 8, no. 3, July 1991, s. 10–26.
- McClelland James L., David E. Rumelhart, PDP Research Group, *Parallel Distributed Processing, Vol. 2: Psychological and Biological Models*, MIT Press, Cambridge, MA 1986.
- McClelland James L., David E. Rumelhart, *Explorations in Parallel Distributed Processing*, MIT Press, Cambridge, MA 1988.
- McClish D.K., „Comparing the Areas Under More than Two Independent ROC Curves”, *Medical Decision Making*, vol. 7, 1987, s. 149–155.
- McCulloch W.S., W.H. Pitts, „A Logical Calculus of Ideas Immanent in Nervous Activity”, *Bulletin of Mathematical Biophysics*, vol. 5, 1943, s. 115–133.
- McQueen G., S. Thorley, „Are Stock Returns Predictable? A Test Using Markov Chains”, *Journal of Finance*, vol. 46, no. 1, March 1990, s. 239.
- Mead W.C. i in., „Prediction of Chaotic Time Series Using CNLS-NET-Example: The Mackey-Glass Equation”, *Nonlinear Modeling and Forecasting*, s. 39–72.
- Miller R.M., *Computer-Aided Financial Analysis*, Addison-Wesley, Reading, MA 1990.
- Miller W.T., R.S. Sutton, P. Werbos, *Neural Networks for Robotics and Control*, MIT Press, Cambridge, MA 1990.

- Minsky Marvin L., Seymour A. Papert, *Perceptrons*, wydanie rozszerzone, MIT Press, Cambridge, MA 1988.
- Muller Berndt, Joachim Reinhardt, *Neural Networks: An Introduction*, Springer-Verlag, New York 1990.
- Murphy John J., *Technical Analysis of Futures Markets*, New York Institute of Finance, New York 1986. Wyd. polskie: *Analiza techniczna*, WIG-Press, Warszawa 1995.
- Newbold Paul, *Statistics for Business and Economics*, wydanie drugie, Prentice-Hall, Englewood Cliffs, NJ 1988.
- Nguyen D., B. Widrow, „The truck backer-upper: an example of self-learning in neural networks”, *International Joint Conference of Neural Networks*, vol. 2, July 1989, s. 357–363.
- Nguyen D., B. Widrow, „Improving the learning speed of 2-layer neural networks by choosing initial values of the adaptive weights”, *International Joint Conference of Neural Networks*, vol. 3, July 1990, s. 21–26.
- Nishikawa Y., H. Kita, A. Kawamura, „NN/I: A Neural Network Which Divides and Learns Environments, I-684 to I-687”, *Proceedings of the International Joint Conference on Neural Networks*, January 1990.
- NYIF, *Futures: A Personal Seminar*, New York Institute of Finance, New York 1989.
- O'Reilly Brian, „Computers That Think Like People”, *Fortune*, 27 February 1989, s. 58–61.
- Orfanidis Sophocles J., „Gram-Schmidt Neural Nets”, *Neural Computation*, vol. 2, 1990, s. 116–126.
- Owens A.J., D.L. Filkin, „Efficient Training of the Backpropagation Network by Solving a Stiff Ordinary Differential Equations”, *Proc. IJCNN*, vol. 2, Washington 1989, s. 381–386, IEEE, New York 1989.
- Pardo Robert, *Design, Testing and Optimisation of Trading Systems*, John Wiley, New York 1992.
- Parkett D.B., „LE Learning Logic”, *Technical Report TR-47*, Center for Computational Research in Economics and Management Science, MIT Press, Cambridge, MA 1985.
- Pau L.F., „Artificial Intelligence and Financial Services”, *IEEE Trans. Knowledge and Data Engineering*, vol. 3, 1991, s. 137–148.
- Peters Edgar E., *Chaos and Order in the Capital Markets*, John Wiley, New York 1991. Wyd. polskie: *Teoria chaosu a rynki kapitałowe*, WIG-Press, Warszawa 1997.
- Poulos E. Michael, „Futures According to Trend Tendency”, *Technical Analysis of Stocks and Commodities*, vol. 10, no. 1, January 1992, s. 61.
- Press William H., Saul A. Teukolsky, William T. Vetterling, Brian P. Flannery, *Numerical Recipes*, wydanie drugie, Cambridge University Press, Cambridge 1992.
- Priestley Maurice B., *Spectral Analysis and Time Series Analysis*, Academic, London 1988.
- Refenes A.N. i in., „Currency Exchange Rate Prediction and Neural Network Design Strategies”, *Neural Computing & Applications*, vol. 1, 1993, s. 46–58.

- Resinkoff H.L., „Foundations of Arithmetic Analysis: Compactly Supported Wavelets and the Wavelet Group”, Aware Report AD890507.1, Aware Inc., One Memorial Drive, Cambridge, MA 1989.
- Rioul Oliver, Martin Vetterli, „Wavelets and Signal Processing”, *IEEE Signal Processing Magazine*, vol. 8, no. 4, October 1991, s. 14–38.
- Rissanen J., *Stochastic Complexity in Statistical Inquiry*, World Scientific, Singapore 1989.
- Rosenblatt F., *Principles of Neurodynamics*, Sparten Press, Washington 1961.
- Ruelle David, „Deterministic Chaos, the Science and the Fiction”, *Proceedings of the Royal Society of London A*, vol. 427, 1990, s. 241–248.
- Rumelhart D.E., G.E. Hinton, R.J. Williams, „Learning Representations by Backpropagating Errors”, *Nature*, vol. 323, 1986, s. 533–536.
- Rumelhart D.E., G.E. Hinton, R.J. Williams, „Learning Internal Representations by Error Propagation”, *Parallel Data Processing*, vol. 1, rozdz. 8, MIT Press, Cambridge, MA 1986.
- Rumelhart D., J. McClelland, *Parallel Distribution Processing*, MIT Press, Cambridge, MA 1986.
- Rutherford Janette, *Introduction to Stock Exchange Investment*, Macmillan, London 1985.
- Savit Robert, „Chaos on the Trading Floor”, *New Scientist*, 11 August 1990, s. 48.
- Schiller Robert J., *Market Volatility*, MIT Press, Cambridge, MA 1989.
- Schmerken I., „Wall Street’s Elusive Goal, Computers that Think Like Pros”, *Wall Street Computer Review*, vol. 7, June 1990, s. 61–69.
- Schwager Jack D., *A Complete Guide to the Futures Markets*, John Wiley, New York 1984.
- Schwager Jack D., „Selecting the Best Futures Price Series for Computer Testing”, *Technical Analysis of Stocks and Commodities*, vol. 10, no. 10, October 1992, s. 65–71.
- Schetzen M., *The Volterra and Wiener Theory of Nonlinear Systems*, John Wiley, New York 1980.
- Shanno David F., „Conjugate Gradient Methods with Inexact Searches”, *Mathematics of Operations Research*, vol. 3, 1978, s. 244–256.
- Shanno D.F., Phua Kang-Hoh, „Matrix Conditioning and Nonlinear Optimisation”, *Mathematical Programming*, vol. 14, 1978, s. 149–160.
- Shih Yin Lung, „Neural Nets in Technical Analysis”, *Technical Analysis of Stocks and Commodities*, vol. 9, no. 2, February 1991, s. 62.
- Simpson P., *Artificial Neural Systems*, Pergamon Press, New York 1990.
- Siu S., C.F.N. Cowan, „Adaptive Equalization Using the Back Propagation Algorithm”, *Proceedings of the Second International Artificial Neural Networks Conference*, Bournemouth 1991, IEE, London 1991, s. 10–12.
- Sluis A. van der, H.A. van der Vorst, „The Rate of Convergence of Conjugate Gradients”, *Numerical Mathematics*, vol. 48, 1986, s. 543–560.
- Specht D., „Probabilistic Neural Networks for Classification, Mapping, or Associative Memory”, *Proceedings of the IEEE International Conference on Neural Networks*, 1, 1988, s. 525–532.
- Specht D., „Probabilistic Neural Networks”, *Neural Networks*, 3, 1990, s. 109–118.

- Specht D., P. Shapiro, „Generalization Accuracy of Probabilistic Neural Networks Compared with Back-Propagation Networks”, *Proceedings of the International Joint Conference on Neural Networks*, July 8–12, 1, 1991, s. 887–892.
- Specht D., „A General Regression Neural Network”, *IEEE Transactions on Neural Networks*, 2, 6, November 1991, s. 568–576.
- Stockbro Kurt, D.K. Umberger, „Forecasting with Weighted Maps”, *Nonlinear Modeling Forecasting*, s. 73–94.
- Sugihara George, Robert May, „Nonlinear Forecasting as a Way of Distinguishing Chaos from Measurement Error in Time Series”, *Nature*, vol. 344, 19 April 1990, s. 734–741.
- Swales George S. Jr., Young Yoon, „Applying Artificial Neural Networks to Investment Analysis”, *Financial Analysts Journal*, vol. 48, no. 5, September–October 1992.
- Takens F., „Detecting Strange Attractor in Turbulence”, w: D. Rand, L. Young (red.), *Lecture Notes in Mathematics*, Springer, Berlin 1981.
- Taylor S.J., *Modeling Financial Time Series*, John Wiley, Chichester 1986, przedruk 1994.
- Teweles R.J., F.J. Jones, *The Futures Game*, wydanie drugie, McGraw-Hill, New York 1987.
- Thompson J.M.T., H.B. Stewart, *Nonlinear Dynamics and Chaos*, John Wiley, Chichester 1986.
- Thorp Edward O., *The Mathematics of Gambling*, Gambling Times Press, Van Nuys, CA 1984.
- Thorp Edward O., Sheen T. Kassouf, *Beat the Market: A Scientific Stock Market System*, Random House, New York 1967.
- Tong Howell, *Nonlinear Time Series: A Dynamical System Approach*, Oxford University Press, Oxford 1990.
- Tong Howell, K.S. Kim, „Threshold Autoregression, Limit Cycles and Cyclical Data”, *Journal of the Royal Statistical Society*, vol. B42, 1980, s. 245–292.
- Touretzky D., D. Pomerleau, *What’s Hidden in the Hidden Layers*, Byte 14, 1989, s. 227–233.
- Vaga Tonis, „The Coherent Market Hypothesis”, *Financial Analysts Journal*, vol. 46, no. 6, November–December 1990, s. 36–49.
- Vince Ralph, *Portfolio Management Formulas*, John Wiley, New York 1990.
- Vince Ralph, *The Mathematics of Money Management*, John Wiley, New York 1992.
- Vogel T.P., J.K. Mangis, A.K. Rigler, W.T. Zink, D.L. Alkon, „Accelerating the Convergence of the Backpropagation Method”, *Biological Cybernetics*, vol. 59, 1988, s. 257–263.
- Wallich Paul, „Wavelet Theory: An Analysis Technique That’s Creating Ripples”, *Scientific American*, January 1991, s. 34–35.
- Wasserman P., *Neural Computing. Theory and Practice*, Van Nostrand Reinhold, New York 1989.
- Weigend Andreas S., Bernardo A. Huberman, David E. Rumelhart, „Generalisation by Weight-Elimination with Application to Forecasting”, w: Richard P. Lippman, John E. Moody, David S. Touretzky (red.),

- Advances in Neural Information Processing Systems 3*, Morgan Kaufmann, San Mateo, CA 1991, s. 875–882.
- Weigend Andreas S., Bernardo A. Huberman, David E. Rumelhart, „Predicting Sunspots and Exchange Rates with Connectionist Networks”, *Nonlinear Modeling and Forecasting*, s. 395–432.
- Weigend Andreas S., Bernardo A. Huberman, David E. Rumelhart, „Back-propagation, Weight-Elimination and Time Series Prediction”, w: D.S. Touretzky i in. (red.), *Connectionist Models, Proceedings of the 1990 Summer School*, Morgan Kaufmann, San Mateo, CA 1991.
- Weiss Sholom M., Casimer A. Kulikowski, *Computer Systems That Learn*, Morgan Kaufmann, San Mateo, CA 1991.
- Werbos P., „Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences”, praca doktorska, Harvard University 1974.
- White H., „Economic Prediction Using Neural Networks, The Case of IBM Daily Stock Returns”, *Proceedings of the IEEE International Conference on Neural Networks*, vol. 2, IEEE, New York 1988, s. 451–458.
- Widrow B., S.D. Sterns, *Adaptive Signal Processing*, Prentice-Hall, New York 1985.
- Wong F.S. i in., „Fuzzy Neural Systems for Stock Selection”, *Financial Analysts Journal*, vol. 48, no. 1, January–February 1992, s. 47–52.
- Zaremba Thomas, „Technology in Search of a Buck”, rozdz. 12 w: *Neural Network PC Tools*.
- Ziemba William T., „A Better Simulation: The Mathematics of Gambling”, *Gambling Times*, June 1987.

BIBLIOGRAFIA POLSKA

- Hertz J., A. Krogh, R.G. Palmer, *Wstęp do teorii obliczeń neuronowych*, WNT, Warszawa 1993.
- Kacprzak T., K. Ślot, *Sieci neuronowe komórkowe*, PWN 1994.
- Korbicz J., A. Obuchowicz, D. Uciński, *Sztuczne sieci neuronowe*, Akademicka Oficyna Wydawnicza PLJ, Warszawa 1994.
- Osowski S., *Sieci neuronowe*, Oficyna Wydawnicza Politechniki Warszawskiej 1995.
- Osowski S., *Sieci neuronowe w ujęciu algorytmicznym*, WNT, Warszawa 1996.
- Rutkowska D., *Inteligentne systemy obliczeniowe*, Akademicka Oficyna Wydawnicza PLJ, Warszawa 1995.
- Tadeusiewicz R., *Elementarne wprowadzenie do techniki sieci neuronowych z przykładowymi programami*, Akademicka Oficyna Wydawnicza PLJ, Warszawa 1998.
- Tadeusiewicz R., *Sieci neuronowe*, Akademicka Oficyna Wydawnicza RM, Warszawa 1993.
- Żurada J., M. Barski, W. Jędruch, *Sztuczne sieci neuronowe*, Wydawnictwo Naukowe PWN, Warszawa 1996.